

Pauta de Corrección

Sistemas Recomendadores - Interrogación 2

Todas las preguntas valen 1 punto. La escala sugerida por pregunta es: 0, 0.25, 0.5, 0.75 y 1.0 puntos. Una respuesta puede recibir puntaje completo aunque no use exactamente las mismas palabras de la pauta, siempre que exprese correctamente la idea central.

Criterio general

Puntaje	Criterio
1.0	Respuesta correcta, precisa y completa.
0.75	Respuesta correcta, pero con una omisión menor.
0.5	Respuesta parcialmente correcta; reconoce la idea central, pero falta una parte importante.
0.25	Respuesta muy vaga; menciona términos relevantes, pero sin explicar bien.
0	Respuesta incorrecta, contradictoria o no responde la pregunta.

1. UserKNN / ItemKNN

Pregunta: Explique la diferencia principal entre calcular vecinos en UserKNN y en ItemKNN. ¿Qué representa la similitud en cada caso?

Respuesta esperada: UserKNN calcula similitud entre usuarios según sus interacciones o ratings. ItemKNN calcula similitud entre ítems según los usuarios que los consumieron/evaluaron o los patrones de interacción. En UserKNN los vecinos son usuarios; en ItemKNN los vecinos son ítems.

Puntaje	Criterio
1.0	Distingue correctamente UserKNN e ItemKNN y explica qué representa la similitud en ambos casos.
0.75	Distingue ambos métodos, pero explica de forma incompleta la similitud.
0.5	Menciona que uno compara usuarios y otro ítems, pero sin explicar según qué información.
0.25	Menciona KNN o vecinos, pero de forma muy vaga.
0	Confunde completamente los métodos.

2. FunkSVD

Pregunta: En FunkSVD, ¿qué representan los vectores latentes de usuarios e ítems, y cómo se usan para predecir un rating?

Respuesta esperada: Los vectores latentes representan preferencias del usuario y características latentes del ítem. El rating se predice mediante el producto punto entre ambos vectores, es decir, comparando qué tan alineadas están las preferencias del usuario con las características del ítem.

Puntaje	Criterio
1.0	Explica correctamente qué representan los vectores latentes de usuarios e ítems y menciona que la predicción se obtiene mediante producto punto.
0.75	Explica correctamente la idea de vectores latentes y predicción, pero sin describir con claridad el producto punto.
0.5	Menciona embeddings o factores latentes de usuarios e ítems, pero no explica bien cómo se usan para predecir.
0.25	Menciona vectores o representación latente de forma muy vaga.
0	Respuesta incorrecta o confunde FunkSVD con KNN, FM u otro método.

3. Implicit Feedback

Pregunta: En un sistema con clicks, compras y visualizaciones, ¿por qué la ausencia de interacción no debe interpretarse directamente como preferencia negativa?

Respuesta esperada: Porque que un usuario no interactúe con un ítem no significa que no le guste; puede no haberlo visto. En implicit feedback, las interacciones observadas son señales positivas, mientras que las no observadas son inciertas.

Puntaje	Criterio
1.0	Explica claramente que ausencia no implica desagrado y menciona incertidumbre/no exposición.
0.75	Explica que ausencia no es preferencia negativa, pero no profundiza en la razón.
0.5	Menciona que clicks/compras son señales positivas, pero no explica bien los no observados.
0.25	Respuesta vaga sobre 'faltan datos'.
0	Afirma que no interacción equivale a rating negativo.

4. Implicit Feedback y Ranking

Pregunta: Compare brevemente ALS para implicit feedback y Bayesian Personalized Ranking. ¿Qué tipo de objetivo intenta optimizar cada uno?

Respuesta esperada: ALS para implicit feedback optimiza una reconstrucción ponderada de preferencias usando niveles de confianza. BPR optimiza un objetivo de ranking pareado, buscando que ítems observados/preferidos queden por sobre ítems no observados.

Puntaje	Criterio
1.0	Compara ambos correctamente: ALS como reconstrucción ponderada/confianza y BPR como ranking pareado.
0.75	Explica bien ambos, pero con poca precisión técnica.
0.5	Describe correctamente solo uno de los dos métodos.
0.25	Menciona ALS/BPR sin explicar el objetivo.
0	Los confunde completamente o da una respuesta irrelevante.

5. Métricas

Pregunta: Un modelo obtiene buen RMSE al predecir ratings, pero sus recomendaciones Top-10 no son útiles. ¿Por qué puede ocurrir esto y qué métrica usaría para evaluar mejor el ranking?

Respuesta esperada: Puede ocurrir porque RMSE mide error de predicción de ratings, no necesariamente la calidad del ranking Top-K. Para evaluar ranking conviene usar métricas como NDCG@10, Recall@10, Precision@10, MAP@10 o MRR@10.

Puntaje	Criterio
1.0	Explica la limitación del RMSE y propone una métrica Top-K adecuada.
0.75	Identifica que RMSE no mide ranking, pero la métrica propuesta es poco justificada.
0.5	Propone una métrica de ranking, pero no explica bien por qué RMSE falla.
0.25	Menciona métricas sin distinguir predicción vs ranking.
0	Responde con otra métrica de error como MAE/MSE sin justificar ranking.

6. Máquinas de Factorización

Pregunta: En un sistema de e-commerce se tienen features de usuario, ítem, categoría, precio y dispositivo. ¿Cómo aprovecha una Factorization Machine esta información para hacer recomendaciones?

Respuesta esperada: Una Factorization Machine representa cada feature con un vector latente y aprende interacciones entre pares de features. Así puede capturar relaciones como usuario-ítem, usuario-categoría, ítem-precio o dispositivo-ítem para estimar la preferencia o probabilidad de interacción.

Puntaje	Criterio
1.0	Menciona que cada feature se representa con un vector latente y que el modelo aprende interacciones entre pares de features.
0.75	Explica que la FM usa múltiples features y sus interacciones, pero no explicita claramente la representación latente.

0.5	Reconoce que la FM combina features de usuario, ítem y contexto para predecir/recomendar, pero no explica el mecanismo de interacción entre features.
0.25	Menciona features o contexto, pero sin explicar cómo se aprovechan en el modelo.
0	Respuesta incorrecta o confunde FM con un modelo que solo usa usuario-ítem sin side information.

7. Máquinas de Factorización / DeepFM

Pregunta: Explique brevemente qué aporta DeepFM respecto de una Factorization Machine tradicional.

Respuesta esperada: DeepFM combina una parte FM, que captura interacciones de bajo orden, con una red profunda, que aprende interacciones no lineales y de mayor orden entre features.

Puntaje	Criterio
1.0	Menciona correctamente combinación FM + red profunda, bajo orden + alto orden/no linealidad.
0.75	Explica que agrega una red profunda, pero no distingue bajo/alto orden.
0.5	Dice que DeepFM es 'más expresivo' sin explicar por qué.
0.25	Menciona Deep Learning de forma genérica.
0	Respuesta incorrecta o confunde DeepFM con MultiVAE/NCF.

8. Deep Learning

Pregunta: ¿Qué ventaja tiene un modelo deep como NCF o MultiVAE frente a una factorización matricial lineal?

Respuesta esperada: Los modelos deep pueden capturar relaciones no lineales y patrones más complejos que una factorización lineal. Además, pueden aprender representaciones más expresivas de usuarios, ítems o historiales de interacción.

Puntaje	Criterio
1.0	Menciona no linealidad, mayor expresividad y/o patrones complejos.
0.75	Menciona mayor capacidad del modelo, pero con poca precisión.
0.5	Compara con MF, pero de forma incompleta.
0.25	Dice solo que 'es más avanzado' o 'usa redes'.
0	Respuesta incorrecta o no relacionada.

9. Recomendación Secuencial

Pregunta: Una app de música quiere recomendar la siguiente canción considerando canciones escuchadas recientemente. ¿Por qué GRU4Rec sería adecuado?

Respuesta esperada: GRU4Rec modela secuencias de interacciones y captura dependencias temporales dentro de una sesión. Es adecuado para predecir el próximo ítem considerando el contexto reciente del usuario.

Puntaje	Criterio
1.0	Menciona secuencia, orden temporal y predicción del próximo ítem.
0.75	Menciona que usa historial reciente, pero no explica claramente el orden temporal.
0.5	Dice que usa canciones anteriores, pero no conecta con modelo secuencial.
0.25	Menciona GRU/RNN de forma vaga.
0	Propone un modelo no secuencial sin justificar.

10. Reinforcement Learning / Bandidos

Pregunta: ¿Por qué RL o bandidos pueden ser útiles en recomendación online? Explique exploración-explotación.

Respuesta esperada: Son útiles porque permiten adaptar recomendaciones mientras el usuario interactúa con el sistema. La explotación recomienda ítems que se sabe que funcionan bien; la exploración prueba ítems menos conocidos para aprender nuevas preferencias.

Puntaje	Criterio
---------	----------

1.0	Explica utilidad online y define correctamente exploración y explotación.
0.75	Explica exploración-explotación, pero no conecta bien con recomendación online.
0.5	Menciona adaptación o exploración, pero de forma incompleta.
0.25	Menciona RL/bandidos sin explicar el trade-off.
0	Respuesta incorrecta o confunde con aprendizaje supervisado offline.

11. GNN

Pregunta: En un grafo usuario-ítem, ¿qué aporta una GNN como GraphSAGE para aprender representaciones útiles?

Respuesta esperada: Una GNN permite propagar y agregar información desde los vecinos del grafo. GraphSAGE aprende embeddings de usuarios e ítems usando sus conexiones, lo que permite capturar estructura colaborativa y relaciones de vecindad.

Puntaje	Criterio
1.0	Menciona grafo, vecinos/agregación y embeddings útiles para recomendación.
0.75	Menciona propagación de información, pero no explica bien el rol de los vecinos.
0.5	Dice que aprende embeddings en grafos, pero sin mayor detalle.
0.25	Menciona grafos de forma muy general.
0	Respuesta incorrecta o no relacionada con GNN.

12. FAccT

Pregunta: El sistema muestra casi siempre ítems de proveedores populares, dejando poca exposición a proveedores pequeños. ¿Qué problema FAccT aparece y qué debería evaluarse?

Respuesta esperada: Aparece un problema de fairness/exposición desigual, especialmente desde el lado de proveedores o productores. Debería evaluarse si ciertos grupos reciben sistemáticamente menor visibilidad, menor exposición o menores oportunidades de ser recomendados.

Puntaje	Criterio
1.0	Identifica fairness/exposición desigual y menciona evaluación por grupos/proveedores.
0.75	Identifica sesgo hacia populares, pero no lo conecta claramente con fairness/exposición.
0.5	Menciona popularidad o sesgo, pero sin explicar qué evaluar.
0.25	Respuesta vaga sobre 'injusticia' sin aterrizarla.
0	No identifica problema FAccT.

13. Métricas: diversidad y novedad

Pregunta: Además de evaluar predicción de ratings o ranking, ¿cómo se pueden calcular diversidad y novedad según lo visto en la Tarea 1? Explique qué aporta cada una.

Respuesta esperada: La diversidad puede calcularse midiendo qué tan distintos son los ítems recomendados entre sí, por ejemplo usando distancia o disimilitud entre ítems de la lista. La novedad puede calcularse penalizando ítems muy populares o premiando ítems menos conocidos. Diversidad mide variedad; novedad mide capacidad de descubrimiento.

Puntaje	Criterio
1.0	Explica cómo calcular ambas y qué aporta cada una.
0.75	Explica correctamente diversidad y novedad, pero una de las dos queda poco operacionalizada.
0.5	Define ambas de forma intuitiva, pero sin decir cómo calcularlas.
0.25	Menciona solo una de las dos correctamente.
0	Confunde diversidad/novedad con precisión, RMSE o ranking.

14. SASRec / GRU4Rec

Pregunta: Explique por qué SASRec suele obtener mejor rendimiento que GRU4Rec en recomendación secuencial. ¿Qué característica permite mejorar el modelamiento de la secuencia?

Respuesta esperada: SASRec usa self-attention, lo que permite ponderar directamente distintas interacciones pasadas y capturar dependencias relevantes dentro de la secuencia. A diferencia de GRU4Rec, no depende solo del procesamiento recurrente paso a paso, por lo que puede modelar mejor relaciones de largo alcance.

Puntaje	Criterio
1.0	Menciona self-attention y explica que permite capturar dependencias relevantes/largo alcance mejor que GRU.
0.75	Menciona attention y mejor modelamiento de secuencia, pero con explicación incompleta.
0.5	Dice que SASRec es mejor porque usa Transformer/attention, pero no explica el beneficio.
0.25	Menciona diferencias generales entre modelos, pero sin precisión.
0	Respuesta incorrecta o afirma que SASRec y GRU4Rec son equivalentes.

Resumen de puntaje

Total: 14 puntos. Cada pregunta vale 1 punto. Se recomienda corregir con la escala 0, 0.25, 0.5, 0.75 y 1.0, priorizando la comprensión conceptual y no la memorización literal.