

Pontificia Universidad Católica de Chile
Escuela de Ingeniería — Departamento de Ciencia de la Computación

IIC3633 — Sistemas Recomendadores

Interrogación 2 — PAUTA Y RÚBRICA

Semestre 2026-1 | Tiempo: 90 minutos | Puntaje total: 62 puntos

USO EXCLUSIVO DOCENTES — NO DISTRIBUIR

1. Factorización Matricial — FunkSVD

[12 pts]

Considera una factorización en espacio latente de dimensión $k = 2$. Los valores iniciales son $\mathbf{p}_u = [0,6 \ 0,4]$ y $\mathbf{q}_i = [0,3 \ 0,8]$, el rating real es $r_{ui} = 5$, la tasa de aprendizaje $\alpha = 0,01$ y la regularización $\lambda = 0,02$.

- (a) **[3 pts]** Calcula la predicción $\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i$ y el error $e_{ui} = r_{ui} - \hat{r}_{ui}$.

$$\begin{aligned}\hat{r}_{ui} &= (0,6)(0,3) + (0,4)(0,8) = 0,18 + 0,32 = \mathbf{0,50} \\ e_{ui} &= 5 - 0,50 = \mathbf{4,50}\end{aligned}$$

Criterio de corrección:

2 pts Producto punto correcto ($\hat{r} = 0,50$) y error correcto ($e = 4,50$).
1 pt Fórmula correcta con error aritmético menor.
0 pts Fórmula incorrecta.

- (b) **[4 pts]** Escribe las reglas de actualización SGD para $\mathbf{p}_u$ y $\mathbf{q}_i$ derivadas de $\mathcal{L} = e_{ui}^2 + \lambda(\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2)$.

$$\begin{aligned}\mathbf{p}_u &\leftarrow \mathbf{p}_u + \alpha(e_{ui} \mathbf{q}_i - \lambda \mathbf{p}_u) \\ \mathbf{q}_i &\leftarrow \mathbf{q}_i + \alpha(e_{ui} \mathbf{p}_u - \lambda \mathbf{q}_i)\end{aligned}$$

Derivadas: $\partial \mathcal{L} / \partial \mathbf{p}_u = -2e_{ui} \mathbf{q}_i + 2\lambda \mathbf{p}_u$ (ascenso negado para minimizar, factor 2 absorbido en α).

Criterio de corrección:

4 pts Ambas reglas correctas con signo de regularización correcto.
2 pts Una regla correcta, o ambas con error de signo en la regularización.
1 pt Estructura correcta pero falta el término λ .
0 pts Reglas incorrectas o no presentadas.

- (c) **[5 pts]** Aplica *una* iteración y reporta los nuevos $\mathbf{p}_u$ y $\mathbf{q}_i$ (componente a componente).

Con $e_{ui} = 4,50$:

Actualización de $\mathbf{p}_u$:

$$\begin{aligned}p_u[0] &\leftarrow 0,6 + 0,01(4,50 \times 0,3 - 0,02 \times 0,6) = 0,6 + 0,01(1,35 - 0,012) = 0,6 + 0,01338 \approx \mathbf{0,6134} \\ p_u[1] &\leftarrow 0,4 + 0,01(4,50 \times 0,8 - 0,02 \times 0,4) = 0,4 + 0,01(3,60 - 0,008) = 0,4 + 0,03592 \approx \mathbf{0,4359}\end{aligned}$$

Actualización de q_i :

$$q_i[0] \leftarrow 0,3 + 0,01 (4,50 \times 0,6 - 0,02 \times 0,3) = 0,3 + 0,01 (2,70 - 0,006) = 0,3 + 0,02694 \approx \mathbf{0,3269}$$

$$q_i[1] \leftarrow 0,8 + 0,01 (4,50 \times 0,4 - 0,02 \times 0,8) = 0,8 + 0,01 (1,80 - 0,016) = 0,8 + 0,01784 \approx \mathbf{0,8178}$$

Criterio de corrección:

- 5 pts Cálculo completo y correcto para los 4 componentes (se acepta redondeo razonable).
- 3-4 pts Proceso correcto con un error aritmético o error propagado de (a)/(b).
- 1-2 pts Intento parcial con errores en más de la mitad de los componentes.
- 0 pts No aplica el SGD o valores incorrectos sin justificación.

2. Feedback Implícito — ALS / WMF

[12 pts]

En Weighted Matrix Factorization (WMF), el vector de usuario se obtiene con:

$$\mathbf{x}_u = (\mathbf{Y}^\top \mathbf{C}^u \mathbf{Y} + \lambda \mathbf{I})^{-1} \mathbf{Y}^\top \mathbf{C}^u \mathbf{p}(u)$$

- (a) [4 pts] Define formalmente $\mathbf{C}^u$ y $\mathbf{p}(u)$ y explica cómo se construyen desde datos de feedback implícito.

$\mathbf{p}(u)$: vector binario de tamaño $|I|$ con $p_{ui} = 1$ si el usuario u ha interactuado al menos una vez con el ítem i , $p_{ui} = 0$ en caso contrario. Representa la *preferencia binaria* inferida.

$\mathbf{C}^u$: matriz diagonal de tamaño $|I| \times |I|$ con entradas $c_{ui} = 1 + \alpha r_{ui}$, donde r_{ui} es el conteo de interacciones (reproducciones, clics, tiempo de visualización, etc.) y α escala la confianza. Para ítems no vistos, $c_{ui} = 1$ (confianza mínima no nula). El sistema confía más en preferencias con mayor número de interacciones.

Criterio de corrección:

2 pts Definición correcta de $\mathbf{p}(u)$ (binario, basado en interacción).

2 pts Definición correcta de $\mathbf{C}^u$ (diagonal, proporcional a conteo, confianza mínima para no-vistos).

- (b) [4 pts] ¿Por qué ALS permite solución de forma cerrada mientras FunkSVD usa SGD?

ALS alterna entre dos subproblemas: fijando $\mathbf{Y}$, optimizar $\mathbf{X}$; y viceversa. Con $\mathbf{Y}$ fijo, la función de pérdida de WMF es **cuadrática en $\mathbf{x}_u$** (problema de mínimos cuadrados ponderados), lo que tiene solución analítica exacta.

En FunkSVD, el modelo se actualiza ítem por ítem sobre las entradas observadas; el SGD es conveniente porque solo se itera sobre los pares (u, i) con rating. En WMF se deben considerar *todos* los ítems (observados y no observados) para el esquema de confianza, por lo que resolver la forma cerrada — apoyado en el lema de inversión de matrices para hacerlo eficiente — es preferible.

Criterio de corrección:

2 pts Menciona la cuadraticidad del subproblema $\Rightarrow$ forma cerrada.

2 pts Explica por qué en WMF hay que considerar todos los ítems (no solo los observados).

- (c) [4 pts] ¿Qué problema existe al tratar no-interacciones como negativos directos? ¿Cómo lo aborda WMF?

Problema: la ausencia de interacción es ambigua: el usuario puede desconocer el ítem, no haberlo encontrado, o genuinamente no gustarlo. Tratar todas las no-interacciones como negativos introduce ruido masivo y sesga el modelo hacia ítems populares.

Solución de WMF: asigna $p_{ui} = 0$ (preferencia nula) a las no-interacciones pero con confianza baja ($c_{ui} = 1$), mientras que las interacciones observadas reciben alta confianza ($c_{ui} = 1 + \alpha r_{ui} \gg 1$). El modelo es penalizado levemente por recomendar ítems no vistos, pero fuertemente por *no* recomendar ítems con muchas interacciones.

Criterio de corrección:

2 pts Identifica la ambigüedad de la ausencia de interacción.

2 pts Explica el mecanismo de confianza diferenciada de WMF.

3. Feedback Implícito — BPR

[10 pts]

- (a) [3 pts] Describe el triplete
- (u, i, j)
- en BPR y cómo se construye
- D_S
- .

Un triplete (u, i, j) expresa que el usuario u **prefiere el ítem i sobre el ítem j** . El conjunto D_S se construye así:

- Para cada usuario u , los ítems con los que interactuó forman el conjunto positivo I_u^+ .
- Los ítems no interactuados forman el conjunto negativo $I \setminus I_u^+$.
- Se generan todos los pares (o muestras) (u, i, j) con $i \in I_u^+$ y $j \in I \setminus I_u^+$.

Supuesto: las interacciones observadas implican preferencia sobre las no observadas.

Criterio de corrección:

- 1 pt Definición correcta del triplete (preferencia relativa $i \succ_u j$).
 1 pt Construcción correcta de D_S (positivos vs. no observados).
 1 pt Supuesto explícito sobre observados $\succ$ no observados.

- (b) [4 pts] ¿Por qué BPR optimiza ranking relativo en lugar de predicción absoluta?

Con feedback implícito **no conocemos la utilidad absoluta** de un ítem: un clic puede ser accidental, y la ausencia no implica desinterés. Lo que sí podemos inferir con confianza es que el usuario *eligió* interactuar con i sobre el universo de ítems no vistos.

Además, la tarea real de un SR es **ordenar ítems** (ranking), no predecir un rating exacto. Optimizar directamente el orden relativo alinea el objetivo del modelo con la métrica de evaluación (Precision@K, NDCG, etc.) y evita la necesidad de calibrar ratings absolutos carentes de significado en datos implícitos.

Criterio de corrección:

- 2 pts Argumenta la ambigüedad de la señal implícita como razón para no usar predicción absoluta.
 2 pts Menciona la alineación con el objetivo de ranking (Precision@K, NDCG, etc.).

- (c) [3 pts] Dado
- $\hat{r}_{ui} = 2,1$
- y
- $\hat{r}_{uj} = 1,4$
- , calcula
- $\hat{x}_{uij}$
- y
- $\sigma(\hat{x}_{uij})$
- . Interpreta el resultado.

$$\hat{x}_{uij} = \hat{r}_{ui} - \hat{r}_{uj} = 2,1 - 1,4 = 0,7$$

$$\sigma(0,7) = \frac{1}{1 + e^{-0,7}} \approx \frac{1}{1 + 0,497} \approx \frac{1}{1,497} \approx \mathbf{0,668}$$

Interpretación: el modelo asigna una probabilidad de $\approx 66,8\%$ de que el usuario prefiera el ítem i sobre el ítem j . Al ser $> 0,5$, la predicción está en la dirección correcta, aunque sin alta certeza. BPR buscará maximizar esta probabilidad durante el entrenamiento.

Criterio de corrección:

- 1 pt Cálculo correcto de $\hat{x}_{uij} = 0,7$.
 1 pt Valor correcto de $\sigma(0,7) \approx 0,668$.
 1 pt Interpretación correcta en términos de probabilidad de preferencia.

4. Recomendación Basada en Contenido — VBPR

[8 pts]

- (a) [4 pts] ¿Qué problema resuelve VBPR y qué tipo de representación incorpora?

VBPR (*Visual Bayesian Personalized Ranking*, McAuley et al.) aborda principalmente el **cold-start de ítems**: cuando un ítem es nuevo y tiene pocos o ningún rating, el filtrado colaborativo no puede aprender una representación latente confiable.

Al incorporar **características visuales** de los ítems (extraídas mediante CNNs pre-entrenadas, p.ej. AlexNet/ResNet sobre fotografías de productos), VBPR puede generar una representación del ítem desde el primer día. Estas features se combinan con la señal colaborativa (BPR sobre preferencias observadas) dentro de un único marco de entrenamiento.

Criterio de corrección:

- 2 pts Identifica el problema de cold-start de ítems.
 1 pt Menciona las features visuales extraídas por CNN.
 1 pt Explica que se combina con la señal colaborativa (BPR).

- (b) [4 pts] Explica
- $\theta_u^\top \mathbf{E} \mathbf{f}_i$
- : ¿qué son
- $\mathbf{f}_i$
- y
- $\mathbf{E}$
- , y por qué no se usa
- $\mathbf{f}_i$
- directamente?

- $\mathbf{f}_i \in \mathbb{R}^d$: vector de características visuales del ítem i extraído de la penúltima capa de una CNN (p.ej. $d = 4096$ en AlexNet). Alta dimensión, espacio visual crudo.
- $\mathbf{E} \in \mathbb{R}^{k \times d}$: **matriz de proyección aprendida** que mapea el espacio visual de dimensión d al espacio latente de dimensión k , compatible con el vector de preferencias visuales del usuario $\theta_u \in \mathbb{R}^k$.

Se necesita $\mathbf{E}$ porque: (1) la alta dimensión de $\mathbf{f}_i$ haría inviable el producto interno con θ_u ; (2) las features crudas no están alineadas con el espacio de preferencias; (3) $\mathbf{E}$ aprende *qué aspectos visuales* importan para la recomendación. Todo se entrena conjuntamente con BPR.

Criterio de corrección:

- 1 pt Definición correcta de $\mathbf{f}_i$ (CNN, alta dimensión).
 2 pts Rol de $\mathbf{E}$ como proyección aprendida al espacio latente.
 1 pt Justificación de por qué no usar $\mathbf{f}_i$ directamente.

5. Multi-Armed Bandits — UCB y Thompson Sampling

[10 pts]

Índice UCB1: $UCB_i = \bar{x}_i + \sqrt{2 \ln n / n_i}$. Tras $n = 30$ interacciones totales:

Ítem	n_i	$\bar{x}_i$
A	15	0,40
B	10	0,55
C	5	0,20

- (a) [5 pts] Calcula el índice UCB1 para cada ítem (usa $\ln 30 \approx 3,40$) y determina cuál se selecciona.

$$UCB_A = 0,40 + \sqrt{\frac{2 \times 3,40}{15}} = 0,40 + \sqrt{0,453} = 0,40 + 0,673 = \mathbf{1,073}$$

$$UCB_B = 0,55 + \sqrt{\frac{2 \times 3,40}{10}} = 0,55 + \sqrt{0,680} = 0,55 + 0,825 = \mathbf{1,375}$$

$$UCB_C = 0,20 + \sqrt{\frac{2 \times 3,40}{5}} = 0,20 + \sqrt{1,360} = 0,20 + 1,166 = \mathbf{1,366}$$

Se selecciona el ítem **B** ($UCB_B = 1,375$ es el mayor).

Criterio de corrección:

- 1 pt c/u Cálculo correcto de cada índice UCB1 ($\times 3$).
2 pts Selección correcta del ítem B con comparación explícita.

- (b) [3 pts] ¿Por qué UCB elige B y no simplemente el de mayor CTR promedio?

UCB no elige solo por CTR promedio; añade un **bono de exploración** $\sqrt{2 \ln n / n_i}$ proporcional a la incertidumbre sobre el brazo. El ítem B tiene el mejor CTR observado *y* un bono moderado ($n_B = 10$), lo que lo lleva al índice más alto. El ítem C tiene bono mayor (solo 5 impresiones) pero su CTR base es tan bajo (0,20) que la suma no supera a B. La elección de B refleja que el algoritmo **explota** su buen desempeño al tiempo que reconoce que aún existe incertidumbre sobre su CTR real.

Criterio de corrección:

- 1 pt Explica el rol del bono de exploración.
1 pt Analiza por qué C no gana a pesar del bono mayor.
1 pt Conecta la elección con el balance explorar-explotar.

- (c) [2 pts] Describe intuitivamente cómo funcionaría Thompson Sampling con distribuciones Beta.

Con Thompson Sampling se modela el CTR de cada ítem como $\text{Beta}(\alpha_i, \beta_i)$, donde $\alpha_i = \text{clicks} + 1$ y $\beta_i = \text{no-clicks} + 1$:

- A: $\approx \text{Beta}(7, 10)$; B: $\approx \text{Beta}(6, 5)$; C: $\approx \text{Beta}(2, 5)$.

En cada paso se *muestra* $\theta_i \sim \text{Beta}(\alpha_i, \beta_i)$ para cada ítem y se selecciona $\arg \max_i \theta_i$. El ítem B gana con alta frecuencia (Beta centrada en $\approx 0,55$, varianza moderada); C gana ocasionalmente por alta incertidumbre, lo que implementa exploración de forma natural y probabilística.

Criterio de corrección:

- | | |
|------|---|
| 1 pt | Parámetros Beta correctos e interpretación ($\alpha = \text{clics}+1$, $\beta = \text{no-clics}+1$). |
| 1 pt | Describe el mecanismo de muestreo y selección, con exploración natural. |

6. Fairness, Accountability and Transparency

[10 pts]

- (a) [3 pts] Distingue *consumer fairness* y *provider fairness*; da un ejemplo de conflicto en streaming.

Consumer fairness: todos los usuarios reciben recomendaciones de calidad similar independientemente de su grupo demográfico (edad, género, ubicación, etc.).

Provider fairness: los creadores o proveedores de contenido tienen acceso equitativo a exposición en el sistema, independientemente de su tamaño o popularidad histórica.

Conflicto en streaming: maximizar la satisfacción del usuario (consumer) lleva al sistema a recomendar sólo contenido *mainstream* de artistas populares — lo que excluye sistemáticamente a músicos independientes (viola provider fairness). Forzar exposición diversa de proveedores puede reducir la relevancia percibida por el usuario (viola consumer fairness).

Criterio de corrección:

- 1 pt Definición correcta de consumer fairness.
- 1 pt Definición correcta de provider fairness.
- 1 pt Ejemplo concreto de conflicto entre ambas.

- (b) [4 pts] Explica cómo el *feedback loop* amplifica sesgo y cómo afecta a grupos subrepresentados.

Ciclo de retroalimentación:

1. El sistema recomienda ítems populares (más datos de entrenamiento).
2. Los usuarios interactúan con lo que ven $\Rightarrow$ más datos para esos ítems.
3. El modelo re-entrenado los favorece aún más.
4. Los ítems de nicho acumulan menos datos $\Rightarrow$ peor estimación $\Rightarrow$ menos exposición $\Rightarrow$ menos datos: ciclo de exclusión progresiva.

Consecuencia para grupos subrepresentados: usuarios con gustos de nicho o de culturas minoritarias reciben recomendaciones de peor calidad, interactúan menos con el sistema y generan aún menos datos, creando un ciclo de **exclusión algorítmica** que se autoreforza.

Criterio de corrección:

- 2 pts Describe el loop con al menos 3 pasos claros de retroalimentación.
- 2 pts Explica la consecuencia concreta para grupos subrepresentados (exclusión progresiva).

- (c) [3 pts] Nombra y describe una métrica de fairness aplicable a SR.

Opción A — Paridad demográfica (*statistical parity*): la proporción de usuarios de distintos grupos que recibe un tipo de contenido debe ser igual entre grupos. En SR: la fracción de recomendaciones de contenido de proveedores independientes debe ser similar para todos los segmentos de usuarios.

Opción B — Exposición proporcional (*provider exposure*): mide si los proveedores reciben exposición proporcional a alguna noción de mérito (calidad, relevancia), no solo a su popularidad histórica. $Exposure_p = \sum_{u,k} \mathbb{I}[\text{ítem de } p \in \text{Top-K}(u)]$.

Opción C — Igualdad de oportunidad (*equal opportunity*): la tasa de verdaderos positivos $P(\text{recomendar ítem relevante} \mid \text{ítem relevante})$ debe ser igual en todos los grupos de usuarios.

Se acepta cualquiera bien descrita con una aplicación concreta al SR.

Criterio de corrección:

- 2 pts Nombra y describe correctamente la métrica elegida.
- 1 pt Indica cómo se aplicaría en un SR real (qué se mide y sobre qué población).

Pregunta	1	2	3	4	5	6	Total
Puntaje máximo	12	12	10	8	10	10	62

$$\text{Nota} = 1 + 6 \times \frac{\text{puntaje}}{62} \quad \text{Aprobación: } \geq 37,2 \text{ pts } (\approx 60\%)$$