Recomendación de Recetas y Promoción de Opciones Saludables: Un Estudio Comparativo entre Modelos Tradicionales y LLMs

SISTEMAS RECOMENDADORES - PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

Aníbal Fermandois, Erick Lara, Lucas Rojas

INTRODUCCIÓN

La recomendación de recetas de comida plantea desafíos únicos en sistemas recomendadores, ya que se debe combinar preferencias personales del usuario (historial y valoraciones) con restricciones estrictas como alergias, intolerancias y criterios de salud (balance calórico y diversidad nutricional).

Tradicionalmente, los modelos optimizan solo métricas de precisión, lo que puede derivar en recomendaciones sesgadas hacia recetas poco saludables. Este trabajo explora el potencial de Large Language Models (LLMs) como alternativa flexible para incorporar múltiples restricciones cualitativas y cuantitativas mediante prompting estructurado y fine-tuning, sin necesidad de modificar arquitecturas híbridas complejas.

OBJETIVO

Desarrollar y evaluar un sistema de recomendación de recetas basado en LLMs que optimice simultáneamente:

- La precisión de las recomendaciones (satisfacción del usuario)
- La calidad nutricional (evitando el sesgo hacia recetas poco saludables)

Se busca demostrar que los LLMs, incluso en configuración zero-shot y en modelos locales de tamaño reducido, pueden igualar o superar a métodos tradicionales en métricas de salud sin comprometer significativamente la precisión, y que el fine-tuning permite cerrar la brecha restante. Además, buscamos ver la capacidad intrinseca de los modelos para entender gustos parecidos y su noción de lo que es saludable o no.

METODOLOGÍA

Como baselines se implementaron Random, Most Popular y SVD. Evaluamos tres LLMs (Gemini 2.0 Flash Lite, Phi-3 Mini y Phi-2) mediante zero-shot prompting estructurado, incorporando historial, nombre de receta y NutriScore (A–E). El desempeño se midió con métricas de precisión (MAE, RMSE), ranking (Precision@10, Recall@10, NDCG@10) y salud (MeanHealth@10). Finalmente, se hizo fine-tuning de Phi-2 usando pares (historial, receta, rating) para mejorar precisión manteniendo la calidad nutricional de las recomendaciones.

Se utilizó el dataset Food.com (522k recetas, 1.4M reseñas), dividido en 80/20 para entrenamiento y prueba, construyendo historiales de usuario con sus 5 calificaciones más recientes.

DATASET

Reviews.csv		**Recipes.csv**	
Metric	**Value**	**Metric**	**Value**
Number of users	271,907	Number of recipes	522,517
Number of items	271,678	Number of authors	57,178
Total ratings	1,401,982	Average rating	4.632
Average review count	5.16	Rating S.D	0.642
Average rating	4.408	Average review count	5.23
Rating S.D.	1.272	Max review count	3,063
Max ratings by a user	8,842	Average calories	484.44
Max ratings of item	2,892	Calories SD	1,397.12
Density	0.00001898		

RESULTADOS

Los baselines muestran desempeños variados, donde SVD alcanza la mayor precisión en rating. Entre los LLMs zero-shot, Gemini 2.0 Flash Lite (API) obtiene los mejores valores en Precision@10, Recall@10 y NDCG@10.

Los modelos locales zero-shot (Phi-3 Mini y Gemma-3: 4B) mantienen métricas similares y MeanHealth@10 sobre 2.8. Finalmente, Phi-2 2.7B fine-tuned mejora notablemente su MAE y RMSE respecto a su versión zero-shot, manteniendo métricas de ranking comparables, sin embargo, no muestra mejoras significativas en Prec@10, Rec@10, NDCG@10 y en MeanHealth@10.

Baseline | Zero-Shot | Fine-Tuned

Modelo	MAE	RMSE	Prec@10	Rec@10	NDCG@10	MeanHealth@10
Random	1.921	2.367	0	0	0	**3.1**
Most Popular	-	-	0.004	0.021	0.013	2.014
SVD	0.744	1.223	0.084	0.429	0.434	2.753
Gemini 2.0 Flash Lite	0.914	1.43	**0.149**	**0.468**	**0.612**	2.837
Gemma 3: 4B	2.091	2.434	0.143	0.422	0.561	2.819
Phi-3 Mini 3.8B	1.349	1.938	0.143	0.422	0.561	2.814
Phi-2 2.7B	1.808	1.899	0.144	0.417	0.559	2.821
Phi-2 2.7B	**0.582**	**1.386**	0.144	0.417	0.559	2.804

EJEMPLO

RECOMMENDATION FOR USER 2001112113

User History (last 5):

- Carla's Basic Meatballs: rated 5
- Sheet Pan Taco Dutch Baby: rated 5
- Margarita Chicken Salad Sandwiches: rated 5
- Poppy Seed Chicken Casserole: rated 5
- Banana Carrot Muffins: rated 5

Top Recommended Recipe:

- Name: My Sausage Breakfast Burritos
- Recipe ID: 349629
- Predicted Rating: 5

Other candidates:

- Guacamole Potatoes (id=65022) → score 5
- Vaca Frita (Shredded Beef) (id=351110) → score 5
- Pizza Casserole (id=395328) → score 5
- Caramel-Cognac Fondue (id=45184) → score 5

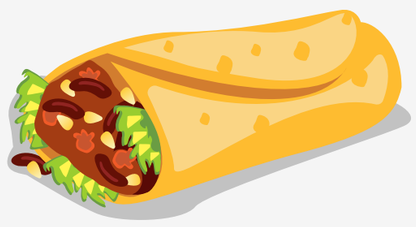

CONCLUSIÓN

Los LLM presentan un area nueva y prometedora en problemas de recomendación frente algoritmos tradicionales. Estos abren camino a resultados competitivos sin previo trabajo como se ve con Gemini 2.0 en métricas **@10** y a mejoras considerables una con técnicas de **fine-tunning** (~-**30**% RSME y ~-**68**% MAE). También se destaca su habilidad superior en optimizar otras métricas ortogonales simultáneamente viendo resultados superiores que algoritmos tradicionales en **MeanHealth@10** en cada caso y siendo superado solamente por **Random**.

REFERENCIAS

- Alvin. (2020). Food.com - recipes and reviews [Data set]. https://www.kaggle.com/datasets/irkaal/foodcom-recipes-and-reviews
- Google DeepMind Team. (2025). Gemma 3 Technical Report. arXiv. https://doi.org/10.48550/arXiv.2503.19786
- Ollama. (2023). Ollama [Software]. https://ollama.com/
- Abdin, M., Jacobs, S. A., Awan, A. A., Aneja, J., Awadallah, A., Awadalla, H. H., ... & Yang, Y. (2024). Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone. arXiv. https://doi.org/10.48550/arXiv.2404.14219