Food Recommender System: Balancing User Preferences and Health

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

ADRIANA BASTÍAS MENDOZA
ANDRÉS MUNDACA ZÚÑIGA
ANDRÉS RIQUELME LE ROY

01. Motivación

- Los sistemas de recomendación de recetas tradicionales priorizan preferencias, pero ignoran la salud nutricional del usuario.
- Se busca generar un sistema que equilibre gusto y salud, evitando recomendaciones potencialmente dañinas.

02. Problema

Actualmente, los sistemas de recomendación de recetas tienden a priorizar únicamente las preferencias de los usuarios. Sin embargo, en el ámbito alimentario esto puede generar un problema relevante: un sistema podría recomendar de manera persistente alimentos poco saludables.
Dado lo anterior, surge la interrogante de ¿qué tan "bueno" es un sistema de recomendación si promueve hábitos alimentarios perjudiciales para la salud del usuario?
Entonces, surge la necesidad de modelar sistemas de recomendación equilibrados, que no solo consideren preferencias, sino también indicadores de salud y nutrición.

03. Metodología

Se utiliza el dataset MealRec+H, el cual incluye información nutricional asociada a cada meal y course mediante dos métricas de salud alimentaria: WHO y FSA, normalizados tal que mientras mayor el valor, más saludable.

El dataset consiste de 7.820 recetas, 1.575 usuarios, con un rating que va entre 1-5. El modelo se entrena para obtener una densidad de interacción usuario-comida del 0.17%.

Modelos
Se entrenan los siguientes modelos:

- UserKNN. *Basada en similitud entre usuarios usando interacciones históricas (k=20)*
- LightFM. *Combina embeddings de usuarios e ítems con factorización y features*
- LightGCN. *Grafo de usuarios e ítems que aprende embeddings propagando en la red*
- MultVAE. *Autoencoder variacional que modela la distribución latente de preferencias*
- DeepFM. *Factorization machines que mezcla IDs y atributos nutricionales del ítem*

Se genera un reranking según la función ***score = (1 - α) x relevancia + α x salud***. Estas recomendaciones fueron evaluadas con Recall@10 y NDCG@10.

04. Resultados

Método	Recall@10	NDCG@10	WHO_health@10	FSA_health@10
UserKNN (α = 0.40)	0.0955	0.0751	0.4178	0.3657
LightFM (α = 0.40)	0.0932	0.0674	0.4433	0.3872
LightGCN (α = 0.40)	0.0463	0.0318	0.4126	0.2891
MultVAE (α = 0.40)	0.0299	0.0200	0.3913	0.2825
DeepFM (health features)	0.0252	0.0159	0.3269	0.3586

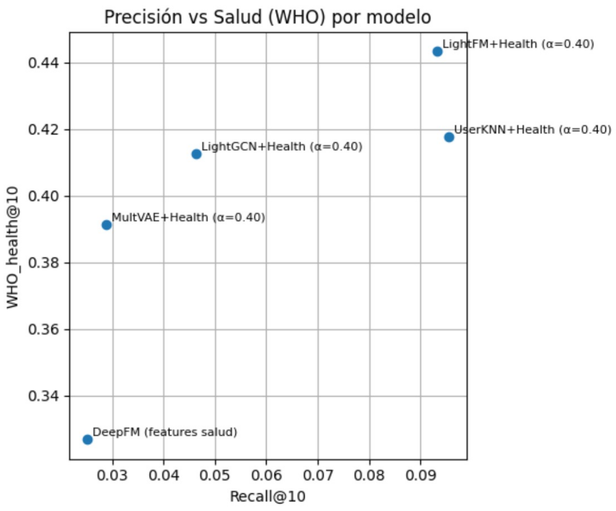

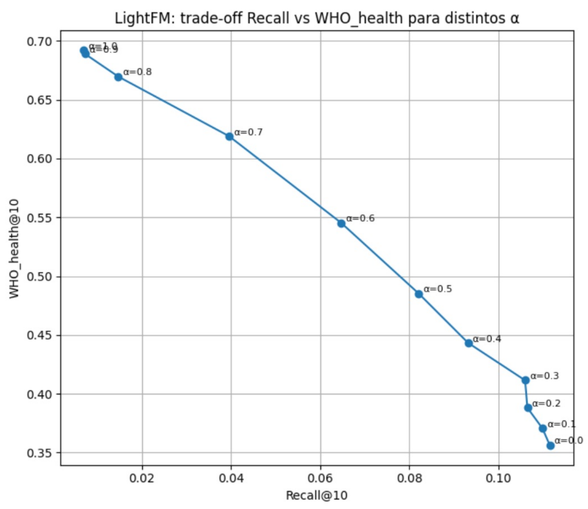

05. Discusión

LightFM con reranking de salud logra el mejor equilibrio entre precisión y calidad nutricional, superando tanto a métodos basados en vecinos (UserKNN) como a modelos más complejos (LightGCN, MultVAE, DeepFM), lo que sugiere que un modelo colaborativo bien regularizado más un reranking explícito de salud es suficiente para estos datos simples.

Analizando el mejor modelo LightFM, y variando el parámetro α, se encontró que pequeños valores de α permiten obtener recomendaciones más saludables casi sin pérdida de precisión, donde a partir de 0.5 en adelante, las pérdidas son significativas

06. Conclusiones

Los resultados demuestran que es posible incorporar criterios nutricionales en sistemas de recomendación sin sacrificar completamente la precisión, mostrando un trade-off gradual y manejable para α entre 0.2–0.4.
Esto sugiere que el reranking puede mantener utilidad para el usuario mientras promueve hábitos más saludables.
Aún así, puede ser relevante analizar datasets más complejos o nuevas funciones de reranking.

Referencias

Li, M., Li, L., Tao, X., & Huang, J. X. (2024). MealRec+: A Meal Recommendation Dataset with Meal-Course Affiliation for Personalization and Healthiness