Evaluación de LLMs Open-Source para Sistemas de Recomendación Conversacional

Eduardo Soto, Martín Muñoz, Randall Biermann

IIC3633 Sistemas Recomendadores

Pontificia Universidad Católica de Chile

Introducción

Los sistemas de recomendación tradicionales funcionan bien con las interacciones usuario–ítem, pero presentan limitaciones al intentar capturar **preferencias expresadas en lenguaje natural** dentro de conversaciones reales.

El reciente avance de los **LLMs open-source** como Gemma, Qwen y Llama ha abierto nuevas posibilidades para la recomendación conversacional, permitiendo interpretar diálogos completos y generar respuestas de manera más contextual. Sin embargo, aún existe una brecha respecto al rendimiento comparativo de estos modelos en escenarios dialogados, considerando diferencias en arquitectura, tamaño y estrategias de prompting.

Dataset

El proyecto utiliza el dataset **ReDial**, un set de conversaciones sobre recomendaciones de películas entre usuarios y un agente recomendador. Los diálogos contienen menciones explícitas a películas, preferencias del usuario y retroalimentación implícita, convirtiéndolo en un punto de referencia adecuado para recomendación conversacional.

ReDial se divide en los conjuntos de ***train* (8004 conversaciones), *validation* (2002) y *test* (1342)**, siguiendo la separación original del paper *Towards Deep Conversational Recommendations*. Las conversaciones tienen en promedio **18 turnos** (desviación estándar ≈ 5), lo que exige a los modelos manejar interacciones extensas y con cambios de contexto.

Cada diálogo menciona en promedio **5.3 películas**, con distribuciones sesgadas hacia pocas menciones (3–7 en la mayoría de los casos). Así, los modelos deben inferir preferencias a partir de señales implícitas y un contexto acotado.

En general, todas estas características hacen que ReDial sea un reto para los modelos de lenguaje pequeños y medianos, porque necesitan entender bien la conversación y captar las preferencias del usuario incluso cuando no se mencionan de forma directa.

Set/Métrica	Total Conversaciones	Promedio de Turnos	Desviación Estándar
Training	8004	18.21	5.38
Validation	2002	18.19	5.04
Test	1342	17.85	4.98

Figura 1. *Estadísticas principales del dataset ReDial, incluyendo tamaño de cada split y longitud promedio de conversación.*

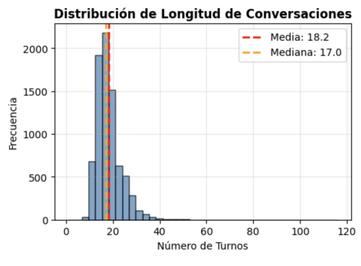

Figura 2. Distribución de número de turnos en conjunto de entrenamiento

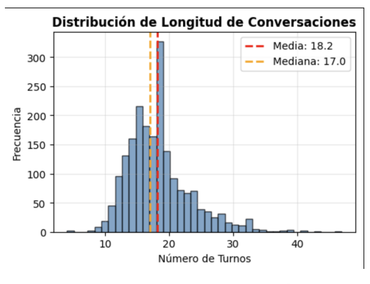

Figura 3. Distribución de número de turnos en conjunto de validación

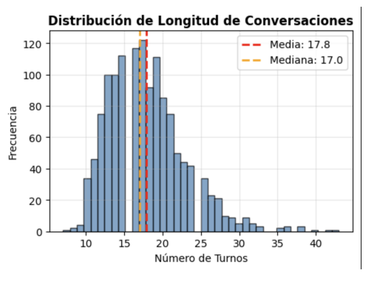

Figura 4. Distribución de número de turnos en conjunto de test

Algoritmos

Se evaluaron distintos **LLMs open-source** entre 1B y 4B parámetros para comparar su capacidad de interpretar diálogo y generar recomendaciones coherentes. La selección incluye modelos recientes y eficientes que representan diferentes enfoques arquitectónicos dentro del panorama actual.

Gemma (Google) Modelos diseñados para eficiencia y razonamiento ligero, útiles como referencia base y para analizar mejoras incrementales:

- **Gemma-2-2b-it**: baseline del estudio.
- **Gemma-3-1b-it**: versión más reciente con mejor comprensión contextual.
- **Gemma-3-4b-it**: mayor capacidad semántica dentro de la familia evaluada.

Qwen (Alibaba Cloud) Modelos optimizados para tareas de diálogo, con énfasis en instrucciones y consistencia conversacional:

- **Qwen3-4B-Instruct-2507**: orientado a instrucciones y conversación general.
- **Qwen2.5-1.5B-Instruct**: alternativa más ligera, eficiente y estable.

Esta diversidad de modelos permite examinar cómo **tamaño, entrenamiento y arquitectura** influyen en la habilidad para capturar preferencias implícitas, mantener coherencia a través del diálogo y producir recomendaciones relevantes.

Metodología

La evaluación se diseñó para comparar de forma consistente distintos LLMs open-source en recomendación conversacional. El proceso se organiza en cuatro etapas:

1. Selección de modelos. Se evaluaron los modelos mencionados anteriormente.

2. Zero-shot prompting. Cada modelo recibió la conversación completa y generó 10 recomendaciones numeradas en un formato fijo, permitiendo comparar su comportamiento sin fine-tuning.

3. Procesamiento y métricas. Se extrajeron los títulos recomendados y se compararon con las películas relevantes. Se calcularon Recall@10, Precision@10, nDCG@10, HitRate@10, MRR y latencia promedio.

4. Protocolo experimental. Las pruebas se ejecutaron en una GPU Quadro RTX5000 con parámetros de inferencia constantes (temperatura 0.7, context ratio 0.7), asegurando condiciones uniformes entre modelos.

Resultados

Los resultados muestran mejoras claras a medida que aumenta la **capacidad del modelo**:

1. Baseline. Gemma-2-2b-it obtuvo el rendimiento más bajo en todas las métricas.

2. Efecto del tamaño. Gemma-3-1b-it y Gemma-3-4b-it superaron ampliamente al baseline, destacando en Recall@10 y HitRate@10.

3. Mejor desempeño. Los modelos Qwen fueron los más efectivos; Qwen3-4B y especialmente Qwen2.5-1.5B-Instruct lograron los mejores resultados globales.

4. Trade-off. La latencia aumenta con modelos mayores, aunque Qwen2.5-1.5B-Instruct mantiene un equilibrio sólido entre calidad y tiempo de respuesta.

En síntesis, los **modelos más recientes** capturan mejor las señales conversacionales de ReDial y producen **recomendaciones más precisas**.

Modelo	Rec@10	Prec@10	nDCG@10	HR@10	MRR	Lat
G-2-2b (Base)	0.0288	0.0038	0.0135	0.0385	0.0092	9.05
G-3-1b	0.1394	0.0192	0.0982	0.1923	0.0920	12.29
G-3-4b	0.1154	0.0135	0.0575	0.1346	0.0434	16.89
Q-4B	0.1587	0.0231	0.1094	0.2115	0.1085	14.06
Q-1.5B	0.1971	0.0269	0.1345	0.2500	0.1150	9.11

Figura 5. *Resultados consolidados para 52 muestras del set de prueba de ReDial.*

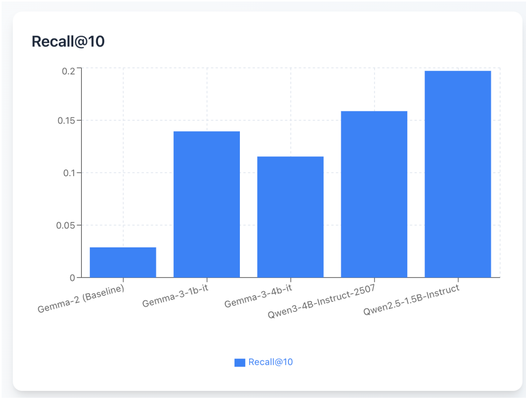

Figura 6. *Recall@10 por modelo.*

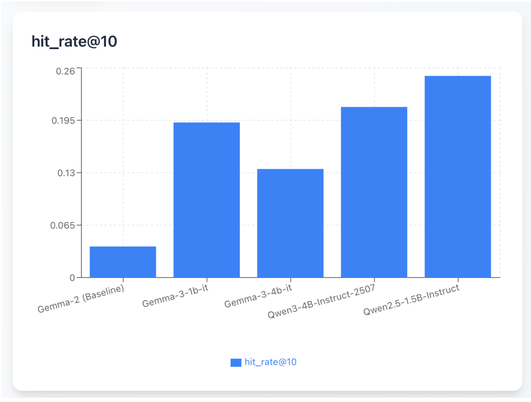

Figura 7. *HitRate@10 por modelo.*

Conclusiones

Los resultados muestran que los LLMs **más recientes y con mayor capacidad** entregan recomendaciones **notablemente más precisas** en escenarios conversacionales. Gemma-2-2b-it sirve como baseline simple, mientras que los modelos Qwen, especialmente Qwen2.5-1.5B-Instruct, lograron el **mejor equilibrio entre calidad y latencia**.

En conjunto, la evaluación confirma que los avances en arquitectura y entrenamiento permiten a los LLMs capturar con mayor efectividad las **preferencias expresadas en diálogo**, mejorando la **relevancia y consistencia** de las recomendaciones sobre el dataset ReDial.

Referencias

- **Wu, L. et al. (2024).** *A survey on large language models for recommendation*. arXiv:2305.19860.
- **Li, R. et al. (2019).** *Towards deep conversational recommendations*. arXiv:1812.07617.
- **Lichtenberg, J. M., Buchholz, A., & Schwöbel, P. (2024).** *Large language models as recommender systems: A study of popularity bias*. Amazon Science.
- **Zhao, Z. et al. (2023).** *Recommender systems in the era of large language models (LLMs)*. arXiv:2307.02046.