Impacto del Dwell Time en Recomendación Secuencial

Tomás Goas, Leopoldo Farr

Pontificia Universidad Católica de Chile

Objetivos

Investigamos si incorporar el **dwell time** mejora el desempeño de modelos de recomendación secuencial.
Dado que la literatura revisada muestra que el dwell ha sido estudiado principalmente en **GRU-based models** [1], pero no en modelos modernos como SASRec o BERT4Rec [2], buscamos reducir este **gap de conocimiento**.
Nuestros objetivos son:

- Comparar sistemáticamente el efecto de agregar o no dwell time en modelos secuenciales.
- Evaluar el impacto del dwell en métricas estándar de ranking.
- Analizar en qué arquitecturas el dwell aporta más valor.
- Establecer lineamientos para incorporar señales temporales en modelos secuenciales.

Introducción

En los sistemas de recomendación secuencial, entender la interacción temporal usuario-ítem es vital para la precisión. Tradicionalmente, muchos modelos priorizan solo el orden de las interacciones, ignorando señales como el dwell time. Aunque este es un reconocido indicador de interés, su incorporación en modelos secuenciales ha sido poco explorada. Esto plantea preguntas clave: ¿En qué medida mejora la calidad de las recomendaciones? ¿Qué modelos se benefician más? ¿Y qué impacto tiene excluirlo?

Metodología

Los experimentos se realizaron sobre dos datasets públicos de comportamiento de usuarios en e-commerce (octubre y noviembre 2019), recolectados por el proyecto **Open CDP de Rees46 Technologies**. La data proviene de un store multicategoría y cada registro corresponde a un evento asociado a un producto.

Características del dataset:

- Millones de interacciones por mes.
- Eventos categorizados en vistas, cart, purchase.
- Datasets separados por mes, Octubre y Noviembre 2019.

Debido a limitaciones computacionales:

- Cada modelo se comparó solo contra su versión **con vs sin** dwell.
- Se filtraron sesiones excesivamente largas para evitar fallas en GPU/CPU.
- El entrenamiento se ejecutó en máquinas locales.

Dwell Time y construcción de sesiones

El **dwell time** se incorporó siguiendo una estrategia simple y consistente: cada ítem dentro de la sesión se repite una cantidad de veces proporcional al tiempo que el usuario permaneció en él. Esto permite que el modelo interprete mayor permanencia como una señal de mayor interés dentro de la secuencia.

Implicancias de esta representación:

- Las sesiones se vuelven más largas al expandir cada ítem según su dwell.
- El costo computacional aumenta: más memoria y más tiempo de entrenamiento.
- La señal temporal se vuelve explícita en la secuencia, permitiendo que modelos secuenciales capturen mejor la intensidad de interacción.

Aunque es una representación sencilla, permitió comparar de forma directa el desempeño de cada modelo **con vs sin** dwell bajo un mismo esquema de construcción de datos.

Modelos evaluados

- **GRU4Rec**

  Modelo recurrente basado en GRU, capaz de capturar dependencias de corto plazo mediante un estado oculto que evoluciona con la sesión.

- **BERT4Rec**

  Modelo Transformer bidireccional con masked item prediction. Aprende representaciones usando todo el contexto, pero es sensible al ruido en señales adicionales.

- **SASRec**

  Modelo que combina lo mejor de dos mundos: utiliza mecanismos de Self-Attention (como BERT) para capturar dependencias a largo plazo, pero de manera unidireccional/causal (como GRU).

- **NARM**

  Modelo híbrido que combina GRU con un mecanismo de atención hacia los ítems más relevantes de la sesión. Su arquitectura permite resaltar señales fuertes como repeticiones, capturando de forma efectiva patrones de intención del usuario.

Resultados Importantes

Recall@10

Modelo	Oct			Nov		
	Sin	Con	Gap	Sin	Con	Gap
BERT4Rec	0.4681	0.4205	-10.2%	0.4748	0.4321	-9.0%
GRU4Rec	0.7722	0.8016	+3.8%	0.7068	0.7655	+8.3%
SASRec	0.7588	0.7922	+4.4%	0.6923	0.7493	+8.2%
NARM	0.5944	0.7511	+26.36%	0.6287	0.7095	+12.85%

NDCG@10

Modelo	Oct			Nov		
	Sin	Con	Gap	Sin	Con	Gap
BERT4Rec	0.3620	0.3255	-10.1%	0.3641	0.3387	-7.0%
GRU4Rec	0.6438	0.6980	+8.4%	0.5649	0.6644	+17.6%
SASRec	0.6394	0.6937	+8.5%	0.5635	0.6522	+17.6%
NARM	0.4193	0.5951	+41.93%	0.4479	0.5585	+24.69%

MRR@10

Modelo	Oct			Nov		
	Sin	Con	Gap	Sin	Con	Gap
BERT4Rec	0.3289	0.2960	-10.0%	0.3379	0.3096	-8.4%
GRU4Rec	0.6036	0.6656	+10.2%	0.5206	0.6329	+21.5%
SASRec	0.6019	0.6629	+10.1%	0.5233	0.6221	+21.5%
NARM	0.3632	0.5446	+49.94%	0.3900	0.5095	+30.64%

Tiempos de Entrenamiento (en segundos)

Modelo	Oct			Nov		
	Sin	Con	Gap	Sin	Con	Gap
BERT4Rec	7144	14824	+51.8%	16781	8123	+51.6%
GRU4Rec	3085.00	4408.28	+42.89%	2183.98	4057.27	+85.77%
SASRec	7298.36	10245.22	+40.37%	4093.12	9334.48	+228%
NARM	1740.52	5838.79	+235.46%	2774.79	2194.72	-26.43%

Representación del procesamiento de sesiones para un usuario específico.

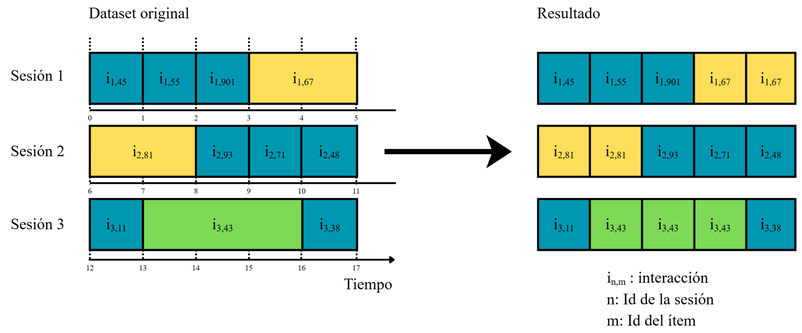

Análisis de resultados

- **Dicotomía en el Desempeño**
  Observamos un comportamiento similar en todos los medelos expecto en BERT:
- **RNNs (GRU4Rec)** Incorporar dwell time mejora todas las métricas (+3.8% a +21.5%). El estado oculto interpreta la repetición del ítem como una señal de refuerzo.
- **Transformers Bidireccionales (BERT4Rec)** El rendimiento cae sistemáticamente (9%). La repetición de ítems es interpretada como ruido debido a su naturaleza bidireccional, afectando la calidad del aprendizaje contextual.
- **Transformers Unidireccionales (SASRec)** La incorporación de dwell mejora de forma consistente (+4–10% en Oct y +8–21% en Nov). Esto confirma que la atención causal sí integra correctamente señales temporales repetidas, y que el problema en BERT proviene específicamente de la bidireccionalidad.
- **Modelos con Atención Híbrida (NARM)** NARM es el modelo que más se beneficia del dwell time, mostrando mejoras muy superiores al resto. Su combinación de GRU + atención sobre el contexto amplifica la señal de repetición del ítem, interpretándola como un fuerte indicador de interés.

En el dataset de noviembre, el entrenamiento sin dwell tardó aproximadamente un 20% menos, algo inusual; una posible explicación es que noviembre presenta sesiones más cortas y con menor variabilidad temporal, haciendo que el modelo converja más rápido al no incorporar repeticiones adicionales.

QR con el repositorio de los modelos

Conclusiones

- El dwell time es una señal temporal relevante que mejora modelos secuenciales, pero su efecto depende de la arquitectura.
- GRU4Rec, SASRec y NARM muestran mejoras claras, confirmando que arquitecturas causales integran bien la repetición del ítem como indicador de interés.
- BERT4Rec sufre degradación, evidenciando que la bidireccionalidad hace que las repeticiones generadas por dwell afecten la consistencia del patrón secuencial.
- Los resultados sugieren que futuros modelos deberían incorporar dwell mediante mecanismos más robustos, como embeddings temporales o filtros de repetición.
- Se abre un espacio para explorar híbridos entre atención causal y señales temporales explícitas.
- El impacto observado también indica que la forma de representar el dwell (replicación del ítem) influye fuertemente: un modelado más fino podría reducir ruido y mejorar consistencia entre meses.
- En conjunto, el dwell demuestra potencial real para mejorar recomendaciones, pero requiere modelado cuidadoso y dependiente de la arquitectura.

Referencias

[1] Hidasi et al. *Session-based Recommendations with Recurrent Neural Networks*. CEUR Workshop, 2017.

[2] Quadrana et al. *A Survey on Sequential Recommendation*. arXiv:2209.09000, 2022.

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE