Clash Royale LLM Recommender System

Jorge De Goyeneche Klein - Victoria Jiménez Sepúlveda - Emilio Latorre Barra

Pontificia Universidad Católica de Chile

Introducción

En Clash Royale, cada jugador construye un mazo de 8 cartas para competir. La composición del mazo es crítica: debe equilibrar ataque, defensa, coste de elixir y sinergias estratégicas.

Problema: Muchos jugadores seleccionan 4 cartas favoritas, pero enfrentan dificultades para completar el mazo de forma competitiva.

Objetivo: Desarrollar un sistema de recomendación que sugiera las 4 cartas restantes, manteniendo coherencia estratégica y potenciando el desempeño.

Enfoque: Comparación de modelos tradicionales (LightFM, DeepFM) con LLMs de última generación (GPT-3.5, GPT-4o, GPT-5, LLaMA-3.3, DeepSeek-V3.1), evaluando su capacidad para razonar sobre sinergias complejas.

Dataset

API oficial de Clash Royale: **4,717** usuarios únicos **121** cartas disponibles, **3,247** mazos únicos, se usó una muestra de **300** usuarios para los experimientos.

Características clave:

- Distribución sesgada: pocas cartas dominan el meta
- Co-ocurrencias revelan sinergias fuertes y arquetipos recurrentes
- División: **77%** entrenamiento, **23%** prueba

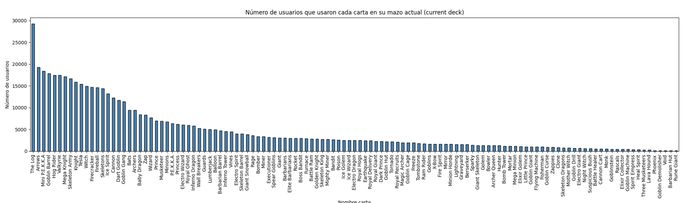

Evaluación: DeckShop proporciona ratings objetivos en 5 dimensiones (ataque, defensa, sinergia, versatilidad, F2P) para comparar mazos generados vs. originales.

Baselines

Modelo	Método	P@4	R@4
LightFM	Embeddings usuario-ítem (WARP)	0.146	0.146
DeepFM	FM + red profunda (128, 64)	0.135	0.278

LLMs

Comerciales: GPT-3.5-turbo, GPT-4o, GPT-5-chat
Abiertos: LLaMA-3.3-70B, DeepSeek-V3.1

Pipeline: Azure Foundry → JSON estructurado → validación → evaluación (DeckShop)

Prompts

Componentes XML: Inputs | Context | Task | Constraints | Guidelines | Output

Variantes: Tamaño - Full/Semi-lite/Lite • Multietapa (3 pasos) • Español o Ingles

Resultados

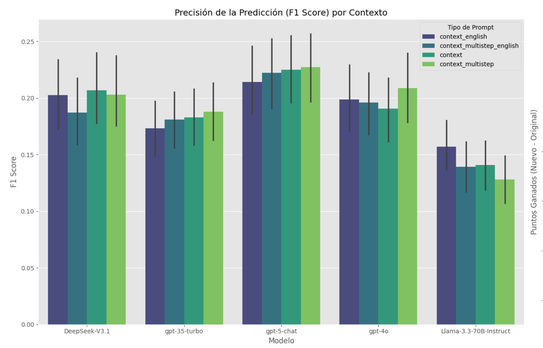

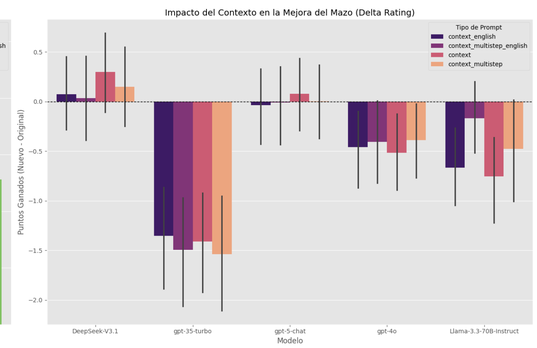

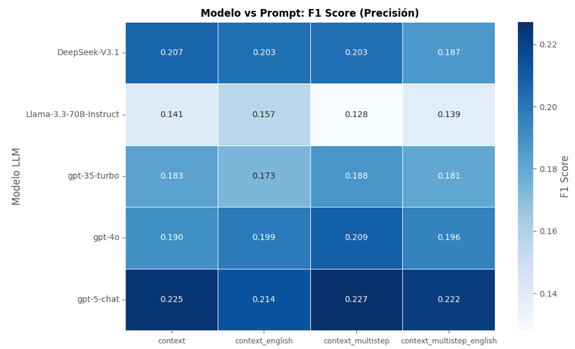

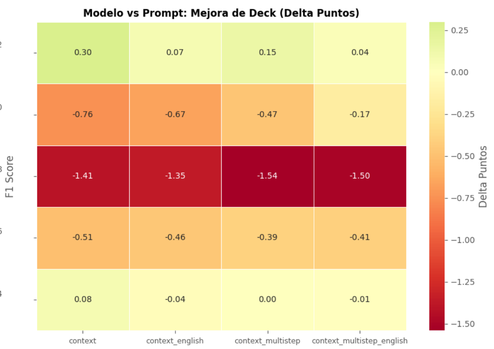

Para mejora del mazo el mejor modelo es DeepSeek-V3.1 con el prompt context. Para recuperación GPT-5-chat con el prompt context multistep es el más seguro. Evitar GPT-3.5 para cualquier decisión estratégica.

Referencias

[1] Lee Boonstra. *Prompt Engineering Guide v7*. https://github.com/jcpierrejr/elementsofpromptengineering/blob/main/Google_Prompt\%20Engineering_v7.pdf. Apr. 2025.

[2] pavelfi. *Deck Shop for Clash Royale*. https://www.deckshop.pro. Accessed: 2025.

[3] Supercell. *Clash Royale API*. https://developer.clashroyale.com. Accessed: 2025.

[4] Jiaxi Tang and Ke Wang. "Personalized Top-N Sequential Recommendation via Convolutional Sequence Embedding". In: *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining*. 2018, pp. 565–573. DOI: 10.1145/3159652.3159656.

Hallazgos

- **Estrategia vs. Precisión:** DeepSeek mejora mazos (Rating > 0), GPT-5 domina predicción (F1=0.22) con impacto neutro
- **Sensibilidad al prompt:** Complejidad contraproducente en modelos top; DeepSeek prefiere contexto simple, LLaMA-3.3 requiere CoT
- **Calidad:** GPT-3.5 degrada sinergia (-1.41), obsoleto para tareas estratégicas
- **Trade-off Creativo:** DeepSeek prioriza la utilidad sobre el novelty, sugiriendo cartas comunes pero efectivas para asegurar la mejora del mazo.
- **El Especialista Diverso:** GPT-5 logra un equilibrio entre alta cobertura de cartas (75%) y precisión, sin caer en repeticiones genéricas.
- **Diversidad sin Calidad:** Llama-3.3 ofrece la mayor variedad de cartas (79%) pero con el peor rendimiento, indicando aleatoriedad.
- **Exploración balanceada:** Modelos avanzados logran novelty sin sacrificar coherencia

Limitaciones

API Clash Royale	Historial con solo 30 batallas (7 días)
DeckShop CAPTCHA	Limitó evaluaciones masivas
Rate limits LLMs	Pausas requeridas (5x en Grok)
Ground truth	Optimalidad desconocida
Evaluación	Indirecta vía DeckShop
Correlación Baselines	Sin comprensión de sinergias estratégicas.

Conclusiones

- **LLMs de última generación** (GPT-5, DeepSeek) superan significativamente a baselines en F1-Score y mazos viables
- **Diseño del prompt** es determinante: reglas explícitas mejoran validez
- **Contexto estratégico** mejora sinergia sin sacrificar diversidad
- **Correlación positiva:** capacidad del modelo ↔ exploración (novelty/coverage)
- **Limitaciones de Baselines:** Aunque DeepFM compite técnicamente en F1-Score (0.182) con GPT-5, los LLMs lo superan en calidad final al aplicar razonamiento estratégico sobre sinergias, mientras los baselines se limitan a correlaciones estadísticas de uso.

Trabajo futuro: Validación con usuarios • Recomendación de k cartas variable (2, 3, 4)