Análisis del Sesgo en Algoritmos de Recomendación de Anime

Damian Gubbins, Jorge de la Fuente, Nicolás Fernandez, Benjamín Huenchuñir.

Departamento de Ciencias de la Computación, Pontificia Universidad Católica de Chile

Objetivos

El objetivo central del proyecto es el **análisis de sesgos de recomendación** en sistemas de recomendación de anime, específicamente en función de las características demográficas de los usuarios como el género.

1. **Evaluar Modelos Específicos:** Comparar el sesgo presente en modelos como DeepFM, ALS y un recomendador específico de anime Anurag122002.
2. **Análisis Multimétrico Avanzado:** Evaluar los modelos con métricas de precisión tradicionales, y también con métricas de **Diversidad, Novedad y Equidad**.
3. **Definir y cuantificar el Sesgo**

Introducción

El sesgo en los sistemas recomendadores es un factor muy importante a considerar. Los sistemas recomendadores pueden generar recomendaciones sesgadas, lo que no solo puede provocar malas recomendaciones, sino que pueden discriminar personas por género, edad, etnia, etc. El 2021, en una conferencia de la UNESCO sobre IA se habló de este tema "AI technologies can be of great service to humanity and all countries can benefit from them, but also raise fundamental ethical concerns, for instance regarding the biases they can embed and exacerbate, potentially resulting in discrimination, inequality, digital divides, exclusion and a threat to cultural, social and biological diversity"[1]

Modelos y Métricas de Evaluación

Modelo 1: ALS es un modelo de filtrado colaborativo basado en factorización matricial.
Modelo 2: Anurag122002 es un modelo que genera representaciones vectoriales a partir de metadatos sugiriendo ítems mediante la similitud de coseno.
Modelo 3: DeepFM es un modelo híbrido de Deep Learning que combina factorizations machines y redes neuronales profundas.

La principal metrica de evaluación a utilizar corresponde a **Disparity**, la cual se calcula a partir de metricas como Recall@k, Precision@k, MAP@K, nDCG@k, Novelty y Diversity.

Datos

El dataset utilizado [2] presenta alta dispersión, donde predominan usuarios con pocas *reviews* concentradas en *animes* populares, generando problemas de *cold start*. Adicionalmente, los usuarios tienden a calificar con puntajes altos y existe un sesgo demografico con predominio masculino y adultos jovenes.
Para enriquecer los datos, se realizo un proceso de *scrapping* para obtener las *reviews* mas recientes de los usuarios existentes. En la gráfica se pueden observar estas mejoras.

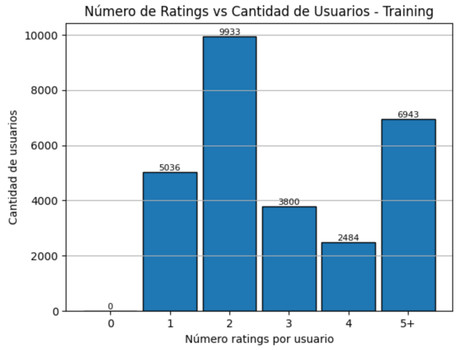

La distribución de edades del dataset se puede observar en el siguiente gráfico.

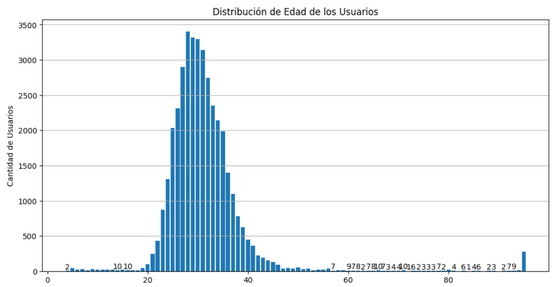

Cuantificación del Sesgo

Para clasificar si un modelo es sesgado utilizaremos el concepto de **Diferencia de Paridad Estadística** entre los subconjuntos Male y Female. Esta se modela con la siguiente fórmula:

$$\text{Disparity}(M) = \frac{\text{mín}\,(M_{\text{Male}},\, M_{\text{Female}})}{\text{máx}\,(M_{\text{Male}},\, M_{\text{Female}})}$$

la cual toma valores cercanos a 1 cuando no hay diferencia significativa. Luego dada una tolerancia $\alpha = 0{,}2$, si $\text{Disparity}(M) < 1 - \alpha$, el modelo se considera sesgado para la metrica M evaluada.

Resultados

Métrica	Disparity Ratio	Sesgado ($\leq 0{,}80$)	Grupo Favorecido
Recall	0,665	**Sí**	Masculino
Precision	0,651	**Sí**	Masculino
MAP	0,714	**Sí**	Masculino
nDCG	0,686	**Sí**	Masculino
Novelty	0,994	No	Masculino
Diversity	0,998	No	Masculino

Cuadro: Disparidad de Rendimiento en ALS (Femenino vs. Masculino)

Métrica	Disparity Ratio	Sesgado ($\leq 0{,}80$)	Grupo Favorecido
Recall	0,681	**Sí**	Masculino
Precision	0,679	**Sí**	Masculino
MAP	0,702	**Sí**	Masculino
nDCG	0,693	**Sí**	Masculino
Novelty	0,986	No	Masculino
Diversity	0,987	No	Femenino

Cuadro: Disparidad de Rendimiento Anurag122002 (Femenino vs. Masculino)

Métrica	Disparity Ratio	Sesgado ($\leq 0{,}80$)	Grupo Favorecido
Recall	0,787	**Sí**	25–34
Precision	0,769	**Sí**	25–34
MAP	0,378	**Sí**	25–34
nDCG	0,572	**Sí**	25–34
Novelty	0,846	No	45–54
Diversity	0,971	No	45–54

Cuadro: Disparidad de Rendimiento en DeepFM (25-34 vs 45-54)

Categoría	Disparity Ratio	Sesgado ($\leq 0{,}80$)	Grupo Favorecido
Más Sesgadas hacia Femenino			
Shoujo	0,549	**Sí**	Femenino
Demons	0,597	**Sí**	Femenino
Dementia	0,611	**Sí**	Femenino
Shounen Ai	0,659	**Sí**	Femenino
Josei	0,759	**Sí**	Femenino
Historical	0,746	**Sí**	Femenino
Más Sesgadas hacia Masculino			
Cars	0,502	**Sí**	Masculino
Space	0,627	**Sí**	Masculino
Game	0,767	**Sí**	Masculino
Mecha	0,775	**Sí**	Masculino
Más Equitativas (Menos Sesgadas)			
Shounen	0,997	No	Femenino
Mystery	0,969	No	Femenino
Parody	0,933	No	Femenino
Supernatural	0,933	No	Femenino
Music	0,932	No	Femenino
Drama	0,950	No	Femenino
Magic	0,943	No	Masculino
Horror	0,862	No	Femenino
Action	0,860	No	Masculino

Cuadro: Disparidad de Exposición Categórica en Anurag122002 (Femenino vs. Masculino)

Discusión

Los modelos estudiados mostraron desempeños variantes. ALS y Anurag122002 mostraron una **presencia fuerte de sesgo de género**. Por su parte, DeepFM mostró una **presencia de sesgo etario moderada**.
Respecto al sesgo de género, ALS y Anurag122002 mostraron un fuerte sesgo hacia el grupo masculino. Sus métricas de disparidad cayeron bastante por debajo del límite aceptable de 0.80. Al mirar el detalle de las categorías en Anurag122002, se nota que el modelo replica estereotipos: recomienda mucho más Cars o Mecha a hombres y Shoujo a mujeres. DeepFM tuvo un desempeño mucho más justo, únicamente presenta sesgo en la métrica de Precisión, donde sí hubo una ligera inclinación hacia los hombres. En la práctica es mucho más equitativo que los otros dos.
Respecto al sesgo etario, DeepFM presenta un sesgo fuerte marcado por una falla crítica en el ranking. Aunque el Recall y Precision son cercanas al umbral, el desplome del MAP (0.378) indica que los ítems relevantes para el grupo mayor (45-54) quedan rezagados al final de la lista, degradando severamente su experiencia.
Finalmente, las métricas de Novelty y Diversity no mostraron sesgo en ningún caso (ratios cercanos a 1.0). Al evaluar información de los ítems y no de los usuarios, la distribución de "novedad."es democrática para todos.

Conclusión

Los resultados evidencian que el buen desempeño global de los modelos esconde disparidades significativas. Mientras algunos discriminan fuertemente por género, otros penalizan el posicionamiento de los ítems por edad. Esto confirma que la optimización de métricas clásicas no garantiza la equidad, resultando en sistemas que favorecen sistemáticamente a los grupos demográficos dominantes.

Referencias

[1] UNESCO. (2021). Draft text of the Recommendation on the Ethics of Artificial Intelligence. `https://unesdoc.unesco.org/ark:/48223/pf0000377897`

[2] Marlesson. (2020). MyAnimeList Dataset - Animes, Profiles, Reviews. Kaggle. `https://www.kaggle.com/datasets/marlesson/myanimelist-dataset-animes-profiles-reviews`

[3] ghasemdev. (s.f.). *anime-recommendation-system* (GitHub Repository). `https://github.com/ghasemdev/anime-recommendation-system`

[4] anurag122002. (s.f.). *Anime_Recommendation_System* (GitHub Repository). `https://github.com/anurag122002/Anime_Recommendation_System/tree/master`

[5] benjahuenchunir. (2025). *Proyecto-Recsys* (GitHub Repository) `https://github.com/benjahuenchunir/Proyecto-Recsys/`