Recomendación Multimodal de Juegos de Mesa

Pedro Irarrázaval – Cristóbal Merino – Diego Sfeir
IIC3633 – Sistemas Recomendadores – PUC Chile

Motivación

Recomendar juegos de mesa es complejo: los usuarios tienen perfiles muy distintos, las preferencias dependen de la dificultad, temática, duración y número de jugadores, y existe una alta concentración de atención en unos pocos títulos.

Estas características convierten el dominio en un laboratorio perfecto para evaluar modelos que deben equilibrar precisión, personalización y diversidad.

La motivación del proyecto es entender cómo se comportan distintos enfoques, desde baselines hasta modelos colaborativos, híbridos y profundos, frente a estos desafíos reales.

Dataset y Protocolo Experimental

Se utilizó el dataset Board Game Database (Kaggle), con 22.000 juegos, 411.000 usuarios y 19,6M ratings. El conjunto incluye metadatos ricos (categorías, mecánicas, peso del juego, diseñadores, tiempo de juego, etc.), lo que permite analizar no solo precisión sino también diversidad temática y novedad en las recomendaciones.

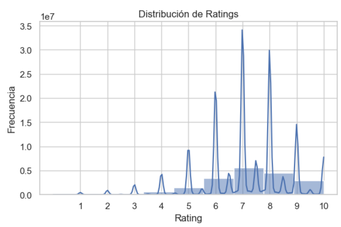

Distribución de ratings en el dataset (1–10). Se observa un sesgo fuerte hacia calificaciones altas.

Evaluación:

La evaluación se realizó utilizando un esquema hold-out por usuario (80/20), generando para cada uno un conjunto de candidatos compuesto por 1 ítem relevante y 100 negativos.

Todas las familias de modelos fueron medidas con Top-10, ya que este es el valor estándar en la literatura y ofrece un buen equilibrio entre precisión y diversidad. Solo para el modelo SVD se exploraron también Top-5 y Top-15, con el fin de analizar cómo la variación de K afecta sus métricas de ranking, diversidad y novedad. Para los demás modelos, el foco se mantuvo exclusivamente en K = 10.

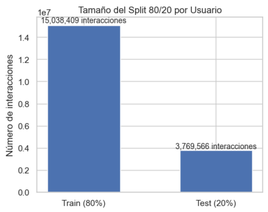

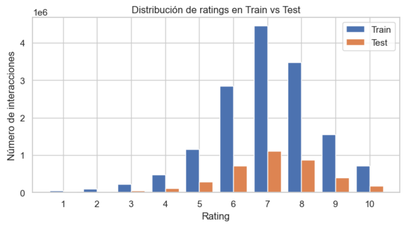

Métricas trabajadas:

Relevancia

- **Precision@10**: proporción de recomendaciones correctas dentro del Top-10.
- **Recall@10**: fracción de juegos relevantes que el modelo logra recuperar.
- **MAP@10**: precisión promedio que penaliza aciertos en posiciones tardías.
- **nDCG@10**: calidad del ranking dando más peso a las primeras posiciones.
- **MRR@10**: qué tan pronto aparece el primer juego relevante en la lista.

Diversidad y Novedad

- **IntraListDiversity@10**: qué tan distintos son entre sí los juegos recomendados (más alto = más variedad).
- **ThemeConcentration@10**: cuán concentrada está la lista en una sola categoría temática (más bajo = mejor diversidad).
- **Novelty@10**: mide cuán poco populares son los juegos recomendados según el historial de interacciones (más alto = juegos menos obvios).

Modelos Evaluados y Resultados

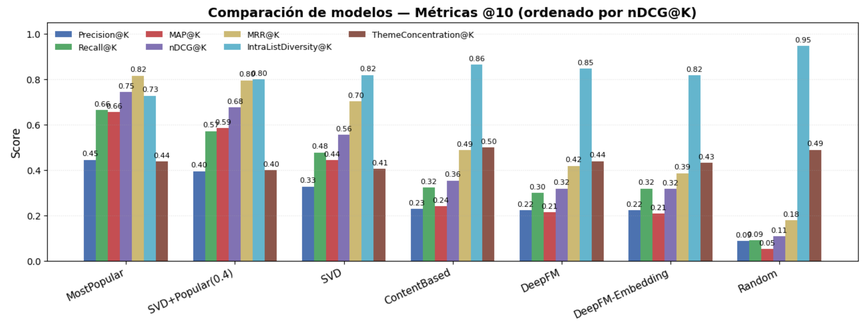

Interpretación de Resultados

Los modelos basados en popularidad (MostPopular, SVD+Popular) dominan las métricas de ranking aprovechando el sesgo del dataset, pero muestran poca variedad temática.

En contraste, DeepFM logra la mayor IntraListDiversity, explorando mejor el Long Tail a costa de menor precisión. SVD se posiciona como un punto de equilibrio entre exactitud y diversidad.

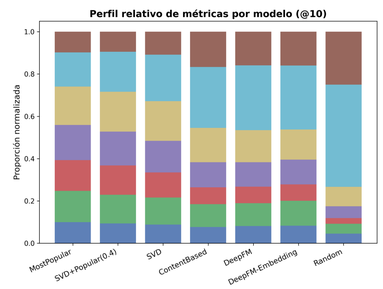

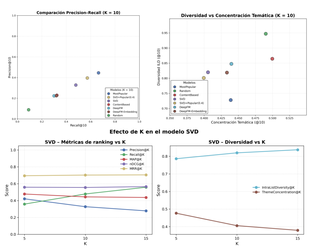

Comportamiento de Modelos

Los modelos se agrupan en patrones claros: popularidad maximiza precisión, DeepFM amplía la diversidad y SVD mantiene un balance estable entre ambos.

Efecto del valor de K en SVD

Al aumentar K, SVD pierde algo de precisión pero gana diversidad, mostrando un trade-off estable y predecible.

Tade-off entre Relevancia y Novedad

- Mayor novedad = mayor sorpresa: modelos que recomiendan juegos poco populares.
- DeepFM y ContentBased destacan en descubrimiento. MostPopular y SVD+Popular priorizan la relevancia, pero con baja novedad. SVD mantiene un equilibrio estable entre calidad del ranking y capacidad de descubrimiento.
- Los modelos se alinean sobre una frontera de Pareto: mejorar nDCG reduce novelty.

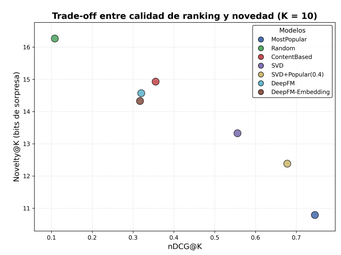

Caso de Usuario 00McCracken

Preferidos del usuario	Recomendados por SVD+Popular
Gloomhaven • Estratégico • Cooperativo • Pesado	**Pandemic Legacy S1** • Estratégico • Cooperativo • Campaña
Twilight Struggle • Conflicto 1v1 • Alta tensión	**Mechs vs Minions** • Estratégico • Cooperativo • Alta producción
Terraforming Mars • Engine Building • Largo	**7 Wonders Duel** • Duelo estratégico • Decisiones tensas

Conclusiones y Lecciones Aprendidas

- Se cumplió el objetivo principal: comparar modelos de recomendación bajo un protocolo experimental consistente y obtener conclusiones claras sobre su comportamiento.
- Cada modelo optimiza algo distinto: popularidad maximiza precisión, DeepFM incrementa diversidad y descubrimiento, y SVD mantiene el equilibrio más estable.
- La precisión no es suficiente: evaluar solo ranking oculta dimensiones clave como variedad temática y novedad.
- El dataset influye fuertemente: el sesgo hacia juegos populares afecta el rendimiento y favorece modelos basados en frecuencia.

Referencias

1. Sahinli, C., Debrauwer, F., Brugaletta, L., Martoja, T., Mishra, V., & Ruppenthal, Y. (2020). Recommender System for Board Games. Maastricht University, Research Project Final Report.
2. Threnjen. (s.f.). Board Game Database from BoardGameGeek [Conjunto de datos]. Kaggle.https://www.kaggle.com/datasets/threnjen/board-games-database-from-boardgamegeek/data

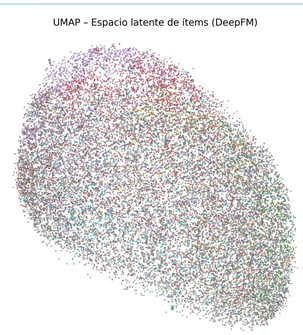

Estructura del Espacio Latente (SVD vs DeepFM)

Las proyecciones UMAP revelan que tanto SVD como DeepFM aprenden un espacio latente continuo y no segmentado, donde las categorías se mezclan de forma natural.

Esto indica que los modelos capturan relaciones basadas en patrones reales de co-interacción, más que en etiquetas rígidas, permitiendo transiciones suaves entre géneros y una organización que refleja cómo los usuarios consumen y combinan distintos tipos de juegos.