Using Collaborative Filtering for Deck Recommendation in Clash Royale

Martín Sánchez, Rodrigo Figueroa, Javiera Larraín
Pontificia Universidad Católica de Chile, Santiago de Chile, Chile
martin.sanchez@uc.cl, rodrifigueroac@uc.cl, javipaz.larrain@uc.cl

MOTIVACIÓN

La confección de barajas en videojuegos de cartas es especialmente compleja para jugadores novicios o intermedios, especialmente en juegos dinámicos y con gran diversidad de cartas como Clash Royale. La masiva audiencia y constante crecimiento del juego, motivó al desarrollo de un modelo capaz de recomendar mazos según el estilo e historial de los jugadores.

INTRODUCCIÓN

Clash Royale es un videojuego MOBA de estrategia para plataformas móviles, el cual se basa en la construcción de un mazo de 8 cartas, con las cuales el jugador puede enfrentarse a contrincantes en tiempo real. Actualmente, el juego cuenta con más de 662 millones de descargas y cerca de 50 millones de jugadores activos diariamente, lo cual implica que existe una comunidad altamente competitiva, donde la confección de un buen mazo puede significar la diferencia entre una victoria y una derrota.

La gran cantidad de usuarios, junto con la alta gama de cartas ofrecidas, puede causar frustración en usuarios nuevos intentando aprender a armar mazos, y así subir de liga.

A partir de esto, se propone un sistema recomendador basado en collaborative filtering, el cual permite a los jugadores encontrar mazos que se ajusten a sus cartas desbloqueadas, y a mazos exitosos de otros jugadores similares, entre otros factores.

DATASET

El dataset utilizado consistió en los historiales de batalla de 3000 usuarios distintos, junto a características como que mazo utilizó, si es que fue una victoria o no, la cantidad de copas con las que contaba el jugador, entre otros. De esta forma se logró recopilar información sobre más de 7500 mazos distintos, los cuales tienen las siguientes características:

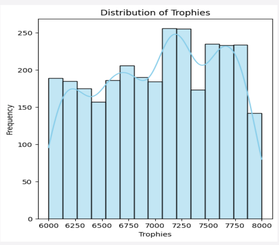

Gráfico 1. Distribución de copas

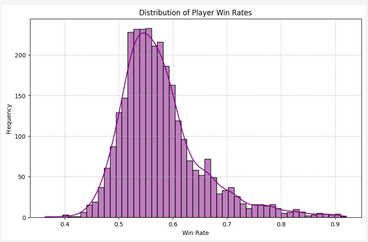

Gráfico 2. Distribución de *winrates*

Además, las cartas más utilizadas fueron *The Log*, *Royale Delivery* y *Lightning.* Por otro lado, el mazo más común encontrado estaba conformado por: *Baby Dragon, Barbarian Barrel, Barbarian Hut, Graveyard, Hunter, Mega Knight, Skeletons* y *X-Bow.*

METODOLOGÍA

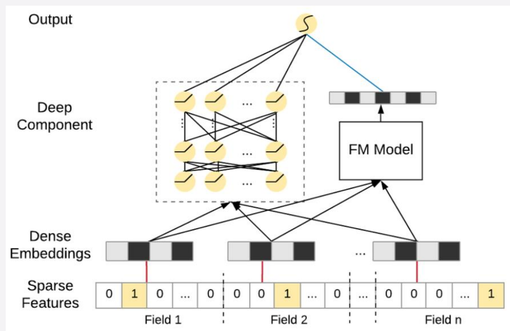

Figura 1. Arquitectura DeepFM

Recopilación de datos:

La recolección de datos se obtuvo a partir API oficial de Clash Royale, extrayendo registros de jugadores basado en que el rango de Trophies se encuentre entre los 6000 y 8000 y su ultima partida jugada haya sido en la última semana. Para cada usuario se construyó un perfil basado en la frecuencia de uso de cartas, el rango promedio y la tasa de victorias.

Estado del Arte:

El estado del arte del problema fue reconocido a través de investigaciones y experimentación. A partir de esto, se reconocieron 3 soluciones:

- LightFM: Estado del arte de *Collaborative Filtering,* útil como baseline para el proyecto.
- MultiVAE: Estado del arte de *Collaborative Filtering,* implementando aprendizaje profundo.
- Trabajo de Zang y Luo (2022): Modelo de recomendación básico de *Collaborative Filtering* orientado a Clash Royale. Fue útil como baseline al momento de decidir como serían procesados los mazos y cartas al momento de recomendar.

Modelo utilizado:

A partir de un análisis de utilidad en la propuesta, se escogió como modelo a utilizar DeepFM, dada su flexibilidad en el aspecto *Content Based.* Esto permitió enriquecer la recomendación a partir de la información cualitativa de las cartas que ofrece la API, aprovechando las características de bajo y alto nivel.

MÉTRICAS

En Clash Royale existen aproximadamente 8.99×10^11 combinaciones posibles de mazos, resultado de seleccionar 8 cartas entre 121. Además, los jugadores cambian su mazo con poca frecuencia, lo que dificulta aplicar técnicas tradicionales de Collaborative Filtering basadas en historiales extensos. Por ello, se definieron las siguientes tres métricas de evaluación.

- Online Testing: Jugadores intermedios disputaron un conjunto de partidas utilizando mazos generados por distintos baselines: META, aleatorio y el modelo propuesto. Esto permite medir el rendimiento real de cada enfoque.
- Survey: Para reducir el costo de experimentos en vivo, jugadores experimentados ordenaron diversos mazos según su calidad. Se evita así el sesgo de jugadores intermedios hacia sus mazos preferidos [1]
- Similitud con el META (offline): Cada actualización define un META representado por los 100 mazos con mayor win rate. La calidad de una recomendación se evalúa comparando su similitud con el mazo más cercano dentro de ese conjunto.

EVALUACIÓN

Dado lo costoso que es el testing con usuarios de manera online, se evaluó solamente para el baseline random y la recomendación final con DeepFM. Esto se puso en práctica con 4 usuarios de experiencia intermedia quienes jugaron 5 partidas con cada uno de los dos mazos propuestos, y que se encontraban dentro del rango de copas del usuario objetico. Los resultados se ven en la tabla 1.

Player	Random	DeepFM
Player 1	20% wins – 30% lost	40% wins – 10% lost
Player 2	30% wins – 20% lost	10% wins – 40% lost
Player 3	30% wins – 20% lost	40% wins – 10% lost
Player 4	30% wins – 20% lost	30% wins – 20% lost

Tabla 1. Resultados Online Testing

A partir del experimento, se notó que el desempeño de los jugadores al utilizar el mazo recomendado por el modelo basado en DeepFM, fue superior a un mazo creado aleatoriamente por el juego (el cual, a pesar de ser aleatorio, cuenta con ciertos parámetros con los cuales se eligen las cartas, con tal de que no sea imposible de jugar).

CONCLUSIONES

- ➔ A partir de los experimentos realizados, se concluyó que una métrica orientada a **resultados online** fue de gran utilidad, al poder nivelar las habilidades de los jugadores con contrincantes de niveles estratégicos similares.
- ➔ Los **mazos META** (Most Efective Tactics Available) fueron difíciles de superar, dado que estos cuentan con análisis y experimentos realizados por usuarios expertos, pero para jugadores de gama media, que no cuentan con un conocimiento completo sobre estrategias óptimas y no cuentan con la disponibilidad de todas las cartas, la recomendación de un mazo que se ajusta a sus disponibilidades y habilidad resultó en una experiencia de juego más agradable.
- ➔ En **trabajo futuro** proponemos un modelo actualizable a la constante adición de mecánicas nuevas al juego, como evoluciones y héroes. También la adición de un reconocimiento de estilo de juego (como defensivo, ofensivo, contraataque, etc.) crearía una experiencia de usuario aún más agradable y personalizable. Por último, la rotulación manual de las cartas según su rol asignado por la comunidad podría optimizar el reconocimiento *Content Based* del modelo, dado que las cartas han sido progresivamente reconocidas por su utilidad en el mazo, como *win condition*, tanque, *cicle*, etc.
- ➔ La recomendación en el contexto de juegos de cartas presentó un desafío no visto en otros sectores y es la dificultad de abordar un espacio donde los ítems se repiten con poca frecuencia y los usuarios no presentan historiales que permitan evaluar localmente sus desempeños.

REFERENCIAS

1. Do, T. D., Yu, D. S., Anwer, S., and Wang, S. I. (2020). Using collaborative filtering to recommend champions in league of legends. In Proceedings of the International Conference on Engineering and Computer Science.
2. Lyst (n.d.). Lightfm documentation. https://making.lyst.com/lightfm/docs/home.html. [Documentaci´on del framework LightFM]. Recuperado el 3 de noviembre de 2025.
3. Zang, L. and Luo, W. (2022). A user-based collaborative filtering system for deck recommendation in game clash royale. In Proceedings of the 2022 IEEE 14th International Conference on Computer Research and Development (ICCRD). IEEE.