PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

SISTEMA RECOMENDADOR DE NOTICIAS

MARCO AGÜERO, MARÍA DE LOS ÁNGELES RONFELDT Y CATALINA COURT

SISTEMA DE RECOMENDACIÓN HÍBRIDO Y MULTIMODAL PARA NOTICIAS UTILIZANDO DATASET MIND-SMALL

PROBLEMA

El consumo de noticias digitales presenta desafíos críticos que los sistemas tradicionales no logran resolver simultáneamente tales como la caducidad inmediata de la información, la sobrecarga de contenido y el problema de Cold-Start (usuarios y artículos nuevos sin historial).
Existe una incertidumbre sobre qué tipo de información es más valiosa para resolver esto. ¿Basta con saber qué leen los demás? ¿Es necesario entender el texto más a profundidad? ¿O se requieren ambos?

MOTIVACIÓN

Nuestra motivación principal es establecer una línea base sólida para el diseño de sistemas de recomendación en entornos de alta rotación. En lugar de asumir una solución única, buscamos evaluar empíricamente distintas estrategias de modelado.
El objetivo es indagar qué arquitectura —desde enfoques estadísticos clásicos hasta modelos híbridos neuronales— ofrece el camino más prometedor para equilibrar la precisión temática con el descubrimiento de contenido, definiendo así la dirección correcta para desarrollos futuros más robustos.

METODOLOGÍA

Utilizamos el dataset MIND-Small (156k impresiones, 48k noticias) bajo una división temporal estricta, 80% Train y 10% Test, para simular un escenario realista de flujo de noticias.
El proceso experimental se diseñó en fases incrementales para aislar el aporte de cada componente:

1. Preprocesamiento: Concatenación de Título + Abstract para maximizar la señal de texto y limpieza de datos.
2. Codificación: Transformación de usuarios e ítems a índices numéricos y generación de matrices dispersas de interacción.
3. Generación de Embeddings: Cálculo de vectores densos para todas las noticias usando S-BERT* y TF-IDF.
4. Evaluación: Medición de métricas Top-10 (Hit Rate, Precision y Recall) bajo dos escenarios complementarios: Predicción de Categoría (para evaluar consistencia temática) y Predicción de Noticia Exacta (para evaluar personalización específica).

Gráfico 1: Frecuencia por longitud de palabras en Título

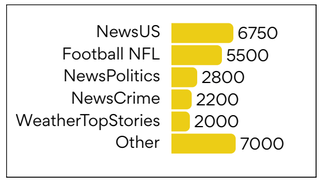

Gráfico 2: Distribución por Categoría

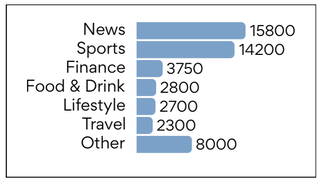

Gráfico 3: Distribución por Sub-Categoría

MODELOS

Para aislar el valor de cada fuente de información, diseñamos una estrategia incremental dividida en tres etapas:

1. La Referencia Social (Baseline):
Iniciamos con un enfoque de Filtrado Colaborativo (User-KNN) que depende exclusivamente del historial de clics. Este modelo actúa como línea base para evaluar si la similitud entre usuarios es suficiente por sí sola, sin necesidad de analizar qué dicen las noticias.

2. La Evolución del Contenido (CBF):
Posteriormente, evaluamos la capacidad de recomendar basándonos solo en el texto. Contrastamos el método clásico TF-IDF (conteo de palabras) frente a Embeddings BERT (comprensión semántica), para determinar si entender el contexto profundo de los títulos mejora la precisión frente a los métodos estadísticos tradicionales.

3. La Fusión Multimodal (Híbridos):
Finalmente, integramos estos componentes en LightFM, un modelo de factorización matricial. Comparamos una versión híbrida LightFM + TF-IDF + Metadatos frente a nuestra propuesta final: LightFM + BERT + Metadatos. Así es como se obtiene una mezcla basado en la semántica y en la adición de metadatos, correspondiente a las categorías y subcategorías en el espacio latente, buscando robustez ante la falta de datos.

REFERENCIAS

A. Mittal, R. K. Singh, R. Khare, V. Gautam, and A. Goyal, "Exploring the impact of financial literacy on individual investment decisions through mediation of financial knowledge and risk tolerance," Financial Innovation, vol. 9, no. 1, p. 207, 2023. [Online]. Available: https://link.springer.com/article/10.1007/s44196-023-00315-5
M. Nabil, "News recommendations system," Kaggle Notebook, 2025, [Online]. Available: https://www.kaggle.com/code/minanabil11111212/news-recommendations-system
G. K. Sagraha, "Mc855d5y1169: News recommendation system," Kaggle Notebook, 2025, [Online]. Available: https://www.kaggle.com/code/mendhiri/mc855d5y1169-news-recommendation-system
D. L. Macedo, "Sentence embeddings using Siamese BERT-networks," Google Colab Notebook, s.f., [Online]. Available: https://colab.research.google.com/github/dlmacedo/starter-academic/blob/master/content/courses/deeplearning/notebooks/SiameseBERT_SemanticSearch.ipynb

RESULTADOS

Para evaluar la robustez del sistema, analizamos el desempeño en dos niveles de granularidad: la capacidad de identificar la temática de interés (Tabla 1) y el desafío más complejo de predecir el artículo específico leído por el usuario (Tabla 2).

Modelo	Hit Rate @10	Recall @10	Precision @10
CF KNN	91.00%	57.34%	35.23%
CBF TF-IDF	90.00%	43.68%	45.78%
CBF BERT	90.00%	35.92%	**49.60%**
LightFM TF-IDF	90.00%	55.43%	39.46%
LightFM BERT	**95.00%**	**61.41%**	46.12%

Tabla 1: Predicción según Categoría

Modelo	Hit Rate @10	Recall @10	Precision @10
CF KNN	0.00%	0.00%	0.00%
CBF TF-IDF	1.00%	0.58%	0.13%
CBF BERT	3.00%	1.73%	0.39%
LightFM TF-IDF	7.00%	3.23%	0.70%
LightFM BERT	**16.00%**	**7.37%**	**1.60%**

Tabla 2: Predicción según Noticia Específica

En la predicción de categorías (Tabla 1), observamos dos fenómenos determinantes:

- El Efecto de Viralidad (CF KNN): Sorpresivamente, el modelo colaborativo obtuvo el segundo mejor rendimiento en cobertura (Recall: 57.34%). Esto se explica por la naturaleza del consumo de noticias: al basarse en vecinos, el modelo captura eficazmente las tendencias globales, acertando en noticias populares aunque carezca de análisis de contenido.
- La Sinergia Híbrida (LightFM BERT): Mientras que el enfoque puro de contenido (CBF BERT) lideró en Precisión (49.6%) gracias a su filtro semántico, el modelo híbrido LightFM BERT se coronó como el más robusto. No solo mantuvo una precisión competitiva (46.12%), sino que dominó indiscutiblemente en Hit Rate (95%) y Recall (61.41%).

Esto confirma que integrar la comprensión profunda del lenguaje con señales colaborativas permite expandir la exploración del usuario (mayor Recall) sin sacrificar la coherencia temática (alta Precisión).

El hallazgo más contundente se revela en la predicción exacta (Tabla 2). Mientras que los modelos base obtuvieron un rendimiento nulo o marginal, la fusión de señales en LightFM BERT logró superar esta barrera alcanzando un 16.00% de Hit Rate. Esto representa una mejora sustancial frente a la versión híbrida LightFM TF-IDF, que alcanzaba un Hit Rate de 7.00%.
Es importante contextualizar que, en un catálogo de noticias caracterizado por su alta rotación y miles de ítems efímeros, la probabilidad estadística de acertar el artículo específico es mínima. Por lo tanto, alcanzar un 16% valida que la inyección conjunta de metadatos y semántica profunda es crítica para lograr una personalización fina en catálogos dinámicos.

CONCLUSIÓN

La experimentación valida que la solución requiere una hibridación estratégica. Si bien la comprensión semántica profunda (BERT) garantiza relevancia temática, por sí sola limita la exploración. La arquitectura propuesta (**LightFM + BERT + Metadatos**) logra el equilibrio más efectivo entre precisión y descubrimiento en este estudio. Más que una solución definitiva, este enfoque se establece como la **dirección más prometedora para futuras investigaciones**, sentando las bases para desarrollar modelos verdaderamente robustos capaces de enfrentar la alta volatilidad del consumo de información.

*S-BERT all-MiniLM-L6-v2