Green RecSys: Avances en la Medición del Trade-off entre Rendimiento y Emisiones de CO2

María Ignacia De la Cuadra F. Francisco Fontecilla C. Catalina Infante M.

Introducción

El desarrollo de modelos de Inteligencia Artificial a gran escala se ha convertido en una fuente importante de emisiones de carbono a nivel global. En los Sistemas de Recomendación (RecSys), esta problemática es especialmente relevante: los modelos modernos son cada vez más complejos, operan de forma continua y requieren un alto poder computacional. Surge así el concepto de Green RecSys, que busca equilibrar la calidad de las recomendaciones con la sostenibilidad ambiental.

Investigaciones previas, como la realizada por Catalán y San Martín (2025), demostraron que entrenar modelos con todos los datos puede aumentar significativamente las emisiones sin mejorar proporcionalmente el rendimiento. Este proyecto continúa esa línea, analizando con mayor detalle cómo varía la eficiencia energética de los sistemas de recomendación según el tipo de modelo, la fracción de datos utilizada y el perfil del usuario.

Objetivos del Proyecto

Se comparan cuatro familias de modelos (Baselines, KNN, Factorización, Redes Neuronales) para entender su comportamiento energético y su capacidad de escalar. A partir de ello, se plantean tres preguntas de investigación:

- Q1: ¿Cómo escalan las emisiones de los modelos neuronales frente a los de factorización a medida que crece el dataset?
- Q2: ¿Existe un punto en que las mejoras de precisión ya no justifican el costo ambiental adicional?
- Q3: ¿El costo de inferencia es constante o depende del tipo de usuario?

Estas preguntas guían los experimentos y permiten identificar modelos que no solo sean precisos, sino también sostenibles.

Dataset

El análisis se realizó utilizando dos datasets con densidades contrastadas. MovieLens 1M representa un entorno denso, mientras que Books Crossing corresponde a un caso altamente disperso. Ambos fueron preprocesados mediante filtrado de usuarios y eliminación de calificaciones implícitas, permitiendo que las métricas fueran comparables en todas las ejecuciones.

Table 1. Estadísticas Comparativas: MovieLens 1M vs. Books Crossing

	MovieLens 1M					Books Crossing				
% Dataset	Users	Items	Train	Test	Densidad %	Users	Items	Train	Test	Densidad %
10	6,015	3,249	80k	20k	0.409	14,112	23,885	31k	8k	0.009
25	6,040	3,466	200k	50k	0.956	24,677	51,113	78k	19k	0.006
50	6,040	3,579	400k	100k	1.851	30,037	88,126	155k	39k	0.006
75	6,040	3,638	600k	150k	2.731	31,494	119,742	233k	58k	0.006
100	6,040	3,675	800k	200k	3.605	31,967	147,660	311k	78k	0.007

Algoritmos

El proyecto utiliza un conjunto diverso de modelos para comparar su rendimiento y su eficiencia energética bajo condiciones controladas. Se evaluaron diez algoritmos ampliamente usados en la literatura, organizados en cuatro familias, lo que permitió analizar diferencias estructurales entre enfoques simples, clásicos y modernos. Todos los modelos fueron entrenados sobre las mismas fracciones del dataset (10%, 25%, 50%, 75% y 100%), asegurando una comparación justa en precisión, escalabilidad y consumo energético. Las familias de modelos son las siguientes: Línea Base: Random y Most Popular. Filtrado Colaborativo Clásico (KNN): UserKNN y ItemKNN. Factorización Matricial: SVD, ALS y LightFM. Modelos Neuronales: NCF, MultiVAE y LightGCN.

Metodología

Las mediciones energéticas se obtuvieron utilizando un entorno controlado de hardware (CPU M1 Pro, 10 núcleos). El consumo de energía y las emisiones estimadas de CO_2 se registraron con la librería CodeCarbon, tanto en entrenamiento como en el proceso de generación de recomendaciones. Esto permitió evaluar el costo computacional de cada modelo desde una perspectiva ambiental.

El estudio también incorpora un análisis del costo de inferencia según el tipo de usuario. Para ello, se definieron seis perfiles representativos (Power User, Cold-Start, Critic, Fan, Niche Seeker y Mainstream) y se midió la energía necesaria para generar recomendaciones para cada uno. Esto permitió identificar diferencias en el costo computacional asociadas al comportamiento del usuario y a la estructura de los datos.

Perfil	Descripción	Comportamiento típico
Power User	Usuario con alta actividad y gran cantidad de interacciones.	Evalúa muchos ítems, lo que incrementa el costo de inferencia.
Cold-Start User	Usuario nuevo o con pocas calificaciones.	Genera mayor incertidumbre en las predicciones.
Critic	Usuario muy activo con calificaciones bajas.	Tiende a reducir la precisión del modelo.
Fan	Usuario muy activo con calificaciones altas.	Refuerza patrones positivos y mejora la precisión.
Niche Seeker	Usuario que prefiere ítems poco populares.	Aumenta el costo computacional por baja coincidencia.
Mainstream User	Usuario que prefiere ítems populares.	Recomendaciones más simples y de bajo costo.

Table 2. Perfiles de usuario considerados en el análisis de inferencia.

Finalmente, la evaluación del trade-off se basó en cuatro dimensiones: precisión (NDCG@10), energía total consumida, escalabilidad con respecto al tamaño del dataset y eficiencia energética en términos de NDCG por kWh. Este enfoque permitió comparar de manera integral el rendimiento de cada familia de modelos en escenarios densos y dispersos.

Resultados - Trade off

El análisis revela patrones claros en la relación entre precisión, consumo energético y estructura del dataset.

En MovieLens (dataset denso), los modelos más modernos, especialmente la Factorización Matricial y algunos neuronales como MultiVAE, superan ampliamente a los baselines y al Filtrado Colaborativo, alcanzando alta precisión con un costo energético bajo.

En Books Crossing, en cambio, el comportamiento cambia drásticamente: las diferencias entre modelos se reducen y los resultados tienden a ser casi aleatorios. Modelos simples como Most Popular e incluso LightFM superan en eficiencia a arquitecturas más complejas, mientras que los modelos neuronales pierden rendimiento y consumen más energía. Esto sugiere que la extrema dispersión y la baja calidad del dataset dificultan que los algoritmos aprendan patrones significativos.

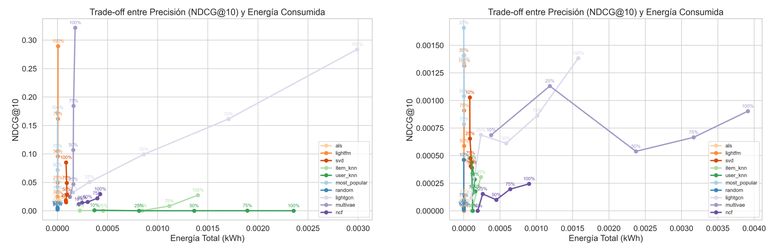

Trade-off entre Precisión (NDCG@10) y Energía Consumida (kWh). (MovieLens 1M, Books Crossing)

Resultados - Escalabilidad por Familia de Modelos

Este análisis evalúa cómo varían la precisión y el consumo energético a medida que se incrementa la fracción del dataset utilizada en el entrenamiento. Este comportamiento permite comparar la estabilidad y eficiencia de cada familia de modelos en escenarios de distinto volumen y densidad de datos.

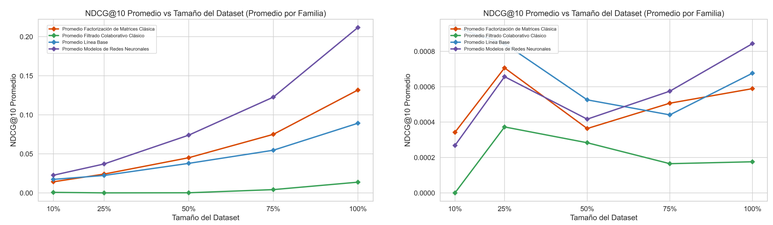

NDCG@10 vs. Fracción de datos por familia, para cada dataset. (MovieLens 1M, Books Crossing)

En términos de precisión, solo los Modelos Neuronales y la Factorización Matricial muestran mejoras reales a medida que aumenta la cantidad de datos. Sus curvas crecen de forma sostenida, evidenciando que estas familias sí logran aprovechar el mayor volumen de información. En contraste, el Filtrado Colaborativo Clásico deja de mejorar, funcionando principalmente como un punto de referencia inferior.

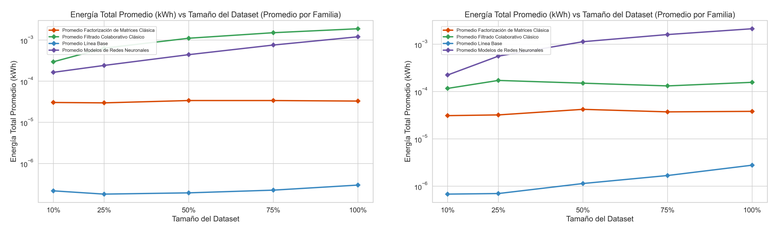

Energía consumida (kWh) vs Fracción de datos por familia. (MovieLens 1M, Books Crossing)

El patrón energético es distinto. La Factorización Matricial presenta el mejor equilibrio: bajo consumo, crecimiento moderado y estabilidad incluso con el 100% del dataset. Los Modelos Neuronales logran mayor precisión, pero su costo energético aumenta de forma más acelerada, especialmente en el caso de LightGCN. El Filtrado Colaborativo Clásico resulta el menos eficiente, ya que incrementa su gasto sin mejorar de manera proporcional su rendimiento.

La densidad del dataset también influye. En MovieLens (denso), los modelos neuronales escalan mejor y muestran mejoras claras en precisión. En Books Crossing (altamente disperso), la eficiencia energética se deteriora y las diferencias entre familias se amplifican, mientras que la factorización mantiene un comportamiento más estable.

En conjunto, estos resultados posicionan a la Factorización Matricial como la familia más sostenible y escalable, logrando el mejor balance entre crecimiento en precisión y costo energético controlado a medida que aumentan los datos.

Resultados - Costo de Inferencia por Perfil de Usuario

El análisis del costo de inferencia busca entender cómo varía la energía necesaria para generar recomendaciones según el tipo de usuario que interactúa con el sistema. Cada uno de los perfiles de usuario captura un estilo distinto de interacción, permitiendo evaluar si la demanda energética depende únicamente del modelo o también del comportamiento del usuario.

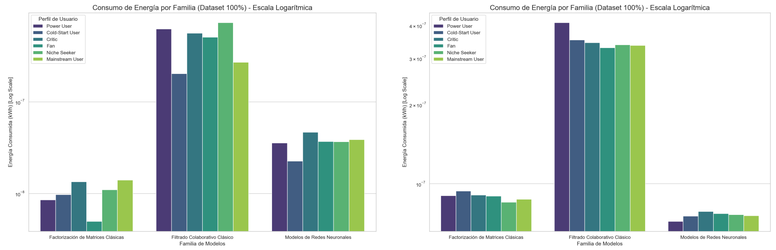

Consumo de Energía por Familia (Dataset 100%). Escala Logarítmica. (MovieLens 1M, Books Crossing)

Los resultados muestran que, en este caso, el perfil del usuario no produce diferencias significativas en el costo de inferencia. Las curvas para Power, Cold-Start, Critic, Fan, Niche Seeker y Mainstream son similares dentro de cada familia de modelos, lo que indica que el consumo energético depende principalmente del tipo de algoritmo y no del comportamiento del usuario.

En particular, el Filtrado Colaborativo Clásico es consistentemente el más costoso, mientras que la Factorización Matricial y los modelos neuronales mantienen consumos más estables y bajos. Esto sugiere que, para inferencia, la elección del modelo tiene un impacto considerablemente mayor que las diferencias entre perfiles de usuarios.

Es importante aclarar que para este análisis usamos un único usuario representativo por cada perfil. Trabajar con más casos hacía el proceso mucho más pesado de ejecutar. Aun así, las diferencias entre perfiles y modelos siguen marcando tendencias, aunque los valores puntuales deben mirarse con cierta cautela.

Discusión

Los resultados del estudio muestran que la sostenibilidad de un Sistema de Recomendación depende principalmente de dos factores: el tipo de modelo y la estructura del dataset. En MovieLens, un entorno denso y bien estructurado, los Modelos Neuronales y la Factorización logran altos niveles de precisión sin un costo energético excesivo. En contraste, en Books Crossing (un dataset extremadamente disperso) esa ventaja desaparece, todos los modelos pierden precisión y los algoritmos más complejos requieren más energía para aprender patrones que prácticamente no existen.

La Factorización Matricial se posiciona como la familia más estable y eficiente. Escala bien cuando aumenta la cantidad de datos, mantiene un consumo energético moderado y conserva rendimiento tanto en escenarios densos como dispersos. En cambio, el Filtrado Colaborativo Clásico muestra baja precisión y un costo energético desproporcionado, especialmente en inferencia, donde el número de vecinos y la falta de coincidencias afecta directamente su eficiencia.

Por otro lado, el análisis por perfiles de usuario revela que, en este experimento, las diferencias entre Power Users, Cold-Start, Critics o Mainstream son menores dentro de cada modelo. Esto indica que, para la mayoría de las arquitecturas, el perfil del usuario tiene un impacto limitado en el costo de inferencia, siendo el tipo de algoritmo y la densidad del dataset los factores determinantes.

Conclusión

El estudio muestra que la sostenibilidad de un sistema de recomendación depende a la vez del modelo y la estructura del dataset.

Q1 — Escalamiento energético.
En MovieLens (denso), los modelos neuronales escalan bien en precisión, pero su consumo energético crece rápido. En cambio, la Factorización Matricial mejora de forma estable y mantiene un gasto energético mucho menor. En Books Crossing (muy disperso), esta diferencia se amplifica: los modelos neuronales pierden rendimiento y se vuelven poco eficientes, mientras que la factorización conserva un comportamiento más robusto.

Q2 — Trade off entre precisión y tamaño del Dataset
En varios modelos vimos que llega un momento en que sumar más datos deja de ser realmente útil: la precisión apenas mejora, pero el consumo energético sigue aumentando. Aun así, hay casos donde la precisión continúa creciendo con más datos.

Q3 — Costo de inferencia según el tipo de usuario.
Las diferencias entre perfiles son pequeñas. El costo de inferencia depende mucho más del tipo de modelo que del usuario: las familias siguen el mismo orden (Filtrado Colaborativo es el más costoso; Factorización Matricial, el más eficiente). Esto sugiere que la sostenibilidad en inferencia se define por el algoritmo, más que por el comportamiento del usuario.

En conjunto, los resultados apuntan a que no existe un único modelo "verde" para todos los casos. La elección depende del dominio, la densidad del dataset y del tipo de usuario al que se quiere servir. Aun así, la Factorización Matricial aparece como la alternativa más consistente entre precisión, eficiencia energética y estabilidad.

Referencias

[1] Ardalan Arabzadeh, Tobias Vente, and Joeran Beel. Green recommender systems: Optimizing dataset size for energy-efficient algorithm performance. *arXiv preprint*, 2024. URL https://arxiv.org/abs/2410.09359.

[2] G. Catalán and I. San Martín. Evaluación del trade-off entre emisiones de carbono y rendimiento en sistemas de recomendación. *Preprint*, 2025. URL https://github.com/PUC-RecSys-Class/RecSysPUC-2025-1/blob/master/proyecto/proy_finales_2025/Paper-G15.pdf.

[3] F. Maxwell Harper and Joseph A. Konstan. The movielens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems (TiiS)*, 5(4):1–19, 2015. doi: 10.1145/2827872.

[4] Qijiong Liu, Jieming Zhu, Quanyu Dai, and Xiao-Ming Wu. Benchmarking news recommendation in the era of green ai. In *Companion Proceedings of the ACM Web Conference 2024 (WWW '24 Companion)*, Singapore, 2024. ACM. doi: 10.1145/3589335.3651472.

[5] Roy Schwartz, Jesse Dodge, Noah A. Smith, and Oren Etzioni. Green ai. *arXiv preprint*, 2019. URL https://arxiv.org/abs/1907.10597.