CIVIConnect: Sistema de recomendación de audiencias cívicas

Felipe Marín & Camila Rojas

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación

Motivación

En Chile, el registro Ley del Lobby dispone de más de 620.000 audiencias entre sujetos activos (solicitantes) y sujetos pasivos (autoridades) desde 2014, pero no provee mecanismos para orientar a los usuarios (solicitantes) respecto de qué autoridad es pertinente de acuerdo a su historial y sus materias de interés. Este vacío genera sobrecarga de opciones, decisiones poco informadas y desigualdades en la capacidad de navegación institucional. Asimismo, la distribución de solicitudes muestra fuerte concentración: un pequeño grupo de autoridades recibe un volumen desproporcionado de audiencias, mientras otras casi nunca son solicitadas.

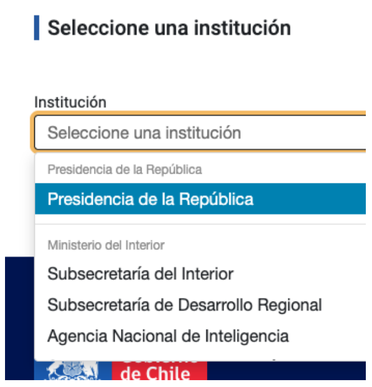

Figura 1. Interfaz actual de selección de institución.

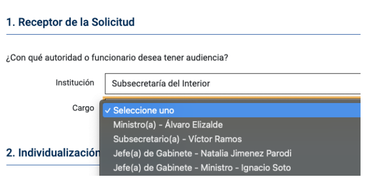

Figura 2. Interfaz actual de selección de autoridad.

Objetivos

- Crear un dataset donde se almacene la información pertinente en relación con las solicitudes de audiencia.
- Desarrollar y evaluar un sistema de recomendación que permita identificar autoridades pertinentes para cada sujeto activo y contribuya a una distribución más equilibrada de las solicitudes.

Datos

La información utilizada proviene del portal público Ley del Lobby (Ley N° 20.730), que registra audiencias entre autoridades públicas (sujetos pasivos) y solicitantes (sujetos activos) desde 2014.
El sitio no ofrece una API ni un formato de descarga estructurado, por lo que implementamos un proceso de *web scraping* que recorre automáticamente las páginas de audiencias, identifica enlaces de detalle y extrae los campos relevantes.
Con este procedimiento construimos un dataset estructurado con más de 622 000 audiencias (2014–2024), cada una con fecha, institución, autoridades participantes, asistentes y materias tratadas. Este dataset es la base de los modelos de recomendación propuestos.

Para capturar la semántica de las materias tratadas, generamos vectores de representación (*embeddings*) utilizando el modelo `Sentence Transformers` (`paraphrase-multilingual-mpnet-base-v2`). Esto permite analizar similitud temática entre audiencias y enriquecer las señales utilizadas por los algoritmos de recomendación.

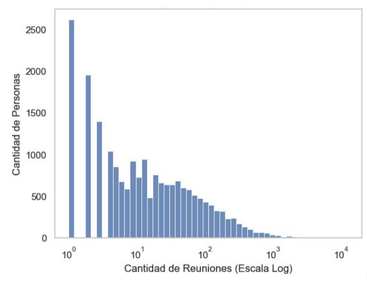

Figura 3. Distribución de audiencias por sujeto pasivo.

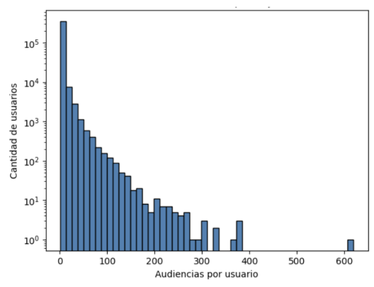

Figura 4. Distribución de audiencias por sujeto activo.

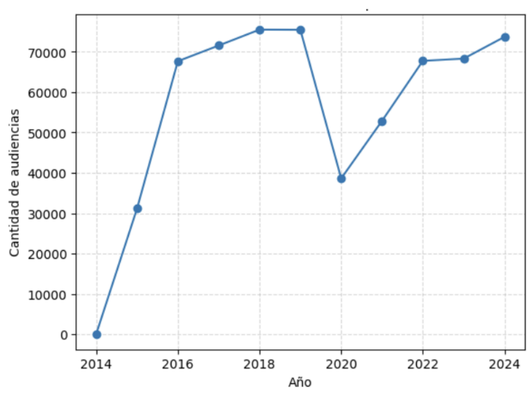

Figura 3. Evolución de audiencias por año.

Metodología

El estudio evalúa cinco enfoques de recomendación que combinan señales estructurales (historial de audiencias) y semánticas (materias tratadas). Todos los métodos se entrenan bajo un marco de *feedback* implícito y se comparan mediante métricas de ranking *top-N* y de saturación de ítems recomendados (Índice Gini).

1. LightFM

Se integra información de interacciones usuario–autoridad con representaciones semánticas basadas en embeddings SBERT. Se aplica un *holdout* user-wise por recencia y se construyen features mediante promedios con decaimiento temporal y normalización L2. El modelo se entrena con pérdida WARP, combinando señales colaborativas y de contenido.

2. LightGCN colaborativo

Modelo basado en un grafo bipartito usuario–autoridad que propaga información sin activaciones no lineales. Captura similitudes implícitas en la estructura institucional. Entrenado con pérdida BPR y muestreo negativo uniforme.

3. LightFM + reranking supervisado

A partir del *top-N* preliminar generado por LightFM, se aplica un *reranker* supervisado que combina características relacionales, señales semánticas de similitud temática y popularidad institucional. Permite comparar un enfoque 2-stage con el rendimiento base.

4. LightGCN con nodos temáticos

Para incorporar información semántica de las materias tratadas, los textos se transformaron en representaciones vectoriales utilizando modelos de lenguaje preentrenados. Estos embeddings se proyectaron a un espacio latente de menor dimensión mediante una técnica de reducción lineal, con el fin de preservar la estructura temática esencial. Sobre este espacio reducido se aplicó el algoritmo de agrupamiento KMeans para identificar conjuntos de materias conceptualmente similares. Cada grupo se interpreta como un *tópico*, cuya representación se obtiene a partir del centroide del grupo. Estos tópicos se incorporan como *nodos temáticos* en el grafo.
Con esta información se construyó un grafo **tripartito** compuesto por usuarios, autoridades y temas. LightGCN se entrena sobre esta estructura, propagando simultáneamente señales *estructurales* (patrones de interacción en el grafo) y *semánticas* (relaciones temáticas).

5. Modelo de clustering semántico

Pipeline basado en embeddings SBERT, reducción dimensional híbrida (PCA + UMAP) y agrupamiento con HDBSCAN. Para mejorar cobertura y estabilidad, se aplica una etapa posterior de sub-clusterización mediante K-Means sobre los elementos no asignados inicialmente utilizando la distancia coseno.

Resultados

En la evaluación del modelo basado en clustering semántico se obtuvo un Hit Rate@10 del 80,7 % y un MRR de 0,76, asegurando un ranking de alta calidad y una correcta cohesión temática. Adicionalmente, las pruebas de estrés confirmaron la robustez del modelo con una precisión del 34 % ante la pérdida parcial de información, evidenciando la captura de patrones profundos.

Modelo	Recall@10	nDCG@10	MAP@10	Índice Gini
ALS	0.01	0.18	0.14	0.63
ItemKNN	0.05	0.74	0.03	0.947
LightGCN	0.09	0.08	0.06	0.80
LightFM	0.04	0.03	0.03	0.90
LightFM + Reranking	0.08	0.06	0.04	0.57
LightGCN Tripartito con nodos temáticos	0.75	0.72	0.70	**0.49**
Clustering semántico	**0.79**	**0.77**	**0.76**	0.5345

Cuadro: Comparación de métricas: El modelo propuesto supera a los baselines y modelos del estado del arte.

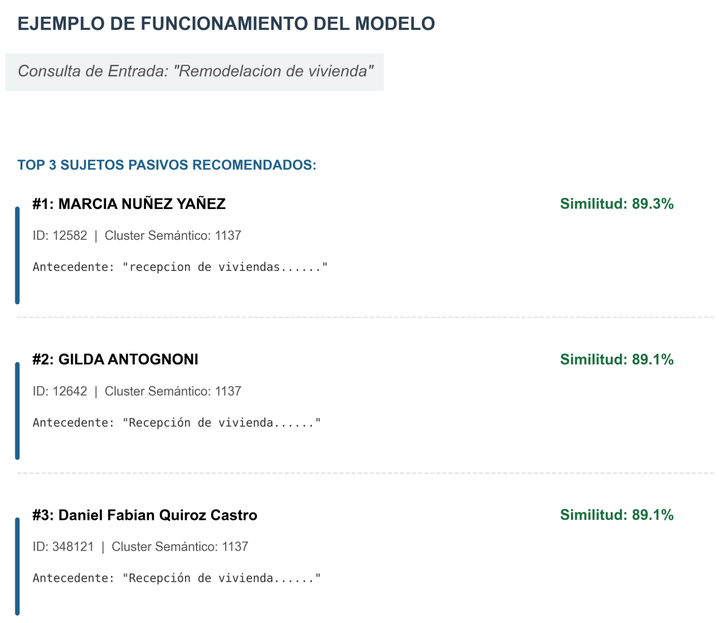

Figura: Ejemplo real de inferencia: A partir de una solicitud de vivienda, el modelo recupera autoridades pertinentes basándose en antecedentes semánticos previos.

Referencias

- N. Reimers and I. Gurevych, "Sentence-bert: Sentence embeddings using siamese bert-networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 11 2019. [Online]. Available: https://arxiv.org/abs/1908.10084
- V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter," *arXiv preprint arXiv:1910.01108*, 2019.
- Gobierno de Chile, "Plataforma Ley de Lobby," https://www.leylobby.gob.cl/, 2025, fuente de datos obtenida mediante Web Scraping. [Accedido: Noviembre 2025].