Leveraging Large Language Models for Zero-Shot and Re-Ranking Recommendation Systems

Matias Giddings

Ingeniería Matemática y Computacional, Pontificia Universidad Católica de Chile

Objetivos de Investigación

- **Evaluar** la capacidad de inferencia semántica de los LLMs en escenarios *Zero-Shot* y como agentes de *Re-Ranking*.
- **Comparar** el impacto del Re-Ranking sobre dos tipos de recuperadores: personalizados (SVD) y no personalizados (Popularity).
- **Analizar** si el razonamiento del LLM puede superar el fuerte sesgo de popularidad existente en set de datos clásicos.

Introducción

Los sistemas de recomendación modernos enfrentan el desafío dual de gestionar la sobrecarga de información y mitigar el problema de *Cold-Start*. Mientras que los métodos clásicos dependen de matrices de interacción densas, carecen de capacidad de razonamiento explicable.

Estudios recientes [1, 2] sugieren que los LLMs pueden actuar como recomendadores generalistas gracias a su vasto conocimiento de mundo y de las relaciones semánticas. Sin embargo, su uso directo como *retrievers* es computacionalmente intensivo/prohibitivo.

Este trabajo propone una arquitectura híbrida: utilizar métodos eficientes (SVD) para la recuperación de candidatos y LLMs para un re-ordenamiento semántico refinado.

Metodología y Modelos

1. Líneas Base (Baselines)

- **Popularity:** Benchmark no personalizado (Top-N global).
- **User-CF:** Filtrado colaborativo basado en memoria (k-NN, $k = 10$). [3]
- **SVD (Singular Value Decomposition):** Factorización matricial que captura patrones latentes. La predicción del rating $\hat{r}_{ui}$ se define como:

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u$$

Donde b_u, b_i son sesgos y q_i, p_u son vectores latentes.

2. Estrategias LLM (Gemini API)

- **Zero-Shot:** El LLM recibe el historial ($m = 10$) y genera items sin candidatos pre-seleccionados.
- **Estrategia B: Re-Ranker (Two-Stage)**
  1. **Retrieval:** Generación eficiente de $2n$ candidatos basada en dos modelos: Popularity y SVD.
  2. **Ranking (LLM):** Re-ordenamiento basado en similitud semántica y razonamiento lógico.

Configuración Experimental

Dataset: MovieLens-100k. [4]
Protocolo de Evaluación:

- *Split Temporal:* Para cada usuario, se utilizaron el 80% de las interacciones más antiguas para entrenamiento y el 20% más reciente para test.
- *Muestra:* Se seleccionaron 30 usuarios aleatorios del conjunto de test para la evaluación con LLM debido a restricciones de costo computacional y latencia API.
- *Métricas:* Precision@K, Recall@K y nDCG@K (con $K = 10$).

Resultados Cuantitativos

Modelo	Prec@10	Rec@10	nDCG@10
Random	0.007	0.007	0.011
SVD	0.038	0.039	0.033
User-CF	0.031	0.042	0.035
Popularity (Baseline)	**0.079**	**0.085**	**0.104**
LLM Zero-Shot	0.028	0.043	0.040
LLM Re-ranker (SVD)	0.048	0.046	0.056
LLM Re-ranker (Pop)	*0.076*	*0.065*	*0.097*

Table 1: Comparación de métricas. Popularity domina el benchmark, pero el LLM mejora significativamente al SVD base.

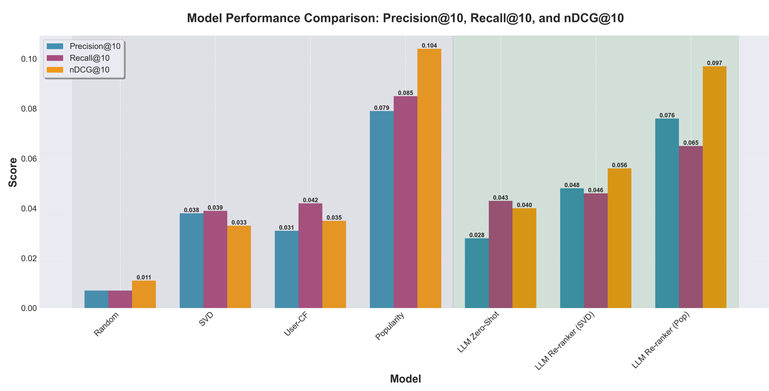

Figure 1: Comparación gráfica de métricas

Análisis de Resultados

1. La "Corrección" del LLM sobre SVD: SVD obtuvo un desempeño pobre (nDCG 0.033). Al aplicar el LLM Re-ranker sobre estos candidatos, el nDCG subió a 0.056 (**+69.7% de mejora**). Esto indica que el LLM es excelente identificando los elementos verdaderamente relevantes dentro de una lista de candidatos ruidosa o débil.

2. La Paradoja de la Popularidad: El modelo *Popularity* superó a todos los modelos personalizados. Curiosamente, aplicar el LLM sobre Popularidad disminuyó levemente las métricas (nDCG 0.104 $\rightarrow$ 0.097). El LLM intentó "personalizar" la lista popular, pero al hacerlo, descartó elementos genéricos que el usuario sí consumió (falsos negativos semánticos).

3. Zero-Shot Competitivo: Sorprendentemente, el *LLM Zero-Shot* superó al SVD base en nDCG (0.040 vs 0.033), demostrando que el conocimiento intrínseco del modelo puede superar a una factorización matricial mal ajustada.

Desafíos de Implementación

La integración de LLMs en sistemas de producción presenta obstáculos significativos:

- **Latencia de Inferencia:** El LLM (4s/query) es órdenes de magnitud más lento que SVD (10ms).
- **Context Window:** Limita la cantidad de historial de usuario inyectable.
- **Alucinaciones de Formato:** Requiere *parsers* robustos para asegurar que la salida sea una lista procesable (JSON/List).
- **Determinismo:** La naturaleza estocástica de los modelos generativos dificulta la reproducibilidad exacta de los experimentos sin semillas fijas.

Discusión y Trabajo Futuro

Hacia Modelos Híbridos: Nuestros resultados confirman que la estrategia óptima no es reemplazar, sino **aumentar** los modelos colaborativos eficientes con la capacidad semántica de los LLMs en la etapa final de ranking.

Próximos Pasos:

- **Chain-of-Thought (CoT):** Forzar al modelo a "razonar" antes de recomendar para mejorar la interpretabilidad.
- **Fine-tuning (PEFT):** Adaptar modelos más pequeños (ej. Llama-3-8B) para reducir latencia y mejorar la adherencia al formato.
- **Evaluación a Gran Escala:** Extender el test a $N > 1000$ usuarios para validar significancia estadística.

Conclusión

Este estudio demuestra la viabilidad de los LLMs como *Re-Rankers* semánticos. Aunque el costo computacional sigue siendo una barrera para el despliegue en tiempo real, la mejora en la calidad del ranking (nDCG) sugiere un futuro prometedor para sistemas híbridos que combinan la eficiencia matemática de la factorización matricial con la comprensión del lenguaje natural.

Referencias

[1] Yupeng Hou, Junjie Zhang, Zihan Lin, Hongyu Lu, Ruobing Xie, Julian McAuley, and Wayne Xin Zhao.
Large language models are zero-shot rankers for recommender systems, 2024.

[2] Likang Wu, Zhi Zheng, Zhaopeng Qiu, Hao Wang, Hongchao Gu, Tingjia Shen, Chuan Qin, Chen Zhu, Hengshu Zhu, Qi Liu, Hui Xiong, and Enhong Chen.
A survey on large language models for recommendation, 2024.

[3] John S. Breese, David Heckerman, and Carl Kadie.
Empirical analysis of predictive algorithms for collaborative filtering, 2013.

[4] F. Maxwell Harper and Joseph A. Konstan.
The movielens datasets: History and context.
ACM Transactions on Interactive Intelligent Systems (TiiS), 5(4):19:1–19:19, 2015.