Análisis del Trade-off entre Precisión y Desinformación en Sistemas de Recomendación de Noticias basados en Grafos

¿Estamos optimizando la viralización de mentiras? Una evaluación de GNNs y Modelos Clásicos.

Vittorio Salvatore, Clemente Acevedo, Cristóbal Fuentes
Pontificia Universidad Católica de Chile · IIC3633 - Sistemas Recomendadores

1. Motivación: El Desafío de la Desinformación

Las redes sociales han democratizado el acceso a la información, pero también han facilitado la propagación viral de noticias falsas. Los algoritmos de recomendación, al optimizar ciegamente la interacción del usuario, pueden amplificar este contenido nocivo.

Viralidad Diferencial

Las fake news generan
1.8x
más interacciones que noticias verdaderas
(33.0 vs 18.1 promedio)

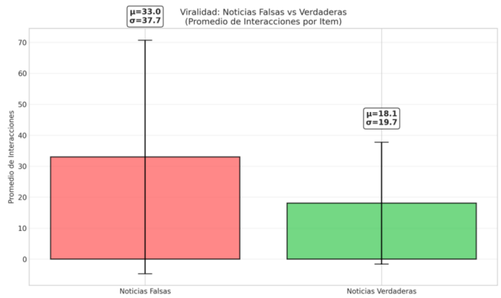

Figura: Viralidad Orgánica: Análisis de datasets *Twitter15* y *Twitter16*. Los algoritmos corren el riesgo de aprender y exacerbar este sesgo.

Pregunta de Investigación

¿Son los modelos de última generación, como las *Graph Neural Networks* (GNNs), capaces de mitigar este fenómeno, o lo empeoran en su búsqueda de mayor precisión?

Dataset: Twitter15 y Twitter16

Utilizamos los datasets **Twitter15** y **Twitter16**, benchmarks clásicos para estudiar *rumor detection* y difusión de noticias. Cada conjunto está centrado en **eventos/rumores** asociados a un **tweet raíz**, junto con su **cascada de propagación** (respuestas/retweets) y señales sociales (usuarios e interacciones).

Las noticias se anotan como **True Rumor (TR)**, **False Rumor (FR)** y **Unverified (UR)**, permitiendo cuantificar exposición a desinformación.

2. Metodología

39,958 Usuarios
110,732 Interacciones

Aplicamos un split temporal estricto (80/10/10) para simular un escenario de recomendación realista sin filtración de datos futuros.

Grafo Social Implícito y Thresholding

Para modelar la difusión, construimos un grafo conectando usuarios con intereses similares. Establecimos un umbral de ≥ 3 ítems compartidos basándonos en la evidencia estadística:

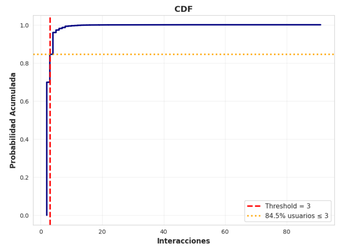

Figura: El **98.9 %** de los pares no comparten ítems. Un umbral de 3 filtra el ruido de coincidencias aleatorias, reteniendo solo conexiones significativas.

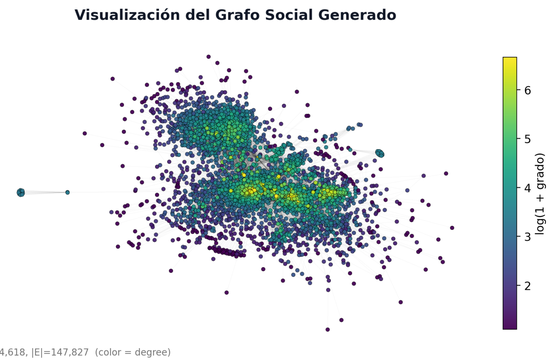

Figura: Visualización del Grado Social generado. Se observa la precencia de nodos hubs y clusters distintos.

Nueva Métrica: Fake@K

Para cuantificar el riesgo de manera objetiva, formalizamos la métrica:

$$\text{Fake@K} = \frac{1}{|U|} \sum_{u \in U} \frac{|\{i \in \text{Top-K}_u : \text{label}(i) = \text{FR}\}|}{K}$$

Mide la proporción de *False Rumors* (FR) que el modelo inyecta en las listas de recomendación.

3. Resultados: El Trade-off

Evaluamos 8 modelos distintos. Al cruzar la precisión (MRR) con la seguridad (Fake@K), emerge una clara **Frontera de Pareto**:

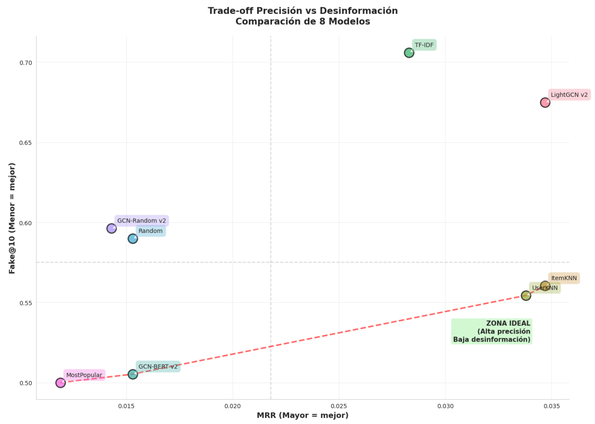

Figura: Precisión vs. Seguridad. Se observa que mayor precisión conlleva mayor riesgo. LightGCN domina en precisión pero falla en seguridad.

HALLAZGO CRÍTICO

LightGCN amplifica la desinformación en un **+10 %** respecto al sesgo orgánico del dataset, exponiendo a los usuarios a un **67.5 %** de fake news.

- **Alta Precisión, Alto Riesgo:** **LightGCN** obtiene el mejor MRR (0.0347) pero expone al usuario a un **67.5 % de Fake News**.
- **Seguridad Semántica:** **GCN-BERT** sacrifica precisión (MRR 0.0153) pero es el único modelo que **reduce** la desinformación (50.5 %) gracias a embeddings de texto.

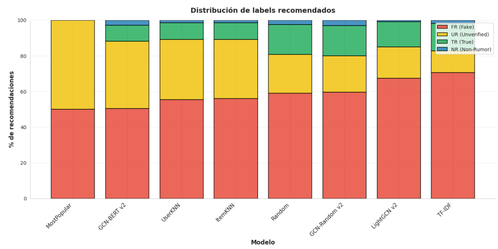

Figura: Los modelos híbridos logran diversificar hacia contenido **'Verdadero'**, mientras que TF-IDF satura con **'Falso'**.

4. Impacto Social y Conclusiones

Simulamos el impacto social utilizando el **Linear Threshold Model (LTM)**. Los resultados confirman que la diversidad en las recomendaciones actúa como un cortafuegos: los modelos más diversos (como GCN-BERT) generaron cascadas de difusión más pequeñas y lentas.

Conclusiones Principales:

1. Trade-off Confirmado
Existe una tensión inherente e inevitable entre maximizar la precisión (MRR) y minimizar la exposición a desinformación con las arquitecturas actuales.

2. La Complejidad no garantiza Seguridad
Modelos estructurales simples como **ItemKNN** resultaron ofrecer un mejor balance ético que GNNs complejas que no incorporan semántica.

3. Recomendación
Para entornos sensibles (noticias, salud), se debe priorizar modelos en la "zona balanceada" de la frontera de Pareto o implementar mecanismos de re-rankeo basados en contenido.

Modelo Recomendado

ItemKNN + Content Filtering

Balance óptimo entre precisión y seguridad
MRR: 0.0347 · Fake@10: 56.0 %

Repositorio y Código:

`github.com/aLotOfGluten/IIC3633-Proyecto`