Álvaro Sotomayor
David Chen

Replicabilidad & Reproducibilidad del Paper

Enhancing User Intent Capture in Session-Based Recommendation with Attribute Pattern

Contexto

La literatura reciente en sistemas de recomendación enfrenta una **crisis de reproducibilidad**, donde las mejoras reportadas en el estado del arte frecuentemente no se sostienen en entornos independientes o no son fácilmente reproducibles.

En este contexto, el modelo **FAPAT** introduce un enfoque novedoso para resolver el problema de las recomendaciones basadas en sesiones: utilizar **patrones frecuentes de atributos** (ej. marca, categoría) para mitigar la escasez de datos en sesiones cortas.

Objetivos

1. **Replicabilidad (Benchmark)**: Replicar los resultados reportados en el paper original utilizando el dataset Diginetica, asegurando la fidelidad del código y los hiperparámetros.

2. **Reproducibilidad y Generalización**: Evaluar la robustez del modelo aplicando la metodología en dominios no explorados por los autores: Cine: MovieLens 100K (Interacciones densas). E-Commerce: Amazon Video Games (Alta dispersión/sparsity). Benchmarking riguroso contra las líneas base del estado del arte (GRU4Rec, S3-Rec, GCE-GNN).

3. **Contribución Técnica (FAPAT V2)**: Diseñar e implementar una variante Time-Aware de FAPAT que integre embeddings de intervalos temporales.Analizar el impacto de esta modificación en métricas de ranking (Recall@K, NDCG@K) frente al modelo original.

Datasets

- **Diginetica:** Dataset de **e-commerce real**
  - Contiene **sesiones anónimas de usuarios**
  - Cada sesión es una secuencia de clics sobre productos
  - Múltiples **atributos por ítem** (categoría, marca, tipo, etc.)
  - Es el **dataset original del paper**, utilizado para:
  - Reproducir todos los experimentos de referencia
  - Validar que los resultados reportados son **reproducibles**

- **MovieLens 100K:** Dataset de **ratings de películas**
  - 100.000 evaluaciones de usuarios
  - Convertido a formato de **sesiones temporales**
  - Atributos utilizados:
    - Género
    - Año de estreno
    - Categoría cinematográfica
  - No es un dataset transaccional natural

- **Amazon Video Games:** Dataset de **Amazon de videojuegos**
  - Interacciones de usuarios con productos de videojuegos
  - Atributos utilizados:
    - Categoría
    - Marca
    - Plataforma
    - Precio
  - Dataset **diferente al dominio original del paper**

Metodología

Para abordar los desafíos de reproducibilidad y generalización, diseñamos un flujo de trabajo en tres etapas:

1. Adaptación del Entorno y Replicación (Benchmark)

Migración de Plataforma: Se migró el código base original de un entorno Linux/Bash a un entorno Windows/PowerShell, resolviendo conflictos de compilación en librerías críticas (PyTorch Geometric) y herramientas de minería de grafos (Parsemis/Java).

Validación: Se replicó el experimento original sobre el dataset Diginetica, manteniendo los hiperparámetros del paper para establecer una línea base confiable.

2. Curación de Datos para Generalización

Para evaluar la robustez del modelo en nuevos dominios (MovieLens 100K y Amazon Video Games), implementamos un pre-procesamiento riguroso. Aplicamos un **3-Core Filtering** recursivo para mitigar el problema de *sparsity* (escasez de datos, garantizando un mínimo de 3 interacciones por usuario e ítem para permitir el aprendizaje secuencial. Sustituimos el corte por fecha fija (inviable en datasets dispersos) presente en el código original de FAPAT por una división basada en percentiles temporales, asegurando consistencia en la evaluación.

3. Diseño de FAPAT Time-Aware (V2)

Extendemos la arquitectura original incorporando la variable temporal explícita:

Ingeniería de Características: Calculamos el lapso de tiempo entre interacciones y lo discretizamos en 128 intervalos (buckets) utilizando una escala logarítmica para capturar tanto la urgencia inmediata como la recurrencia a largo plazo.

Fusión Latente: Introducimos una matriz de embeddings temporales aprendibles ($\boldsymbol{E_{time}}$) que se inyecta directamente en la representación del ítem:

$$h_{final} = E_{item} + E_{pos} + \boldsymbol{E_{time}}$$

Esto permitiría que el mecanismo de Self-Attention pondere la relevancia de los ítems basándose no solo en su posición secuencial, sino en su contexto temporal real.

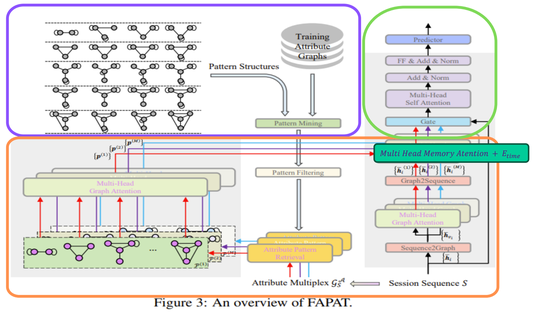

Figure 3: An overview of FAPAT.

Resultados

Replicabilidad

Model	diginetica					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	31.57*	17.40*	13.08*	43.19*	20.33*	13.88*
GRU4Rec	36.77*	20.71*	15.80*	49.68*	23.97*	16.70*
NARM	35.98*	20.18*	15.36*	48.89*	23.44*	16.26*
STAMP	33.59*	18.89*	14.41*	45.87*	22.00*	15.26*
CSRM	33.97*	19.43*	14.98*	45.83*	22.42*	15.80*
S3-Rec‡	33.48*	18.58*	14.04*	45.97*	21.74*	14.90*
M2TRec‡	29.67*	16.30*	12.23*	41.23*	19.22*	13.02*
SR-GNN	35.21*	19.68*	14.94*	47.99*	22.90*	15.82*
GC-SAN	35.25*	19.72*	14.97*	47.87*	22.90*	15.85*
S2-DHCN	30.76*	17.04*	12.86*	42.39*	19.98*	13.66*
GCE-GNN	36.32*	20.77*	16.02*	48.67*	23.89*	16.87*
LESSR	33.68*	18.71*	14.14*	46.23*	21.88*	15.01*
MSGIFSR	34.74*	19.43*	14.76*	46.23*	21.88*	15.01*
FAPAT‡	**37.42**	**21.31**	**16.39**	**50.41**	**24.59**	**17.29**
Improv.	*3.03%*	*2.60%*	*2.31%*	*1.46%*	*2.59%*	*2.49%*

Cuadro 1: Rendimiento para la predicción del siguiente elemento para dataset Diginetica. La diferencia de los resultados obtenidos con los del paper se indican entre paréntesis. Los mejores y segundos mejores resultados se resaltan en negrita y subrayados, respectivamente. Los métodos que utilizan atributos se marcan con ‡, y * indica un valor $p < 0,0001$ en t-test

Model	Hit@10	NDCG@10	MRR@10	Hit@20	NDCG@20	MRR@20
FPMC	26.32* (-5.25)	14.32* (-3.08)	10.67* (-2.41)	36.54* (-6.65)	16.90* (-3.43)	11.37* (-2.51)
GRU4Rec	35.95* (-0.82)	20.26* (-0.45)	15.47* (-0.33)	48.76* (-0.92)	23.49* (-0.48)	16.36* (-0.34)
NARM	34.62* (-1.36)	19.30* (-0.88)	14.63* (-0.73)	47.65* (-1.24)	22.59* (-0.85)	15.53* (-0.73)
STAMP	33.03* (-0.56)	18.64* (-0.25)	14.25* (-0.16)	45.22* (-0.65)	21.72* (-0.28)	15.10* (-0.16)
CSRM	33.62* (-0.35)	18.85* (-0.58)	14.35* (-0.63)	45.82* (-0.01)	21.93* (-0.49)	15.19* (-0.61)
S3-Rec‡	30.89* (-2.59)	17.12* (-1.46)	12.93* (-1.11)	43.13* (-2.84)	20.21* (-1.53)	13.78* (-1.12)
M2TRec‡	28.78* (-0.89)	15.59* (-0.71)	11.58* (-0.65)	40.48* (-0.75)	18.54* (-0.68)	12.39* (-0.63)
SR-GNN	34.16* (-1.05)	18.81* (-0.87)	14.13* (-0.81)	46.78* (-1.21)	22.00* (-0.90)	15.00* (-0.82)
GC-SAN	34.06* (-1.19)	19.00* (-0.72)	14.41* (-0.56)	46.61* (-1.26)	22.16* (-0.74)	15.27* (-0.58)
S2-DHCN	32.94* (+2.18)	18.21* (+1.17)	13.72* (+0.86)	44.84* (+2.45)	21.21* (+1.23)	14.54* (+0.88)
GCE-GNN	35.88* (-0.44)	20.58* (-0.19)	15.90* (-0.12)	48.18* (-0.49)	23.69* (-0.20)	16.75* (-0.12)
LESSR	34.44* (+0.76)	18.96* (+0.25)	14.24* (+0.10)	47.40* (+1.17)	22.23* (+0.35)	15.14* (+0.13)
MSGIFSR	34.26* (-0.48)	19.06* (-0.37)	14.43* (-0.33)	47.10* (+0.87)	22.30* (+0.42)	15.31* (+0.30)
FAPAT	**36.09*** (-1.33)	**20.77*** (-0.54)	**16.09*** (-0.30)	48.17* (-2.24)	**23.82*** (-0.77)	**16.93*** (-0.36)
FAPAT_v2	35.92*	20.42*	15.68*	**48.77***	23.66*	16.57*

Cuadro 2: Rendimiento para la predicción del siguiente elemento para dataset Diginetica, tras la replicación del paper. La diferencia de los resultados obtenidos con los del paper se indican entre paréntesis. Los mejores y segundos mejores resultados se resaltan en negrita y subrayados, respectivamente. Los métodos que utilizan atributos se marcan con ‡, y * indica un valor $p < 0,0001$ en t-test

Reproducibilidad

Model	Hit@10	NDCG@10	MRR@10	Hit@20	NDCG@20	MRR@20
FPMC	11.62*	5.65*	3.87*	19.54*	7.65*	4.42*
GRU4Rec	**14.73***	**7.01***	4.69*	24.61*	9.49*	5.36*
NARM	13.98*	7.01*	**4.91***	**24.69***	**9.70***	**5.64***
STAMP	10.00*	4.80*	3.23*	17.59*	6.71*	3.75*
CSRM	14.44*	6.98*	4.76*	22.82*	9.08*	5.33*
S3-Rec‡	9.59*	4.54*	3.04*	16.47*	6.26*	3.50*
M2TRec‡	8.67*	4.21*	2.88*	14.65*	5.71*	3.29*
SR-GNN	12.90*	6.21*	4.21*	21.24*	8.30*	4.78*
GC-SAN	13.28*	6.22*	4.12*	22.12*	8.43*	4.70*
S2-DHCN	8.67*	3.75*	2.31*	16.35*	5.68*	2.83*
GCE-GNN	13.24*	5.75*	3.53*	23.44*	8.31*	4.23*
LESSR	12.24*	5.97*	4.08*	20.50*	8.03*	4.63*
MSGIFSR	12.28*	5.98*	4.11*	21.54*	8.30*	4.74*
FAPAT	8.76*	3.88*	2.43*	17.84*	6.15*	3.04*
FAPAT_v2	8.63*	3.78*	2.34*	18.30*	6.22*	3.01*

Cuadro 3: Rendimiento para la predicción del siguiente elemento para dataset de Amazon de la categoría Digital Music. Los mejores y segundos mejores resultados se resaltan en negrita y subrayados, respectivamente. Los métodos que utilizan atributos se marcan con ‡, y * indica un valor $p < 0,0001$ en t-test

Model	Hit@10	NDCG@10	MRR@10	Hit@20	NDCG@20	MRR@20
FPMC	13.88*	9.39*	8.01*	17.21*	10.23*	8.24*
GRU4Rec	17.88*	12.72*	11.12*	21.67*	13.67*	11.38*
NARM	16.65*	11.24*	9.58*	20.21*	12.14*	9.83*
STAMP	15.79*	10.98*	9.49*	18.82*	11.75*	9.70*
CSRM	18.82*	13.02*	11.22*	22.66*	13.98*	11.48*
S3-Rec‡	17.29*	11.99*	10.34*	20.83*	12.88*	10.58*
M2TRec‡	14.50*	9.58*	8.05*	17.98*	10.45*	8.29*
SR-GNN	16.77*	11.51*	9.89*	20.34*	12.41*	10.13*
GC-SAN	17.35*	12.21*	10.62*	21.02*	13.13*	10.87*
S2-DHCN	12.09*	8.70*	7.65*	14.61*	9.33*	7.82*
GCE-GNN	**21.18***	**15.36***	**13.55***	**25.13***	**16.35***	**13.82***
LESSR	18.08*	12.60*	10.89*	21.84*	13.55*	11.15*
MSGIFSR	19.91*	14.13*	12.34*	23.43*	15.01*	12.58*
FAPAT	20.01*	14.81*	13.20*	23.94*	15.80*	13.47*
FAPAT_v2	20.29*	14.93*	13.28*	24.14*	15.90*	13.54*

Cuadro 4: Rendimiento para la predicción del siguiente elemento para dataset de Amazon de la categoría Video Games. Los mejores y segundos mejores resultados se resaltan en negrita y subrayados, respectivamente. Los métodos que utilizan atributos se marcan con ‡, y * indica un valor $p < 0,0001$ en t-test

Complicaciones de Desarrollo

Desafíos de Infraestructura y Entorno: El despliegue del entorno experimental presentó significativos retos de compatibilidad, dado que el código base fue diseñado nativamente para Linux. Esto requirió una adaptación integral de los scripts a Windows (PowerShell) y la resolución de múltiples conflictos de dependencias.

Entre los obstáculos más críticos destacaron la instalación de faiss-gpu (que requirió el uso de conda-forge en lugar de pip), la compilación específica de torch-geometric mediante Visual Studio Build Tools y la gestión de incompatibilidades de versión entre numpy y faiss. Adicionalmente, la herramienta externa de minería gSpan demandó una configuración manual de rutas y asignación de memoria en Python para ejecutarse correctamente en un entorno local.

Desafíos de Datos y Curación: Durante la fase experimental, enfrentamos un problema crítico de dispersión de datos (sparsity) con el dataset "Digital Music", lo que resultó en métricas de rendimiento nulas. La extrema escasez de interacciones por usuario provocó que los filtros de limpieza estándar eliminaran el 90% de la información, mientras que la estrategia original de división temporal por fecha fija dejó vacíos los conjuntos de validación y prueba.

Para solucionar esto, se migró al dataset "Amazon Video Games", caracterizado por una mayor densidad, y se implementó un filtrado recursivo 3-Core, garantizando así historiales suficientes para el aprendizaje secuencial efectivo.

Análisis y Discusión

- **Validación de Replicabilidad**: Se confirmó que independientemente de la robustez de FAPAT en el benchmark Diginetica, validando las métricas reportadas en el estado del arte y demostrando la estabilidad de su arquitectura basada en patrones de atributos.

- **Sensibilidad al Dominio (Generalización)**: Se observó que la capacidad de generalización del modelo no es universal, sino que depende de la densidad del dataset (Sparsity Sensitivity). FAPAT brilla en entornos con atributos ricos, pero requiere pre-procesamiento estricto (K-Core) en dominios altamente dispersos como Amazon Video Games.

- **Impacto de la Variante Time-Aware**: La propuesta FAPAT V2 demuestra ser competitiva frente a las líneas base, confirmando nuestra hipótesis de que la inyección explícita de intervalos temporales (Time Buckets) en el espacio latente enriquece la representación de la intención del usuario sin sacrificar eficiencia.

Referencias Bibliográficas

[1] Liu, X., Li, Z., Gao, Y., Yang, J., Cao, T., Wang, Z., Yin, B., & Song, Y. (2023). Enhancing user intent capture in session-based recommendation with attribute patterns. In *Proceedings of the 37th Conference on Neural Information Processing Systems (NeurIPS 2023)*.

[2] Li, J., et al. (2020). Time Interval Aware Self-Attention for Sequential Recommendation. WSDM.