Calidad vs CO_2 en sistemas recomendadores: un análisis de eficiencia climática.

Cristóbal Saravia y Felipe Tachack

Departamento ciencias de la computación, Universidad Pontificia Católica, Avenida Vicuña Mackenna 4860, Macul, Santiago.

csaravia@uc.cl, jtachacks@estudiante.uc.cl

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

1. Introducción

Los sistemas recomendadores suelen optimizar únicamente la calidad de ranking, ignorando el costo ambiental del entrenamiento. En este trabajo estudiamos el compromiso **calidad–carbono** en algoritmos de recomendación mediante métricas de eficiencia para los valores de **nDCG@10** y **MAP@10** basadas en la métrica **ApC** del paper de Qijiong Liu, et al. Nuestro objetivo es **identificar configuraciones en la frontera calidad–CO_2e** y analizar el comportamiento de las métricas de eficiencia.

2. Problema

Planteamos la evaluación como un **problema multiobjetivo**: maximizar calidad de ranking y minimizar CO_2e. Buscamos las **configuraciones no dominadas** en el plano {calidad, CO_2e}, y analizar las métricas de eficiencia de carbono.

3. Motivación

El entrenamiento a escala —rejillas extensas de hiperparámetros y arquitecturas profundas— pueden **incrementar sustancialmente las emisiones de CO_2**, y a menudo con **retornos decrecientes** en calidad. Contar con **métricas de eficiencia climática** permite tomar decisiones informadas: fijar límites de complejidad y elegir **configuraciones livianas** que ya resuelven bien.

4. Metodología

Datos. MovieLens-1M [1](6,040 usuarios, 3,883 ítems, 1M interacciones). Matriz usuario–ítem (CSR). Split 60/20/20 (train/val/test).
Book-Crossing [2] (complementario): (278,859 usuarios, 271,379 ítems, $\approx$ 1M interacciones). Misma matriz y splits.

Modelos. Baselines (Popular, Random); colaborativos implícitos **ALS** (*implicit*); neuronal **DeepFM**, **MultiVAE** (TFRS). Rejillas acotadas de hiperparámetros por familia.

Evaluación Top-N. Para cada usuario: listas Top-10 y métricas: MAP@10, nDCG@10.
CO_2e. Entrenamientos medidos con la librería **CodeCarbon** [3]. Misma máquina/entorno por familia (Google Colab GPU T4).
Eficiencia calidad–carbono. Definimos eficiencias como ganancia sobre *Random* por gramo de CO_2e:

$$\text{MAP-C} = \frac{\text{MAP} - \text{MAP}_{\text{rand}}}{\text{CO2e}}, \qquad \text{nDCG-C} = \frac{\text{nDCG} - \text{nDCG}_{\text{rand}}}{\text{CO2e}}. \tag{1}$$

Selección. *Fronteras de Pareto* en {calidad, CO_2e}; ajuste lineal sobre la frontera para estimar *ganancia marginal* y detectar retornos decrecientes. Reporte por: (i) mejor eficiencia (–C), (ii) configuraciones no dominadas y (iii) correlaciones entre métricas de calidad y eficiencia.

5. Resultados

En MovieLens-1M, **ALS con pocos factores** se posiciona de forma consistente con los mejores resultados para las métricas de calidad. Sin embargo, la frontera de Pareto solo contiene un punto. Con Book-Crossing se obtienen fronteras más adecuadas para comparación, y se observa que el punto más bajo de la frontera tiene la mayor eficiencia de carbono para las métricas (NDCG-C $\approx$ 1162%, MAP-C $\approx$ 839%). Al aumentar los factores, las métricas de calidad aumentan pero disminuye la eficiencia, ya que aumentan las emisiones de CO_2. Se observa una correlación muy negativa entre las eficiencias y las métricas (≈ -0.97).
Para **MultiVAE**, las configuraciones con mejor calidad de recomendación tienden a tener menores emisiones de carbono, específicamente aquellas con dimensión latente más pequeña. Sin embargo, se observa que la configuración con peor eficiencia NDCG-C es también la de mejor eficiencia MAP-C ($\approx -1400\%$ y $\approx$ 1600%, respectivamente). Esto se debe a que el valor es un poco mejor que el baseline en MAP y un poco peor en NDCG, pero con emisiones de CO_2 ínfimas, lo cual muestra la volatilidad de estas métricas en este rango. Al eliminar este outlier se obtiene una correlación positiva entre las métricas de calidad y de eficiencia (≈ 0.90).
Para **DeepFM**, en cambio, se observa una correlación negativa moderada entre las métricas de calidad y de eficiencia sin la existencia de este tipo de outliers (≈ -0.44), donde los modelos con mayor embedding size (64) tienen mayor eficiencia pero peor calidad (NDCG-C $\approx$ 202%, MAP-C $\approx$ 139%). Esto es similar al caso con ALS, donde mejorar la calidad implica aumentar las emisiones de CO_2.
Con esto, determinamos que estas métricas de eficiencia se comportan de manera distinta para distintos modelos, lo cual nos deja ver que la relación calidad-CO_2 es muy compleja para ser representada por solo una de estas mediciones (métrica o emisiones).

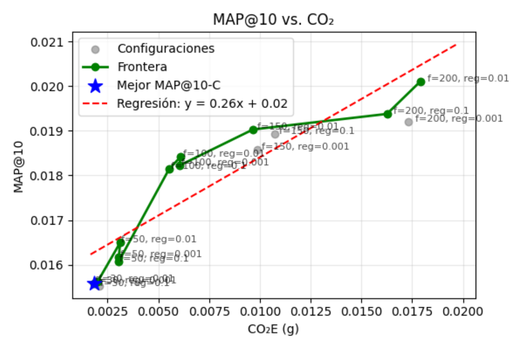

ALS: MAP@10 vs CO_2e (Book-Crossing).

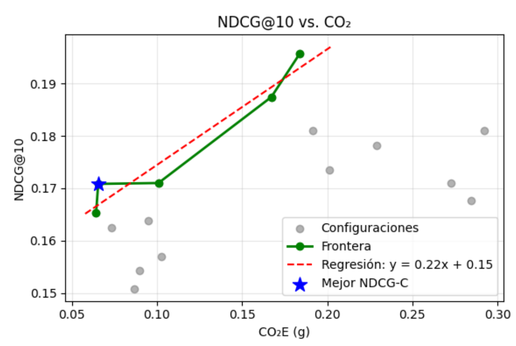

DeepFM: nDCG@10 vs CO_2e (ML-1M).

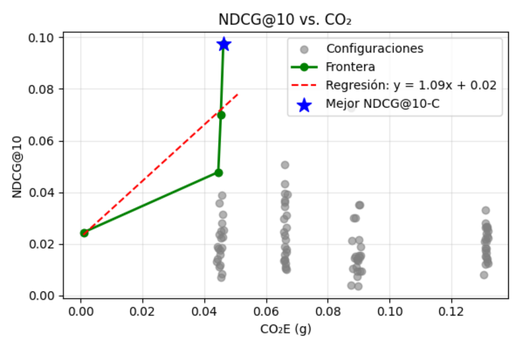

MultiVAE: nDCG@10 vs CO_2e (ML-1M).

6. Discusión de resultados

El análisis de resultados muestra que la relación entre calidad y CO_2 es altamente dependiente del modelo evaluado (ALS, MultiVAE, DeepFM), haciendo que el patrón del trade-off sea impredecible a priori. Esta dependencia justifica la necesidad de métricas de eficiencia como NDCG-C y MAP-C, que funcionan como la herramienta objetiva para identificar y resolver el trade-off específico de cada arquitectura.
En ALS se observa el caso de conflicto más marcado: la eficiencia disminuye considerablemente al aumentar la calidad, situando a las configuraciones con mejor calidad y mejor eficiencia en extremos opuestos de la Frontera de Pareto. Esto obliga a evaluar explícitamente el compromiso entre rendimiento y costo ambiental, posiblemente adoptando un punto intermedio según las necesidades del sistema.
DeepFM presenta un trade-off similar, aunque de forma más moderada. La mejor eficiencia no coincide con la configuración de peor calidad y la correlación negativa entre métricas y eficiencias es menos pronunciada que en ALS, lo que sugiere que el conflicto entre ambas dimensiones es menos extremo.
Por otro lado, MultiVAE revela una limitación importante para estas métricas en rangos donde las emisiones son cercanas a cero: se observa una fuerte volatilidad que vuelve a las métricas de eficiencia poco útiles. El caso identificado en los experimentos —donde una misma configuración obtiene simultáneamente la mejor MAP-C y la peor NDCG-C al presentar valores cercanos al baseline con emisiones casi inexistentes— muestra que es fundamental considerar la magnitud absoluta de CO_2 para evaluar cuán informativa es la métrica. Sin este outlier, MultiVAE demuestra que basta con encontrar la mejor calidad para obtener la mejor eficiencia, evidenciando que el trade-off observado en ALS y DeepFM no es universal.

7. Referencias

[1] F Maxwell Harper and Joseph A Konstan. The movielens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems (TiiS)*, 5(4):19:1–19:19, 2015.

[2] Cai-Nicolas Ziegler, Sean M McNee, Joseph A Konstan, and Georg Lausen. Improving recommendation lists through topic diversification. In *Proceedings of the 14th International World Wide Web Conference (WWW '05)*, pages 22–32, Chiba, Japan, 2005. ACM.

[3] Benoit Courty, Victor Schmidt, Sasha Luccioni, Goyal-Kamal, MarionCoutarel, Boris Feld, Jérémy Lecourt, LiamConnell, Amine Saboni, Inimaz, supatomic, Mathilde Léval, Luis Blanche, Alexis Cruveiller, ouminasara, Franklin Zhao, Aditya Joshi, Alexis Bogroff, Hugues de Lavoreille, Niko Laskaris, Edoardo Abati, Douglas Blank, Ziyao Wang, Armin Catovic, Marc Alencon, Michał Stęchły, Christian Bauer, Lucas Otávio N. de Araújo, JPW, and MinervaBooks. mlco2/codecarbon: v2.4.1, May 2024.

[4] Qijiong Liu, Jieming Zhu, Quanyu Dai, and Xiao-Ming Wu. Benchmarking news recommendation in the era of green ai, 2024.