Recomendación de Libros con Embeddings Textuales y Modelo Híbrido

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

Cristóbal Tolorza Bastián Guacucano Diego Valenzuela

Motivación

El catálogo de libros en plataformas como Goodreads crece de forma explosiva, generando sobrecarga de información y dificultando que los lectores descubran títulos relevantes. Los sistemas de recomendación pueden aliviar este problema, especialmente si aprovechan el contenido textual de los libros. En este proyecto exploramos modelos de lenguaje profundo aplicados a los títulos para mejorar la personalización incluso cuando hay pocas interacciones.

Problema

En catálogos grandes y dispersos aparecen fuertes problemas de *data sparsity* y *cold start*: muchos libros tienen pocas evaluaciones y usuarios nuevos casi no tienen historial. Aunque los títulos contienen información semántica rica, no está claro qué encoder textual la captura mejor ni cuánto aporta al combinarse con filtrado colaborativo. El problema central es elegir y evaluar encoders de lenguaje para títulos y medir si un enfoque híbrido texto + SVD supera a modelos tradicionales.

Propuesta

Estudiamos un recomendador de libros basado sólo en títulos usando el dataset Goodreads. Comparamos tres encoders de *Sentence-Transformers* para generar embeddings y construir un modelo *content-based* por similitud de coseno. Sobre esta base entrenamos un SVD colaborativo y un modelo híbrido que combina ambas puntuaciones mediante un parámetro de fusión α, evaluando distintas configuraciones (CB, SVD e híbrido) para identificar la combinación encoder + estrategia que optimiza precisión, diversidad y cobertura de catálogo.

Metodología

Representación textual

Para convertir los títulos en vectores numéricos (embeddings) se emplearon modelos de la familia Sentence-Transformers:

- **all-distilroberta-v1**(ligero)
- **all-mpnet-base-v2**(generalista para similitud semántica)
- **multi-qa-mpnet-base-dot-v1**(optimizado para recuperación tipo QA)

Cada título se codificó en un embedding denso de dimensión fija. Los embeddings se normalizaron (norma L2) para que el producto punto coincida con la similitud coseno.

Modelos

- Colaborativo con **SVD**: factorización de la matriz usuario–libro para estimar ratings latentes.
- Basado en contenido: perfil de usuario como media ponderada de embeddings de libros leídos y ranking por similitud coseno sobre libros no vistos.
- Híbrido lineal: combinación de ambos scores con un parámetro de fusión α

$$H(u,i) = \alpha \cdot SCF(u,i) + (1-\alpha) \cdot SCB(u,i)$$

Se evaluaron distintos valores de α para estudiar el compromiso precisión/diversidad.

Evaluación

Los modelos se evaluaron en un esquema offline con partición entrenamiento/prueba estratificada por usuario. Se utilizaron métricas de ranking a nivel de Top-K, tales como:

- MAP@K (Mean Average Precision)
- NDCG@K (Normalized Discounted Cumulative Gain)
- Recall@K
- MRR@K (Mean Reciprocal Rank)
- Diversidad intra-lista y cobertura de catálogo

Resultados

Table 1: Resultados detallados ($K = 10$).

Modelo	MAP	NDCG	Rec.	MRR	Div.
— *Baselines* —					
SVD (Colab.)	0.0187	0.0292	0.0058	0.0189	**0.8348**
CB-DistilRob	0.0063	0.0102	0.0019	0.0065	0.1650
CB-MultiQA	0.0094	0.0140	0.0025	0.0095	0.1580
CB-MPNet	0.0076	0.0122	0.0022	0.0078	0.1706
— *Híbridos* —					
Hyb-DistilRob	0.0482	0.0759	0.0170	0.0498	0.5857
Hyb-MultiQA	**0.0607**	0.0887	**0.0244**	**0.0629**	0.4495
Hyb-MPNet	0.0585	**0.0890**	0.0243	0.0602	0.5230

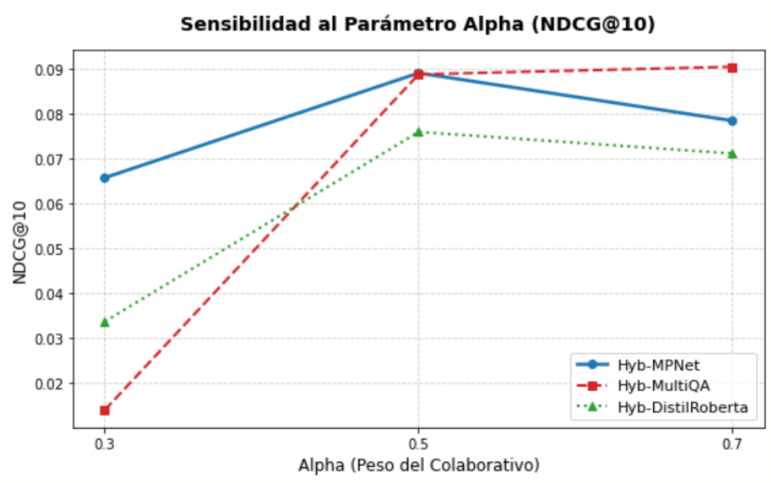

Figure 1: Sensibilidad del rendimiento (NDCG@10) ante el parámetro de fusión α.

Discusión

Comparación de Modelos

A partir de los resultados presentados en la Tabla 1, podemos destacar tres hallazgos principales:

1. Superioridad del Enfoque Híbrido: Los modelos baseline por sí solos mostraron un rendimiento insuficiente. Sin embargo, al unirlos en un modelo híbrido, los resultados mejoraron drásticamente, confirmando que ambos enfoques se complementan de buena manera. La semántica de los títulos cubre los vacíos de información (sparsity) que el SVD no puede resolver por sí solo, validando que ambas fuentes de información funcionan mejor integradas que por separado.

2. Equilibrio entre Precisión y Diversidad: Si bien Hyb-MultiQA logró la mayor precisión puntual (ganando en MAP, Recall y MRR), Hyb-MPNet obtuvo el mejor ranking global (NDCG) y lo superó notablemente en diversidad (0.523 vs 0.4495). Es por esto que, MultiQA resulta ideal para búsquedas específicas, mientras que MPNet ofrece el mejor balance para un recomendador real, evitando la repetición y favoreciendo el descubrimiento de nuevos libros que pueden ser del gusto del usuario.

3. Impacto de la Profundidad del Modelo: El modelo Hyb-DistilRob tuvo un desempeño inferior a los demás. Aunque es más rápido y ligero, su "superficialidad" le juega en contra: al trabajar con títulos cortos, se requiere una mayor profundidad (capacidad del modelo) para captar bien la semántica. Su ventaja en velocidad no logra compensar la pérdida de calidad en las recomendaciones.

Sensibilidad de Parámetros

El parámetro utilizado es alpha, que indica el peso del modelo base SVD dentro del modelo híbrido generado. La gráfica de la Figura 1 nos indica la sensibilidad de la métrica de recomendación NDCG@10 con respecto a este parámetro para los tres modelos híbridos evaluados.

Observando la gráfica, podemos notar claramente que el modelo Hyb-MPNet es el más estable frente a la variación del valor de alpha, manteniendo un rendimiento alto para los tres valores evaluados. Por otro lado, vemos que el modelo Hyb-MultiQA presenta una mayor inestabilidad, mostrando una gran variación de NDCG entre valores de alpha menores a 0.5 y aquellos mayores o iguales a 0.5. En concreto, presenta un bajo rendimiento para valores menores a 0.5, lo que indica que el buen desempeño del modelo híbrido Hyb-MultiQA depende en gran medida del modelo base SVD.

Conclusiones

Se demostró que la integración de Deep Learning textual (SentenceTransformers) con la factorización matricial (SVD) es una estrategia efectiva para mitigar el problema de sparsity en dominios de libros. El modelo híbrido logró triplicar el rendimiento del mejor baseline evaluado, validando que la semántica de los títulos aporta información crítica cuando las interacciones de los usuarios son escasas.

Si bien el modelo Hyb-Multi-QA es muy exacto para búsquedas específicas, concluimos que Hyb-MPNet-Base es la mejor opción para recomendar libros. Debido a que logra el equilibrio perfecto entre acertar con sugerencias relevantes y ofrecer variedad al usuario. Además, demostró ser mucho más robusto y estable, manteniendo un buen funcionamiento sin importar cómo ajustemos el peso de cada modelo base (alpha), a diferencia de los otros modelos que resultaron ser más inestables.

Referencias

[1] K. Sarode and S. R. Javaji.
Multi-BERT for embeddings for recommendation system.
arXiv preprint arXiv:2308.13050, 2023.

[2] D. Suhartono and A. Subalie.
Book Recommendation Using Double-Stack BERT: Utilizing BERT to Extract Sentence Relation Features for a Content-Based Filtering System.
In *Multi-disciplinary Trends in Artificial Intelligence*, Lecture Notes in Artificial Intelligence (LNAI 14078), Springer, 2023.

[3] F. Paulin.
Book Recommendation Using NLP.
RAJAR (Recent Advances in Journal of Applied Research), 11(10), 2025.