Recomendación grupal de juegos de mesa

Vicente Correa[1], Alberto Maturana[1] y Mariela Zambrano[1]
[1] Pontificia Universidad Católica de Chile, Santiago de Chile, Chile
vicente.correa@uc.cl, alberto.maturana@uc.cl, mariela.zambrano@uc.cl

INTRODUCCIÓN

Los sistemas recomendadores suelen enfocarse en preferencias individuales, mientras que muchas decisiones a las que nos enfrentamos, pueden ser colectivas. Este trabajo aborda la recomendación grupal en el contexto de la selección de juegos de mesa, balanceando los gustos individuales de los integrantes del grupo para maximizar la satisfacción de todos. Se debe considerar que la elección de los juegos de mesa puede ser dada por diferentes factores, es por eso que a continuación, se mostrarán los resultados de modelos que combinan filtrado colaborativo y características del contenido del juego.

Este trabajo responde a la pregunta:
¿Cómo recomendar un juego de mesa que satisfaga a todos los miembros de un grupo, considerando gustos individuales y evitando decisiones dominadas por un único usuario?

DATASET

El dataset utilizado fue Board Games Database de BoardGameGeek, disponible en Kaggle.

Cuenta con información básica de 22 mil juegos de mesa, con un rating de 0 a 10 en intervalos de 0.1 puntos. Además contiene todos los ratings hechos por los más de 411 mil usuarios de los distintos juegos de mesa. Así, se tiene un total de 19 millones de reseñas.

El 60% de los datos fue destinado al set de entrenamiento, y el 40% restante se dividió en dos, para validación y testing.
También se binarizaron las interacciones considerando relevante un rating r >= 7. Esto se alinea con la media global del dataset (=7.1) y el estándar de la comunidad BGG donde 7 es un juego 'Bueno', filtrando ruido de ítems mediocres.

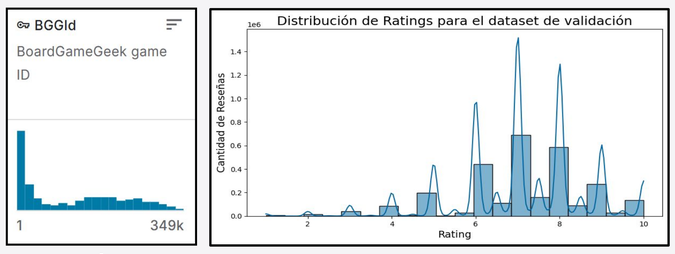

A B

Figura 1. Distribución Ids de juegos de mesa (imagen A). Gráfico de cantidad de reseñas vs rating (imagen B).

ESTADO DEL ARTE

En recomendación grupal existen dos enfoques principales:

1. Agregación de predicciones individuales, donde cada usuario obtiene una recomendación propia y luego se combinan mediante estrategias como Average, Least Misery o Most Pleasure.
2. Perfiles grupales, donde las preferencias del grupo se integran en un usuario virtual antes de aplicar el modelo.

Dentro de estas técnicas, Matrix Factorization (MF) destaca por capturar patrones latentes entre usuarios e ítems, permitiendo generar recomendaciones que buscan maximizar la satisfacción colectiva a partir de gustos individuales.

METODOLOGÍA

La experimentación realizada comenzó evaluando los modelos (DeepFM, SVD++, Most Popular, Random, MF y MF con SVD++) a nivel individual, que luego se extendió a grupos simulados. Para el caso del modelo individual se entrenó durante 10 épocas, para distinguir qué ítems eran de su gusto. Para evaluar el modelo se generó una lista de top 10 recomendaciones para cada usuario.
Por otro lado, para evaluar las recomendaciones grupales, se crearon 1000 grupos compuestos por 4 usuarios seleccionados aleatoriamente del conjunto de validación. Se aplicaron 3 estrategias de agregación:

- Average: calculando el rating promedio predicho por el modelo para todos los miembros del grupo.
- Least Misery: en donde la calificación del grupo para un ítem será la calificación mínima predicha entre todos los miembros, para evitar ítems que disgusten mucho a un integrante.
- Most Pleasure: en donde la calificación del grupo será la máxima predicha, buscando maximizar la satisfacción del miembro más fanático.

Para la evaluación se consideró un ítem como relevante para un grupo sólo si todos los miembros del grupo lo habían calificado positivamente. El desempeño de cada modelo se evaluará con las métricas: Precision, Recall, RMSE, MAE, nDCG, Novedad y Diversidad.

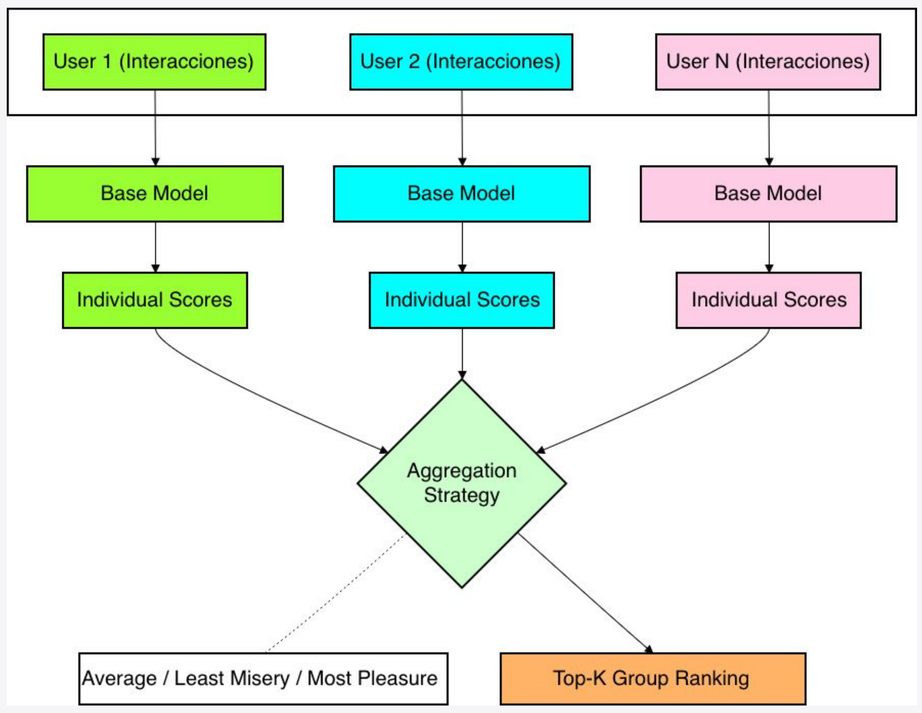

Figura 2. Arquitectura del Sistema de Recomendación Grupal.

RESULTADOS

Individual					
Modelo / Métrica	Precision@10	Recall@10	nDCG@10	Novedad	Diversidad
Random	0.0897	0.7461	0.1692	11.6093	0.1890
Most Popular	**0.4335**	0.8476	**0.7638**	10.9649	0.6756
Matrix Factorization	0.2034	**0.8681**	0.5163	11.3097	0.4869
DeepFM	0.4195	0.8370	0.7488	**18.8258**	0.4073
SVD++	0.4269	0.8431	0.7564	11.0452	**0.6777**

Grupales					
Average					
Modelo / Métrica	Precision@10	Recall@10	nDCG@10	Novedad	Diversidad
Random	0.4	0.1502	0.6832	14.5771	**0.9077**
Most Popular	**0.9017**	0.1439	0.9676	10.4756	0.8157
Matrix Factorization	0.8868	**0.2525**	**0.9677**	10.9126	0.8433
DeepFM	0.8448	0.1353	0.9471	**19.4430**	0.5926
SVD++	0.8936	0.1411	0.9629	10.7883	0.8435
Least Misery					
Modelo / Métrica	Precision@10	Recall@10	nDCG@10	Novedad	Diversidad
Random	0.4	0.1502	0.6832	14.5771	**0.9077**
Most Popular	**0.9017**	0.1439	0.9676	10.4756	0.8157
Matrix Factorization	0.8874	**0.2526**	**0.9678**	10.9232	0.8435
DeepFM	0.8458	0.1354	0.9475	**19.4402**	0.5938
SVD++	0.8916	0.1406	0.9626	10.8095	0.8445
Most Pleasure					
Modelo / Métrica	Precision@10	Recall@10	nDCG@10	Novedad	Diversidad
Random	0.4	0.1502	0.6832	14.5771	**0.9077**
Most Popular	**0.9017**	0.1439	**0.9676**	10.4756	0.8157
Matrix Factorization	0.8832	**0.2514**	0.9660	10.9015	0.8433
DeepFM	0.8420	0.1350	0.9453	**19.4462**	0.5973
SVD++	0.8991	0.1418	0.9648	10.7161	0.8435

ANÁLISIS

A partir de los resultados anteriores, podemos concluir lo siguiente de los modelos:

- Most Popular: si bien tiene una alta precisión, no hay novedad en sus recomendaciones y no logra identificar los ítems más relevantes.
- DeepFM: si bien la novedad es la más alta para en las tres estrategias, la precisión y recall es más bajo que MF, por lo que sacrifica la relevancia en sus recomendaciones.
- SVD++: las métricas de las recomendaciones son similares a las obtenidas por MF, pero es menos novedoso que este y el recall es más bajo ya que es más "conservador" en sus recomendaciones.
- Matrix Factorization: hay un balance entre la relevancia, el orden de sus recomendaciones y la novedad y diversidad de ellas. Esto hace que sea más "exploratorio" por lo que alcanza los ítems relevantes y por ende obtiene un mayor recall en cada una de las estrategias. Es decir, descubre más ítems relevantes para el grupo que los demás modelos.

Como podemos observar, las estrategias de agregación tienen métricas similares entre sí, por lo que si bien tiene un impacto, el impacto mayor se da por el modelo escogido.
Para un usuario real, un alto nivel de Recall (el caso de MF) implica que no sólo recomienda juegos populares, sino también títulos menos obvios pero relevantes para el grupo, lo que se alinea con la experiencia social de jugar.

CONCLUSIONES

La recomendación grupal es un desafío para los sistemas recomendadores. En este trabajo, en el contexto de elegir un juego para un grupo, se evaluó el desempeño de distintos modelos y estrategias de agregación. Los resultados muestran que el modelo tiene mayor impacto que la técnica de agregación.

Matrix Factorization destaca por capturar patrones latentes compartidos entre los integrantes, logrando un mejor ordenamiento de ítems relevantes y un desempeño superior en nDCG, además de un buen equilibrio entre relevancia, novedad y diversidad. En contraste, Most Popular obtiene alta precisión debido al sesgo del dataset hacia juegos ampliamente conocidos, pero con baja novedad y diversidad, mientras que DeepFM explora recomendaciones menos obvias a costa de una menor relevancia.

Estos hallazgos sugieren la necesidad de incorporar información contextual adicional y nuevas técnicas de agregación para mejorar la personalización en la recomendación grupal.

REFERENCIAS

[1] MatrixFactorization for Group https://ase.sai.tugraz.at/wp-content/uploads/sites/34/2014/01/group recommendersystemschapter2.pdf

[2] Honda, H., Kagawa, R., & Shirasuna, M. (2022). On the round number bias and wisdom of crowds in different response formats for numerical estimation. Scientific reports, 12(1), 8167. https://doi.org/10.1038/s41598-022-11900-7

[3]Hu, N., Zhang, J., & Pavlou, P. A. (2009). Overcoming the J-shaped distribution of product reviews. Communications of the ACM, 52(10), 144–147. https://doi.org/10.1145/1562764.1562800

[4] Wadkins, J. (2021). *Board Games Database from BoardGameGeek* [Dataset].Kaggle.https://www.kaggle.com/datasets/threnjen/board-games-database-from-boardgamegeek