

14

modelos evaluados  
2 triviales + 12 KG-aware

6

paradigmas KG-aware  
comparados de raíz

3

datasets  
ml-100k · ml-1m · lastfm-2k

~1.000×

ventaja en eficiencia  
de lo trivial (nDCG/gCO<sub>2</sub>)

×7-9

más CO<sub>2</sub> al escalar  
de 100k a 1M de interacc.

3 órdenes

de magnitud separan  
calidad y sostenibilidad

## 1 Problema y motivación

Los recomendadores basados en **grafos de conocimiento (KG)** logran alta calidad, pero su **huella de carbono** casi nunca se reporta.

**Pregunta:** ¿cuánto CO<sub>2</sub> cuesta cada punto de calidad y qué familias dan el mejor balance?

**Motivación.** La IA sostenible exige evaluar los modelos por su **eficiencia ambiental**, dimensión casi ausente en recomendación KG-aware.

## 2 Datos

Tres datasets públicos de distinta escala y densidad, con su grafo de conocimiento. Split 80/20 y semilla fija compartida.

| Dataset   | Usuarios | Ítems  | Interacc. |
|-----------|----------|--------|-----------|
| ML-100k   | 943      | 1.682  | 100.000   |
| ML-1M     | 6.040    | 3.706  | 1.000.209 |
| LastFM-2k | 1.892    | 17.632 | 92.834    |

Cada dataset se enriquece con un KG (géneros, directores, artistas); ml-100k aporta 2.893 triplas. ml-1m escala la interacción ~10×.

## 3 Metodología

**Modelos.** 2 triviales (Random, MostPopular) + 12 KG-aware en 6 paradigmas:

- **Embedding:** CKE · KTUP · CFKG
- **Propagación:** RippleNet
- **GNN:** KGCN · KGNNLS · KGIN
- **Multi-task:** MKR
- **Contrastivo / auto-superv.:** KGCL · KGRec
- **Difusión:** DiffKG

**Frameworks.** RecBole y SSLRec, mismo split y evaluación full-ranking sobre todo el catálogo. **Medición de CO<sub>2</sub>.** CodeCarbon (OfflineEmissionsTracker, GPU incluida) registra la energía CPU/GPU/RAM por corrida en Google Colab.

**Métricas @K=10.** Precision, Recall, nDCG, MAP, MRR, diversidad, cobertura y novedad, más la eficiencia ambiental **nDCG por gramo de CO<sub>2</sub>**.

## 4 Resultados — MovieLens-100k

13 de 14 modelos ejecutados (KGAT no ejecutó)

Trade-off calidad vs. huella de carbono (MovieLens-100k)





Fig. 1 — Trade-off calidad vs. CO<sub>2</sub>: solo contrastivos/difusión superan a MostPopular en calidad, a ~3 órdenes más de CO<sub>2</sub>.

| Modelo    | Familia    | nDCG  | Recall | CO <sub>2</sub> (m) | nD/g   |
|-----------|------------|-------|--------|---------------------|--------|
| KGCL      | Contrastiv | 0,391 | 0,215  | 654,4               | 0,60   |
| DiffKG    | Difusión   | 0,346 | 0,187  | 549,8               | 0,63   |
| KGRec     | Auto-      | 0,255 | 0,114  | 430,3               | 0,59   |
| MostPop   | Trivial    | 0,222 | 0,116  | 0,20                | 1,119, |
| KGIN      | GNN        | 0,213 | 0,091  | 214,9               | 0,99   |
| KGNNLS    | GNN        | 0,047 | 0,020  | 331,2               | 0,14   |
| KGCN      | GNN        | 0,047 | 0,020  | 324,1               | 0,14   |
| CKE       | Embeddin   | 0,044 | 0,019  | 328,2               | 0,14   |
| MKR       | Multi-task | 0,038 | 0,015  | 1.355,5             | 0,03   |
| CFKG      | Embeddin   | 0,031 | 0,013  | 160,1               | 0,19   |
| RippleNet | Propagaci  | 0,021 | 0,010  | 1.699,0             | 0,01   |
| KTUP      | Embeddin   | 0,020 | 0,008  | 393,7               | 0,05   |
| Random    | Trivial    | 0,014 | 0,006  | 0,56                | 25,33  |


## 5 Desglose de energía



En GPU se concentra la mayor parte del consumo de los modelos KG-aware; los triviales son prácticamente nulos.

## 6 Huella de carbono por modelo


Huella de carbono por modelo (MovieLens-100k)



RippleNet y MKR son los más costosos (1.699 y 1.355 mg); MostPopular y Random, casi nulos. **CFKG es el KG-aware más barato vía RecBole.**

## 7 Eficiencia ambiental

Eficiencia ambiental: lo trivial domina por 3 órdenes




Medida como **nDCG por gramo de CO<sub>2</sub>**, MostPopular supera a todo modelo KG-aware por ~3 órdenes: bajo restricción ambiental estricta, lo trivial es imbatible.

## 8 Otras métricas

**Diversidad y novedad.** Entre los KG-aware, **RippleNet** maximiza diversidad (0,43) y novedad (31,4)... pero al mayor costo de CO<sub>2</sub>. Calidad, diversidad y sostenibilidad rara vez coinciden en un mismo modelo.

## 9 Generalización entre datasets


Mejor calidad por dataset: trivial vs. KG-aware



La ventaja KG-aware se mantiene en los 3 datasets; en ml-1m (donde SSLRec no corrió) gana un modelo de embedding, CKE.

## 10 Fine-tuning

Fine-tuning: tamaño de embedding vs. CO<sub>2</sub> y calidad (ml-100k)



**Duplicar el embedding (64→128) sube el CO<sub>2</sub> ~89 % por solo +5 % de nDCG;** reducirlo (→32) recorta ~40 % de emisiones con mínima pérdida. Un learning rate muy bajo colapsa la calidad sin ahorrar energía.

## 11 Conclusiones

- **Trade-off real:** más calidad ⇒ ~3 órdenes más CO<sub>2</sub>.
- **Lo trivial gana en eficiencia** (~1.000× en nDCG/gCO<sub>2</sub>).
- **Solo SSLRec** (KGCL/DiffKG/KGRec) bate a MostPopular en calidad.
- **El costo escala** ×7-9 con el tamaño del dataset.
- **Ajuste = ahorro:** embeddings pequeños recortan CO<sub>2</sub> sin perder calidad.
- **Limitación:** KGAT no se ejecutó (brecha DGL/torchdata).