

Recomendación secuencial de productos en e-commerce con feedback implícito y modelos híbridos basados en categorías

Grupo 3: Paula Elicer, Ian Fuenzalida, Maximiliano Navia
IIC3633 Sistemas recomendadores – Profesor Denis Parra, Pontificia Universidad Católica de Chile



Introducción

En **e-commerce**, los usuarios suelen interactuar con productos mediante señales implícitas como vistas, agregados al carrito y compras, sin entregar ratings explícitos. Además, gran parte de los usuarios tiene historiales muy cortos, lo que dificulta la personalización. Este proyecto estudia recomendación secuencial de próximo ítem en **RetailRocket** y evalúa si la metadata de categorías puede complementar las señales temporales de interacción.

¿Puede la metadata de categorías mejorar la recomendación secuencial en usuarios con poco historial?

Dataset

Dataset	RetailRocket
Interacciones	2.76 M
Usuarios	1.41 M
Eventos	View, addtocart, transaction
Periodo	4.5 meses
Usuarios con 1 interacción	71.15%
Usuarios con ≤ 2 interacciones	85.79%
Eventos con categoría conocida	90.73%

Tabla 1: Dataset del modelo

El dataset **RetailRocket** contiene interacciones reales de usuarios en un e-commerce durante **4,5 meses**, registradas como view, addtocart y transaction. Al no existir ratings explícitos, las preferencias deben inferirse desde el comportamiento observado. Además, incluye metadata de productos y un árbol de categorías, lo que permite complementar la recomendación secuencial en un contexto de alta esparsidad y usuarios con poco historial.

Metodología

Se formuló el problema como una tarea de **next-item recommendation**, donde el objetivo es recomendar el próximo producto relevante para un usuario a partir de su historial temporal de interacciones. Como el dataset no contiene ratings explícitos, las señales de comportamiento fueron tratadas como feedback implícito y ponderadas según su intensidad: **view = 1, addtocart = 3 y transaction = 5**.


Para respetar la naturaleza secuencial del problema, se utilizó un **split temporal leave-one-out** por usuario: el último evento de cada usuario se reservó como test y todos los eventos anteriores fueron utilizados para entrenamiento. Para la selección de hiperparámetros del modelo propuesto se utilizó un conjunto de validación separado (50% de los usuarios evaluables), evitando así data leakage entre la etapa de tuning y el reporte de resultados finales. La evaluación se realizó con métricas top-K: **Recall@10, nDCG@10, Novelty@10, Category Diversity@10** y **Catalog Coverage@10**.

Modelo Propuesto

El **modelo final combina cuatro señales**: transiciones secuenciales, popularidad dentro de la última categoría del usuario, información jerárquica del árbol de categorías y popularidad global como respaldo. La contribución de cada señal se ajusta de forma adaptativa según la disponibilidad y confiabilidad del historial del usuario, lo que permite generar recomendaciones más robustas en escenarios con pocos eventos observados.

$$score(u, i) = w_{seq}S_{seq}(u, i) + w_{cat}S_{cat}(u, i) + w_{hier}S_{hier}(u, i) + w_{pop}S_{pop}(i)$$
$$(w_{seq}, w_{cat}, w_{hier}, w_{pop}) = f(c_{sep}(u), |H_u|)$$

El modelo combina señales secuenciales, categóricas, jerárquicas y de popularidad. Los pesos se adaptan según la confianza del último ítem y el historial disponible del usuario. C_{sep} mide qué tan confiable es recomendar a partir del último ítem visto por el usuario.



Modelos Base

- **Random**: recomienda ítems aleatorios observados en entrenamiento. Se utiliza como piso inferior de desempeño.
- **Most Popular**: recomienda los productos globalmente más populares, calculados a partir de la suma ponderada de interacciones implícitas. Sirve como baseline simple de popularidad.
- **Category Popularity**: recomienda productos populares dentro de la última categoría conocida del usuario. Este modelo permite evaluar si la metadata de categorías aporta señal predictiva por sí sola.
- **ItemKNN**: baseline colaborativo para feedback implícito que recomienda productos similares según patrones de co-interacción entre usuarios e ítems.
- **Sequential Transition**: modelo secuencial que aprende transiciones entre ítems consecutivos. Usa el último ítem observado por el usuario para recomendar productos que históricamente suelen aparecer después.
- **GRU4Rec**: modelo neuronal recurrente basado en GRU que aprende representaciones de sesiones de usuario. Entrenado con cross-entropy sobre secuencias de interacciones, con vocabulario de los 50.000 ítems más populares.

Modelos Híbridos

- **Fixed Hybrid Seq+Category**: combina un score secuencial con un score de categoría usando pesos fijos. Permite evaluar si integrar comportamiento reciente y metadata mejora frente a usar cada señal por separado.
- **Adaptive Hybrid**: ajusta dinámicamente el peso de cada componente según la confianza de la señal secuencial. Si el último ítem tiene transiciones confiables, se prioriza la secuencia; si la señal secuencial es débil, aumenta el peso de categoría y popularidad.
- **Adaptive Hierarchical Hybrid (tuned)**: modelo final propuesto.

Resultados

El modelo **Adaptive Hierarchical Hybrid (tuned)** obtuvo el mejor desempeño global con **Recall@10 = 0.1144 y nDCG@10 = 0.0686**, superando a todos los baselines evaluados. En usuarios con historial corto, alcanzó **Recall@10 = 0.1263 y nDCG@10 = 0.0763**.

El baseline neuronal **GRU4Rec**, pese a ser un modelo más complejo, obtuvo **Recall@10 = 0.0164**, por debajo de todos los métodos basados en popularidad y transiciones. Esto sugiere que en datasets de alta esparsidad, los modelos neuronales no tienen suficiente señal para aprender representaciones útiles, mientras que la señal categórica y jerárquica compensa efectivamente esa limitación.

El **Ablation Study** muestra que las señales categóricas por sí solas no superan al componente secuencial, pero sí aportan valor cuando se combinan con este. La mayor mejora aparece al incorporar la jerarquía de categorías y la adaptación de pesos, que permiten recuperar candidatos que el modelo secuencial puro no alcanza.

Además de las métricas agregadas, se realizó un **análisis cualitativo de casos específicos de usuarios con historial corto**. En estos casos, el modelo secuencial puede fallar cuando el último ítem tiene pocas transiciones confiables. El modelo Adaptive Hierarchical Hybrid (tuned) corrige parte de estos casos al aumentar el peso de las señales categóricas y jerárquicas, incorporando candidatos relevantes que no aparecen en el ranking secuencial puro.

Modelo	Recall@10	nDCG@10	Novelty@10	Cat.Div@10	Coverage@10
AHH (tuned)	0.1144	0.0686	13.60	0.507	0.230
Fixed Hybrid Seq+Cat	0.1096	0.0685	13.16	0.623	0.228
Sequential Transition	0.1025	0.0664	13.24	0.730	0.256
ItemKNN	0.0791	0.0443	15.42	0.741	0.371
Category Popularity	0.0750	0.0399	13.51	0.070	0.059
GRU4Rec	0.0164	0.0100	13.78	0.931	0.143
Most Popular	0.0022	0.0009	10.20	0.955	0.000
Random	0.0000	0.0000	18.78	0.995	0.810

Tabla 2: Resultados globales de los modelos

Modelo	Recall@10	nDCG@10	Novelty@10	Cat.Div@10
AHH (tuned)	0.1263	0.0763	13.53	0.503
Fixed Hybrid Seq+Cat	0.1209	0.0763	13.05	0.640
Sequential Transition	0.1120	0.0737	13.10	0.744
ItemKNN	0.0868	0.0498	15.08	0.755
Category Popularity	0.0832	0.0447	13.46	0.090
GRU4Rec	0.0173	0.0107	13.58	0.938
Most Popular	0.0025	0.0011	10.20	0.956
Random	0.0000	0.0000	18.79	0.995

Tabla 3: Resultados en usuarios con historial corto (≤2 interacciones)

Conclusiones


Los resultados muestran que la metadata de categorías aporta información complementaria al historial secuencial del usuario. El modelo híbrido adaptativo jerárquico mejora la recomendación combinando intención reciente, popularidad por categoría, relaciones jerárquicas y popularidad global.

La jerarquía de categorías no reemplaza a la señal secuencial, pero sí ayuda a refinarla. **GRU4Rec** confirma que en escenarios de alta esparsidad los modelos neuronales no superan a métodos híbridos más simples: la señal categórica y jerárquica es más informativa que la capacidad de representación del GRU cuando el historial es escaso.


En síntesis, **en escenarios de feedback implícito y usuarios con poco historial, combinar señales de comportamiento con metadata de productos permite generar recomendaciones más efectivas que los métodos neuronales o colaborativos tradicionales**.

Ejemplo usuario con historial corto:

Sequential Transition → miss
Category / Hierarchy → aporta candidatos relevantes
Adaptive Hierarchical Hybrid (tuned) → hit@10



Comparación Global de Desempeño



Referencias

- [1] Ricci, Francesco & Rokach, Lior & Shapira, Bracha. (2010). Recommender Systems Handbook. 10.1007/978-0-387-85820-3_1.
- [2] Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2015). Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939*.
- [3] Hu, Y., Koren, Y., & Volinsky, C. (2008, December). Collaborative filtering for implicit feedback datasets. In *2008 Eighth IEEE international conference on data mining* (pp. 263–272). Ieee.