

Recomendación Multimodal de Restaurantes con Datos de Yelp

Joaquín Burdiles Alonso Tamayo Marcelo Vargas

Pontificia Universidad Católica de Chile



Problema


Queremos recomendar restaurantes relevantes para cada usuario a partir de su historial de visitas y reseñas. El desafío es que la decisión de comer fuera mezcla preferencias personales, contexto local y señales poco estructuradas como texto e imágenes.

Usuarios Restaurantes Reviews Fotos

Pregunta del proyecto: ¿la información textual y visual aporta sobre el filtrado colaborativo puro en recomendación de restaurantes?

Motivación

- Las reseñas expresan preferencias semánticas: tipo de comida, servicio, precio, ambiente y ocasiones de consumo.
- Las fotos aportan evidencia visual sobre platos, decoración, presentación y estilo del local.
- El dominio es disperso: muchos usuarios interactúan con pocos restaurantes, por lo que las modalidades de contenido pueden mejorar la personalización y la cobertura.



Distribución de ratings y actividad temporal del subconjunto procesado.


Dataset procesado

Elemento	Cantidad	Uso
Usuarios 5-core	10.490	perfiles
Restaurantes 5-core	1.151	ranking
Reviews train	83.256	entrenamiento
Reviews test	17.191	evaluación
Restaurantes con fotos	3.824	señal CLIP

Split temporal 80/20 por usuario: las interacciones más recientes quedan para test, evitando evaluar con información futura.

Metodología

Se comparan baselines colaborativos, modelos con contenido y modelos de grafos multimodales bajo el mismo protocolo de evaluación Top-K.



K=10
ranking principal

80/20
split temporal

5-core
usuarios/items
activos

Modelos evaluados


Modelo	Señal	Idea
Random	Ninguna	Recomendación aleatoria
MostPopular	Popularidad	Restaurantes con más interacciones
SVD	Colaborativa	Factores latentes usuario-item
TextCF	SVD + MiniLM	Perfil textual desde restaurantes valorados positivamente
VisualCF	SVD + CLIP	Perfil visual desde fotos de restaurantes preferidos
MMGCN	Grafo + texto + imagen	Propagación en grafo bipartito multimodal
MMGCN-TMC	Grafo + incertidumbre	Fusión Dempster-Shafer por modalidad

Fusión multimodal

TextCF y VisualCF combinan la predicción colaborativa con similitud de contenido. MMGCN y MMGCN-TMC propagan embeddings de usuarios y restaurantes sobre el grafo bipartito para capturar relaciones indirectas entre usuarios con gustos similares y restaurantes visual/textualmente cercanos.

Resultados

Modelo	P@10	R@10	NDCG@10
MMGCN	0.0197	0.1231	0.0690
MMGCN-TMC	0.0190	0.1167	0.0665
VisualCF	0.0188	0.1105	0.0630
SVD	0.0180	0.1059	0.0605
TextCF	0.0159	0.0889	0.0527
MostPopular	0.0071	0.0463	0.0265
Random	0.0009	0.0049	0.0026



Curvas para Precision, Recall, NDCG, Novelty, Coverage e ILD.

Discusión

- MMGCN obtiene el mejor ranking:** mejora a SVD en NDCG@10 (0.0690 vs. 0.0605), lo que sugiere que la propagación en el grafo aprovecha señales colaborativas y multimodales complementarias.
- La modalidad visual aporta:** VisualCF supera a SVD en las tres métricas principales, indicando que las fotos contienen información relevante para preferencias gastronómicas y de ambiente.
- El texto aislado es más ruidoso:** TextCF queda bajo SVD, probablemente porque las reseñas agregadas mezclan experiencias, contextos y opiniones heterogéneas.
- Mayor complejidad no siempre mejora:** MMGCN-TMC queda cerca de MMGCN, pero no lo supera; en este conjunto, la fusión simple resulta más efectiva que modelar incertidumbre por modalidad.

Referencias

- A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, "Learning transferable visual models from natural language supervision," in *Proceedings of ICML*, 2021, pp. 8748–8763.
- Z. Han, F. Yang, J. Huang, C. Zhang, and J. Yao, "Trusted multi-view classification with dynamic evidential fusion," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 2, pp. 2551–2566, 2023.