

Motivación

Los sistemas tradicionales de recomendación ignoran el contenido multimodal, limitando su precisión ante el problema del "arranque en frío" de usuarios e ítems sin historial. Este proyecto replica enfoques SOTA (VL-CLIP y EFMRec) y propone mejoras arquitectónicas para resolver esta brecha semántica.

Dataset

PixelRec es un dataset multimodal diseñado para entrenar y evaluar sistemas de recomendación utilizando imágenes y texto. Para nuestro caso, utilizamos el subconjunto PixelRec50K, el cual es una muestra representativa que incluye 989.494 interacciones provenientes de 50.000 usuarios con 82.865 ítems.

Método

Gated Fusion (GF) combina las features de imagen y texto. Para esto, concatena ambas modalidades y calcula un peso w mediante un MLP con activación sigmoide. Luego, las features se combinan con la siguiente formula:

$$e_{fused} = w \odot e_{img} + (1 - w) \odot e_{txt}$$

Modelos


- 1. **CLIP/SigLIP**: Modelos multimodales que extraen features de texto e imagen.
- 2. **EFMRec(ER)**: Framework que une modalidades mediante early fusion, propaga representaciones con un grafo y luego usa filtrado colaborativo.
- 3. **VL-CLIP**: Modelo que mejora embeddings integrando segmentación de objetos e información textual refinada por LLM.
- 4. **SASRec(SR)**: Modelo SRS. Basado en mecanismo de auto-atención

Resultados

Para comparar, se utilizan las métricas Recall, nDCG y MAP, cada una incluye @5 y @10. La combinación entre CLIP y GF (Gated Fusion) retorna los mejores resultados.

Model	R@5	N@5	M@5	R@10	N@10	M@10
ER-Siglip-GF	0.002293	0.001629	0.001271	0.003135	0.001922	0.001373
ER-CLIP-GF	0.002212	0.001652	0.001307	0.003350	0.002067	0.001460
ER-Siglip	0.001914	0.001430	0.001089	0.003509	0.001986	0.001310
ER-CLIP	0.002196	0.001599	0.001249	0.003527	0.002064	0.001417
ER-SasRec	0.000690	0.000381	0.000160	0.002051	0.000857	0.000221
ER-Siglip-GF-SR	0.000978	0.000542	0.000208	0.001713	0.000810	0.000229
Item-KNN	0.001414	0.000944	0.000748	0.001962	0.001144	0.000828
VL-CLIP	0.001930	0.001440	0.000680	0.001930	0.001430	0.000340
Most Popular	0.000624	0.000583	0.000507	0.001033	0.000727	0.000558
Random	0.000192	0.000146	0.000089	0.000430	0.000206	0.000105

Gráfico comparación métricas



Conclusión y Trabajo Futuro

Los modelos multimodales preentrenados logran buenos resultados en sistemas de recomendación. Un siguiente paso sería fine-tunearlos con datos específicos de la tarea. Además hay amplio margen para desarrollar métodos de fusión más sofisticados, dado que Gated Fusion sigue siendo una mejora simple.

References

Chen, L., Yi, P., Hou, X., Yang, C., & Cai, X. (2026). When modalities go missing: Early fusion for multimodal recommendation. *Proceedings of the 19th ACM International Conference on Web Search and Data Mining*, 1094–1098.

Cheng, Y., Pan, Y., Zhang, J., Ni, Y., Sun, A., & Yuan, F. (2023). An image dataset for benchmarking recommender systems with raw pixels. *arXiv preprint arXiv:2309.06789*.

Giahi, R., Yao, K., Kollipara, S., Zhao, K., Mirjalili, V., Xu, J., Biswas, T., Korpeoglu, E., & Achan, K. (2025). VL-clip: Enhancing multimodal recommendations via visual grounding and llm-augmented clip embeddings. *arXiv preprint arXiv:2507.17080*.

Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *arXiv preprint arXiv:2103.00020*.

Zhai, X., Mustafa, B., Kolesnikov, A., & Beyer, L. (2023). Sigmoid loss for language image pre-training. *arXiv preprint arXiv:2303.15343*.