

RECOMENDACIÓN SECUENCIAL EN SESIONES DE E-COMMERCE

Tomás Andrés Ketterer Aguirre - Cristóbal Miguel Moreno Rojas - Vicente Ignacio Soto González

PROBLEMA Y MOTIVACIÓN

- Objetivo:** Resolver el problema de next-item prediction en e-commerce, prediciendo el próximo producto basado en las acciones recientes del usuario.
- Desafío:** Las sesiones son cortas y carecen de historial suficiente, obligando a recomendar solo con interacciones inmediatas (Jannach et al., 2022).
- Propuesta:** Evaluar si integrar reglas secuenciales, metadatos y modelos temporales logra superar a los enfoques clásicos de coocurrencia local.

DATASET Y PREPROCESAMIENTO

- Fuente:** Dataset eCommerce Multi-Category (Kaggle, Nov 2019) usando eventos de view, cart y purchase.
- Muestreo:** Reducción de volumen reproducible mediante hashing de sesiones (Amand et al., 2024).
- Preprocesamiento:** Creación de secuencias para next-item prediction, eliminando duplicados consecutivos para reducir ruido.
- Split Temporal:** División estricta en noviembre (Train: días 1-24, Val: 25-27, Test: 28-30).
- Filtrado:** Remoción de sesiones cortas e ítems de bajo soporte utilizando únicamente información de train.





Figura 1: Distribución de tipos de eventos



Figura 2: Distribución de la longitud de las sesiones

SEÑALES DEL DATASET



METODOLOGÍA

- Baselines:** Random, Popularidad e Item-KNN (co-ocurrencias).
- Neuronales:** GRU4Rec y SASRec.
- Reglas Secuenciales:** Transiciones intra-sesión más frecuentes.
- Híbridos:** Ensamble de vecinos (KNN) + reglas + popularidad.
- Reranking:** Ajuste final mediante metadatos (categoría, marca, precio).
- Exploración:** Integración del modelo TALE y análisis segmentado.

RESULTADOS GLOBALES

Al comparar únicamente modelos evaluados bajo el mismo pipeline y split temporal, las **variantes híbridas con metadatos** mostraron los resultados más consistentes.

MODELO	RECALL@20	NDCG@20	MAP@20
random	0.0007	0.0004	0.0003
most_popular	0.0787	0.0314	0.0184
gru4rec	0.1268	0.0598	0.0413
sasrec	0.1006	0.0458	0.0306
item_knn	0.3351	0.1654	0.117
hybrid_knn_rules	0.345	0.1684	0.1182
hybrid_tuned_meta	0.3518	0.1717	0.1203
tale	0.4186	0.2067	0.1465

Tabla 1: Resultados globales en test para los principales modelos

- TALE usa catálogo top-2000 de train.** Se muestra como extensión exploratoria y no como ganador de la comparación principal

LECTURA DE RESULTADOS




Figura 3: Recall@20 de los principales modelos comparables

Bajo condiciones comparables de evaluación, **los modelos híbridos superan a los modelos neuronales** y consolidan el mejor desempeño en Recall@20.

ANÁLISIS SEGMENTADO

El conjunto de test **no está distribuido de manera uniforme: predominan las sesiones cortas, los ítems populares y los casos con metadatos disponibles**. Esto es importante porque ayuda a interpretar por qué los **métodos basados en vecinos** obtienen tan buen desempeño promedio y en qué segmentos el **reranking con metadatos** aporta más valor.

TARGETS TAIL

ITEM-KNN MANTIENE BUEN DESEMPEÑO EN LA COLA LARGA, MIENTRAS GRU4REC Y SASREC CAEN A 0.0000 EN RECALL@20.

SESIONES LARGAS

LA MEJORA DEL RERANKING EN EL HÍBRIDO TAMBIÉN CRECE EN SESIONES LARGAS: +0.0112 EN RECALL@20.

RERANKING EN TAIL

EL RERANKING CON METADATOS APORTA MÁS EN ÍTEMS POCO FRECUENTES: +0.0200 EN ITEM-KNN Y +0.0186 EN EL HÍBRIDO.

SIN METADATA

CUANDO FALTAN METADATOS, EL RECALL PUEDE SUBIR LEVEMENTE, PERO NDCG Y MAP PUEDEN EMPEORAR.

TALE COMO EXTENSIÓN EXPLORATORIA

- Motivación:** TALE (modelo temporal lineal) es ideal para este dataset dominado por recencia y sesiones cortas.
- Implementación:** Se restringió al catálogo top-2000 de train por viabilidad computacional.
- Resultados:** Logró el mejor desempeño aislado (Recall@20 = 0.4186, NDCG@20 = 0.2067).
- Limitación y Trabajo Futuro:** Al usar un catálogo restringido, no es directamente comparable. Queda como desafío escalar TALE para una evaluación justa.

CONCLUSIONES

- Item-KNN:** fue un **baseline extremadamente fuerte** para este dataset.
- Los **modelos neuronales no lograron aprovechar una ventaja clara** bajo esta configuración.
- Las mejoras más consistentes vinieron de **hibridar señales locales** y usar **reranking con metadatos**.
- El análisis segmentado mostró que **el aporte de metadata no es uniforme**, ayuda mas en **mid/tail** y sesiones medias/largas.
- TALE** sugiere una linea futura interesante, pero queda como **extensión exploratoria** por su **catálogo restringido y desafíos de escalabilidad**.
- La estructura del dataset favorece **señales de corto plazo**, por lo que el contexto de evaluación **influye fuertemente** en qué modelos resultan más competitivos.

TRABAJO FUTURO

- Análisis por **tipo de evento** reteniendo **event_type** en las secuencias
- Comparaciones justas** bajo un **mismo catálogo reducido** para todos los modelos
- Escalar la integración de TALE** o evaluar variantes más eficientes
- Probar el pipeline en **más meses** o en **otro período de tiempo** del mismo e-commerce
- Validar si los hallazgos observados **se mantienen en otros datasets** o **dominios de recomendación secuencial**.

EJEMPLO DE RECOMENDACIÓN

- En este ejemplo, hybrid_tuned_meta utiliza los tres productos previos de la sesión como contexto y recomienda correctamente el siguiente producto en rank 1.



Figura 4: Ejemplo cualitativo de recomendación con hybrid_tuned_meta

REFERENCIAS

- Aamand, A., Bercea, I. O., Houen, J. B. T., Klausen, J., & Thorup, M. (2024). *Hashing for sampling-based estimation*.
- Jannach, D. et al. (2022). Session-based recommender systems.
- Ludewig, M. & Jannach, D. (2018). Evaluation of session-based recommendation algorithms.
- Hidasi, B. et al. (2016). Session-based recommendations with recurrent neural networks.
- Kang, W.-C. & McAuley, J. (2018). Self-attentive sequential recommendation.
- Park, et al. (2025). Temporal Linear Item-Item Model for Sequential Recommendation.