

El problema

Entrenar recomendadores emite CO₂ [1], en especial al aumentar la complejidad de los modelos. La comunidad optimiza la **calidad** e ignora el **costo ambiental** [2], lo que genera un desafío importante de abordar. Encontramos artículos que se refieren a la importancia de las funciones de pérdida en el impacto ambiental de los modelos de recomendación [7], como de la labor de las loss en la mejora de los resultados. Muchos de esos experimentos se publican con configuraciones de hardware que no son necesariamente extensivas en su uso ¿Qué pasa entonces al hacer prueba de esto en el entorno de Google Colab?

Preguntas

- **P1.** ¿Cómo se comparan las pérdidas en el *trade-off* calidad vs CO₂?
- **P2.** ¿Cómo afecta el hardware a las emisiones?

Método

- **Modelos:** tres arquitecturas secuenciales: **SASRec** [5] (*self-attention*), **GRU4Rec** [6] (red recurrente) y **NextItNet** (convoluciones dilatadas), más baselines sin entrenamiento **Pop** y **Random**.
- **Pérdidas:** BPR, TOP1, CE, y **BPR-max / TOP1-max** implementadas por nosotros (*N*=10 negativos).
- **Datasets:** cuatro dominios y escalas: música (**LastFM**, ~52K), películas (**ML-100K**, ~100K), e-commerce (**Beauty**, ~198K) y sesiones de compra (**Diginetica**, ~993K interacciones).
- **Medición:** CodeCarbon [3] en 3 GPUs de Colab (T4, L4, A100). Hiperparámetros fijos para aislar el efecto de la pérdida.


204 runs en total

El costo de cada pérdida

Depende de contra cuántos ítems se compara el positivo [7, 8]:


BPR, TOP1	1 negativo	barato
-max	10 negativos	medio
CE	catálogo completo	caro

Calidad vs emisiones



CE da la mejor calidad independiente del modelo. A una escala mayor, por ejemplo, en Diginetica, es la más contaminante. Las **-max** son parecen ser un buen punto medio.

Escalamiento por dataset



El ritmo relativo de crecimiento es similar entre modelos. NextItNet es el más caro en absoluto en todas las escalas. (A100, CE.)

P1 — Pérdidas

SASRec, T4						
Dataset	Métrica	CE	BPR	TOP1	BPR-m	TOP1-m
LastFM	NDCG	0.025	0.017	0.017	<u>0.024</u>	0.023
	CO ₂ (g)	0.18	0.19	0.19	0.19	<u>0.19</u>
ML-100K	NDCG	0.046	0.032	0.026	0.043	<u>0.043</u>
	CO ₂ (g)	0.90	0.95	0.94	<u>0.91</u>	0.91
Beauty	NDCG	0.043	0.020	0.013	<u>0.028</u>	0.024
	CO ₂ (g)	2.04	2.07	2.07	2.03	<u>2.03</u>
Diginetica	NDCG	0.238	0.162	0.142	<u>0.186</u>	0.148
	CO ₂ (g)	2.89	2.57	<u>1.19</u>	2.51	1.02


CE domina en NDCG; las -max quedan segundas con igual o menos CO₂. Baselines (NDCG): Pop = 0.022 / **0.056** / 0.010 / 0.005, Random < 0.008.

P2 — Hardware

CE, SASRec				
Dataset	Métrica	T4	L4	A100
LastFM	NDCG	0.025	0.025	0.025
	CO ₂ (g)	0.18	0.58	0.74
ML-100K	NDCG	0.046	0.047	0.045
	CO ₂ (g)	0.90	1.10	1.26
Beauty	NDCG	0.043	0.042	0.043
	CO ₂ (g)	2.04	1.81	2.04
Diginetica	NDCG	0.238	0.239	0.238
	CO ₂ (g)	2.89	8.67	9.76

Mismo NDCG entre GPUs; solo cambia el CO₂. Tablas completas en el repositorio.

CO₂ total por hardware



La GPU más rápida (A100) no es la más limpia. **L4 es 2.4× más verde que T4 experimentando con estos modelos.**

NextItNet desvía los resultados. La T4 tiene buenas métricas al mismo tiempo que gasta menos, en modelos livianos. A100 termina más rápido, pero sigue gastando más.

Hallazgos


- CE gana en calidad (26 de 36 casos), pero su sobrecosto **crece con el catálogo** (+59 % de CO₂ en Diginetica).
- TOP1 y BPR obtienen peores métricas. Versiones **-max** mejoran las métricas, elevando emisiones levemente.
- El hardware cambia el **costo**, no la calidad (mismo NDCG en las 3 GPUs).
- **Interacción modelo×hardware:** en modelos livianos la GPU con menor capacidad es la más verde. NextItNet en la T4 explota (277 g vs 64 g en L4).
- **Pop supera a los neuronales en ML-100K** con ~0 g de entrenamiento.

Conclusiones

Pérdida: preferir **-max** por sobre versión normal. CE mantiene emisiones y obtiene buena calidad. Si el catálogo aumenta, crecen los costos. BPR y TOP1 no obtienen buenas métricas

Hardware: elegir **según el modelo**: T4 es recomendable para modelos livianos, L4 para modelos más pesados. Modelos muy pesados como NextItNet empeoran mucho con T4.

Código y datos



github.com/davidlealo/green-recsys

Referencias

[1] Vente, T., Wegmeth, L., Said, A., Beel, J. *From Clicks to Carbon: The Environmental Toll of Recommender Systems*. RecSys 2024.

[2] Beel, J., Said, A., Vente, T., Wegmeth, L. *Green Recommender Systems — A Call for Attention*. 2024.

[3] Courty, B., Schmidt, V., Luccioni, S., et al. *CodeCarbon: Estimate and Track Carbon Emissions from ML Computing*. 2021.

[4] Rendle, S., Freudenthaler, C., Gantner, Z., Schmidt-Thieme, L. *BPR: Bayesian Personalized Ranking from Implicit Feedback*. UAI 2009.

[5] Kang, W., McAuley, J. *Self-Attentive Sequential Recommendation*. ICDM 2018.

[6] Hidasi, B., Karatzoglou, A., Baltrunas, L., Tikk, D. *Session-based Recommendations with Recurrent Neural Networks*. ICLR 2016.

[7] Plaza, A., Gil, J.C., Parra, D. *14 Kg of CO₂: Analyzing the Carbon Footprint and Performance of Session-Based Recommendation Algorithms*. RecSoGood 2024.

[8] Li, F., Peng, H., Yu, S., Zeng, F., Chen, F., Yang, F. *Revisiting the Loss Functions in Sequential Recommendation*. Eng. Appl. of Artificial Intelligence, 2024.