

RECOMENDACIÓN REPEAT-AWARE EN STREAMING MUSICAL

Pedro Munita, José Racioppi, Tomás Couyoumdjian

Pontificia Universidad Católica de Chile | Grupo 32 - IIC3633

Motivación y Problema

Los sistemas recomendadores tradicionales asumen erróneamente que un ítem ya consumido pierde interés futuro. En streaming musical, el reconsumo es estructural. El desafío radica en predecir el siguiente ítem coexistiendo dos modos: **Repetición** e **Exploración**.

La señal de repetición no depende de la frecuencia absoluta, sino de la **dimensión temporal**. El objetivo es evaluar si modelos sensibles a dinámicas temporales mitigan el sesgo exploratorio bajo un protocolo estricto.

Infraestructura de Datos y Pipeline

El dataset original *Last.fm 1K Users* (2.5 GB, ≈ 19 M interacciones) saturaba la RAM local. Se diseñó un pipeline robusto en dos pasadas:

- **Procesamiento por Fragmentos:** Lectura indexada descartando campos nulos redundantes (`artist_id`, `track_id`).
- **Clave de Ítem Única:** Ante la falta de IDs, se construyó la clave combinada: `"<artist_name>- <track_name>"` blindando la semántica.
- **Almacenamiento Optimizado:** Escritura en Parquet comprimido con PyArrow, reduciendo la memoria máxima a **1 GB** y el cómputo a **67 s**.

Contribución Central: Temporal BPR (T-BPR)

1. Fase de Entrenamiento (Muestreo Negativo Temporal)

Reemplazamos el muestreo uniforme de BPR por una **distribución dependiente del tiempo**. Definimos una ventana dinámica de repetición $W_u = (p_{25}, p_{75})$ basada en los intervalos empíricos del usuario. La probabilidad de muestrear un ítem j como negativo es:

$$p(j|u, t) \propto \begin{cases} \alpha & \text{si } \Delta_{uj}(t) \in W_u \\ 1 & \text{si } j \notin H_u \\ \beta & \text{en otro caso} \end{cases}$$

Esto castiga severamente ($\beta > 1$) repetir fuera de compás, y reduce la penalidad ($\alpha < 1$) en la zona típica del usuario.

2. Fase de Inferencia (Capas Repeat-Aware)

Para construir el ranking Top-K final, los puntajes del espacio latente ($s_{u,i} = P_u Q^T + b$) se modulan dinámicamente mediante tres heurísticas:

- **Recency Boost:** Aumento directo a ítems únicos consumidos recientemente, aplicando un decaimiento $1/(1 + \text{pos})$.
- **Activación Temporal (Memoria):** Favorece ítems frecuentes/recientes sumando un logaritmo con decaimiento: $\log(1 + \sum \Delta_h(t)^{-\gamma})$.
- **Calibración del Repeat Ratio:** Búsqueda binaria de un *offset* global aplicado a ítems no vistos, forzando matemáticamente al Top-K a converger hacia la proporción objetivo de repetición del usuario.

Resultados Cuantitativos

Tabla 1: Matriz comparativa de rendimiento

Modelo	Recall@10	nDCG@10	MRR	Repeat Ratio	Hits
<i>Baselines Clásicos</i>					
Random	0.0000	0.0000	0.0000	0.009	0/100
MostPopular	0.0000	0.0000	0.0000	0.055	0/100
SimpleRepeat-Freq	0.0000	0.0000	0.0000	0.055	0/100
SimpleRepeat-Rec.	0.0900	0.0667	0.0597	1.000	9/100
<i>Modelos Avanzados e Implementados</i>					
TemporalBPR	0.0700	0.0596	0.0564	0.507	7/100
PISA (RecSys 2024)	0.0900	0.0673	0.0604	0.992	9/100
RepeatNet	0.0800	0.0374	0.0247	0.267	8/100

Análisis Descriptivo y Discusión

- **Insuficiencia de la Frecuencia Histórica:** La correlación de Spearman entre frecuencia y reaparición secuencial es muy débil ($\rho = 0,284$). **SimpleRepeat-Freq** obtuvo 0 aciertos.
- **Calibración Dinámica del Ratio:** La tasa global histórica es del 60.43 %, pero cae al 33 % en la última interacción. **T-BPR** se destaca logrando el mejor balance (0.507), mitigando el sobreajuste al historial.
- **Validación de Localidad Temporal:** Los intervalos de repetición exhiben una asimetría crítica: el 25 % ocurre en menos de 1.74 h (p_{25}) y el 50 % dentro de 27.04 h (p_{50}).




Fig. 1: Distribución de $\log(1 + \text{intervalo})$ entre repeticiones evidenciando localidad temporal

Conclusiones y Trabajo Futuro

Se demostró experimentalmente que BPR logra superar a métricas básicas como Random, Most Popular o SimpleRepeat-Freq, demostrando su utilidad y el valor del aspecto temporal en la recomendación. Sin embargo no se logran alcanzar valores de PISA o RepeatNet. Por lo tanto, se proponen los siguientes pasos futuros:

Proyecciones:

1. **Búsqueda de Hiperparámetros:** Continuar en búsqueda de combinaciones de hiperparámetros que mejoren resultados de métricas.
2. **Escalamiento Estadístico:** Validar los modelos sobre los 992 usuarios del catálogo completo vía *bootstrap*.
3. **Adaptación a Nuevos Conjuntos de Datos:** Adaptar el modelo a nuevos set de datos y comparar resultados con PISA y RepeatNet.
4. **Modelo Híbrido:** Implementar un árbol de decisión basado en cuatro *features* ($r_u, \tau_{u,t}, \bar{\Delta}_u, |H_u^{30d}|$) para conmutar probabilísticamente entre enfoques.




Fig. 2: Arquitectura del Modelo Híbrido de Ruteo

Referencias

- Rendle, S. et al. (2009). BPR: Bayesian Personalized Ranking from Implicit Feedback.
Ren, K. et al. (2019). RepeatNet: A Repeat Aware Neural Recommendation Machine.
Tran, T. et al. (2024). PISA: Repeat-Aware Session Recommendation via ACT-R.
Benson, A. R. et al. (2016). Modeling user consumption sequences.