

Continuación Automática de Playlists (APC)

Two-Stage Hybrid vs. Baselines Secuenciales y Colaborativos

Agustín Llambias Amaya Quero Larry Uribe

Pontificia Universidad Católica de Chile – IIC3633 Sistemas Recomendadores (2026-1) **Mensaje clave:** el modelo híbrido mejora cobertura y mantiene un rendimiento competitivo sin depender de APIs externas.



UC | Chile

1. Introducción

La tarea de *Automatic Playlist Continuation* (APC) consiste en recomendar canciones para extender playlists existentes de forma coherente con el contexto musical ya presente.

En escenarios reales, APC enfrenta dos tensiones: maximizar calidad de ranking y mantener diversidad/coertura para evitar recomendaciones redundantes.

Este trabajo propone un enfoque reproducible y local, sin dependencia operacional de APIs externas. La idea es capturar señales de co-ocurrencia y contexto mínimo para producir recomendaciones coherentes, pero también útiles para exploración del catálogo.

La contribución principal es un protocolo completo de evaluación que combina exactitud, cobertura y análisis por segmentos sobre un mismo conjunto de playlists.

2. Pregunta de investigación y objetivos

Pregunta: ¿Qué tan competitivo es un sistema APC local y reproducible de dos etapas frente a métodos secuenciales y colaborativos, al evaluar tanto accuracy como métricas beyond-accuracy?

Hipótesis de trabajo: la co-ocurrencia debe dominar la calidad estructural del ranking, mientras que el reranking local ayuda a sostener cobertura y diversidad.

Objetivos:

- Evaluar rendimiento frente a baselines fuertes.
- Cuantificar aporte de cada señal mediante ablations.
- Analizar comportamiento por segmentos y casos cualitativos.

3. Datos y protocolo experimental

- Dataset Spotify Playlists (Kaggle) con muestra determinística por hash.
- Ejecución principal: 30% (63,851 playlists evaluadas).
- Ejecución de sensibilidad: 20%.
- Esquema de evaluación: *leave-last-out*, mínimo 3 canciones por playlist.

4. Metodología propuesta

Two-Stage Hybrid

1 **Retrieval:** vecinos item-item por co-ocurrencia (normalización coseno).

2 **Reranking:** fusión ponderada de cooc + popularidad + artista + nombre de playlist.


Definición de señal cooc: cooc corresponde a la frecuencia de co-ocurrencia de dos canciones dentro de una misma playlist; a mayor co-ocurrencia relativa, mayor afinidad estructural entre ítems.

La primera etapa reduce el espacio de búsqueda a candidatos plausibles; la segunda reordena con señales locales que ayudan a recuperar contexto y a suavizar sesgos de popularidad.

Comparadores incluidos

- Sequential Markov (primer orden)
- Collaborative ItemKNN
- Random, Most Popular, Playlist Name Popular

5. Arquitectura (pipeline visual)




6. Métricas reportadas

- Accuracy: HitRate@10, Precision@10, MAP@10, nDCG@10.
- Beyond-accuracy: ILD@10 (diversidad), Novelty@10, CatalogCoverage@10.


18. Referencias

- 1 Raasveldt, M. y Muhleisen, H. *DuckDB: An Embeddable Analytical Database*. CIDR, 2020.
- 2 Chen, S. et al. *Automatic Playlist Continuation through a Hybrid of Collaborative and Content Signals*. RecSys Workshop.
- 3 Schedl, M. et al. *Current Challenges and Visions in Music Recommender Systems Research*. International Journal of Multimedia Information Retrieval.


7. Resultados principales (ejecución 30%)




8. Ablations por señal



9. Robustez (ejecución 20%)



10. Trade-off beyond-accuracy



11. Análisis de resultados


- Markov lidera en calidad de ranking (MAP/nDCG).
- Two-Stage mantiene HitRate competitivo y mayor cobertura de catálogo.
- La ablación *sin cooc* produce la mayor caída: cooc es la señal estructural clave.
- El método híbrido ofrece mejor balance entre exactitud y exploración del catálogo.

La lectura conjunta de las métricas sugiere que el modelo no solo acierta más o menos, sino que reordena mejor el espacio de recomendación cuando necesita cubrir perfiles menos frecuentes.

17. Trabajo futuro

- Reranking sensible a cola larga (targets *tail*).
 - Ajuste dinámico de pesos según coherencia y tamaño de playlist.
 - Embeddings semanticos livianos para reducir drift de genero.
- Evaluar estas variantes por segmento y por dominio musical ayudaría a medir estabilidad real fuera de la muestra actual.

12. Análisis por segmentos



13. Evidencia cualitativa

Caso de acierto (perfil medium + head): el modelo conserva coherencia musical y recupera recomendaciones cercanas al objetivo.

Caso de error (perfil long + tail): deriva hacia subgeneros cercanos, sin capturar identidad de nicho del target.

Estos casos muestran el patrón más estable del sistema: cuando existe suficiente huella de co-ocurrencia, el reranking refina bien; cuando el target es muy raro, faltan señales externas para desambiguar.

14. Decisión metodológica sobre LastFM

LastFM se evaluo como enriquecimiento opcional, pero se excluyo del pipeline principal por latencia de API y reproducibilidad limitada a gran escala.

La evaluación final prioriza un protocolo **local, estable y repetible**.

En un póster final, esta decisión importa porque fija un mensaje metodológico claro: la validez experimental depende de que el sistema pueda volver a ejecutarse con las mismas entradas y sin costo operacional oculto.

15. Discusión y limitaciones

- El rendimiento disminuye en playlists largas con targets de cola larga.
- La ausencia de embeddings semánticos limita la capacidad de generalización en nichos.
- Existe un trade-off explícito entre diversidad extrema y precisión de ranking.

En consecuencia, el sistema es sólido como base metodológica, pero todavía sensible a escenarios donde la coherencia musical no puede inferirse solo con co-ocurrencia local.

16. Conclusiones

- 1 Two-Stage Hybrid es una base robusta y reproducible para APC.
- 2 Comparadores fuertes (Markov/ItemKNN) son esenciales para una evaluación justa.
- 3 Las métricas beyond-accuracy muestran trade-offs relevantes para despliegue real.

En conjunto, el trabajo deja una evidencia clara: la mejora de ranking no debe evaluarse aislada de cobertura y diversidad, porque en APC ambas dimensiones son parte del objetivo final.