



Warning Labels Meet Recommender Systems: A Nutrition Aware Recipes Recommender



Catalina Anusch, José Villalobos, Anibal Villegas

Motivación

Los sistemas de recomendación de comida tradicionales suelen priorizar la relevancia basada en preferencias históricas, llevando a un sesgo hacia alimentos procesados o con alta densidad calórica. Nuestra propuesta busca mitigar este problema, integrando la **Ley de Etiquetado de Alimentos de Chile (Ley 20.606)** mediante la penalización o re-ranking de las sugerencias.

Intersección de Sellos en las 10,000 Recetas Más Populares




Figura 1: Intersección de Sellos



Figura 2: Sellos

Problema

El objetivo fue entregar a cada usuario una **lista top@10 de recetas recomendadas**, que balancearan tanto relevancia como salud. Algo particularmente desafiante en Food.com: 73,9% de las reseñas tenían rating 5 (Figura 3), por lo que casi cualquier receta consumida por un usuario podía ser "relevante". Beneficiando así sistemáticamente a las recetas más populares, que como indica la Figura 1, concentraban sellos de advertencia nutricional.




Figura 3: Distribución de Ratings

Dataset

Utilizamos el dataset [Food.com Recipes and Reviews](#) disponible en Kaggle, tras filtrado de atributo de porciones vacías y usuario con un solo review:

- 257.707 recetas
- 72.099 usuarios

Por otra parte, a partir del cálculo de las ponderaciones TF-ISF (Term Frequency-Inverse Recipe Frequency) para los ingredientes de las recetas, se construyó un grafo de similitud. Luego, mediante el algoritmo de detección de **comunidades Louvain** se detectaron **clústers pertinentes (repostería, panes, pollo, bebidas)**, guardando así una categoría para cada receta.

Metodología

Se evaluaron cuatro familias de modelos con tres mecanismos distintos de integración de salud: Content-Based (TF-IDF + SVD, baseline sin salud), LightFM (sellos como features en el embedding), HTFRS-Sellos (re-ranking que penaliza recetas con sellos mediante un peso y controlable, basado en Rostami et al. 2023), y Deep Q-Learning (agente que balancea relevancia y salud en su recompensa mediante un peso α). Además, se definieron algunas métricas propias:

- **S@k**: Promedio de sellos por receta en el top-K.
- **SS@k**: Porcentaje de recetas sin ningún sello en el top-K.
- **Novedad@K**: Proporción de ítems no vistos por el usuario, sin sellos y pertenecientes al clúster dominante de su historial en el top-K.
- **Diversidad@K**: Proporción de clústers distintos presentes en las top-K recomendaciones respecto al número de recomendaciones.

Resultados

Modelo	P@10 ↑	R@10 ↑	F1@10 ↑	nDCG@10 ↑	S@10 ↓	SS@10 ↑	Div ↑	Nov ↑
Content – Based	0.0002	0.0009	0.0002	0.0011	1.309	0.3588	0.4809	0.1134
LightFM(sin sellos)	0.0051	0.0148	0.0056	0.0117	1.226	0.3139	0.7286	0.0472
LightFM(con sellos)	0.0044	0.0103	0.0043	0.0093	0.0469	0.957	0.3632	0.0221
HTFRS (sin sellos)	0.0027	0.0103	0.004	0.014	1.2288	0.3421	0.7876	0.0327
HTFRS ($\gamma = 0.2$)	0.0016	0.0078	0.0025	0.0102	0.3411	0.7803	0.4772	0.0174
HTFRS ($\gamma = 0.5$)	0.001	0.0047	0.0016	0.0072	0.2613	0.8589	0.4289	0.0174
Deep Q – Learning ($\alpha = 0$)	0.0004	0.0011	0.0005	0.0007	2.2204	0.0216	0.62925	0.2813
Deep Q – Learning ($\alpha = 0.5$)	0.0007	0.0018	0.001	0.0014	0.0691	0.9315	0.4194	0.024

Trade-Off Relevancia Salud

Cada modelo integra los sellos de forma distinta: LightFM en el embedding, HTFRS mediante re-ranking con peso γ , y Deep Q-Learning en la recompensa con peso α . **LightFM (con sellos) logra el mejor balance: SS@10 sube de 31% a 95.7% con solo -0.0024 en nDCG.** HTFRS ofrece control granular ($\gamma=0.2$: SS@10=78%; $\gamma=0.5$: SS@10=86%) y Deep Q-Learning ($\alpha=0.5$) alcanza SS@10=93% pero con nDCG muy bajo (0.0014). La Frontera de Pareto confirma que no existe un modelo dominante en ambas dimensiones, permitiendo elegir según la prioridad del sistema.




Figura 5: Diversidad y Novedad LightFM




Figura 6: Top 8 Clústers en Recetas Recomendadas por LightFM

Conclusiones clave

Los modelos sin factor de salud (Content-Based, LightFM base, HTFRS $\gamma=0$) presentan S@10 superior a 1.2, indicando que en promedio cada receta recomendada tiene más de un sello. Al integrar salud, todos los mecanismos logran reducir S@10, pero con distintos costos en relevancia y diversidad. **Se observa además que mayor SS@10 se asocia consistentemente a menor diversidad**, sugiriendo que las recetas saludables disponibles se concentran en pocas categorías.

¿Cómo cambian las recetas?

Recetas preparadas por usuario (ID = 312081)

- Arroz español con tocino (2 sellos)



- Pollo frito con almendras (2 sellos)



- Chocolate brownies (3 sellos)



- Barra de chocolate navideña (3 sellos)




Recetas recomendadas por LightFM (con sellos)

- Sopa de carne asada



- Pasta con pollo y brócoli



- Pancakes (2 sellos)



- Pollo cajún con crema (1 sello)



Referencias

- [1] Ministerio de Salud. Manual de etiquetado nutricional de alimentos (2a ed.). 2019. Recuperado de: <https://minsal.cl>
- [2] Rostami, M., Farrahi, V., Ahmadian, S., Jalali, S. M. J., & Oussalah, M. A novel healthy and time-aware food recommender system using attributed community detection. Expert Systems With Applications, 221, 119719, 2023. <https://doi.org/10.1016/j.eswa.2023.119719>



Pontificia Universidad Católica de Chile
Departamento de Ciencias de la Computación
IIC3633 - Sistemas Recomendadores