

Recomendador Multimodal de Juegos de Mesa con Cascade, CLIP, DeepFM y MMR

Martín Cortés · Manuel Delpiano · Yampai Ludueña
Pontificia Universidad Católica de Chile - Sistemas Recomendadores: IIC3633 - Profesor: Daniel Parra



Contexto

El crecimiento del catálogo de juegos de mesa en plataformas como BoardGameGeek dificulta el descubrimiento de títulos afines. Los recomendadores tradicionales tienden a favorecer títulos populares, ignorando la diversidad y la long-tail del catálogo. Este trabajo evalúa modelos colaborativos, basados en contenido e híbridos multimodales, analizando el balance entre precisión, diversidad y costo computacional. Se utilizó el dataset de BoardGameGeek (Kaggle), que incluye calificaciones explícitas (0-10) complementadas con descripciones textuales, mecánicas, temáticas y portadas visuales. Tras un filtro iterativo, el conjunto final comprende ~272K usuarios, ~21.9K juegos y ~18.7M interacciones (sparsity 99.69%). Se realizó una partición 80/20 y se evaluó el ranking con K=10 sobre N=2000 usuarios.

Metodología

Se implementaron modelos organizados en complejidad creciente. Como baselines se utilizaron un recomendador aleatorio (Random), uno basado en popularidad (Most Popular) y un Content-Based con TF-IDF construido sobre las descripciones textuales, mecánicas y temáticas de cada juego, donde el perfil de usuario se genera como un promedio ponderado por rating de los vectores TF-IDF de los ítems consumidos. Para filtrado colaborativo se entrenó un modelo ALS (Alternating Least Squares) con 100 factores latentes, utilizando interacciones binarizadas con un umbral de relevancia ≥ 7.0 para capturar preferencias implícitas. Para incorporar señales multimodales, se generaron representaciones complementarias: embeddings textuales densos mediante el modelo BERT all-MiniLM-L6-v2 (sentence-transformers) aplicado sobre el contenido textual concatenado de cada juego, y embeddings visuales de las portadas extraídos con VGG19 (Entrega 2) y posteriormente reemplazados por CLIP (openai/clip-vit-base-patch32), que ofrece representaciones más ricas al estar preentrenado con supervisión conjunta texto-imagen. Todos los embeddings se normalizaron con L2 para permitir comparaciones por similitud del coseno. El Ensemble Cascada combina las tres fuentes de información en un pipeline de dos etapas: ALS genera 200 candidatos iniciales y sus scores se combinan con las similitudes BERT y VGG19/CLIP mediante un promedio ponderado Min-Max normalizado. Los pesos óptimos (0.7 ALS, 0.2 BERT, 0.1 visual) se determinaron mediante grid search exhaustivo con paso 0.1 evaluando nDCG@10 sobre 250 usuarios.

El modelo DeepFM Multimodal extiende esta arquitectura con una red neuronal híbrida personalizada en Keras. En la primera etapa, ALS preselecciona 200 candidatos; en la segunda, DeepFM los re-rankea integrando embeddings colaborativos (factores ALS), semánticos (BERT proyectado a 100 dims) y visuales (CLIP proyectado a 100 dims). La arquitectura combina un componente de Factorization Machine, que captura interacciones cruzadas de bajo orden entre las distintas modalidades (user×BERT, user×CLIP, ALS×BERT, ALS×CLIP) con una torre DNN profunda (256→128→64 con BatchNorm y Dropout) para interacciones de alto orden. Se entrena con Binary Cross Entropy y

negative sampling (4 negativos por cada positivo, umbral ≥ 7.0) para optimizar directamente el ranking implícito.

Finalmente, para promover diversidad en las listas de recomendación, se aplica MMR (Maximal Marginal Relevance) como etapa posterior de reordenamiento ($\lambda=0.25$). MMR selecciona iterativamente el ítem que maximiza la combinación entre relevancia predicha y disimilitud respecto a los ítems ya seleccionados, utilizando una similitud combinada de BERT (80%) y CLIP (20%) para penalizar redundancia temática y visual dentro de la lista

Resultados

Para contrastar el rendimiento de los modelos propuestos frente a los baselines, se evaluaron las recomendaciones top-10 utilizando tanto métricas de exactitud (Precision@10, Recall@10 y NDCG@10) como de experiencia de usuario: novedad (Novelty@10), diversidad intra-lista (ILD@10) y cobertura global del catálogo (Coverage@10). En la Tabla se detallan los resultados obtenidos sobre el conjunto de test para una muestra representativa de usuarios.

Métrica	M. Popular	ALS	TF-IDF	CLIP	Cascada	Casc. + MMR	DeepFM Hib.	DeepFM + MMR
Precision@10	0.0566	0.0551	0.0058	0.0029	0.0562	0.0431	0.0600	0.0404
Recall@10	0.1185	0.0900	0.0199	0.0080	0.0959	0.0709	0.1039	0.0818
NDCG@10	0.0978	0.0894	0.0159	0.0059	0.0932	0.0705	0.0982	0.0781
Novelty@10	7.9750	9.8947	15.5856	14.6729	9.9303	9.9426	9.9443	10.1672
ILD@10	0.9272	0.9518	0.6824	0.9481	0.9481	0.9645	0.9478	0.9639
Coverage@10	0.0024	0.0206	0.0966	0.0548	0.0224	0.0226	0.0248	0.0318

Análisis

DeepFM Híbrido y MMR: El modelo DeepFM Híbrido alcanza la mayor precisión global del experimento (Precision@10 = 0.060, NDCG@10 = 0.098), demostrando que la fusión neuronal profunda de señales colaborativas, textuales y visuales supera a los enfoques individuales y al ensamble lineal. La arquitectura two-stage resulta clave: evaluar una red neuronal compleja sobre los ~21.9K ítems del catálogo sería demasiado costoso, pero al restringir la inferencia a 200 candidatos preseleccionados por ALS, el costo computacional se reduce en órdenes de magnitud sin sacrificar calidad. Al agregar el reordenamiento MMR, la diversidad intra-lista aumenta significativamente (ILD@10 = 0.964) y la novedad sube a 10.16, a costa de una reducción controlada en precisión. Este comportamiento confirma que MMR logra introducir variedad temática y visual en la lista sin destruir la relevancia del ranking, alcanzando un trade-off favorable entre ambos objetivos.

Ensamble Cascada (ALS + BERT + VGG19): La cascada con ponderación óptima (0.7, 0.2, 0.1) supera al baseline colaborativo ALS puro (Precision@10: 0.055 → 0.056), confirmando que incluso una combinación lineal simple de señales multimodales aporta información complementaria que enriquece al filtrado colaborativo tradicional. La mejora, aunque modesta en términos absolutos, es consistente y se observa también en Recall y NDCG. La variante con MMR eleva el ILD@10 al valor más alto de todo el estudio (0.965), lo que sugiere que la diversidad del reordenamiento se beneficia de la naturaleza más heterogénea de los candidatos generados por la cascada lineal frente a los del re-ranker neuronal.

Modelos Content-Based (TF-IDF y CLIP): Estos modelos obtienen valores de precisión y recall notablemente inferiores a las aproximaciones colaborativas e híbridas, resultado esperable dado que no aprovechan la señal de co-ocurrencia entre usuarios. Sin embargo, TF-IDF alcanza la mayor novedad del estudio (15.59) y la mayor cobertura de catálogo (9.66%), mientras que CLIP obtiene una cobertura de 5.48%. Esto evidencia que los modelos basados puramente en contenido e imágenes son inmunes al sesgo de popularidad inherente al filtrado colaborativo, logrando recomendar juegos de la long-tail que de otro modo quedarían ocultos. Este hallazgo justifica su inclusión como señales complementarias dentro de las arquitecturas híbridas, donde su rol no es generar recomendaciones directas sino enriquecer la representación de los ítems con información semántica y visual que el CF no puede capturar por sí solo.

Los resultados demuestran que la integración multimodal progresiva, desde baselines simples hasta DeepFM con reordenamiento MMR, permite mejorar simultáneamente la relevancia y la diversidad de las recomendaciones. La arquitectura two-stage con preselección ALS resuelve el cuello de botella computacional de evaluar redes profundas sobre catálogos grandes, mientras que el reordenamiento por diversidad (MMR) mitiga eficazmente la tendencia de los modelos colaborativos a concentrar recomendaciones en el mismo segmento de ítems populares.

Ejemplos Cualitativos

Usuario 9556 — Perfil: Estratega

#	DeepFM Base	DeepFM + MMR
1	Ra	Ra
2	San Juan	1960: Making of the President
3	The Princes of Florence	Railways of the World *
4	Tichu	Notre Dame
5	Samurai	Tichu
6	Notre Dame	Saint Petersburg
7	Saint Petersburg	San Juan
8	Amun-Re	Attika *
9	Taj Mahal	Imperial *
10	1960: Making of the Pres.	Taj Mahal

Usuario 224104 — Perfil: Aventurero Cooperativo / Horror

#	DeepFM Base	DeepFM + MMR
1	Betrayal at House on the Hill	Betrayal at House on the Hill
2	Elder Sign	Saboteur
3	Saboteur	Guillotine *
4	Smash Up	Exploding Kittens
5	Dixit: Odyssey	Dixit: Odyssey
6	Ghost Stories	Smash Up
7	Exploding Kittens	Elder Sign
8	Zombicide	Ghost Stories
9	Shadows over Camelot	Fluxx *
10	Zombie Dice	Zombie Dice

Referencias

- [1] Threnjen (2022). Board Games Database from BoardGameGeek. Kaggle.
- [2] M. Kaminskas, D. Bridge (2016). Diversity, serendipity, novelty, and coverage: A survey and empirical analysis of beyond-accuracy objectives in recommender systems. ACM TIIS, 7(1).
- [3] Y. Hu, Y. Koren, C. Volinsky (2008). Collaborative filtering for implicit feedback datasets. Proc. IEEE ICDM, 263-272.
- [4] N. Reimers, I. Gurevych (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. Proc. EMNLP-IJCNLP, 3982-3992.
- [5] K. Simonyan, A. Zisserman (2015). Very deep convolutional networks for large-scale image recognition. Proc. ICLR.
- [6] R. Burke (2002). Hybrid recommender systems: Survey and experiments. User Modeling and User-Adapted Interaction, 12(4), 331-370.
- [7] S. Vargas, P. Castells (2011). Rank and relevance in novelty and diversity metrics for recommender systems. Proc. ACM RecSys, 109-116.
- [8] M. Kula (2017). Metadata embeddings for user and item cold-start recommendations. Proc. CBRecSys@RecSys.
- [9] A. Radford, J.W. Kim, C. Hallacy, et al. (2021). Learning transferable visual models from natural language supervision. Proc. ICML, 8748-8763.
- [10] H. Guo, R. Tang, Y. Ye, Z. Li, X. He (2017). DeepFM: A factorization-machine based neural network for CTR prediction. Proc. IJCAI, 1725-1731.
- [11] J. Carbonell, J. Goldstein (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. Proc. ACM SIGIR, 335-336.
- [12] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, T.S. Chua (2017). Neural collaborative filtering. Proc. WWW, 173-182.