



Recomendación de noticias clickbait-aware sobre dataset MIND

Clemente Campos

Alvaro Restuccia

Max Reyes

Problema y Motivación

En la recomendación de noticias, optimizar solo por clicks puede favorecer titulares llamativos o clickbait, afectando la experiencia del usuario. Por ello, el problema no es solo recomendar noticias relevantes, sino también reducir señales no deseadas como clickbait, baja diversidad temática y baja novedad. En este proyecto se parte desde un ranking TF-IDF interpretable y se estudia si es posible reordenarlo usando features de clickbait, novedad y diversidad, buscando recomendaciones más informativas sin perder demasiado rendimiento en métricas como AUC, MRR y nDCG@10.

Dataset

Métrica	Train	Validation
Impresiones	156965	73152
Usuarios únicos	50000	50000
Noticias	51282	42416
Categorías	17	17
Subcategorías	264	257
Candidatos totales	5843444	2470998
Clicks totales	236344	111383
CTR	0.0404	0.0406
Promedio candidatos/impresión	37.2277	37.4699
Mediana historial usuario	24	23
Entity embeddings	26904	22893

Tabla 1: Resumen de datos de entrenamiento y validación




Gráfico 1: Categoría de noticias más frecuentes.

Se utilizó un subconjunto del dataset MIND balanceado con 50,000 usuarios únicos tanto en el conjunto de entrenamiento como en el de validación. El dataset recopila el comportamiento de clics sobre un catálogo dinámico de noticias que abarca 17 categorías generales y más de 250 subcategorías. El comportamiento del usuario es altamente denso, registrando una mediana de historial de 24 interacciones en Train y 23 en Validation.

El catálogo presenta un fuerte desbalance en sus temáticas (Gráfico 1); las categorías de "News" y "Sports" dominan drásticamente el volumen de noticias disponibles, sumando más de 30,000 artículos en el conjunto de entrenamiento, mientras que el resto de áreas exhibe una presencia significativamente menor.


El dataset registra un volumen masivo de candidatos recomendados, superando los 5.8M en entrenamiento y los 2.4M en validación, manteniendo una media consistente de ~37 candidatos por impresión. A pesar del enorme espacio de búsqueda, el Click-Through Rate (CTR) se mantiene sumamente estable en torno al 4.04% - 4.06% en ambos conjuntos.

Metodología

- Primero se representó cada noticia mediante un vector TF-IDF (Term Frequency - Inverse Document Frequency) calculado sobre la concatenación del título y el resumen. Para la recomendación, se construyó un perfil de usuario promediando las representaciones de las noticias en su historial. El ranking base se generó calculando la similitud coseno (producto punto de vectores normalizados) entre el perfil del usuario y las noticias candidatas.
- Se comparó el modelo TF-IDF base contra las siguientes variantes de re-ranking diseñadas para optimizar objetivos multimodales: **Random**, **Most Popular**, **TF-IDF + Low Clickbait**, **TF-IDF + Novelty** y **Re-ranking Completo/Optimizado**.
- Se utilizó la partición estándar del dataset MIND Small, empleando los conjuntos de train para el cálculo de popularidad y entrenamiento de representaciones, y el conjunto de dev (limitado a las primeras 5,000 impresiones) como set de validación/test para medir el desempeño del ranking.
- Se utilizaron dos tipos de métricas para contrastar los modelos:
 - Métricas de Precisión** (Ranking): AUC, MRR@10 y NDCG@10.
 - Métricas de Calidad Informativa**: CategoryCoverage@10 y CategoryDiversity@10 (Diversidad), Novelty@10 (Novedad), y ClickbaitScore@10 / HighClickbaitRate@10 (Reducción de contenido clickbait)

ClickbaitScore(CS) se calcula teniendo en cuenta las siguiente variables (Biyani et al., 2016):

- Presencia de frases comunes de clickbait.
- Presencia de signos de exclamación y/o interrogación.
- Presencia de muchas mayúsculas.
- Poca relación entre el título y el abstract.



Donde las metricas asociadas a clickbait se definen como:

$$\text{ClickbaitScore}@K = \frac{1}{K} \sum_{i=1}^K CS_i$$

$$\text{HighClickbaitRate}@K = \frac{1}{K} \sum_{i=1}^K \mathbb{1}(CS_i \geq \tau)$$

Donde τ representa un umbral de tolerancia, que fue elegido como el percentil 80 dentro de la distribución global de los score de clickbait.

Resultados

	AUC	MRR	nDCG@5	nDCG@10
LibFM	59.93	28.23	30.05	35.74
DSSM	64.31	30.47	33.86	38.61
Wide&Deep	62.16	29.31	31.38	37.12
DeepFM	60.30	28.19	30.02	35.71

Tabla 2: Baselines de referencia del paper MIND (Wu et al., 2020)

Modelo	AUC	MRR@10	nDCG@10	ClickbaitScore@10 ↓	HighClickbaitRate@10 ↓	Diversity@10 ↑	Novelty@10 ↑
Random	0.4987	0.2275	0.2869	0.1804	0.1850	0.8754	0.7285
Most Popular	0.4975	0.2259	0.2879	0.1880	0.2489	0.8853	0.5054
TF-IDF base	0.5809	0.3091	0.3625	0.1823	0.1716	0.8287	0.7182
TF-IDF + low clickbait	0.5868	0.3095	0.3627	0.1732	0.1463	0.8257	0.7218
TF-IDF + low clickbait + novelty	0.5859	0.3096	0.3623	0.1733	0.1434	0.8245	0.7380
Re-ranking optimizado	0.5794	0.3071	0.3588	0.1745	0.1470	0.8483	0.7372

Tabla 3: Resultados propios; TF-IDF, reducción de clickbait y re-ranking

Discusión

El ranking base TF-IDF logra superar a los métodos Random y Most Popular, lo que confirma que el contenido textual de las noticias, es decir, título y abstract, aporta información relevante para ordenar las recomendaciones. Además, al incorporar una penalización por clickbait, el desempeño no disminuye: TF-IDF + low clickbait obtiene el mejor AUC y el mejor nDCG@10, al mismo tiempo que reduce el ClickbaitScore@10 respecto al TF-IDF base. Esto sugiere que parte de las noticias con mayor señal de clickbait no eran necesariamente las más útiles para mejorar el ranking. Al agregar novedad, el modelo TF-IDF + low clickbait + novelty mantiene un rendimiento muy similar al TF-IDF base y obtiene la menor proporción de noticias con alto clickbait (HighClickbaitRate@10). Esto indica que es posible introducir criterios informativos adicionales sin afectar de manera relevante la calidad tradicional del ranking.




Gráfico 2: NDCG@10 vs HighClickbaitRate@10

El gráfico de dispersión complementa la tabla al mostrar distintas configuraciones de pesos del re-ranking. Cada punto corresponde a una combinación diferente de penalización por clickbait, bonificación por novedad y penalización por repetición de categoría. El objetivo del gráfico no es identificar cada combinación individual, sino observar el comportamiento general del sistema al modificar estos pesos.

Se observa que existen configuraciones con menor HighClickbaitRate@10 y un NDCG@10 cercano al mejor resultado obtenido. Esto muestra que la reducción de clickbait no necesariamente implica una pérdida fuerte de relevancia. Sin embargo, el gráfico también evidencia que no todas las configuraciones son igualmente convenientes: algunas reducen más el clickbait, pero con menor desempeño de ranking. Por esto, la selección del modelo final debe entenderse como un balance entre relevancia, menor exposición a clickbait, novedad y diversidad. Aun así, el AUC sigue siendo menor que el de DeepFM en MIND, por lo que el aporte principal está en la interpretabilidad y el control de clickbait/novedad/diversidad, no en superar el estado del arte.

Conclusión

Se desarrolló un sistema de recomendación de noticias clickbait-aware basado en TF-IDF y re-ranking interpretable sobre MIND Small. Los resultados muestran que es posible reducir señales de clickbait e incorporar novedad/diversidad manteniendo un rendimiento similar al ranking base. Aunque el desempeño predictivo aún es menor que el de modelos más complejos como DeepFM, el enfoque propuesto permite controlar explícitamente métricas de calidad informativa, ofreciendo una alternativa simple, interpretable y ajustable para recomendaciones de noticias.

Referencias

- [1] Wu et al. (2020). MIND: A Large-scale Dataset for News Recommendation.
- [2] Biyani et al. (2016). “8 Amazing Secrets for Getting More Clicks”: Detecting Clickbaits in News Streams Using Article Informality.