



Sistemas de Recomendación Conversacional (CRS): Evaluación de Representación de Diálogo y Tamaño de Contexto

Maximiliano Perry & Jenaro Prieto

Pontificia Universidad Católica de Chile

Motivación

Los sistemas de recomendación conversacional se diferencian de sistemas de recomendación tradicionales, principalmente porque el usuario interactúa directamente en el proceso de recomendación. Esto permite una interacción dinámica entre el usuario y el recomendador.



Una de las ventajas de estos sistemas es la capacidad de capturar las intenciones inmediata del usuario. Pero para lograr esto se necesita representar la conversación de una forma que lo entienda el recomendador y también hay que escoger que parte del contexto incluir, puede que no toda la conversación sea útil o que sea necesario darle mas importancia a lo mas reciente.

Problema

El problema se puede dividir en tres tareas fundamentales.

1. **Captar intención del usuario:** El usuario al inicio y durante la conversación va revelando sus gustos y su interés actual.
2. **Recomendación:** La recomendación en base al contexto actual.
3. **Generación de respuesta:** La recomendación se debe comunicarse al usuario dando un razonamiento que satisface las intenciones de este.

Datos





Metodología

Para evaluar la capacidad del recomendador ocupamos las metricas **Hit Ratio (HR@10)** y **Mean Reciprocal Rank (MRR@10)** ocupando distintas ventanas de contexto sobre las conversaciones de prueba de REDIAL, usando como *ground truth* a las películas mencionadas en estas recomendaciones.

1. **Captar intención del usuario:** sentence-BERT (all-MiniLM-L6-v2) y similitud coseno. utilizando N turnos del dialogo actual comparándolos con los diálogos de entrenamiento.
2. **Recomendación:** Las 10 películas mas mencionadas en los K diálogos mas similares.
3. **Generación de respuesta:** En base del la recomendación anterior y diálogos similares se genera una respuesta al usuario ocupando el modelo LLM Qwen-3.5-0.8B.

Resultados



- Mientras mas grande el contexto (N de turnos) mejora el rendimiento. Posiblemente, ya que los turnos cortos los efectos negativos asociados a grandes contextos no se alcanzan a ver.
- También se observa que el K optimo es cercano a 50. Esto posiblemente se debe a la dominancia que tienen los item populares en el datasets y después de este numero comienza a empeorar dado que consideran diálogos que no son relevantes.

Ejemplo de recomendación del set de prueba

- seeker: I like to watch scary movies
- recomender: tell me what kind of movie do you like?
- recomender: Did you watch It ?
- recomender: And It ?
- seeker: I have seen the old one
- recomender: Did you watch The Exorcist ?
- seeker: i have not seen the new one
- seeker: i do like the excorcist
- recomender: Ok, you should watch the new one
- recomender: Even though i would rather the old one
- recomender: And did you watch The Last Exorcism ?
- recomender: i hope i have helped
- seeker: no I have not but it sounds scary!
- seeker: thank you for the suggestions!
- recomender: You should try them
- recomender: your welcome
- recomender: good bye
- seeker: bye!

Recomendaciones: ['It (2017)', 'Nightmare (2011)', 'Get Out (2017)', 'The Conjuring (2013)', 'Annabelle 2 (2017)', 'The Shining (1980)', 'Saw (2004)', 'Paranormal Activity (2007)', 'Halloween (2007)', 'The Last Exorcism (2010)']

Discusión

Modelo	HR@10	MRR@10
azar	0.0142	0.0036
most popular	0.2399	0.1214
retrieval BM25	0.3271	0.1755
Ours[N=Full,K=50]	0.6363	0.3599

- Mientras que se soluciona el *cold start* para usuarios este problema sigue estando para los items
- Los diálogos suelen basarse en mencionar películas que los usuarios están familiarizados y solo se habla superficialmente de su contenido
- Creemos que para trabajos futuros una mejor estrategia seria solucionar cada tarea por separado en vez de intentar solucionar las tres a la vez

Referencias

Bibliografía:

- Li, R., et al. (2018). *Towards deeply conversational recommendations*. NeurIPS (Vol. 31). <https://arxiv.org/abs/1812.07617>
- Zhang, Z., et al. (2024). *LLM-powered user simulator for recommender system*. AAAI-25. <https://arxiv.org/abs/2406.01288>