



Agentic Context Engineering for Conversational Movie Recommendation: A Test-Time Approach

Autores: Tomás Ariztía, Rodrigo Meza, Vicente Muñoz

Pontificia Universidad Católica de Chile / Departamento de Ciencia de la Computación

Motivación y Problema de Investigación

- El fine-tuning de LLMs para sistemas recomendadores conversacionales (CRS) requiere datos etiquetados y es computacionalmente caro, por lo que es poco viable en entornos de industria con recursos limitados.
- Las estrategias de prompting estático (zero-shot, few-shot, CoT) tratan cada conversación de forma independiente, sin poder acumular aprendizajes sobre la calidad de las recomendaciones.
- La ingeniería de contexto adaptativa permite que el modelo refine sus estrategias episodio a episodio, sin modificar sus pesos ni requerir datos adicionales de entrenamiento.

Pregunta de Investigación:

¿Puede la actualización estructurada del contexto en tiempo de inferencia, mejorar la recomendación conversacional basada en LLMs sin modificar los pesos del modelo?

Métodos Comparados y Tipos de Memoria

Método	Tipo de Memoria	Mecanismo de Actualización
Zero-shot CoT	Ninguna (control)	—
Reflexion	Reflexión verbal no estructurada	Solo ante un fallo
Dynamic Cheatsheet	Notas acumulativas	Reescritura completa cada episodio
ACE	Playbook estructurado	Actualizaciones incrementales con deduplicación

Progresión: ninguna → reflexión verbal → notas acumulativas → Playbook con evaluación de utilidad de decisiones
Se usó muestra n=100 para los warmups de memorias.

Decisiones clave de adaptación:

- Cada diálogo de ReDial se trata como un episodio independiente (evaluación offline)
- El Reflector opera sobre TODAS las muestras (aciertos y fallos), lo que permite al Curator distinguir qué patrones de recomendación fueron útiles y cuáles no.
- Control de eco: todos los métodos comparten una instrucción explícita de no repetir títulos ya mencionados en el diálogo.
- Modelo base: Qwen3-8B (cuantizado a 4 bits) en los cinco métodos.
- El Generator devuelve un JSON con message de la recomendación principal con su lógica de recomendación + la lista de las 5 recomendaciones como lista en structured_recommendations.


Preparación de Datasets y Evaluación

	ReDial	PEARL
Fuente	Li et al. 2018	Kim et al. 2024
Diálogos	~10,000	~50.000
Selección de GT	gt_accepted	gt_accepted
GT / diálogo	2.48	1
Riesgo de Eco	Alto (GT son parte del diálogo)	Bajo (GT acotado)

Métricas: Recall@1, Recall@5, MRR, BERTscore, novelty. Soft-matching umbral=0.90

Evaluación: muestra n=300, Qwen3-8B 4-bit, prompt con reglas compartidas.

Método: Adaptación del pipeline ACE



Hallazgos

Hallazgos:

- En ReDIAL, ACE obtiene el R@5 más alto (0.43) pero también el echo rate más alto (28%). Refleja repetición, no recomendación genuina
- En PEARL con bajo echo los cinco métodos obtienen resultados similares y estadísticamente casi idénticos. (R@5 0.023–0.033): la memoria adaptativa no supera al CoT sin memoria
- Contribución central: un protocolo de evaluación que controla eco sobre dos datasets (real vs. sintético) revela que el recall exacto en diálogos reales está inflado por parroting.
- Reportar el echo rate es esencial para una comparación válida

Resultados

ReDia	Método	HR@1	R@5	MRR	BERTscore	Novelty	Echo %
	Zero-shot CoT	0.093	0.143	0.114	0.8588	0.73	18
	Reflexion	0.073	0.150	0.104	0.8576	0.71	20
	Dyn. Cheatsheet	0.050	0.093	0.066	0.8554	0.76	11
	ACE	0.2857	0.4286	0.3451	0.8661	0.6857	28
	ACE + Tools	0.1502	0.2344	0.181	0.8642	0.7113	21.1
PEARL	Método	HR@1	R@5	MRR	BERTscore	Novelty	Echo %
	Zero-shot CoT	0.013	0.030	0.021	0.8764	0.67	2.2
	Reflexion	0.010	0.023	0.014	0.8588	0.69	2.7
	Dyn. Cheatsheet	0.013	0.033	0.021	0.8754	0.68	1.8
	ACE	0.010	0.033	0.019	0.8761	0.6659	0.4
	ACE + Tools	0.0067	0.0233	0.0124	0.8761	0.6617	0.4

ACE + Tools consulta la API de TMDb para obtener género, director y reparto de las películas mencionadas en el diálogo. Esa metadata se inyecta en el prompt del Generator junto con el Playbook.

Conclusiones y Trabajo Futuro

Alcance de Resultados:

- Bajo control de eco (PEARL), ningún método muestra ventaja clara, el orden aparente en ReDIAL correlaciona con el echo rate, no con la calidad de la recomendación

- Los resultados son válidos como comparación relativa bajo este protocolo, modelo (Qwen3-8B 4-bit) y dominio (películas)

Próximos pasos:

- La metodología propuesta se debe extender a más modelos y tamaños, con mayor n de muestras y validación con LLM-as-Judge, u otro tipo de métricas más representativas de la recomendación en CRS.

- Distintas implementaciones para evitar la recomendación repetida

- Evaluar baselines con uso de tools.