



Recomendación Multimodal de Videojuegos en Steam

Comparación de recomendadores bajo un **protocolo común de evaluación**: la misma métrica (NDCG@10) varía $\sim 7\times$ según el protocolo, por lo que evaluamos todos los modelos con **full-ranking sobre el catálogo completo**.

Pablo Lagos • Benjamín Suazo IIC3633 Sistemas Recomendadores • Prof. Denis Parra • 2026



Código

Introducción y motivación

Recomendar “el próximo juego” en Steam es ranking a gran escala con señal implícita (*ownership*, *playtime*, reviews) sobre un catálogo dominado por blockbusters. Las métricas de la literatura para modelos profundos (NDCG@10 $\approx$ 0,99) y las de baselines (ALS $\approx$ 0,04) **no son directamente comparables**: se obtuvieron bajo **protocolos de evaluación distintos**. Contribución: **evaluar todos los modelos bajo un protocolo común** (full-ranking sobre el catálogo completo).

Preguntas de investigación

- **RQ1** ¿Cuánto cambia el NDCG@10 de los deep del **re-ranking per-user** al **full-ranking**?
- **RQ2** Bajo un **protocolo común**, ¿destaca el GNN/deep o un baseline clásico?
- **RQ3** ¿El modelo que destaca depende de la densidad del catálogo (UCSD/Kozyriev/SCGRec)?
- **RQ4** ¿Aporta la multimodalidad (contenido/grafos) sobre la señal colaborativa pura?


Datasets

	UCSD	Kozyriev	SCGRec
Señal (positivo)	ownership + playtime	reviews is_rec	interacciones
Catálogo (prot. común)	9.198 j	22.590 j	2.675 j
positivos/usuario	$\sim$ 8,9 (denso)	1,82 (disperso)	$\sim$ 2,3
Rol	reprod. Cheuque’19	nuestro dataset	reprod. CPGRec

El catálogo va de 2.675 a 22.590 j; ese eje ordena el “hallazgo del catálogo”. Absolutos **NO** comparables entre datasets.

Hallazgo del catálogo — reordenamiento del ranking


- **ALS** sube al 1.^{er} lugar en el catálogo más grande y disperso; BPR baja al crecer el catálogo.



Mismo eje del catálogo (2.675 $\rightarrow$ 22.590 j): el modelo destacado pasa del GNN/BPR (denso) a ALS (grande y disperso).

Beyond-accuracy — Diversidad (Coverage@10)


- El más diverso cambia por dataset: CB-SBERT (contenido) solo lidera en UCSD; en Kozyriev y SCGRec ganan baselines colaborativas (BPR y ALS) (RQ4).



CB-SBERT (contenido) es el más diverso solo en UCSD (25,6); en Kozyriev lo es BPR (33,0) y en SCGRec ALS (20,0) —baselines colaborativas—; CPGRec (grafo) queda bajo ALS en los tres. Cov = n.^o de categorías en el top-10; no comparable entre datasets.

Beyond-accuracy — Tradeoff accuracy $\leftrightarrow$ diversidad

- CB-SBERT (contenido) trepa en diversidad y cae en accuracy; en Kozyriev ALS combina ambos (RQ4).



Arriba-izq. = diverso pero impreciso (CB-SBERT); derecha = preciso (CPGRec/BPR). En Kozyriev ALS queda arriba-derecha: gana en ambos ejes.

Modelos (por modalidad)

- **Colaborativa** (interacciones + **playtime**) — **ALS** (MF implícito), **BPR** (ranking *pairwise*); **Most Popular** = piso por popularidad.
- **Contenido** (texto $\rightarrow$ SBERT) — **CB-SBERT**: embeddings de título/desc/tags.
- **Grafo de categorías** (género/dev/editor) — **CPGRec** (GNN, 2024) + extensiones **PER/PRG**.
- **Feature-based** (Cheuque’19) — **FM** / **DeepFM** / **DeepNN**.


Dos protocolos de evaluación

	Protocolo común (full-ranking)	Protocolo per-user (Cheuque’19)
Qué mide	desempeño sobre todo el catálogo	orden dentro del conjunto de test del usuario
Candidatos a rankear	TODO el catálogo (2,6K–22,6K ítems)	solo los ítems de test del usuario (pocos)
Evaluación	full-ranking	re-ranking per-user
playtime	como peso (confianza/perfil)	como feature de entrada
Rango típico	bajo (R@5 $\sim$ 0,03–0,4)	alto ($\sim$ 0,7–0,99)

Mismos datos y modelos; distinto protocolo. Cada uno responde una pregunta distinta y sus métricas no son directamente comparables: por eso adoptamos un protocolo común (full-ranking) para todos los modelos.

El protocolo mueve la métrica

- La misma métrica (NDCG@10) varía $\sim 7\times$ según el protocolo; el paso a full-ranking mueve más que quitar la feature.



Dos pasos: quitar *playtime* de las features (−0,28) y pasar a full-ranking (−0,57). Cada número es válido en SU protocolo; el protocolo de ranking es el que más mueve la métrica.

Resultados — Protocolo común (full-ranking)

- El modelo destacado cambia por dataset; ningún modelo gana en los tres (RQ2).

Método	UCSD	Kozyriev	SCGRec
Most Popular	0,119 / 0,165	0,029 / 0,028	0,213 / 0,207
ALS	0,105 / 0,144	0,059 / 0,056	0,375 / 0,355
BPR	0,140 / 0,187	0,039 / 0,038	0,415 / 0,397
CB-SBERT	0,013 / 0,017	0,016 / 0,014	—
CPGRec base	0,144 / 0,205	0,044 / 0,043	0,408 / 0,399
CPGRec +PER	0,138 / 0,197	0,044 / 0,043	0,395 / 0,383
CPGRec +PER+PRG	0,141 / 0,200	0,041 / 0,040	0,395 / 0,384
FM/DeepFM/DeepNN (R@5)	0,091 / 0,092 / 0,040	0,024 / 0,026 / 0,009	N/A

SCGRec (denso): CPGRec $\approx$ BPR — un baseline de 2009 iguala al GNN. UCSD (medio): CPGRec $\approx$ BPR $>$ ALS. Kozyriev (catálogo grande y disperso): destaca ALS, un baseline clásico (2008) es el más fuerte.

Ejemplos de recomendación

- Cada modelo “entiende” algo distinto (saga / tema / conducta / popularidad); el protocolo común indica cuál predice mejor.

Perfil (dataset)	Acierta ✓	Falla ✗	Lectura
Valve / Half-Life (SCGRec)	CPGRec : Counter-Strike, Left 4 Dead 2	ALS : Unreal Tournament, CoD	CPGRec capta la saga; ALS falla en heavy users.
Fallout / Borderlands (Kozyriev)	ALS : Life is Strange Ep.1	CB-SBERT : Fallout 4, Borderlands 3	Contenido: entiende el tema, no la conducta.
Usuario cold, CS:GO en test (UCSD)	MostPop / ALS : CS:GO	CB-SBERT : juegos de nicho	Catálogo concentrado en blockbusters.

Protocolo per-user (Cheuque’19) — NDCG@10


- Bajo re-ranking per-user los deep alcanzan $\sim$ 0,99 en ambos datasets (RQ1).

Método	con playtime / sin playtime		Koz. con	Koz. sin
	UCSD con	UCSD sin		
ALS (full-ranking)	0,414	—	0,140	—
FM (per-user)	0,992	0,708	0,999	0,905
DeepFM (per-user)	0,992	0,715	0,998	0,909
DeepNN (per-user)	0,992	0,731	0,999	0,925

El valor depende del protocolo, no del modelo (ALS full-ranking: 0,41 / 0,14). **Alcance**: el per-user reproduce los feature-based de Cheuque’19 (FM/DeepFM/DeepNN, únicos con *playtime* como feature); ALS es su contraste full-ranking. BPR/CPGRec van en el protocolo común.

Long-tail — NDCG@10 por actividad del usuario

- **ALS** cae en heavy users (SCGRec), donde BPR y CPGRec se mantienen; en Kozyriev ALS domina la cola.



Es el mecanismo del hallazgo del catálogo: la actividad del usuario decide qué modelo destaca en el promedio.

Análisis

- **Hallazgo del catálogo**: el modelo que destaca depende de la densidad. ALS es el más fuerte en catálogo abierto/disperso (Kozyriev); el GNN destaca en catálogos densos (SCGRec, UCSD).
- **Descomposición del protocolo**: el paso 0,99 $\rightarrow$ 0,14 se parte en (i) **playtime** como feature (UCSD −0,28) y (ii) per-user $\rightarrow$ full-ranking (UCSD −0,57); el protocolo de ranking domina ($\sim$ 67% UCSD, $\sim$ 91% Kozyriev).
- **Comparabilidad con Cheuque’19**: reproducimos su resultado (deep $\gg$ ALS) bajo su protocolo per-user; bajo full-ranking común los deep $\approx$ ALS y por debajo de CPGRec. Ambos números válidos, sobre la misma base.

Conclusiones

1. El **NDCG@10** de los deep depende del **protocolo (RQ1)**: pasa de $\approx$ 0,99 (per-user) a $\approx$ 0,14 (full-ranking); el factor que más mueve la métrica es el protocolo de ranking.
2. El **modelo que destaca depende del catálogo (RQ2+RQ3)**: ALS es el más fuerte en el catálogo grande y disperso de Steam; el GNN (CPGRec) destaca en catálogos densos.
3. La **multimodalidad no supera a la señal colaborativa pura (RQ4)**: el grafo (CPGRec) apenas iguala al mejor baseline (BPR) en accuracy y el contenido (CB-SBERT) es el piso; en diversidad solo CB-SBERT lidera, y solo en UCSD.
4. **Contribución metodológica**: el protocolo de evaluación es una decisión de primera clase; la comparabilidad entre trabajos y datasets exige un protocolo común (full-ranking) sobre 3 datasets.

Limitaciones y trabajo futuro

- **Convención playtime** (UCSD min vs h): solo mueve a ALS. **Densidad de Cheuque’19 no replicable** en Kozyriev (reviews): es estructural, no un defecto de datos.
- **1 seed** en baselines/deep (3 en CPGRec); **subsamples** (Koz 500K, SCGRec 2M); **PER** con rating global (proxy); reproducción de CPGRec $\sim$ 79–88% del paper.
- **Posibles extensiones**: CB-SBERT en SCGRec (falta texto), **Novelty@10** y modelos secuenciales (SASRec/GRU4Rec) bajo el mismo protocolo común.

Referencias

[1] Cheuque, Guzmán & Parra (2019), *Recommender Systems for Online Video Game Platforms: STEAM*, WWW’19 Comp. [2] Li et al. (2024), *CPGRec*, WWW’24. [3] Li et al. (2026), *CPGRec+*. [4] Yang et al. (2022), *SCGRec*, WWW’22. [5] Hu, Koren & Volinsky (2008), *CF for Implicit Feedback*, ICDM. [6] Rendle et al. (2009), *BPR*, UAI. [7] Reimers & Gurevych (2019), *Sentence-BERT*, EMNLP. Datasets: Kozyriev (Kaggle), FronkonGames (Kaggle), UCSD/McAuley Steam.