



Multimodalidad: Recomendación de películas

Florencia Schiappacasse, Gustavo Gonzalez y Alinna Vidal

Motivación y objetivo

El crecimiento exponencial de contenido digital ha generado un problema de **sobrecarga de información**, donde los usuarios enfrentan dificultades para encontrar contenido relevante. Los sistemas de recomendación surgen como una solución a este problema, permitiendo filtrar información y entregar contenido personalizado a los usuarios. En particular, los sistemas de recomendación basados en filtrado colaborativo utilizan interacciones usuario-ítem, como calificaciones, para predecir preferencias.

Sin embargo, estos enfoques presentan limitaciones importantes, tales como la **dispersión de los datos (sparsity)** y el **problema de cold-start**, donde no existe suficiente información para nuevos usuarios o ítems. En este contexto, los **sistemas de recomendación multimodales** han surgido como una alternativa prometedora. Estos sistemas integran múltiples fuentes de información, como texto, imágenes y datos estructurados, permitiendo capturar mejor las características de los ítems y mejorar la calidad de las recomendaciones. Este proyecto tiene como **objetivo analizar el impacto de la multimodalidad en sistemas de recomendación de películas**.

Representación de los Ítems

Como features de ítem se utilizan tres fuentes de información:

- Géneros codificados** en one-hot a partir de los metadatos de MovieLens.
- Embeddings semánticos de la sinopsis**, obtenidos procesando el campo overview de TMDb mediante el encoder de texto del modelo CLIP ViT-B/32 de OpenAI, que produce vectores de 512 dimensiones en un espacio semántico compartido.
- Embeddings visuales del póster**, extraídos procesando las imágenes descargadas de TMDb mediante el encoder de imagen del mismo modelo CLIP ViT-B/32, que produce vectores de 512 dimensiones en el mismo espacio vectorial. Ambas modalidades son proyectadas al espacio conjunto de CLIP y normalizadas en la esfera unitaria, lo que permite calcular similitud coseno directamente entre texto e imagen.

Modelos utilizados

- LightFM: pérdida “warp”, con learning rate de 0.05, 64 componentes latentes y 30 épocas.
- DeepFM: optimizador “adam”, función de pérdida “Binary Cross-Entropy”, métricas “Binary Cross-Entropy” y “AUC”, 40 épocas, 0.1 de validation split.

Estos modelos se entrenaron con los datos; **base** (solo lo de MovieLens), **base + sinopsis** (texto), **base + sinopsis** (texto) + **póster** (imagen).

- Modelos baseline: Random, MostPopular, FunkSVD

Resultados

Modelo (Baseline)	Recall@10	Precision@10	Diversidad	Novedad
Random	0,0023	0,0068	9,8877	9,2556
Most Popular	0,0489	0,0888	18,1664	5,8831
FunkSVD	0,0111	0,0240	7,8995	9,8448

Modelo	Recall@10	Precision@10	Diversidad	Novedad
LightFM base	0,0181	0,0457	22,5368	7,9390
LightFM base + sinopsis	0,0457	0,0907	23,2726	7,1626
LightFM base + sinopsis + póster	0,0408	0,0826	23,3423	7,4504
DeepFM base	0,6339	0,6792	20,2687	12,0164
DeepFM base + sinopsis	0,6346	0,6813	20,4636	12,3524
DeepFM base + sinopsis + póster	0,6343	0,6804	17,7876	12,3699

Diversidad (ILS): mide qué tan similares son entre sí los ítems dentro de una lista de recomendación, calculando el **promedio de similitud coseno** entre todos los pares posibles de ítems recomendados.

Novedad: mide qué tan novedosos son los ítems recomendados a nivel global, usando la fórmula $\log(1/\text{popularidad})$ promediada sobre la lista.

Análisis de resultados


- Los resultados muestran que **la información textual (sinopsis) es la fuente multimodal que más contribuye** a mejorar la calidad de las recomendaciones, especialmente en LightFM. La sinopsis proporciona una descripción detallada de la trama, los personajes, el género implícito y otros aspectos semánticos de la película que no están presentes únicamente en los géneros, permitiendo construir representaciones más discriminativas de los ítems.
- En cambio, la **incorporación del póster no produce una mejora adicional en la precisión**, incluso genera una ligera disminución tanto en LightFM como en DeepFM respecto al modelo que utiliza solo la sinopsis. Una posible explicación es que el contenido visual de los pósters suele aportar información redundante respecto al texto o elementos que no están directamente relacionados con las preferencias de los usuarios, como estilos gráficos, tipografías, logotipos o decisiones de marketing. Por ello, los embeddings visuales no siempre añaden información complementaria que ayude a distinguir mejor las películas.
- En DeepFM, la mejora de precisión al incorporar la sinopsis también es relativamente pequeña. Esto puede deberse a que el modelo ya posee una alta capacidad para aprender interacciones complejas entre las características de usuarios e ítems mediante su componente profundo. En consecuencia, la información adicional proporcionada por la sinopsis representa una ganancia marginal, ya que el modelo captura gran parte de las relaciones relevantes incluso utilizando únicamente las características base.
- Aunque el uso del póster no incrementa la precisión, en DeepFM sí contribuye a obtener recomendaciones más diversas y novedosas, reduciendo la similitud entre los ítems recomendados. Esto sugiere que la información visual no mejora significativamente la capacidad predictiva del modelo, pero sí enriquece la representación de las películas, favoreciendo la recomendación de títulos con características visuales distintas y disminuyendo el sesgo hacia contenidos muy similares o populares.

Data Sets


- MovieLens 1M:** conjunto de datos de recomendaciones que contiene calificaciones de usuarios sobre películas, utilizado como base para el entrenamiento y evaluación del sistema.
- The Movie Database (TMDb):** base de datos en línea de películas utilizada para enriquecer MovieLens con información multimodal, como sinopsis y pósters oficiales. (cobertura de 94,1% de MovieLens, 3654 de 3883 películas)

Sinopsis disponible: **94,1%**
(3654)

Póster disponible: **93,9%**
(3650)



Metodología



<https://claude.ai/share/826f801e-9409-4fa6-b27a-b564fbf7e13e>

Self-attention: mecanismo en el que cada elemento (token) de una secuencia calcula su representación considerando todos los demás elementos de la misma secuencia.

Cross-attention: mecanismo de atención en el que las Queries (Q) provienen de una secuencia diferente a aquella de donde se obtienen las Keys (K) y Values (V). Permite que una secuencia consulte información relevante de otra secuencia.

Cross-attention da fusión semántica inteligente cuando el texto es rico, pero img_emb da robustez visual cuando el texto falla. Promediarlos combina ambas ventajas.

Conclusión

Este trabajo evaluó el impacto de incorporar información multimodal en sistemas de recomendación de películas mediante embeddings de texto e imagen. Los resultados muestran que **la sinopsis constituye la fuente de información adicional más útil**, ya que mejora consistentemente la precisión y el recall respecto al uso exclusivo de los géneros. En cambio, los embeddings obtenidos a partir de **los pósters no producen mejoras en la precisión**, lo que sugiere que la información visual disponible no aporta suficiente contenido complementario para fortalecer la capacidad predictiva del recomendador.

Asimismo, se comprobó que **DeepFM supera ampliamente a LightFM en las métricas de precisión y recuperación**, evidenciando una mayor capacidad para modelar las preferencias de los usuarios. Aunque la incorporación de imágenes no incrementa la precisión en DeepFM, sí permite obtener recomendaciones más diversas y novedosas, lo que representa una ventaja desde la perspectiva de la experiencia del usuario.

Como trabajo futuro, sería interesante explorar otras técnicas de fusión multimodal (por ejemplo con MLP) o la incorporación de nuevas fuentes de información, como actores o directores, para aprovechar de mejor manera el potencial de la multimodalidad en sistemas de recomendación.

