

Camino de aprendizaje con recomendación Deep KT

Ignacio Alonso Sanhueza Pino

Departamento ciencias de la computación, Pontificia Universidad Católica de Chile

ignaciosanhueza233@uc.cl



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Introducción

El knowledge tracing modela el conocimiento de un estudiante a partir de su historial de respuestas, el modelo estima el nivel de dominio de los conocimientos y predice si acertará el próximo ejercicio en base a este. Los modelos deep KT utilizan redes neuronales que procesan toda la secuencia de un alumno y detecta patrones entre habilidades. En este trabajo se busca reproducir 3 modelos deep KT y construir una capa de recomendación de ejercicios sobre un alumno.

Problema

Se busca ver si es posible replicar los resultados de KT bajo protocolo honesto con pyKT, y con ello, dado que KT predice pero no decide el ejercicio, buscar una forma de convertir la predicción en una recomendación del próximo ejercicio.

Motivación

Mejoras reportadas en KT que no siempre se sostienen bajo evaluación honesta de múltiples conceptos por interacción, por lo que resulta necesario reproducir para verificar. El estado de conocimiento estimado permite personalizar la ruta de aprendizaje, dado que se busca recomendar el ejercicio en la **Zona de Desarrollo Próximo (ZDP)**, con tal de que el ejercicio no sea tan fácil que aburra, ni tan difícil que frustre.

Metodología

Datos: ASSISTments2009 (versión *corrected & collapsed*) [5], registro real de una plataforma de tutoría escolar. Cada interacción es (estudiante, ejercicio, concepto, acierto/fallo) ordenada en el tiempo.

Estudiantes	Interacciones	Preguntas	Conceptos
4.217	282.619	17.737	123

Modelos: Tres modelos Deep KT vía la librería **pyKT** [1]: **DKT** (LSTM)[2], **SAKT** (auto-atención)[3] y **AKT** (atención sensible al contexto) [4]. **Baselines:** *global mean* (tasa media de acierto, constante) y *question difficulty* (dificultad media por pregunta).

Evaluación honesta: Se reporta **AUC/ACC a nivel de pregunta**, con el protocolo honesto de pyKT. El nivel de pregunta emite **una predicción por pregunta**, fusionando sus conceptos, y evita la filtración por múltiples conceptos. Sobre el KT entrenado, una política de *Zona de Desarrollo Próximo*: entre los ejercicios candidatos $\mathcal{C}$, recomendar aquel cuya probabilidad de acierto predicha sea más cercana a 0.6

$$e^* = \arg \min_{e \in \mathcal{C}} \left| \hat{P}(\text{acierto} | e) - 0.6 \right|.$$


Se valida la política con un análisis de **calibración**: verificar que una $\hat{P} \approx 0.6$ corresponde a un $\sim 60\%$ de acierto real.

Resultados


Los tres Deep KT superan a los baselines. El orden **AKT > DKT > SAKT reproduce el benchmark** de pyKT bajo evaluación honesta.

Método	AUC	ACC	Método	AUC	ACC
AKT	0.787	0.741	Question difficulty	0.689	0.675
DKT	0.749	0.720	Global mean	0.500	0.638
SAKT	0.729	0.709			

La brecha entre la evaluación a nivel de concepto y de pregunta (DKT baja de 0.83 a 0.75 de AUC) cuantifica el *label leakage* que se remueve. Que los Deep KT superen al baseline de *question difficulty* (0.689) muestra que capturan la evolución temporal del alumno y no solo la dificultad del ítem; el *global mean*, con AUC 0.5 pero ACC 0.64, evidencia que el ACC engaña bajo clases desbalanceadas por lo que resulta necesario reportar el AUC



Comparación de AUC a nivel de pregunta



Distribución de la dificultad del ejercicio recomendado por política




Diagrama de fiabilidad de DKT

La ZDP (azul) concentra las recomendaciones en la banda óptima [0.5, 0.7] el *random* se dispersa y las políticas ingenuas caen en los extremos de frustración o aburrimiento.

Referencias

- [1] Z. Liu, Q. Liu, J. Chen, S. Huang, J. Tang, W. Luo. *pyKT: A Python Library to Benchmark Deep Learning based Knowledge Tracing Models*. NeurIPS Datasets & Benchmarks, 2022.
- [2] C. Piech, J. Bassen, J. Huang, S. Ganguli, M. Sahami, L. Guibas, J. Sohl-Dickstein. *Deep Knowledge Tracing*. NeurIPS, 2015.
- [3] S. Pandey, G. Karypis. *A Self-Attentive Model for Knowledge Tracing*. EDM, 2019.
- [4] A. Ghosh, N. Heffernan, A. S. Lan. *Context-Aware Attentive Knowledge Tracing*. KDD, 2020.
- [5] M. Feng, N. Heffernan, K. Koedinger. *Addressing the Assessment Challenge with an Online System that Tutors as it Assesses*. UMUAI, 2009.

Conclusiones

La reproducibilidad se sostiene, pero la evaluación importa. Bajo el protocolo honesto, el orden entre modelos se reproduce y los valores caen en el rango de pyKT: la librería es replicable en un entorno independiente. La caída respecto al nivel de concepto ($0.83 \rightarrow 0.75$ en DKT) confirma que el *label leakage* de las preguntas multi-concepto infla la evaluación ingenua, y que reportar bajo el protocolo honesto cambia la magnitud del estado del arte. Los modelos profundos aportan modelado del estudiante. Los tres Deep KT superan al baseline de *question difficulty* (0.689), que solo conoce la dificultad media de cada ejercicio. La diferencia indica que capturan la evolución temporal del conocimiento del alumno y no meramente la dificultad estática del ítem. El *global mean*, con AUC 0.5 pero ACC 0.64, evidencia que el ACC engaña bajo clases desbalanceadas y justifica reportar AUC como métrica principal. La capa de recomendación convierte la predicción en acción pedagógica, la política ZDP ubica al alumno en la banda de dificultad óptima de forma sistemática, mientras que un currículo aleatorio lo logra apenas el 42.7% de las veces. La calibración ($ECE = 0.012$) valida que esa dificultad objetivo es *real* ($\hat{P} \approx 0.61$ corresponde a un 61% de acierto observado). Los resultados corresponden a una única corrida en CPU, sin barras de error; correr los cinco *folds* daría intervalos de confianza. La recomendación opera a nivel de concepto (DKT), extenderla a nivel de pregunta (AKT) es una mejora directa. Además, el *targeting* se mide contra las predicciones del propio modelo mitigado en parte y no mide ganancia de aprendizaje real, lo que requeriría un estudio de usuarios.