Evaluación de LLMs Open-Source para Sistemas de Recomendación Conversacional

Martín Muñoz, Eduardo Soto y Randall Biermann

Pontificia Universidad Católica de Chile

Abstract

Impulsados por la creciente adopción de modelos de lenguaje abiertos en tareas de recomendación, este trabajo evalúa la capacidad de varios LLMs *open-source* (entre 1B y 4B parámetros) para generar recomendaciones de películas en contexto conversacional usando el dataset ReDial. Planteamos un pipeline experimental que compara *baselines* simples con arquitecturas modernas bajo un protocolo de *zero-shot prompting*, y medimos precisión, recuperación, ordenamiento y latencia para analizar el compromiso entre calidad y eficiencia. Los resultados muestran que los modelos más recientes capturan mejor las señales implícitas del diálogo y producen recomendaciones más relevantes, aunque el tamaño por sí solo no garantiza mejoras: ciertos modelos medianos optimizados para diálogo alcanzan el mejor equilibrio entre rendimiento y tiempo de respuesta. Estas observaciones sugieren que avances en diseño y entrenamiento son clave para la recomendación conversacional; como trabajo futuro se propuso explorar ajuste fino, el estudio sistemático de hiperparámetros y evaluaciones humanas para validar la utilidad práctica de las recomendaciones.

1. Revisión del estado del arte

Impulsados por los últimos avances significativos modernos en la arquitectura de los Modelos de Lenguaje (LLMs) open-source y su creciente adopción y relevancia en la recomendación conversacional, se ha desarrollado un pipeline que comprende una fase de evaluación y experimentación. De manera inicial, se decidió establecer una prueba de concepto utilizando modelos baseline (random y most popular).

Posteriormente, se decidió aumentar la complejidad de las pruebas incorporando arquitecturas modernas más atingentes al caso de estudio, tales como Gemma-3-1b-it, Gemma-3-4b-it, Qwen3-4B-Instruct-2507 y Qwen2.5-1.5B-Instruct.

La metodología se ha consolidado y evaluado mediante el cálculo y la determinación de métricas clásicas de la literatura en sistemas recomendadores (Recall@10, Precision@10, nDCG@10, HitRate@10, MRR y latencia). Lo que ha permitido poder establecer una base metodológica robusta para realizar un análisis comparativo.

Estos avances son cruciales para poder evidenciar las debilidades de cada uno de los modelos, entender ciertos patrones y diferencias en cómo puede afectar las distintas arquitecturas en la recomendación, comportamiento, debilidades y fortalezas frente a las exigencias del dataset ReDial.

2. Dataset

Para los experimentos se utilizó el dataset ReDial, un set de conversaciones sobre recomendaciones de películas entre usuarios y un agente recomendador. Los diálogos contienen menciones explícitas a películas, preferencias del usuario y retroalimentación implícita, convirtiéndolo en un punto de referencia adecuado para recomendación conversacional.

ReDial se divide en los conjuntos de *train* (8004 conversaciones), *validation* (2002) y *test* (1342), siguiendo la partición original descrita en [2]. Las conversaciones tienen en promedio 18 turnos (desviación estándar ≈ 5), lo que exige a los modelos manejar interacciones extensas y con cambios de contexto.

Cada diálogo menciona en promedio 5.3 películas, con distribuciones sesgadas hacia pocas menciones (3–7 en la mayoría de los casos). Así, los modelos deben inferir preferencias a partir de señales implícitas y un contexto acotado. En general, todas estas características hacen que ReDial sea un reto para los modelos de lenguaje pequeños y medianos, porque necesitan entender bien la conversación y captar las preferencias del usuario incluso cuando no se mencionan de forma directa.

Tabla 1: Estadísticas principales del dataset ReDial

Set/Métrica	Total conversaciones	Promedio de turnos	Desviación estándar
Training	8004	18.21	5.38
Test	2002	18.19	5.04
Validation	1342	17.85	4.98

Figura 1: Distribución de número de turnos en conjunto de entrenamiento

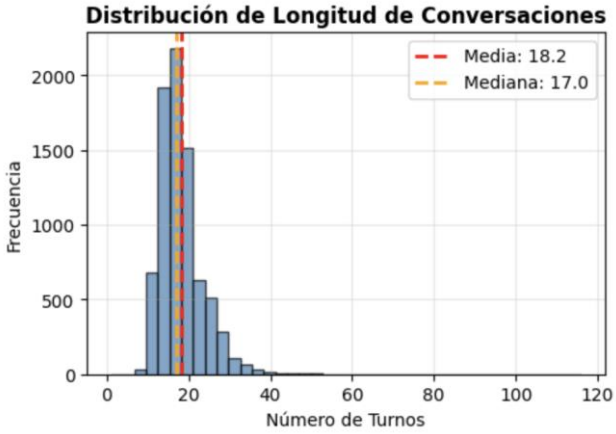

Figura 2: Distribución de número de turnos en conjunto de validación

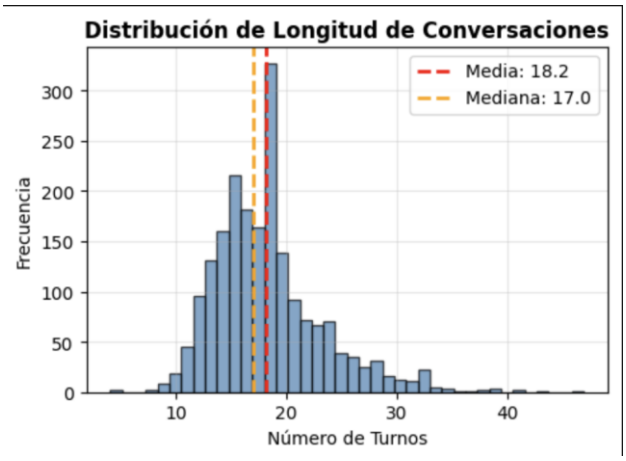

Figura 3: Distribución de número de turnos en conjunto de prueba

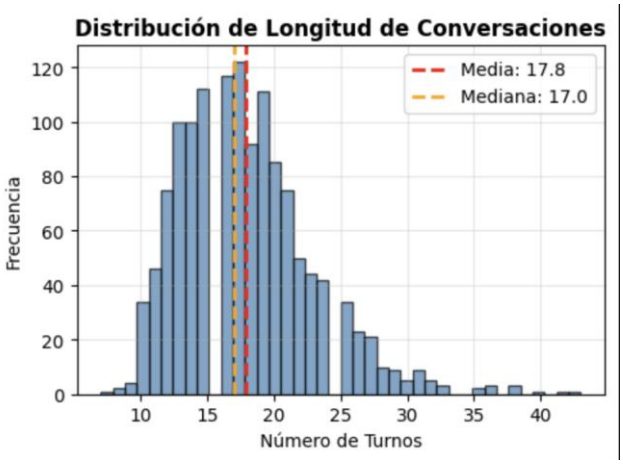

3. Metodología utilizada

Se evaluaron distintos LLMs open-source entre 1B y 4B parámetros para comparar su capacidad de interpretar diálogo y generar recomendaciones coherentes. La selección incluye modelos recientes y eficientes que representan diferentes enfoques arquitectónicos dentro del panorama actual.

Se comenzó evaluando un modelo que actuara como *baseline* para poder comparar con las evaluaciones de modelos más modernos y con diferentes cantidades de parámetros. En particular, se evaluó el modelo de Gemma-2-2b-it mediante *zero-shot prompting* sobre 52 *samples* del dataset, un número seleccionado como conjunto representativo que permite obtener una estimación del desempeño manteniendo un bajo costo computacional, obteniendo un desempeño de baja precisión (*Precision*@10 = 0.0038 ± 0.0192) y bajo *recall* (*Recall*@10 = 0.0288 ± 0.1523), con una latencia promedio de 9.05 ± 1.85 s (Tabla 2). Este modelo resulta adecuado como *baseline* porque representa un punto de partida simple, reproducible y sin ajustes específicos.

Luego de la evaluación del *baseline*, se evaluaron diferentes modelos más complejos manteniendo configuraciones constantes tanto de parámetros (*Context Ratio* de 0.7 y temperatura de 0.7) como de entorno (GPU Quadro RTX5000). Además, a cada modelo se le solicitó generar una lista de la siguiente forma:

"1. Película 1

2. Película 2 ... "

y así sucesivamente (Ver Anexo 1), para poder calcular métricas tales como *Precision*10 y *Recall*@10.

Los otros modelos evaluados, a parte del *baseline* fueron:

- **Gemma (Google):** Modelos diseñados para eficiencia y razonamiento ligero, útiles como referencia base y para analizar mejoras incrementales:
    - Gemma-3-1b-it: versión más reciente con mejor comprensión contextual.
    - Gemma-3-4b-it: mayor capacidad semántica dentro de la familia evaluada.
- **Qwen (Alibaba Cloud):** Modelos optimizados para tareas de diálogo, con énfasis en instrucciones y consistencia conversacional:
    - Qwen3-4B-Instruct-2507: orientado a instrucciones y conversación general.
    - Qwen2.5-1.5B-Instruct: alternativa más ligera, eficiente y estable.

Esta diversidad de modelos permite examinar cómo el tamaño, entrenamiento y arquitectura influyen en la habilidad para capturar preferencias implícitas, mantener coherencia a través del diálogo y producir recomendaciones relevantes.

Después de las evaluaciones, cada modelo recibió la conversación completa y generó 10 recomendaciones numeradas en un formato fijo, permitiendo comparar su comportamiento sin *fine-tuning*. Finalmente, se extrajeron

los títulos recomendadores y se compararon con las películas relevantes, y se calcularon las métricas mencionadas anteriormente.

Tabla 2: Métricas obtenidas para el modelo Gemma-2-2b-it para 52 muestras del dataset de ReDial (*baseline*)

***Recall*@10**	***Precision*@10**	**nDCG@10**	***HitRate*@10**	**MRR**	***Latency* (s)**
0.0288 ± 0.1523	0.0038 ± 0.0192	0.0135 ± 0.0737	0.0385 ± 0.1923	0.0092 ± 0.0495	9.0502 ± 1.8466

Anexo 1: Prompt zero-shot para generar recomendaciones en lista

You are a movie recommendation expert. Given the following conversation between a user seeking movie recommendations and a recommender, suggest 10 movies that the user would enjoy based on their preferences. Conversation: {context} Provide exactly 10 movie recommendations as a numbered list. Output ONLY the movie titles with their release year in parentheses, one per line, nothing else. Recommendations: 1.

4. Análisis de parámetros

El análisis de parámetros se enfocó, más que nada, en ver cómo afectaba el tamaño del modelo y la eficiencia computacional, aunque se trató de mantener controles bastante estrictos durante la inferencia. Para que la comparación fuera más pareja, se dejaron la Temperatura y el Context Ratio en 0.7, ya que estos valores, según lo que ya se sabía, suelen equilibrar bien la diversidad y la estabilidad en tareas de recomendación conversacional.
Al revisar modelos entre 1B y 4B de parámetros, se notó un trade-off bastante directo entre complejidad y eficiencia: cuando suben los parámetros, normalmente también sube la latencia. Por ejemplo, el modelo Gemma-3-4b-it mostró una latencia de 16.89 s, lo cual es un aumento notable comparado con el baseline Gemma-2-2b-it (9.05 s).
Aun así, el modelo que mejor rendimiento tuvo, Qwen2.5-1.5B-Instruct, consiguió mantener un tiempo de respuesta muy competitivo (9.11 s), incluso con métricas superiores. Esto deja ver que encontró, de algún modo, un equilibrio bastante óptimo entre calidad y eficiencia computacional.

5. Resultados obtenidos

5.1. Análisis preliminar

Se tiene que, al analizar los resultados obtenidos en la experimentación, se observa una tendencia ascendente en todas las métricas de rendimiento (*Recall*@10, *Precision*@10, nDCG@10, *HitRate*@10 y MRR) conforme se tiende a incrementar la complejidad y tamaño del modelo utilizado.

Por un lado, se tiene que el modelo Gemma-2, el cual actúa como *baseline*, muestra resultados deficientes en todas las métricas, lo cual confirma su rol como baseline de comparación dado que es de los modelos más simples.

Por otro lado, los modelos Gemma-3-1b-it y Gemma-3-4b-it, evidencian mejoras bastantes significativas, en especial en métricas como *Recall*@10 y *HitRate*@10, las cuales sugieren que existe una mejor capacidad en la recuperación de ítems relevantes. Además, se tiene que los modelos Qwen3-4B-Instruct-2507 y Qwen2.5-1.5B-Instruct, obtienen los mejores resultados con los valores más altos en métricas, alcanzando valores en *Recall*@10 = 0.1971 y *Precision*@10 = 0.0269, por lo que reflejan un salto bastante notable con respecto al baseline.

Esto indica que existe una clara tendencia de que, si se incrementa la complejidad de los modelos y se aumenta la cantidad de parámetros, en general tenderán a capturar mejores relaciones contextuales en el dataset de ReDial.

Finalmente, se puede ver que las métricas de relevancia y ordenamiento también siguen la misma tendencia. Por ejemplo, los modelos de Qwen tienden a obtener resultados en nDCG@10 y MRR@10 hasta 10 veces más altos que el *baseline*, lo que sugiere que los modelos más recientes priorizan de una manera más eficiente los ítems relevantes en las primeras posiciones de la recomendación, lo que se esperaría que resulte en una mejor experiencia para el usuario. Aunque siempre con un *trade-off* dado que se observa un incremento ligero en la latencia promedio en los modelos más complejos, en particular, Gemma-3-4b-it tiene una latencia de 16.89 s, a diferencia del baseline que es de 9.05 s, lo tiene que tomarse en cuenta.

5.2. Problemas identificados durante el proceso

Se tiene que los principales problemas identificados durante el proceso del desarrollo del proyecto se relacionan en general con el tiempo de ejecución y evaluación de los distintos modelos. Es probable que esto se deba a la arquitectura basada en Transformers, las cuales utilizan una gran cantidad de parámetros, por lo que el proceso podría resultar demandante en términos de ejecución.

Por esto, la ejecución, en general, utilizando un modelo de GPU Quadro RTX5000, ha tomado para cada modelo sobre las 52 muestras del dataset alrededor de 10 a 15 minutos, con ciertas variaciones dependiendo de la complejidad del modelo.

Además de este problema, se detectaron otros que también son de suma relevancia como la variabilidad de la latencia, lo cual mostró ciertas diferencias entre modelos, lo cual podría indicar que, si no se hace un incremento equivalente de hardware al aumentar la complejidad de modelos, podría afectar en su escalabilidad en el largo plazo.

Por último, se identificó un problema potencial de compatibilidad entre entornos y dependencias dado que, en ciertos casos, en la lectura de *papers*, era común identificar modelos que se veían muy funcionales. Sin embargo, en algunos casos requerían compatibilidad con librerías ya deprecadas o metodologías que ya no estaban tan vigentes, por lo que se tuvo que ir más allá e investigar en mayor profundidad para poder encontrar modelos funcionales, aunque como es una tecnología en constante actualización y evolución, si los autores de los modelos no se van actualizando, existe el riesgo en el futuro de que los resultados actuales mencionados en esta investigación no sean replicables, por lo que habrá que investigar medidas para mitigar este riesgo.

Tabla 3: Resultados consolidados para 52 muestras del set de prueba para ReDial

Modelo	Rec@10	Prec@10	nDCG@10	HR@10	MRR	Lat (s)
G-2-2b (Base)	0.288	0.0038	0.0135	0.0385	0.0092	9.05
G-3-1b	0.1394	0.0192	0.0982	0.1923	0.0920	12.29
G-3-4b	0.1154	0.0135	0.0575	0.1346	0.0434	16.89

Q-4B	0.1587	0.0231	0.1094	0.2115	0.1085	14.06
Q-1.5B	0.1971	0.0269	0.1345	0.2500	0.1150	9.11

Figura 4: Comparación de *Recall*@10 entre modelos probados

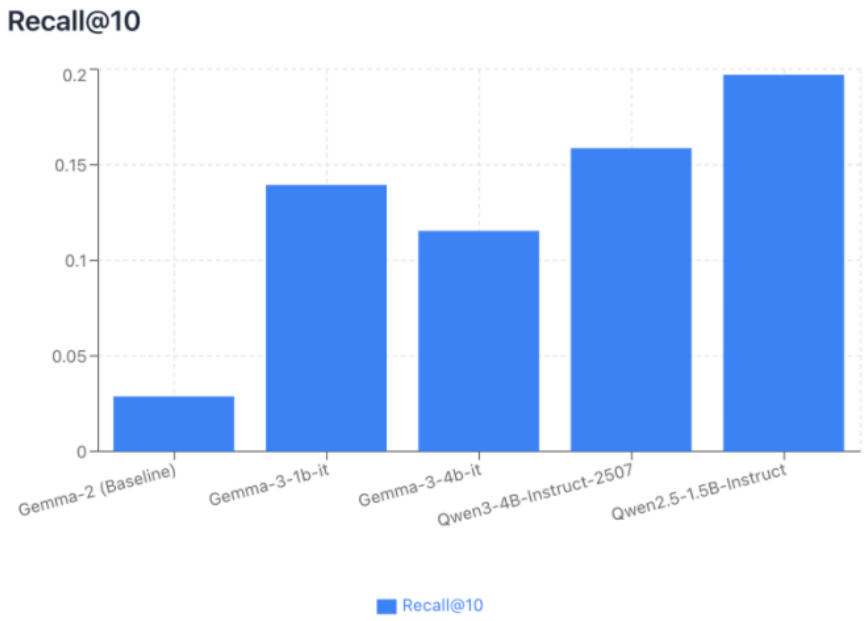

Figura 5: Comparación de *HitRate*@10 entre los modelos

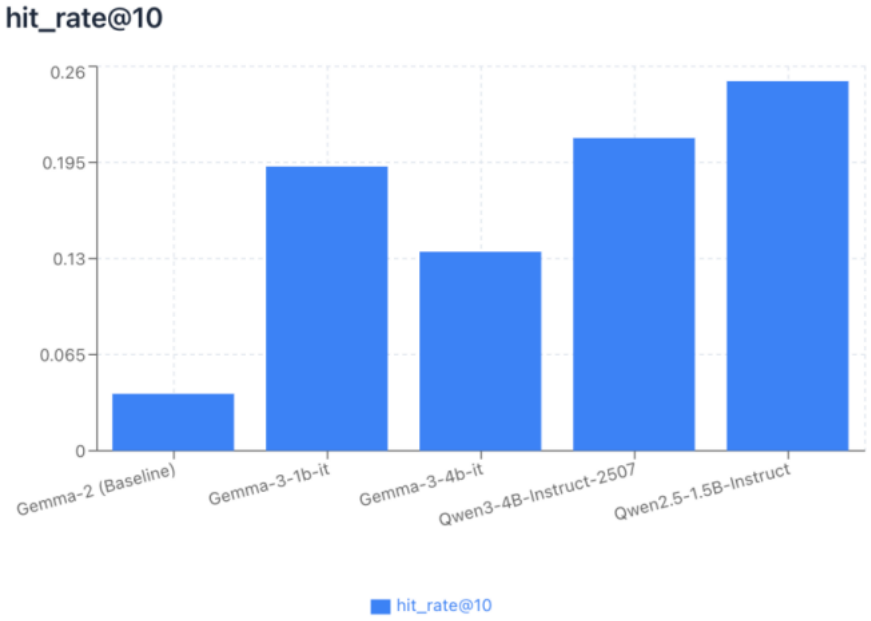

6. Conclusiones

Los resultados muestran una tendencia clara, aunque no necesariamente la que suele asumirse: incrementar el número de parámetros dentro de una misma arquitectura no implicó una mejora en el rendimiento. De hecho, en todos los modelos evaluados se observó un empeoramiento consistente en todas las métricas al aumentar los parámetros. Esto sugiere que, para escenarios de recomendación conversacional y bajo esquemas zero-shot prompting, los modelos más grandes pueden volverse más

inestables o propensos a desviarse del objetivo cuando se usan las mismas configuraciones de hiperparámetros, como la temperatura o el *context ratio*. En otras palabras, la complejidad adicional no garantiza un mejor comportamiento si no se ajustan cuidadosamente estas condiciones.

El *baseline* Gemma-2-2b-it obtuvo el rendimiento más bajo, lo que reafirma su rol como punto de partida. Sin embargo, los modelos de la serie Gemma-3 no mostraron la mejora esperada con el aumento de parámetros, al contrario, su desempeño disminuyó pese a su mayor capacidad teórica, lo que refuerza la idea de que, en tareas sensibles al control del comportamiento generativo, la arquitectura por sí sola no basta.

Los modelos Qwen fueron los que mostraron la calidad más alta de forma general, pero incluso dentro de esta familia se mantuvo la misma tendencia: el modelo más pequeño, Qwen2.5-1.5B-Instruct, superó al más grande en todas las métricas, lo que destaca la importancia de configuraciones óptimas antes que del tamaño del modelo. Su rendimiento superior, sumado a una baja latencia, sugiere que los avances recientes en entrenamiento y diseño pueden ser más determinantes que el simple aumento de parámetros.

Para ir cerrando, los hallazgos indican que la relación entre tamaño del modelo y rendimiento no es lineal ni garantizada. En contextos conversacionales complejos, especialmente bajo zero-shot prompting, los modelos más grandes pueden divergir más fácilmente ante una misma temperatura o *context ratio*, afectando negativamente su precisión y consistencia. Es por esto por lo que se debe ajustar cuidadosamente los hiperparámetros y estrategias de prompting para aprovechar realmente la capacidad de modelos más complejos, y refuerza el potencial de LLMs open-source optimizados para eficiencia y razonamiento contextual más que para escala bruta.

7. Referencias

[1] Wu, L., Zheng, Z., Qiu, Z., Wang, H., Gu, H., Shen, T., Qin, C., Zhu, C., Zhu, H., Liu, Q., Xiong, H., & Chen, E. (2024) *A survey on large language models for recommendation.*

[2] Li, R., Ebrahimi Kahou, S., Schulz, H., Michalski, V., Charlin, L., & Pal, C. (2019) *Towards deep conversational recommendations.*

[3] Lichtenberg, J. M., Buchholz, A., & Schwöbel, P. (2024) *Large language models as recommender systems: A study of popularity bias. Amazon Science.*

[4] Zhao, Z., Fan, W., Li, J., Liu, Y., Mei, X., Wang, Y., Wen, Z., Wang, F., Zhao, X., Tang, J., & Li, Q. (2023) *Recommender systems in the era of large language models (LLMs).*