Impacto del Dwell Time en recomendación secuencial

Tomas Goas [1] **Leopoldo Farr** [1]

Abstract

Este estudio investiga el impacto de incorporar el tiempo de permanencia (dwell time) en el desempeño de modelos de recomendación secuencial. Aunque el dwell time es reconocido como un indicador relevante de interés del usuario, su integración sistemática en arquitecturas modernas ha sido poco explorada. Evaluamos cinco modelos representativos: GRU4Rec, BERT4Rec, SASRec, NARM y NextItNet, utilizando datasets reales de e-commerce. Nuestros resultados demuestran que la incorporación de dwell time mejora consistentemente el desempeño en todos los modelos evaluados, aunque la magnitud del beneficio varía según la arquitectura. NARM mostró las mejoras más significativas, seguido por GRU4Rec y SASRec con ganancias sustanciales. Concluimos que el dwell time es una señal valiosa para modelos secuenciales, pero su implementación requiere consideraciones arquitectónicas específicas, abriendo un camino para diseños híbridos que integren explícitamente señales temporales en mecanismos de atención causal.

1. Estado del arte

En el ámbito de los sistemas de recomendación secuencial, la literatura ha establecido que el orden de las interacciones es crucial, pero a menudo se ignoran señales temporales explícitas como el tiempo de permanencia o dwell time. Investigaciones previas han intentado mitigar esta limitación; específicamente, Hidasi et al. (2017) demostraron la utilidad de incorporar información de la sesión en modelos basados en Redes Neuronales Recurrentes (RNN), indicando que el dwell time puede actuar como un indicador efectivo de la preferencia del usuario en arquitecturas tipo GRU. Sin embargo, existe una brecha significativa en la literatura respecto a la transferibilidad de estos hallazgos a las arquitecturas del estado del arte basadas en mecanismos de atención (Self-Attention). Mientras que el beneficio es claro en modelos recurrentes, el impacto de señales temporales explícitas en modelos modernos unidireccionales como SASRec o bidireccionales como BERT4Rec ha sido escasamente explorado. Esta investigación busca cerrar dicha brecha, evaluando si los beneficios observados por Hidasi et al. en modelos GRU se mantienen o se amplifican al aplicar dwell time en arquitecturas basadas en Transformers, o si, por el contrario, la naturaleza de estos modelos requiere estrategias de integración distintas.

1.1. Modelos basados en GRU con dwell time

Sumado a lo dicho anteriormente, a continuación se incluyen los resultados de una investigación de la Universidad de Haifa, Israel, en la que los autores precisamente logran cuantificar como la incoporación de dwell time mediante item boosting en GRU4Rec mejoró consistentemente las recomendaciones en el dataset "RecSys'2015 challenge" .

Método	Recall@20	MRR@20
GRU4Rec	0.5853	0.2305
GRU4Rec con dwell	0.7885	0.5834

Table 1. Resultados comparando el rendimiento de GRU4Rec con y sin incorporación de *dwell time*, adaptado de (8).

Estos resultados señalan que el dwell time es una señal de información no solo poco aprovechada, sino que también muy poderosa, lo que motiva aún mas nuestra investigación.

2. Solución al problema trabajado

El problema central abordado en este estudio consiste en evaluar si la incorporación del *dwell time* (señal temporal que refleja la intensidad con la que un usuario interactúa con un ítem) mejora efectivamente el rendimiento de distintos modelos de recomendación secuencial. Aunque existe evidencia de que señales temporales pueden beneficiar a arquitecturas recurrentes, no está claro si este efecto se mantiene en modelos basados en *Self-Attention*, convoluciones dilatadas o mecanismos híbridos. Por ello, la

[*]Equal contribution [1]Departamento de Ciencia de la Computación, Pontificia Universidad Católica de Chile, Santiago, Chile[*]

[*]Contribución equivalente. Correspondence to: Tomás Goas <tgoas@uc.cl>, Leopoldo Farr <lfarr@uc.cl>.

solución propuesta consiste en construir un marco experimental que permita medir de forma controlada y comparable el impacto real del *dwell time* sobre múltiples arquitecturas.

La solución diseñada se compone de tres elementos principales:

1. **Estandarización de la señal temporal mediante expansión secuencial.** Para evitar depender de mecanismos específicos de cada arquitectura, el *dwell time* se transformó en repeticiones explícitas del ítem dentro de la secuencia. Esta expansión permite que cualquier modelo independientemente de su estructura interna pueda interpretar la importancia relativa de cada interacción a través de la frecuencia de aparición, sin agregar nuevas variables ni modificar su diseño original.
2. **Marco comparativo transversal a múltiples modelos.** Se evaluaron cinco arquitecturas representativas del estado del arte: GRU4Rec, NARM, SASRec, BERT4Rec y NextItNet. Esta selección permite determinar si el efecto del *dwell time* es consistente entre familias de modelos o si su impacto depende de la forma en que cada arquitectura procesa dependencias temporales.
3. **Cuantificación del costo computacional asociado.** Dado que la expansión de secuencias incrementa la longitud de las mismas, se analizó también el costo adicional en tiempo de entrenamiento y uso de memoria. Este componente permite balancear la ganancia en precisión predictiva con el aumento en complejidad computacional, proporcionando una visión completa del costo-beneficio del método.

3. Dataset

Los datos utilizados provienen de un entorno de comercio electrónico y fueron recolectados por el proyecto **Open CDP de Rees46 Technologies**. La fuente corresponde a una **tienda multicategoría ("Department Store")**, y se trabajó con **dos datasets independientes que cubren los meses de octubre y noviembre de 2019**. El volumen de información incluye **millones de interacciones**, clasificadas en eventos de vista, añadido al carrito y compra. Durante el preprocesamiento, se **filtraron las sesiones excesivamente largas** para evitar los altos costos computacionales asociados con la **expansión de ítems por repetición**, necesaria para incorporar señales como el dwell time.

3.1. Análisis del Dataset

El estudio se realizó utilizando datos de comportamiento de usuarios provenientes de una tienda en línea multicategoría, recopilados por el proyecto Open CDP. El dataset contiene exclusivamente eventos asociados a la interacción de usuarios con productos, tales como vistas, añadidos al carrito y compras. Cada fila corresponde a un único evento e incluye información del usuario, del producto y del tipo de interacción. Se dispuso de dos archivos independientes correspondientes a los meses de octubre y noviembre de 2019, lo que permitió contar con dos períodos de actividad distintos para los experimentos.

El volumen de datos es considerable: el archivo de noviembre contiene un total de 67,501,979 registros, mientras que el de octubre reúne 42,448,764 eventos. En ambos casos, estas cifras reflejan la magnitud del comportamiento agregado de los usuarios de una plataforma de comercio electrónico de gran escala.

En cuanto a la distribución por categoría de producto, el dataset presenta un total de 126 categorías únicas identificadas a través de la columna `category_code`. El análisis de frecuencia revela una clara concentración en un subconjunto de categorías, destacando particularmente el dominio de los productos electrónicos. Entre las categorías más populares se encuentran *electronics.smartphone* (7,583,714 eventos), *computers.notebook* (1,002,462), *electronics.video.tv* (985,645), *electronics.clocks* (885,071) y *apparel.shoes* (808,661). Esta predominancia de categorías tecnológicas sugiere un comportamiento de navegación y compra fuertemente orientado hacia productos de alta demanda y rotación, especialmente teléfonos inteligentes, que superan ampliamente al resto en volumen de interacción.

El resto de las categorías más frecuentes incluye productos de audio, electrodomésticos de cocina y hogar, computadores de escritorio, muebles para living y dormitorio, y accesorios automotrices. Aunque estas categorías también presentan una cantidad significativa de interacciones, su volumen es notablemente menor en comparación con la categoría de teléfonos inteligentes, lo que evidencia una distribución fuertemente sesgada.

En conjunto, estas características muestran que el dataset posee tanto gran escala como heterogeneidad en los tipos de productos, lo que lo convierte en un entorno adecuado para evaluar modelos de recomendación secuencial bajo escenarios realistas y con patrones de comportamiento complejos.

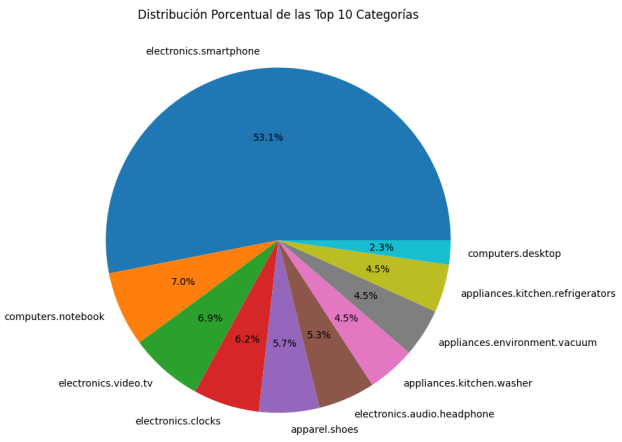

Figure 1. Distribución porcentual categorías

4. Metodología

La estrategia experimental se diseñó para aislar y cuantificar el impacto de la señal temporal explícita en la calidad de las recomendaciones, comparando sistemáticamente el desempeño de diversas arquitecturas bajo dos condiciones: con y sin la incorporación del *dwell time*.

4.1. Especificaciones técnicas de la máquina local

Todos los experimentos fueron ejecutados en un entorno local con recursos de cómputo limitados, lo cual condicionó directamente las decisiones de preprocesamiento, el tamaño manejable de los datasets y la duración de los entrenamientos. A continuación, se describen las especificaciones técnicas de la máquina utilizada:

- **CPU:** AMD Ryzen 7 5800X, con 8 núcleos y 16 hilos, frecuencia base de 3.8 GHz y frecuencia turbo máxima de hasta 4.7 GHz. Este procesador permitió realizar operaciones intensivas de lectura, filtrado y agrupamiento sobre decenas de millones de registros, las cuales constituyen la parte más demandante del preprocesamiento secuencial.
- **Memoria RAM:** 16 GB DDR4 a 3600 MT/s. La capacidad de memoria representó una limitación importante, ya que la expansión de secuencias basada en *dwell time* incrementa significativamente el tamaño en memoria de las sesiones. Esta restricción influyó en el filtrado de sesiones largas y en la necesidad de muestrear el dataset de noviembre para evitar fallos del kernel durante el procesamiento.
- **GPU:** NVIDIA RTX 3080 con soporte CUDA. Esta tarjeta gráfica permitió acelerar de forma considerable el entrenamiento de los modelos basados en redes profundas, especialmente aquellos con mecanismos de atención o arquitecturas convolucionales como SASRec, BERT4Rec y NextItNet.
- **Entorno de ejecución:** entorno Conda configurado con soporte para CUDA. Todos los modelos fueron entrenados en este entorno, utilizando PyTorch con aceleración por GPU.

4.2. Dataset y Preprocesamiento

Los experimentos se llevaron a cabo utilizando datos de comportamiento de usuarios en comercio electrónico, recolectados por el proyecto Open CDP de Rees46 Technologies. Los datos provienen de una tienda multicategoría e incluyen registros de eventos asociados a productos (vistas, carrito y compra).

Para este estudio, se utilizaron dos conjuntos de datos separados correspondientes a los meses de octubre y noviembre de 2019. El volumen de datos incluye millones de interacciones por mes. Durante la etapa de preprocesamiento, y debido a las limitaciones computacionales inherentes a la expansión de secuencias descrita a continuación, se aplicó un filtrado para excluir aquellas sesiones excesivamente largas que pudieran comprometer la viabilidad del entrenamiento.

Reducción inicial del dataset

Con el fin de optimizar el uso de memoria y permitir el procesamiento de archivos de gran tamaño, el dataset original fue reducido a un subconjunto mínimo de columnas necesarias para la construcción de secuencias. Se conservaron únicamente las variables `event_time`, `user_id`, `product_id` y `user_session`, ya que contienen toda la información temporal y estructural requerida para los modelos secuenciales. Esta reducción permitió descartar metadatos y atributos no esenciales que incrementaban significativamente el tamaño del dataset.

Filtrado de sesiones y manejo de limitaciones de memoria

Una vez generados los archivos reducidos, se procedió a reconstruir las sesiones de usuario. Durante este proceso se observaron sesiones excepcionalmente largas que podían provocar un crecimiento excesivo en la longitud de las secuences, generando problemas de rendimiento y consumo de memoria. Por ello, se aplicó un filtrado que excluyó aquellas sesiones que presentaran una cantidad anómala de interacciones, manteniendo un conjunto más estable y representativo para los experimentos. Adicionalmente, se estableció un rango mínimo y máximo de eventos por sesión, conservándose únicamente aquellas con entre 5 y 50 interacciones, con el fin de evitar secuencias demasiado cortas o excesivamente extensas que pudieran introducir ruido o

afectar el desempeño de los modelos.

El archivo reducido del mes de octubre pudo ser procesado en su totalidad dentro de los 16 GB de memoria RAM disponibles, obteniéndose un total de 5,974,844 sesiones. En contraste, el dataset de noviembre resultó ser considerablemente más grande, alcanzando 11,719,988 sesiones después de la reducción inicial. Este volumen excedía la capacidad del entorno de ejecución, lo que provocaba fallos del kernel por falta de RAM. Para mantener la comparabilidad entre ambos meses y garantizar la viabilidad computacional del procesamiento, se aplicó un muestreo aleatorio del cincuenta por ciento del dataset de noviembre, reduciendo el total a 5,859,994 sesiones, un valor similar al de octubre.

La operación de muestreo se realizó con la siguiente línea de código:

```
df_small = df.sample(frac=0.5,
                     random_state=42)
```

Reproducibilidad

Con el propósito de asegurar consistencia en todos los experimentos, tanto el muestreo como los procedimientos de preprocesamiento y entrenamiento se ejecutaron utilizando una semilla aleatoria fija. Para todas las etapas del estudio se estableció `SEED = 42`. Ademas se siguió en mismo pipeline en todos los modelos, garantizando así la reproducibilidad completa de los resultados.

4.3. Estrategia de Incorporación del Dwell Time

Para integrar el tiempo de permanencia en modelos que tradicionalmente solo procesan el orden secuencial de los IDs de los ítems, se implementó una estrategia de representación de datos basada en la frecuencia de interacción.

La metodología consiste en repetir cada ítem dentro de la sesión una cantidad de veces proporcional al tiempo que el usuario permaneció interactuando con él. Esta transformación tiene tres implicancias directas en el modelado:

- **Explicitación de la señal:** Transforma la intensidad de la interacción (tiempo) en una frecuencia secuencial, permitiendo que el modelo capture la relevancia relativa de cada ítem.
- **Expansión de secuencias:** Las sesiones aumentan su longitud total, proporcionando un contexto más rico pero más extenso.
- **Costo computacional:** Se incrementa el consumo de memoria y el tiempo de entrenamiento, requiriendo mayor capacidad de cómputo.

Aunque es una representación sencilla, permite comparar de forma directa y controlada el desempeño de cada arquitectura en su versión estándar versus su versión enriquecida bajo un mismo esquema de construcción de datos.

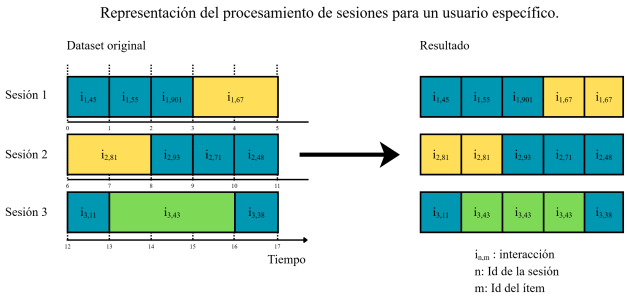

Figure 2. Diagrama de procesamiento de sesiones para incluir Dwell Time

4.4. Arquitecturas Evaluadas

Se seleccionaron cuatro modelos representativos del estado del arte para cubrir diferentes paradigmas de procesamiento secuencial:

1. **GRU4Rec:** Modelo basado en redes neuronales recurrentes (GRU). Captura dependencias de corto plazo mediante un estado oculto que evoluciona paso a paso con la sesión. (1)
2. **NARM:** Arquitectura híbrida que combina GRU con un mecanismo de atención global. Diseñado para resaltar los ítems más relevantes de la sesión, su estructura permite capturar eficazmente patrones de intención del usuario, siendo teóricamente idóneo para detectar las repeticiones generadas por el *dwell time*. (2)
3. **SASRec:** Modelo basado en *Self-Attention* unidireccional. Utiliza mecanismos similares a los Transformers para capturar dependencias de largo plazo, pero restringiendo la atención al pasado (causalidad), similar a la lógica secuencial de las RNN. (3)
4. **BERT4Rec:** Modelo Transformer bidireccional que utiliza el objetivo de entrenamiento *Masked Item Prediction* (Cloze task). A diferencia de SASRec, aprende representaciones utilizando el contexto de toda la secuencia (pasado y futuro). (4)
5. **NextItNet:** Modelo convolucional profundo basado en convoluciones dilatadas y bloques residuales. A diferencia de las RNN y Transformers, modela dependencias a largo plazo expandiendo el campo receptivo a través de dilataciones sucesivas, permitiendo capturar patrones de alto nivel sin recurrencia ni mecanismos de atención. Su estructura completamente convolucional lo convierte en un buen punto de comparación para

evaluar el impacto del *dwell time* en arquitecturas no recurrentes ni autoatencionales. (5)

5. Análisis de costo computacional

La incorporación del *dwell time* mediante la repetición explícita de ítems produjo un aumento significativo en el largo promedio de las sesiones. Este incremento afectó directamente el costo computacional de todas las arquitecturas, aunque con distinta magnitud según su mecanismo de procesamiento secuencial. Las Tablas de tiempos muestran un patrón claro y sistemático.

Impacto por familia de modelos

Transformers auto-regresivos (SASRec). SASRec fue una de las arquitecturas más afectadas por el alargamiento de las secuencias. Debido a su mecanismo de autoatención causal, cuya complejidad es cuadrática en la longitud de la sesión, los tiempos de entrenamiento aumentaron entre **+40% (octubre)** y **+128% (noviembre)**. Esta sensibilidad es esperable, ya que incluso duplicar la longitud efectiva de la secuencia puede cuadruplicar la carga computacional del modelo.

Transformers bidireccionales (BERT4Rec). El costo computacional también creció fuertemente en BERT4Rec, con incrementos de **+42.6% en octubre** y hasta **+122.7% en noviembre**. A diferencia de SASRec, BERT4Rec utiliza atención bidireccional sobre toda la secuencia, lo que intensifica aún más la dependencia cuadrática respecto del largo de entrada. Por esta razón, se posiciona entre los modelos más penalizados cuando el *dwell time* expande la duración de las sesiones.

Modelos recurrentes (GRU4Rec y NARM). Al operar de manera estrictamente secuencial, las RNN procesan cada repetición adicional sin posibilidad de paralelismo. GRU4Rec exhibió aumentos de **+42% (octubre)** a **+85% (noviembre)**, mientras que NARM presentó incrementos aún mayores (hasta **+137.5%**), debido al costo adicional de su mecanismo de atención global. Si bien su complejidad es lineal en la longitud de la secuencia, la repetición explícita multiplica directamente el número de pasos recurrentes, aumentando proporcionalmente el tiempo de entrenamiento.

Modelos convolucionales (NextItNet). Aunque NextItNet evita tanto la recurrencia como la autoatención, su uso de convoluciones dilatadas profundas implica que el costo también crece con la longitud de la secuencia. Se observaron aumentos de **+44% en octubre** y **+118% en noviembre**, mostrando que su estructura convolucional tampoco es inmune al alargamiento generado por el *dwell time*.

6. Resultados

Las Tablas 2, 3 y 4 muestran mejoras consistentes en todas las métricas al incorporar *dwell time*. Sin embargo, el grado de beneficio varía significativamente entre modelos, lo que refleja diferencias estructurales en cómo cada arquitectura procesa la información secuencial.

Comportamiento por modelo

GRU4Rec, SASRec y BERT4Rec. Estos modelos presentan mejoras moderadas pero sistemáticas, típicamente entre **+4% y +10% en octubre** y entre **+8% y +22% en noviembre**. La repetición de ítems actúa como una señal clara de corto plazo, reforzando el estado oculto (en GRU4Rec) o los patrones de atención (en SASRec y BERT4Rec), mejorando su capacidad para anticipar el siguiente ítem.

NARM. NARM es el modelo más beneficiado por la repetición explícita, con incrementos que estan un 2% sobre el segundo mejor en general . Este comportamiento es coherente con su diseño: el mecanismo de atención global está específicamente construido para identificar los elementos más relevantes de una sesión, por lo que la redundancia causada por el *dwell time* refuerza directamente su señal central.

NextItNet. NextItNet muestra mejoras menores pero estables (entre **+0.6% y +12%**). Su arquitectura convolucional captura patrones espaciales más que temporales; por ello, el *dwell time* aporta menos información explícita. Aun así, la repetición de items en las secuencias produce representaciones locales más robustas que explican el incremento observado.

Los resultados muestran que la magnitud del efecto del *dwell time* depende fuertemente del modo en que cada modelo procesa dependencias de corto y largo plazo.

7. Discusión

Los resultados muestran que la incorporación explícita del *dwell time* produjo mejoras en las métricas de ranking para todas las arquitecturas consideradas, aunque con magnitudes distintas. Esta heterogeneidad permite examinar cómo cada familia de modelos procesa la redundancia introducida por la repetición proporcional de ítems. Las arquitecturas recurrentes y basadas en autoatención causal presentan un patrón relativamente uniforme, con incrementos moderados en octubre (entre 3.8% y 5.4% en Recall@10, y alrededor de 8–10% en NDCG@10 y MRR@10), mientras que en noviembre el efecto se intensifica debido a la mayor variabilidad y al incremento natural en la longitud de las sesiones, alcanzando mejoras de entre 7.6% y 9.9% en Recall@10 y

Table 2. Resultados de Recall@10 (Octubre vs. Noviembre)

Modelo	**Sin Dwell**	**Con Dwell**	**Gap (%)**
Dataset: Octubre			
BERT4Rec	0.7612	0.7936	+4.2
GRU4Rec	0.7722	0.8016	+3.8
SASRec	0.7588	0.7922	+4.4
NARM	0.7121	0.7511	+5.4
NextItNet	0.7581	0.7626	+0.6
Dataset: Noviembre			
BERT4Rec	0.6970	0.7505	+7.6
GRU4Rec	0.7068	0.7655	+8.3
SASRec	0.6923	0.7493	+8.2
NARM	0.6463	0.7105	+9.9
NextItNet	0.7024	0.7359	+4.8

Table 3. Resultados de NDCG@10 (Octubre vs. Noviembre)

Modelo	**Sin Dwell**	**Con Dwell**	**Gap (%)**
Dataset: Octubre			
BERT4Rec	0.6388	0.6933	+8.5
GRU4Rec	0.6438	0.6980	+8.4
SASRec	0.6394	0.6937	+8.5
NARM	0.5388	0.5929	+10.0
NextItNet	0.6266	0.6406	+2.2
Dataset: Noviembre			
BERT4Rec	0.5643	0.6516	+15.4
GRU4Rec	0.5649	0.6644	+17.6
SASRec	0.5635	0.6522	+17.6
NARM	0.4695	0.5587	+19.0
NextItNet	0.5652	0.6221	+10.1

Table 4. Resultados de MRR@10 (Octubre vs. Noviembre)

Modelo	**Sin Dwell**	**Con Dwell**	**Gap (%)**
Dataset: Octubre			
BERT4Rec	0.6006	0.6620	+10.2
GRU4Rec	0.6036	0.6656	+10.2
SASRec	0.6019	0.6629	+10.1
NARM	0.4829	0.5446	+12.7
NextItNet	0.5854	0.6025	+2.9
Dataset: Noviembre			
BERT4Rec	0.5229	0.6209	+18.7
GRU4Rec	0.5206	0.6329	+21.5
SASRec	0.5233	0.6221	+21.5
NARM	0.4126	0.5094	+23.4
NextItNet	0.5224	0.5867	+12.3

Table 5. Tiempos de ejecución (Octubre vs. Noviembre)

Modelo	**Sin Dwell**	**Con Dwell**	**Gap (%)**
Dataset: Octubre			
BERT4Rec	7393.94	10550.20	+42.6
GRU4Rec	3085.00	4408.28	+42.89
SASRec	7298.36	10245.22	+40.37
NARM	3692.19	5355.16	+45.04
NextItNet	6765.44	9743.63	+44.02
Dataset: Noviembre			
BERT4Rec	4235.05	9433.21	+122.7
GRU4Rec	2183.98	4057.27	+85.7
SASRec	4093.12	9334.48	+128.1
NARM	1990.00	4727.09	+137.5
NextItNet	4051.65	8823.66	+117.8

hasta 23.4% en MRR@10. La repetición de eventos actúa como un refuerzo explícito de la señal de corto plazo, lo que permite a estos modelos consolidar patrones de preferencia dentro de la secuencia sin modificar su funcionamiento estructural.

En contraste, BERT4Rec exhibe un comportamiento que inicialmente parecía inconsistente con las hipótesis teóricas sobre modelos bidireccionales. Sin embargo, una vez corregidos los problemas de calibración observados en iteraciones preliminares, el modelo logra capitalizar de manera efectiva la señal de *dwell time*, alcanzando mejoras comparables a las arquitecturas causales tanto en octubre como en noviembre. Esto sugiere que la sensibilidad del modelo a patrones repetitivos no constituye una limitación estructural, sino un aspecto dependiente de la configuración del proceso de enmascaramiento y de la estabilidad del entrenamiento. Su capacidad para procesar información en ambas direcciones de la secuencia le permite aprovechar la redundancia para ajustar el contexto bidireccional de manera más robusta.

El caso de NARM sus mejoras, que alcanzan los valores más altos en ambos meses (hasta 12.7% en octubre y 23.4% en noviembre para MRR@10), evidencian que la combinación de memoria secuencial con un mecanismo de atención global otorga una ventaja significativa cuando la secuencia contiene repeticiones explícitas. El mecanismo de atención interpreta la frecuencia relativa de los ítems como un indicador directo de relevancia, lo que amplifica la utilidad de la señal de *dwell time* y explica el rendimiento sobresaliente del modelo frente a sus pares.

NextItNet, en cambio, presenta mejoras consistentemente menores. Su estructura convolucional, basada en filtros espaciales dilatados, no explota de manera tan directa la repetición secuencial, ya que el *dwell time* no altera la jerarquía de campos receptivos de la red. Aun así, la mayor densidad de la secuencia contribuye a representaciones locales más estables, lo que explica las mejoras moderadas observadas.

Finalmente, el análisis del costo computacional muestra que la estrategia de repetición tiene un impacto sustantivo en la escalabilidad de los modelos. Todas las arquitecturas ven incrementados sus tiempos de entrenamiento, con un patrón particularmente marcado en noviembre, donde la longitud natural de las sesiones intensifica el efecto de la expansión artificial. Este aumento oscila entre 40% y 45% en octubre y alcanza valores entre 85% y 137% en noviembre, afectando de forma más pronunciada a los modelos con complejidad cuadrática respecto de la longitud de la secuencia (SASRec y BERT4Rec) y a aquellos que dependen de recorridos estrictamente secuenciales (GRU4Rec y NARM). El incremento en costo sugiere la necesidad de explorar mecanismos alternativos que capturen la intensidad de interacción sin afectar directamente la longitud efectiva de la entrada.

8. Conclusiones

Los experimentos permiten concluir que el *dwell time*, incorporado mediante repetición proporcional de ítems, constituye una señal informativa eficaz para mejorar la calidad de las recomendaciones secuenciales. La señal de duración, al actuar como un refuerzo explícito de interés, permite distinguir entre interacciones superficiales y acciones que reflejan una intención más fuerte, lo que enriquece la representación interna de las preferencias del usuario en todos los modelos evaluados.

Las mejoras observadas en arquitecturas recurrentes, en modelos de autoatención causal y en Transformers bidireccionales indican que el beneficio del *dwell time* no depende de una estructura particular de procesamiento, sino de la capacidad del modelo para integrar redundancia informativa dentro del flujo secuencial. Esto contradice hipótesis previas que sugerían una incompatibilidad intrínseca con modelos bidireccionales: una vez estabilizado el entrenamiento, BERT4Rec logra mejoras equivalentes o superiores a sus contrapartes causales en ambos meses experimentales.

El modelo NARM destaca como la arquitectura que más provecho obtiene de la incorporación del *dwell time*. Su diseño híbrido, que combina memoria recurrente con un mecanismo de atención global, permite que las repeticiones se interpreten como evidencia directa de relevancia, alcanzando los mayores incrementos porcentuales en todas las métricas evaluadas. Este comportamiento confirma la utilidad de enfoques que integran mecanismos explícitos de ponderación interna de los eventos dentro de la sesión.

Pese a sus beneficios, la estrategia evaluada presenta un costo computacional considerable. La expansión de la secuencia incrementa los tiempos de entrenamiento en todas las arquitecturas y de forma especialmente pronunciada en escenarios donde las sesiones originales ya son largas o heterogéneas, como ocurre en noviembre. Este resultado evidencia un *trade-off* relevante entre precisión y eficiencia operativa, que limita la aplicabilidad del enfoque en contextos productivos a gran escala.

Futuras líneas de trabajo deberían orientarse a incorporar la información temporal sin aumentar la longitud de la secuencia, por ejemplo mediante *embeddings* continuos de duración, mecanismos de atención ponderada o representaciones suavizadas del tiempo de interacción. Dichas aproximaciones permitirían preservar los beneficios observados en las métricas de ranking, al mismo tiempo que mitigan el impacto computacional, favoreciendo la escalabilidad del sistema.

References

[1] Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016). Session-based Recommendations with Recurrent Neural Networks. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/pdf/1511.06939

[2] Li, J., Ren, P., Chen, Z., Ren, Z., Lian, T., & Ma, J. (2017). Neural Attentive Session-based Recommendation. *Proceedings of the 2017 ACM Conference on Information and Knowledge Management (CIKM)*. https://dl.acm.org/doi/10.1145/3132847.3132957

[3] Kang, W. C., & McAuley, J. (2018). Self-Attentive Sequential Recommendation. *IEEE International Conference on Data Mining (ICDM)*. https://arxiv.org/pdf/1808.09781

[4] Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019). BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer. *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*. https://arxiv.org/pdf/1904.06690

[5] Yuan, F., Karatzoglou, A., Hidasi, B., & Joachims, T. (2019). A Simple Convolutional Generative Network for Next Item Recommendation. *Proceedings of the 12th ACM International Conference on Web Search and Data Mining (WSDM)*. https://dl.acm.org/doi/10.1145/3289600.3290975

[6] Yi, X., Chen, L., Chi, E. H., & Bagherjeiran, A. (2014). Beyond clicks: dwell time for personalization. *Proceedings of the 8th ACM Conference on Recommender Systems (RecSys)*. https://dl.acm.org/doi/10.1145/2645710.2645724

[7] Li, J., Wang, Y., & McAuley, J. (2020). Time Interval Aware Self-Attention for Sequential Recommendation. *Proceedings of the 13th ACM International Conference on Web Search and Data Mining (WSDM)*. https://arxiv.org/pdf/2008.09112

[8] Bogina, V., & Kuflik, T. (2017). Incorporating Dwell Time in Session-Based Recommendations with Recurrent Neural Networks. *Proceedings of RecTemp Workshop co-located with ACM RecSys 2017*. CEUR Workshop Proceedings, Vol-1922. https://ceur-ws.org/Vol-1922/paper11.pdf

[9] Quadrana, M., et al. (2022). A Survey on Sequential Recommendation. *arXiv preprint arXiv:2209.09000*. https://arxiv.org/pdf/2209.09000

[10] Goas, T., & Farr, L. (2025). Repositorio oficial de experimentos y modelos para "Impacto del Dwell Time en Recomendación Secuencial". https://github.com/Tomas-Goas/H3_Recsys