Sistema Robusto de Recomendación Secuencial para Sesiones Ruidosas en E-commerce

Isabella Peña [1] **Vicente Rodríguez** [1] **Baltazar Lutjens** [1]

Abstract

En este trabajo evaluamos modelos secuenciales de recomendación (GRU4Rec, SASRec y DIF-SR) sobre el dataset *RetailRocket*, con el objetivo de mejorar la utilidad real del Top-K, el cual suele ser poco diverso y frágil frente al ruido propio de sesiones cortas. Para abordar este problema aplicamos dos métodos de re-ranking. El primero, Item-kNN, combina la relevancia del modelo con un puntaje explícito de similitud entre ítems. El segundo, SRD-ReRank, integra relevancia, confiabilidad del score y diversidad para construir un Top-10 más robusto en escenarios de alta incertidumbre. Analizamos el impacto de ambos métodos en precisión, diversidad y cobertura, e implementamos mejoras destinadas a adaptar la diversificación a modelos Transformer. Nuestros resultados muestran que es posible aumentar diversidad sin perder precisión en arquitecturas recurrentes, y que ajustes controlados permiten extender esta idea a modelos auto-atentivos.

1. Introducción

Los sistemas de recomendación secuencial se han convertido en un componente central del comercio electrónico moderno. A diferencia de los enfoques basados en historial estático, estos modelos buscan capturar la dinámica inmediata de una sesión de usuario para predecir el próximo ítem relevante. Sin embargo, en escenarios reales, como *RetailRocket*, las sesiones suelen ser cortas, ruidosas y altamente heterogéneas, lo que vuelve la señal secuencial débil y dificulta la obtención de un *Top-K* estable y útil. En particular, modelos ampliamente utilizados como GRU4Rec (Hidasi et al., 2016), SASRec (Kang & McAuley, 2018) y DIF-SR (Xie et al., 2022) tienden a generar rankings poco diversos, dominados por una sola categoría o por ítems muy similares entre sí, reduciendo la capacidad del sistema para explorar alternativas cuando la intención del usuario es incierta.

Esta limitación ha motivado el desarrollo de estrategias de *re-ranking*, cuyo objetivo es ajustar el ordenamiento entregado por el modelo base sin modificar su proceso de entrenamiento. El re-ranking permite corregir sesgos inherentes al modelo (como la baja diversidad o la excesiva concentración de probabilidad en un solo ítem) y mejorar la utilidad práctica del *Top-K*. En este contexto, evaluamos dos métodos complementarios. El primero, Item-kNN, refina la lista original mediante un puntaje explícito de similitud entre ítems, ponderando la coherencia del candidato con el historial reciente de la sesión. El segundo, SRD-ReRank, es una propuesta híbrida que integra tres señales: relevancia secuencial, confiabilidad del score y diversidad estructural, articuladas mediante una estrategia voraz inspirada en técnicas de diversificación como *Maximal Marginal Relevance* (Carbonell & Goldstein, 1998).

El objetivo central de este trabajo es analizar en profundidad cómo estos métodos de re-ranking afectan la precisión, diversidad y cobertura del sistema en presencia de ruido, y determinar bajo qué condiciones es posible mejorar la diversidad del *Top-K* sin sacrificar precisión. Esto es relevante no solo desde un punto de vista algorítmico, sino también desde la experiencia de usuario: listas redundantes que muestran productos muy similares tienden a ser menos útiles y menos atractivas en escenarios reales. Asimismo, mostramos que los modelos basados en atención, como SASRec, presentan una sensibilidad marcada a re-rankings agresivos, lo que nos llevó a proponer un conjunto de mejoras metodológicas orientadas a preservar sus predicciones más confiables mientras se diversifica el resto del ranking.

En conjunto, este trabajo contribuye con:

(i) Una evaluación empírica detallada del comportamiento de tres modelos secuenciales bajo métodos de re-ranking.

(ii) Un análisis explícito del puntaje utilizado en Item-

Trabajo presentado en el curso IIC3633. Repositorio del proyecto `https://github.com/IsabellaKPM/IIC3633-Proyecto.git`

[1]Pontificia Universidad Católica de Chile, Escuela de Ingeniería, Santiago, Chile. Correspondence to: Grupo 8 <recsys.g8@gmail.com>.

Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267, 2025. Copyright 2025 by the author(s).

kNN.

(iii) La propuesta de SRD-ReRank como mecanismo robusto ante sesiones ruidosas.

(iv) Un conjunto de extensiones diseñadas para adaptar la diversificación a arquitecturas Transformer.

Estos elementos permiten avanzar hacia sistemas de recomendación más robustos y capaces de equilibrar precisión y diversidad en contextos de interacción real.

2. Estado del Arte

Los sistemas de recomendación secuencial buscan modelar la dinámica temporal de las interacciones de usuario para predecir el próximo ítem relevante. Uno de los primeros enfoques ampliamente adoptados fue GRU4Rec (Hidasi et al., 2016), que emplea redes recurrentes tipo GRU optimizadas para datos de sesiones. Este modelo demostró que capturar dependencias de corto plazo mediante una arquitectura recurrente mejora significativamente el desempeño frente a métodos tradicionales basados en historial agregado.

El desarrollo posterior de modelos basados en atención impulsó arquitecturas más expresivas, destacando SASRec (Kang & McAuley, 2018), que introduce un mecanismo de *self-attention* unidireccional para modelar relaciones de largo alcance dentro de una sesión. Su superioridad en precisión se atribuye a la capacidad de asignar pesos adaptativos entre interacciones pasadas, aunque esta misma propiedad tiende a producir distribuciones de puntajes altamente concentradas. Más recientemente, DIF-SR (Xie et al., 2022) propone desacoplar la información secuencial de la información lateral (side-information), combinando ambas mediante bloques de atención paralelos. Si bien estos modelos muestran avances en escenarios con metadata rica, su desempeño depende fuertemente de la disponibilidad y calidad de los atributos asociados a los ítems.

De manera complementaria a los modelos secuenciales, la literatura ha explorado técnicas de *re-ranking* para ajustar el ordenamiento producido por el modelo base sin modificar su entrenamiento. En particular, métodos basados en vecindad, como item-kNN, utilizan similitudes entre ítems obtenidas a partir de embeddings o patrones de co-ocurrencia para refinar el *Top-K*. Por otro lado, técnicas de diversificación estructural, como *Maximal Marginal Relevance* (MMR) (Carbonell & Goldstein, 1998), buscan equilibrar relevancia y diversidad penalizando redundancia entre candidatos. Estas líneas de trabajo han demostrado ser efectivas en contextos donde el modelo base produce rankings homogéneos o dominados por categorías específicas.

En este trabajo nos apoyamos en ambas direcciones: evaluamos el impacto de un re-ranking basado en similitud (Item-kNN) y desarrollamos un método híbrido (SRD-ReRank) inspirado en normalización robusta y diversificación tipo MMR. Nuestro enfoque se alinea con investigaciones recientes que resaltan la importancia de controlar la concentración del *Top-K* en sesiones ruidosas, manteniendo precisión mientras se incrementa la diversidad y cobertura del catálogo.

3. Dataset y Planteamiento del Problema

Utilizamos el dataset público (RetailRocket, 2016), que contiene eventos de navegación, agregación al carrito y compras en un sitio de comercio electrónico real. Cada registro incluye un identificador de usuario anónimo (*visitor*), un ítem, un tipo de evento y una marca temporal en milisegundos, pero no define sesiones explícitas, por lo que fue necesario construirlas a partir de los logs.

3.1. Construcción de sesiones

A partir del archivo `events.csv`, agrupamos los eventos por usuario y los ordenamos cronológicamente. Luego definimos sesiones aplicando un umbral de inactividad de 30 minutos: si el tiempo entre dos eventos consecutivos de un mismo usuario excede ese umbral, se inicia una nueva sesión. Umbrales de este orden de magnitud son habituales en trabajos de recomendación por sesión y análisis de logs web, donde se busca aproximar una "visita continua" al sitio antes de considerar que el usuario inicia una nueva sesión de interacción (Hidasi et al., 2016).

Sobre las sesiones detectadas, reordenamos los eventos por tiempo dentro de cada sesión, generamos un índice de posición secuencial y eliminamos filas con información crítica faltante o duplicados exactos. El resultado es un dataset maestro (`retailrocket_sessions.parquet`) con identificadores de sesión, usuario e ítem, tipo de evento, timestamps crudos y legibles, y la posición del evento dentro de la sesión. Este archivo es la base común para todo el pipeline posterior.

3.2. Preprocesamiento para modelos secuenciales

En una segunda etapa aplicamos filtros específicos para el entrenamiento de modelos secuenciales. En particular:

- Se eliminan sesiones de longitud 1, que no aportan señal secuencial.
- Se descartan ítems con menos de 5 apariciones globales, para evitar clases casi imposibles de aprender.
- Se remueven las sesiones que, tras el filtrado de ítems, quedan por debajo de una longitud mínima de 2 eventos.

Después de estos pasos obtenemos un dataset con aproximadamente **322 937 sesiones** y **50 441 ítems**, ya formateado en términos de `SessionId`, `ItemId` y `Time` en segundos Unix. A partir de este conjunto construimos un *split* temporal: un día completo se reserva para prueba, otro para validación y el resto para entrenamiento, garantizando que los ítems presentes en validación y prueba hayan aparecido previamente en entrenamiento. Finalmente, remapeamos los identificadores de ítems a un espacio denso de enteros y alineamos las categorías de `item_properties.csv` con estos nuevos identificadores.

3.3. Propiedades del dataset

A continuación resumimos las características más relevantes del dataset RetailRocket, apoyándonos en las Figuras 1–5.

Longitud de sesiones

La Figura 1 muestra que el conjunto contiene **322,937 sesiones**, con una mediana de **2** eventos, percentil 90 igual a **6** y un máximo de **307**. Es decir, la mayoría de las sesiones son muy cortas, por lo que la señal secuencial disponible para los modelos es limitada y altamente sensible al ruido de los primeros clics.

Popularidad de ítems (cola larga)

Según la Figura 2, existen **50,441 ítems únicos**, con frecuencia máxima de **1,959** interacciones y una mediana de solo **11**. La curva en escala log-log evidencia una cola larga pronunciada: pocos ítems concentran gran parte del tráfico, lo que empuja a los modelos a sobrerrecomendar ítems populares y reduce la cobertura efectiva del catálogo.

Concentración categorial

A partir de `item_properties`, identificamos **917 categorías** distintas. No obstante, la Figura 3 muestra que las **10 categorías más frecuentes concentran el 20.61%** de todos los eventos. Esta concentración categorial favorece rankings dominados por unas pocas familias de productos, dificultando la diversidad temática del *Top-K*.

Patrones temporales

La Figura 4 resume los intervalos de tiempo entre eventos consecutivos dentro de una sesión. La mediana es **1.17 minutos**, el percentil 75 es **3.2 minutos** y el máximo supera los **118 minutos**. Predominan ráfagas de navegación rápida, pero con pausas largas ocasionales, lo que introduce ruido temporal y vuelve frágil la interpretación de la secuencia.

Entropía categorial por sesión

Finalmente, la Figura 5 muestra la distribución de entropía categorial. La media es **0.24** y la mediana es **0**, con un **79.36%** de sesiones de entropía cero (una sola categoría). Es decir, la mayoría de las sesiones explora productos muy similares, con un subconjunto menor de sesiones más ambiguas.

3.4. Implicancias para modelos y re-ranking

En conjunto, estas propiedades generan un escenario donde la señal secuencial es débil, el sesgo hacia ítems y categorías populares es fuerte y la dinámica temporal es ruidosa. Bajo estas condiciones, incluso modelos secuenciales avanzados tienden a producir *Top-K* poco diversos, con baja cobertura del catálogo y dominados por unos pocos ítems frecuentes.

Este diagnóstico motiva el uso de estrategias de *re-ranking* que ajusten el ordenamiento original para estabilizar el *Top-K*, aumentar su diversidad y mejorar la cobertura sin deteriorar en exceso la precisión. Las metodologías estudiadas en este trabajo se diseñaron precisamente teniendo en cuenta estas características del dataset, y se describen en detalle en la Sección 4.

4. Metodología

Nuestra metodología se organiza en cuatro componentes principales: (i) preparación del dataset y segmentación de sesiones, (ii) análisis descriptivo de las interacciones, (iii) entrenamiento de modelos secuenciales con sus implementaciones oficiales y (iv) aplicación de dos métodos de re-ranking: Item-kNN y nuestra propuesta, SRD-ReRank. Finalmente, incorporamos extensiones metodológicas orientadas a mejorar el comportamiento del re-ranking en arquitecturas basadas en atención.

4.1. Preparación del dataset y segmentación de sesiones

Tal como se detalló en la Sección 3, partimos del conjunto *RetailRocket* y reconstruimos sesiones aplicando un umbral estándar de inactividad de 30 minutos. En esta etapa sólo realizamos los pasos mínimos necesarios para su uso en modelos secuenciales: ordenamiento temporal, estandarización de identificadores y eliminación de sesiones demasiado cortas para aportar señal. El resultado es el mismo dataset preprocesado descrito anteriormente, ahora directamente compatible con las implementaciones oficiales consideradas en este trabajo.

4.2. Análisis descriptivo

Siguiendo el diagnóstico presentado en la Sección 3, incorporamos un análisis descriptivo únicamente como referencia metodológica y para justificar posteriormente el

uso de re-ranking. Las visualizaciones de longitud de sesiones, popularidad e información categorial ya mostraron una señal secuencial débil y una fuerte concentración en pocos ítems, por lo que aquí sólo recordamos que estas propiedades motivan explícitamente los mecanismos propuestos para aumentar diversidad y cobertura del *Top-*K.

4.3. Modelos secuenciales

Entrenamos tres modelos representativos de la literatura utilizando sus repositorios oficiales: GRU4Rec (Hidasi et al., 2016), SASRec (Kang & McAuley, 2018) (específicamente la implementación en *pytorch* de *pmixer* (Huang, 2020)) y DIF-SR (Xie et al., 2022). Cada modelo genera, para cada sesión s, un conjunto de candidatos C_s acompañado de un puntaje de relevancia $rel(i \mid s)$. A partir de estos candidatos aplicamos dos métodos de re-ranking: Item-kNN y SRD-ReRank.

4.4. Re-ranking

Los métodos de re-ranking fueron implementados de forma que estos reciban una lista de candidatos, que es la lista de recomendación de salida del modelo base, de un largo mayor al Top-K objetivo, sobre la que se realiza el re-ranking, reordenando estos ítems y luego, al salir de este, se trunca esta lista de ítems al largo K esperado (en este paper se trabaja con un Top-10 objetivo) y es sobre este Top-K que se miden las métricas.

A lo largo del paper, a esta lista de candidatos de entrada de los re-ranking también se le denomina "Top-N a Top-K", con $N \in \{20, 25, 50\}$ y $K = 10$, por simplicidad y como una forma de denotar la cantidad de ítems que entran, N, y los que salen, K.

A continuación, se detallan las especificaciones de cada uno de los métodos implementados:

4.4.1. Re-ranking mediante Item-kNN

El método Item-kNN ajusta el ordenamiento original combinando la relevancia secuencial con un puntaje de similitud entre ítems. Primero, construimos un índice de vecinos cercanos utilizando las representaciones de ítems aprendidas por el modelo:

$$sim(i, j) = 1 - d(emb(i), emb(j)),$$

donde $d(\cdot)$ corresponde a distancia coseno o euclidiana. Para un candidato i, definimos un puntaje de coherencia respecto del historial de la sesión $hist(s)$:

$$knn(i \mid s) = \sum_{j \in hist(s)} sim(i, j)\, w(j),$$

donde $w(j)$ pondera la recencia del ítem en la sesión. El puntaje final utilizado para reordenar es:

$$score_{\text{kNN}}(i \mid s) = \alpha\, rel(i \mid s) + (1 - \alpha)\, knn(i \mid s)$$

El re-ranking mantiene el conjunto de candidatos, modificando únicamente su orden según este puntaje.

4.4.2. Re-ranking mediante SRD-ReRank

Proponemos SRD-ReRank, un método híbrido que busca construir un Top-10 robusto en sesiones ruidosas integrando tres señales complementarias:

1. **Relevancia secuencial** $rel(i \mid s)$, entregada por el modelo base.
2. **Confiabilidad del score**, modelada como una normalización robusta dentro de la sesión:
$$conf(i \mid s) = \frac{rel(i \mid s) - \mu_s}{\sigma_s + \varepsilon}$$
3. **Diversidad estructural**, inspirada en *Maximal Marginal Relevance* (Carbonell & Goldstein, 1998):
$$div(i, L) = -\max_{j \in L} sim(i, j)$$

Combinamos estas señales mediante:

$$score_{\text{SRD}}(i \mid s, L) = \alpha\, rel(i \mid s) + \beta\, conf(i \mid s) + \gamma\, div(i, L)$$

El Top-10 final se construye a través de la siguiente estrategia: en cada iteración seleccionamos el ítem con el mayor puntaje $score_{\text{SRD}}$ y actualizamos el conjunto parcial L.

4.5. Métricas de evaluación

La evaluación se realiza sobre el *Top*-10 truncado a partir del Top-50, Top-25 o Top-20 retornado por el re-ranking, utilizando, en primer lugar, las métricas discutidas en clases y definidas por el práctico del curso: **Recall@K**, **MAP@K**, **NDCG@K**, junto con **diversidad** y **novedad**. Estas métricas se emplean en su forma estándar: Recall@K cuantifica la fracción de ítems relevantes dentro del *Top-*K; MAP@K promedia la precisión acumulada a los distintos cortes k; y NDCG@K pondera la posición de los aciertos mediante descuentos logarítmicos, mientras que diversidad y novedad evalúan la variedad y el alejamiento de la popularidad, respectivamente.

Para completar el diagnóstico, incorporamos indicadores habituales en la literatura, pero no vistos en clases, por lo que presentamos sus expresiones resumidas. El **MRR@K** (Mean Reciprocal Rank) asigna puntuaciones más altas cuando el primer acierto aparece en posiciones tempranas:

$$\text{MRR@K} = \frac{1}{|S|} \sum_{s \in S} \frac{1}{r_s}, \quad r_s = \min\{r \leq K : \text{item}_r \in g_s\},$$

y **HitRate@K** (también llamada **Recall@K**) verifica simplemente la existencia de algún acierto dentro del *Top-*K:

$$\mathrm{HitRate@K} = \frac{1}{|S|} \sum_{s \in S} \mathbf{1}\{g_s \cap C_s^{(K)} \neq \emptyset\}.$$

Finalmente, incluimos tres métricas de *cobertura* orientadas a evaluar la amplitud del catálogo recomendado:

ILD@K o *Intra-List Diversity*, mide qué tan diferentes son las categorías de los ítems recomendados dentro del Top-K:

$$\mathrm{ILD@K} = \frac{2}{K(K-1)} \sum_{1 \leq i < j \leq K} \begin{cases} 1, & \text{si } \mathrm{cat}(i) \neq \mathrm{cat}(j), \\ 0, & \text{e.o.c.} \end{cases}$$

CategoryCoverage calcula la fracción de categorías del catálogo presentes al menos una vez en las recomendaciones:

$$\mathrm{CategoryCoverage} = \frac{|\{\mathrm{cat}(i) : i \in C^{(K)}\}|}{|\mathcal{C}|},$$

y **LongTailCoverage** mide la proporción de ítems de cola larga exhibidos en el *Top-*K:

$$\mathrm{LongTailCoverage} = \frac{1}{|C^{(K)}|} \sum_{i \in C^{(K)}} \mathbf{1}\{i \in \mathcal{L}\}.$$

Con este conjunto de métricas evaluamos simultáneamente la relevancia y la capacidad de los modelos (y de los esquemas de re-*ranking*) para diversificar las recomendaciones, lo que permitirá comparar de forma consistente los resultados.

4.6. Extensiones metodológicas

Los resultados iniciales mostraron que los modelos basados en atención (SASRec y DIF-SR) son sensibles a re-rankings agresivos debido a su alta concentración de probabilidad en los primeros puestos. Para abordar este comportamiento implementamos tres mejoras complementarias:

- **Reducción del Top-K inicial**: limitar el conjunto de candidatos a $K \in \{20, 25, 50\}$ reduce el impacto de reordenamientos profundos.
- **Preservación del Top-3**: mantenemos sin alteración los primeros 3 ítems del ranking original antes de aplicar re-ranking al resto.

Estas extensiones permiten compatibilizar diversidad y precisión en arquitecturas Transformer, manteniendo el espíritu modular del re-ranking.

5. Resultados y Discusión

5.1. Resultados globales por modelo

A partir del *split* temporal descrito en la Sección 3, evaluamos los modelos secuenciales sobre listas *Top-10* generadas por sus implementaciones oficiales. La comparación considera métricas de precisión (Recall@10, MRR@10, NDCG@10, MAP@10) y de diversidad/cobertura (Novelty@10, Diversity@10, ILD@10, así como cobertura de categorías y de cola larga), siguiendo los lineamientos metodológicos presentados en la Sección 4.

Presentamos primero el desempeño de los modelos base, para luego analizar el efecto incremental de *Item-kNN* y, finalmente, el impacto de nuestra propuesta *SRD-ReRank*. En las tablas, los valores en **negrita** señalan el mejor resultado registrado por cada métrica.

Modelo	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	0.5148	0.4737	0.6444	0.1468	**0.5585**	0.2678	0.9565	0.6238	**0.5421**
GRU4Rec + DWELL	0.5060	0.4638	0.6400	0.1437	0.5575	**0.2854**	**0.9575**	**0.6499**	0.5381
SASRec	**0.7978**	**0.7742**	**0.8713**	**0.2318**	0.2924	0.1975	0.1856	0.5879	0.0580
DIF-SR	0.1925	0.1766	0.2430	0.1925	0.0260	0.0260	0.9481	0.02998	0.086

Table 1. Resultados de los modelos secuenciales sin re-ranking.

Modelo	Distancia	K	α	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	Cosine	50	0.5	0.5248	0.4830	0.6560	0.1500	0.5591	0.2634	0.9559	0.6205	0.5424
	Cosine	50	0.9	0.5158	0.4747	0.6453	0.1472	0.5586	0.2670	0.9564	0.6238	**0.5425**
	Euclidean	50	0.5	**0.5471**	**0.5051**	**0.6773**	0.1573	0.5579	0.2756	0.9574	0.6249	0.5399
	Euclidean	50	0.9	0.5180	0.4775	0.6453	0.1481	0.5585	0.2686	0.9565	0.6227	0.5418
GRU4Rec + DWELL	Cosine	50	0.5	0.5165	0.4719	0.6569	0.1471	0.5582	0.2822	0.9571	0.6521	0.5402
	Cosine	50	0.9	0.5072	0.4645	0.6427	0.1440	0.5575	0.2856	0.9575	0.6510	0.5381
	Euclidean	50	0.5	0.5335	0.4893	0.6702	0.1533	0.5568	**0.2906**	**0.9585**	0.6565	0.5353
	Euclidean	50	0.9	0.5088	0.4662	0.6436	0.1448	0.5573	0.2853	0.9576	0.6521	0.5378
SASRec	Cosine	50	0.5	0.0044	0.0026	0.0105	0.2286	**0.7282**	0.2037	0.1967	0.6449	0.1366
	Cosine	50	0.9	0.0063	0.0040	0.0140	0.2297	0.7263	0.2014	0.1929	0.6263	0.1360
	Euclidean	50	0.5	0.0059	0.0041	0.0117	0.2299	0.7269	0.2042	0.1980	0.6414	0.1392
	Euclidean	50	0.9	0.0057	0.0033	0.0138	**0.2305**	0.7267	0.2026	0.1948	**0.6566**	0.1383
DIF-SR	Cosine	50	0.8	0.1927	0.1767	0.2430	0.1767	0.0259	0.0260	0.9482	0.02998	0.086

Table 2. Resultados de re-ranking de Top-50 A Top-10 con Item-kNN sobre modelos secuenciales.

Modelo	Distancia	K	α	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	Cosine	50	0.5	0.5202	0.4770	0.6560	0.1484	**0.5591**	0.2634	0.9559	0.6205	0.5424
	Cosine	50	0.9	0.5153	0.4740	0.6453	0.1470	0.5586	0.2670	0.9564	0.6238	**0.5425**
	Euclidean	50	0.5	0.5299	0.4832	0.6764	0.1512	0.5579	0.2755	0.9574	0.6249	0.5398
	Euclidean	50	0.9	0.5157	0.4745	0.6453	0.1473	0.5585	0.2686	0.9565	0.6227	0.5418
GRU4Rec + DWELL	Cosine	50	0.5	0.5139	0.4687	0.6569	0.1460	0.5582	0.2822	0.9571	0.6521	0.5402
	Cosine	50	0.9	0.5070	0.4643	0.6427	0.1439	0.5575	0.2856	0.9575	0.6510	0.5381
	Euclidean	50	0.5	0.5207	0.4732	0.6702	0.1481	0.5568	**0.2906**	**0.9585**	**0.6565**	0.5353
	Euclidean	50	0.9	0.5079	0.4651	0.6436	0.1444	0.5573	0.2853	0.9576	0.6521	0.5378
SASRec	Cosine	50	0.5	0.7800	0.7662	**0.8214**	**0.2319**	0.4450	0.2033	0.1963	0.6461	0.1057
	Cosine	50	0.9	0.7725	0.7577	0.8176	0.2294	0.4472	0.1988	0.1885	0.6321	0.1046
	Euclidean	50	0.5	0.7685	0.7549	0.8091	0.2284	0.4456	0.2042	0.1982	0.6461	0.1086
	Euclidean	50	0.9	**0.7801**	**0.7666**	0.8210	0.2314	0.4476	0.2042	0.1980	0.6380	0.1079
DIF-SR	Cosine	50	0.5	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	Cosine	50	0.9	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881

Table 3. Resultados de re-ranking de Top-25 a Top-10 con Item-kNN sobre modelos secuenciales y Top-3 fijo.

Modelo	Distancia	K	α	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	Cosine	50	0.5	0.5202	0.4770	0.6560	0.1484	**0.5591**	0.2634	0.9559	0.6205	0.5424
	Cosine	50	0.9	0.5153	0.4740	0.6453	0.1470	0.5586	0.2670	0.9564	0.6238	**0.5425**
	Euclidean	50	0.5	0.5294	0.4830	0.6747	0.1512	0.5580	0.2754	0.9574	0.6249	0.5399
	Euclidean	50	0.9	0.5157	0.4745	0.6453	0.1473	0.5585	0.2686	0.9565	0.6227	0.5418
GRU4Rec + DWELL	Cosine	50	0.5	0.5139	0.4687	0.6569	0.1460	0.5582	0.2822	0.9571	0.6521	0.5402
	Cosine	50	0.9	0.5070	0.4643	0.6427	0.1439	0.5575	0.2856	0.9575	0.6510	0.5381
	Euclidean	50	0.5	0.5199	0.4729	0.6676	0.1480	0.5567	**0.2905**	**0.9585**	**0.6565**	0.5352
	Euclidean	50	0.9	0.5079	0.4651	0.6436	0.1444	0.5573	0.2853	0.9576	0.6521	0.5378
SASRec	Cosine	50	0.5	0.7839	0.7683	0.8309	0.2327	0.4046	0.2014	0.1923	0.6449	0.0981
	Cosine	50	0.9	0.7764	0.7602	0.8252	0.2297	0.4064	0.2024	0.1947	0.6228	0.0989
	Euclidean	50	0.5	**0.7861**	**0.7710**	**0.8321**	**0.2328**	0.4048	0.1999	0.1901	0.6217	0.0968
	Euclidean	50	0.9	0.7801	0.7637	0.8304	0.2306	0.4052	0.1984	0.1873	0.6205	0.0980
DIF-SR	Cosine	50	0.5	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	Cosine	50	0.9	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881

Table 4. Resultados de re-ranking de Top-20 a Top-10 con Item-kNN sobre modelos secuenciales y Top-3 fijo.

Modelo	α	β	γ	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	1.0	0.2	0.4	**0.5010**	**0.4620**	**0.6258**	0.1421	0.5690	0.4697	0.9698	0.7437	0.5739
	1.0	0.2	0.6	0.4828	0.4485	0.5938	0.1368	0.5755	0.5780	0.9774	0.7743	0.5931
	1.0	0.4	0.4	0.4916	0.4533	0.6160	0.1385	0.5711	0.5003	0.9730	0.7557	0.5797
	1.0	0.4	0.6	0.4683	0.4366	0.5724	0.1320	0.5777	0.6094	0.9806	0.7819	0.5968
GRU4Rec + DWELL	1.0	0.2	0.4	0.4869	0.4489	0.6089	0.1378	0.5696	0.5238	0.9730	0.7601	0.5741
	1.0	0.2	0.6	0.4648	0.4328	0.5698	0.1312	0.5771	0.6455	0.9809	0.7732	0.5959
	1.0	0.4	0.4	0.4763	0.4400	0.5947	0.1342	0.5716	0.5560	0.9756	0.7677	0.5799
	1.0	0.4	0.6	0.4512	0.4221	0.5484	0.1268	0.5797	**0.6770**	**0.9837**	0.7841	**0.6022** a
SASRec	1.0	0.2	0.4	0.0052	0.0028	0.0132	0.2293	**0.6945**	0.4612	0.5821	0.8300	0.1288
	1.0	0.2	0.6	0.0049	0.0031	0.0111	0.2308	0.6791	0.5167	0.6475	**0.8638**	0.1247
	1.0	0.4	0.4	0.0058	0.0040	0.0118	**0.2361**	0.6929	0.4674	0.5893	0.8359	0.1285
	1.0	0.4	0.6	0.0052	0.0029	0.0131	0.2310	0.6795	0.5232	0.6539	0.8556	0.1279
DIF-SR	1.0	0.2	0.4	0.19272	0.17668	0.2430	0.1767	0.025939	0.0260	0.9482	0.03	0.0867
	1.0	0.2	0.6	0.19272	0.17668	0.2430	0.1767	0.025939	0.0260	0.9482	0.03	0.0867
	1.0	0.4	0.4	0.19272	0.17668	0.2430	0.1767	0.025939	0.0260	0.9482	0.03	0.0867
	1.0	0.4	0.6	0.19272	0.17668	0.2430	0.1767	0.025939	0.0260	0.9482	0.03	0.0867

Table 5. Resultados de re-ranking de Top-50 A Top-10 con SRD para distintas combinaciones de (α, β, γ).

Modelo	α	β	γ	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	1.0	0.2	0.4	0.5123	0.4724	0.6382	0.1462	0.5608	0.3265	0.9606	0.6718	0.5491
	1.0	0.2	0.6	0.5101	0.4713	0.6320	0.1458	0.5620	0.3502	0.9625	0.6947	0.5519
	1.0	0.4	0.4	0.5109	0.4716	0.6347	0.1459	0.5617	0.3344	0.9620	0.6805	0.5501
	1.0	0.4	0.6	0.5083	0.4705	0.6267	0.1456	0.5633	0.3580	0.9643	0.6990	0.5556
GRU4Rec + DWELL	1.0	0.2	0.4	0.5025	0.4620	0.6311	0.1430	0.5603	0.3460	0.9617	0.6947	0.5469
	1.0	0.2	0.6	0.5003	0.4609	0.6249	0.1426	0.5622	0.3757	0.9641	0.7088	0.5528
	1.0	0.4	0.4	0.5007	0.4610	0.6267	0.1425	0.5613	0.3559	0.9630	0.6979	0.5500
	1.0	0.4	0.6	0.4995	0.4601	0.6249	0.1420	**0.5634**	**0.3817**	**0.9653**	0.7132	**0.5567**
SASRec	1.0	0.2	0.4	0.7819	0.7658	0.8302	0.2319	0.4454	0.2568	0.2894	0.6868	0.1027
	1.0	0.2	0.6	0.7893	0.7743	0.8344	0.2339	0.4389	0.2783	0.3247	0.7322	0.1026
	1.0	0.4	0.4	**0.7909**	**0.7756**	**0.8365**	**0.2346**	0.4420	0.2667	0.3060	0.7066	0.1021
	1.0	0.4	0.6	0.7809	0.7669	0.8234	0.2313	0.4410	0.2819	0.3292	**0.7451**	0.1039
DIF-SR	1.0	0.2	0.4	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.2	0.6	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.4	0.4	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.4	0.6	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881

Table 6. Resultados de re-ranking de Top-25 a Top-10 con SRD para distintas combinaciones de (α, β, γ) y Top-3 fijo.

Modelo	α	β	γ	NDCG@10	MRR@10	Recall@10	MAP@10	Novelty@10	Diversity@10	ILD@10	CC	LTC
GRU4Rec BASE	1.0	0.2	0.4	0.5132	0.4728	0.6409	0.1464	0.5602	0.3104	0.9595	0.6630	0.5462
	1.0	0.2	0.6	0.5119	0.4721	0.6373	0.1461	0.5612	0.3311	0.9611	0.6783	0.5504
	1.0	0.4	0.4	0.5119	0.4721	0.6373	0.1461	0.5607	0.3118	0.9601	0.6630	0.5483
	1.0	0.4	0.6	0.5102	0.4713	0.6329	0.1458	**0.5617**	0.3308	0.9620	0.6783	**0.5516**
GRU4Rec + DWELL	1.0	0.2	0.4	0.5032	0.4623	0.6329	0.1431	0.5598	0.3287	0.9606	0.6794	0.5446
	1.0	0.2	0.6	0.5022	0.4618	0.6302	0.1429	0.5607	**0.3527**	0.9623	**0.6979**	0.5483
	1.0	0.4	0.4	0.5024	0.4618	0.6311	0.1429	0.5597	0.3287	0.9611	0.6816	0.5444
	1.0	0.4	0.6	0.5009	0.4610	0.6276	0.1425	0.5609	0.3497	**0.9628**	0.6947	0.5477
SASRec	1.0	0.2	0.4	0.7860	0.7698	0.8356	0.2324	0.4069	0.2366	0.2547	0.6752	0.0984
	1.0	0.2	0.6	0.7759	0.7607	0.8217	0.2302	0.4057	0.2491	0.2757	0.6810	0.0975
	1.0	0.4	0.4	0.7652	0.7483	0.8159	0.2278	0.4062	0.2398	0.2603	0.6810	0.0986
	1.0	0.4	0.6	**0.7921**	**0.7758**	**0.8418**	**0.2341**	0.4038	0.2516	0.2798	0.6764	0.0957
DIF-SR	1.0	0.2	0.4	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.2	0.6	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.4	0.4	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881
	1.0	0.4	0.6	0.1949	0.1809	0.2391	0.1809	0.0264	-	0.9464	0.0300	0.0881

Table 7. Resultados de re-ranking de Top-20 a Top-10 con SRD para distintas combinaciones de (α, β, γ) y Top-3 fijo.

Se puede observar que los re-ranking utilizados tuvieron un efecto significativo en las métricas en general, ya sea de forma positiva como negativa. Particularmente, las métricas de precisión disminuyen mucho en el primer acercamiento al re-ranking en SASRec, tal como se puede ver en la Tabla 2 y Tabla 5, mientras que en GRU4Rec se mantienen en rangos similares a los del modelo original. Este comportamiento se debe al uso del re-ranking sobre un Top-50 que luego se trunca a un Top-10, lo que produce que el ítem relevante buscado por las métricas de precisión, como NDCG@10, quede muy debajo en el reordenamiento del Top-50, lo cual genera que, al truncarlo, este se vea desplazado a una posición muy baja o que directamente no se encuentre entre el Top-10 de ítems recomendados. Lo anterior, resulta perjudicial al medir precisión pero tiene un impacto positivo en las métricas de diversidad y novedad en modelos como GRU4Rec y SASRec, que es nuestro objetivo, aunque el sacrificio de precisión es demasiado grande.

Además, es importante destacar que el modelo SASRec utiliza *self-attention* en su implementación, lo que genera un Top-1 muy preciso y permite obtener las mejores métricas de precisión entre los cuatro modelos, la cual corresponde a otra de las razones por las cuales se ve tan altamente afectado por los re-ranking. Es esta precisión la que también genera que el modelo tenga peor rendimiento, en comparación a GRU4Rec, en métricas de novedad o diversidad.

Por lo anterior es que se decidió re-entrenar los modelos utilizando los mismos hiperparámetros, pero fijando el Top-3 para no dañar tanto las métricas de precisión (sobretodo en SASRec) y en vez de pasar un Top-50 al re-ranking, se pasan un Top-25 (Tabla 3 y Tabla 6) y un Top-20 (Tabla 4 y Tabla 7). Así, los resultados muestran valores similares a los de los modelos base en cuanto a precisión, mientras que mejoran considerablemente la novedad y diversidad de los modelos. En particular, las métricas de novedad y diversidad en SASRec aumentan casi al doble, manteniendo las métricas de precisión más altas entre todos los modelos, mientras que en GRU4Rec, los resultados de novedad aumentan en cierta medida, mientras que los de diversidad aumentan casi al doble en SRD, sin ver resultados relevantes en ItemKNN.

Se observa que ItemKNN tiene un menor rendimiento en comparación a SRD, ya que a pesar de aumentar bastante la novedad, no aumenta demasiado la diversidad y deteriora más las métricas de precisión.

5.1.1. Discusión DIF-SR

El análisis del desempeño del modelo DIF-SR y las estrategias de re-ranking implementadas en este, revelan una discrepancia significativa entre la precisión métrica y la diversidad del sistema. En este apartado, se discutirán los principales fenómenos observados que llevan a estos resultados.

Si bien el modelo base alcanzó métricas de precisión competitivas, con un $HR@10$ de 0.2391 y un $NDCG@10$ de 0.1951, un análisis profundo de la distribución de recomendaciones evidencia un fuerte sesgo de popularidad. La métrica de *Catalog Coverage* se estancó en un $\approx 3.00\%$.

Este comportamiento sugiere que la arquitectura implementada, una arquitectura GRU contextualizada mediante concatenación de embedding de usuario no logro capturar los intereses secuenciales de los usuarios, en su lugar convergiendo hacia un *Mode Colapse*, optimizando la función de perdida mediante la recomendación de tendencias globales, esto visto con que ignoró el 91% del catalogo ($Long - TailCoverage \approx 8,8\%$)

Los resultados experimentales mostraron que las métricas de evaluación permanecieron invariables (hasta el cuarto decimal) tras aplicar las estrategias de *Item-KNN* y *SRD* (Score-Reliability-Diversity). Este estancamiento no se debe a una falla teórica de los algoritmos de re-ranking, sino a

dos restricciones técnicas críticas en el diseño experimental:

- **Restricción de Posición (Fixed Top-N):** Al fijar los primeros 3 ítems (`fixed_top_n=3`), se impidió que el re-ranker modificara las posiciones de mayor impacto en las métricas de Top-10. Dado el sesgo del modelo base, es altamente probable que los aciertos relevantes (*hits*) se concentraran en estas primeras posiciones inamovibles.
- **Homogeneidad de Candidatos:** El re-ranker opera sobre el conjunto de candidatos recuperados por el modelo base ($K_{in} = 50$). Dado que el modelo base sufre de baja cobertura, los candidatos suministrados al re-ranker carecían de diversidad intrínseca. El algoritmo SRD no pudo promover diversidad porque el subconjunto de entrada ya estaba saturado de ítems populares, demostrando que un re-ranker no puede corregir defectos fundamentales en la etapa de recuperación (*retrieval*).

Finalmente, el análisis de las curvas de aprendizaje corrobora la hipótesis de (*overfitting*) estructural. Como se observa en los registros de entrenamiento, la función de pérdida del conjunto de entrenamiento disminuyó drásticamente y de manera monótona, pasando de 10.54 en la primera época a 3.64 en la última.

En contraste, la función de pérdida en el conjunto de validación exhibió una degradación progresiva. Si bien comenzó en 10.42, comenzó a divergir rápidamente de la pérdida de entrenamiento. Este comportamiento se volvió crítico a partir del quinto *epoch*, donde la pérdida de validación escaló hasta 16.54. Esta brecha creciente entre el rendimiento en entrenamiento y validación demuestra que el modelo, en lugar de aprender patrones generalizables, comenzó a memorizar el ruido específico de los datos de entrenamiento, perdiendo su capacidad de predicción sobre datos no vistos y corroborando estas hipótesis.

5.2. Resultados por tipos de usuarios

Las métricas agregadas presentadas previamente permiten comparar de manera global el rendimiento de los modelos secuenciales y sus variantes con re-ranking. Sin embargo, dichas métricas no ilustran cómo cambian concretamente las recomendaciones a nivel de sesión, ni muestran el tipo de diversificación que se produce en escenarios particulares. Para complementar la evaluación cuantitativa, realizamos un análisis cualitativo sobre casos reales del conjunto `TEST`.

5.2.1. GRU4REC

Considerando que **GRU4Rec-Dwell** constituye la configuración secuencial más completa para GRU4Rec, centramos el análisis de casos exclusivamente en este modelo. De esta forma, se seleccionaron tres sesiones representativas que reflejan perfiles típicos observados en sistemas de recomendación:

- **Usuario de baja diversidad**: la mayoría de los candidatos pertenecen a 1–2 categorías.
- **Usuario de diversidad media**: los candidatos se reparten en un número intermedio de categorías.
- **Usuario de alta diversidad**: el Top-25 incluye muchas categorías distintas.

	Posición en el Top-10									
Método	1	2	3	4	5	6	7	8	9	10
BASE	31177	556	39351	31043	8192	908	11303	22278	38000	41428
Item-kNN	31177	556	39351	31043	8192	908	11303	22278	38000	41428
SRD	31177	556	39351	31043	8192	908	22278	38000	11303	4693

Table 8. Sesión de baja diversidad con GRU4Rec-Dwell (`1840000002`).

	Posición en el Top-10									
Método	1	2	3	4	5	6	7	8	9	10
BASE	14782	44769	21467	23051	48685	31440	48025	35799	17317	8242
Item-kNN	14782	44769	21467	23051	48685	31440	48025	35799	17317	8242
SRD	14782	44769	21467	23051	13768	48685	48025	40516	31440	35799

Table 9. Sesión de diversidad media con GRU4Rec-Dwell (`329136000001`).

	Posición en el Top-10									
Método	1	2	3	4	5	6	7	8	9	10
BASE	48804	41600	48542	38261	35645	24897	4501	9122	31317	29312
Item-kNN	48804	41600	48542	38261	35645	24897	4501	9122	31317	29312
SRD	48804	41600	48542	38261	35645	24897	4501	9122	31317	29312

Table 10. Sesión de alta diversidad con GRU4Rec-Dwell (`1093357000001`).

En los tres perfiles se observa que *Item-kNN* tiende a preservar la estructura del Top-10 entregada por GRU4Rec-Dwell, mientras que *SRD* introduce ajustes selectivos cuando existe redundancia categorial, sobre todo en el caso de diversidad media. Cuando el conjunto inicial es altamente concentrado, el efecto es limitado, y cuando el propio modelo ya genera listas equilibradas, las tres variantes convergen prácticamente en los mismos ítems. En conjunto, estos resultados sugieren que *SRD* actúa como un mecanismo de *diversificación controlada*, alternando elementos sólo Cuando existe espacio real para mejorar la cobertura sin degradar la relevancia del modelo secuencial.

6. Conclusiones

De acuerdo con los resultados obtenidos anteriormente, se puede observar que se logró el objetivo de añadir diversidad

y novedad a modelos secuenciales a través de la aplicación de re-ranking: ItemKKN y SRD, los cuales presentaron mejoras significativas, aunque SRD fue particularmente bueno para añadir novedad sin dejar de lado la diversidad ni las métricas de precisión.

En cuanto a la implementación de los modelos, se logro el objetivo con 2 modelos secuenciales, siendo GRU4Rec y SASRec. Estas arquitecturas demostraron una solidez superior en la captura de dependencias temporales, logrando un equilibrio efectivo entre precisión y generalización sin caer en la memorización excesiva de los datos. Por el contrario, la implementación de DIF-SR, no alcanzo los estándares esperados, a pesar de tener un diseño mas complejo, demostró una clara tendencia al overfitting y al colapso de la diversidad, demostrando que no era el modelo adecuado para este tipo de datos.

A lo largo del paper, se logró identificar que los modelos secuenciales que utilizan *self-attention* son particularmente sensibles a los re-ranking, debido a que su alta precisión se ve afectada de sobremanera al introducir reordenamientos sobre la recomendación, sin embargo, también se demostró que la fijación del Top-3 en conjunto con el control de la cantidad de ítems que entran al re-ranking, son soluciones concretas a esta pérdida de precisión, generando sacrificios mínimos e incluso nulos de esta.

Finalmente, se puede concluir que SRD con Top-3 fijo, permite mejorar las métricas globales de GRU4Rec, con y sin *Dwell Time*, y de SASRec, produciendo recomendaciones más diversas y novedosas, con pérdidas ínfimas de precisión.

References

Agrawal, R., Gollapudi, S., Halverson, A., and Ieong, S. Diversifying search results. In *Proceedings of the ACM International Conference on Web Search and Data Mining (WSDM)*, 2009.

Carbonell, J. and Goldstein, J. The use of mmr for diversity-based ranking. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 1998.

Hidasi, B., Karatzoglou, A., Baltrunas, L., and Tikk, D. Session-based recommendations with recurrent neural networks. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2016.

Huang, Z. SASRec.pytorch. `https://github.com/pmixer/SASRec.pytorch`, 2020. URL `https://github.com/pmixer/SASRec.pytorch`. Accessed: 2025-11-19.

Kang, W.-C. and McAuley, J. Self-attentive sequential recommendation. In *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2018.

RetailRocket. Retailrocket recommender system dataset. `https://www.kaggle.com/datasets/retailrocket/ecommerce-dataset`, 2016. Accessed: 2025-10-01.

Vargas, S. and Castells, P. Intent-aware metrics for search and recommendation diversity. *Information Retrieval*, 16(4):345–375, 2013.

Xie, Y., Zhou, P., and Kim, S. Decoupled side information fusion for sequential recommendation. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2022.

Zhang, Y., Chen, L., Zheng, W., Zhang, Z., and Li, S. Attribute-aware diversification for sequential recommendations. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022.

7. Apéndice de Figuras

7.1. Análisis descriptivo del dataset

Longitud de sesiones

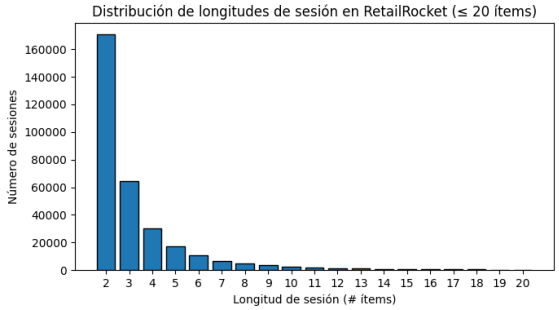

Figure 1. Distribución de longitudes de sesión en RetailRocket ($\leq$ 20 ítems).

Popularidad de ítems (cola larga)

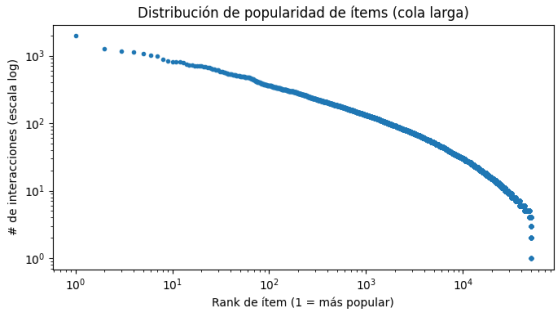

Figure 2. Distribución de popularidad de ítems en escala log-log.

Concentración categorial

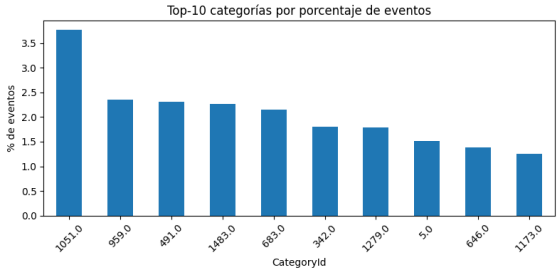

Figure 3. Top-10 categorías por porcentaje de eventos.

Patrones temporales

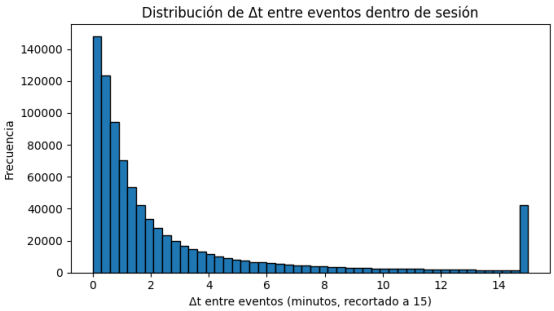

Figure 4. Distribución de intervalos de tiempo entre eventos consecutivos dentro de sesión (recortado a 15 minutos).

7.1.1. Entropía categorial por sesión

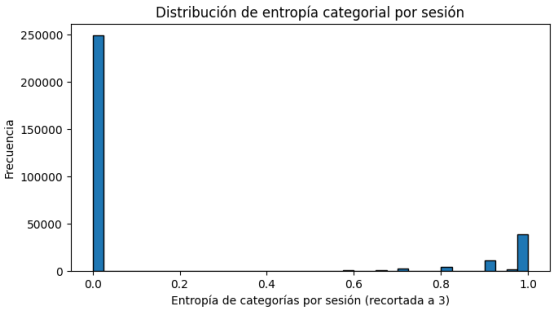

Figure 5. Distribución de entropía categorial por sesión.

7.2. Distribución categorial por tipo de usuario

Usuario de diversidad media GRU4Rec

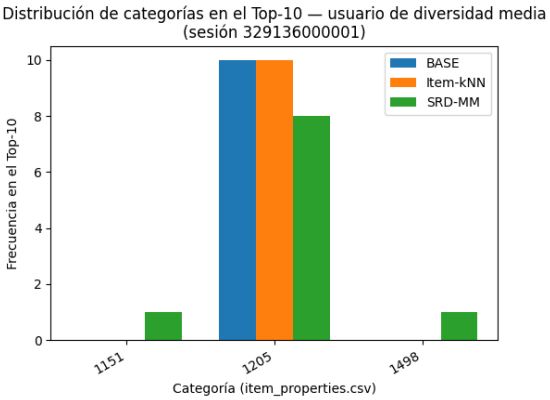

Figure 6. Distribución de categorías en el *Top-10* para un usuario de diversidad media (sesión `329136000001`), comparando BASE, Item-kNN y SRD-MM.