Un sistema híbrido de filtrado colaborativo y basado en contenido para la recomendación de mazos en Clash Royale.

Rodrigo Figueroa [*1] **Martín Sánchez** [*1] **Javiera Larraín** [*1]

Abstract

This document provides a basic paper template and submission guidelines. Abstracts must be a single paragraph, ideally between 4–6 sentences long. Gross violations will trigger corrections at the camera-ready phase.

1. Introducción

La confección de barajas en videojuegos de cartas representa un desafío considerable para jugadores novatos e intermedios, especialmente en títulos dinámicos y con una amplia variedad de opciones disponibles, como es el caso de *Clash Royale*. El constante crecimiento del juego y su extensa base de usuarios motivan la necesidad de desarrollar modelos capaces de recomendar mazos adecuados al estilo e historial de cada jugador.

Clash Royale es un videojuego MOBA de estrategia para dispositivos móviles, basado en la construcción de un mazo de ocho cartas con las cuales los jugadores se enfrentan en tiempo real. Actualmente supera las 662 millones de descargas y cuenta con cerca de 50 millones de jugadores activos diariamente, lo que refleja la magnitud de su comunidad y el nivel de competitividad presente en ella. En este contexto, la construcción de un mazo óptimo puede determinar de forma significativa el desempeño del jugador.

La combinación entre una gran cantidad de usuarios, la amplia oferta de cartas disponibles y el hecho de que cada carta posea un nivel que puede mejorar según el rendimiento del jugador —impactando directamente su efectividad en combate— incrementa la complejidad del proceso de construcción de mazos. Esto puede generar frustración entre jugadores nuevos que buscan aprender a armar configuraciones funcionales y progresar a través de las distintas ligas del juego. A esta complejidad se suma la gestión del *elixir*, el recurso que permite desplegar cartas en el campo de batalla y cuyo costo varía entre ellas.

[*]Equal contribution [1]Escuela de Ingeniería, Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: Rodrigo Figueroa <rodrifigueroac@uc.cl>, Martín Sánchez <martin.sanchez@uc.cl>, Javiera Larraín <javipaz.larrain@uc.cl>.

Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267, 2025. Copyright 2025 by the author(s).

2. Estado del arte

Nuestro trabajo esta estrechamente relacionado con los modelos: LightFM, MultiVAE y DeepFM. Además de relacionarse con el estudio *A User-based Collaborative Filtering System for Deck Recommendation in Game Clash Royale*.

2.1. LightFM

Es la implementación de multiples algoritmos de recomendación implícitos y explícitos, que incorpora metadata de los items y los usuarios en la factorización de las matrices, lo que entrega resultados de alta calidad (**?**).

2.2. MultiVAE

Es una biblioteca que implementa métodos de Multimodal Variational Autoencoders dentro de un marco unificado. Además tiene módulos de métricas para calcular coherencias, verosimilitudes y FID, métricas de reconstrucción y métricas de agrupamiento (**?**).

2.3. DeepFM

Modelo que integra de manera unificada métodos para capturar interacciones de características de bajo y alto orden. Combina un componente Factorization Machine, con un componente profundo. Ambos operan sobre la misma entrada y se entrenan simultáneamente, permitiendo una representación conjunta para mejorar la calidad de las predicciones (**?**).

2.4. Recomendación de mazos en Clash Royale

Desarrollado por Linfeng Zang y Wenyi Luo, y presentado en la *International Conference on Computer Research and Development* de 2022. En dicho trabajo, los autores proponen un sistema de recomendación basado en filtrado colaborativo centrado en el usuario, utilizando información histórica de mazos y comportamientos de jugadores para

identificar similitudes y sugerir configuraciones efectivas. Esta aproximación resulta altamente pertinente para nuestro proyecto, ya que compartimos el objetivo de asistir a los jugadores en la selección de mazos óptimos mediante el análisis de patrones de uso y rendimiento. Sin embargo, el estudio presenta una limitada evaluación experimental, aspecto que buscamos abordar mediante un diseño de experimentos más completo y comparativo. Además, en nuestro trabajo se incorporan variaciones metodológicas, como el uso de frecuencias relativas de cartas y el coeficiente de similitud de Jaccard, lo que nos permite manejar de forma más eficiente la alta dimensionalidad y diversidad de combinaciones posibles dentro del juego (**?**).

3. Base de datos

3.1. Procesamiento de los datos

La información de batalla se obtuvo desde la *API oficial de Clash Royale*, extrayendo registros de jugadores seleccionados aleatoriamente mediante una *API key*. Para cada usuario se construyó un perfil basado en la frecuencia de uso de cartas, el rango promedio y la tasa de victorias, excluyendo jugadores con menos de diez batallas. Tal como señalan (**?**), los métodos clásicos de *Filtrado Colaborativo* enfrentan dos limitaciones: la ausencia de calificaciones explícitas y el enorme espacio de combinaciones posibles (aprox. 8.99×10^{11} mazos), lo que dificulta comparaciones directas entre jugadores.

3.2. Confección de la base de datos

La información fue recopilada mediante la *Royale API*. Se aplicó un filtrado para considerar únicamente jugadores activos, con un historial mínimo de 30 batallas y un rango de trofeos entre 6000 y 8000. Dado que el sistema de progresión del juego abarca desde 0 hasta 15000 trofeos, este intervalo corresponde a un perfil de habilidad intermedio.

Bajo estos criterios, se obtuvieron registros de aproximadamente 3000 jugadores, incluyendo información relevante como el mazo utilizado en cada partida, el resultado (victoria o derrota) y la cantidad de trofeos del jugador, entre otras variables. A partir de estos datos, se identificaron más de 7500 mazos distintos utilizados a lo largo de las partidas analizadas.

3.3. Descripción de los datos

A partir de los 3000 jugadores seleccionados y de los más de 7500 mazos utilizados por ellos, se identificaron los siguientes componentes relevantes dentro de los datos recopilados:

- **PlayerID**: Identificador único del jugador.
- **Trophies**: Cantidad de trofeos obtenidos, indicador directo del nivel.
- **Badges**: Conjunto de logros dentro del juego, tales como maestrías de cartas, desafíos completados y otras distinciones.
- **Cards**: Colección de cartas disponibles para cada jugador, junto con el nivel asociado a cada una de ellas.
- **BattleLog**: Historial de batallas del jugador, que incluye entre 30 y 40 partidas registradas. Para cada batalla se detalla:
  - El mazo utilizado por el jugador.
  - El mazo utilizado por el oponente.

– El resultado de la batalla.

Figure 1. Carta de *Knight*

Además, por cada carta se tienen los siguientes campos:

- **CardID**:Identificador único de la carta.
- **Nombre**
- **Coste de elixir**: Cantidad de elixir que le cuesta al jugador poner a dicha carta en el campo de batalla.
- **Tipo**: Cada carta pertenece a uno de estos cinco tipos: común, especial, epica, legendaria, campeón

En las Figuras 3.3 y 3.3 se presentan las distribuciones del *win rate* y de los trofeos, respectivamente, para los 3000 jugadores que cumplen con los criterios de selección. A partir de estas visualizaciones se aprecia que la probabilidad de victoria para un jugador de nivel intermedio se aproxima al 50%.

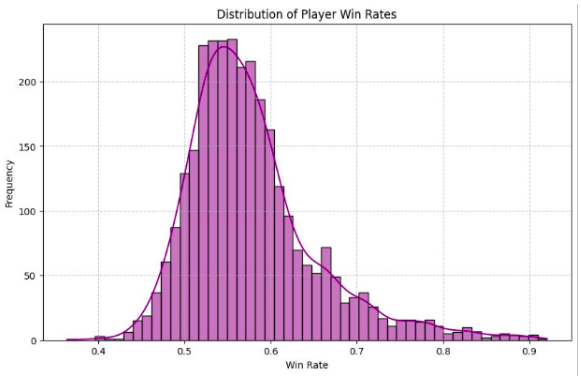

Figure 2. Distribución del *winrate* para los 3000 jugadores selecionados

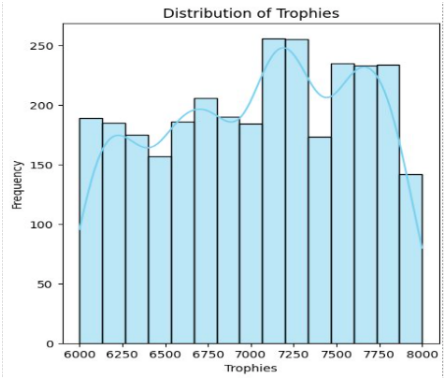

Figure 3. Distribución de los trofeos para los 3000 jugadores selecionados

4. Metodología

En este trabajo se implementaron 3 modelos de recomendación y dos modelos bases para realizar el análisis de los resultados. Tomando como referencia el trabajo de Zang y Luo (**?**), cuyo modelo se basa principalmente en Collaborative Filtering tradicional. Su enfoque consiste en construir perfiles de usuario a partir de historiales de mazos, calcular similitudes entre jugadores y predecir la afinidad hacia posibles mazos mediante ratings inferidos. Como segundo baseline incorporamos una recomendación completamente aleatoria de mazos, que permite establecer un punto de comparación mínimo. Finalmente, para evaluar mejoras sobre estos enfoques, implementamos tres modelos de recomendación basados en filtrado colaborativo, LightFM, MultiVAE y DeepFM.

En este ensayo se dividio el proceso en 6 etapas. 4.1. *Preprocesamiento y filtrado*; 4.2. *Construcción de interacciones y features*; 4.3 *Modelos implementados*; 4.4 *Análisis de hiperparámetros*; 4.5 *Procedimiento Offline*; y 4.6 *Procedimiento Online*.

4.1. Preprocesamiento y filtrado

El winrate ignora factores determinantes como la diferencia de niveles entre mazos y la magnitud de la victoria, lo que introduce sesgos significativos al comparar usuarios con contextos distintos. Es por esto, que utilizando lo anterior, definimos el rating de cada mazo utilizado como:

$$\text{RATING}_{\text{deck}} = \left(\sum_{\text{batallas}} \Delta_{\text{rating}} \right) \cdot \log(1 + \text{plays}) \tag{1}$$

La métrica propuesta se define a nivel de batalla como:

$$\begin{aligned} \text{rating} = 0.5 + 0.5 \cdot \text{battle result} \\ + 0.15 \cdot \text{level difference} + 0.2 \cdot \text{crown difference} \end{aligned} \tag{2}$$

donde *battle result* toma valores entre $\{-1, 1\}$ indica derrota o victoria, *level difference* representa la diferencia promedio de niveles entre los mazos —normalizada para unificar los límites máximos según rareza—, y *crown difference* cuantifica la diferencia de coronas obtenidas.

Los pesos asignados equilibran la contribución relativa de cada término: la victoria tiene el mayor impacto, mientras que las correcciones por nivel (0.15) y coronas (0.2) ajustan la métrica sin sobreponderar factores externos al desempeño estratégico del mazo. El *rating* final de cada mazo se calcula como el promedio de los valores obtenidos en todas sus batallas registradas.

Esta formulación entrega una medida más estable y representativa del rendimiento, al considerar tanto la equidad del enfrentamiento como la magnitud del resultado, constituyendo así una alternativa más informativa que el *win rate* tradicional en escenarios heterogéneos.

4.2. Construcción de interacciones y features

4.3. Modelos implementados

Los modelos implementados en este trabajo consistieron en 3 modelos *state of the art* en recomendaciones por *Collaborative Filtering*, más el modelo creado por Zang y Luo para este caso en especial.

Los modelos de LightFM, MultiVAE y DeepFM fueron entrenados y utilizados para predecir a través de 3 archivos de datos distintos:

- *user_features.csv*: cuenta con una gran gama de información relevante de los usuarios que fueron *scrapeados*. Los datos contenidos por este archivo eran el ID, sus trofeos, el record de trofeos alcanzados, victorias por 3 coronas, nivel de experiencia, arena, y sus distintos niveles de medallas, las cuales indican factores como la maestría con ciertas cartas, victorias en algunos modos de juego, etc.
- *item_features.csv*: cuenta con el ID de cada mazo, junto a el ID de todas sus cartas, el promedio de elixir y la cantidad de tropas, estructuras y hechizos.
- *interactions.csv*: cuenta con una relación ID usuario e ID mazo, indicando que usuario utilizó que mazo, junto a un rating calculado por 1.

4.4. Análisis de hiperparámetros

4.4.1. Hiperparámetros de LightFM

Para el modelo LightFM se emplearon hiperparámetros orientados a equilibrar capacidad expresiva y prevención de sobreajuste. Se utilizaron `NO_COMPONENTS = 30` para definir la dimensionalidad de los *embeddings* de usuarios e ítems, junto con una tasa de aprendizaje de `0.05`. La función de pérdida seleccionada fue `bpr`, adecuada para datos de retroalimentación implícita. El entrenamiento se ejecutó durante `10` épocas utilizando `4` *threads* para acelerar el proceso. Para evitar sobreajuste, se aplicaron términos de regularización L2 tanto para usuarios como para ítems, con valores `ITEM_ALPHA = 1e-6` y `USER_ALPHA = 1e-6`. Esta configuración permite capturar patrones relevantes sin complejidad excesiva.

4.4.2. Hiperparámetros de MultiVAE

El modelo MultiVAE se configuró con una dimensión de entrada y salida de `3006` ítems, correspondiente al total de cartas observadas en la matriz de interacción. La arquitectura

del codificador se definió mediante `q_dims = [3006, 600, 200]`, donde la última capa representa el espacio latente. El decodificador se estructuró simétricamente con `p_dims = [200, 600, 3006]`. Se aplicó *dropout* de `0.5` en la entrada del codificador para mayor robustez. El modelo se entrenó con `batch size = 128`, tasa de aprendizaje `0.005` y `36` épocas. La función de pérdida utilizada combina la negación del *log-likelihood* multinomial con la divergencia de Kullback–Leibler, lo que permite regularizar el espacio latente y mejorar la reconstrucción.

4.4.3. Hiperparámetros de DeepFM

Para DeepFM se utilizaron `19364` características totales, derivadas de las representaciones categóricas de jugadores, mazos y atributos. El modelo considera `22` campos de entrada y utiliza `EMBEDDING_DIM = 32` para las representaciones de cada característica. El componente profundo se estructuró con capas ocultas de `[128, 64]` y una tasa de *dropout* de `0.2` para mitigar sobreajuste. El entrenamiento se realizó con tasa de aprendizaje `0.001` y `24` épocas. La función de pérdida escogida fue `MSELoss`, adecuada para predecir valores continuos asociados al desempeño estimado de cada mazo.

4.5. Procedimiento Offline

Como parte de nuestras métricas *offline*, utilizamos la herramienta de evaluación de mazos provista por *DeckShop*. *DeckShop* es una página web dedicada al juego móvil *Clash Royale*, diseñada para asistir a los jugadores en la búsqueda, construcción y análisis de barajas (**?**). Esta plataforma incluye un evaluador de mazos que, al momento de nuestro estudio, se encontraba actualizado a la temporada de diciembre de 2025. El evaluador asigna calificaciones en cinco dimensiones: *Ataque*, *Defensa*, *Sinergia*, *Versatilidad* y *Puntuación F2P*, esta última indica qué tan fácil es para un jugador progresar sin gastar dinero real. Cada dimensión se clasifica en una escala ordinal compuesta por los niveles *DEP*, *Regular*, *Bueno*, *Genial* y *Divino* (**?**). Utilizamos estas calificaciones para evaluar objetivamente los mazos generados por nuestras distintas estrategias de recomendación, permitiendo así comparar su calidad desde un punto de vista externo y estandarizado.

Figure 4. AGREGAR CAPTION

4.6. Procedimiento Online

Las métricas offline son útiles para orientar la evaluación, pero no consideran cómo juega realmente el usuario con el mazo recomendado. En Clash Royale, la efectividad de un mazo depende tanto de su composición como de la habilidad del jugador, por lo que evaluar solo su estructura resulta insuficiente. Esto hace necesario incorporar métricas online, donde los jugadores prueben directamente las recomendaciones y se observe su rendimiento real en partida.

Para la medición *online*, dos usuarios jugaron cuatro partidas: dos utilizando mazos recomendados por modelos de línea base y dos empleando mazos sugeridos por nuestros modelos. Debido al costo asociado a este tipo de evaluación, se compararon únicamente tres métodos: Zang–Luo, una recomendación aleatoria y DeepFM. La inclusión del modelo aleatorio es relevante porque este tipo de medición no se ha utilizado en trabajos previos, por lo que no existe evidencia de que Zang–Luo supere dicho umbral. Comparar con DeepFM permite, además, evaluar el desempeño frente a nuestro modelo más completo.

5. Resultados

Para medir la calidad de la recomendación se reclutaron cinco usuarios de nivel intermedio, con rangos de trofeos entre 6000 y 8000. Para cada uno de ellos se generaron recomendaciones de mazos utilizando todos los modelos evaluados. Los perfiles de los usuarios se presentan en la Tabla 3.

Table 1. Perfiles de los usuarios utilizados en la evaluación

Perfil	Copas	Nivel torre del rey	Ejemplo de recomendación
P1			
P2			
P3			
P4			
P5			

Figure 5. Foto ejemplo recomendación

5.1. Resultados Offline

	Novelty@10	Diversity@10	MAP@10
Random	0.7000	0.2100	0.5778
Zang y Luo	0.6167	0.2183	0.5202
LightFM	0.5500	0.2450	0.7787
MultiVAE	0.3500	0.2050	0.8141
DeepFM	0.5500	0.2450	0.3780

	nDCG@10	R@10	P@10
Random	0.7921	1.0000	0.3000
Zang y Luo	0.6913	1.0000	0.3833
LightFM	0.9126	1.0000	0.4500
MultiVAE	0.8872	1.0000	0.6500
DeepFM	0.5685	1.0000	0.4500

Table 2. Evaluación de los modelos para recomendación de 10 mazos

5.2. Resultados Online

Table 3. Perfiles de los usuarios utilizados en la evaluación

Modelo	winrate con Zang y Lou	winrate con DeepFM
Usuario1	20%	20%
Usuario2	60%	40%
Usuario3	80%	60%
Usuario4	80%	20%

6. Conclusión

En este trabajo se evaluaron distintos modelos de recomendación para la generación de mazos en *Clash Royale*, empleando un conjunto amplio de métricas *offline* orientadas a capturar no solo la relevancia de los resultados (MAP@10, nDCG@10, Precision@10 y Recall@10), sino también propiedades complementarias como diversidad y novedad. Los resultados muestran que *MultiVAE* se posiciona como el modelo más sólido en términos generales, alcanzando el mejor rendimiento en MAP@10 y un desempeño competitivo en nDCG@10 y precisión, lo que evidencia su capacidad para capturar relaciones latentes entre cartas y construir recomendaciones más coherentes con las preferencias del jugador.

Por otro lado, *LightFM* también exhibe un rendimiento consistente, especialmente en métricas de ranking (nDCG@10), superando a métodos clásicos como Zang y Luo. En contraste, *DeepFM* y el enfoque *baseline* utilizado presentan menores niveles de relevancia, lo que sugiere que su capacidad para modelar interacciones de orden superior es menos eficaz en este dominio específico.