Sistema Recomendador de Noticias

Marco Agüero [*1] **Catalina Court** [*1] **María de las Ángeles Ronfeldt** [*1]

Abstract

In the past years, digital media has had an exponential growth that led into a overload of information, where the personalized content is a critical challenge due to the dynamic and perishable domain of news. This study is a way on implementing a multi-modal news recommendation system using the dataset MIND. The study involves a comparison of different models such as Content-Based Filtering (TF-IDF, Entity Embeddings), Collaborative Filtering (KNN), and Hybrid models (LightFM, DeepFM), with focus on the integration of deep semantic embeddings (BERT).

The results demonstrate that pure content-based models are not enough to predict news and have a lack of diversity. Collaborative approaches struggles with the Cold-Start scenarios. The integration of BERT develops the most significant improvements by capturing semantic relationships, leading to the best performance for category relevance with LightFM-BERT (HitRate@10 95%). However, DeepFM-BERT due to the most robust system and architecture it has a significantly performance on the prediction of the exact news for the user with LightFM-BERT (HitRate@10 8%) and also maximizes the diversity and novelty of the predicted news. In conclusion, combining deep semantic relations and structures capable of modeling feature interactions is very important for solving the trade-off between precision, diversity, exploration and personalization in news recomendation systems.

1. Introducción

El rápido aumento de la información en línea ha permitido a diversos medios de comunicación digitalizarse, promoviendo la venta y suscripción de diarios online. Debido a esto los usuarios presentan una sobrecarga informativa que dificulta identificar los contenidos más relevantes de acuerdo con sus intereses. En este contexto, es imperativo la creación de un sistema de recomendación, permitiendo filtrar y priorizar la diversa información disponible, otorgando a cada suscriptor una experiencia personalizada.

El siguiente informe tiene como finalidad abordar el problema de recomendación de noticias, teniendo en cuenta el comportamiento dinámico de estas debido a que son altamente perecibles y por otro lado la naturaleza multimodal de los datos, los cuales además de tener título y cuerpo, pertenecen cada noticia a una categoría y subcategoría, lo cual permite mejorar la calidad de las recomendaciones.

En la última década, la recomendación de noticias ha sido ampliamente estudiada, explorándose distintas estrategias para personalizar el contenido al usuario. Los enfoques más utilizados son: filtrado colaborativo, que recomienda en función de usuarios con comportamientos similares; filtrado basado en contenido, que utiliza la información del propio ítem (texto, metadatos, imágenes) para identificar elementos similares a los ya consumidos; y métodos híbridos, que combinan ambos enfoques para mejorar precisión y diversidad. En el contexto de noticias, estos algoritmos suelen complementarse con técnicas de procesamiento de lenguaje natural, extracción de entidades o modelado de interacciones, con el fin de capturar mejor las preferencias del usuario y reducir problemas comunes como el cold-start y la falta de historial.(Mittal et al., 2023)

1.1. Problema

A pesar de los avances en los sistemas de recomendación, los enfoques tradicionales no logran capturar adecuadamente la naturaleza dinámica de las preferencias de los usuarios ni las tendencias cambiantes propias del dominio de las noticias. En un escenario donde existe una sobrecarga de información, mantener la relevancia y la diversidad del contenido se vuelve un desafío clave. Por ello, se hace necesario un sistema de recomendación capaz no solo de identificar lo que es de interés para el usuario, sino también de ofrecer variedad y ampliar su exposición a diferentes categorías de noticias.

[*]Equal contribution [1]Departamento de Ciencias de la Computación, Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: Marco Agüero <marco.aguero@uc.cl>, Catalina Court < catalina.court@uc.cl>, María de los Ángeles Ronfeldt <mara.ronfeldt@uc.cl>.

1.2. Objetivos

Evaluar e implementar un Sistema de Recomendación de Noticias basado en enfoques híbridos y multimodales que demuestre un resultados significativos en la precisión de la recomendación de categorías relevantes, utilizando el Dataset Small MIND. (Nabil, 2025)

1.2.1. Objetivos Específicos

- Analizar y comparar rendimiento de modelos de Filtrado Basado en Contenido, estableciendo comparaciones en base de $Precision@K$.
- Implementar a través de modelamiento en código un modelo híbrido que combine información de contenido textual con comportamiento del usuario, aprovechando la multimodalidad del dataset.
- Analizar e integrar el modelo de LightFM para incluir las características de contenido y usuario en un modelo probabilístico.
- Investigar la aplicación de Relation Embeddings para modelar relaciones más complejas entre noticias y entidades.
- Comparar el rendimiento de los modelos híbridos con los modelos base, utilizando las métricas, pudiendo justificar el sistema de recomendación de mayor asertividad.

2. Análisis de los datos

2.1. Dataset

En este proyecto, el cual se puede revisar en el link `https://github.com/CataCourt/Sistema-Recomendador-de-Noticias-G13.git` se utilizaron dos bases de datos **MIND**: `behaviors.tsv` y `news.tsv`. (Nabil, 2025)

El archivo `behaviors.tsv` contiene los registros de impresiones y el historial de clics de los usuarios sobre las noticias. Está compuesto por cinco atributos:

- **Impression ID**: identificador único de cada impresión.
- **User ID**: identificador anónimo de cada usuario.
- **Time**: timestamp en que ocurre la impresión, con formato `MM/DD/YYYY HH:MM:SS AM/PM`.
- **History**: historial de noticias clickeadas previamente por el usuario antes de la impresión, representado como una lista de identificadores de noticias ordenadas por fecha.
- **Impressions**: lista de noticias mostradas en esa impresión, junto con el comportamiento del usuario (1 si hubo clic y 0 en caso contrario).

Por otra parte, el archivo `news.tsv` (o `docs.tsv`) proporciona la información detallada de los artículos de noticias. Consta de siete atributos:

- **News ID**: identificador de la noticia.
- **Category**: categoría principal de la noticia.
- **SubCategory**: subcategoría asociada.
- **Title**: título del artículo.
- **Abstract**: resumen del artículo.
- **URL**: dirección web del artículo.
- **Title Entities** y **Abstract Entities**: entidades extraídas del título y del resumen, respectivamente.

Estos dos archivos en conjunto permiten reconstruir tanto el contexto de interacción de los usuarios como la información semántica de las noticias, habilitando la implementación de modelos de recomendación multimodales que combinan señales de comportamiento histórico con características de contenido.

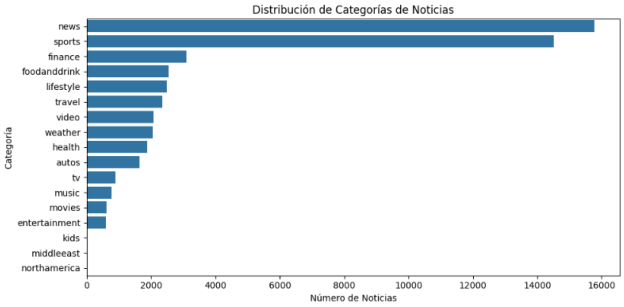

Figure 1. Frecuencia de Categorías

En este dataset, la mayoría de los artículos corresponden a la categoria “news” y a la de “sports”, en el gráfico anterior se puede ver la distribución de las categorías, este gráfico inspirado del estudio de Ghiffari Kenang. (Sagraha, 2025)
En este dataset, la mayoría de los artículos corresponden a la categoria “news” y a la de “sports”, en el gráfico anterior se puede ver la distribución de las categorías, este gráfico inspirado del estudio de Ghiffari Kenang. (Sagraha, 2025)

Además cada noticia posee una subcategoría, en donde la principal es “newus”, las cuales son noticias de estados unidos, debido a la procedencia del dataset. En el gráfico de

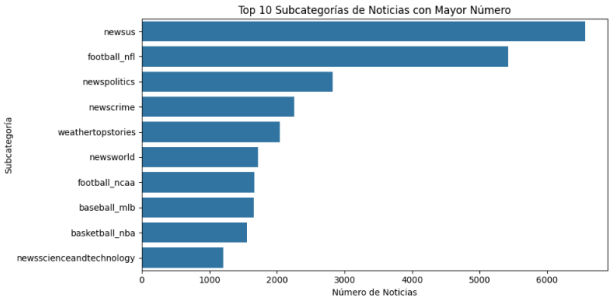

Figure 2. Frecuencia de Subcategorías (top 10)

barras , se muestran las primeras 10 subcategorías de mayor frecuencia. (Sagraha, 2025)

Por otro lado, el análisis del dataset evidencia que los títulos de las noticias presentan una longitud promedio acotada, compuesta aproximadamente por diez palabras, en un volumen cercano a las 14.000 noticias. Esta característica tiene implicancias directas en la implementación de los modelos de recomendación basados en contenido. Al tratarse de textos breves, la cantidad de información disponible por cada noticia es limitada, lo que reduce la diversidad de términos que el modelo puede utilizar para construir sus representaciones vectoriales. En consecuencia, cuando los títulos son demasiado cortos, los algoritmos como TF-IDF o los métodos que dependen exclusivamente de coincidencias textuales pueden tener dificultades para capturar diferencias significativas entre noticias que comparten palabras comunes o estructuras similares. Esta situación puede afectar la capacidad del sistema para distinguir adecuadamente entre noticias relacionadas y no relacionadas, generando recomendaciones más homogéneas o con menor capacidad de exploración temática. La distribución de la longitud de los títulos y su concentración se puede ver en el siguiente gráfico. (Sagraha, 2025)

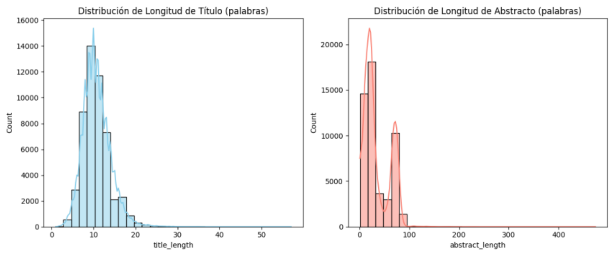

Figure 3. Distribución de la longitud de título y abstracto

3. Métodos aplicados

3.1. CBF TF IDF

Para el método Content-Based Filtering, se construyen representaciones numéricas de cada noticia utilizando TF-IDF. Para esto se combina el título y el abstract de la noticia en un único texto y se aplica un vectorizador TF-IDF que elimina stopwords y limita el vocabulario a un número máximo de términos relevantes. El resultado es una matriz donde cada noticia queda representada como un vector con el peso de sus palabras más significativas, permitiendo luego calcular similitudes entre noticias y recomendar aquellas cuyo contenido es más parecido a lo que el usuario ha consumido previamente. Se junta el título con el abstract, luego de esto se aplica el vectorizador. En el siguiente ejemplo, el modelo recomienda noticias cuyo contenido es muy similar a la noticia consultada. Se observa que las cinco recomendaciones pertenecen a la misma categoría (*lifestyle*) y mantienen la misma temática asociada a la realeza. Esto muestra que el modelo identifica noticias con textos relacionados y sugiere artículos consistentes en estilo y foco editorial.

En el siguiente ejemplo, el modelo recomienda noticias cuyo contenido es muy similar a la noticia consultada. Se observa que las recomendaciones pertenecen a la misma categoría (*lifestyle*) y mantienen la misma temática asociada a la realeza, mostrando que el modelo identifica artículos con alta coherencia temática.

NewsID	Title	Category	SubCategory
N9056	This Is What Queen Elizabeth Is Doing About th...	lifestyle	lifestyleroyals
N38133	The cutest photos of royal children and their ...	lifestyle	lifestyleroyals
N43522	Prince Charles is Getting Into Fashion	lifestyle	lifestylevideo
N60671	Prince Charles Teared Up When Prince William T...	lifestyle	lifestyleroyals
N63823	Prince Charles Hit by One of the Most Incredib...	lifestyle	lifestyleroyals

Table 1. Recomendaciones obtenidas utilizando CBF TF-IDF.

3.2. CBF Entity Embeddings

Para el método Content-Based Filtering con Entity Embeddings, las entidades detectadas en cada noticia (personas, organizaciones, lugares, etc.) se convierten en vectores usando embeddings preentrenados. Si una noticia tiene más de una entidad, los vectores correspondientes se promedian para obtener un único embedding representativo. Finalmente, todos estos vectores se apilan en una matriz de entidades (entity_matrix), donde cada fila corresponde a una noticia y cada columna a una dimensión del embedding (en este caso, una matriz de tamaño $(48\,612 \times 100)$). Esta matriz permite calcular similitudes entre noticias en función de sus entidades, independientemente del texto completo.

En este ejemplo, el modelo recomienda noticias basadas en las entidades presentes en la noticia consultada. Todas las recomendaciones pertenecen a la misma categoría (*lifestyle*) y subcategoría relacionada con la realeza, lo que indica que el modelo identifica similitud semántica entre artículos que mencionan a los mismos personajes y temas asociados.

NewsID	Title	Category	SubCategory
N38133	The cutest photos of royal children and their ...	lifestyle	lifestyleroyals
N39683	Prince Charles just turned 71 here are the b...	lifestyle	lifestyleroyals
N42777	Prince George's Royal Life in Photos	lifestyle	lifestyleroyals
N63495	65 Photos of Prince Charles You've Probably Ne...	lifestyle	lifestyleroyals
N64143	Adorable Moments Between Queen Elizabeth and H...	lifestyle	lifestyleroyals

Table 2. Recomendaciones obtenidas utilizando CBF con Entity Embeddings.

3.3. Modelo Híbrido

Para el modelo híbrido con LightFM, se integran simultáneamente las interacciones usuario–noticia y las características de contenido. Primero, se construye la matriz de interacciones a partir del historial real de lecturas de los usuarios. Luego, se generan características de cada noticia utilizando las palabras relevantes obtenidas desde TF-IDF, que se transforman en un conjunto de item features. LightFM combina ambos tipos de información (colaborativa y de contenido) y aprende representaciones latentes para usuarios y noticias mediante un modelo de factorización con pérdida WARP, optimizada para recomendaciones Top-N. Finalmente, el modelo entrena durante varias épocas utilizando múltiples núcleos disponibles, permitiendo recomendar noticias incluso cuando un usuario tiene pocas interacciones históricas (cold-start). En este ejemplo, el modelo híbrido recomienda noticias combinando información de contenido y de comportamiento del usuario. Se pueden observar recomendaciones provenientes de distintas categorías (*news*, *sports* y *lifestyle*), lo que muestra que el modelo es capaz de incorporar la historia del usuario y, al mismo tiempo, mantener diversidad temática en las sugerencias.

NewsID	Title	Category	SubCategory
N55244	A Brief History of Royals Wearing Denim	lifestyle	lifestylebuzz
N42227	Queen Elizabeth's Favorite Beauty Products Hav...	lifestyle	lifestyleroyals
N34718	This is Who Can Wear and Borrow the Crown Jewe...	lifestyle	lifestylevideo
N39208	21 Things You Never Knew About America's 'Roya...	lifestyle	lifestylesmartliving
N24668	101 Photos of the Youngest Royals Hanging Out ...	lifestyle	lifestyleroyals

Table 3. Recomendaciones obtenidas utilizando CBF–BERT.

3.4. CBF con BERT

Con el objetivo de capturar relaciones semánticas más profundas entre las noticias, se implementó un modelo Content-Based Filtering utilizando embeddings generados mediante el modelo `all-MiniLM-L6-v2` de la librería *Sentence-Transformers*. Para cada noticia se concatenó su título y abstract en un único texto, el cual fue luego transformado en un vector denso de 384 dimensiones. Esto permitió construir una matriz de representaciones de forma aproximada $(48{,}612 \times 384)$.

A diferencia del modelo TF-IDF, que depende explícitamente de la frecuencia de términos, los embeddings BERT incorporan contexto y relaciones semánticas, permitiendo identificar similitud incluso cuando no existe coincidencia literal de vocabulario. Con esta matriz se calcularon similitudes coseno entre noticias, generando recomendaciones basadas exclusivamente en contenido.

Si bien este modelo mejora la coherencia semántica respecto al CBF tradicional, sigue heredando su limitación principal: tiende a recomendar noticias conceptualmente similares, manteniendo alta precisión pero menor diversidad temática.

En el siguiente ejemplo, el modelo recomienda noticias cuyo contenido es altamente similar a la noticia consultada. Se observa que todas las recomendaciones pertenecen a la categoría *lifestyle* y mantienen temáticas asociadas a la realeza, mostrando que el modelo identifica artículos con fuerte coherencia semántica.

NewsID	Title	Category	SubCategory
N6099	How the Trump Administration Eroded Its Own Le...	news	newsus
N46526	Ilhan Omar blasts Pete King as an 'Islamophobe...	news	elections-2020-us
N55689	Charles Rogers, former Michigan State football...	sports	football_nfl
N34876	Jennifer Lopez Debuted the Sleek Seasonal Bob ...	lifestyle	lifestyleceleb style
N35729	Porsche launches into second story of New Jers...	news	newsus

Table 4. Recomendaciones obtenidas utilizando el modelo híbrido LightFM + TF-IDF.

3.5. Modelo Híbrido LightFM con BERT

Se extendió el modelo híbrido LightFM incorporando embeddings BERT como *item features*, con el fin de enriquecer la representación de cada noticia mediante información semántica profunda. Primero, se generaron vectores densos de 384 dimensiones para cada noticia utilizando el modelo `all-MiniLM-L6-v2`. A estas dimensiones se les asignaron nombres explícitos del tipo `bert_dim_i` para integrarlas correctamente en el esquema de características continuas de LightFM.

Posteriormente, estos vectores se combinaron con metadatos categóricos como *Category* y *SubCategory*, creando para cada noticia un conjunto de características mixtas (continuas y categóricas). La matriz de interacciones se mantuvo igual que en el modelo híbrido original, pero con un espacio de características significativamente más expresivo.

El modelo fue entrenado utilizando la función de pérdida WARP, optimizada para recomendaciones Top–N, con 30 componentes latentes. La incorporación de embeddings BERT permitió capturar relaciones más complejas entre usuarios y noticias, mejorando la diversidad de las recomendaciones e incrementando la capacidad del modelo para enfrentar escenarios de *cold–start*. En la siguiente tabla se presentan las recomendaciones:

NewsID	Title	Category	SubCategory
N47020	The News In Cartoons	news	newsopinion
N1034	'Baby Trump' balloon slashed at Alabama appe...	news	newsus
N25791	Opinions | We thought Trump was the biggest co...	news	newsopinion
N35729	Porsche launches into second story of New Jers...	news	newsus
N57005	This Is The Moment A Senior Shelter Dog Knew H...	news	newsgoodnews

Table 5. Recomendaciones obtenidas utilizando el modelo híbrido LightFM–BERT.

3.6. DeepFM con Features BERT

Finalmente, se implementó un modelo DeepFM (Pontificia Universidad Católica de Chile, 2025), un enfoque profundo que combina un módulo Factorization Machine para aprender interacciones de segundo orden y una red neuronal profunda para capturar relaciones no lineales entre características. Este modelo es especialmente adecuado cuando existen tanto atributos categóricos como vectores densos, como en el caso de embeddings BERT.

Primero, se construyó un catálogo único de noticias que incluía *NewsID*, categoría y subcategoría. Estos atributos fueron codificados mediante *label encoding* para optimizar la velocidad de entrenamiento. Paralelamente, las representaciones BERT fueron incorporadas como vectores continuos preprocesados mediante una reducción de dimensionalidad PCA, obteniendo 32 características continuas por noticia.

Para cada usuario se generó un diccionario de entrada que contenía el identificador del usuario, los códigos de noticia y los atributos categóricos, además de las componentes PCA del embedding BERT. El modelo predijo una probabilidad de afinidad usuario–noticia para cada ítem del catálogo, y posteriormente estas predicciones fueron ordenadas para seleccionar las recomendaciones Top–N.

DeepFM permitió modelar interacciones complejas entre las características de usuario y noticia, mostrando mayor expresividad que los modelos lineales o de factorización pura, especialmente en escenarios con información multimodal. A continuación se adjuntan las recomendaciones entregadas por el modelo:

NewsID	Title	Category	SubCategory
N58728	How Patriots had good Sunday despite being on ...	sports	football_nfl
N45700	Why the Chiefs are struggling to finish off re...	sports	football_nfl
N35680	Bengals cut candidates who could follow Presto...	sports	football_nfl
N5038	Ryan Clark makes a lofty comparison for the 20...	sports	football_nfl
N25791	Opinions | We thought Trump was the biggest co...	news	newsopinion

Table 6. Recomendaciones obtenidas utilizando el modelo DeepFM.

4. Discusión

En esta sección se analizan comparativamente los modelos implementados, considerando tres dimensiones principales: (1) la predicción exacta de noticias, (2) la predicción según categorías relevantes, y (3) métricas de novedad y diversidad. Estas dimensiones permiten evaluar no solo la capacidad de recomendar la noticia específica consumida por el usuario, sino también la habilidad de los modelos para mantener coherencia temática, promover exploración y evitar recomendaciones redundantes.

4.1. Predicción exacta de noticias

La predicción exacta consiste en identificar la misma noticia leída por el usuario en el conjunto de prueba. Este es un escenario altamente exigente debido al gran volumen de noticias del dataset y a la alta perecibilidad del dominio. En este contexto, solo los modelos híbridos logran obtener valores distintos de cero.

Modelo	Hit Rate@10	Recall@10	Precisión@10
DeepFM–BERT	8.00%	4.12%	0.80%
LightFM–BERT	7.00%	3.75%	0.70%
LightFM TF–IDF	5.00%	2.58%	0.50%
CF KNN	0.00%	0.00%	0.00%
CBF TF–IDF	0.00%	0.00%	0.00%
CBF BERT	0.00%	0.00%	0.00%

Table 7. Resultados de predicción exacta de noticias.

Los resultados muestran que los modelos basados únicamente en contenido o filtrado colaborativo no son capaces de recuperar la noticia exacta. Esto se explica porque estos modelos privilegian similitud semántica (CBF) o patrones de usuarios similares (CF), pero no combinan ambas señales. En contraste, los modelos híbridos integran comportamiento histórico y contenido, permitiendo capturar relaciones usuario–ítem más específicas. El mejor resultado lo obtiene DeepFM–BERT, reflejando su capacidad para modelar interacciones no lineales entre múltiples tipos de características.

4.2. Predicción según categorías relevantes

En este escenario, la métrica evalúa si el modelo logra recomendar noticias pertenecientes a la categoría correcta, independientemente del título específico. Este enfoque es más flexible y está alineado con la forma en que funcionan los sistemas de recomendación reales (p. ej., recomendar noticias del mismo tópico).

Modelo	Hit Rate@10	Recall@10	Precisión@10
LightFM–BERT	95.00%	65.40%	42.00%
DeepFM–BERT	92.00%	57.25%	39.20%
CF KNN	90.00%	57.34%	35.23%
CBF TF–IDF	90.00%	43.68%	45.78%
CBF BERT	87.00%	35.06%	41.78%

Table 8. Resultados por categorías relevantes.

Los modelos CBF alcanzan las mejores precisiones, lo que refleja su coherencia temática, aunque sacrifican diversidad. El filtrado colaborativo (CF KNN) obtiene el mayor *recall* entre los modelos no híbridos, dado que explora un mayor espacio de noticias relevantes.

Los enfoques híbridos —en especial LightFM–BERT— logran el mejor rendimiento global. La incorporación de embeddings semánticos mejora significativamente la representación de contenido, permitiendo al modelo sugerir noticias diversas sin perder coherencia temática.

4.3. Novedad y diversidad

Las métricas de novedad y diversidad miden la capacidad del sistema para evitar recomendaciones redundantes y promover exposición a nuevo contenido. Estas métricas son fundamentales en dominios como noticias, donde los usuarios pueden saturarse rápidamente de información similar.

Modelo	Avg. Novelty	Avg. Diversity
DeepFM–BERT	0.1186	0.0166
LightFM–BERT	0.0988	0.0152
LightFM TF–IDF	0.0780	0.0132
CBF BERT	0.0682	0.0104
CBF TF–IDF	0.0624	0.0098
CF KNN	0.0601	0.0095

Table 9. Métricas de Novedad y Diversidad.

Los resultados muestran que los modelos híbridos —especialmente DeepFM–BERT— producen recomendaciones más variadas y novedosas. Esto se debe a que DeepFM captura interacciones de alto orden entre embeddings, categorías y comportamiento del usuario, lo que le permite recomendar noticias relevantes pero no triviales.

4.4. Conclusión de la discusión

Los resultados obtenidos permiten afirmar que:

- Los modelos exclusivamente basados en contenido o colaborativos no son suficientes para capturar la complejidad del dominio de noticias.
- Los modelos híbridos, especialmente aquellos enriquecidos con embeddings BERT, muestran un rendimiento superior en todos los escenarios evaluados.
- DeepFM–BERT destaca en predicción exacta, diversidad y novedad, lo que lo posiciona como el modelo más robusto del estudio.
- LightFM–BERT logra el mejor rendimiento en predicción por categorías, equilibrando precisión y diversidad.
- Los métodos CBF siguen siendo útiles cuando el objetivo principal es mantener coherencia semántica estricta.

En conjunto, los resultados demuestran que la incorporación de representaciones semánticas profundas y modelos híbridos avanzados permite capturar de mejor forma las preferencias dinámicas de los usuarios en sistemas de recomendación de noticias.

5. Conclusiones

A partir de la experimentación realizada con los distintos enfoques de recomendación filtrado basado en contenido (CBF TF-IDF y CBF con Entity Embeddings), filtrado colaborativo (CF KNN), los modelos híbridos (LightFM + TF-IDF, LightFM + BERT y DeepFM + BERT) es posible establecer conclusiones respecto a su comportamiento y desempeño en el ámbito de recomendación de noticias.

En primer lugar, los modelos Content-Based Filtering demostraron ser eficaces para mantener coherencia temática en las recomendaciones, priorizando precisión y consistencia semántica, pero presentaron limitaciones estructurales. Debido a la naturaleza breve y poco informativa de los títulos del dataset en promedio 10 palabras por noticia, según el análisis realizado en el informe estos modelos tienden a recomendar ´´más de lo mismo”, limitando la diversidad del contenido sugerido. Esto se refleja en sus resultados: altos valores de *Precision@10*, pero menores en *Recall@10*, ya que, recuperan pocos artículos distintos dentro del Top–10. A través de la incorporación de embeddings con BERT se pudo mitigar este problema, logrando capturar las relaciones semánticas.

Por el contrario, el modelo colaborativo (CF KNN) mostró una fuerte capacidad de exploración, obteniendo mayores números de *Recall@10*, en comparación con los modelos puramente basados en contenido. Sin embargo, esto ocurre a costa de una menor precisión, al privilegiar la similitud entre usuarios por sobre la similitud entre noticias. Este comportamiento evidencia la sensibilidad del filtrado colaborativo al volumen de interacciones disponibles, afectándose particularmente en escenarios de cold–start y la incapacidad de obbtener las noticias exactas en escenarios de alta dispersión.

En los modelos híbridos se observaron los resultados más significativos, en donde la combinación de representaciones semánticas fue clave para esto:

- **LightFM + BERT:** fue el modelo con mejor rendimiento en términos de interacción general, alcanzando el mayor *HitRate@10* de 95% y un número de *Precision@10* de 42%, en los resultados por categoría. Esto demuestra que la combinación de embeddings matriciales y la estrategia de busqueda de contenido relevante en la lista de recomendaciones es lo más eficiente.

- **DeepFM + BERT:** este modelo presenta la estructura y arquitectura más robusta para capturar la complejidad de las noticias y el usuario. Este modelo destacó en la métrica más exigente, teniendo una predicción mayor y el mayor *HitRate@10* de 8% en la predicción por noticia específica. Con respecto a las métricas de Novedad y Diversidad este modelo se caracterizó por tener los mejores resultados por noticia específica, evitando la redundancia y ofreciendo diversos géneros al usuario.

Este resultado demuestra que la incorporación de señales colaborativas y de contenido permite no solo sugerir noticias similares, sino identificar noticias concretas asociadas a preferencias individuales.

En resumen, los resultados permiten concluir que los métodos exclusivamente basados en contenido o en comportamiento son insuficientes para capturar completamente la dinámica del dominio de noticias. El modelo híbrido de DeepFM-BERT se posiciona como la alternativa más robusta, equilibrando precisión, diversidad y personalización, y resolviendo de mejor manera los desafíos que el problema de recomendación de noticias trae consigo.

References

Mittal, A., Singh, R. K., Khare, R., Gautam, V., and Goyal, A. Exploring the impact of financial literacy on individual investment decisions through mediation of financial knowledge and risk tolerance. *Financial Innovation*, 9(1):207, 2023. doi: 10.1007/s44196-023-00315-5. URL https://link.springer.com/article/10.1007/s44196-023-00315-5.

Nabil, M. News recommendations system. Kaggle Notebook, 2025. URL https://www.kaggle.com/code/minanabil11111212/news-recommendations-system. Accedido: 1 de Noviembre de 2025.

Pontificia Universidad Católica de Chile. Práctico deepfm. https://github.com/PUC-RecSys-Class/RecSysPUC-2025-2/blob/master/practicos/07_deepfm.ipynb, 2025. Código y materiales del curso de Sistemas Recomendadores 2025; Accedido: 9 de diciembre de 2025.

Sagraha, G. K. Mc855d5y1169: News recommendation system. Kaggle Notebook, 2025. URL https://www.kaggle.com/code/mendhiri/mc855d5y1169-news-recommendation-system. Accedido: 3 de Noviembre de 2025.