Calidad vs CO_2 en sistemas recomendadores: un análisis de eficiencia climática

Juan Felipe Tachack Suarez
jtachacks@estudiante.uc.cl

Cristóbal Saravia
csaravia@uc.cl

Código fuente: `https://github.com/cristobalSaravia/Proyecto-Recsys`

***Abstract*— We study the trade-off between recommendation quality and training carbon footprint. Using a reproducible pipeline on MovieLens-1M (with Book-Crossing as contrast), we evaluate collaborative models (ALS, BPR) and neural models (DeepFM, MultiVAE) with Top-N ranking metrics (MAP@10, nDCG@10), diversity, and novelty. We define climate-efficiency metrics that normalize quality gains by training CO_2e and trace quality–CO_2e Pareto frontiers. Results show that lightweight ALS (few factors, moderate regularization) consistently lies on the efficient frontier, while increasing latent dimensionality raises emissions without proportional ranking gains. DeepFM exhibits flatter frontiers—higher CO_2e buys small quality improvements—whereas MultiVAE highlights instability of efficiency metrics in very low-emission regimes. Overall, the evidence favors simple, well-regularized configurations when the objective is to maximize quality per gram of CO_2e and provides a practical framework to compare recommenders under simultaneous performance and sustainability criteria.**

I. Introducción

Este documento presenta la metodología de experimentación para evaluar diferentes algoritmos de sistemas recomendadores y obtener sus principales resultados. El enfoque considera la generación de listas Top-N, la evaluación con métricas de ranking y la medición de la eficiencia climática (calidad/CO2) para comparar configuraciones e identificar una frontera de Pareto entre desempeño y costo de carbono. Además, se describe cada modelo y sus hiperparámetros, el procedimiento experimental, la obtención de resultados y su discusión, con el objetivo de seleccionar el mejor modelo y la configuración de hiperparámetros de acuerdo con el criterio de eficiencia climática. En la primera parte se definen cuatro métricas con las que se evaluaron los modelos: AP@K, nDCG@K, diversidad y novedad. Para la experimentación se utilizó el dataset MovieLens 1m, constituida por 1,000,209 registros de calificaciones dadas por diferentes usuarios para distintas películas. A modo de comparación. también se utilizó el dataset Book-crossing, que contiene 1,149,779 calificaciones de libros. Se realizó una caracterización de la base de datos y se obtuvieron métricas y gráficos asociados a su contenido.Esta base de datos se dividió en entrenamiento, validación y test. Se adecuó para los requisitos de parámetros de entrada de las funciones, de acuerdo con los modelos. Se creó una función reutilizable para obtener las recomendaciones de los modelos y otra para obtener el promedio de las cuatro métricas ya definidas. Se obtuvieron resultados para un recomendador base basado en popularidad como experimento inicial. Se implementó el modelo ALS con varios hiperparámetros y se iteró sobre cada uno de ellos para calcular la eficiencia/CO2; este procedimiento se repitió para BPR y DeepFM. Después, se filtró para obtener el modelo con menor CO2 para las métricas nDCG y MAP, y se generaron gráficos que muestran la frontera entre desempeño (según las métricas) y consumo de CO2. Finalmente, se presentan los modelos con mejor rendimiento junto con los hiperparámetros utilizados.

II. Estado del arte

La evolución reciente de los sistemas recomendadores muestra una tendencia clara hacia arquitecturas cada vez más complejas y de mayor tamaño desde variantes sofisticadas de factorización hasta modelos profundos y basados en Transformers [1], [2]. En paralelo, el nuevo paradigma *Green AI* establece no solo la necesidad de reportar métricas de desempeño, sino también tiempo, energía y emisiones, con el fin de lograr una sostenibilidad [3], [4]. Estudios sobre el coste real del entrenamiento evidencian que las emisiones dependen fuertemente del hardware, la región (intensidad de carbono), la duración y el escalado del modelo lo que lleva a diferencias en los resultados dadas distintas configuraciones y prácticas [4], [5]; sin embargo, dichas evaluaciones suelen concentrarse en PLN/visión y emplear supuestos promedios, limitando su transferibilidad y granularidad para recomendación. Frente a ello, nacen métricas de eficiencia que normalizan la ganancia de calidad por el CO_2e consumido y la referencian respecto a una línea base (p. ej., aleatoria), lo que habilita comparar "calidad por gramo de CO_2e" entre modelos y datasets [6]. Aunque herramientas como CarbonTracker y CodeCarbon han mejorado la trazabilidad (hardware, energía, intensidad de carbono), persiste la falta de estandarización de protocolos qué fases incluir (entrenamiento/inferencia), cómo normalizar por tamaño de datos o *early stopping*, y cómo homogeneizar intensidades regionales dificultando la comparabilidad directa [7], [8]. En este contexto, nuestro trabajo busca aportar mediante el análisis explícito de *fronteras calidad–CO_2e* en recomendación: definimos métricas de eficiencia basadas en ganancia relativa al *baseline* aleatorio, y caracterizamos configuraciones no dominadas (Pareto) para estudiar el *trade-off* entre ranking y huella climática, avanzando hacia prácticas reproducibles que integren calidad y sostenibilidad.

III. Solucion propuesta

III-A. Objetivo y enfoque general

Proponemos un *pipeline* reproducible para evaluar algoritmos de recomendación desde dos ejes complementarios: (i) la calidad de ranking en listas Top-N y (ii) la eficiencia climática, entendida como la razón calidad/CO_2. Nuestro objetivo es seleccionar, para cada modelo, la configuración de hiperparámetros que maximiza el desempeño con el menor costo de carbono, trazando así la frontera calidad–CO_2e y priorizando configuraciones no dominadas.

III-B. Preparación de datos

III-B.1. MovieLens-1M: Trabajamos con MovieLens-1M (1 000 209 calificaciones) utilizando el dataset prácticamente "tal cual", resolviendo únicamente detalles de codificación y separación de columnas para estandarizar el flujo de trabajo. A partir de los identificadores originales construimos mapeos densos de usuarios e ítems (`user_id_map` y `item_id_map`) que reindexan a rangos continuos $0..U-1$ y $0..I-1$. Sobre esta base, definimos la *relevancia* binaria mapeando cada interacción a 1 si el *rating* es mayor o igual a 3 (y a 0 en caso contrario), lo que habilita una evaluación Top-N coherente con retroalimentación implícita. Para el entrenamiento construimos una matriz dispersa usuario×ítem en formato `csr_matrix` con los valores de *rating*; en paralelo derivamos metadatos de catálogo: un diccionario `item_genre_dict` con los géneros por película (usado para medir diversidad) y `item_popularity_dict` con la popularidad empírica (usado para novedad). Esta representación unifica el procesamiento y permite comparar modelos bajo un mismo protocolo experimental.

III-B.2. Book-Crossing: Como contraste, utilizamos Book-Crossing (1 149 799 calificaciones) armonizando su esquema para reutilizar el formato anterior. Estandarizamos nombres de columnas y conectamos las calificaciones con la tabla de libros mediante `isbn`, de forma que el *join* produzca una vista consistente de usuarios e ítems. Al igual que en MovieLens, generamos mapeos densos `user_id_map` e `item_id_map` y definimos la *relevancia* como 1 si el *rating* es mayor o igual a 5 (y 0 en otro caso), ajustando el umbral a la escala de este conjunto. Para el entrenamiento, construimos la matriz dispersa usuario×ítem en `csr_matrix`. En cuanto a metadatos, utilizamos los autores como proxy de "género" para la medición de diversidad (vía `item_genre_dict`) y calculamos la popularidad empírica por ítem (`item_popularity_dict`) para estimar novedad. Esta estandarización facilita comparar resultados entre dominios (películas vs. libros) manteniendo invariable el protocolo de evaluación y el cálculo de eficiencia climática.

IV. Metodología

Evaluamos recomendadores bajo ranking Top-N y eficiencia climática mediante un pipeline reproducible aplicado a MovieLens-1M y Book-Crossing. A partir de los ratings generamos índices densos de usuario e ítem, definimos relevancia binaria acorde al dominio (MovieLens: rating ≥ 3; Book-Crossing: rating ≥ 5) y construimos una matriz dispersa usuario×ítem; luego particionamos en ∼60/20/20 (entrenamiento/validación/prueba) preservando mapeos y *ground truth* por usuario. Comparamos líneas base (Popular, Random), factorización implícita (ALS, BPR) y un modelo neuronal (DeepFM); para ALS y BPR exploramos cuadrículas compactas en número de factores y regularización (manteniendo el resto estable), y en DeepFM variamos tamaño de *embedding*, tasa de aprendizaje y *batch size*. La calidad se mide con MAP@10 y nDCG@10 (promedio por usuario), complementadas con diversidad y novedad; sobre ellas definimos métricas de eficiencia climática normalizando la ganancia respecto al baseline aleatorio por el carbono emitido: MAP-C $=$ (MAP@10 $-$ MAP_{rand})/$CO_2e \cdot 100\,\%$ y nDCG-C $=$ (nDCG@10 $-$ $\text{nDCG}_{\text{rand}}$)/$CO_2e \cdot 100\,\%$, donde valores mayores indican más calidad por gramo. Las emisiones se registran con `CodeCarbon`, distinguiendo CPU y GPU para capturar diferencias reales de potencia e intensidad de carbono regional; con los pares {calidad, CO_2e} construimos la frontera de Pareto y reportamos configuraciones no dominadas que estiman la ganancia marginal de calidad por incremento de CO_2e.

V. Parámetros

Para cada modelo se probó con una variedad de configuraciones de hiperparámetros para obtener datos sobre la performance de los modelos en la tarea de ranking y sus emisiones de carbono.

V-A. ALS

Para ALS se probaron combinaciones de factores latentes y factores de regularización:

- **Factores**: 30, 50, 100, 150, 200
- **Regularización**: 0.0001, 0.001, 0.01, 0.1

V-B. DeepFM

Para DeepFM se probaron combinaciones de embedding size, batch size y learning rate. Se utilizó un valor fijo para las epochs de 5.

- **Embedding size**: 8, 16, 32, 64
- **Batch size**: 512, 1024
- **Learning rate**: 0.001, 0.0001

V-C. MultiVAE

Para DeepFM se probaron combinaciones para la dimensión del cuello de botella ($hidden_dim$), learning rate, batch size, weight decay, dropout rate del encoder y epochs. Para la dimension de capa oculta (intermediate dim), se utilizó el valor fijo de 400.

- **Hidden dim**: 50, 100
- **Learning rate**: 0.000001, 0.00001
- **dropout rate**: 0.2, 0.5, 0.8
- **Batch size**: 512, 1024
- **weight decay**: 0.0, 0.0001
- **epochs**: 10, 20

VI. Resultados

VI-A. *Baselines*

Primero, se obtienen los resultados para las métricas de calidad para los baselines Random y Most Popular sobre dos datasets. Recordar que el baseline Random se utiliza para los calculos de eficiencia.

TABLE I

Resultados de los baselines en MovieLens 1M.

Modelo	MAP@10	nDCG@10	Div.	Nov.
Most Popular	0,218	0,310	9,00	8,49
Random	0,0248	0,0383	8,69	13,3

TABLE II

Resultados de los baselines en Book-Crossing.

Modelo	MAP@10	nDCG@10	Div.	Nov.
Most Popular	0,0212	0,0266	9,00	10,3
Random	0,000144	0,000205	9,99	18,8

VI-B. *ALS MovieLens 1m*

Para ALS se obtuvo una configuración no dominada para las métricas de calidad y CO_2E. Esta configuración corresponde a ALS con 30 factores latentes y regularización de 0.1. Configuraciones con más factores tienen peor valor de las métricas de calidad MAP@10 y NDCG@10, y configuraciones con los mismos factores pero regularización más pequeña tienen prácticamente el mismo performance para las métricas de calidad, pero tienen emisiones de carbono mayores.

TABLE III

ALS MovieLens 1m: Mejores modelos para NDCG-C y MAP-C.

Modelo	Valor de la Eficiencia (%)	Factores	Regularización
Modelo con mejor NDCG-C	47100	30	0,1
Modelo con mejor MAP-C	35800	30	0,1

Al tener solo una configuración no dominada, tenemos una frontera de Pareto de solo un punto, como se puede observar en la figura 1 para el caso de NDCG@10. Esto no nos permite hacer mucho análisis comparativo entre la frontera de Pareto y las métricas de eficiencia.

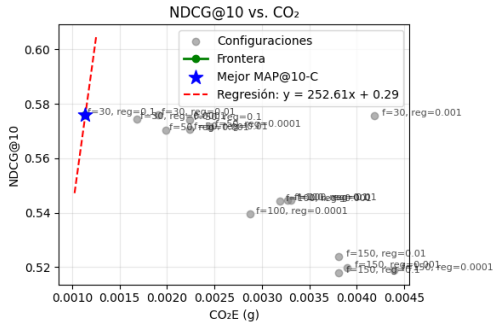

Fig. 1. NDCG@10 vs CO_2 para ALS en MovieLens 1m

Para las correlaciones, se obtienen valores positivos moderadamente altos entre las métricas de calidad y eficiencias, además de correlaciones negativas para las emisiones de CO_2 (Fig. 2). Esto es predecible si consideramos la formulación de las eficiencias, ya que la mejora sobre el baseline está en el numerador y las emisiones en el denominador. Sin embargo, más adelante se verá que este razonamiento no funciona para todos los modelos.

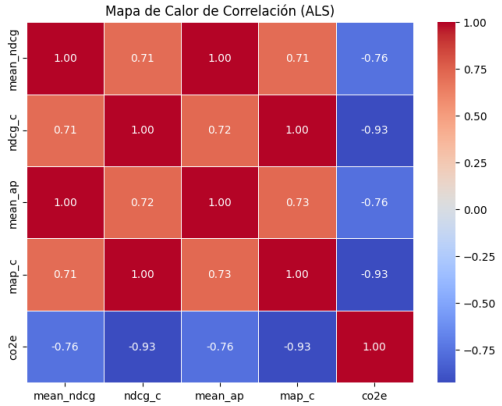

Fig. 2. Correlaciones ALS MovieLens 1m

VI-C. *ALS Book Crossing*

En Book Crossing, se obtuvo una frontera de Pareto más extensa (Fig. 3).

TABLE IV

ALS Book Crossing: Mejores modelos para NDCG-C y MAP-C.

Modelo	Valor de la Eficiencia (%)	Factores	Regularización
Modelo con mejor NDCG-C	1160	30	0,001
Modelo con mejor MAP-C	839	30	0,001

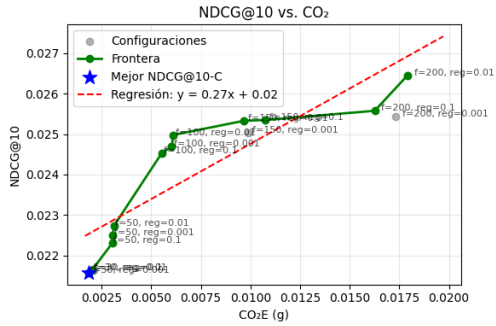

Fig. 3. NDCG@10 vs CO_2 para ALS en Book Crossing

Se puede observar que las eficiencias más altas caen consistentemente en la frontera de Pareto, es decir, las eficiencias más altas, en general, nos entregan configuraciones no dominadas (Fig.4).

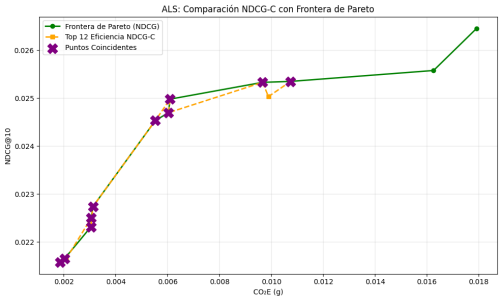

Fig. 4. ALS Book Crossing: Mejores NDCG-C en la frontera de Pareto.

A diferencia de el caso de Movie Lens 1m, en Book Crossing con ALS, se observa un conflicto entre eficiencia y calidad de recomendación, donde obtener mejores métricas de calidad en la frontera de Pareto implica perder eficiencia debido al aumento de emisiones. Las correlaciones en este caso son muy negativas entre las eficiencias y métricas de calidad (Fig. 5).

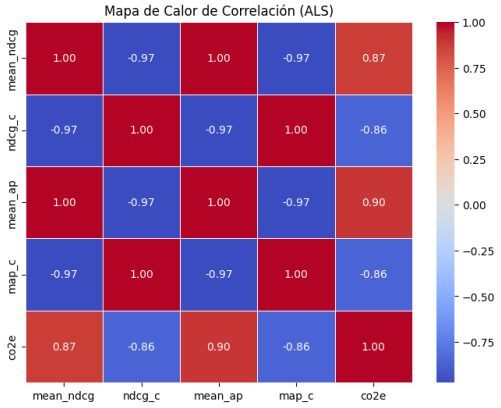

Fig. 5. Correlaciones ALS Book Crossing

VI-D. *DeepFM MovieLens 1m*

Para DeepFM se obtiene un caso menos extremo en términos de la relación entre eficiencia y métricas de calidad. La mejor eficiencia no se encuentra para las configuraciones con mejor calidad de recomendación ni para la configuración con menor emisiones de CO_2E de la frontera de Pareto (Fig. 6). En particular, se tiene que los modelos en la frontera de Pareto con embedding size más pequeños (8) tienen mejor calidad de recomendación pero peor eficiencia, en contraste con los modelos con embedding size más grandes (64), que tienen las mejores eficiencias pero peores calidad de recomendación (Ver Tablas XIV y XV).

TABLE V

DEEPFM: MEJORES MODELOS PARA NDCG-C Y MAP-C.

Modelo	Valor de la Eficiencia (%)	Emb. Size	Batch Size	LR
Modelo con mejor NDCG-C	202	64	1024	0,0001
Modelo con mejor MAP-C	139	64	1024	0,0001

Se observa que la mayoría de los puntos con mayor eficiencia si caen en la frontera de pareto, aunque no con la consistencia que se ve con ALS en Book Crossing (Fig. 7).

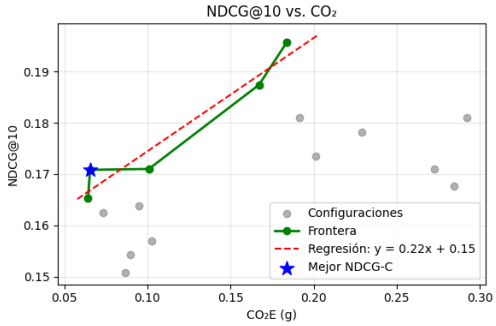

Fig. 6. NDCG@10 vs CO_2 para DeepFM

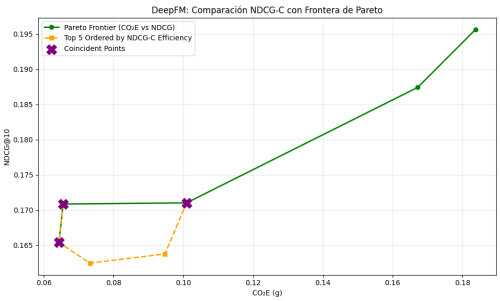

Fig. 7. Deepfm: Mejores NDCG-C en la frontera de Pareto.

Las correlaciones entre las métricas de calidad y eficiencias son negativas, aunque bastante más moderadas que en el caso de ALS en Book Crossing (Fig. 8).

VI-E. *MultiVAE MovieLens 1m*

Para MultiVAE se obtiene que las configuraciones en la frontera de Pareto tienen una hidden dimension pequeña (50) y pocas epochs (10). Se observa un patron de configuraciones agrupadas, donde el primer grupo tienen una hidden dimension de 50. Además, las configuraciones no dominadas se mantienen en este grupo con hidden dimension de 50 (Fig. 9). Sin embargo, se obtiene un resultado interesante para la mejor eficiencia MAP-C (Tabla VI).

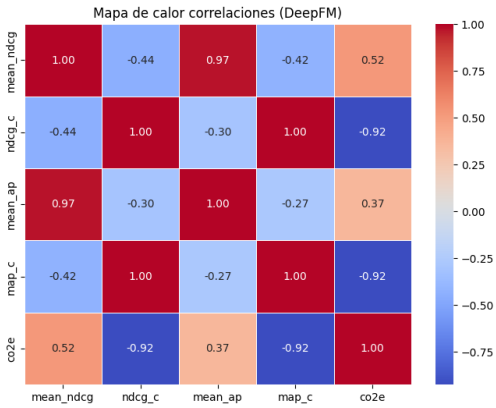

Fig. 8. Correlaciones DeepFM Movie Lens 1m

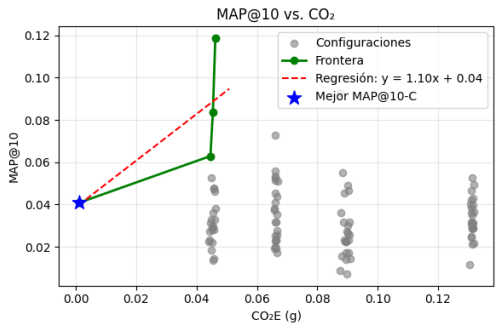

Fig. 9. NDCG@10 vs CO_2 para MultiVAE en MovieLens 1m

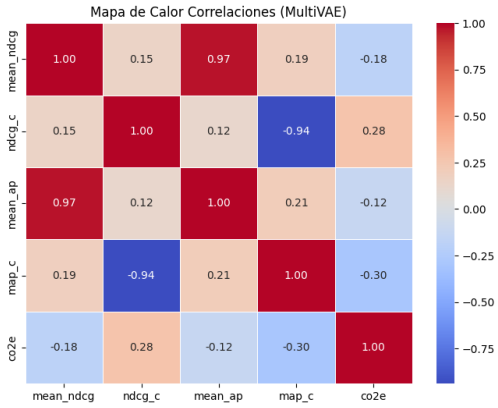

Fig. 10. Correlaciones MultiVAE (con outlier)

TABLE VI
MULTIVAE: MEJORES MODELOS PARA NDCG-C Y MAP-C.

Modelo	Valor de la Eficiencia (%)	Hidden Dim	Interm. Dim	LR
Modelo con mejor NDCG-C	127	50	400	0,00001
Modelo con mejor MAP-C	1620	50	400	0,000001

Se observa una eficiencia extrañamente alta para el máximo MAP-C, sobre todo comparandola con la mayor eficiencia NDCG-C. Revisando los resultados de las eficiencias se observa un outlier que revela una limitación que presenta este paradigma de eficiencias, debido a la formulación de la misma. Concretamente, en rangos de CO_2E muy bajos, las mediciones de eficiencia se vuelven inestables, y configuraciones con malos resultados en términos de métricas de calidad de recomendación pueden tener eficiencias muy altas o muy bajas al tener emisiones muy bajas.

TABLE VII
MODELO CON MEJOR MAP-C PARA MULTIVAE (OUTLIER).

	MAP-C	NDCG-C	mean_AP	mean_NDCG	CO_2E (g)
1	1620	−1400	0,0408	0,0244	0,000984

Este outlier también produce que las correlaciones sean muy negativas entre las dos eficiencias, y una correlación positiva baja entre las eficiencias y las métricas de calidad.

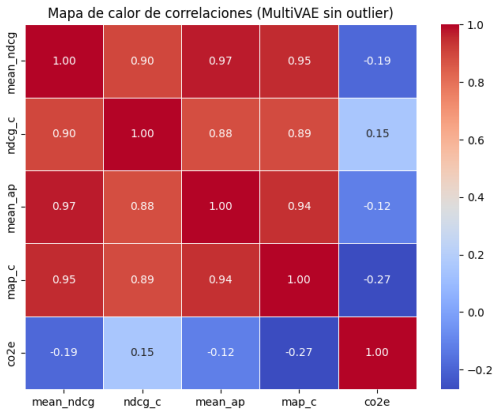

Fig. 11. Correlaciones MultiVAE (sin outlier)

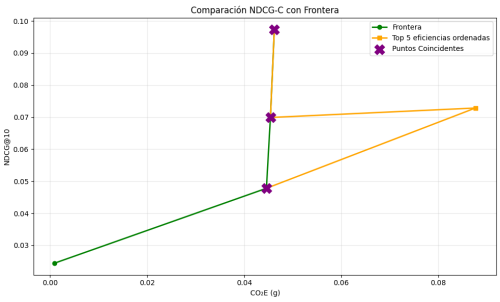

Fig. 12. MultiVAE: Mejores NDCG-C en la frontera de Pareto.

Eliminar este outlier nos da correlaciones muy positivas entre las métricas de calidad y las eficiencias, similar a ALS en MovieLens 1m. En contraste con DeepFM, obtener mejores métricas no implica tener peores eficiencias, y se puede observar en la linea que se forma en la frontera de Pareto, donde todas las configuraciones tienen valores muy cercanos de CO_2E pero varian bastante en las métricas de calidad (Fig. 11).

Para MultiVAE las configuraciones con mejores eficiencias también caen consistentemente en la frontera de Pareto (Fig. 12), lo cual refleja la utilidad de la métrica al encontrar las configuraciones no dominadas.

VII. DEEPFM Y MULTIVAE EN BOOK CROSSING

No se reportan resultados para DeepFM y MultiVAE en Book Crossing ya que no se obtuvo resultados útiles para el análisis. La gran dispersidad del dataset resulta en que las métricas MAP@10 y NDCG@10 toman valores 0 de manera consistente para las configuraciones, por lo que no se puede realmente comparar las eficiencias con una frontera de Pareto o sacar conclusiones de estos resultados.

VIII. CONCLUSIONES

VIII-A. ALS con MovieLens 1m

Para ALS con el dataset MovieLens es difícil obtener conclusiones concretas respecto a las mediciones de eficiencia de carbono, principalmente por la falta de una frontera de Pareto

más extensa que nos permita comparar con las eficiencias más altas. Las correlaciones positivas altas entre las eficiencias y métricas de calidad nos muestran que las eficiencias pueden depender mucho de la métrica de calidad, o ser predecidas por estas mediciones de calidad. Se observa una correlación negativa entre las emisiones y las eficiencias, y con los gráficos de calidad vs CO_2E, vemos que las recomendaciones con mayores emisiones tienden a tener peores métricas de calidad, debido principalmente a una mala optimización respecto a la tarea. En concreto, modelos más grandes en términos de factores latentes, que emiten más CO_2 no mejoran la performance necesariamente, y por lo tanto, tienen peor eficiencia.

VIII-B. ALS con Book crossing

Con el dataset Book crossing, en cambio, tenemos una frontera de Pareto más extensa, y se puede observar que al subir en los valores de calidad y de CO_2E, disminuyen las eficiencias. La correlación entre las eficiencias y las métricas de calidad es tan negativa que las eficiencias de carbono más altas están en la parte más baja de la frontera. Dicho esto, la gran mayoría de configuraciones con mayor eficiencia de carbono están situadas en esta frontera, lo cual nos muestra que las métricas de eficiencia nos permiten encontrar configuraciones no dominadas, es decir, la métrica es relevante para encontrar los modelos más sustentables. Los resultados para este modelo y dataset particular también abren la discusión de la elección del modelo con mayor eficiencia vs elegir una configuración menos eficiente pero más performante en calidad de recomendación para casos donde estos valores entran en conflicto, quizas, eligiendo un punto medio entre ellas.

VIII-C. DeepFM

Con DeepFM con MovieLens 1M observamos un caso más moderado de conflicto entre eficiencias y calidad de recomendación que el de ALS con book crossing. Para DeepFM se tiene una correlación negativa moderada entre las eficiencias y las métricas de calidad, es decir, eficiencia disminuye al aumentar la calidad, ya que aumentan las emisiones. Las eficiencias más altas no se encuentran ni en el extremo de mayor calidad ni en el de menor CO_2E, lo cual nos indica aún más la relevancia de las métricas de eficiencia, ya que la mayor sostenibilidad no se obtiene simplemente escogiendo uno de los extremos de la frontera de Pareto.

VIII-D. MultiVAE

Para MultiVAE tenemos un caso interesante que revela una limitación del paradigma propuesto en el paper de Qijiong Liu et al. Un outlier con métricas de calidad cercanas a random obtiene la mejor eficiencia MAP-C y la peor eficiencia NDCG-C simultaneamente, debido a sus casi inexistentes emisiones de carbono. Esto muestra que las métricas de eficiencias son muy volátiles en rangos de CO_2 muy cercanos a cero. Este resultado nos indica que hay que tener cuidado al evaluar las eficiencias. Se debe tener en cuenta el valor de la métrica de calidad de recomendación asociada y el valor de emisiones de CO_2 para evitar comparar con eficiencias que explotaron en valor debido a esta volatilidad. Al eliminar el outlier, se ve una correlación muy positiva entre las eficiencias y las métricas de calidad. Se observa el fenomeno contrario que con ALS en Book crossing, ya que aquí las mejores eficiencias se encuentran en el punto de la frontera con mejor calidad de recomendación para las métricas. Esto nos da otro caso más que muestra que no siempre existe un tradeoff entre eficiencia y calidad, lo cual entrega más utilidad a la métrica, ya que no basta con tomar el CO_2E más bajo o la calidad más alta para llegar a la mejor eficiencia de manera universal a través de los distintos modelos.

VIII-E. Síntesis

En general, las métricas NDCG-C y MAP-C nos entregan información valiosa sobre que tan eficientes son los modelos en términos de mejora sobre el baseline random y sus emisiones de carbono, al no poder predecir con certeza la configuración que entrega mayores mejoras por gramo de carbono emitido solo observando las variables de métricas de calidad y CO_2E en la frontera de Pareto de las configuraciones de los modelos. Las eficiencias más altas caen consistentemente en la frontera de Pareto, lo cual nos muestra que no se eligen configuraciones dominadas para este conjunto, en general. Sin embargo, la limitación encontrada con el caso de MultiVAE debe ser considerada con precaución, ya que en rangos de CO_2E muy bajos, las métricas de eficiencia se vuelven muy volatiles y poco informativas.

REFERENCES

[1] S. Zhang, L. Yao, A. Sun, and Y. Tay, "Deep learning based recommender system: A survey and new perspectives," *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019.

[2] F. Sun, J. Liu, J. Wu *et al.*, "Bert4rec: Sequential recommendation with bidirectional encoder representations from transformers," in *Proceedings of the 28th CIKM*, 2019, pp. 1441–1450.

[3] R. Schwartz, J. Dodge, N. A. Smith, and O. Etzioni, "Green ai," *Communications of the ACM*, vol. 63, no. 12, pp. 54–63, 2020, preprint arXiv:1907.10597.

[4] E. Strubell, A. Ganesh, and A. McCallum, "Energy and policy considerations for deep learning in NLP," in *Proceedings of ACL*, 2019, pp. 3645–3650.

[5] D. Patterson, J. E. Gonzalez, Q. V. Le, C. Liang *et al.*, "The carbon footprint of machine learning training will plateau, then shrink," *IEEE Computer*, vol. 55, no. 12, pp. 18–28, 2022.

[6] Q. Liu, J. Zhu, Q. Dai, and X.-M. Wu, "Benchmarking news recommendation in the era of green ai," in *Companion Proceedings of the ACM Web Conference 2024*, 2024, pp. 1–4.

[7] L. F. W. Anthony, B. Kanding, and R. Selvan, "Carbontracker: Tracking and predicting the carbon footprint of training deep learning models," *arXiv preprint arXiv:2007.03051*, 2020.

[8] A. Lacoste, A. S. Luccioni, V. Schmidt, and T. Dandres, "Quantifying the carbon emissions of machine learning," *arXiv preprint arXiv:1910.09700*, 2019.

IX. Anexo

IX-A. *Caracterización del dataset*

IX-A.1. MovieLens 1m: Se utilizó **MovieLens-1M**, con **6 040** usuarios, **3 883** películas y **1 000 209** calificaciones. La matriz usuario×ítem presenta una densidad de **4.2647 %** (sparsity ≈ **0.957353**). La distribución de calificaciones está sesgada a valores altos (promedio **3.58**, desviación estándar **1.12**, mínimo **1**, máximo **5**); el promedio por usuario es **3.70** y por ítem **3.24**. Existe una *cola larga* en el número de calificaciones por ítem: la mayoría de películas reciben pocas reseñas, con máximos de **3 428** y mínimos de **1**. Por usuario, el máximo es **2 314** y el mínimo **20**. Identificamos **1 743** usuarios en situación de *cold-start* (50 reseñas) y **870** ítems con 30 reseñas. Estas propiedades motivan complementar las métricas de ranking con **novedad** y **diversidad**, y analizar la eficiencia bajo sesgo a la popularidad.

En la tabla 4 se presentan los principales resultados (usuarios, ítems, densidad, promedios, máximos/mínimos, cold-start).

TABLE VIII
Resumen de la caracterización de MovieLens-1M

Indicador	Valor	Notas
Usuarios únicos	6,040	
Películas únicas	3,883	
Calificaciones totales	1,000,209	
Densidad de la matriz	4.2647 %	Sparsity ≈ 0.957353
Rating promedio (global)	3.58	Desv. estándar = 1.12
Rating mínimo / máximo	1 / 5	
Rating promedio por usuario	3.70	
Rating promedio por ítem	3.24	
Promedio de reseñas por usuario	165.60	Mín = 20, Máx = 2,314
Promedio de reseñas por ítem	257.59	Mín = 1, Máx = 3,428
Usuarios *cold-start* (¡50 reseñas)	1,743	
Ítems *cold-start* (¡30 reseñas)	870	
Ocupaciones únicas	21	

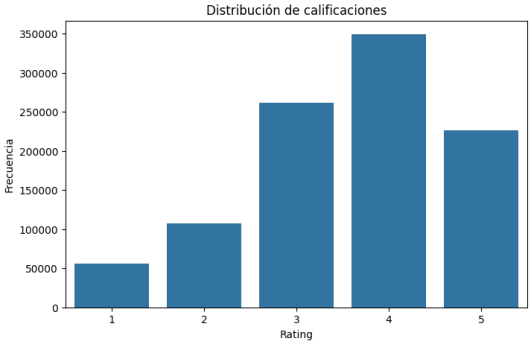

Fig. 13. Distribución de calificaciones en MovieLens-1M.

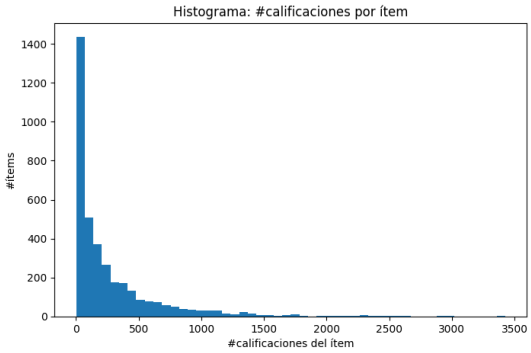

Fig. 14. Histograma del número de calificaciones por ítem (cola larga).

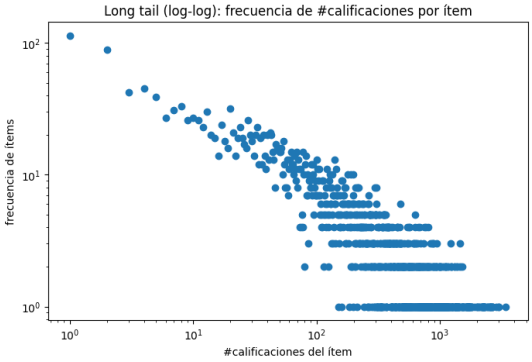

Fig. 15. Relación log–log de frecuencia vs. #calificaciones por ítem.

IX-A.2. Book-Crossing: A modo de comparación, se utilizó un dataset de similar tamaño que MovieLens 1m, llamado **Book-Crossing**. Este dataset contiene **1,149,779 ratings** de **278,859 usuarios**, con **271,379 libros**. La matriz usuariosxitem tiene una densidad mucho menor de **0.004 %** (sparsity ≈ 0.9999). Los ratings también están sesgados a valores altos (promedio de 7.6, desviación estandar de 1.84). El rating promedio por usuario es de 7.46 y el rating promedio por libro es 7.49. Los valores 0 representan que no hubo interacción.

TABLE IX
Resumen de la caracterización Book-Crossing

Indicador	Valor	Notas
Usuarios únicos	278,869	
Películas únicas	271,379	
Calificaciones totales	1,149,799	(sin filtrar ceros)
Densidad de la matriz	0,004 %	Sparsity ≈ 0.9999
Rating promedio (global)	7.6	Desv. estándar = 1.84
Rating mínimo / máximo	1 / 10	
Rating promedio por usuario	7.46	
Rating promedio por ítem	7.49	
Promedio de reseñas por usuario	5.57	
Promedio de reseñas por ítem	2.33	
Usuarios *cold-start* (¡5 reseñas)	63,585	
Ítems *cold-start* (¡5 reseñas)	171,438	

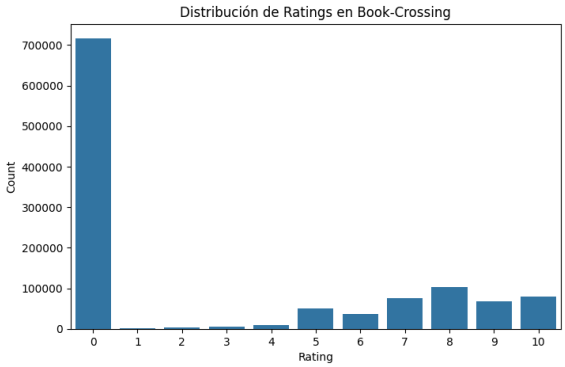

Fig. 16. Distribución de calificaciones en Book Crossing

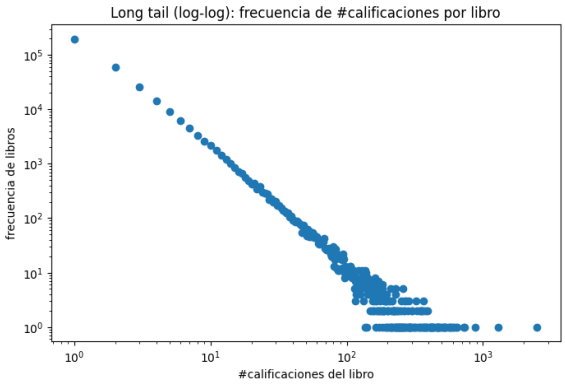

Fig. 17. Relación log-log de frecuencia vs #calificaciones por ítem

IX-B. Detalles de la partición de datos

A continuación se muestran las tablas con los splits especificos para cada dataset.

TABLE X
TAMAÑOS DE LOS SUBCONJUNTOS TRAS LA PARTICIÓN ALEATORIA EN MOVIELENS

Conjunto	# Interacciones	Proporción
Entrenamiento (train)	600,125	60 %
Validación (val)	200,042	20 %
Prueba (test)	200,042	20 %

TABLE XI
TAMAÑOS DE LOS SUBCONJUNTOS TRAS LA PARTICIÓN ALEATORIA EN BOOK-CROSSING

Conjunto	# Interacciones	Proporción
Entrenamiento (train)	618,711	60 %
Validación (val)	206,238	20 %
Prueba (test)	206,238	20 %

X. FRONTERAS DE PARETO

TABLE XII
FRONTERA DE PARETO PARA MAP@10 Y CO_2E PARA ALS EN BOOK CROSSING.

	MAP@10	CO_2E (g)	Factores	Reg.
1	0,0156	0,00185	30	0,001
2	0,0156	0,00202	30	0,01
3	0,0161	0,00304	50	0,1
4	0,0162	0,00306	50	0,001
5	0,0165	0,00312	50	0,01
6	0,0181	0,00553	100	0,1
7	0,0182	0,00603	100	0,001
8	0,0184	0,00610	100	0,01
9	0,0190	0,00966	150	0,01
10	0,0194	0,0163	200	0,1
11	0,0201	0,0179	200	0,01

TABLE XIII
FRONTERA DE PARETO PARA NDCG@10 Y CO_2E PARA ALS EN BOOK CROSSING.

	NDCG@10	CO_2E (g)	Factores	Reg.
1	0,0216	0,00185	30	0,001
2	0,0216	0,00202	30	0,01
3	0,0223	0,00304	50	0,1
4	0,0225	0,00306	50	0,001
5	0,0227	0,00312	50	0,01
6	0,0245	0,00553	100	0,1
7	0,0247	0,00603	100	0,001
8	0,0250	0,00610	100	0,01
9	0,0253	0,00966	150	0,01
10	0,0253	0,0107	150	0,1
11	0,0256	0,0163	200	0,1
12	0,0265	0,0179	200	0,01

TABLE XIV
FRONTERA DE PARETO PARA MAP@10 Y CO_2E PARA DEEPFM EN MOVIELENS 1M.

	MAP@10	CO_2E (g)	Emb. Size	Batch Size	LR
1	0,111	0,0643	32	1024	0,0001
2	0,116	0,0655	64	1024	0,0001
3	0,127	0,167	16	1024	0,001
4	0,134	0,184	8	1024	0,001

TABLE XV
FRONTERA DE PARETO PARA NDCG@10 Y CO_2E PARA DEEPFM EN MOVIELENS 1M.

	NDCG@10	CO_2E (g)	Emb. Size	Batch Size	LR
1	0,165	0,0643	32	1024	0,0001
2	0,171	0,0655	64	1024	0,0001
3	0,171	0,1009	64	512	0,0001
4	0,187	0,167	16	1024	0,001
5	0,196	0,184	8	1024	0,001

TABLE XVI

FRONTERA DE PARETO PARA MAP@10 Y CO_2E PARA MULTIVAE EN MOVIELENS 1M.

	MAP@10	CO_2E (g)	H. Dim	Int. Dim	Batch	Dropout	W. Decay	Epochs
1	0,0408	0,000984	50	400	512	0,20	0,0	20
2	0,0629	0,0446	50	400	1024	0,50	0,0001	10
3	0,0837	0,0454	50	400	1024	0,80	0,0001	10
4	0,119	0,0462	50	400	1024	0,80	0,0	10

TABLE XVII

FRONTERA DE PARETO PARA NDCG@10 Y CO_2E PARA MULTIVAE EN MOVIELENS 1M.

	NDCG@10	CO_2E	H. Dim	Int. Dim	Batch	Dropout	W. Decay	Epochs
1	0,0244	0,000984	50	400	512	0,20	0,0	20
2	0,0478	0,0446	50	400	1024	0,50	0,0001	10
3	0,0699	0,0454	50	400	1024	0,80	0,0001	10
4	0,0973	0,0462	50	400	1024	0,80	0,0	10

XI. GRÁFICOS RESULTADOS

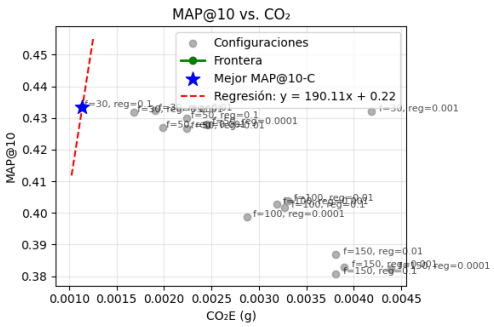

Fig. 18. ALS MovieLens 1m: MAP@10 vs CO_2E

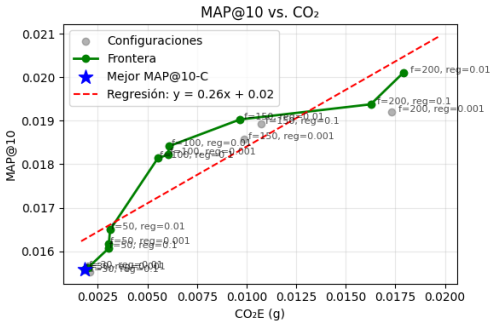

Fig. 19. ALS Book Crossing: MAP@10 vs CO_2E

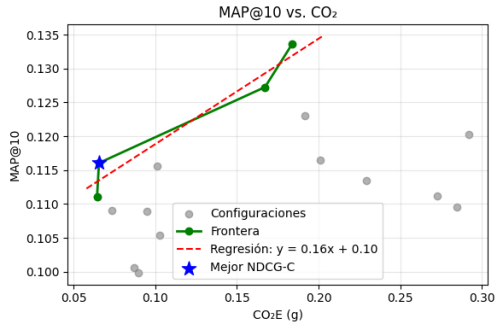

Fig. 20. DeepFM: MAP@10 vs CO_2E

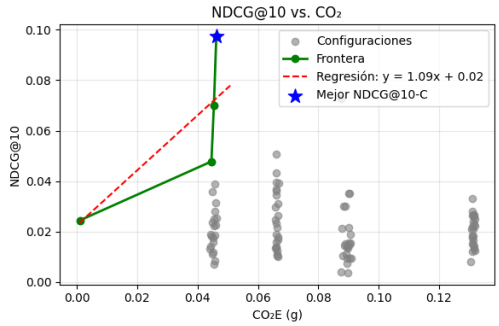

Fig. 21. MultiVAE: NDCG@10 vs CO_2E

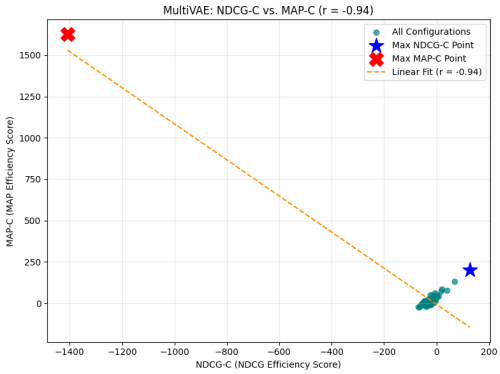

Fig. 22. MultiVAE: NDCG-C vs MAP-C (con outlier)

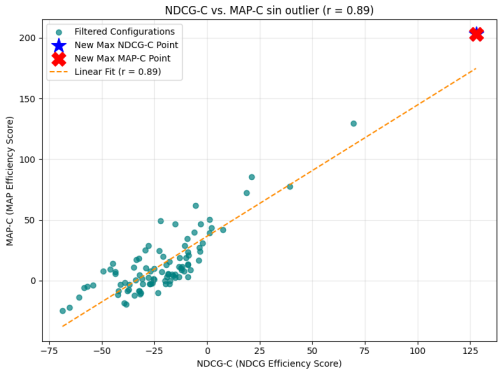

Fig. 23. MultiVAE: NDCG-C vs MAP-C (sin outlier)