Recomendación Híbrida de Libros: Evaluando la Suficiencia de la Semántica de Títulos vía Embeddings Profundos

Cristóbal Tolorza
Pontificia Universidad Católica
Santiago, Chile
christ.tolorza@uc.cl

Bastián Guacucano
Pontificia Universidad Católica
Santiago, Chile
bastian.gl@uc.cl

Diego Valenzuela
Pontificia Universidad Católica
Santiago, Chile
diego.valenzuela@uc.cl

Abstract

En este trabajo abordamos el desafío de recomendar libros en escenarios con pocos datos de interacción. Nuestro objetivo principal fue evaluar si la información semántica contenida solo en los títulos de los libros es suficiente para mejorar la calidad de las recomendaciones. Para ello propusimos un modelo híbrido que combina la factorización de matrices SVD con embeddings profundos generados por modelos de lenguaje modernos.

Evaluamos tres arquitecturas diferentes para procesar el texto: DistilRoBERTa, All-MPNet-Base y Multi-QA. Los resultados experimentales muestran que nuestro enfoque híbrido supera ampliamente a los métodos tradicionales. En particular encontramos que el uso de MPNet-Base permite mejorar el rendimiento en casi un 200% en comparación con el modelo colaborativo base. Además realizamos un análisis de sensibilidad que demuestra que combinar la semántica de los títulos con las interacciones de los usuarios no solo aumenta la precisión. También logramos generar listas de recomendación más diversas y útiles para el usuario final. Concluimos que los títulos son una fuente de información valiosa y ligera cuando se integran correctamente en un sistema híbrido.

El código fuente y los datasets procesados están disponibles públicamente en nuestro repositorio de GitHub: https://github.com/vdiego28/Proyecto-recsys

CCS Concepts

• **Information systems** → **Recommender systems**; *Collaborative filtering*; • **Computing methodologies** → *Natural language processing*; Neural networks.

Keywords

Sistemas Recomendadores Híbridos, Sentence Embeddings, Factorización de Matrices, SVD, Deep Learning, Recomendación de Texto Corto

ACM Reference Format:
Cristóbal Tolorza, Bastián Guacucano, and Diego Valenzuela. 2025. Recomendación Híbrida de Libros: Evaluando la Suficiencia de la Semántica de Títulos vía Embeddings Profundos. In *Proceedings of Pontificia Universidad Católica (Sistemas Recomendadores).* ACM, New York, NY, USA, 9 pages.

1 Introducción

1.1 Contexto y Motivación

El crecimiento explosivo de los catálogos digitales de libros en plataformas como Goodreads, Amazon o bibliotecas en línea ha generado un escenario de sobrecarga de información, donde a los lectores les resulta cada vez más difícil descubrir obras relevantes entre miles de títulos disponibles. En este contexto, los sistemas de recomendación se han consolidado como una pieza central para facilitar el descubrimiento de contenido personalizado, aumentando la satisfacción del usuario y el uso efectivo de las plataformas digitales [20].

Tradicionalmente, gran parte de estos sistemas se ha apoyado en técnicas de filtrado colaborativo basadas en las interacciones histórico–comportamentales de los usuarios (calificaciones, clics, reseñas), las cuales permiten capturar patrones latentes de preferencia en grandes matrices usuario–ítem. Sin embargo, estos enfoques presentan limitaciones reconocidas: sufren con la esparsidad de datos, dependen fuertemente de la densidad de interacciones y fallan en escenarios de arranque en frío (usuarios o ítems nuevos sin historial suficiente), lo que conduce a recomendaciones poco confiables o directamente imposibles para una fracción significativa del catálogo [11].

En paralelo, ha surgido un interés creciente por explotar la *información de contenido* asociada a los ítems –títulos, descripciones, reseñas textuales, metadatos– mediante técnicas de procesamiento de lenguaje natural (PLN). El desarrollo reciente de modelos de lenguaje profundo basados en *transformers*, como BERT y sus variantes, ha permitido obtener *representaciones vectoriales densas* (*embeddings*) capaces de capturar la semántica de oraciones y documentos con un nivel de precisión notable (Reimers & Gurevych, 2019). Estos modelos han demostrado su utilidad para tareas de recuperación de información y recomendación basada en texto, donde la similitud se define en un espacio semántico continuo más allá de la coincidencia literal de palabras [9, 22].

En el dominio específico de los libros, esta línea de trabajo es especialmente atractiva: el texto condensado en títulos, sinopsis y reseñas contiene pistas semánticas sobre género, tono, temática o estilo narrativo que pueden servir para aproximar los gustos de un lector incluso cuando se dispone de pocas interacciones colaborativas [7, 18]. Sin embargo, la mayoría de los enfoques existentes utilizan descripciones completas o reseñas extensas; es menos claro hasta qué punto la semántica de los títulos por sí sola resulta suficiente para construir buenas recomendaciones. Por otro lado, los sistemas basados únicamente en contenido tienden a generar listas muy homogéneas, con poca diversidad, ya que recomiendan ítems semánticamente muy similares a los ya consumidos [6].

En este escenario, los enfoques híbridos que combinan filtrado colaborativo con información de contenido han demostrado ser una estrategia eficaz para mitigar tanto la esparsidad como el problema de *cold start*, logrando al mismo tiempo mejoras en métricas de precisión y diversidad [6, 19]. Nuestro trabajo se sitúa en esta

Sistemas Recomendadores, Santiago, Chile
2025.

línea, y se centra en estudiar hasta qué punto la información semántica contenida exclusivamente en los títulos de libros, codificada mediante *embeddings* profundos, puede complementar un modelo colaborativo clásico de factorización de matrices para mejorar la calidad de las recomendaciones.

1.2 Planteamiento del Problema

Pese a los avances recientes en recomendación basada en texto, el diseño de sistemas efectivos en el dominio de libros sigue enfrentando varias preguntas abiertas. Una de ellas es cuánta información semántica relevante se puede extraer únicamente de los títulos y qué tan lejos puede llegar un sistema de recomendación si se restringe a esa vista extremadamente compacta del contenido. Los títulos suelen ser breves, a veces crípticos o metafóricos, y no siempre describen explícitamente el género o la trama. Aun así, los modelos de lenguaje profundo entrenados a gran escala podrían capturar patrones semánticos sutiles que resulten útiles para la recomendación.

Al mismo tiempo, los modelos de filtrado colaborativo siguen siendo la base de muchos sistemas de recomendación industriales debido a su capacidad para capturar correlaciones de consumo que no están explícitas en el contenido [20]. Sin embargo, cuando se usan de forma aislada, estos modelos no aprovechan la información textual disponible y mantienen sus debilidades frente a ítems poco populares o usuarios con poco historial. Por otro lado, los modelos puramente basados en contenido que utilizan *embeddings* textuales tienden a mostrar buena capacidad de recuperación semántica, pero su rendimiento en métricas de *ranking* (como MAP o NDCG) suele ser limitado cuando no se consideran las preferencias colectivas, y la diversidad de las listas recomendadas puede verse comprometida [22].

De esta tensión surgen dos cuestiones centrales que motivan nuestro trabajo:

- **Suficiencia de la semántica de títulos.** ¿Es posible obtener recomendaciones de libros competitivas utilizando exclusivamente los títulos como fuente de contenido, representados mediante *embeddings* profundos, sin recurrir a descripciones completas ni reseñas extensas?
- **Beneficio real de la hibridación.** ¿Hasta qué punto combinar la información colaborativa de un modelo de factorización de matrices con la similitud semántica basada en títulos mejora la precisión y la diversidad respecto de los modelos puramente colaborativos o puramente basados en contenido?

Responder estas preguntas requiere, además, evaluar el impacto de distintas arquitecturas de *encoders* de lenguaje (por ejemplo, DistilRoBERTa, All-MPNet-Base, Multi-QA MPNet-Base) y analizar cómo el parámetro de mezcla entre el componente colaborativo y el componente semántico afecta el equilibrio entre precisión y diversidad de las recomendaciones.

En síntesis, el problema que abordamos puede formularse como el diseño y análisis de un sistema de recomendación híbrido de libros que emplea factorización de matrices sobre interacciones usuario–libro y, simultáneamente, *embeddings* profundos de los títulos, con el objetivo de determinar si esta señal textual mínima es suficiente para complementar eficazmente al modelo colaborativo y mejorar su rendimiento global.

1.3 Contribuciones

Este trabajo realiza aportes concretos en la intersección entre recomendación híbrida, factorización de matrices y representaciones semánticas de texto para el dominio de libros. Nuestras principales contribuciones son las siguientes:

(1) **Propuesta de un *framework* híbrido centrado en la semántica de títulos:** Desarrollamos un modelo de recomendación híbrido que combina un esquema de filtrado colaborativo basado en factorización de matrices (SVD) con un componente *content-based* construido a partir de *embeddings* profundos de los títulos de los libros. El modelo híbrido linealiza ambas fuentes mediante un parámetro de peso α que controla la contribución relativa del puntaje colaborativo y de la similitud semántica en la función de *ranking*.
(2) **Evaluación sistemática de la suficiencia de los títulos mediante diferentes *encoders* profundos:** Implementamos variantes del modelo híbrido utilizando tres arquitecturas de lenguaje ampliamente empleadas en tareas de similitud semántica de oraciones: DistilRoBERTa, All-MPNet-Base y Multi-QA MPNet-Base. Con ello, analizamos cómo la elección del *encoder* impacta la calidad de las recomendaciones cuando solo se dispone de títulos como entrada textual, contribuyendo a la discusión sobre qué tipo de representaciones son más adecuadas para este escenario específico.
(3) **Análisis del *trade-off* precisión–diversidad inducido por la hibridación:** Realizamos un estudio de sensibilidad sobre el parámetro de mezcla α y evaluamos el comportamiento del sistema frente a métricas estándar de *ranking* y recuperación (MAP@10, NDCG@10, Recall@10, MRR@10) junto con métricas de diversidad y *coverage* a nivel de lista. Mostramos empíricamente que el modelo híbrido puede alcanzar un punto óptimo de hibridación donde mejora significativamente la precisión respecto al modelo colaborativo puro, al tiempo que incrementa la diversidad en comparación con los enfoques basados únicamente en contenido o con ciertos valores extremos de α.
(4) **Evidencia empírica sobre el valor de la semántica de títulos en recomendación de libros:** Nuestros resultados indican que, aunque los modelos basados solo en títulos presentan limitaciones cuando se usan de forma aislada, la integración de sus *embeddings* en un *framework* de factorización de matrices produce un aumento sustancial en precisión y diversidad frente a los modelos base.

En conjunto, estas contribuciones proporcionan evidencia cuantitativa de que la semántica de títulos, codificada mediante *embeddings* profundos, constituye un recurso valioso y ligero para enriquecer sistemas de recomendación de libros, y ofrecen un marco experimental reproducible para futuros trabajos que deseen extender el análisis a otras fuentes textuales (como sinopsis o reseñas) o a otros dominios de ítems.

2 Trabajos Relacionados

2.1 Filtrado Colaborativo y Factorización de Matrices

El *filtrado colaborativo* (FC) constituye uno de los enfoques más estudiados y desplegados en sistemas de recomendación. Su premisa es que usuarios con patrones de interacción similares tenderán a compartir preferencias futuras; en consecuencia, las recomendaciones se generan a partir de la estructura de la matriz usuario–ítem sin requerir información explícita de los productos [1]. Los enfoques clásicos se dividen en métodos basados en vecindario (usuario–usuario o ítem–ítem) y métodos basados en modelos. Los primeros calculan similitudes explícitas entre perfiles para propagar ratings, mientras que los segundos aprenden representaciones latentes que explican las interacciones observadas.

Dentro de los modelos, la *factorización de matrices* (MF) se ha consolidado como la técnica dominante debido a su capacidad para capturar factores latentes de usuarios e ítems a partir de grandes matrices dispersas [10]. En su forma básica, MF descompone la matriz de interacciones $R \in \mathbb{R}^{m \times n}$ en el producto de dos matrices de baja dimensión $P \in \mathbb{R}^{m \times f}$ y $Q \in \mathbb{R}^{n \times f}$, de modo que $R \approx PQ^\top$. Cada fila de P representa un usuario en un espacio latente de dimensión f, y cada fila de Q representa un ítem en el mismo espacio; la predicción de la afinidad usuario–ítem se obtiene mediante el producto interno de sus vectores. Extensiones como SVD++, la incorporación de sesgos y la regularización han demostrado mejoras significativas en tareas de predicción de ratings y *top–N recommendation* [10, 21].

No obstante, el FC basado únicamente en interacciones presenta limitaciones bien conocidas. En primer lugar, su rendimiento depende de la densidad de la matriz usuario–ítem, por lo que sufre fuertemente con la *esparsidad* de datos: muchos usuarios califican solo una pequeña fracción del catálogo, lo que dificulta inferir similitudes confiables. En segundo lugar, enfrenta el problema de *arranque en frío* tanto para usuarios nuevos como para ítems recientemente incorporados, para los cuales no existen suficientes interacciones que permitan estimar factores latentes de manera robusta. Finalmente, al operar exclusivamente sobre patrones de consumo, los modelos MF clásicos no explotan la rica información de contenido disponible en dominios textuales como el de los libros.

En el contexto de este trabajo, utilizamos una variante de MF de tipo SVD como *baseline colaborativo* y como componente colaborativo de nuestro modelo híbrido. Este componente captura patrones de preferencia basados en las calificaciones históricas, mientras que sus carencias frente a ítems poco populares y usuarios con escaso historial se abordan mediante la incorporación de información semántica de títulos, descrita en las subsecciones siguientes.

2.2 Representaciones Semánticas de Texto en RecSys

Los sistemas de recomendación basados en contenido explotan atributos explícitos de los ítems (por ejemplo, género, autor, palabras clave) para construir perfiles de usuario y medir similitudes entre productos. En dominios textuales, estos atributos se derivan típicamente de descripciones, reseñas o metadatos en lenguaje natural. Los enfoques tempranos representaban documentos mediante modelos de *bolsa de palabras* con pesos TF–IDF; si bien estos métodos han sido exitosos en recuperación de información, presentan limitaciones al ignorar el orden de las palabras y las relaciones semánticas entre términos.

Para superar estas limitaciones, se introdujeron técnicas de representación latente como LSI/LSA y LDA, que proyectan los documentos a espacios temáticos de baja dimensión. Sin embargo, en la última década han ganado protagonismo los *embeddings* densos aprendidos mediante redes neuronales, tanto a nivel de palabra (Word2Vec, GloVe) como de oración y documento. Estos *embeddings* capturan regularidades semánticas y sintácticas, permitiendo que documentos con vocabularios distintos, pero significados similares, queden cercanos en el espacio vectorial [2, 12].

La irrupción de modelos de lenguaje basados en *transformers*—como BERT y sus variantes—marcó un punto de inflexión en la representación semántica de texto. Modelos como Sentence-BERT [13] o MPNet generan *embeddings* de oraciones optimizados para tareas de similitud semántica y recuperación, lo que los hace especialmente atractivos para recomendación basada en texto. En lugar de operar sobre vectores dispersos de tamaño vocabulario, los ítems se representan mediante vectores densos de dimensión moderada (p. ej. 768), que condensan información semántica de alto nivel.

En el ámbito de sistemas de recomendación, diversos trabajos han explorado el uso de estos *embeddings* para mejorar la calidad de las sugerencias, ya sea reemplazando los perfiles de contenido tradicionales o complementando modelos colaborativos [21]. Algunos enfoques utilizan descripciones completas o reseñas extensas de los ítems para construir representaciones ricas, mientras que otros se centran en información textual más compacta, como títulos y etiquetas. No obstante, existe todavía poca evidencia sistemática sobre cuán *suficiente* resulta la semántica contenida únicamente en los títulos para alimentar un sistema de recomendación competitivo, especialmente en dominios con catálogos amplios y heterogéneos como el de los libros.

Nuestro trabajo se sitúa precisamente en este punto: utilizamos modelos de *sentence embeddings* basados en DistilRoBERTa, All-MPNet-Base y Multi-QA MPNet-Base para codificar exclusivamente los títulos de los libros. De este modo, podemos aislar el poder predictivo de esta señal textual mínima y analizar empíricamente hasta qué punto sus *embeddings* son capaces de complementar al componente colaborativo en un escenario de recomendación de libros.

2.3 Estrategias de Recomendación Híbridas

Los sistemas de recomendación híbridos combinan dos o más técnicas de recomendación con el objetivo de aprovechar sus fortalezas y mitigar sus debilidades individuales [4]. En particular, la combinación de filtrado colaborativo con métodos basados en contenido ha demostrado ser efectiva para abordar la esparsidad, el arranque en frío y la baja diversidad que afectan a los enfoques puros. La literatura ha propuesto diversas taxonomías de hibridación; entre las estrategias más comunes se encuentran:

- **Combinación ponderada (*weighted hybrid*):** se calculan puntuaciones de recomendación independientes a partir de varios modelos y luego se combinan mediante una suma

o promedio ponderado. Ajustando los pesos se controla la influencia relativa de cada componente.

- **Conmutación (*switching*):** el sistema selecciona dinámicamente qué método utilizar según ciertas condiciones, por ejemplo, privilegiar el contenido en escenarios de arranque en frío y el colaborativo cuando existe suficiente historial.
- **Combinación de características (*feature combination*) y enriquecimiento de características (*feature augmentation*):** las características generadas por un modelo (por ejemplo, *embeddings* de texto) se incorporan como entradas adicionales a otro modelo, típicamente colaborativo, enriqueciendo la matriz de interacciones.
- **Híbridos en cascada:** un modelo genera un conjunto inicial de candidatos y otro modelo reordena o filtra dicho conjunto, aplicando criterios más sofisticados (por ejemplo, reranking basado en contenido).

Con el auge del aprendizaje profundo, han surgido modelos híbridos neurales que integran explícitamente representaciones latentes colaborativas y de contenido dentro de una misma arquitectura, por ejemplo, reemplazando el producto punto de la factorización de matrices por redes neuronales que combinan vectores de usuario e ítem junto con *embeddings* de texto, imagen o audio [21]. Estos enfoques han mostrado mejoras en precisión, pero a menudo introducen una complejidad considerable y requieren grandes volúmenes de datos para entrenarse de forma estable.

En el dominio de libros, varios trabajos han incorporado descripciones o reseñas textuales para complementar el filtrado colaborativo, mostrando beneficios en escenarios de datos escasos y en la recomendación de ítems de cola larga. Sin embargo, estos estudios suelen considerar texto relativamente extenso y no analizan de manera aislada la señal proporcionada por los títulos. Además, pocos trabajos cuantifican explícitamente el *trade-off* entre precisión y diversidad inducido por el grado de hibridación.

Nuestro enfoque se enmarca en la categoría de *combinación ponderada*: definimos un modelo híbrido lineal donde la puntuación final se obtiene como combinación convexa del puntaje colaborativo (SVD) y de un puntaje de similitud semántica basado en *embeddings* profundos de títulos. Al variar el parámetro de mezcla α, podemos estudiar cómo interactúan ambos componentes y analizar empíricamente el equilibrio precisión–diversidad, así como el impacto de distintas arquitecturas de *encoder* sobre el rendimiento global del sistema en el contexto específico de recomendación de libros.

3 Dataset y Preprocesamiento

3.1 Descripción de los Datos

Para la realización de este estudio se construyó un conjunto de datos híbrido integrando dos fuentes públicas del dominio literario. La información de catálogo y metadatos de los libros se obtuvo del dataset *Goodreads-Books* alojado en Hugging Face por Bright Data [3], el cual contiene más de 5,7 millones de títulos únicos con información estructurada sobre identificadores, autores, promedio de calificaciones, número de reseñas, géneros y resúmenes. Esta fuente define el espacio de búsqueda semántico sobre el cual operan los modelos basados en texto.

Por otro lado, las interacciones de usuarios (calificaciones explícitas) provienen de *Goodreads Book Datasets with User Rating 2M* disponible en Kaggle [8], que compila múltiples archivos CSV con historiales de valoración en escala de 1 a 5 estrellas. A partir de esta colección se extrajeron las tuplas usuario–libro necesarias para construir la matriz de retroalimentación utilizada por los modelos de Filtrado Colaborativo.

Ambas fuentes se integraron mediante un proceso de cruce por identificadores de libro, manteniendo únicamente aquellos títulos presentes en el catálogo de metadatos y que además registran al menos una interacción en los datos de ratings. El conjunto de datos final se compone de una matriz de interacciones usuario–ítem que vincula las calificaciones de usuarios con los títulos enriquecidos con metadatos. Las estadísticas descriptivas del dataset procesado son:

- **Usuarios únicos**: 3,947.
- **Interacciones (ratings)**: 230,052.
- **Catálogo base**: $\approx$ 5.7 millones de libros (utilizados como espacio de recuperación semántica).

Esta configuración induce un escenario de alta esparsidad, típico de sistemas de recomendación en catálogos de gran escala: la proporción de celdas observadas en la matriz usuario–ítem es muy inferior al 1 % del total posible. En este contexto, la señal colaborativa disponible resulta limitada, lo que hace especialmente pertinente el uso de estrategias híbridas que combinan la estructura latente extraída de las interacciones con información semántica densa proveniente de los títulos de los libros.

3.2 Pipeline de Preprocesamiento

El preprocesamiento de los datos comprende dos flujos principales: normalización de la matriz de interacciones y limpieza de los títulos para su posterior codificación semántica.

En primer lugar, filtramos usuarios y libros con un número muy reducido de interacciones, lo que permite eliminar ruido extremo y reducir la esparsidad estructural de la matriz R. Fijamos umbrales mínimos tanto para el número de calificaciones por usuario como por libro; los valores concretos se determinaron de forma empírica observando la distribución de frecuencias y buscando un compromiso entre cobertura del catálogo y densidad de la matriz. Tras este filtrado reindexamos usuarios y libros para obtener identificadores consecutivos, lo que facilita la implementación de la factorización de matrices.

Posteriormente, centramos y escalamos las calificaciones para el modelo colaborativo. En particular, restamos la media global y consideramos términos de sesgo por usuario y por ítem (presentados en la Sección 4.2), lo que ayuda a capturar diferencias sistemáticas en las escalas de evaluación. Esta normalización es estándar en modelos de factorización de matrices y contribuye a una mejor estabilidad numérica durante el entrenamiento [10].

En paralelo aplicamos un preprocesamiento ligero sobre los títulos. Se normaliza el uso de mayúsculas y minúsculas, se corrigen ciertos caracteres especiales y se eliminan espacios redundantes. No aplicamos lematización ni eliminación agresiva de stopwords, dado que los transformadores utilizados manejan internamente la tokenización subpalabra y pueden aprovechar información sintáctica sutil. Cada título preprocesado se pasa directamente al tokenizador

correspondiente de cada modelo de lenguaje (DistilRoBERTa, MPNet y Multi-QA MPNet), manteniendo su longitud original dentro de los límites de contexto permitidos.

Finalmente, para cada usuario u construimos el conjunto de libros observados $\mathcal{I}_u = \{i \in \mathcal{I} : r_{ui} \text{ está definido}\}$, que se utilizará tanto para entrenar el modelo colaborativo como para definir el perfil semántico del usuario en el componente basado en contenido. Los ejemplos del conjunto de prueba se excluyen explícitamente del cálculo de estos perfiles para evitar fugas de información.

4 Metodología

4.1 CB: Deep Semantic Embeddings

La componente basada en contenido del sistema se construye a partir de representaciones semánticas profundas de los títulos de los libros. Para ello se emplea la librería Sentence-Transformers [14], que permite obtener *sentence embeddings* densos en un espacio vectorial de 768 dimensiones a partir de modelos *Transformer* preentrenados y posteriormente ajustados mediante aprendizaje contrastivo sobre grandes colecciones de pares de oraciones.

En este trabajo se evalúan tres encoders distintos, que difieren tanto en su arquitectura base como en los datos y objetivos de entrenamiento:

All-DistilRoBERTa (all-distilroberta-v1). Este modelo se basa en `distilroberta-base`, una versión comprimida y más ligera de RoBERTa, y fue afinado mediante un objetivo contrastivo sobre más de mil millones de pares de oraciones [15]. El entrenamiento utiliza un conjunto heterogéneo de fuentes (comentarios de Reddit, pares de citas académicas, preguntas y respuestas, entre otros), con el objetivo de aprender representaciones universales de frases. El resultado es un encoder eficiente que mapea oraciones y párrafos cortos a vectores de 768 dimensiones adecuados para tareas generales de similitud semántica y agrupamiento. En nuestro caso, este modelo se emplea como línea base de contenido (*Baseline CB*), generando recomendaciones únicamente a partir de la similitud del título sin usar información de interacciones.

All-MPNet-Base (all-mpnet-base-v2). El segundo encoder se construye a partir de `mpnet-base`, un modelo que combina ideas de enmascaramiento bidireccional y predicción de permutaciones para mejorar la captura de dependencias contextuales en la oración. La variante `all-mpnet-base-v2` fue afinada sobre un corpus de más de mil millones de pares de oraciones utilizando también un objetivo contrastivo [16]. Estudios comparativos muestran que esta familia de modelos tiende a ofrecer mejor calidad que otras alternativas de propósito general en tareas de similitud y búsqueda semántica [14]. En este trabajo se lo utiliza tanto como estrategia puramente basada en contenido como dentro del framework híbrido, donde sus embeddings de títulos alimentan la capa de combinación con el modelo colaborativo SVD.

Multi-QA MPNet-Base (multi-qa-mpnet-base-dot-v1). El tercer encoder corresponde a `multi-qa-mpnet-base-dot-v1`, diseñado específicamente para tareas de búsqueda semántica y recuperación de preguntas y respuestas. Este modelo también se basa en MPNet, pero se entrena sobre aproximadamente 215 millones de pares pregunta–respuesta provenientes de múltiples dominios (foro de preguntas, motores de búsqueda, plataformas de QA, entre otros) [17]. A diferencia de los modelos *all-**, que están orientados a similitud general y usan típicamente la similitud de coseno, los modelos *multi-qa* son optimizados para trabajar con producto punto como función de puntuación, capturando patrones finos de correspondencia entre consultas y documentos. En nuestro sistema, este encoder se utiliza para proyectar los títulos a un espacio semántico particularmente adecuado para tareas de recuperación, lo que permite explotar mejor la naturaleza de búsqueda del problema de recomendación top-K en catálogos extensos.

Representación de libros. En los tres casos, cada libro se representa exclusivamente mediante el título normalizado (sin utilizar reseñas completas ni descripciones largas). El texto se tokeniza y se codifica con el encoder correspondiente, obteniendo un vector denso en $\mathbb{R}^{768}$. Para las variantes basadas en similitud de coseno, los embeddings se normalizan a norma unitaria, mientras que para el modelo Multi-QA se emplea directamente el producto punto, siguiendo las recomendaciones de los autores del modelo [17]. Estas representaciones se utilizan tanto para construir modelos puramente de contenido como para alimentar el módulo de hibridación que combina la señal semántica con las preferencias aprendidas por el modelo SVD.

4.2 CF: Factorización de Matrices

El componente colaborativo de nuestro método se basa en un modelo de factorización de matrices del tipo SVD regularizado, que ha demostrado ser especialmente efectivo en tareas de recomendación basadas en calificaciones [10, 20]. La idea central es aproximar la matriz de calificaciones R mediante el producto de dos matrices de baja dimensión que capturan factores latentes de usuarios e ítems.

Específicamente, modelamos la calificación predicha $\hat{r}_{ui}$ para el usuario u y el libro i como:

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i, \tag{1}$$

donde μ es la media global de calificaciones, b_u y b_i son términos de sesgo de usuario y de ítem, respectivamente, y $p_u, q_i \in \mathbb{R}^f$ son vectores latentes de dimensión f que representan las preferencias del usuario y las características del libro. Los parámetros $\{b_u\}$, $\{b_i\}$, $\{p_u\}$ y $\{q_i\}$ se aprenden minimizando una función de pérdida cuadrática regularizada sobre las calificaciones observadas:

$$\mathcal{L} = \sum_{(u,i)\in\Omega} (r_{ui} - \hat{r}_{ui})^2 + \lambda \left(\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2 \right), \tag{2}$$

donde Ω denota el conjunto de pares usuario–libro observados y λ es un hiperparámetro de regularización que controla la complejidad del modelo. Optimizamos esta función mediante descenso de gradiente estocástico, recorriendo las interacciones observadas y actualizando los parámetros en cada iteración.

A partir de las puntuaciones $\hat{r}_{ui}$, generamos para cada usuario un ranking de libros no vistos y evaluamos su calidad mediante las métricas top-K descritas en la Sección 5.1. Este modelo sirve tanto como *baseline* colaborativo como componente principal dentro del esquema de hibridación.

4.3 Framework de Hibridación

Para combinar la información colaborativa y de contenido adoptamos una estrategia de *combinación ponderada* [5]. En este esquema, el puntaje final de relevancia para un usuario u y un libro candidato j se define como una combinación convexa de las puntuaciones normalizadas provenientes de los modelos colaborativo y basado en contenido:

$$s_{\mathrm{H}}(u, j) = (1 - \alpha)\, \tilde{s}_{\mathrm{CF}}(u, j) + \alpha\, \tilde{s}_{\mathrm{CB}}(u, j), \tag{3}$$

donde $\alpha \in [0, 1]$ es un parámetro de peso que controla la contribución relativa de cada componente. Los términos $\tilde{s}_{\mathrm{CF}}(u, j)$ y $\tilde{s}_{\mathrm{CB}}(u, j)$ corresponden a versiones normalizadas de las puntuaciones $s_{\mathrm{CF}}(u, j)$ y $s_{\mathrm{CB}}(u, j)$, respectivamente, obtenidas mediante una transformación por usuario (por ejemplo, normalización min–max o estandarización) para asegurar que ambos componentes operen en escalas comparables.

En la práctica, procedemos del siguiente modo. Primero, calculamos para cada usuario u las puntuaciones colaborativas $\hat{r}_{uj}$ sobre todos los libros candidatos $j \notin \mathcal{I}_u$ y las normalizamos en el intervalo $[0, 1]$, obteniendo $\tilde{s}_{\mathrm{CF}}(u, j)$. En paralelo, calculamos las puntuaciones de contenido $s_{\mathrm{CB}}(u, j)$ basadas en la similitud coseno entre el perfil semántico del usuario y los *embeddings* de los libros, y las normalizamos de forma análoga para obtener $\tilde{s}_{\mathrm{CB}}(u, j)$. Luego combinamos ambas puntuaciones mediante la ecuación anterior y ordenamos los libros candidatos de acuerdo con $s_{\mathrm{H}}(u, j)$.

El parámetro α se varía sistemáticamente en el rango 0.1 a 0.9 con incrementos de 0.1, lo que nos permite estudiar cómo evoluciona el rendimiento al privilegiar en distinta medida la información colaborativa o la semántica de los títulos. Esta exploración da origen a los análisis de sensibilidad presentados en la Sección 6.3, donde observamos que los mejores resultados en NDCG@10 se obtienen para valores intermedios de α, evidenciando que ninguna de las fuentes de información es suficiente por sí sola y que la combinación ponderada aporta un beneficio real.

Además, este framework de hibridación es modular: permite intercambiar el modelo de lenguaje subyacente (DistilRoBERTa, All-MPNet-Base o Multi-QA MPNet-Base) sin modificar el resto de la arquitectura, lo que facilita aislar el impacto de la elección del encoder semántico sobre el desempeño final del sistema. Esto se explota en los experimentos reportados en las Secciones 6.2 y 6.4, donde comparamos de manera directa distintas configuraciones del componente de contenido y analizamos el *trade-off* entre precisión y diversidad inducido por el parámetro α.

5 Configuración Experimental

5.1 Métricas de Evaluación

Para medir la calidad de las recomendaciones utilizamos cinco métricas estándar con un corte de $K = 10$. Primero usamos NDCG@10 y MAP@10 para evaluar la calidad del ranking. Estas métricas son importantes porque castigan al modelo si el ítem relevante aparece muy abajo en la lista. También medimos el MRR (Mean Reciprocal Rank) que nos indica qué tan rápido aparece el primer resultado correcto.

Además evaluamos la capacidad de recuperación del sistema mediante Recall@10. Esta métrica nos dice qué porcentaje de los ítems relevantes para el usuario fueron encontrados exitosamente. Finalmente, medimos la Diversidad calculando la desigualdad entre los ítems recomendados. Esto es fundamental para asegurar que el sistema no sugiera siempre productos casi idénticos y ofrezca variedad al usuario.

5.2 Modelos Baseline

Para validar nuestra propuesta, comparamos los resultados contra dos estrategias tradicionales. Por el lado del filtrado colaborativo, utilizamos SVD (Singular Value Decomposition). Este modelo se basa únicamente en la matriz de interacciones usuario-ítem para encontrar patrones latentes.

Por otro lado, comparamos contra estrategias basadas puramente en contenido (Content-Based). Estos modelos generan recomendaciones calculando la similitud coseno entre los embeddings de los títulos, sin usar datos de otros usuarios. Para esto, probamos tres arquitecturas de lenguaje diferentes: DistilRoBERTa, All-MPNet-Base y Multi-QA. Esto nos permite ver cuánto mejora el rendimiento al pasar de un enfoque simple a nuestro método híbrido.

6 Resultados y Discusión

6.1 Suficiencia de la Semántica de Títulos

La Tabla 1 presenta una comparación del rendimiento entre las estrategias base (Collaborative Filtering y Content-Based) y las arquitecturas híbridas propuestas. A partir de los resultados obtenidos, podemos notar una clara superioridad por parte de los modelos híbridos frente a los modelos baseline en la mayoría de las métricas de precisión y ranking. Especificamente, el modelo híbrido basado en All-MPNet-Base logra los mejores resultados en general en terminos de métricas de ranking, con un NDCG@10 igual a 0.089 y MAP@10 igual a 0.0585. Si comparamos esto con el modelo base SVD, que apenas alcanzaba un NDCG de 0.0292, vemos que el rendimiento mejoró casi un 200%. Esto nos confirma que la estrategia de combinar la factorización de matrices con información semántica realmente funciona y marca una diferencia importante en los resultados.

Por otro lado, es importante notar que las estrategias basadas únicamente en contenido (Baseline CB) tuvieron un rendimiento muy bajo, con métricas cercanas a cero (por ejemplo, un $NDCG$@10 de apenas 0.0016 para DistilRoBERTa). Esto nos indica que, en este caso, usar solo el texto de los títulos no basta para entender al usuario si nos falta el contexto. Al no tener datos de interacciones, estos modelos no consiguen identificar las preferencias reales del usuario; terminan sugiriendo cosas solo porque los títulos se parecen, sin asegurar que sean realmente de su interés.

Por su parte, el modelo base de Filtrado Colaborativo (SVD) funcionó mejor que los métodos de solo texto, logrando captar ciertos patrones ocultos en las interacciones de los usuarios. Sin embargo, su precisión ($NDCG$@10 de 0.0292) sigue quedándose muy atrás en comparación con nuestras propuestas híbridas. Es importante notar que el SVD base obtiene la diversidad más alta de todas (0.8348), pero al tener una precisión tan baja, ese alto valor de diversidad sugiere que el modelo está recomendando un poco de todo sin mucho criterio, en lugar de ofrecer una variedad realmente útil para el usuario.

Table 1: Comparación del rendimiento entre modelos baseline e híbridos ($K = 10$). Se destacan en negrita los mejores resultados, mientras que el segundo mejor rendimiento está subrayado.

Estrategia	Encoder	MAP@10	NDCG@10	Recall@10	MRR@10	Diversity@10	Coverage@10
Baseline (CF)	SVD	0.0187	0.0292	0.0058	0.0189	**0.8348**	0.0000
Baseline (CB)	All-DistilRoberta	0.0010	0.0016	0.0009	0.0010	0.3366	<u>0.0018</u>
Baseline (CB)	Multi-QA-MPNet-Base	0.0004	0.0007	0.0008	0.0004	0.2493	0.0012
Baseline (CB)	All-MPNet-Base	0.0071	0.0109	0.0050	0.0070	0.3365	**0.0018**
Híbrido	All-DistilRoberta	0.0482	0.0759	0.0170	0.0498	<u>0.5857</u>	0.0006
Híbrido	Multi-QA-MPNet-Base	**0.0607**	<u>0.0887</u>	**0.0244**	**0.0629**	0.4495	0.0006
Híbrido	All-MPNet-Base	<u>0.0585</u>	**0.0890**	<u>0.0243</u>	<u>0.0602</u>	0.5230	0.0007

Finalmente, queda claro que unir ambas estrategias fue un acierto. Al combinar la estructura del SVD con la comprensión profunda del texto que tienen modelos como MPNet o Multi-QA, logramos llenar los vacíos de información (sparsity) que suelen limitar a estos sistemas. De esta forma, las recomendaciones no solo se basan en popularidad, sino que mantienen una coherencia temática con el usuario. Esto se nota de forma muy clara en métricas como el *Recall*@10, que subió desde 0.0058 en el SVD original hasta 0.0244 con el Híbrido Multi-QA, demostrando que ahora el sistema es capaz de recuperar muchos más ítems relevantes.

6.2 Impacto de la Arquitectura del Encoder

Al analizar los distintos modelos de lenguaje, encontramos diferencias claras en la calidad de las recomendaciones. Los resultados muestran que tanto MPNet-Base como Multi-QA logran un rendimiento superior al de DistilRoBERTa. Mientras que este último obtuvo resultados más bajos con un *NDCG*@10 de 0.0759, los otros modelos híbridos alcanzaron valores cercanos a 0.089. Esto nos indica que la capacidad del modelo para representar el texto influye directamente en el resultado final del sistema.

La diferencia en el rendimiento se debe, probablemente, al diseño y entrenamiento de cada modelo. DistilRoBERTa es una versión reducida, lo que limita un poco su capacidad para captar detalles complejos en el texto. En cambio, MPNet-Base y Multi-QA fueron optimizados específicamente para entender la relación entre oraciones completas. Esto les permite generar representaciones numéricas (embeddings) más precisas de los títulos, ayudando al sistema a relacionar mejor los productos, aunque existan pocos datos de interacción.

Por último, cabe mencionar el desempeño del modelo Multi-QA. Este modelo logra los resultados más altos en métricas específicas como MAP y MRR, superando ligeramente al resto en su capacidad para ordenar los ítems relevantes. Esto sugiere que su entrenamiento original, basado en preguntas y respuestas, le ayuda a distinguir con mucha exactitud qué resultados son correctos. Sin embargo, es importante notar que la diferencia con MPNet-Base en cuanto a precisión es pequeña, y como veremos luego, este último ofrece ventajas en otras áreas como la diversidad.

6.3 Análisis de Sensibilidad de Parámetros

Para entender mejor cómo interactúan el modelo colaborativo y el de contenido analizamos el impacto del parámetro α (alpha). Este valor define el peso que le damos al modelo colaborativo SVD en la ecuación final del modelo híbrido. Un valor bajo significa que se le da más peso a la similitud de los textos y un valor alto da mayor prioridad a los patrones de interacción de los usuarios.

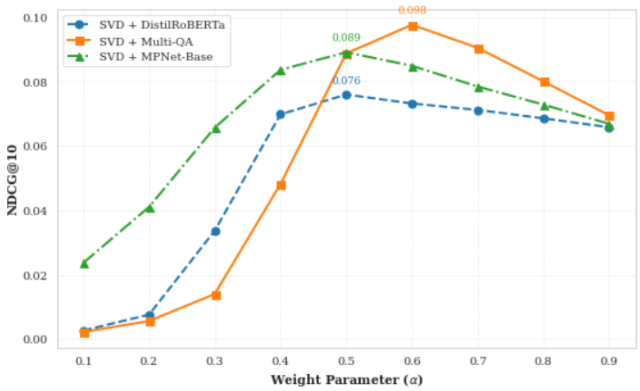

Figure 1: Sensibilidad del rendimiento (NDCG@10) respecto al parámetro de peso α. Se observa que el modelo SVD + Multi-QA alcanza el máximo global (0.098) en $\alpha = 0.6$, demostrando una mayor capacidad para aprovechar la información semántica en comparación con MPNet-Base y DistilRoBERTa.

Como se observa en la Figura 1, el rendimiento sigue una curva donde el mejor resultado se encuentra siempre en un valor intermedio. Esto confirma que el sistema no funciona bien si depende solo de una fuente de información. El máximo desempeño se logra únicamente cuando equilibramos la información del contenido con las interacciones previas.

El punto de máximo rendimiento varía según el modelo utilizado. MPNet-Base alcanza su mejor resultado con un α de 0.5 y Multi-QA logra su máximo con un α de 0.6. Si observamos la parte izquierda del gráfico vemos que MPNet se mantiene estable incluso con valores bajos de α. Por el contrario, el modelo Multi-QA cae drásticamente en esa zona y necesita un mayor peso del modelo mase SVD para lograr un mejor resultado, por lo que depende un poco más de este.

6.4 Precisión vs. Diversidad

Finalmente analizamos la relación entre la precisión y la diversidad de las recomendaciones. La Figura 2 muestra dos comportamientos muy diferentes a medida que aumentamos el valor de alpha. La

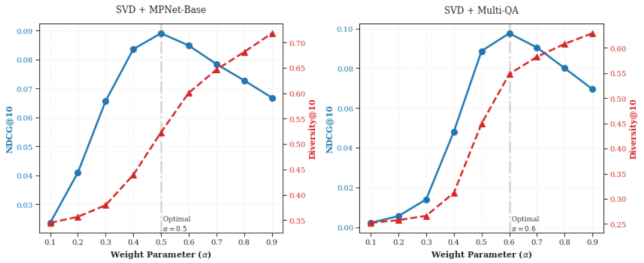

Figure 2: Análisis del trade-off entre precisión y diversidad. Se muestra el comportamiento de SVD + MPNet-Base y SVD + Multi-QA al variar α. La línea sólida azul (eje izq.) representa la precisión (NDCG@10), mientras que la línea punteada roja (eje der.) muestra la Diversidad@10. Las líneas verticales grises marcan el punto óptimo de hibridación, donde se maximiza la precisión logrando un aumento significativo en la diversidad respecto al modelo base ($\alpha = 0$).

línea azul indica que la precisión mejora hasta llegar a un máximo y luego cae. Por el contrario la línea roja muestra que la diversidad aumenta de forma constante a medida que le damos más peso al modelo colaborativo.

Esto revela una ventaja clave de nuestra estrategia híbrida. En el punto de mayor rendimiento ($\alpha = 0.5$ para MPNet-Base) no solo obtenemos la máxima precisión posible. También logramos aumentar la diversidad hasta un valor cercano a 0.52. Esto representa una mejora significativa respecto a los modelos basados solo en contenido que apenas superan el 0.33 en diversidad y suelen ser muy repetitivos.

Es cierto que el modelo SVD base tiene la diversidad más alta de todas. Sin embargo ya vimos anteriormente que su precisión es baja porque recomienda ítems muy dispersos sin acertar en los gustos del usuario. Por lo tanto el modelo híbrido ofrece el mejor equilibrio real para el sistema. Logra entregar recomendaciones que son altamente relevantes para el usuario y al mismo tiempo lo suficientemente variadas para mantener su interés.

7 Conclusiones y Trabajo Futuro

En este trabajo presentamos una estrategia que mezcla el método clásico de SVD con modelos de lenguaje modernos. Los resultados nos mostraron que los títulos de los libros por sí solos no sirven para recomendar correctamente pero al combinarlos con las interacciones logramos superar por mucho a los métodos tradicionales. También confirmamos que es vital elegir bien el modelo de lenguaje. Vimos que modelos como MPNet-Base y Multi-QA funcionaron mucho mejor que otros más básicos como DistilRoBERTa porque entienden mejor el significado de los títulos.

Para el futuro queremos probar formas más inteligentes de unir estos dos modelos en lugar de usar una suma simple con un valor fijo. Una idea es utilizar redes neuronales para que el sistema aprenda por sí solo la importancia del texto y de las interacciones, siguiendo la tendencia actual hacia sistemas de recomendación neuronales ricos en información [20]. También tenemos planeado usar más datos como los resúmenes de los libros. Esto nos ayudaría a tener mucha más información para recomendar ítems nuevos o que tienen muy pocos datos de usuarios.

References

[1] Jesús Bobadilla, Fernando Ortega, Antonio Hernando, and Javier Gutiérrez. 2013. Recommender Systems Survey. *Knowledge-Based Systems* 46 (2013), 109–132. doi:10.1016/j.knosys.2013.03.012

[2] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. 2017. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics* 5 (2017), 135–146. doi:10.1162/tacl_a_00051

[3] Bright Data. 2024. Goodreads-Books. https://huggingface.co/datasets/BrightData/Goodreads-Books. Dataset de metadatos de libros de Goodreads, consultado el 9-dic-2025.

[4] Robin Burke. 2002. Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction* 12, 4 (2002), 331–370. doi:10.1023/A:1021240730564

[5] Robin Burke. 2002. Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction* 12, 4 (2002), 331–370. doi:10.1023/A:1021240730564

[6] Abedalrahim Butmeh and Ashraf Abu-Issa. 2024. Hybrid Attribute-Based Recommender System for Personalized E-Learning with Emphasis on Cold Start Problem. *Frontiers in Computer Science* (2024). Advance online publication.

[7] Albertus Dwi Andhika Putra Darmansius and Hafiz Irsyad. 2025. Implementation of Word Embedding in Book Recommendations Based on Descriptions. *Brilliance: Research of Artificial Intelligence* 5, 1 (2025), 474–492. doi:10.47709/brilliance.v5i1.6456

[8] Bahram Jannesar. 2020. Goodreads Book Datasets with User Rating 2M. https://www.kaggle.com/datasets/bahramjannesarr/goodreads-book-datasets-10m. Dataset de interacciones usuario–libro de Goodreads, consultado el 9-dic-2025.

[9] Shashidhar Reddy Javaji and Krutika Sarode. 2023. Hybrid Recommendation System Using Graph Neural Network and BERT Embeddings. *arXiv preprint* arXiv:2310.04878 (2023). https://arxiv.org/abs/2310.04878

[10] Yehuda Koren, Robert Bell, and Chris Volinsky. 2009. Matrix Factorization Techniques for Recommender Systems. *Computer* 42, 8 (2009), 30–37. doi:10.1109/MC.2009.263

[11] Katjana Kosic. 2022. Introduction to Recommender Systems and their Applications. Bachelor's thesis, Technical University of Munich. Retrieved from mediaTUM institutional repository.

[12] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient Estimation of Word Representations in Vector Space. In *Proceedings of the International Conference on Learning Representations (ICLR 2013), Workshop Track*. ICLR. arXiv:1301.3781.

[13] Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, 3982–3992. doi:10.18653/v1/D19-1410

[14] Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, 3982–3992. doi:10.18653/v1/D19-1410

[15] Nils Reimers and Iryna Gurevych. 2020. all-distilroberta-v1: A General-Purpose Sentence Embedding Model. https://huggingface.co/sentence-transformers/all-distilroberta-v1. Accessed: 2025-12-09.

[16] Nils Reimers and Iryna Gurevych. 2020. all-mpnet-base-v2: A General-Purpose MPNet-Based Sentence Embedding Model. https://huggingface.co/sentence-transformers/all-mpnet-base-v2. Accessed: 2025-12-09.

[17] Nils Reimers and Iryna Gurevych. 2021. multi-qa-mpnet-base-dot-v1: A Semantic Search Model Trained on Question–Answer Pairs. https://huggingface.co/sentence-transformers/multi-qa-mpnet-base-dot-v1. Accessed: 2025-12-09.

[18] Seema Safar, Babita Roslind Jose, Jimson Mathew, and T. Santhanakrishnan. 2025. Recommendation Systems with LLM-Based Semantic Embeddings and FAISS Similarity Search. *Neurocomputing* 649 (2025), 130753. doi:10.1016/j.neucom.2025.130753

[19] Mostafa Salehi et al. 2013. A Hybrid Attribute-Based Recommender System for E-Learning Material Recommendation. *Journal of e-Learning and Higher Education* (2013). Hybrid recommendation of educational resources based on attributes.

[20] Le Wu, Xiangnan He, Xiang Wang, Kun Zhang, and Meng Wang. 2023. A Survey on Accuracy-Oriented Neural Recommendation: From Collaborative Filtering to Information-Rich Recommendation. *IEEE Transactions on Knowledge and Data Engineering* 35, 5 (2023), 4425–4445.

[21] Shuai Zhang, Lina Yao, Aixin Sun, and Yi Tay. 2019. Deep Learning Based Recommender System: A Survey and New Perspectives. *Comput. Surveys* 52, 1

(2019), 5:1–5:38. doi:10.1145/3285029

[22] Tomáš Černý. 2024. Text Embeddings for Recommender Systems. Bachelor's thesis, Czech Technical University in Prague. Faculty of Electrical Engineering, Department of Computer Science.