CIVIConnect: Sistema de recomendación de audiencias cívicas

Felipe Marín [1] **Camila Rojas** [1]

Abstract

En la sociedad de la información, los sistemas de recomendación cumplen un rol crucial al ayudar a los usuarios a navegar grandes volúmenes de datos. En el contexto de la gestión de intereses en Chile, el registro de la Ley de Lobby presenta un desafío particular: aunque contiene información detallada sobre más de un millón de audiencias, no ofrece herramientas que orienten a los solicitantes hacia las autoridades más pertinentes. Esta ausencia de soporte dificulta la toma de decisiones, incrementa la carga cognitiva y contribuye a una fuerte concentración de solicitudes en un pequeño grupo de autoridades, reforzando el sesgo de popularidad.

Este trabajo aborda este problema mediante el desarrollo de un sistema de recomendación híbrido diseñado para identificar autoridades relevantes a partir de afinidades temáticas latentes. Para enfrentar obstáculos estructurales como la extrema esparsidad de la matriz de interacciones y el problema de arranque en frío (*Cold-Start*), se propone una arquitectura que combina modelos de lenguaje (SBERT) con un esquema de *clustering* en dos etapas capaz de estructurar semánticamente el corpus. Este enfoque permite capturar la relación entre temas y autoridades incluso en ausencia de historial de interacciones, sentando las bases para un sistema de recomendación más equitativo y eficaz dentro del ecosistema del lobby regulado.

El código fuente completo, incluyendo el procesamiento, modelamiento y evaluación, se encuentra disponible públicamente en: https://github.com/camirojasguajardo/lobby-recsys.

1. Introducción

En Chile, el registro de audiencias de la Ley del Lobby ha acumulado más de 620.000 reuniones entre sujetos activos (solicitantes) y sujetos pasivos (autoridades) desde 2014. A pesar de su volumen y detalle, el registro carece de mecanismos que orienten a los solicitantes respecto de qué autoridad es más pertinente para sus temas de interés o sus antecedentes de interacción. Esta ausencia de guía genera una carga cognitiva elevada, decisiones poco informadas y desigualdades en la capacidad de navegación institucional, afectando con mayor fuerza a actores con menor experiencia en gestiones públicas. El fenómeno se agrava por la alta concentración en la distribución de solicitudes: un grupo reducido de autoridades concentra un volumen desproporcionado de audiencias, mientras muchas otras prácticamente no reciben solicitudes. Esta asimetría no solo revela ineficiencias en el uso del mecanismo, sino que puede restringir la diversidad de voces que acceden a ciertas autoridades y reproducir dinámicas de poder preexistentes.

Frente a este escenario, proponemos desarrollar y evaluar un sistema de recomendación que integre simultáneamente señales estructurales (patrones de interacción, perfiles históricos) y semánticas (materias tratadas, afinidades temáticas) derivadas del registro de audiencias. El objetivo es identificar autoridades pertinentes para cada solicitante, reducir la sobrecarga de opciones y promover una distribución más equilibrada y eficiente de las solicitudes dentro del ecosistema del lobby regulado.

2. Dataset

La información utilizada en este proyecto proviene del portal público Ley del Lobby, regulado por la Ley N° 20.730, que registra las audiencias entre autoridades públicas (sujetos pasivos) y solicitantes (sujetos activos) desde 2014. Si bien los datos son públicos y accesibles, el sitio no ofrece una API ni un formato estructurado de descarga, lo que hizo necesario implementar un proceso de web scraping para su recolección. Se desarrolló un programa para navegar de forma automática las distintas secciones del sitio, identificar enlaces de detalle y extraer información de manera controlada. Este procedimiento permitió construir una base de datos estructurada con más de 1,153,810 audiencias registradas entre 2014 y 2024, cada una con su fecha, institución, autoridades participantes, asistentes y materias tratadas. Esto fue indispensable para transformar datos dispersos y no estructurados en un formato analizable, que posteriormente servirá como entrada para los modelos de recomendación propuestos. El dataset se puede encontrar aquí.

Table 1. Caracterización del Dataset

Métrica	Valor
Total de Interacciones	1,153,810
Total Sujetos Pasivos (Items)	20,481
Total Sujetos Activos (Usuarios)	376,788
Esparsidad	99.9850%
Promedio x Autoridad	56.34
Promedio x Gestor	3.06

3. Solucion al problema

El objetivo central del sistema es predecir la afinidad latente entre un Sujeto Activo u (gestor de intereses) y un Sujeto Pasivo i (autoridad/funcionario). A diferencia de los sistemas de recomendación tradicionales que operan con *feedback explícito* (calificaciones), este escenario se modela bajo un esquema de feedback implícito positivo: la existencia de una audiencia registrada constituye una señal de interés, mientras que la ausencia de interacción no implica necesariamente desinterés negativo. El reto consiste en generar un ranking de autoridades relevantes para cada gestor, maximizando la probabilidad de una interacción futura exitosa basada en la coherencia temática.

La implementación efectiva de este sistema enfrenta barreras estructurales críticas inherentes al dominio de la gestión de intereses. En primer lugar, la matriz de interacción Usuario-Item presenta una extrema esparsidad, dado que la gran mayoría de los gestores interactúa con una fracción mínima del universo total de autoridades. Simultáneamente, el sistema debe gestionar un problema de Cold-Start) bidireccional, afectando tanto a nuevos gestores que ingresan al sistema sin historial, como a nuevas autoridades asumidas que aún no registran audiencias. Finalmente, existe un desafío de desbalance de carga o sesgo de popularidad: un subconjunto reducido de autoridades tiende a concentrar la mayoría de las solicitudes, generando una saturación que el sistema de recomendación debe intentar mitigar distribuyendo la visibilidad hacia otras autoridades igualmente competentes en las materias requeridas.

Para superar estas limitaciones, proponemos un enfoque de recomendación híbrido fundamentado en el contenido semántico latente. La hipótesis central sostiene que la afinidad temática —extraída del procesamiento de los detalles de las reuniones— es un predictor más robusto y estable que el historial de interacciones puro, especialmente en escenarios de esparsidad y arranque en frío.

Para validar esta aproximación, el estudio contempla un diseño experimental que contrasta el desempeño de métodos de referencia (*baselines*) del estado del arte frente a cinco arquitecturas propietarias. Estos cinco modelos proponen diferentes enfoques para la construcción del perfil de usuario y la fusión de información semántica, permitiendo evaluar qué estrategia de representación logra capturar mejor la intención del usuario y equilibrar la relevancia con la diversidad en las recomendaciones.

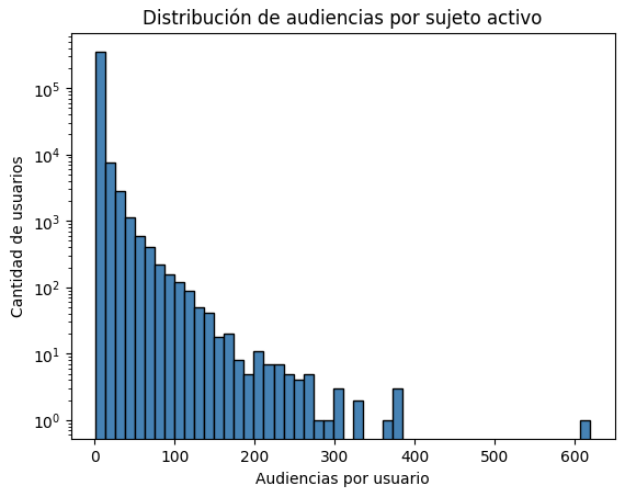

Figure 1. Distribución de la cantidad de audiencias realizadas por Sujeto Activo (Gestor). La escala logarítmica en el eje Y evidencia una distribución de *cola larga* (Power Law), donde la gran mayoría de los actores posee un historial mínimo de interacciones, lo que confirma visualmente el desafío de la esparsidad en la matriz de datos.

Adicionalmente, para cuantificar y mitigar el sesgo de popularidad (desbalance de carga), se incorpora el Coeficiente de Gini como métrica de dispersión. Este indicador permite monitorear que el sistema no concentre excesivamente las recomendaciones en un subconjunto reducido de autoridades. Matemáticamente, dada una lista de autoridades ordenadas de forma ascendente según la frecuencia con la que fueron recomendadas (y_i), el coeficiente se define como:

$$G = \frac{\sum_{i=1}^{n}(2i - n - 1)y_i}{n\sum_{i=1}^{n} y_i} \tag{1}$$

Donde n representa el número total de autoridades disponibles (sujetos pasivos) y y_i es la cantidad de veces que la autoridad i apareció en las listas de recomendación. Un valor de G cercano a 1 evidencia una fuerte concentración (pocos reciben todas las recomendaciones), mientras que un valor cercano a 0 indica una distribución equitativa de la carga, objetivo deseable para fomentar la visibilidad de actores menos conocidos pero temáticamente relevantes.

4. Metodología

La metodología se organiza en tres etapas complementarias. En primer lugar, se implementan modelos de referencia que

permiten establecer un umbral comparativo sobre el cual evaluar métodos más expresivos. En la segunda etapa, se introducen dos modelos que constituyen referencias de estado del arte en sistemas de recomendación: LightFM, que integra interacciones implícitas con atributos semánticos de usuarios y autoridades, y LightGCN, que aprende representaciones latentes a partir de la estructura del grafo de audiencias. Estos modelos permiten estimar la capacidad predictiva de señales colaborativas y semánticas bajo configuraciones de estado del arte. Sin embargo, las limitaciones observadas en ambos enfoques —LightFM al no modelar explícitamente la topología de la red, y LightGCN al no incorporar información temática— motivan una tercera etapa centrada en extensiones específicas de cada familia de modelos. Por un lado, se propone un esquema jerárquico en dos etapas basado en clustering semántico y re-ranking supervisado; por otro, se desarrolla una variante tripartita de LightGCN que incorpora nodos temáticos para integrar semántica y estructura en un único grafo. En conjunto, esta secuencia metodológica permite evaluar de forma incremental el aporte marginal de cada fuente de información y fundamenta por qué las variaciones propuestas son necesarias para capturar de manera más fiel la pertinencia entre sujetos activos y autoridades públicas.

4.1. LightFM

Para incorporar señales de contenido en combinación con preferencias observadas, se empleó el modelo LightFM con retroalimentación implícita, integrando interacciones usuario–autoridad y atributos semánticos derivados de los textos de materias tratadas. Para integrar señales semánticas en el modelo de recomendación, se construyeron matrices de características para usuarios y autoridades a partir de los textos de las materias tratadas en sus audiencias previas. Cada texto fue representado mediante un embedding de 384 dimensiones generado con distiluse-base-multilingual-cased-v2, y las representaciones finales de usuarios y autoridades se obtuvieron como el promedio ponderado por recencia de los embeddings de todas las materias asociadas a sus audiencias históricas. Estas features se combinaron con la matriz de interacciones en un modelo LightFM con retroalimentación implícita, entrenado mediante la función de pérdida WARP, adecuada para optimizar rankings top-k, y un espacio latente de 32 dimensiones. La evaluación se realizó con un corte temporal de las interacciones y las métricas estándar Precision@10 y AUC. Finalmente, se llevó a cabo un barrido de hiperparámetros considerando variantes de la función de pérdida, dimensionalidad y tasa de aprendizaje, seleccionándose la configuración con mejor desempeño para su entrenamiento final sobre el conjunto completo.

4.2. LightGCN

Como modelo de referencia basado exclusivamente en señales colaborativas, se implementó LightGCN siguiendo la formulación original de He et al. (2020). A partir del conjunto de audiencias históricas, se construyó un grafo bipartito usuario–autoridad y su matriz de adyacencia normalizada $\hat{A} = D^{-1/2}AD^{-1/2}$, representada como tensor disperso para permitir propagación eficiente. Cada usuario y autoridad se inicializó con un vector latente aprendido, y las representaciones finales se obtuvieron mediante un promedio de múltiples capas de propagación sobre el grafo, sin transformaciones no lineales, manteniendo la simplicidad estructural característica del modelo. El entrenamiento se realizó mediante optimización de la función Bayesian Personalized Ranking (BPR), utilizando muestreo negativo uniforme y regularización L_2 sobre los embeddings. Se empleó validación temporal por usuario (leave-last-1), con *early stopping* basado en nDCG@10, y evaluación final en el conjunto de prueba considerando Recall@10, nDCG@10 y MAP@10, aplicando filtrado estricto de interacciones presentes en el entrenamiento. Esta implementación permite capturar afinidades estructurales dentro de la red institucional de audiencias, entregando un estimador puramente topológico del grado de pertinencia entre sujetos activos y autoridades públicas.

4.3. LightGCN en base a grafo tripartito

Para incorporar información semántica en el modelo y enriquecer la estructura colaborativa original, se extendió el grafo bipartito usuario–autoridad mediante la incorporación de una tercera partición compuesta por nodos temáticos. Estos nodos representan grupos latentes de materias tratadas en las audiencias y se conectan a las autoridades según su historial de temas, permitiendo que LightGCN propague señales tanto estructurales como semánticas. El proceso de construcción temática se desarrolló en tres etapas. Primero, los *embeddings* originales de las materias fueron reducidos dimensionalmente mediante Análisis de Componentes Principales (PCA), conservando 212 componentes. Esta dimensionalidad coincide con la configuración seleccionada para el modelo base, de acuerdo con los resultados del barrido de hiperparámetros (Tabla 3), lo que asegura coherencia entre la representación semántica y el espacio latente utilizado por LightGCN. En segundo lugar, se exploró la estructura temática aplicando `MiniBatchKMeans` sobre una submuestra de 50.000 observaciones de los *embeddings* reducidos. Se evaluaron distintos niveles de granularidad, variando el número de clústeres en $k \in 100, 200, 300, 500, 600, 700, 800$ y calculando para cada partición el índice de silueta y el índice de Davies–Bouldin. Aunque los valores absolutos de estas métricas reflejan la naturaleza difusa del espacio semántico, los resultados muestran una mejora relativa al incrementar la granulari-

dad. En particular, $k = 500$ obtiene simultáneamente el mayor valor de silueta y una de las menores puntuaciones de Davies–Bouldin, configurándose como el punto de equilibrio más adecuado para capturar diversidad temática sin fragmentación excesiva. Finalmente, se ajustó un modelo definitivo de `MiniBatchKMeans` con $k = 500$ clústeres y se asignó a cada materia un identificador de tópico, el cual se utilizó para construir las conexiones autoridad–tema dentro del grafo tripartito. Los nodos temáticos fueron inicializados con sus *embeddings* PCA, mientras que usuarios y autoridades se inicializaron aleatoriamente. El modelo tripartito se entrenó utilizando LightGCN con tres capas de propagación, pérdida BPR y regularización L2 de 10^{-4}, manteniendo la tasa de aprendizaje 10^{-3} seleccionada en el barrido preliminar. Esta configuración permite preservar la efectividad observada en el modelo colaborativo base, a la vez que introduce una vía explícita para integrar señales semánticas en la propagación de representaciones.

4.4. Clustering semántico

El análisis se fundamentó en el atributo textual *detalle* de los 1.15 millones de registros de la Ley de Lobby, considerado el elemento crítico para inferir similitudes semánticas. El flujo de trabajo propuesto se estructura en cuatro etapas secuenciales: pre-procesamiento, reducción de dimensionalidad, clustering multiple y etiquetado semántico.

Se implementó una etapa de limpieza para eliminar artefactos HTML y normalizar el texto, descartando estructuras burocráticas repetitivas mediante una lista de *stop-words* de dominio específico. Para la representación vectorial, se utilizó el modelo *SBERT (Sentence-BERT)*, generando *embeddings* semánticos contextuales diseñados para capturar la intención en textos cortos.

Para mitigar la dispersión de los datos y el costo computacional, se diseñó una estrategia de reducción en dos etapas:

1. *PCA (Lineal):* Aplicado para filtrar el ruido redundante y retener la varianza global esencial de los vectores de alta dimensión.

2. *UMAP (No Lineal):* Utilizado para proyectar los datos a un espacio de menor dimensión, preservando la estructura topológica y optimizando la conectividad de la vecindad local (*manifold structure*) necesaria para el agrupamiento por densidad.

Se empleó el algoritmo *HDBSCAN* como motor principal para identificar núcleos temáticos de alta densidad de manera jerárquica. Dado que los métodos de densidad tienden a descartar puntos dispersos como ruido —una característica prevalente en textos administrativos cortos—, se diseñó un módulo de recuperación híbrida. Esta estrategia consiste en aislar los datos no clasificados (*outliers*) y aplicarles un algoritmo de partición *MiniBatch K-Means*. El número óptimo de clústeres para esta fase (K_{opt}) se determina mediante la optimización conjunta del Coeficiente de Silueta y la Inercia (Método del Codo).

Para dotar de interpretabilidad a los grupos resultantes (tanto densos como recuperados), se implementó la técnica *C-TF-IDF (Class-based TF-IDF)*. Este método calcula la importancia de las palabras dentro de cada clúster penalizando los términos burocráticos transversales (e.g., "solicitud", "audiencia") y priorizando los términos discriminantes, generando así etiquetas dinámicas representativas.

5. Resultados

5.1. Baselines y Selección de Modelos de Referencia

Para contextualizar el desempeño de la propuesta híbrida, se implementaron tres modelos de referencia ajustados para retroalimentación implícita. Se evaluaron primero métodos basados en vecindad (*User-KNN* e *Item-KNN*) usando similitud del Coseno y un vecindario de $K = 20$. *User-KNN* obtuvo el mejor desempeño en recall entre los baselines (Recall@10 = 0.0828), superando a *Item-KNN* (Recall@10 = 0.0527). Este último presentó un marcado sesgo de popularidad, reflejado en un Coeficiente de Gini de 0.9470, lo que indica que tiende a recomendar casi exclusivamente a las autoridades más frecuentes. Como alternativa, se implementó el algoritmo *Alternating Least Squares* (ALS) siguiendo la formulación de Hu et al. Tras la búsqueda de hiperparámetros, la configuración óptima ($f = 200$, $\alpha = 80$, $\lambda = 0.1$) alcanzó las mejores métricas de ranking del grupo (MAP@10 = 0.1409; nDCG@10 = 0.1885). Esto muestra que la factorización matricial ordena mejor la relevancia, aunque su recall (Recall@10 = 0.0156) sea menor que el de los métodos basados en memoria en este dominio disperso.

5.2. LightFM

Para explorar el desempeño, se realizó un barrido de hiperparámetros considerando variaciones en la función de pérdida (warp y bpr), el tamaño del espacio latente (32 y 64 dimensiones) y la tasa de aprendizaje (0.01 y 0.05). Todos los modelos se entrenaron en un conjunto reducido de 2.000 usuarios con al menos cinco interacciones, con el objetivo de acelerar la exploración manteniendo una señal colaborativa representativa. Los resultados muestran que las configuraciones basadas en la pérdida WARP obtuvieron sistemáticamente mejores métricas que las variantes BPR, especialmente en términos de Precision@10, que es la métrica más relevante para el problema de recomendación top-k. Dentro de las combinaciones evaluadas, el mejor desempeño

se alcanzó con WARP, 32 dimensiones latentes y una tasa de aprendizaje de 0.05, logrando un P@10 = 0.007 y un AUC = 0.869. Las configuraciones con mayor dimensionalidad (64) no produjeron mejoras sustantivas y, en algunos casos, aumentaron el sobreajuste en el conjunto reducido de entrenamiento. A partir de estos resultados, se seleccionó como configuración final para los experimentos de mayor escala el modelo LightFM (WARP), 32 dimensiones, learning rate = 0.05, con regularización mínima.

Table 2. Resultados del barrido de hiperparámetros para LightFM (muestra de 2,000 usuarios)

Pérdida	**Dimensiones**	**LR**	**P@10**	**AUC**	**Épocas**
WARP	32	0.05	**0.0070**	0.869	8
WARP	64	0.05	0.0067	0.873	8
WARP	64	0.01	0.0027	0.829	6
BPR	64	0.05	0.0027	0.795	8
WARP	32	0.01	0.0020	0.814	6
BPR	32	0.05	0.0020	0.795	8
BPR	64	0.01	0.0020	0.672	8
BPR	32	0.01	0.0013	0.621	6

Una vez seleccionada la mejor configuración en la fase de exploración (LightFM con pérdida WARP, 32 dimensiones latentes y tasa de aprendizaje 0.05), el modelo se entrenó sobre el conjunto completo. Los resultados muestran un desempeño consistente con lo observado en la muestra reducida, alcanzando un AUC de 0.86, indicando una buena separación global entre interacciones observadas y no observadas. Sin embargo, el desempeño en ranking top-k se mantuvo bajo, obteniendo un P@10 de 0.003, lo cual es esperable dada la alta dispersión y la baja densidad de interacciones relevantes por usuario. El entrenamiento se detuvo por early stopping alrededor de la época 10, reflejando que el modelo converge rápidamente pero carece de capacidad para capturar estructuras más ricas en el espacio de recomendaciones.

5.3. LightGCN e incorporación de nodos temáticos

Para evaluar el desempeño de LightGCN y seleccionar una configuración adecuada para los experimentos a gran escala, se realizó un barrido de hiperparámetros utilizando una muestra del 10% de los usuarios. El objetivo fue acelerar la exploración manteniendo una señal colaborativa representativa, en un escenario particularmente desafiante debido a la extrema dispersión de interacciones en el conjunto completo.

Se consideraron variaciones en la dimensionalidad del espacio latente (64 y 128 dimensiones), en la profundidad del modelo (1, 2 y 3 capas) y en los parámetros de optimización (tasas de aprendizaje de 5e–4 y 1e–3 junto con regularizaciones L2 de 1e–5 y 1e–4). Cada configuración se entrenó durante 10 épocas aplicando un muestreo reducido de pares (`sample_frac = 0.002`), lo que permitió ejecutar los experimentos en pocos segundos por combinación sin perder capacidad comparativa entre modelos.

Los resultados del barrido muestran que la métrica MAP@10 —la más relevante para evaluar el rendimiento en un escenario de recomendación top-k— mejora sistemáticamente al aumentar la dimensionalidad y la profundidad de propagación. En particular, las configuraciones con 128 dimensiones y tres capas obtienen los mejores desempeños en la muestra exploratoria, superando tanto a las alternativas con 64 dimensiones como a modelos más superficiales. Asimismo, el uso de una tasa de aprendizaje más alta (1e–3) combinado con una regularización moderada (1e–4) contribuye a una convergencia estable incluso bajo el muestreo agresivo utilizado para acelerar la experimentación.

La Tabla 3 resume los resultados obtenidos. Dentro del conjunto evaluado, la mejor configuración corresponde a 128 dimensiones latentes, 3 capas, learning rate = 1e–3 y regularización L2 = 1e–4, alcanzando un MAP@10 = **0.01057** en la muestra del 10%.

Table 3. Resultados del barrido de hiperparámetros para LightGCN (muestra del 10%)

Dimensiones	Capas	LR	L2	MAP@10
128	3	1e-3	1e-4	**0.01057**
64	3	1e-3	1e-4	0.01025
64	1	5e-4	1e-5	0.00790
64	2	1e-3	1e-5	0.00990
128	1	5e-4	1e-4	0.00920
128	2	1e-3	1e-5	0.01059
64	2	5e-4	1e-4	0.00940
128	1	1e-3	1e-5	0.00980

Con esta configuración seleccionada, se procedió a entrenar el modelo sobre el *dataset completo*. El comportamiento de validación mostró una evolución estable y monótonamente creciente: las primeras épocas ya obtenían valores competitivos (MAP@10 = 0.0270 en la época 1 y 0.0300 en la época 4), y a partir de la época 10 el modelo se estabilizó en torno a MAP@10 $\approx$ 0.030. La métrica continúo mejorando gradualmente hasta alcanzar MAP@10 = 0.0345 en la última época, acompañada de incrementos consistentes en Recall@10 (de 0.0624 a 0.0755) y nDCG@10 (de 0.0353 a 0.0441), indicando una capacidad creciente para priorizar correctamente los ítems relevantes.

Finalmente, en el conjunto de prueba del *dataset* completo, esta configuración alcanzó un **MAP@10 = 0.01060**, junto con Recall@10 = 0.0239 y nDCG@10 = 0.0137, superando de manera consistente al resto de las alternativas evaluadas en el barrido preliminar. Para caracterizar la distribución de

exposición generada por el modelo, se calculó además el *índice de Gini* sobre la frecuencia con que los distintos ítems aparecen en las recomendaciones top-10, obteniéndose un valor de Gini = 0.896. Esta cifra refleja una concentración elevada de exposición, consistente con la alta dispersión y escasez de interacciones en el conjunto original. En función de estos resultados, se adoptó esta configuración como modelo base para los experimentos a gran escala.

El desempeño del modelo tripartito fue evaluado utilizando la misma configuración óptima identificada para el LightGCN base, lo que permite una comparación directa entre ambas arquitecturas. Durante el entrenamiento, la métrica nDCG@10 en el conjunto de validación mostró una trayectoria estable y monótonamente ascendente: desde valores iniciales cercanos a 0.0297 en las primeras épocas, pasando por 0.0345 en torno a la época 38, hasta alcanzar un máximo de 0.0418 en la época 100. Esta evolución indica que la incorporación de nodos temáticos no introduce inestabilidad en la propagación y que el modelo logra aprovechar de manera creciente la señal semántica adicional. En el conjunto de prueba, el rendimiento final del modelo tripartito fue comparable al observado en la versión puramente colaborativa, obteniendo Recall@10 = 0.0232, nDCG@10 = 0.0133 y MAP@10 = 0.0103. Si bien estos resultados no representan mejoras sustantivas respecto del modelo base, confirman que la integración explícita de tópicos mantiene la calidad predictiva.

5.4. Clustering semántico

La aplicación inicial de HDBSCAN logró detectar núcleos temáticos de alta coherencia; sin embargo, como se anticipaba debido a la naturaleza difusa de los textos, el algoritmo clasificó aproximadamente el 65% de la muestra como ruido (etiqueta -1).

La implementación de la estrategia híbrida resultó crítica para la viabilidad del sistema. Mediante el análisis de silueta e inercia sobre el ruido, se determinó un $K_{opt} = 200$ para la fase de recuperación. Esta intervención permitió clasificar exitosamente la totalidad del ruido residual, elevando la cobertura del modelo del 35% al 100%. La integración final de ambas fases resultó en un inventario consolidado de 2,091 temas latentes, abarcando desde tópicos densos y específicos hasta temáticas más generales recuperadas por la partición.

La Tabla 4 presenta una muestra de los clústeres identificados y sus etiquetas generadas automáticamente mediante C-TF-IDF. Se observa una alta correspondencia semántica entre las palabras clave extraídas y la etiqueta asignada, tanto para clústeres densos (IDs bajos) como para los recuperados (IDs altos), validando la capacidad del modelo para generar una taxonomía coherente sin intervención humana.

ID	*Etiqueta Generada*	*Palabras Clave (Top 3)*
2948	proyectos-reunion-informa	proyectos, reunion, informa
904	proyectos-ambientales-evaluación	proyectos, ambientales, evaluación
1238	solicitante-solicitantes-presentó	solicitante, solicitantes, presentó
3075	social-socialsocial-beneficiosocial	social, social social, beneficio social
2901	permiso-permisoedificación-edificación	permiso, permiso edificación, edificación

Table 4. Muestra aleatoria de clústeres semánticos identificados. Se observa la coherencia entre la etiqueta generada automáticamente y las palabras clave más representativas (Top-3 C-TF-IDF).

Finalmente, la Figura 2 muestra la capacidad operativa del modelo. Al procesar una consulta en lenguaje natural no vista previamente, el sistema es capaz de mapear la intención del usuario hacia el centroide del clúster más cercano (e.g., temas de vivienda) y recuperar a las autoridades pertinentes, superando la limitación de coincidencia exacta de palabras clave.

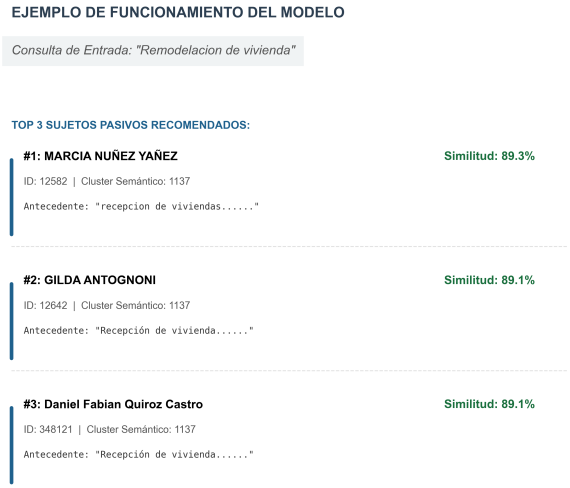

Figure 2. Ejemplo de funcionamiento del motor de recomendación semántico. A partir de una consulta en lenguaje natural ("Remodelación de vivienda"), el sistema recupera los sujetos pasivos con mayor similitud coseno respecto a sus perfiles latentes. *Nota: Esta visualización se generó utilizando la totalidad del corpus para fines ilustrativos de la capacidad cualitativa del modelo.*

6. Conclusiones

El análisis comparativo muestra diferencias marcadas entre las familias de modelos evaluadas, evidenciando que la incorporación de información semántica es crítica en dominios con esparsidad extrema. El enfoque de *Clustering Semántico* obtuvo el mejor desempeño global (Recall@10 = 0.58, nDCG@10 = 0.54, MAP@10 = 0.53), superando ampliamente a los métodos basados exclusivamente en retroalimentación implícita. Esto confirma que el atributo textual

Modelo	Recall@10	nDCG@10	MAP@10	Índice Gini
ALS	0.0156	0.1885	0.1409	0.63
LightGCN (base)	0.0239	0.0137	0.0106	0.896
LightGCN Tripartito con nodos temáticos	0.0232	0.0133	0.0103	0.896
Clustering semántico	**0.58**	**0.54**	**0.53**	0.84

Table 5. Comparación de modelos utilizando métricas consistentes entre arquitecturas con retroalimentación implícita.

detalle constituye la señal más informativa para capturar afinidad temática y mitigar de forma efectiva el problema de *Cold-Start*.

En contraste, los modelos colaborativos presentaron limitaciones inherentes al dominio. Aunque *ALS* logró un ordenamiento interno competitivo (MAP@10 = 0.1409), su baja recuperación (Recall@10 = 0.0156) reflejó dificultades para generar un conjunto amplio de candidatos relevantes. De manera similar, *LightGCN* y su versión tripartita mostraron un rendimiento moderado (Recall@10 $\approx$ 0.023), lo que indica que la sofisticación arquitectónica no compensa la ausencia de una señal semántica fuerte cuando la matriz de interacciones supera el 99.9% de esparsidad. La estrategia híbrida de clustering propuesta fue determinante para la viabilidad del sistema.

La combinación de *HDBSCAN* y *K-Means* permitió clasificar el 100% del corpus en 2,091 temas latentes, ofreciendo una representación estructurada e interpretativa que modelos colaborativos de tipo "caja negra" no pueden proveer. Esta capa temática incrementó la transparencia y habilitó explicaciones legibles basadas en conceptos concretos. Finalmente, aunque el modelo redujo parcialmente el sesgo de popularidad (índice de Gini = 0.84), la concentración de recomendaciones sigue siendo un desafío abierto. Una línea de investigación prometedora consiste en integrar esta estructura semántica dentro de arquitecturas de grafos (GNN), con el fin de combinar la precisión basada en contenido con mecanismos de propagación que fomenten una distribución más equitativa de visibilidad entre autoridades públicas.

Referencias Bibliográficas

Gini, C. Variabilità e mutuabilità. *Bologna: Tipografia di Paolo Cuppini*, 1912.

Grootendorst, M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv preprint arXiv:2203.05794*, 2022.

He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., and Wang, M. Lightgcn: Simplifying and powering graph convolution network for recommendation. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 639–648, 2020. doi: 10.1145/3397271.3401063.

Hu, Y., Koren, Y., and Volinsky, C. Collaborative filtering for implicit feedback datasets. In *Proceedings of the 2008 IEEE International Conference on Data Mining (ICDM)*, pp. 263–272. IEEE, 2008. doi: 10.1109/ICDM.2008.22.

Kula, M. Metadata embeddings for user and item cold-start recommendations. *arXiv preprint arXiv:1507.08439*, 2015.

McInnes, L., Healy, J., and Astels, S. hdbscan: Hierarchical density based clustering. *The Journal of Open Source Software*, 2(11):205, 2017. doi: 10.21105/joss.00205.

McInnes, L., Healy, J., and Melville, J. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

Reimers, N. and Gurevych, I. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pp. 3982–3992. Association for Computational Linguistics, 2019. doi: 10.18653/v1/D19-1410.