Análisis del Trade-off entre Diversidad y Desinformación en Sistemas de Recomendación de Noticias basados en Grafos

Clemente Acevedo
Pontificia Universidad Católica de Chile
clementeacevedo@uc.cl

Vittorio Salvatore
Pontificia Universidad Católica de Chile
vittorio.salvatore@uc.cl

Cristóbal Fuentes
Pontificia Universidad Católica de Chile
crisfuentes@uc.cl

Abstract

Los sistemas de recomendación desempeñan un papel fundamental en la difusión de información en redes sociales; sin embargo, su tendencia a priorizar el *engagement* a menudo conduce a la amplificación involuntaria de desinformación. Si bien las Redes Neuronales de Grafos (GNNs) definen el estado del arte en precisión de recomendación, su impacto en la propagación de noticias falsas sigue siendo poco explorado. En este trabajo, analizamos el *trade-off* entre la precisión de la recomendación y la exposición a la desinformación utilizando los datasets Twitter15 y Twitter16. Implementamos un pipeline de evaluación temporal riguroso, procesando más de 110.000 interacciones para comparar baselines clásicos frente a arquitecturas GNN modernas, incluyendo LightGCN y variantes de GCN enriquecidas semánticamente. Nuestros experimentos revelan un claro conflicto entre precisión y seguridad: el modelo de mayor rendimiento, LightGCN, alcanza un Mean Reciprocal Rank (MRR) de 0.0347 pero expone al 99% de los usuarios a desinformación, siendo el 67.5% de sus recomendaciones rumores falsos. Por el contrario, la incorporación de embeddings semánticos (GCN-BERT) reduce la exposición a un 50.5%, pero a costa de una degradación significativa en la precisión (MRR 0.0153). Además, simulaciones de difusión mediante el modelo Linear Threshold (LTM) demuestran que los modelos de alta precisión facilitan un mayor alcance de contenido falso en el grafo social. Estos hallazgos proporcionan evidencia empírica de que optimizar únicamente la relevancia en GNNs conlleva el riesgo inherente de amplificar la desinformación.

Palabras clave: Sistemas de Recomendación, Redes Neuronales de Grafos, Desinformación, Noticias Falsas, Diversidad, Trade-off.

Disponibilidad de Código y Datos:
El código completo, los conjuntos de datos y los scripts de reproducción están disponibles en:
https://github.com/aLotOfGluten/IIC3633-Proyecto

1 Introducción

Las redes sociales se han consolidado como el principal canal de comunicación e información en el mundo contemporáneo. Sin embargo, esta estructura descentralizada ha facilitado la proliferación de campañas de desinformación, donde agentes maliciosos buscan alterar narrativas políticas y sociales

Preprint. Under review.

con gran éxito (Muñoz et al., 2025). Estudios recientes indican que las noticias falsas en plataformas como Twitter son significativamente más virales que la información veraz, generando en promedio casi el doble de interacciones que las noticias verificadas (Vosoughi et al., 2018). En este contexto, los sistemas recomendadores actúan como guardianes críticos; al filtrar vastos catálogos de contenido para maximizar la interacción del usuario, corren el riesgo de crear "cámaras de eco" y amplificar contenido falso sensacionalista (Pathak et al., 2023).

Las Redes Neuronales de Grafos (GNNs) han surgido como la técnica del estado del arte para sistemas de recomendación, capaces de modelar interacciones complejas de alto orden entre usuarios e ítems (Gao et al., 2025). Aunque las GNNs destacan por capturar señales colaborativas para mejorar la precisión, su propensión a propagar desinformación sigue siendo un área crítica de preocupación. La literatura existente a menudo aborda la detección de *fake news* y la recomendación como tareas separadas, descuidando la interacción entre las propiedades estructurales de las GNNs y la dinámica de difusión de desinformación.

En este trabajo, abordamos este vacío analizando sistemáticamente el *trade-off* entre diversidad, precisión y propagación de desinformación en recomendaciones de noticias basadas en GNN. Unificamos los datasets Twitter15 y Twitter16 (Ma et al., 2016) en un pipeline temporal consistente, decodificando los identificadores *Snowflake* para asegurar una división de evaluación realista que evita el sesgo de *look-ahead* común en estrategias de división aleatoria. Comparamos el rendimiento de métodos clásicos de filtrado colaborativo frente a arquitecturas GNN avanzadas, específicamente LightGCN (Chen et al., 2025) y variantes de GCN conscientes del contenido.

Nuestras contribuciones son las siguientes:

- **Pipeline de Evaluación Temporal Robusto:** Proponemos una metodología de preprocesamiento rigurosa para Twitter15/16, construyendo un split temporal transductivo basado en marcas de tiempo de interacción. Este enfoque preserva la evolución natural de las cascadas de noticias y mitiga evaluaciones poco realistas de *cold-start*.
- **Evidencia Empírica del Trade-off Precisión-Riesgo:** Demostramos que los modelos que optimizan puramente señales colaborativas (ej. LightGCN) logran una precisión superior (MRR 0.0347) pero amplifican desproporcionadamente la desinformación, recomendando rumores falsos a una tasa (67.5%) significativamente mayor que la distribución orgánica del dataset.
- **Análisis de Mitigación Semántica:** Evaluamos el impacto de integrar contenido semántico (embeddings BERT) en la arquitectura GNN. Encontramos que, si bien la conciencia semántica reduce la proporción de noticias falsas recomendadas (bajando al 50.5%), incurre en una penalización sustancial en la precisión, destacando una frontera de Pareto no trivial entre utilidad y seguridad.
- **Impacto en la Propagación:** Utilizando una simulación con el modelo Linear Threshold (LTM) sobre el grafo social, cuantificamos los efectos posteriores de estas recomendaciones, mostrando que los recomendadores de alta precisión pueden actuar como vectores eficientes para maximizar el alcance de la desinformación.

2 Trabajo Relacionado

La intersección entre sistemas de recomendación, redes neuronales de grafos y la propagación de desinformación es un campo de estudio emergente.

2.1 Sistemas de Recomendación y Propagación de Desinformación

La literatura reciente ha identificado a los algoritmos de recomendación como actores clave en la dinámica de la desinformación (Muñoz et al., 2025). Se ha demostrado que la optimización de métricas de *engagement* tiende a generar fenómenos de hiperpersonalización, conocidos como "cámaras de eco" (*echo chambers*) y "burbujas de filtro" (Areeb et al., 2023; Hartmann et al., 2025). Estudios como los de Pathak et al. (2023) y Fernandez et al. (2024) han analizado cómo los algoritmos colaborativos pueden amplificar inadvertidamente contenido malicioso.

2.2 Redes Neuronales de Grafos (GNNs) en RecSys

Las GNNs han revolucionado el filtrado colaborativo al modelar explícitamente las interacciones de alto orden. Modelos fundacionales como GCN (Kipf and Welling, 2017) y LightGCN (Chen et al., 2025) han establecido nuevos estándares de precisión. Sin embargo, Phan et al. (2023) revisaron el uso de GNNs para la *detección* de noticias falsas, pero la evaluación de GNNs como *motores de recomendación* susceptibles a propagar desinformación sigue siendo un área subexplorada.

2.3 Diversidad y el Trade-off de Precisión

Existe una tensión inherente entre la precisión de un recomendador y la diversidad de su contenido. Pathak and Spezzano (2024) exploraron la interacción entre la diversidad de las recomendaciones de noticias y la propagación de desinformación. Nuestro trabajo extiende esta línea adoptando un enfoque empírico sobre datasets reales de Twitter (Twitter15/16) con evaluación temporal estricta.

3 Metodología

Para analizar el impacto de los algoritmos en la difusión de desinformación, diseñamos un pipeline experimental que abarca desde el preprocesamiento hasta la simulación de propagación.

3.1 Procesamiento de Datos y Split Temporal

Utilizamos los datasets Twitter15 y Twitter16 (Ma et al., 2016), unificándolos para evitar sesgos. Desarrollamos un método de **split temporal estricto**:

- **Decodificación de Timestamps:** Reconstruimos la cronología decodificando los *Snowflake IDs* de Twitter.
- **Corte Temporal:** Establecimos una fecha de corte en marzo de 2015 para asegurar un balance de clases representativo (Rumor Falso, Verdadero, No Verificado, No Rumor).
- **División Transductiva:** Dividimos las interacciones en 80% entrenamiento, 10% validación y 10% prueba, ordenadas cronológicamente, evitando el problema de *cold-start* total (100%) observado en intentos previos.

El dataset final consta de 39.958 usuarios, 1.386 ítems únicos y 110.732 interacciones totales.

A pesar de la naturaleza de los tweets, se decidió abarcar el problema de recomendación como un fenómeno no secuencial, en el que los tweets existentes son tratados como ítems, y la interacción usuario-ítem se da si es que un usuario interactuó con algún tweet, vía un tweet propio.

3.2 Construcción de Grafos

Grafo Bipartito Usuario-Ítem: Modela las interacciones directas. Aplicamos un *cap* de 5 interacciones por par para evitar sesgos de usuarios hiperactivos. El grafo resultante contiene 177.240 aristas.

Grafo Social Implícito: Inferimos una red social basada en intereses compartidos. Se establece una conexión si dos usuarios interactuaron con al menos 3 ítems en común ($threshold \geq 3$). Este grafo (39.958 nodos, 311.020 aristas) se utiliza para la simulación de propagación.

3.3 Modelos de Recomendación

Evaluamos los siguientes modelos:

1. **Baselines:** *Most Popular*, *Random*, *TF-IDF* y *KNN* (User/Item-KNN).
2. **LightGCN:** Implementamos la arquitectura de Chen et al. (2025) con 4 capas de propagación, eliminando no-linealidades.
3. **GCN-BERT:** Variante de GCN (Kipf and Welling, 2017) con 3 capas. Inicializamos los ítems utilizando embeddings de `all-mpnet-base-v2` (768d) para capturar el contenido semántico.

Utilizamos la pérdida *Bayesian Personalized Ranking* (BPR) con muestreo negativo temporalmente consciente.

3.4 Modelo de Propagación (LTM)

Simulamos la difusión utilizando el **Linear Threshold Model (LTM)**. Definimos como *semillas* a los usuarios que recibieron al menos una noticia falsa (FR) en su Top-10. La simulación (Monte Carlo, 50 iteraciones) mide el alcance (*Mean Reach*) y profundidad.

4 Configuración Experimental

La evaluación se realizó sobre el conjunto de prueba temporal (último 10% de interacciones). El test set presenta un desbalance orgánico: el 57.39% de las interacciones son Rumores Falsos (FR).

4.1 Métricas

Evaluamos desempeño, diversidad y seguridad. Para cuantificar la exposición a desinformación, definimos formalmente la métrica **Fake@K**:

Dado un usuario u y su lista de recomendaciones Top-K, denotada como $R_u = \{i_1, i_2, ..., i_K\}$, definimos la proporción de desinformación como:

$$Fake@K(u) = \frac{1}{K} \sum_{j=1}^{K} \mathbb{I}(label(i_j) = \text{False Rumor}) \tag{1}$$

Donde $\mathbb{I}(\cdot)$ es la función indicadora. Reportamos el promedio de $Fake@10$ sobre todos los usuarios del conjunto de prueba. Adicionalmente, medimos:

- **MRR@10:** Calidad del ranking (Precisión).
- **ILD:** Diversidad intra-lista.
- **Usuarios Expuestos (%Exp):** Porcentaje de usuarios con $Fake@10(u) > 0$.
- **LTM Mean Reach:** Alcance viral promedio de la desinformación recomendada.

5 Resultados

Los resultados consolidados se presentan en la Tabla 1.

Tabla 1: Comparación de Rendimiento y Seguridad (Top-10). Ordenado por MRR. Se observa el trade-off: mayor MRR correlaciona con mayor Fake@10.

Modelo	MRR	ILD	Coverage	Fake@10 (%)	Usr. Exp. (%)	LTM Reach
LightGCN	**0.0347**	0.9101	**1.0000**	67.49%	99.01%	0.5830
ItemKNN	**0.0347**	0.8314	0.9826	56.04%	96.20%	0.5749
UserKNN	0.0338	0.8197	0.9512	55.44%	95.98%	0.5738
TF-IDF	0.0283	0.8706	0.9965	**70.60%**	99.51%	0.5846
GCN-BERT	0.0153	0.9386	**1.0000**	50.53%	93.67%	0.5742
Random	0.0153	**0.9814**	**1.0000**	58.99%	100.00%	0.5859
Most Popular	0.0119	0.0000	0.0348	50.00%	100.00%	0.5859

5.1 El Trade-off Precisión-Riesgo

Los experimentos confirman que existe un conflicto directo entre precisión y seguridad. Como se observa en la Figura 1, los modelos tienden a agruparse en una frontera de Pareto donde no es posible maximizar MRR sin incrementar Fake@10.

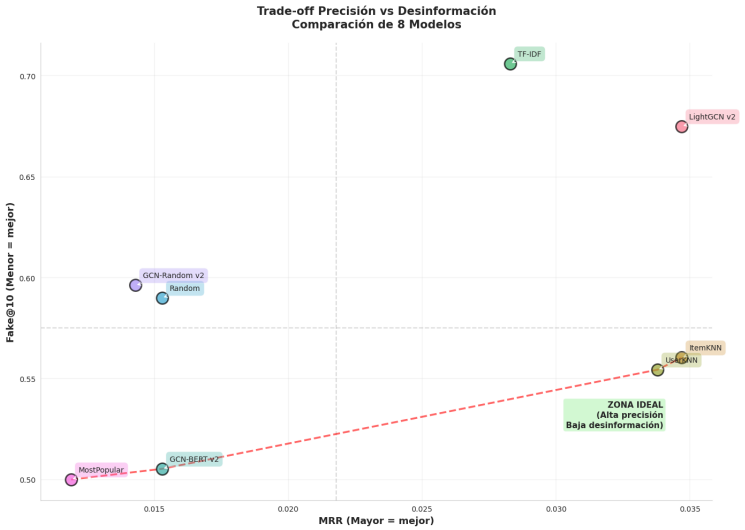

Figura 1: Frontera de Pareto entre Precisión (MRR, eje Y) y Exposición a Desinformación (Fake@10, eje X). LightGCN (extremo superior derecho) maximiza la precisión pero también el riesgo. GCN-BERT (centro) ofrece un compromiso intermedio.

LightGCN amplifica la desinformación, alcanzando un 67.49% de noticias falsas (+10.1% sobre la base). Esto indica que el modelo aprende a priorizar contenido viral falso. **TF-IDF** presenta el peor escenario (70.60% FR), explotando patrones léxicos de las noticias falsas.

5.2 Mitigación Semántica con GCN-BERT

El modelo **GCN-BERT** demuestra ser más "responsable". Al integrar embeddings semánticos, reduce la proporción de noticias falsas a un 50.53%. La Figura 2 ilustra cómo este modelo altera la composición de las recomendaciones, disminuyendo la barra roja (FR) en favor de noticias no verificadas o verdaderas.

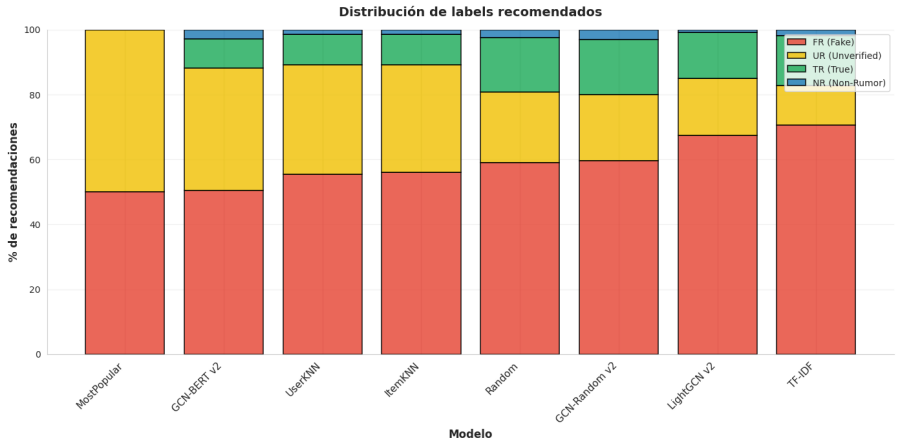

Figura 2: Distribución de etiquetas en el Top-10. GCN-BERT logra reducir la proporción de Rumores Falsos (FR) comparado con LightGCN y TF-IDF.

Sin embargo, esta seguridad tiene un costo: su MRR cae a 0.0153. Esto evidencia que la semántica por sí sola no captura suficientemente la relevancia de interacción.

6 Discusión y Conclusiones

Nuestros hallazgos evidencian que optimizar ciegamente la precisión en GNNs conlleva un riesgo sistémico. LightGCN explota la viralidad de la desinformación (que genera el doble de interacciones) como señal de relevancia. Existe una frontera de Pareto clara: los modelos semánticos actúan como filtros de seguridad pero degradan la utilidad.

El análisis de propagación (LTM) confirma que esta exposición algorítmica se traduce en un mayor alcance viral simulado. Si bien la diferencia numérica en *Mean Reach* puede parecer marginal (0.58 vs 0.57), en una red de la escala de Twitter, esto representa miles de usuarios adicionales expuestos innecesariamente a contenido falso.

Como trabajo futuro, proponemos arquitecturas híbridas que combinen la capacidad colaborativa de LightGCN con *post-filtering* semántico para navegar este trade-off de manera óptima.

Agradecimientos

Este trabajo fue desarrollado para el curso IIC3633 Sistemas Recomendadores en la Pontificia Universidad Católica de Chile, bajo la supervisión del profesor Denis Parra.

Referencias

Muñoz, P., et al. (2025). The role of recommendation algorithms in the formation of disinformation networks. *Information Processing & Management*, 62.

Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. *Science*, 359(6380).

Pathak, R., Spezzano, F., & Pera, M. S. (2023). Understanding the contribution of recommendation algorithms on misinformation. *ACM Transactions on the Web*, 17(4).

Gao, C., et al. (2025). A survey on recommender systems using graph neural network. *ACM TOIS*, 43(1).

Ma, J., et al. (2016). Detecting rumors from microblogs with recurrent neural networks. In *IJCAI*.

Chen, G., Xia, L., & Huang, C. (2025). LightGNN: Simple graph neural network for recommendation. *arXiv:2501.03228*.

Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *arXiv:1609.02907*.

Areeb, Q. M., et al. (2023). Filter bubbles in recommender systems: Fact or fallacy. *Wiley WIREs*.

Hartmann, D., et al. (2025). A systematic review of echo chamber research. *J. Comput. Soc. Sci.*

Fernandez, M., et al. (2024). Analysing the effect of recommendation algorithms on the spread of misinformation. *ACM WebSci*.

Phan, H. T., et al. (2023). Fake news detection: A survey of graph neural network methods. *Applied Soft Computing*.

Pathak, R., & Spezzano, F. (2024). Analyzing the interplay between diversity of news recommendations and misinformation. *ACM UMAP*.

A Apéndice: Análisis Exploratorio del Dataset

Presentamos evidencia estadística adicional que justifica las decisiones de diseño del estudio.

A.1 Distribución de Cola Larga

Las Figuras 3 (a) y (b) muestran la distribución de interacciones en el dataset unificado Twitter15/16. La clara ley de potencia justifica el uso de modelos GNN capaces de capturar señales colaborativas en distribuciones de cola larga, donde los métodos tradicionales suelen fallar.

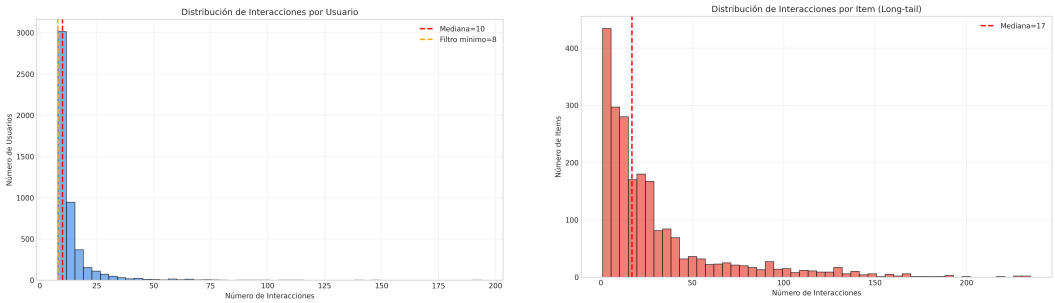

(a) Interacciones por Usuario

(b) Interacciones por Ítem

Figura 3: Distribuciones de actividad (Long-tail) en el dataset unificado.

A.2 Viralidad Diferencial: El Motor del Sesgo

Para validar la motivación del estudio, comparamos la viralidad promedio (número de interacciones) entre noticias etiquetadas como Falsas y Verdaderas en nuestro dataset (Figura 4).

Se observa empíricamente que las noticias falsas generan casi el doble de interacciones promedio ($\mu \approx 33$) que las verdaderas ($\mu \approx 18$). Esto confirma que los algoritmos que optimizan ciegamente la interacción (como LightGCN) están entrenando sobre una señal sesgada intrínsecamente hacia la desinformación.

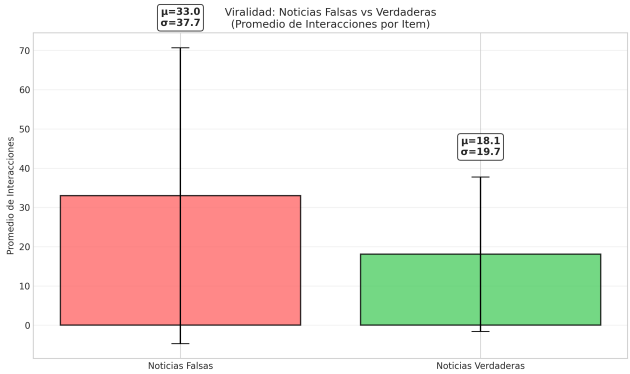

Figura 4: Comparativa de viralidad promedio. Las noticias falsas (izquierda) exhiben una capacidad de propagación orgánicamente superior a las noticias verdaderas (derecha) en el dataset.