
Recomendación Multimodal de Restaurantes sobre Yelp: Filtrado Colaborativo frente a Texto, Imagen y Fusión Evidencial

Joaquín Burdiles¹ Alonso Tamayo¹ Marcelo Vargas¹

Abstract

Estudiamos si las modalidades de contenido de texto de reseñas e imágenes de restaurantes aportan alguna señal complementaria al filtrado colaborativo (CF) puro para recomendar locales. Considerando un subconjunto de las cinco ciudades más activas del Yelp Open Dataset (18,117 usuarios, 3,824 restaurantes, 188,822 reseñas) implementamos y evaluamos siete modelos bajo un protocolo común de *split* temporal 80/20: dos *baselines* (Random, MostPopular), un CF matricial (SVD), dos híbridos por combinación de similitud (TextCF con SBERT, VisualCF con CLIP) y dos redes de grafos multimodales (MMGCN con fusión por promedio y MMGCN-TMC con fusión de Dempster-Shafer). MMGCN obtiene el mejor NDCG@10 (0.0692, +14.4% sobre SVD), seguido por MMGCN-TMC (+12.6%); ambos modelos de grafo superan con claridad a VisualCF y al CF puro. Encontramos que (i) la imagen (CLIP) mejora sobre CF con costo mínimo y amplia cobertura, (ii) el texto (SBERT) combinado por similitud coseno *deteriora* el CF, y (iii) la fusión evidencial Dempster-Shafer iguala a la fusión por promedio pero no la supera bajo alta esparsidad. Complementamos las métricas de precisión con métricas *beyond-accuracy* (novedad, cobertura, diversidad intra-lista). El código, los datos procesados y los *notebooks* reproducibles están disponibles públicamente.

1. Introducción

La recomendación de restaurantes es un problema de gran valor práctico en plataformas como Yelp, TripAdvisor o

¹Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: Joaquín Burdiles <joaquin.burdiles@uc.cl>, Alonso Tamayo <aetamayo@uc.cl>, Marcelo Vargas <marcelo.vargas@uc.cl>.

Google Maps. A diferencia de dominios como películas o música, un restaurante posee una fuerte componente de *contenido*: las fotografías de sus platos y ambiente y el texto de las reseñas transmiten información semántica que en principio podría complementar la señal colaborativa de quién visitó qué lugar.

La pregunta que motiva este trabajo es directa: **¿aportan realmente las modalidades visuales y textuales sobre el filtrado colaborativo puro, y cómo conviene fusionarlas?** El filtrado colaborativo (CF) captura de forma implícita muchas preferencias, por lo que no es evidente que añadir contenido mejore el ranking; y cuando se combinan varias modalidades, la estrategia de fusión puede ser determinante, ya sea si utiliza un simple promedio, o esquemas que modelen explícitamente la incertidumbre de cada fuente.

Para responderla, construimos un banco de pruebas homogéneo sobre el Yelp Open Dataset (Yelp Inc., 2024) y evaluamos, bajo un único protocolo temporal, un conjunto de siete modelos de complejidad creciente. Nuestras contribuciones son:

- Un **protocolo de evaluación unificado** (*split* temporal 80/20, 5-core) que permite comparar de forma justa *baselines*, medidas de similitud híbrida y redes de grafos multimodales, reportando tanto métricas de precisión como *beyond-accuracy*.
- Una **adaptación de MMGCN** (Wei et al., 2019) al dominio de restaurantes con *embeddings* SBERT (Reimers & Gurevych, 2019) y CLIP (Radford et al., 2021), y una variante **MMGCN-TMC** que reemplaza la fusión por promedio con la combinación evidencial de Dempster-Shafer del marco TMC (Han et al., 2023).
- Un **análisis empírico** que muestra que la imagen ayuda, el texto por similitud coseno perjudica, y la fusión evidencial no supera al promedio simple bajo la esparsidad de este dataset.

Todo el código y los datos son públicos (Sección 7), y cada *notebook* del repositorio está ejecutado por completo.

2. Trabajo Relacionado

Filtrado colaborativo. La factorización matricial (Koren et al., 2009) es el estándar del CF: representa usuarios e ítems como vectores latentes cuyo producto interno predice la afinidad. Sobre *feedback* implícito, la pérdida BPR (Rendle et al., 2009) optimiza directamente el orden relativo entre ítems observados y no observados, alineándose con las métricas de ranking.

Recomendación con grafos. LightGCN (He et al., 2020) simplifica las redes convolucionales de grafos para recomendación eliminando transformaciones no lineales y propagando únicamente los *embeddings* por el grafo bipartito usuario-ítem, capturando relaciones de alto orden. MMGCN (Wei et al., 2019) extiende esta idea al caso **multimodal**: construye un grafo por modalidad, propaga las *features* de contenido y fusiona las representaciones resultantes.

Fusión evidencial. El *deep learning* evidencial (Sensoy et al., 2018) modela la incertidumbre de una predicción como una distribución de Dirichlet sobre las clases. TMC (Han et al., 2023) lleva esto al escenario multi-vista: cada modalidad produce una *opinión* (masa de creencia + incertidumbre) y las combina con la regla de Dempster-Shafer, ponderando dinámicamente las fuentes según su confiabilidad. Adaptamos este mecanismo como estrategia de fusión modal en MMGCN-TMC.

3. Datos y Preprocesamiento

3.1. Dataset y filtrado

Partimos del Yelp Open Dataset (Yelp Inc., 2024) (150,346 negocios, ~6.99M reseñas) y aplicamos, en orden: (1) selección de restaurantes con al menos 20 reseñas y 5 fotografías; (2) restricción geográfica a las **cinco ciudades** con más restaurantes (Philadelphia, Tampa, New Orleans, Nashville, Indianapolis) para maximizar densidad y evitar ruido geográfico; (3) filtrado de reseñas con menos de 10 palabras; y (4) filtrado **5-core** de usuarios (≥ 5 reseñas). La tabla 1 resume las estadísticas resultantes.

3.2. Análisis exploratorio

El análisis exploratorio (figura 1) revela dos propiedades relevantes para el modelado. Primero, un **sesgo positivo** marcado: las calificaciones de 4 y 5 estrellas dominan la distribución de reseñas, lo que reduce el poder discriminativo del rating explícito y motiva tratar el problema como ranking sobre *feedback* implícito. Segundo, una distribución de actividad de **cola larga**: la mayoría de los restaurantes acumula pocas reseñas mientras que unos pocos concentran cientos. La matriz usuario-ítem resultante ($18,117 \times 1,832$)

Tabla 1. Estadísticas del dataset procesado (top-5 ciudades).

Magnitud	Valor
Usuarios	18,117
Restaurantes (con ≥ 5 fotos)	3,824
Restaurantes reseñados	1,832
Reseñas	188,822
Fotografías	60,199
Reseñas por usuario (media)	10.4
Sparsity de la matriz	99.43%
Reseñas de entrenamiento (80%)	156,121
Reseñas de test (20%)	32,701




Figura 1. Distribución de estrellas de las reseñas (izq.) y volumen de reseñas por año (der.). El sesgo hacia 4–5 estrellas motiva el enfoque de ranking sobre *feedback* implícito.

tiene una sparsity del 99.43% (densidad 0.57%), un régimen que penaliza a los modelos dependientes de co-ocurrencia y favorece a las señales de contenido para los ítems poco vistos.

3.3. Extracción de *features* multimodales

Texto (SBERT). Concatenamos todas las reseñas de entrenamiento de un mismo restaurante y las codificamos con all-MiniLM-L6-v2 de Sentence-BERT (Reimers & Gurevych, 2019) en un único vector de 384 dimensiones por local. Este proceso cubre los 1,830 restaurantes reseñados en entrenamiento.

Imagen (CLIP). Codificamos cada fotografía con CLIP ViT-B/32 (Radford et al., 2021) (512 dimensiones) y tomamos la **media** de los *embeddings* de todas las fotos de un restaurante (categorías *food*, *inside*, *outside*, *drink*, *menu*). Cubre los 3,824 restaurantes.

La tabla 2 resume la cobertura de cada modalidad. La imagen cubre todo el catálogo, mientras que el texto cubre los restaurantes reseñados en entrenamiento; los modelos de grafos, que requieren ambas modalidades, operan sobre la intersección de 1,830 ítems.

4. Metodología

Evaluamos siete modelos de complejidad creciente. La tabla 3 los sintetiza.

Tabla 2. Cobertura de modalidades y modelos que las usan.

Modalidad	Restaurantes	Modelos
Texto (SBERT, 384d)	1,830	TextCF, MMGCN(-TMC)
Imagen (CLIP, 512d)	3,824	VisualCF, MMGCN(-TMC)
Ambas	1,830	MMGCN, MMGCN-TMC

Tabla 3. Resumen de los modelos evaluados. CF: filtrado colaborativo; DS: Dempster-Shafer.

Modelo	Señal	Fusión	Pérdida
Random	—	—	—
MostPopular	Popularidad	—	—
SVD	CF	—	MSE
TextCF	CF + SBERT	α -blend	—
VisualCF	CF + CLIP	α -blend	—
MMGCN	CF + texto + img	GCN + promedio	BPR + L2
MMGCN-TMC	CF + texto + img	GCN + DS	BPR + KL-DS

4.1. Baselines y CF

Random recomienda ítems no vistos al azar y **MostPopular** los restaurantes con más reseñas en entrenamiento. **SVD** factoriza la matriz usuario-ítem con **TruncatedSVD** (50 factores latentes) y puntúa mediante el producto interno de los vectores latentes.

4.2. Híbridos por similitud: TextCF y VisualCF

Ambos construyen un perfil de contenido del usuario $\mathbf{p}_u$ como la media de los *embeddings* de los ítems que valoró con ≥ 4 estrellas. El puntaje final combina la predicción SVD normalizada con la similitud coseno entre el perfil y el ítem candidato:

$$\text{score}(u, i) = \alpha \hat{r}_{\text{SVD}}(u, i) + (1 - \alpha) \cos(\mathbf{p}_u, \mathbf{e}_i), \quad (1)$$

con $\alpha^* = 0.5$ seleccionado por búsqueda en grilla. TextCF usa *embeddings* SBERT y VisualCF usa *embeddings* CLIP.

4.3. MMGCN: grafo multimodal con fusión por promedio

MMGCN (Wei et al., 2019) construye un grafo bipartito usuario-ítem y propaga la información por $L = 3$ capas (similar a LightGCN (He et al., 2020), $\dim = 64$). Cada usuario dispone de un *embedding* de preferencia aprendible; cada ítem parte de sus *features* modales proyectadas por un MLP (imagen $512 \rightarrow 256$; texto 384d directo), con un *residual id-embedding* en cada capa. Se procesa una rama por modalidad $m \in \{v, t\}$ obteniéndose representaciones $\mathbf{e}_v$ y $\mathbf{e}_t$, que se fusionan por **promedio aritmético**:

$$\mathbf{e}_{\text{final}} = \frac{1}{2} (\mathbf{e}_v + \mathbf{e}_t). \quad (2)$$

El modelo se entrena con la pérdida BPR (Rendle et al., 2009) más regularización L2 ($lr = 10^{-4}$, $batch = 1024$,

50 épocas), sobre 18,117 usuarios y los 1,830 restaurantes multimodales.

4.4. MMGCN-TMC: fusión evidencial de Dempster-Shafer

MMGCN-TMC comparte la arquitectura GCN pero reemplaza la ecuación (2) por la combinación evidencial del marco TMC (Han et al., 2023). Para cada modalidad, una cabeza con ReLU estima una **evidencia** no negativa que induce una distribución de Dirichlet, de la que se derivan una masa de creencia $\mathbf{b}_m$ y una incertidumbre u_m con $\sum_k b_{m,k} + u_m = 1$. Las opiniones de ambas modalidades se combinan con la **regla de Dempster**:

$$\mathbf{e}_{\text{final}} = \text{DS}(\langle \mathbf{b}_v, u_v \rangle, \langle \mathbf{b}_t, u_t \rangle), \quad (3)$$

que otorga mayor peso a la modalidad más confiable (menor u_m). La pérdida agrega un término KL sobre las Dirichlet con *annealing* lineal:

$$\mathcal{L} = \mathcal{L}_{\text{BPR}} + \lambda_t (\text{KL}_v + \text{KL}_t) + \mathcal{L}_2, \quad (4)$$

donde λ_t crece linealmente durante las primeras épocas (*annealing_step* = 10). Se entrena 150 épocas con los mismos hiperparámetros base.

4.5. Protocolo de evaluación

Empleamos un **split temporal 80/20**: para cada usuario, el 20% de reseñas más recientes forma el conjunto de test, evitando la fuga de información futura de un *split* aleatorio. Consideramos *relevante* un ítem de test valorado por el usuario. Reportamos, para $K \in \{5, 10, 20\}$, métricas de **precisión**: Precision@K, Recall@K y NDCG@K (Järvelin & Kekäläinen, 2002); y métricas *beyond-accuracy* (Castells et al., 2015): *Novelty* (auto-información media de la lista), *Coverage* (fracción del catálogo alcanzada) e *ILD* (diversidad intra-lista, disimilitud coseno media sobre el espacio CLIP).

5. Resultados

La tabla 4 reporta los resultados a $K = 10$ ordenados por NDCG@10, y la figura 2 muestra las curvas completas para $K \in \{5, 10, 20\}$.

Ranking global. Los dos modelos de grafo (MMGCN, MMGCN-TMC) encabezan todas las métricas de precisión y se separan con claridad de VisualCF y del SVD puro; todos superan ampliamente a los *baselines* triviales. MMGCN lidera en Precision@10, Recall@10 y NDCG@10, con MMGCN-TMC a poca distancia, mientras que VisualCF (sin entrenamiento neural) se ubica una posición por encima del CF puro.

Tabla 4. Comparativa a $K = 10$ (*split* temporal 80/20). En **negrita** el mejor valor por columna. Δ indica la mejora relativa en NDCG@10 respecto a SVD. Nov.: Novelty; Cov.: Coverage; ILD: diversidad intra-lista.

MODELO	P@10	R@10	NDCG@10	Nov.@10	Cov.@10	ILD@10	Δ NDCG
MMGCN	0.0198	0.1219	0.0692	6.29	0.669	0.497	+14.4%
MMGCN-TMC	0.0192	0.1200	0.0681	6.04	0.538	0.499	+12.6%
VISUALCF	0.0188	0.1104	0.0629	6.07	0.318	0.504	+4.0%
SVD	0.0180	0.1059	0.0605	6.09	0.245	0.516	—
TEXTCF	0.0160	0.0905	0.0528	6.52	0.667	0.402	−12.7%
MOSTPOPULAR	0.0071	0.0463	0.0265	4.57	0.011	0.483	−56.2%
RANDOM	0.0009	0.0049	0.0026	8.78	0.999	0.548	−95.7%

Beyond-accuracy. Random maximiza trivialmente novedad, cobertura y diversidad al recomendar de forma uniforme, mientras que MostPopular exhibe la menor novedad y cobertura (0.011), evidenciando su sesgo de popularidad. Entre los modelos útiles, MMGCN combina la mejor precisión con la mayor cobertura (0.669), es decir, recomienda una porción amplia del catálogo sin sacrificar calidad. TextCF, pese a su baja precisión, muestra alta novedad pero la menor diversidad (ILD = 0.402), como consecuencia de la tendencia de los *embeddings* de agrupar restaurantes semánticamente similares.

6. Discusión

La propagación en grafo es la que más aporta. MMGCN logra la mejor precisión (+14.4% NDCG@10 sobre SVD). Propagar *features* multimodales a lo largo de tres capas captura relaciones de segundo y tercer orden entre usuarios y restaurantes que ni la factorización matricial ni los modelos de similitud directa alcanzan. Además, MMGCN alcanza la mayor cobertura entre los modelos precisos (0.669), combinando calidad de ranking con exploración amplia del catálogo.

Las imágenes ayudan; el texto por similitud perjudica. VisualCF mejora sobre SVD (+4.0%) **sin entrenamiento neural** y con la ventaja de cubrir todo el catálogo (3,824 ítems). En cambio, TextCF cae un 12.7% bajo SVD: mezclar la similitud coseno de SBERT con la predicción colaborativa de la ecuación (1) introduce ruido, porque el CF ya captura implícitamente gran parte de las preferencias semánticas y las reseñas agregadas de un restaurante resultan semánticamente poco discriminativas entre locales. Es notable que la señal textual sí aporta al propagarse por el grafo (MMGCN), pero no al combinarse por similitud directa: la modalidad visual resulta así más informativa y robusta que la textual para la fusión por similitud.

La fusión evidencial no supera al promedio. MMGCN-TMC queda apenas por debajo de MMGCN (0.0681 vs. 0.0692 en NDCG@10), sin superarlo pese a su mayor complejidad y a triplicar las épocas de entrenamiento.

Con $\sim 1.8k$ ítems y alta esparsidad, el mecanismo de estimación de incertidumbre no dispone de suficiente señal para aprender pesos diferenciales entre modalidades: la fusión Dempster-Shafer converge a un comportamiento cercano al promedio. El resultado sugiere que, en regímenes de datos pequeños, el costo adicional de la fusión evidencial no se traduce en ganancia de ranking, aunque su estimación de incertidumbre podría ser valiosa en escenarios con modalidades faltantes o ruidosas.

Limitaciones. Los modelos de grafos se restringen a la intersección multimodal (1,830 ítems), dejando fuera 1,994 restaurantes que tienen imagen pero no reseñas de entrenamiento. La representación textual agrega todas las reseñas de un local en un solo vector, perdiendo el detalle a nivel de reseña o de aspecto. Finalmente, el sesgo positivo de ratings puede afectar de forma diferencial a los modelos basados en similitud coseno.

7. Conclusión

Comparamos, bajo un protocolo temporal común, siete modelos de recomendación de restaurantes que van desde *base-lines* triviales hasta redes de grafos multimodales con fusión evidencial. La evidencia indica que las modalidades de contenido *sí* aportan sobre el CF puro, pero de forma heterogénea: la imagen (CLIP) mejora con costo mínimo, mientras que el texto (SBERT) combinado por similitud coseno perjudica. La propagación en grafo (MMGCN) obtiene la mejor precisión, y la fusión evidencial de Dempster-Shafer iguala, pero no supera a la fusión por promedio bajo la esparsidad del dataset. Como trabajo futuro proponemos (i) extender el grafo a los 3,824 ítems con imagen manejando la modalidad faltante con un *embedding* aprendido, (ii) enriquecer la representación textual con codificaciones a nivel de reseña o de aspecto en lugar del vector agregado por local, y (iii) explorar fusiones adaptativas más ligeras (atención cruzada, *gating*) frente a la combinación Dempster-Shafer.




Figura 2. Curvas de las seis métricas para $K \in \{5, 10, 20\}$. Las de precisión (Precision, Recall, NDCG) decrecen con K ; las *beyond-accuracy* (Novelty, Coverage, ILD) crecen con K .

Software y Datos

El código completo, los datos procesados y los *notebooks* reproducibles (ya ejecutados) están disponibles en [este repositorio](#). Se incluye un archivo README que describe la estructura, el pipeline de preprocesamiento, los siete modelos y las instrucciones de reproducción. Los *notebooks* 01–04 generan los datos y *embeddings*; 05–11 entrenan y evalúan cada modelo escribiendo sus métricas en *results/*; y 12 produce la tabla y la figura comparativas de este artículo.

Declaración de impacto

Este trabajo busca avanzar en la comprensión de la recomendación multimodal. Los sistemas de recomendación de restaurantes pueden reforzar sesgos de popularidad, perjudicando a locales pequeños o nuevos, por lo que reportamos explícitamente métricas de cobertura y novedad. El uso de fotografías y texto de reseñas debe respetar los términos del Yelp Open Dataset y la privacidad de los usuarios. Fuera de estas consideraciones, no identificamos consecuencias éticas o sociales que deban destacarse especialmente.

Referencias

- Castells, P., Hurley, N. J., and Vargas, S. Novelty and diversity in recommender systems. In *Recommender Systems Handbook*, pp. 881–918. Springer, 2nd edition, 2015.
- Han, Z., Zhang, C., Fu, H., and Zhou, J. T. Trusted multi-view classification with dynamic evidential fusion. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(2):2551–2566, 2023. DOI: 10.1109/TPAMI.2022.3171983.
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., and Wang, M. LightGCN: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 639–648, 2020.
- Järvelin, K. and Kekäläinen, J. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002.
- Koren, Y., Bell, R., and Volinsky, C. Matrix factorization

- techniques for recommender systems. *Computer*, 42(8): 30–37, 2009.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., and Sutskever, I. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139, pp. 8748–8763, 2021.
- Reimers, N. and Gurevych, I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 3982–3992, 2019.
- Rendle, S., Freudenthaler, C., Gantner, Z., and Schmidt-Thieme, L. BPR: Bayesian personalized ranking from implicit feedback. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*, pp. 452–461, 2009.
- Sensoy, M., Kaplan, L., and Kandemir, M. Evidential deep learning to quantify classification uncertainty. *Advances in Neural Information Processing Systems (NeurIPS)*, 31: 3179–3189, 2018.
- Wei, Y., Wang, X., Nie, L., He, X., Hong, R., and Chua, T.-S. MMGCN: Multi-modal graph convolution network for personalized recommendation of micro-video. In *Proceedings of the 27th ACM International Conference on Multimedia (MM)*, pp. 1437–1445, 2019.
- Yelp Inc. Yelp Open Dataset. <https://business.yelp.com/data/resources/open-dataset/>, 2024. Accedido: 2026-07-05.