
Integración dinámica de múltiples modalidades mediante Gated Fusion

Bruno Cerda M.^{1,2} Alonso Casanova^{1,2} Berioska C. Vargas^{1,2}

Abstract

Los sistemas de recomendación multimodal han logrado un rendimiento notable, sin embargo, frecuentemente enfrentan una brecha semántica significativa entre las modalidades visuales y textuales. Para mitigar este problema, presentamos una mejora arquitectónica al framework EFMRec mediante la integración de diferentes modalidades mediante un mecanismo llamado Gated Fusion (GF). Los resultados experimentales demuestran que la combinación de EFMRec con Gated Fusion alcanza un rendimiento superior en todas las métricas evaluadas, incluyendo Recall, nDCG y MAP, al comparar con puntos de referencia como VL-CLIP y EFMRec. La implementación completa se encuentra disponible en nuestro repositorio de GitHub: [🔗](#)

1. Introduction

Los sistemas de recomendación tradicionales (Sarwar et al., 2001) (Zhang & Pu, 2007), basados predominantemente en el filtrado colaborativo, a menudo presentan limitaciones al ignorar la información del contenido multimodal. Esta deficiencia influye directamente ante el desafío del *arranque en frío* (Yuan & Hernandez, 2023), donde la falta de un historial de interacciones previo para nuevos usuarios o ítems impide un modelamiento preciso. En respuesta a esta problemática, modelos recientes han convergido en la integración de datos multimodales como una estrategia clave para mitigar dichas restricciones, permitiendo que el sistema complemente la señal colaborativa con información visual y textual intrínseca a los ítems.

¹Pontificia Universidad Católica de Chile ²Campus San Joaquín, Santiago.. Correspondence to: Bruno Cerda M <bcmardini@gmail.com>, Alonso Casanova <alonso.casanova@uc.cl>, Berioska C. Vargas <bcontrerasv6@estudiante.uc.cl>.

1.1. Motivación

Esta investigación tiene como objetivo explorar y extender las capacidades de los modelos de recomendación actuales frente al problema del arranque en frío. Para ello, realizamos replicación y análisis comparativo de dos arquitecturas SOTA; VL-CLIP y EFMRec. A partir de este estudio, identificamos limitaciones estructurales en la fusión de modalidades y proponemos una mejora arquitectónica basada en un mecanismo de *Gated Fusion*. Esta modificación permite al sistema aprender de manera dinámica la relevancia de cada modalidad, optimizando la representación de los ítems en escenarios complejos. En las secciones 2 y 3, detallamos el funcionamiento de los modelos de referencia, así como la propuesta técnica desarrollada para fortalecer la robustez del sistema.

1.2. Dataset

Para validar la eficacia de nuestras mejoras arquitectónicas, empleamos *PixelRec* (Cheng et al., 2023), un dataset diseñado específicamente para la evaluación de sistemas de recomendación multimodal con imágenes y texto. Los experimentos se realizaron sobre el subconjunto *PixelRec50K*, una muestra representativa que comprende 989,494 interacciones generadas por 50,000 usuarios sobre 82,865 ítems. La utilización de este conjunto de datos permite una evaluación bajo diversidad de contenido, proporcionando un entorno adecuado para medir el impacto de la fusión dinámica de modalidades en la precisión de las recomendaciones.

2. Estado del Arte

Dos modelos destacados en el área de sistemas recomendadores multimodales son VL-CLIP y EFMRec, los cuales enfrentan limitaciones específicas en el alineamiento de características y la integración multimodal. También destacamos modelos que fueron relevantes en las diversas pruebas que hicimos, como por ejemplo CLIP, SigLIP y SASRec.

CLIP/SigLIP: (Radford et al., 2021) (Zhai et al., 2023) Modelos multimodales que extraen features de texto e imagen. Estos modelos nos permiten extraer el contenido de los pares (imagen, texto) en nuestros datos para informar nuestras recomendaciones.

VL-CLIP: (Giahi et al., 2025) Este modelo aborda las lim-

itaciones de los modelos basados en CLIP estándar, los cuales a menudo sufren un alineamiento débil a nivel de objeto y representaciones textuales ambiguas. Para superar estos problemas, VL-CLIP integra Visual Grounding (utilizando Grounding DINO) para localizar y recortar regiones clave del producto, refinando así las representaciones visuales y reduciendo el ruido de fondo. Simultáneamente, emplea un LLM para desambiguar y enriquecer las descripciones de los productos, resultando en embeddings textuales con mejor contenido semántico. Mediante el entrenamiento con un objetivo de aprendizaje contrastivo, VL-CLIP logra un alineamiento superior entre estas características refinadas, demostrando mejoras significativas en métricas como HITS y MRR.

EFMRec: (Chen et al., 2026) A diferencia de los enfoques tradicionales basados en *late fusion*, que requieren la presencia simultánea de todas las modalidades para realizar el alineamiento y resultan subóptimos en situaciones de datos faltantes, EFMRec propone un método de integración llamado *early fusion*. Este marco toma en cuenta la ausencia de modalidades y sigue el principio de aprovechar las modalidades solo cuando están disponibles, eliminando la necesidad de módulos de imputación o pérdidas auxiliares complejas. EFMRec utiliza modelos multimodales preentrenados para proyectar las características disponibles en un espacio semántico compartido, donde son agregadas mediante un operador de *early fusion* que garantiza una representación unificada incluso si faltan algunas modalidades. Estas representaciones se propagan posteriormente, a través, de una arquitectura basada en GCN junto con un componente de filtrado colaborativo, logrando una robustez superior frente a la falta de datos multimodales.

SASRec(SR): (Kang & McAuley, 2018) Modelo de recomendación secuencial, basado en mecanismo de auto-atención. Este modelo se puede resumir en dos partes, primero, se crean embeddings para todos los items en los datos, segundo, SASRec aprende a modelar la temporalidad de las secuencias en los datos en base al mecanismo de auto-atención. En los resultados de la sección 4, en vez de pedirle a SASRec que genere los embeddings, se toman los generados por EFMRec después de ser entrenados. De esta forma, SASRec solo debe aprender la temporalidad de los datos.

3. Método

EFMRec utiliza *early fusion*, el cual consiste básicamente en el promedio de los embeddings de las distintas modalidades disponibles. Este enfoque fue diseñado para enfrentar situaciones en las que existen modalidades de datos faltantes. Dado que en nuestro caso no tenemos este problema, proponemos sustituir el promedio simple por un mecanismo de aprendizaje dinámico que permita al modelo determinar qué

modalidad priorizar según el contexto.

Para implementar este mecanismo de *Gated Fusion*, concatenamos las distintas modalidades (imagen y texto en este caso) y las procesamos mediante un MLP con una activación sigmoide. Este proceso genera un peso $w \in [0, 1]$, el cual utilizamos para multiplicar los embeddings de las imágenes y su complemento $(1 - w)$ por los embeddings del texto, logrando una ponderación adaptativa. La representación fusionada f_{fusion} se define matemáticamente como:

$$w = \sigma(MLP(f_{image} \oplus f_{text})) \quad (1)$$

$$f_{fusion} = w \cdot f_{image} + (1 - w) \cdot f_{text} \quad (2)$$

Donde σ representa la función de activación sigmoide, $\oplus$ denota la concatenación de vectores, y f_{image} y f_{text} corresponden a los embeddings de las modalidades visual y textual, respectivamente.

4. Resultados

Para comparar, se utilizan las métricas Recall, nDCG y MAP, cada una incluye @5 y @10 (Jadon & Patil, 2024). La combinación entre CLIP y GF (Gated Fusion) retorna los mejores resultados.

Vemos que los modelos que incorporan SASRec tienen resultados decepcionantes, en muchos casos no superan a los baselines (Ivanova et al., 2023) de *most - popular* y *item - KNN*. Explicaciones de este hecho se discuten en la sección (5) de análisis.

En general, se observa que los modelos a nivel de estado del arte, superan ampliamente a los modelos básicos utilizados como base.

Table 1. Comparación de modelos de recomendación (Top-5)

Model	R@5	N@5	M@5
ER-Siglip-GF	0.002293	0.001629	0.001271
ER-CLIP-GF	0.002212	0.001652	0.001307
ER-Siglip	0.001914	0.001430	0.001089
ER-CLIP	0.002196	0.001599	0.001249
ER-SasRec	0.000690	0.000381	0.000160
ER-Siglip-GF-SR	0.000978	0.000542	0.000208
Item-KNN	0.001414	0.000944	0.000748
VL-CLIP	0.001930	0.001440	0.000680
Most Popular	0.000624	0.000583	0.000507
Random	0.000192	0.000146	0.000089

5. Análisis

Se demuestra que la estrategia de combinación de características aprendidas a través de gated fusion es efectiva

Table 2. Comparación de modelos de recomendación (Top-10)

Model	R@10	N@10	M@10
ER-Siglip-GF	0.003135	0.001922	0.001373
ER-CLIP-GF	0.003350	0.002067	0.001460
ER-Siglip	0.003509	0.001986	0.001310
ER-CLIP	0.003527	0.002064	0.001417
ER-SasRec	0.002051	0.000857	0.000221
ER-Siglip-GF-SR	0.001713	0.000810	0.000229
Item-KNN	0.001962	0.001144	0.000828
VL-CLIP	0.001930	0.001430	0.000340
Most Popular	0.001033	0.000727	0.000558
Random	0.000430	0.000206	0.000105

en el ajuste de las características multimodales (imagen y texto). Esto difiere de una mera concatenación o promedio, ya que el modelo aprende un peso w que determina la contribución relativa de cada modalidad.

Los modelos ER-CLIP-GF y ER-CLIP logran consistentemente los valores más altos en las métricas Recall, nDCG y MAP. Si bien, ER-SIGLIP es competitivo, especialmente en Recall@10, este queda relegado tras las variantes CLIP. Cabe recordar que CLIP utiliza una función de pérdida contrastiva basada en softmax para todos los "batches", mientras que SIGLIP reemplaza la función de pérdida por una clasificación binaria basada en una función sigmoide.

De este modo, la integración de la fusión GF mejora el rendimiento en la mayoría de los casos comparado a los modelos de base. En relación con los modelos de línea base, Item-KNN y VL-CLIP exhiben un rendimiento moderado, superando la línea base aleatoria (Random), aunque por debajo de CLIP y SIGLIP. A su vez, los modelos SASREC y MostPopular demostraron ser modelos débiles, ya que superan levemente a Random.

Es importante notar que la cantidad de datos utilizada es muy pequeña, menos de 50 mil imágenes, debido a la falta de recursos computacionales. Para establecer conclusiones con mayor confianza se necesita un estudio sobre un dataset más amplio.




Figure 1. Comparación de modelos y valores de métricas @5




Figure 2. Comparación de modelos y valores de métricas @10

5.1. Discusión

Se observa que los modelos a nivel de estado del arte mejoran los resultados obtenidos en baseline de forma notable. Esto demuestra que incorporar el contenido multimodal en el modelo mejora considerablemente los resultados.

Sin embargo, en un nivel absoluto, los resultados obtenidos no son buenos, se encuentran todos en una escala de 10^{-3} . Esto, creemos se debe a muchos factores, primero que los modelos de SOTA están pensados para datos de otro tipo, en específico de *e-commerce*, y no para los datos de este problema, que corresponden a publicaciones de una red social. La diferencia es clara al momento de aplicar los modelos; en datos de *e-commerce*, el texto asociado a una imagen es una descripción textual de características de la imagen (por ejemplo, una foto de un vestido tiene una descripción como "vestido floral tamaño S material algodón"), por otro lado en una red social el texto que acompaña a una imagen puede no tener nada que ver si se comparan literalmente (por ejemplo, una foto de un vestido puede tener una descripción que sea "que bonito"). Esta diferencia complica el funcionamiento de modelos como CLIP, que se basan en el supuesto de encontrar una representación compartida para texto e imagen. Además, los datos tienen muchas categorías como "comedia", que no son identificables dentro de una imagen.

Esta diferencia es la que nos lleva a realizar los cambios en los modelos descritos en la entrega anterior y explica en parte los resultados obtenidos.

Por otro lado, los resultados obtenidos al incluir SASRec en los modelos obtenidos resultó ser decepcionante en comparación con las recomendaciones generadas por los modelos sin usar técnicas de recomendación secuencial. Esto puede deberse a que el largo de las secuencias en los datos no es lo suficientemente larga (en promedio solo 3 interacciones por usuario), por lo tanto SASRec no es capaz de aprender patrones relevantes en los datos.

6. Conclusión

En este trabajo, hemos propuesto una mejora arquitectónica al framework EFMRec mediante la integración de un mecanismo de Gated Fusion para la ponderación dinámica de modalidades. A diferencia del promedio simple utilizado en la implementación original de EFMRec para manejar datos faltantes, nuestra propuesta permite al modelo aprender automáticamente la importancia relativa de las fuentes visuales y textuales, optimizando así la representación final del ítem. Los resultados experimentales demuestran que este enfoque de fusión dinámica alcanza un rendimiento superior en métricas como Recall, nDCG y MAP en comparación con las líneas base evaluadas. En conclusión, la implementación de un mecanismo de ponderación adaptable no solo refina la integración multimodal, sino que también ofrece una estrategia más flexible y precisa, superando las limitaciones de los métodos basados en promedios.

References

- Chen, L., Yi, P., Hou, X., Yang, C., and Cai, X. When modalities go missing: Early fusion for multimodal recommendation. In *Proceedings of the 19th ACM International Conference on Web Search and Data Mining*, pp. 1094–1098. ACM, 2026.
- Cheng, Y., Pan, Y., Zhang, J., Ni, Y., Sun, A., and Yuan, F. An image dataset for benchmarking recommender systems with raw pixels. *arXiv preprint arXiv:2309.06789*, 2023.
- Giahi, R., Yao, K., Kollipara, S., Zhao, K., Mirjalili, V., Xu, J., Biswas, T., Korpeoglu, E., and Achan, K. Vl-clip: Enhancing multimodal recommendations via visual grounding and llm-augmented clip embeddings. *arXiv preprint arXiv:2507.17080*, 2025.
- Ivanova, V., Lashinin, O., Ananyeva, M., and Kolesnikov, S. Recbaselines2023: a new dataset for choosing baselines for recommender models, 2023. URL <https://arxiv.org/abs/2306.14292>.
- Jadon, A. and Patil, A. A comprehensive survey of evaluation techniques for recommendation systems, 2024. URL <https://arxiv.org/abs/2312.16015>.
- Kang, W.-C. and McAuley, J. Self-attentive sequential recommendation, 2018. URL <https://arxiv.org/abs/1808.09781>.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., and Sutskever, I. Learning transferable visual models from natural language supervision. *arXiv preprint arXiv:2103.00020*, 2021.
- Sarwar, B., Karypis, G., Konstan, J., and Riedl, J. Item-based collaborative filtering recommendation algorithms. In *Proceedings of the 10th International Conference on World Wide Web*, pp. 285–295, New York, NY, USA, 2001. Association for Computing Machinery. doi: 10.1145/371920.372071.
- Yuan, H. and Hernandez, A. A. User cold start problem in recommendation systems: A systematic review. *IEEE Access*, 11:136958–136977, 2023. doi: 10.1109/ACCESS.2023.3338705.
- Zhai, X., Mustafa, B., Kolesnikov, A., and Beyer, L. Sigmoid loss for language image pre-training, 2023. URL <https://arxiv.org/abs/2303.15343>.
- Zhang, J. and Pu, P. A recursive prediction algorithm for collaborative filtering recommender systems. In *Proceedings of the 2007 ACM Conference on Recommender Systems*, pp. 57–64, New York, NY, USA, 2007. Association for Computing Machinery. doi: 10.1145/1297231.1297241.