
Recomendación Secuencial Basada en Sesiones en E-Commerce: Un Estudio Comparativo de Modelos Locales, Neuronales e Híbridos

Tomás Andrés Ketterer Aguirre¹ Cristóbal Miguel Moreno Rojas¹ Vicente Ignacio Soto González¹

Abstract

Este trabajo estudia el problema de recomendación secuencial basada en sesiones en e-commerce, formulado como una tarea de predicción del siguiente ítem a partir de las interacciones recientes de un usuario. Se evalúan modelos basados en coocurrencias locales, reglas secuenciales, arquitecturas neuronales y variantes híbridas con reranking mediante metadatos, bajo un pipeline de evaluación temporal estricto y sobre dos datasets públicos con estructuras complementarias: *eCommerce Behavior Data from Multi Category Store* y *RetailRocket*. Los resultados muestran que, en escenarios dominados por sesiones cortas, alta sparsity y fuerte señal de recencia, los enfoques locales e híbridos superan consistentemente a los modelos neuronales considerados en ambos datasets. Un análisis segmentado por longitud de sesión, popularidad del ítem objetivo y disponibilidad de metadatos revela que el aporte del reranking con metadatos es heterogéneo y mejora de forma consistente el Recall en objetivos de popularidad media y baja con metadatos disponibles, pero puede degradar NDCG y MAP cuando el ítem objetivo carece de metadatos. Además, se incorpora de manera exploratoria el modelo TALE, cuyos resultados sugieren potencial para este tipo de problema, aunque su comparación requiere cautela debido a restricciones metodológicas asociadas al catálogo utilizado. En conjunto, los hallazgos muestran que la estructura del dataset y la naturaleza local de la señal secuencial son factores determinantes para el desempeño de los recomendadores en sesiones de e-commerce.

1. Introducción

La recomendación secuencial basada en sesiones es un problema especialmente relevante en e-commerce, donde el objetivo es predecir el siguiente ítem con el que interactuará un usuario a partir de su secuencia reciente de acciones. Esta formulación, conocida como next-item prediction, resulta

particularmente adecuada cuando las sesiones son breves y no se dispone de suficiente historial de largo plazo para modelar preferencias estables del usuario, por lo que la señal útil proviene principalmente de interacciones recientes y ordenadas dentro de la sesión (Jannach et al., 2022).

En este contexto, surge la pregunta de qué tipo de modelos y señales resultan más efectivos para abordar y resolver el problema. En particular, resulta interesante comparar el aporte de enfoques basados en co-ocurrencias locales, reglas secuenciales, modelos neuronales y estrategias de reranking con metadatos propios de los productos, tales como categoría, marca o precio. Esta comparación resulta relevante no solo desde el punto de vista del desempeño, sino también para entender qué propiedades y contextos del dataset favorecen a cada familia de modelos. Por ello, un objetivo central de este trabajo es ir más allá de la comparación global entre modelos y estudiar, mediante un análisis segmentado, bajo qué condiciones específicas cada variante aporta valor.

Para abordar este problema, utilizamos dos datasets públicos de e-commerce con características complementarias. El primero es *eCommerce Behavior Data from Multi Category Store*, que contiene interacciones de tipo view, cart y purchase, junto con atributos de producto como precio, marca y categoría. El segundo es *RetailRocket eCommerce Dataset*, que incluye eventos de navegación y compra, además de información de catálogo y propiedades de producto. Dado el tamaño del primer dataset, construimos una muestra reproducible mediante un esquema de muestreo basado en hashing estable de sesiones, lo que permite seleccionar observaciones de forma consistente entre ejecuciones sin depender del orden físico del archivo (Aamand et al., 2024). Sobre ambos datasets definimos pipelines de evaluación temporal estrictos y realizamos un estudio comparativo de recomendadores secuenciales en sesiones de e-commerce. La incorporación del segundo dataset permite evaluar directamente si las conclusiones obtenidas dependen de un único conjunto de datos o si se mantienen al cambiar la estructura de las interacciones, la disponibilidad de metadatos y la forma de construir las sesiones.

2. Estado del arte

La recomendación secuencial basada en sesiones ha recibido una creciente atención como un caso particular de sistemas recomendadores en el que no se dispone un perfil o historial de largo plazo del usuario y sus interacciones. En este escenario, el objetivo se define como intentar predecir el siguiente ítem a partir de la secuencia reciente de interacciones dentro de una sesión, lo que ha generado y motivado el desarrollo de múltiples enfoques que difieren en la forma de modelar dependencias locales, patrones de transición y relaciones de largo plazo. La literatura reciente muestra que, aunque los modelos neuronales han ampliado considerablemente la capacidad de representación, estudios comparativos bajo condiciones de estricta igualdad han encontrado que métodos más simples basados en vecinos o co-ocurrencias pueden seguir siendo altamente competitivos, especialmente en datasets con sesiones cortas y caracterizados por una alta dispersión (Ludewig & Jannach, 2018; Ludewig et al., 2019).

2.1. Métodos clásicos basados en co-ocurrencias y transiciones locales

Una primera familia de métodos para recomendación basada en sesiones modela el problema a partir de co-ocurrencias ítem-ítem, reglas secuenciales o dependencias Markovianas. Estos enfoques se apoyan en la base de que la señal más útil para predecir el siguiente ítem se encuentra en las transiciones locales observadas en sesiones similares o en la vecindad inmediata del elemento actual. Su punto fuerte es la simplicidad, interpretabilidad y eficiencia computacional, además de su desempeño muy competente en escenarios con sesiones cortas y datasets dispersos. Evaluaciones comparativas amplias han mostrado que métodos basados en vecinos pueden igualar o superar a alternativas más complejas en tareas de recomendación secuencial basada en sesiones (Ludewig & Jannach, 2018; Ludewig et al., 2019).

2.2. Modelos neuronales secuenciales

Una parte importante del estado del arte se ha dirigido hacia modelos neuronales capaces de capturar dependencias más complejas dentro de la secuencia de eventos. Entre los trabajos más relevantes destaca GRU4Rec, que introdujo el uso de redes recurrentes tipo GRU para la predicción del siguiente ítem en sesiones anónimas (Hidasi et al., 2016). Posteriormente, modelos como NARM incorporaron mecanismos de atención para combinar la dinámica secuencial con una representación del propósito principal de la sesión (Li et al., 2017), mientras que SASRec buscó equilibrar la capacidad de modelar dependencias de corto y largo alcance con una implementación más eficiente que las arquitecturas recurrentes profundas (Kang & McAuley, 2018). En conjunto, esta línea de modelos ha ampliado la cantidad de técnicas

disponibles, aunque su superioridad depende fuertemente de las características del dataset y del contexto experimental en el que sean implementadas.

2.3. Modelos basados en grafos

Otra línea relevante modela cada sesión como un grafo de transiciones entre productos, en lugar de tratarla únicamente como una secuencia lineal. Bajo esta visión, los ítems y sus conexiones permiten representar relaciones más complejas entre pasos de navegación. Un modelo importante es SR-GNN, que utiliza redes neuronales sobre grafos para capturar transiciones complejas y combinar preferencia global de la sesión con interés actual del usuario (Wu et al., 2019).

2.4. Modelos lineales y señal temporal

Más recientemente, han resurgido enfoques lineales ítem-ítem que buscan combinar eficiencia y precisión en la recomendación secuencial. Un ejemplo es la familia de modelos lineales que se encuentran conscientes de la sesión, que muestran qué formulaciones cerradas y escalables pueden competir con métodos más complejos (Choi et al., 2021). En esta línea, TALE propone un modelo lineal temporal ítem-ítem que incorpora explícitamente información de tiempo, incluyendo intervalos temporales y cambios de tendencia, con el objetivo de capturar información temporal de preferencia sin sacrificar la eficiencia computacional (Park et al., 2024).

3. Datasets

Con el fin de estudiar la recomendación secuencial basada en sesiones en contextos de e-commerce, este trabajo considera dos datasets públicos. El primero corresponde a *eCommerce Behavior Data from Multi Category Store*, que contiene eventos de comportamiento de usuarios en una tienda online multi-categoría entre octubre de 2019 y abril de 2020, donde cada fila representa una interacción usuario-producto (Mkechinov, 2019). Este dataset resulta especialmente adecuado para la evaluación hecha, ya que incluye identificadores de sesión explícitos, tipos de evento y atributos de producto como categoría, marca y precio.

El segundo corresponde a *RetailRocket eCommerce Dataset*, un conjunto de datos de e-commerce compuesto por eventos de comportamiento, propiedades de ítems y una jerarquía de categorías (RetailRocket, 2015). A diferencia del primer dataset, RetailRocket no entrega explícitamente las sesiones de los usuarios, por lo que estas deben reconstruirse a partir de la actividad temporal de cada usuario mediante una ventana de inactividad. Esta combinación permite evaluar si los hallazgos observados dependen de un único dataset o si se mantienen al cambiar la estructura de las interacciones, la disponibilidad de metadatos y la forma de construir las

sesiones.

3.1. eCommerce Behavior Data from Multi Category Store

Dado que el archivo original supera los 67 millones de eventos, se construyó una muestra reproducible mediante un muestreo basado en hashing estable de sesiones, técnica que selecciona observaciones a partir del valor hash de una clave y mantiene la consistencia del muestreo entre ejecuciones (Amand et al., 2024), permitiendo trabajar eficientemente sin cargar el archivo completo en memoria. La muestra utilizada, correspondiente a una fracción del 1% de las sesiones, contiene 677.781 eventos de 138.013 sesiones únicas y 67.792 productos distintos, cubriendo específicamente el mes de noviembre de 2019. La sparsity de la matriz sesión-producto es de 0,999928.

El preprocesamiento incluyó la conversión de `event_time` a formato fecha-hora con zona UTC, la normalización de `event_type` a minúsculas, la imputación de valores faltantes en `brand` y `category_code` con la categoría `unknown`, y la conversión de `price` a formato numérico. Se eliminaron filas sin información esencial para reconstruir la secuencia (`event_time`, `product_id` o `user_session`), los eventos se ordenaron temporalmente dentro de cada sesión y se construyeron las secuencias de ítems eliminando duplicados consecutivos del mismo producto para no inflar artificialmente la longitud de las sesiones.

El dataset está dominado muy fuertemente por eventos `view` (94,2%), seguidos por `cart` (4,4%) y `purchase` (1,4%). Esta distribución, presentada en la Figura 2 del Apéndice, sugiere que la mayor parte de la actividad corresponde a navegación exploratoria y no necesariamente a intención inmediata de compra. En consecuencia, y con el objetivo de construir secuencias más robustas para la tarea de next-item prediction, en este trabajo se unificaron los tipos de evento en una única secuencia de interacción por sesión. La mayoría de las sesiones son cortas, con una longitud promedio de 4,91 eventos y una distribución de cola larga que alcanza un máximo de 316 interacciones. Esta concentración en sesiones de baja longitud puede observarse en la Figura 3 del Apéndice. Las interacciones por producto se caracterizan por una alta concentración de la actividad en pocos ítems, como se observa en la Figura 4 del Apéndice. Esto justifica el umbral de soporte mínimo aplicado y anticipa que los enfoques puramente colaborativos pueden enfrentar dificultades en la *long-tail*. Las categorías más frecuentes pertenecen a electrónica, como se observa en la Figura 5 del Apéndice. Además, debido a la alta dispersión y presencia de outliers en los precios, se utilizó el logaritmo del precio como feature para estabilizar el módulo de reranking por metadatos. Un aspecto relevante para el

análisis posterior es que un 32,4% de los eventos tiene categoría desconocida, lo que limita el uso de esta señal en algunos contextos. La secuencia de transición más frecuente es `view`→`view`, seguida de `view`→`cart`, como se observa en la Tabla 7 del Apéndice. Esto valida que modelar el orden secuencial aporta mayor información que considerar únicamente la co-ocurrencia de eventos.

Las estadísticas resultantes tras el split temporal y el filtrado se resumen en la Tabla 1.

Table 1. Estadísticas del dataset eCommerce tras filtrado y split temporal estricto.

Partición	Sesiones	Interacc.	Ítems
Train (1–24 Nov)	48.661	255.659	12.519
Validation (25–27 Nov)	4.135	18.836	5.194
Test (28–30 Nov)	4.423	19.330	5.032

3.2. RetailRocket eCommerce Dataset

RetailRocket contiene 2.756.101 eventos de 1.407.580 visitantes únicos y 235.061 ítems, con una cobertura temporal de 139 días. A diferencia del dataset eCommerce, RetailRocket no trae sesiones explícitas, por lo que estas se reconstruyen por `visitorid` usando un corte de 30 minutos de inactividad, una heurística común en la construcción de sesiones cuando no existen sesiones explícitas (Jannach et al., 2022). Luego se construyen las secuencias por sesión y se eliminan duplicados consecutivos del mismo ítem. Tras descartar sesiones demasiado cortas para *next-item prediction*, quedan 263.899 sesiones útiles, con una longitud media de 3,70, mediana de 2, máximo de 415 y una sparsity del problema de 0,999984, valores que refuerzan el carácter disperso y de sesiones cortas observado también en el primer dataset.

En términos de comportamiento, RetailRocket presenta una estructura muy similar al dataset eCommerce, la actividad está dominada por eventos `view`, mientras que `cart` y `purchase` aparecen con una frecuencia bastante menor, como se muestra en la Figura 6 del Apéndice. Esto permite observar que nuevamente, la mayor parte de las interacciones corresponde a navegación exploratoria, por lo que se mantiene la decisión de unificar los distintos tipos de evento en una única secuencia de interacción por sesión. La distribución de longitudes también confirma que la mayoría de las sesiones son breves y que existe una cola larga de sesiones considerablemente más extensas, patrón presentado en la Figura 7 del Apéndice. Este comportamiento es muy relevante para la evaluación, ya que favorece métodos capaces de explotar señales locales fuertes, pero limita el potencial de modelos que requieren secuencias largas para aprender dependencias de mayor alcance.

La popularidad de productos en RetailRocket también presenta una distribución altamente concentrada, una proporción reducida de ítems acumula gran parte de las interacciones, mientras que la mayoría del catálogo permanece en la *long-tail*, como se observa en la Figura 8 del Apéndice. Este patrón se condice con el dataset eCommerce y justifica el uso de filtros de soporte mínimo para reducir ruido y mejorar la estabilidad de los modelos colaborativos. A su vez, esto anticipa dificultades para recomendar ítems poco frecuentes, especialmente para enfoques puramente basados en coocurrencia o vecinos.

Finalmente, las transiciones entre tipos de evento refuerzan el carácter secuencial del problema. En RetailRocket, la transición dominante es *view*→*view*, seguida por transiciones desde *view* hacia *cart* y desde *cart* hacia *view*, como se muestra en la Figura 9 del Apéndice. Este patrón es totalmente consistente con el dataset eCommerce y muestra que no solo importa qué ítems aparecen juntos, sino también el orden y el tipo de interacción que los conecta. Por ello, ambos datasets permiten evaluar si los modelos capturan únicamente popularidad y coocurrencia local, o si logran aprovechar señales secuenciales más informativas.

Los metadatos se construyeron en una versión mínima basada en *categoryid* y *category_root* a partir de *item_properties* y *category_tree*: 33.608 ítems del catálogo final de train quedaron con categoría, con una cobertura de 0,973, distribuidos en 799 categorías y 19 categorías raíz. Las estadísticas del split se resumen en la Tabla 2.

Table 2. Estadísticas del dataset RetailRocket tras filtrado y split temporal estricto.

Partición	Sesiones	Interacc.	Ítems
Train	187.639	713.906	34.542
Validation	8.511	29.313	–
Test	7.407	26.000	–

4. Metodología experimental

4.1. Formulación y split temporal

El problema se formula como next-item prediction. Dado el prefijo de una sesión, el sistema debe predecir el siguiente producto con el que interactuará el usuario. En ambos datasets se utiliza un split temporal estricto, que evita la filtración de información del futuro que ocurriría con particiones aleatorias. En eCommerce se reservaron los últimos seis días del mes (3 para validación y 3 para test) y los primeros 24 para entrenamiento. En RetailRocket se realizó un corte análogo por *end_time*. El filtrado iterativo por soporte mínimo (5 para ítems y longitud mínima de 2 ítems por sesión) se ejecutó exclusivamente sobre el con-

junto de entrenamiento, y los conjuntos de validación y test se proyectaron al catálogo final de train para proteger el catálogo de cualquier contaminación de datos futuros.

4.2. Métricas

Se evaluó cada configuración mediante Recall@K, NDCG@K y MAP@K, para $K \in \{5, 10, 20\}$, usando $K = 20$ como punto de referencia principal. Estas tres métricas capturan aspectos complementarios, Recall@K mide la capacidad de incluir el ítem objetivo dentro del top-K, mientras que NDCG@K y MAP@K son sensibles a la posición del acierto dentro del ranking. Esta distinción es central para el análisis posterior, ya que una intervención puede mejorar el Recall (traer el objetivo al top-K) sin mejorar necesariamente su posición en la lista, o incluso empeorándola.

4.3. Modelos implementados

Se evaluaron cuatro familias de modelos, implementadas de forma idéntica en ambos datasets:

Baselines. *Random* se utiliza como cota inferior, mientras que *Most Popular* recomienda los ítems más interactuados en train. Además, se incorpora *Item-KNN*, un recomendador basado en similitud ítem-ítem por coocurrencias locales dentro de sesiones, siguiendo la lógica de los enfoques de vecinos cercanos para recomendación basada en sesiones (Ludewig & Jannach, 2018). En nuestra implementación, la similitud se ajusta mediante normalización por soporte y ponderación por recencia.

Modelos neuronales secuenciales. *GRU4Rec*, modelo recurrente basado en unidades GRU (Hidasi et al., 2016), y *SASRec*, modelo secuencial basado en autoatención (Kang & McAuley, 2018).

Reglas secuenciales e híbridos. *Sequential Rules*, modelo que aprende transiciones ponderadas entre ítems considerando orden y distancia entre eventos (Ludewig & Jannach, 2018); *Hybrid KNN+GRU* y *Hybrid KNN+Rules*, mezclas ponderadas de las señales, y *Hybrid tuned*, una variante ajustada mediante búsqueda de pesos sobre las señales combinadas (Item-KNN, Sequential Rules y popularidad reciente) en validación.

Reranking con metadatos. Los candidatos generados por Item-KNN y por el híbrido se reordenan según similitud de categoría, marca y precio en escala logarítmica respecto del último ítem de la sesión, produciendo las variantes con sufijo *_meta*. Adicionalmente se consideró *recent_pop*, un recomendador de popularidad reciente ponderada por tipo de evento y decaimiento temporal.

Finalmente, se integró de manera exploratoria *TALE* (Park et al., 2024), un modelo lineal temporal item-item, entre-

nado sobre un catálogo limitado al top-2000 de train para mantener viable la forma cerrada.

5. Resultados globales

Las Tablas 3 y 4 resumen los resultados en test para $K = 20$ en eCommerce y RetailRocket, respectivamente. En ambos datasets la lectura principal es la misma, los modelos neuronales quedan muy por debajo de los enfoques locales, e Item-KNN se comporta como un baseline extraordinariamente fuerte que solo es superado por sus propias hibridaciones y por el reranking con metadatos.

Table 3. Resultados en test (eCommerce), $K = 20$. Mejores valores en negrita. TALE se reporta aparte por usar un catálogo restringido (ver Sección 7).

Modelo	Recall@20	NDCG@20	MAP@20
random	0.000678	0.000357	0.000272
most_popular	0.078680	0.031365	0.018393
sasrec	0.100610	0.045791	0.030616
gru4rec	0.126837	0.059843	0.041309
seq_rules	0.318336	0.153470	0.106601
hybrid_knn_gru	0.333936	0.165250	0.117142
item_knn	0.335067	0.165375	0.116971
item_knn_meta	0.342076	0.168141	0.118255
hybrid_knn_rules	0.345015	0.168435	0.118196
hybrid_tuned	0.346145	0.167777	0.117148
hybrid_tuned_meta	0.351797	0.171730	0.120342
hybrid_knn_rules_meta	0.352024	0.171679	0.120093
<i>tale (top-2000)</i>	<i>0.418627</i>	<i>0.206736</i>	<i>0.146454</i>

Table 4. Resultados en test (RetailRocket), $K = 20$. Mejores valores en negrita. TALE se reporta aparte por usar un catálogo restringido.

Modelo	Recall@20	NDCG@20	MAP@20
random	0.000135	0.000035	0.000010
most_popular	0.013906	0.004855	0.002366
recent_pop	0.015526	0.006460	0.003959
sasrec	0.022006	0.011149	0.008116
gru4rec	0.025651	0.013353	0.009920
seq_rules	0.361415	0.205586	0.159777
hybrid_knn_gru	0.372756	0.205310	0.156868
item_knn	0.384906	0.210559	0.159927
hybrid_knn_rules	0.394087	0.220332	0.169658
hybrid_tuned	0.394357	0.220849	0.170238
item_knn_meta	0.397732	0.213285	0.159837
hybrid_knn_rules_meta	0.404617	0.221653	0.168459
hybrid_tuned_meta	0.404887	0.222781	0.169847
<i>tale (top-2000)</i>	<i>0.468619</i>	<i>0.274752</i>	<i>0.217953</i>

En eCommerce, `hybrid_knn_rules_meta` obtiene el mayor Recall@20 (0,352), mientras que `hybrid_tuned_meta` lidera en NDCG@20 y MAP@20,

con diferencias mínimas entre ambos. En RetailRocket, `hybrid_tuned_meta` lidera en Recall@20 y NDCG@20, mientras que `hybrid_tuned` (sin reranking) obtiene el mejor MAP@20, lo que permite observar que el aporte del reranking no es uniforme entre métricas. En ambos casos, la mejor mezcla del híbrido ajustado en validación asignó pesos concentrados en Item-KNN y Sequential Rules (0,5 / 0,5), con peso nulo a la popularidad reciente, que por sí sola tuvo un desempeño muy bajo y no entró en la mejor combinación.

5.1. Análisis cualitativo

A modo de ilustración, la Figura 1 presenta un caso real de predicción dentro del conjunto de prueba utilizando `hybrid_tuned_meta`. Ante un prefijo de sesión corto y homogéneo enfocado en dispositivos móviles, el modelo logra explotar con éxito la señal de coocurrencia local y la coherencia de metadatos, posicionando el ítem objetivo (*target real*) directamente en el primer lugar (Rank 1) del top-5 de recomendaciones.



Figure 1. Ejemplo cualitativo de recomendación basada en sesiones con `hybrid_tuned_meta`. El sistema procesa los tres productos previos como contexto secuencial y predice correctamente el siguiente ítem, ubicándolo en la primera posición del ranking.

6. Análisis segmentado

La comparación global no permite observar que el desempeño relativo de los modelos y, sobre todo, el aporte del reranking con metadatos, dependen fuertemente del segmento del conjunto de prueba. Para profundizar aún más, particionamos los casos de test según tres ejes o puntos de vista: longitud de sesión, popularidad del ítem objetivo y disponibilidad de metadatos del objetivo. La distribución de los segmentos (Tabla 5) es fuertemente desbalanceada en ambos datasets.

Table 5. Distribución de casos de test por segmento (número de casos).

Eje	Segmento	eCommerce	RetailRocket
Long. sesión	corta (2–3)	2.522	5.549
	media (4–6)	1.189	1.294
	larga (≥ 7)	712	564
Popularidad	head	2.984	1.484
	mid	739	2.250
	tail	700	3.673
Metadata	completa/con	3.093	7.169
	parcial	1.023	–
	sin metadata	307	238

6.1. Por qué Item-KNN supera a los modelos neuronales

El hallazgo más significativo es que Item-KNN supera a GRU4Rec y SASRec en todos los segmentos de ambos datasets, y el análisis segmentado explica por qué. Los modelos neuronales concentran el poco desempeño que alcanzan en el segmento *head*. En RetailRocket, GRU4Rec y SASRec alcanzan Recall@20 de 0,125 y 0,105 en *head*, pero **terminan alcanzando 0,0 en los segmentos *mid* y *tail***, donde se concentra la mayoría del test (5.923 de 7.407 casos). El mismo patrón, aunque menos extremo, aparece en eCommerce, donde ambos modelos caen a Recall@20 = 0,0 en *tail*. En terminos prácticos, los modelos neuronales aprendieron en esencia un sesgo de popularidad, comportándose de forma similar a *most_popular* en las colas.

Este resultado es consistente con estudios comparables en recomendación basada en sesiones, donde métodos simples basados en vecinos han mostrado ser altamente competitivos, e incluso superar a modelos neuronales más complejos bajo condiciones homogéneas de evaluación (Ludewig & Jannach, 2018; Ludewig et al., 2019). En el caso de este proyecto, una posible explicación es que la señal secuencial disponible se concentra en patrones locales de coocurrencia, especialmente dado el predominio de sesiones cortas en ambos datasets.

6.2. Cuándo aporta el reranking con metadatos

El reranking con metadatos mejora el desempeño agregado, pero el análisis segmentado muestra que ese aporte es **condicional** y depende de la popularidad del objetivo, la disponibilidad de metadatos y la métrica considerada. La Tabla 6 reporta la diferencia de desempeño (Δ) al aplicar reranking sobre Item-KNN por segmento.

Table 6. Aporte del reranking con metadatos sobre Item-KNN ($\Delta = \text{item_knn_meta} - \text{item_knn}$) en Recall@20, NDCG@20 y MAP@20, por segmento.

Dataset	Segmento	ΔR	ΔN	ΔM
eCom.	pop=head	+0.0047	+0.0000	−0.0015
	pop=mid	+0.0041	+0.0087	+0.0091
	pop=tail	+0.0200	+0.0083	+0.0048
	meta=completa	+0.0071	+0.0034	+0.0021
	meta=sin	+0.0098	−0.0072	−0.0120
RRocket	pop=head	+0.0115	−0.0034	−0.0075
	pop=mid	+0.0169	+0.0068	+0.0041
	pop=tail	+0.0109	+0.0027	+0.0003
	meta=con	+0.0138	+0.0044	+0.0017
	meta=sin	−0.0168	−0.0491	−0.0553

De la Tabla 6 emergen tres patrones consistentes entre datasets:

(i) **El reranking aporta más en objetivos de popularidad media y baja.** La mayor ganancia de Recall se concentra en *mid* y *tail* (por ejemplo, +0,020 en *tail* de eCommerce y +0,017 en *mid* de RetailRocket), donde la coherencia semántica de categoría, marca y precio ayuda a rescatar ítems poco populares que el ranking base ordenaba demasiado abajo. En *head*, en cambio, el objetivo suele estar ya bien posicionado y el reranking aporta poco en Recall y puede incluso degradar NDCG y MAP (−0,0075 de MAP en *head* de RetailRocket), al reordenar candidatos que ya estaban correctamente arriba.

(ii) **El reranking penaliza cuando el objetivo carece de metadatos.** Cuando el ítem objetivo no tiene metadatos, el reranking degrada de forma marcada las métricas sensibles al orden: en RetailRocket, $\Delta NDCG = -0,049$ y $\Delta MAP = -0,055$ en el segmento *sin_metadata*. Esto ocurre porque el reordenamiento por similitud de atributos empuja hacia arriba a candidatos coherentes en metadatos, desplazando a un objetivo que, por no tener atributos, no puede beneficiarse de esa señal. El efecto se replica en eCommerce ($\Delta NDCG = -0,0072$, $\Delta MAP = -0,0120$ en *sin_metadata*).

(iii) **Recall, NDCG y MAP no siempre se mueven en conjunto.** Un caso es el segmento *sin_metadata* de eCommerce, donde el reranking mejora el Recall (+0,0098) pero empeora NDCG y MAP, el ítem objetivo entra al top-20 con algo más de frecuencia, pero en promedio queda peor rankeado. Esto explica por qué en la tabla global de RetailRocket el mejor MAP@20 lo obtiene *hybrid_tuned_sin_reranking*, pese a que *hybrid_tuned_meta* lidera en Recall y NDCG.

El patrón sobre el híbrido ajustado es análogo en ambos casos, el reranking aporta más en *mid/tail* y con metadatos

presentes, y penaliza en `sin_metadata` (en RetailRocket, $\Delta\text{Recall} = -0,025$ sobre el híbrido). Por longitud de sesión, el aporte del reranking es positivo en Recall en prácticamente todos los buckets, con mayor efecto en sesiones medias y largas, donde el último ítem del prefijo ofrece un ancla de metadatos más informativa.

6.3. Consistencia de los híbridos por segmento

Las mejores variantes globales (`hybrid_tuned_meta` y `hybrid_knn_rules_meta`) no son de forma uniforme óptimas en todos los segmentos. En las sesiones cortas, que dominan ambos test, los híbridos con reranking ganan de forma clara. Sin embargo, en las sesiones largas de eCommerce, Item-KNN y `hybrid_knn_rules` alcanzan el mayor Recall@20, y el reranking aporta menos, esto ya que un prefijo largo ya provee suficiente evidencia de coocurrencia y los metadatos del último ítem pierde peso. Del mismo modo, en los objetivos *head* de RetailRocket, `hybrid_tuned` sin reranking supera en NDCG/MAP a su versión con metadatos. Por lo tanto, la ventaja de los híbridos con reranking es real y consistente en el agregado, pero se concentra en los segmentos de sesiones cortas y objetivos de popularidad media-baja con metadatos disponibles, y no debe interpretarse como una dominancia total.

7. TALE como extensión exploratoria

Adicionalmente, se incorporó una versión de TALE (Park et al., 2024), el modelo lineal temporal item-item estudiado en el seminario. En ambos datasets, TALE obtuvo los mejores números absolutos (Recall@20 = 0,419 en eCommerce y 0,469 en RetailRocket), superando a todas las demás variantes. Sin embargo, estos resultados no deben leerse como que TALE gana por sobre el resto de los modelos, ya que para mantener viable la solución cerrada item-item, TALE se entrenó y evaluó sobre un catálogo limitado al top-2000 de ítems de train, es decir, resolviendo el problema bajo un espacio de candidatos significativamente más restringido que el catálogo completo (12.519 ítems en eCommerce, 34.542 en RetailRocket) usado por los demás modelos. Bajo esa restricción, el problema es más fácil, por lo que la comparación es metodológicamente distinta. Aun así, la magnitud de la mejora y la coherencia entre datasets sugieren que un modelo lineal que incorpora explícitamente información temporal es una dirección prometedora, y que una evaluación futura sobre el catálogo completo sería necesaria para una comparación justa.

8. Discusión: validez de los resultados

Dos decisiones metodológicas condicionan la validez de las conclusiones y deben ser abordadas de forma explícita.

Impacto del muestreo. En eCommerce se trabajó sobre

una muestra del 1% de las sesiones. El muestreo basado en hashing estable garantiza una selección reproducible y libre del sesgo de truncamiento lineal, y las estadísticas de longitud de sesión y sparsity de la muestra son consistentes con las esperadas para este tipo de dataset. No obstante, un muestreo por sesiones reduce la densidad de coocurrencias observadas, lo que afecta de manera desigual a las familias de modelos, penalizando especialmente a los modelos neuronales, que requieren mayor volumen para aprender representaciones útiles, y menos a Item-KNN, cuya señal local es más robusta a la escasez de datos. De todas formas, que RetailRocket, usado sin submuestreo de sesiones, reproduzca el mismo ordenamiento entre familias de modelos es la evidencia más fuerte de que el hallazgo central no es un artefacto del muestreo, sino una propiedad del régimen de sesiones cortas y alta sparsity.

Alta proporción de categorías desconocidas. En eCommerce, un 32,4% de los eventos tiene categoría desconocida, y solo el 70% de los casos de test tiene metadatos completos. Esto limita directamente el alcance del reranking, la señal de metadatos solo puede ayudar donde efectivamente existe, y como muestra la Sección 6, perjudica activamente el ranking cuando el objetivo carece de atributos. Por ello, las mejoras del reranking reportadas en el agregado son en realidad un promedio entre un subconjunto donde la señal es fuerte (objetivos con metadatos, popularidad media-baja) y otro donde es contraproducente. Interpretar el aporte del reranking sin condicionar por la presencia de metadatos sobreestima su utilidad general.

9. Revisión del plan y ajustes respecto de la etapa intermedia

En la etapa intermedia se comprometieron dos líneas de trabajo. La primera fue incorporar TALE para compararlo con los híbridos, este compromiso **se cumplió**, integrando el modelo en ambos pipelines, aunque con el ajuste metodológico, no previsto originalmente, de restringir su catálogo al top-2000 para hacer manejable la forma cerrada, lo que obliga a leer sus resultados como exploratorios (Sección 7). La segunda línea comprometida fue evaluar la robustez de las conclusiones bajo distintas condiciones de datos. Aquí ajustamos el alcance, en lugar de un split temporal alternativo dentro del mismo dataset de e-commerce, optamos por un segundo dataset independiente (RetailRocket), decisión que consideramos más informativa, pues cambia simultáneamente la estructura de las interacciones, la disponibilidad de metadatos y la forma de construir sesiones. Este cambio cumple y refuerza el objetivo de robustez, al confirmar que la fortaleza de Item-KNN y el comportamiento del reranking se mantienen en un dataset con sesiones reconstruidas.

Finalmente, abordando la retroalimentación de la etapa in-

termedia, el aporte principal de esta versión es la profundización del análisis más allá de la comparación global, el estudio segmentado por longitud de sesión, popularidad del objetivo, disponibilidad de metadatos y la distinción entre Recall, NDCG y MAP (Sección 6) permite ahora justificar cuándo el reranking aporta valor, por qué Item-KNN supera a los modelos neuronales y en qué segmentos las mejoras de los híbridos son consistentes.

10. Conclusiones

Este trabajo estudió la recomendación secuencial basada en sesiones en e-commerce sobre dos datasets con estructuras complementarias. La conclusión central es robusta a través de ambos, en escenarios dominados por sesiones cortas, alta sparsity y fuerte señal de recencia, los enfoques locales e híbridos superan consistentemente a los modelos neuronales, e Item-KNN es un baseline sorprendentemente fuerte. Las mejoras sostenidas provienen de combinar señales complementarias, como Item-KNN con Sequential Rules, y del reranking con metadatos, cuyo aporte es heterogéneo, ya que mejora el Recall en objetivos de popularidad media-baja con metadatos disponibles, pero puede perjudicar NDCG y MAP cuando el objetivo carece de atributos. El análisis segmentado muestra que las diferencias entre las mejores variantes son pequeñas y dependientes del segmento, por lo que no existe un único modelo ganador universal, sino un conjunto de candidatos válidos cuya elección debe estar condicionada al perfil del tráfico y la presencia de metadatos de cada contexto particular de aplicación. Finalmente, TALE aparece como una extensión prometedora, cuya evaluación justa sobre el catálogo completo queda como trabajo futuro. En conjunto, los hallazgos confirman que la estructura del dataset y la naturaleza local de la señal secuencial son factores determinantes para el desempeño de los recomendadores en sesiones de e-commerce.

References

- Aamand, A., Bercea, I. O., Houen, J. B. T., Klausen, J., and Thorup, M. Hashing for sampling-based estimation. *arXiv preprint arXiv:2411.19394*, 2024. URL <https://arxiv.org/abs/2411.19394>.
- Choi, M., Kim, J., Lee, J., Shim, H., and Lee, J. Session-aware linear item-item models for session-based recommendation. In *Proceedings of The Web Conference 2021*, pp. 2186–2197. ACM, 2021. doi: 10.1145/3442381.3450005. URL <https://doi.org/10.1145/3442381.3450005>.
- Hidasi, B., Karatzoglou, A., Baltrunas, L., and Tikk, D. Session-based recommendations with recurrent neural networks. In *International Conference on Learning Representations*, 2016. URL <https://arxiv.org/pdf/1511.06939>.
- Jannach, D., Quadrana, M., and Cremonesi, P. Session-based recommender systems. In Ricci, F., Rokach, L., and Shapira, B. (eds.), *Recommender Systems Handbook*, pp. 301–335. Springer, 3 edition, 2022. URL https://web-ainf.aau.at/pub/jannach/files/BookChapter_RS_Handbook_Sessions.pdf.
- Kang, W.-C. and McAuley, J. Self-attentive sequential recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)*, pp. 197–206. IEEE, 2018. doi: 10.1109/ICDM.2018.00035. URL <https://ieeexplore.ieee.org/document/8594844>.
- Li, J., Ren, P., Chen, Z., Ren, Z., and Ma, J. Neural attentive session-based recommendation. In *Proceedings of the 2017 ACM on Conference on Information and Knowledge Management*, pp. 1419–1428. ACM, 2017. URL <https://arxiv.org/abs/1711.04725>.
- Ludewig, M. and Jannach, D. Evaluation of session-based recommendation algorithms. *arXiv preprint arXiv:1803.09587*, 2018. URL <https://arxiv.org/abs/1803.09587>.
- Ludewig, M., Mauro, N., Latifi, S., and Jannach, D. Empirical analysis of session-based recommendation algorithms. *arXiv preprint arXiv:1910.12781*, 2019. URL <https://arxiv.org/abs/1910.12781>.
- Mkechinov. ecommerce behavior data from multi category store. Kaggle dataset, 2019. URL <https://www.kaggle.com/datasets/mkechinov/e-commerce-behavior-data-from-multi-category-store>.
- Park, S., Yoon, M., Choi, M., and Lee, J. Temporal linear item-item model for sequential recommendation. *arXiv preprint arXiv:2412.07382*, 2024. URL <https://arxiv.org/abs/2412.07382>.
- RetailRocket. Retailrocket ecommerce dataset. Kaggle dataset, 2015. URL <https://www.kaggle.com/datasets/retailrocket/e-commerce-dataset>.
- Wu, S., Tang, Y., Zhu, Y., Wang, L., Xie, X., and Tan, T. Session-based recommendation with graph neural networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pp. 346–353, 2019. doi: 10.1609/aaai.v33i01.3301346. URL <https://arxiv.org/abs/1811.00855>.

A. Distribución de tipos de evento en el dataset eCommerce




Figure 2. Desbalance en la distribución de tipos de evento del dataset eCommerce.

B. Distribución de la longitud de sesiones en el dataset eCommerce.




Figure 3. Distribución de la cantidad de eventos por sesión en el dataset eCommerce, con cap visual en 40 eventos.

C. Distribución de popularidad de productos en el dataset eCommerce, medida como número de interacciones por producto.




Figure 4. Distribución de popularidad de productos en el dataset eCommerce, medida como número de interacciones por producto.

D. Categorías más populares en el dataset eCommerce




Figure 5. Categorías más populares del dataset eCommerce según número de interacciones.

E. Transiciones más comunes en el dataset eCommerce

Table 7. Transiciones más comunes entre tipos de evento consecutivos en el dataset eCommerce.

Evento actual	Siguiente evento	Conteo
view	view	481954
view	cart	25703
cart	view	13646
cart	purchase	7533
purchase	view	5170
cart	cart	4078
view	purchase	1618
purchase	cart	45
purchase	purchase	21

F. Distribución de tipos de evento en el dataset RetailRocket




Figure 6. Desbalance en la distribución de tipos de evento del dataset RetailRocket.

G. Distribución de longitud de sesiones en el dataset RetailRocket




Figure 7. Distribución de la cantidad de eventos por sesión en el dataset RetailRocket, con cap visual en 40 eventos.

H. Distribución de popularidad de productos en el dataset RetailRocket




Figure 8. Distribución de popularidad de productos en el dataset RetailRocket, medida como número de interacciones por producto.

I. Transiciones entre tipos de evento en el dataset RetailRocket



Figure 9. Transiciones entre tipos de evento consecutivos en el dataset RetailRocket.

J. Detalle del análisis segmentado

Esta sección complementa la Sección 6 con el detalle de Recall@20 por segmento para las variantes más representativas, ilustrando el colapso de los modelos neuronales en los objetivos no populares y la concentración del aporte del reranking en los segmentos de popularidad media-baja.

Table 8. RetailRocket: Recall@20 por segmento de popularidad del objetivo. Los modelos neuronales colapsan a 0,0 en *mid* y *tail*.

Modelo	head	mid	tail
hybrid_tuned_meta	0.5148	0.4338	0.3428
hybrid_tuned	0.5142	0.4249	0.3273
item_knn_meta	0.4865	0.4227	0.3466
item_knn	0.4751	0.4058	0.3357
gru4rec	0.1253	0.0018	0.0000
sasrec	0.1051	0.0031	0.0000

Table 9. eCommerce: Recall@20 por longitud de sesión. En sesiones largas Item-KNN y hybrid_knn_rules lideran, y el reranking aporta menos.

Modelo	corta (2–3)	media (4–6)	larga (≥ 7)
hybrid_tuned_meta	0.4520	0.3022	0.1773
item_knn_meta	0.4428	0.2998	0.1791
item_knn	0.4296	0.2898	0.2289
hybrid_knn_rules	–	–	0.2275
gru4rec	0.0296	0.0155	0.0106
sasrec	0.0269	0.0070	0.0089

K. Declaración sobre el uso de Inteligencia Artificial

Durante el desarrollo de este estudio, se emplearon herramientas de inteligencia artificial generativa, específicamente Claude, para asistir en distintas etapas operativas de la investigación. En términos de desarrollo, la IA se utilizó de manera directa como apoyo en la escritura, refactorización y estructuración del código. Su uso fue particularmente clave para la creación de funciones reutilizables transversales a los distintos módulos del proyecto, facilitando la estandarización tanto en la arquitectura de los modelos como en las funciones auxiliares (helpers).

Asimismo, estas herramientas sirvieron como apoyo en la fase exploratoria de datos, agilizando la búsqueda e identificación del dataset RetailRocket. Esto permitió contrastarlo eficientemente con otras alternativas disponibles y establecer un entorno de validación cruzada, entregando una segunda lectura fundamental para corroborar y robustecer los hallazgos inicialmente observados en el dataset eCommerce.

L. Repositorio del proyecto

El código completo del proyecto (notebooks, módulos Python y detalle de los datasets utilizados) está disponible públicamente en el siguiente repositorio de GitHub: <https://github.com/crism0/ECommerce-y-Retail>.