
Green RecSys: El costo ambiental de las funciones de pérdida en recomendación secuencial

David Leal¹ Gabriel Venegas¹

Abstract

El entrenamiento de modelos de *deep learning* para recomendación consume una cantidad creciente de energía y genera emisiones de CO₂, pero la investigación continúa optimizando métricas de precisión sin evaluar sistemáticamente ese costo ambiental. En recomendación secuencial, la función de pérdida determina cuántos ítems negativos se comparan con cada ejemplo positivo, por lo que influye simultáneamente en la calidad del ranking y en el costo computacional del entrenamiento; sin embargo, ese equilibrio entre desempeño y sostenibilidad permanece poco estudiado. Este trabajo cuantifica dicho *trade-off* mediante un experimento controlado en el que entrenamos tres arquitecturas de recomendación secuencial (SAS-Rec, GRU4Rec y NextItNet) con cinco funciones de pérdida (BPR, TOP1, CE y las variantes BPR-max y TOP1-max, implementadas por nosotros con diez negativos) sobre cuatro datasets de distinto tamaño y dominio (LastFM, MovieLens 100K, Amazon Beauty y Diginetica). Realizamos 204 corridas y medimos las emisiones con CodeCarbon en tres GPUs de Google Colab (T4, L4 y A100), manteniendo constantes los hiperparámetros para aislar el efecto de la pérdida.

1. Introducción

El entrenamiento de modelos de aprendizaje automático, especialmente aquellos basados en arquitecturas de *deep learning*, exige recursos computacionales masivos que se traducen en un alto consumo energético. Dado el crecimiento acelerado de estas tecnologías y la finitud de los recursos disponibles, resulta imperativo cuantificar su impacto ambiental. En este contexto, la medición de la huella

de carbono se ha consolidado como una métrica estándar fundamental para guiar la toma de decisiones (Lottick et al., 2019). La urgencia de esta medida se subraya al considerar que el sector de las Tecnologías de la Información y la Comunicación (TIC) representa actualmente entre el 2,1 % y el 3,9 % de las emisiones globales (Gardner et al., 2026), con proyecciones que sugieren que el consumo energético asociado a la IA podría más que duplicarse para el año 2030.

A pesar de que los algoritmos de recomendación son ampliamente utilizados en la industria, existe una escasez de estudios empíricos sobre su impacto ambiental (Plaza et al., 2024). Abordar este desafío trasciende la mera optimización algorítmica, ya que la infraestructura de hardware subyacente es un factor determinante en el volumen de emisiones (Wu et al., 2022). Esta problemática se agrava por el creciente despliegue de hardware de alto consumo energético. A modo de ejemplo, NVIDIA, que controla el 80 % del mercado de GPUs para centros de datos, reportó ventas por 60.920 millones de dólares en 2024, un aumento del 126 % respecto a 2023. De hecho, se estima que las GPUs vendidas únicamente en 2023 consumieron una cantidad de electricidad equivalente a la de 1,3 millones de hogares (Gardner et al., 2026).

En el dominio de los sistemas recomendadores secuenciales, la elección de la función de pérdida (*loss function*) no sólo define la calidad predictiva (Li et al., 2023), sino que condiciona severamente el costo computacional (Ren et al., 2023). En este trabajo evaluamos empíricamente el equilibrio entre calidad (NDCG) y emisiones de CO₂ al entrenar modelos como SASRec (Kang & McAuley, 2018), GRU4Rec (Hidasi et al., 2015) y NextItNet (Yuan et al., 2019), probando distintas funciones de pérdida (CE, BPR, TOP1 y variantes -max) sobre múltiples configuraciones de hardware en la nube. Todo el código y los datos están disponibles en el repositorio público del proyecto: <https://github.com/davidlealo/green-recsys>.

Concretamente, este trabajo se organiza en torno a dos preguntas de investigación: (P1) ¿cómo se comparan las funciones de pérdida en el *trade-off* entre calidad de recomendación (NDCG) y emisiones de CO₂?, y (P2) ¿cómo afecta el hardware a las emisiones cuando la calidad se mantiene constante? La Sección 6 está estructurada en torno a ambas.

¹Departamento de Ciencia de la Computación, Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: David Leal <dlealo@estudiante.uc.cl>, Gabriel Venegas <gabriel.venegas@uc.cl>.

2. Revisión del estado del arte

2.1. El impacto de las funciones de pérdida en RecSys

La literatura reciente revela que la diferencia de rendimiento en modelos secuenciales deriva, en gran medida, de la función de pérdida empleada (Li et al., 2024). Tradicionalmente, modelos como GRU4Rec han empleado funciones *pairwise* como BPR y TOP1 (Hidasi et al., 2015). Sin embargo, estas sufren de desvanecimiento de gradientes al escalar el muestreo negativo. Sus evoluciones, BPR-max y TOP1-max, introducen una ponderación *softmax* que permite al modelo enfocarse en ejemplos negativos informativos (*hard negatives*) sin incrementar excesivamente el costo computacional.

Por otro lado, la *Cross-Entropy* (CE) se ha consolidado como el estándar de calidad al evaluar el catálogo completo, evitando la sobreconfianza (*overconfidence*) asociada a funciones como la BCE con muestreo negativo. Aunque CE es computacionalmente costosa, métodos recientes como SCE (*Scalable Cross-Entropy*) permiten aproximar su rendimiento con una fracción del costo de memoria (Mezentsev et al., 2024).

2.2. Infraestructura y sostenibilidad

Según JetBrains (2025), Python domina el desarrollo de IA, utilizado por el 41 % de su comunidad global (JetBrains, 2025). Herramientas como Google Colab son pilares fundamentales, reportadas como el entorno principal para el 17 % de los profesionales de datos a nivel mundial (JetBrains, 2023). Estudios como el de Kyei et al. (2025) demuestran que, para el entrenamiento de arquitecturas intensivas, el uso de plataformas en la nube resulta en una menor huella de carbono comparado con hardware local de bajas prestaciones. Esto justifica nuestra metodología de emplear Google Colab y CodeCarbon (Courty et al., 2021), reconociendo que, como señalan Milutinović & Lukić (2025), nuestras estimaciones representan un límite inferior (*lower bound*) del costo ambiental real al excluir costos pasivos como la refrigeración de los centros de datos.

Los resultados demuestran que las funciones de pérdida son un vector crítico de eficiencia. Mientras que funciones como CE dominan en calidad, el sobre costo de sus emisiones crece con el catálogo. Las variantes -max emergen como un punto de equilibrio superior.

Si bien este estudio se centró en la fase de entrenamiento, la literatura sugiere que la inferencia en dispositivos *Edge* puede reducir el consumo energético en más de un 90 % y las emisiones de carbono y agua en más de un 80 % (Li et al., 2025). Por lo tanto, como trabajo futuro, resulta imperativo investigar si estas eficiencias son transferibles a las arquitecturas evaluadas, analizando el *trade-off* entre latencia, calidad (NDCG) y reducción del impacto ambiental

sistémico.

3. Solución al problema trabajado

El aporte de este trabajo no es una arquitectura nueva, sino la implementación de las funciones de pérdida que RecBole (Zhao et al., 2021) no trae de fábrica, condición necesaria para la comparación controlada de las cinco funciones.

3.1. Implementación de BPR-max y TOP1-max en RecBole

RecBole ofrece de fábrica solo BPR (Rendle et al., 2009) y CE como valores del parámetro `loss_type` en los modelos secuenciales, y TOP1 únicamente en GRU4Rec. Para completar la comparación implementamos TOP1, BPR-max y TOP1-max siguiendo la formulación de Hidasi & Karatzoglou (2018). En lugar de modificar el código fuente de RecBole, definimos las pérdidas como módulos propios de PyTorch (`TOP1Loss`, `BPRMaxLoss` y `TOP1MaxLoss`) y creamos, para cada arquitectura (SASRec, GRU4Rec y NextItNet), una subclase envoltorio que hereda del modelo base de RecBole y sobrescribe el método `calculate_loss`: este calcula la representación de la secuencia, obtiene los *scores* por producto punto contra los *embeddings* de los ítems positivo y negativos, y los entrega a la pérdida correspondiente.

Un obstáculo técnico determinó el diseño de las variantes -max: para los modelos secuenciales, RecBole entrega un único ítem negativo por positivo e ignora el parámetro de muestreo múltiple, por lo que el *softmax* sobre los negativos colapsaría a 1 y degradaría la pérdida a su versión estándar. Para resolverlo, en las variantes -max desactivamos el muestreo *pairwise* nativo (fijando el tipo de entrada en `POINTWISE`) e implementamos un muestreo negativo propio que genera N ítems negativos por ejemplo positivo con `torch.randint` sobre el rango $[1, n_items)$, evitando el índice 0 reservado al *padding* de las secuencias. Así se construye un tensor de *scores* negativos de forma $(lote, N)$ sobre el que la ponderación *softmax* de las pérdidas -max sí tiene efecto, dando mayor peso a los negativos con *score* alto (*hard negatives*). El valor $N = 10$ se mantuvo fijo en todos los experimentos para que el costo de las variantes -max fuera comparable entre modelos y datasets; BPR y TOP1 usan $N = 1$.

La instrumentación de cada corrida con CodeCarbon y el diseño experimental completo (particiones, baselines, métricas e hiperparámetros) se describen en la sección de metodología. Todo el código, incluidas las pérdidas implementadas y los CSV de las 204 corridas, está disponible en el repositorio público del proyecto.

Table 1. Resumen de los cuatro datasets, ordenados por escala.

Dataset	Dominio	Usuarios	Ítems	Interacc.
LastFM	Música	1.091	3.647	52.551
ML-100K	Películas	943	1.682	100.000
Amazon Beauty	E-commerce	22.363	12.101	198.502
Diginetica	Sesiones	204.000*	43.000	993.000

* Sesiones anónimas en lugar de usuarios. Esparsidad: 98,68 % / 93,70 % / 99,93 % / ~99,99 %, respectivamente.

4. Dataset

4.1. Origen y criterio de selección

Se utilizan cuatro datasets públicos de dominios distintos que abarcan aproximadamente de 52 mil a 993 mil interacciones. Esta gradiente de escala es una decisión de diseño: dado que el costo de cada función de pérdida depende de contra cuántos ítems se compara el positivo (uno para BPR y TOP1, diez para las variantes -max y el catálogo completo para CE), solo una serie de datasets de tamaños crecientes permite observar cómo escala el sobre costo de emisiones de CE respecto de las alternativas.

Los cuatro datasets provienen de fuentes ampliamente utilizadas en la literatura de recomendación secuencial. Para garantizar reproducibilidad se optó, cuando fue posible, por las versiones preprocesadas del repositorio público de S3Rec (Zhou et al., 2020), que son las mismas que utilizan trabajos posteriores como SASRec (Kang & McAuley, 2018) y BERT4Rec (Sun et al., 2019) en sus evaluaciones. ML-100K se carga directamente desde el formato atómico nativo de RecBole. Diginetica se obtuvo desde un archivo público en Google Drive documentado en el repositorio del proyecto. Todos los detalles de descarga están en los notebooks del repositorio.

- **LastFM** (música, S3Rec): el más pequeño de la serie y el de mayor promedio de interacciones por usuario (48,2), un régimen de secuencias largas.
- **MovieLens 100K** (películas, GroupLens): con un mínimo de 20 interacciones por usuario impuesto en la recolección original y la esparsidad más baja de los cuatro. Cargado desde el formato atómico de RecBole.
- **Amazon Beauty** (e-commerce, Amazon Reviews 5-core, S3Rec): promedio de solo 8,9 interacciones por usuario, dos órdenes de magnitud más esparso que MovieLens; un régimen de secuencias cortas.
- **Diginetica** (sesiones de compra, CIKM Cup 2016): el más grande de la serie y el único de sesiones anónimas, el escenario clásico de GRU4Rec.

4.2. Limpieza y preprocesamiento

Los datasets llegan al *pipeline* ya en formato atómico de RecBole (archivos `.inter` con las tripletas usuario-ítem-*timestamp*), por lo que no requieren un preprocesamiento adicional a nivel de tabla. Los filtros de calidad de cada dataset provienen de la fuente original y son heterogéneos por diseño, lo que enriquece la diversidad experimental: el mínimo de 20 interacciones por usuario en ML-100K viene impuesto por GroupLens en la recolección, el 5-core en Beauty por el corpus Amazon Reviews, y LastFM y Diginetica traen el filtrado del preprocesamiento S3Rec y del *zip* original, respectivamente. No se aplicó ningún filtro extra en este trabajo para evitar introducir variación entre condiciones experimentales.

El *pipeline* aplicado dentro de RecBole a los cuatro datasets es idéntico: *ratings*, escuchas y clics se convierten a *feed-back* implícito (práctica estándar donde interesa el orden de consumo y no la magnitud de la señal), las interacciones de cada usuario o sesión se ordenan cronológicamente por *timestamp* para construir las secuencias, y no se aplica un tratamiento adicional de nulos porque los archivos `.inter` entregan tripletas usuario-ítem-*timestamp* completas.

La diversidad de dominios y la gradiente de escala (52K→993K interacciones) son las que habilitan el análisis de escalamiento de emisiones que se presenta en la Sección 6; los detalles de partición (entrenamiento/validación/prueba) y los hiperparámetros comunes a todas las corridas se describen en la metodología.

5. Análisis de Parámetros e Implementación

Para entrenar los modelos utilizando RecBole, mantuvimos los hiperparámetros por defecto. Se realizaron 204 entrenamientos, con una partición de 80 % para entrenamiento, 10 % para validación y 10 % para testeo, durante 20 épocas cada uno. La evaluación se realizó usando todo el dataset, con un tamaño de *embedding* de 64 y una longitud de secuencia de 5, es decir, el modelo utiliza como historial máximo los últimos 5 ítems interactuados. También se modificó el tamaño del *batch* (`train_batch_size`), que se fijó en 2048 a partir de una apreciación propia para asegurar que los tensores encajaran sin problemas en la memoria VRAM de las tres tarjetas gráficas utilizadas, evitando así la necesidad de una búsqueda de grilla exhaustiva. Adicionalmente, integramos y evaluamos las funciones de pérdida TOP1, BPR-Max y TOP1-Max —además de las nativas de RecBole BPR y CE— mediante subclases envoltorio de cada modelo que sobrescriben el cálculo de la pérdida y, en las variantes -Max, incorporan un muestreo negativo propio, según se detalla en la Sección 3. Finalmente, para las funciones de pérdida se usó $N = 1$ (*negative sampling*) en BPR y TOP1, y $N = 10$ en las versiones -Max.

Medimos el consumo energético real y las emisiones de CO₂ mediante la herramienta CodeCarbon con sus parámetros por defecto. Los experimentos se ejecutaron sobre tres GPUs de distintas gamas y generaciones (fuentes oficiales NVIDIA):

- **NVIDIA T4:** arquitectura Turing (16 GB), con un límite máximo de potencia (TDP) de 70 W (NVIDIA, s.f.c).
- **NVIDIA L4:** arquitectura Ada Lovelace (24 GB), enfocada en alta eficiencia energética, con un TDP de 72 W (NVIDIA, s.f.b).
- **NVIDIA A100:** variante SXM4 orientada a fuerza bruta computacional, con un TDP de 400 W (NVIDIA, s.f.a).

El TDP indica únicamente un máximo teórico de disipación de calor. Nuestras mediciones ambientales se respaldan solamente en el consumo eléctrico real capturado con CodeCarbon durante los bucles de entrenamiento. Para nuestro análisis, no consideramos la eficiencia del hardware reportada por la librería, la temperatura u otros factores similares. En cambio, observamos las emisiones de carbono equivalente y la calidad de los modelos, e intentamos extraer conclusiones a partir de estos resultados.

6. Resultados y Análisis

6.1. Calidad vs. Emisiones según Función de Pérdida (P1)

La Tabla 2 resume los resultados de calidad (NDCG@10, HIT@10 y MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s), comparando distintas funciones de pérdida. Para ello, se fija el modelo en **SASRec** y el hardware en **T4**.

Para comprender cómo las funciones de pérdida afectan la relación entre rendimiento y costo ambiental, observamos la Figura 1. En esta figura, cada fila corresponde a un mismo dataset, mientras que cada columna mantiene fijo el hardware evaluado.

Al cruzar la evidencia visual de la Figura 1 con los resultados de la Tabla 2, se confirman los siguientes hallazgos:

- **CE lidera en calidad y tiende a emitir más a gran escala:** Cross-Entropy (CE) logra la mejor calidad predictiva, lo que se comprueba cuantitativamente al obtener el mayor NDCG@10 en 26 de los 36 casos evaluados. Sin embargo, su sobre costo energético crece más que el del resto de las funciones de pérdida al aumentar el tamaño del catálogo de ítems. En escenarios más realistas, como el dataset *Diginetica*, las mediciones muestran que CE llega a emitir, en promedio, un **39 % más de CO₂** frente al resto de las funciones de pérdida.

Table 2. Comparación por función de pérdida para el modelo SASRec entrenado en una GPU T4. Las columnas representan las funciones de pérdida Cross-Entropy, BPR, TOP1, BPR-Max y TOP1-Max, respectivamente. Métr. abrevia la métrica reportada: NDCG, HIT y MAP corresponden a NDCG@10, HIT@10 y MAP@10. CO₂ son emisiones en gramos y T es el tiempo de entrenamiento en segundos. Digin. abrevia Diginetica.

Dataset	Modelo	Métr.	CE	BPR	TOP1	BPR-M	TOP1-M
lastfm	SASRec	NDCG	0.0251	0.0168	0.0172	0.0235	0.0233
		HIT	<u>0.0514</u>	0.0355	0.0353	0.0520	0.0502
		MAP	0.0171	0.0111	0.0117	0.0149	<u>0.0152</u>
		CO ₂	0.184	0.195	0.194	0.190	<u>0.189</u>
		T	67.3	72.7	71.4	69.6	<u>69.0</u>
ml-100k	SASRec	NDCG	0.0455	0.0315	0.0264	0.0427	<u>0.0433</u>
		HIT	0.0973	0.0694	0.0575	0.0925	<u>0.0928</u>
		MAP	0.0301	0.0203	0.0172	0.0279	<u>0.0285</u>
		CO ₂	0.896	0.947	0.936	<u>0.906</u>	0.909
		T	129.5	137.7	136.4	<u>130.9</u>	131.6
beauty	SASRec	NDCG	0.0427	0.0195	0.0126	<u>0.0280</u>	0.0244
		HIT	0.0859	0.0421	0.0265	<u>0.0617</u>	0.0520
		MAP	0.0295	0.0126	0.0084	<u>0.0177</u>	0.0161
		CO ₂	2.036	2.070	2.072	2.028	<u>2.029</u>
		T	215.7	221.3	220.6	214.0	<u>214.3</u>
Digin.	SASRec	NDCG	0.2383	0.1622	0.1417	<u>0.1864</u>	0.1475
		HIT	0.4039	0.2713	0.2417	<u>0.3120</u>	0.2599
		MAP	0.1875	0.1289	0.1111	<u>0.1480</u>	0.1132
		CO ₂	2.893	2.569	<u>1.188</u>	2.514	1.022
		T	1058.6	937.9	<u>432.6</u>	910.3	371.2




Figure 1. Relación entre rendimiento y costo ambiental.

A continuación, se detalla el promedio global (agrupando todos los modelos y hardware) de calidad y emisiones para cada función de pérdida en *Diginetica*, lo que evidencia numéricamente este sobre costo:

- **BPR y TOP1 presentan menor calidad:** A lo largo de los experimentos, se observa que las versiones de BPR y TOP1 obtienen consistentemente las métricas más bajas de calidad de recomendación. En cambio, las versiones -Max parecen mejorar respecto de sus versiones base. Para entender mejor este cambio, la Figura 2 compara BPR y BPR-Max en el dataset *Digi-*

Table 3. Calidad y emisiones promedio según función de pérdida en Diginetica. CO₂ corresponde al promedio de emisiones en gramos y NDCG corresponde al promedio de NDCG@10. Dif. vs CE indica cuánto más emite CE, en porcentaje, respecto de cada alternativa.

Pérdida	CO ₂	NDCG	Dif. vs CE
CE	11.23	0.1985	Referencia
TOP1	9.25	0.0570	CE + 21.3 %
BPRMax	9.01	0.1225	CE + 24.6 %
TOP1Max	7.72	0.1043	CE + 45.5 %
BPR	6.27	0.0655	CE + 79.2 %
Global sin CE	8.06	0.0873	CE + 39.3 %




Figure 2. Comparación empírica en Diginetica para BPR (izquierda) y BPR-Max (derecha).

netica:

En la Figura 2, se aprecia una tendencia en la que BPR-Max eleva levemente las emisiones de carbono frente a BPR. Sin embargo, los resultados confirman que esta alza energética se ve compensada por una mejora en las métricas predictivas (NDCG). Específicamente, BPR-Max queda en segundo lugar promedio. Esto permite inferir que las variantes -Max podrían ser una buena alternativa a CE a medida que escala el dataset.

Adicionalmente, en la Figura 2 se observa un patrón asociado al hardware: la A100 parece emitir consistentemente más que la L4. Además, los modelos SASRec y GRU4Rec parecen tener un comportamiento lineal con respecto a la capacidad de la tarjeta gráfica utilizada, mientras que NextItNet constituye la excepción. Esto motiva la siguiente sección, centrada en el análisis de hardware y escala.

6.2. Escalabilidad y el Efecto del Hardware Físico (P2)

A medida que aumenta el tamaño del dataset, también aumenta el tiempo de entrenamiento para una cantidad fija de épocas. Este efecto se observa en cualquier modelo secuencial utilizado, independientemente del hardware y de la función de pérdida. La Figura 3 muestra este comportamiento al fijar la función de pérdida en BPR y el hardware en L4.

La Tabla 4 resume los resultados de calidad (NDCG@10, HIT@10 y MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s), comparando plataformas de hardware. Para resumir estos resultados, se fija el modelo en **SASRec**



Figure 3. Total global de CO₂ emitido versus el tamaño del dataset. Se fija la función de pérdida en BPR y el hardware en L4.

y la función de pérdida en **CE**.

En general, la Figura 3 muestra cómo influyen el modelo utilizado y su costo computacional en las emisiones de CO₂. NextItNet es el modelo que más emite, seguido de SASRec y, finalmente, GRU4Rec. Esto es esperable debido a la naturaleza de los modelos. Todos parecen crecer linealmente de acuerdo con la cantidad de información que deben procesar, aunque con diferentes constantes de crecimiento asociadas. En esta figura también se observan los valores de emisión que alcanza BPR (que en promedio es la función que menos emite) en la L4, un hardware que suele emitir menos, al menos en comparación con la A100.

Table 4. Comparación por hardware para el modelo SASRec entrenado con la función de pérdida CE. Las columnas T4, L4 y A100 corresponden a las GPUs evaluadas. Métr. abrevia la métrica reportada: NDCG, HIT y MAP corresponden a NDCG@10, HIT@10 y MAP@10. CO₂ son emisiones en gramos y T es el tiempo de entrenamiento en segundos. Digin. abrevia Diginetica.

Dataset	Modelo	Métr.	T4	L4	A100
lastfm	SASRec	NDCG	0.0251	0.0249	0.0249
		HIT	0.0514	0.0508	0.0508
		MAP	0.0171	0.0171	0.0171
		CO ₂	0.184	0.577	0.736
		T	67.3	<u>54.6</u>	38.8
ml-100k	SASRec	NDCG	0.0455	0.0468	0.0447
		HIT	0.0973	0.1001	0.0952
		MAP	0.0301	0.0309	0.0297
		CO ₂	0.896	1.096	1.258
		T	129.5	<u>103.9</u>	70.2
beauty	SASRec	NDCG	0.0427	0.0422	0.0426
		HIT	0.0859	0.0865	0.0853
		MAP	0.0295	0.0287	0.0295
		CO ₂	2.036	1.814	2.043
		T	215.7	<u>172.5</u>	111.1
Digin.	SASRec	NDCG	0.2383	0.2385	0.2381
		HIT	0.4039	0.4049	0.4043
		MAP	0.1875	0.1875	0.1872
		CO ₂	2.893	8.671	9.758
		T	1058.6	<u>815.9</u>	491.6

Al analizar el hardware en la Figura 4, a diferencia del análisis anterior sobre funciones de pérdida, podemos observar lo siguiente:




Figure 4. Total global de CO₂ emitido agrupado por hardware.

- **El hardware no altera la calidad predictiva:** El cambio de GPU modifica los costos energéticos y monetarios (tiempo y CO₂), pero mantiene la misma calidad de las recomendaciones.
- **Interacción Modelo × Hardware:** Los resultados revelan variaciones importantes dependiendo del modelo. Al desagregar las emisiones de CO₂ promediadas en todos los datasets, separando la arquitectura de mayor costo computacional empírico (*NextItNet*, con un tiempo de entrenamiento global promedio de 823 segundos) de las redes más rápidas en cómputo (*SASRec* y *GRU4Rec*, con promedios de 221 s y 79 s, respectivamente), se observan diferencias importantes en la eficiencia energética:
 - **Promedio en modelos de menor carga:** La GPU T4 emite la menor cantidad de CO₂ (0.86 g), superando en eficiencia a la L4 (1.53 g) y a la A100 (1.85 g).
 - **Promedio en modelo de alta carga:** La T4 incrementa considerablemente sus emisiones (13.85 g), mientras que la L4 (3.15 g) y la A100 (4.19 g) presentan un mejor comportamiento energético.

A continuación, se expone la tabla consolidada de emisiones promedio (CO₂ en gramos) a lo largo de todos los datasets:

Table 5. Interacción Modelo × Hardware. Todas las celdas numéricas son emisiones promedio de CO₂ en gramos, alineadas por el punto decimal. Menor Carga representa el promedio de emisiones de CO₂ de los modelos base (*SASRec* y *GRU4Rec*), fijando el conjunto de datasets evaluados; Alta Carga corresponde a *NextItNet* y Global promedia todos los modelos.

HW	SASRec	GRU4Rec	Menor Carga	Alta Carga	Global
T4	1.30	0.43	0.86	13.85	5.19
L4	2.32	0.75	1.53	3.15	2.07
A100	2.78	0.93	1.86	4.19	2.64

Este desglose indica que la elección de la GPU más eficiente depende estrictamente de la carga computacional requerida por la arquitectura de la red. En los modelos de menor requerimiento, el menor TDP de la T4 (70 W) favorece menores

emisiones. Creemos que esto se debe a que el procesamiento de los tensores no provoca un uso del 100 % de la tarjeta y a que, solo por mantenerse encendida, esta GPU emite mucho menos que el resto de las tarjetas evaluadas.

■ Impacto de la T4 en arquitecturas de alto costo:

El menor promedio global de emisiones de la L4 está influido por el comportamiento de *NextItNet*. Al entrenar este modelo de convoluciones dilatadas profundas en la T4, los tiempos de ejecución aumentan abruptamente. Esto mismo sucede al entrenar en CPU, razón por la cual esta alternativa fue descartada del estudio. *NextItNet* genera muchas más emisiones en los datasets de mayor tamaño, empeorando la situación para la T4. En consecuencia, la GPU L4 resulta ser la opción con menores emisiones de CO₂ principalmente cuando los requerimientos matemáticos del modelo superan la capacidad de cómputo eficiente de la T4.

6.3. Modelos Base

En el dataset *ML-100k*, el modelo *Most Popular (Pop)* supera consistentemente a todos los modelos en NDCG@10. Es decir, logra una mejor recomendación con costo cero de emisiones.

Table 6. Eficacia de modelos base en ML-100k. NDCG corresponde al promedio de NDCG@10, CO₂ al promedio de emisiones en gramos y T al tiempo promedio de entrenamiento en segundos.

Modelo	NDCG	CO ₂	T
Pop	0.0557	0.018	2.5
SASRec	0.0378	1.062	101.1
NextItNet	0.0333	2.675	330.0
GRU4Rec	0.0298	0.238	25.2

En el resto de resultados, los baselines obtienen peores resultados que los modelos secuenciales, lo que muestra que los modelos si aprendieron algo, justificando los costos energéticos.

7. Conclusiones

Basándonos en la evidencia recolectada, desprendemos las siguientes conclusiones y recomendaciones directas:

1. **Selección de función de pérdida:** CE garantiza la mejor calidad predictiva, pero sus costos energéticos aumentan cuando el catálogo de ítems es demasiado grande. Habría que explorar con mayor profundidad si esta tendencia sigue aumentando en datasets más grandes que *Diginetica*. A priori, en esta configuración inicial, con hiperparámetros no optimizados y considerando las emisiones como un factor relevante, creemos que es recomendable explorar el uso de funciones como BPR-Max o TOP1-Max por sobre sus

versiones base, pues mejoran las métricas sacrificando solo parcialmente el desempeño ambiental. A pesar de lo anterior, también se observó que BPR-Max seguía, en promedio, por detrás de CE, seguido de TOP1-Max. En general, para obtener la mejor calidad de recomendación, los datos determinarán qué función de pérdida resulta más adecuada.

2. **Selección y sensibilidad de hardware:** La infraestructura de hardware debe seleccionarse de acuerdo con el requerimiento computacional del modelo, ya que el hardware más rápido o potente no asegura menores emisiones. Para modelos de costo computacional bajo o moderado y configuraciones pequeñas (SASRec, GRU4Rec), la GPU T4 presenta la mayor eficiencia energética. Por otro lado, para arquitecturas densas o de alto requerimiento (NextItNet), la ejecución en la T4 prolonga los tiempos de entrenamiento por cuellos de botella, aumentando considerablemente las emisiones. En estos casos, el uso de hardware más avanzado (como la L4) podría ser una buena opción cuando ya se está escalando a niveles productivos, aunque todavía no sea necesario utilizar una A100 para este tipo de experimentos.
3. **Google Colab:** A partir de los resultados observados entre los modelos de mayor tamaño y las GPU de menor capacidad computacional (T4), surge una consideración relevante para la comunidad académica. Colab proporciona acceso gratuito a GPU T4 a cualquier persona con una cuenta. Esta disponibilidad podría incentivar a investigadores y estudiantes con presupuestos limitados a entrenar modelos complejos en una infraestructura que, según lo observado, resulta ser sustancialmente menos eficiente en términos energéticos para estas cargas de trabajo. Esto contribuye a un incremento no intencionado en la huella de carbono asociada a la recomendación secuencial y, por tanto, a la inteligencia artificial. Creemos que podría ser útil que Google Colab incorporara un sistema de alerta y concientización sobre el costo energético asociado a cada modelo. Por ejemplo, sería útil que Colab advirtiera sobre la ejecución de modelos como NextItNet en CPU o T4, cuantificando los posibles costos medioambientales asociados. Incluso podría ser específico respecto de qué funciones de pérdida resultan más interesantes según el dominio de recomendación. Esto podría ayudar a que académicos, estudiantes y personas de la industria tomen mejores decisiones ambientales en beneficio de todos.
4. **Estudios posteriores:** Se plantea que podría ser interesante reproducir estos mismos experimentos modificando los hiperparámetros utilizados. Por ejemplo, no sabemos qué valor de `batch.size` podría repre-

sentar el punto medio entre calidad de recomendación y gasto energético. Además, nuestras recomendaciones sobre las versiones -Max se basan en un número arbitrario de $N = 10$. El número óptimo entre gasto energético y calidad podría ser una línea interesante de exploración cuando se quiere manejar implícitamente el CO_2 producido por la función de pérdida. También se recomienda realizar análisis estadísticos más exhaustivos para estudiar la explicabilidad de las funciones de pérdida en las emisiones de CO_2 y la calidad. Finalmente, sería interesante explorar más funciones de pérdida para validar sus efectos en las emisiones de la recomendación secuencial.

Referencias

- Courty, B., Schmidt, V., Luccioni, S., et al. CodeCarbon: Estimate and track carbon emissions from machine learning computing. <https://github.com/mlco2/codecarbon>, 2021.
- Gardner, J., Dutta, A., Roy, S., Kreidl, O. P., and Bölöni, L. Greener deep reinforcement learning: Analysis of energy and carbon efficiency across Atari benchmarks. *Artificial Intelligence Review*, 2026.
- Hidasi, B. and Karatzoglou, A. Recurrent neural networks with top-k gains for session-based recommendations. In *Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM)*, pp. 843–852, 2018.
- Hidasi, B., Karatzoglou, A., Baltrunas, L., and Tikk, D. Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939*, 2015.
- JetBrains. The state of developer ecosystem 2023: Data science. <https://www.jetbrains.com/lp/devecosystem-2023/data-science/>, 2023.
- JetBrains. Why is Python so popular in 2025? <https://blog.jetbrains.com/pycharm/2025/09/why-is-python-so-popular/>, 2025. PyCharm Blog.
- Kang, W.-C. and McAuley, J. Self-attentive sequential recommendation. In *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, pp. 197–206, 2018.
- Kyei, E. A., Asare, J. W., Ujakpa, M. M., Mutasa, L. S., Gavua, E. K., Freeman, E., and Lempogo, F. Carbon emissions of a CNN model: A comparative study of Colab and Jupyter notebook with an example. In *International Conference on the AI Revolution*, pp. 94–115. Springer Nature Switzerland, 2025.

- Li, F., Yu, S., Zeng, F., and Yang, F. Improving sequential recommendation models with an enhanced loss function. *arXiv preprint arXiv:2301.00979*, 2023.
- Li, F., Peng, H., Yu, S., Zeng, F., Chen, F., and Yang, F. Re-visiting the loss functions in sequential recommendation. *Engineering Applications of Artificial Intelligence*, 138: 109366, 2024.
- Li, P., Islam, M. J., and Ren, S. A case study of environmental footprints for generative AI inference: Cloud versus edge. *ACM SIGMETRICS Performance Evaluation Review*, 53(2):21–26, 2025.
- Lottick, K., Susai, S., Friedler, S. A., and Wilson, J. P. Energy usage reports: Environmental awareness as part of algorithmic accountability. *arXiv preprint arXiv:1911.08354*, 2019.
- Mezentsev, G., Gusak, D., Oseledets, I., and Frolov, E. Scalable cross-entropy loss for sequential recommendations with large item catalogs. In *Proceedings of the 18th ACM Conference on Recommender Systems (RecSys)*, pp. 475–485, 2024.
- Milutinović, M. and Lukić, M. How green is your algorithm? assessing the carbon footprint of machine learning. In *21st International Conference “Man and Working Environment” (SEMSIE)*, 2025.
- NVIDIA. NVIDIA A100 tensor core gpu datasheet. <https://www.nvidia.com/content/dam/en-zz/Solutions/Data-Center/a100/pdf/nvidia-a100-datasheet-us-nvidia-1758950-r4-web.pdf>, s.f.a. Consultado el 7 de julio de 2026.
- NVIDIA. NVIDIA L4 tensor core gpu datasheet. <https://www.cisco.com/c/dam/en/us/products/collateral/servers-unified-computing/ucs-c-series-rack-servers/nvidia-l4-gpu.pdf>, s.f.b. Consultado el 7 de julio de 2026.
- NVIDIA. NVIDIA T4 70w low profile pcie gpu accelerator product brief. <https://www.nvidia.com/content/dam/en-zz/Solutions/Data-Center/tesla-t4/t4-tensor-core-product-brief.pdf>, s.f.c. Consultado el 7 de julio de 2026.
- Plaza, A., Gil, J. C., and Parra, D. 14 Kg of CO₂: Analyzing the carbon footprint and performance of session-based recommendation algorithms. In *International Workshop on Recommender Systems for Sustainability and Social Good (RecSoGood)*, pp. 123–134. Springer Nature Switzerland, 2024.
- Ren, Y., Yang, X., Lu, X., Li, L., Zhou, J., Gu, J., and Zhang, G. GreenSeq: Automatic design of green networks for sequential recommendation systems. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 3364–3368, 2023.
- Rendle, S., Freudenthaler, C., Gantner, Z., and Schmidt-Thieme, L. BPR: Bayesian personalized ranking from implicit feedback. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*, pp. 452–461, 2009.
- Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., and Jiang, P. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, pp. 1441–1450, 2019.
- Wu, C.-J., Raghavendra, R., Gupta, U., Acun, B., Ardalani, N., Maeng, K., et al. Sustainable AI: Environmental implications, challenges and opportunities. *Proceedings of Machine Learning and Systems (MLSys)*, 4:795–813, 2022.
- Yuan, F., Karatzoglou, A., Arapakis, I., Jose, J. M., and He, X. A simple convolutional generative network for next item recommendation. In *Proceedings of the 12th ACM International Conference on Web Search and Data Mining (WSDM)*, pp. 582–590, 2019.
- Zhao, W. X., Mu, S., Hou, Y., Lin, Z., Chen, Y., Pan, X., et al. RecBole: Towards a unified, comprehensive and efficient framework for recommendation algorithms. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM)*, pp. 4653–4664, 2021.
- Zhou, K., Wang, H., Zhao, W. X., Zhu, Y., Wang, S., Zhang, F., Wang, Z., and Wen, J.-R. S3-Rec: Self-supervised learning for sequential recommendation with mutual information maximization. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM)*, pp. 1893–1902, 2020.

A. Resultados complementarios

A.1. Visualizaciones adicionales




Figure 5. Emisiones de CO₂ agrupadas por hardware. En las filas se mantiene el dataset y, en las columnas, la función de pérdida.




Figure 6. Emisiones de CO₂ versus NDCG@10 en el dataset *Diginetica*. Se omite el modelo usado, y solo se muestran la función de pérdida y el hardware usado.

A.2. Tablas de resultados generales por dataset

Table 7. Resultados Generales: beauty (20 épocas)

HW	Modelo	Loss	NDCG@10	HIT@10	MAP@10	CO ₂ (g)	Tiempo (s)
T4	SASRec	BPR	0.0195	0.0421	0.0126	2.070	221.3
T4	SASRec	BPRMax	0.0280	0.0617	0.0177	2.028	214.0
T4	SASRec	CE	0.0427	0.0859	0.0295	2.036	215.7
T4	SASRec	TOP1	0.0126	0.0265	0.0084	2.072	220.6
T4	SASRec	TOP1Max	0.0244	0.0520	0.0161	2.029	214.3
T4	GRU4Rec	BPR	0.0104	0.0205	0.0074	0.583	64.6
T4	GRU4Rec	BPRMax	0.0179	0.0359	0.0124	0.551	60.3
T4	GRU4Rec	CE	0.0267	0.0519	0.0191	0.625	68.2
T4	GRU4Rec	TOP1	0.0097	0.0187	0.0070	0.573	63.5
T4	GRU4Rec	TOP1Max	0.0176	0.0357	0.0121	0.556	60.8
T4	NextItNet	BPR	0.0091	0.0179	0.0065	11.625	1208.9
T4	NextItNet	BPRMax	0.0158	0.0327	0.0107	11.486	1193.7
T4	NextItNet	CE	0.0207	0.0415	0.0145	11.646	1209.1
T4	NextItNet	TOP1	0.0099	0.0198	0.0070	11.523	1198.6
T4	NextItNet	TOP1Max	0.0158	0.0335	0.0105	11.489	1193.4
T4	Pop	–	0.0095	0.0208	0.0062	0.297	58.3
T4	Random	–	0.0003	0.0008	0.0002	0.178	35.7
L4	SASRec	BPR	0.0190	0.0427	0.0118	1.770	173.4
L4	SASRec	BPRMax	0.0271	0.0589	0.0174	1.808	173.9
L4	SASRec	CE	0.0422	0.0865	0.0287	1.814	172.5
L4	SASRec	TOP1	0.0125	0.0263	0.0083	1.821	176.1
L4	SASRec	TOP1Max	0.0242	0.0526	0.0157	1.810	174.3
L4	GRU4Rec	BPR	0.0103	0.0210	0.0071	0.432	44.0
L4	GRU4Rec	BPRMax	0.0181	0.0368	0.0124	0.430	43.3
L4	GRU4Rec	CE	0.0271	0.0532	0.0193	0.469	45.7
L4	GRU4Rec	TOP1	0.0097	0.0196	0.0068	0.436	44.7
L4	GRU4Rec	TOP1Max	0.0172	0.0354	0.0117	0.426	43.1
L4	NextItNet	BPR	0.0084	0.0173	0.0058	2.047	218.6
L4	NextItNet	BPRMax	0.0156	0.0325	0.0105	2.008	201.6
L4	NextItNet	CE	0.0215	0.0428	0.0151	2.284	237.7
L4	NextItNet	TOP1	0.0105	0.0209	0.0074	2.020	203.3
L4	NextItNet	TOP1Max	0.0167	0.0346	0.0114	2.006	201.6
L4	Pop	–	0.0095	0.0208	0.0062	0.289	44.1
L4	Random	–	0.0003	0.0008	0.0002	0.206	33.2
A100	SASRec	BPR	0.0187	0.0414	0.0119	2.049	116.7
A100	SASRec	BPRMax	0.0278	0.0625	0.0173	2.063	117.1
A100	SASRec	CE	0.0426	0.0853	0.0295	2.043	111.1
A100	SASRec	TOP1	0.0134	0.0273	0.0092	2.070	118.6
A100	SASRec	TOP1Max	0.0246	0.0529	0.0160	2.057	117.1
A100	GRU4Rec	BPR	0.0095	0.0195	0.0066	0.566	35.6
A100	GRU4Rec	BPRMax	0.0183	0.0374	0.0125	0.564	35.1
A100	GRU4Rec	CE	0.0277	0.0547	0.0196	0.553	30.2
A100	GRU4Rec	TOP1	0.0097	0.0199	0.0067	0.556	36.7
A100	GRU4Rec	TOP1Max	0.0168	0.0346	0.0115	0.568	35.3
A100	NextItNet	BPR	0.0088	0.0171	0.0063	2.982	201.7
A100	NextItNet	BPRMax	0.0163	0.0334	0.0112	2.726	158.6
A100	NextItNet	CE	0.0207	0.0423	0.0141	3.101	193.9
A100	NextItNet	TOP1	0.0099	0.0204	0.0068	2.726	160.0
A100	NextItNet	TOP1Max	0.0174	0.0361	0.0118	2.719	158.8
A100	Pop	–	0.0095	0.0208	0.0062	0.503	50.5
A100	Random	–	0.0003	0.0008	0.0002	0.318	32.6

Table 8. Resultados Generales: diginetica (20 épocas)

HW	Modelo	Loss	NDCG@10	HIT@10	MAP@10	CO ₂ (g)	Tiempo (s)
T4	SASRec	BPR	0.1622	0.2713	0.1289	2.569	937.9
T4	SASRec	BPRMax	0.1864	0.3120	0.1480	2.514	910.3
T4	SASRec	CE	0.2383	0.4039	0.1875	2.893	1058.6
T4	SASRec	TOP1	0.1417	0.2417	0.1111	1.188	432.6
T4	SASRec	TOP1Max	0.1475	0.2599	0.1132	1.022	371.2
T4	GRU4Rec	BPR	0.0288	0.0571	0.0204	0.782	292.4
T4	GRU4Rec	BPRMax	0.1067	0.1987	0.0789	0.764	285.6
T4	GRU4Rec	CE	0.2048	0.3590	0.1577	1.162	432.5
T4	GRU4Rec	TOP1	0.0163	0.0332	0.0113	0.783	293.1
T4	GRU4Rec	TOP1Max	0.0971	0.1876	0.0699	0.763	283.4
T4	NextItNet	BPR	0.0061	0.0123	0.0042	14.540	5204.0
T4	NextItNet	BPRMax	0.0769	0.1523	0.0543	36.503	5141.3
T4	NextItNet	CE	0.1474	0.2674	0.1109	50.454	5308.7
T4	NextItNet	TOP1	0.0135	0.0283	0.0091	49.002	5161.6
T4	NextItNet	TOP1Max	0.0670	0.1324	0.0474	36.529	5145.4
T4	Pop	–	0.0045	0.0096	0.0030	3.043	810.0
T4	Random	–	0.0001	0.0003	0.0001	2.689	719.8
L4	SASRec	BPR	0.1635	0.2761	0.1291	5.910	559.1
L4	SASRec	BPRMax	0.1868	0.3134	0.1482	7.874	742.9
L4	SASRec	CE	0.2385	0.4049	0.1875	8.671	815.9
L4	SASRec	TOP1	0.1444	0.2459	0.1134	3.601	342.8
L4	SASRec	TOP1Max	0.1483	0.2613	0.1139	3.174	300.4
L4	GRU4Rec	BPR	0.0303	0.0594	0.0216	2.015	200.2
L4	GRU4Rec	BPRMax	0.1066	0.2001	0.0783	1.996	195.2
L4	GRU4Rec	CE	0.2066	0.3624	0.1590	2.974	281.1
L4	GRU4Rec	TOP1	0.0148	0.0309	0.0100	2.058	204.7
L4	GRU4Rec	TOP1Max	0.0974	0.1873	0.0703	2.008	196.5
L4	NextItNet	BPR	0.0026	0.0053	0.0018	8.369	877.1
L4	NextItNet	BPRMax	0.0706	0.1398	0.0499	8.721	858.6
L4	NextItNet	CE	0.1540	0.2797	0.1158	9.665	963.0
L4	NextItNet	TOP1	0.0142	0.0299	0.0095	8.771	867.3
L4	NextItNet	TOP1Max	0.0674	0.1338	0.0475	8.544	857.2
L4	Pop	–	0.0045	0.0096	0.0030	2.628	425.1
L4	Random	–	0.0001	0.0003	0.0001	2.748	470.6
A100	SASRec	BPR	0.1639	0.2720	0.1309	8.999	497.4
A100	SASRec	BPRMax	0.1861	0.3129	0.1474	8.966	494.5
A100	SASRec	CE	0.2381	0.4043	0.1872	9.758	491.6
A100	SASRec	TOP1	0.1410	0.2404	0.1106	4.108	228.6
A100	SASRec	TOP1Max	0.1486	0.2616	0.1142	3.637	201.0
A100	GRU4Rec	BPR	0.0299	0.0580	0.0214	2.566	153.2
A100	GRU4Rec	BPRMax	0.1082	0.2016	0.0800	2.558	147.8
A100	GRU4Rec	CE	0.2060	0.3610	0.1587	3.371	147.2
A100	GRU4Rec	TOP1	0.0161	0.0329	0.0111	2.563	155.7
A100	GRU4Rec	TOP1Max	0.0971	0.1870	0.0700	2.576	149.0
A100	NextItNet	BPR	0.0026	0.0054	0.0018	10.638	723.8
A100	NextItNet	BPRMax	0.0738	0.1481	0.0515	11.175	665.9
A100	NextItNet	CE	0.1524	0.2783	0.1141	12.099	742.7
A100	NextItNet	TOP1	0.0114	0.0238	0.0077	11.203	674.0
A100	NextItNet	TOP1Max	0.0680	0.1339	0.0482	11.194	668.5
A100	Pop	–	0.0045	0.0096	0.0030	4.114	427.6
A100	Random	–	0.0001	0.0003	0.0001	4.460	471.7

Table 9. Resultados Generales: lastfm (20 épocas)

HW	Modelo	Loss	NDCG@10	HIT@10	MAP@10	CO ₂ (g)	Tiempo (s)
T4	SASRec	BPR	0.0168	0.0355	0.0111	0.195	72.7
T4	SASRec	BPRMax	0.0235	0.0520	0.0149	0.190	69.6
T4	SASRec	CE	0.0251	0.0514	0.0171	0.184	67.3
T4	SASRec	TOP1	0.0172	0.0353	0.0117	0.194	71.4
T4	SASRec	TOP1Max	0.0233	0.0502	0.0152	0.189	69.0
T4	GRU4Rec	BPR	0.0099	0.0201	0.0069	0.054	20.6
T4	GRU4Rec	BPRMax	0.0127	0.0275	0.0083	0.050	19.2
T4	GRU4Rec	CE	0.0140	0.0271	0.0101	0.051	19.6
T4	GRU4Rec	TOP1	0.0074	0.0165	0.0048	0.053	20.5
T4	GRU4Rec	TOP1Max	0.0139	0.0283	0.0096	0.050	19.4
T4	NextItNet	BPR	0.0082	0.0169	0.0057	1.111	397.4
T4	NextItNet	BPRMax	0.0120	0.0267	0.0077	1.097	390.8
T4	NextItNet	CE	0.0096	0.0189	0.0068	1.104	393.9
T4	NextItNet	TOP1	0.0091	0.0185	0.0063	1.108	395.1
T4	NextItNet	TOP1Max	0.0137	0.0259	0.0101	1.097	390.9
T4	Pop	–	0.0216	0.1092	0.0102	0.005	3.8
T4	Random	–	0.0029	0.0156	0.0017	0.004	2.7
L4	SASRec	BPR	0.0180	0.0386	0.0118	0.564	56.0
L4	SASRec	BPRMax	0.0234	0.0494	0.0155	0.592	56.6
L4	SASRec	CE	0.0249	0.0508	0.0171	0.577	54.6
L4	SASRec	TOP1	0.0161	0.0357	0.0102	0.593	56.8
L4	SASRec	TOP1Max	0.0231	0.0482	0.0157	0.589	56.4
L4	GRU4Rec	BPR	0.0095	0.0207	0.0061	0.137	14.1
L4	GRU4Rec	BPRMax	0.0136	0.0281	0.0093	0.139	14.2
L4	GRU4Rec	CE	0.0138	0.0267	0.0099	0.130	13.1
L4	GRU4Rec	TOP1	0.0069	0.0157	0.0043	0.076	8.0
L4	GRU4Rec	TOP1Max	0.0146	0.0293	0.0101	0.139	14.2
L4	NextItNet	BPR	0.0079	0.0173	0.0051	0.746	79.7
L4	NextItNet	BPRMax	0.0085	0.0191	0.0053	0.655	65.6
L4	NextItNet	CE	0.0105	0.0211	0.0074	0.735	77.4
L4	NextItNet	TOP1	0.0089	0.0177	0.0063	0.664	66.9
L4	NextItNet	TOP1Max	0.0149	0.0291	0.0107	0.656	66.1
L4	Pop	–	0.0216	0.1092	0.0102	0.019	3.4
L4	Random	–	0.0029	0.0156	0.0017	0.021	2.7
A100	SASRec	BPR	0.0159	0.0343	0.0103	0.753	41.5
A100	SASRec	BPRMax	0.0231	0.0488	0.0152	0.763	41.5
A100	SASRec	CE	0.0249	0.0508	0.0171	0.736	38.8
A100	SASRec	TOP1	0.0169	0.0361	0.0111	0.778	42.6
A100	SASRec	TOP1Max	0.0223	0.0462	0.0151	0.766	41.6
A100	GRU4Rec	BPR	0.0083	0.0171	0.0057	0.180	13.8
A100	GRU4Rec	BPRMax	0.0129	0.0261	0.0089	0.172	13.1
A100	GRU4Rec	CE	0.0143	0.0279	0.0103	0.192	10.7
A100	GRU4Rec	TOP1	0.0071	0.0149	0.0047	0.176	13.7
A100	GRU4Rec	TOP1Max	0.0152	0.0295	0.0109	0.175	13.0
A100	NextItNet	BPR	0.0087	0.0173	0.0061	0.955	72.4
A100	NextItNet	BPRMax	0.0116	0.0237	0.0080	0.991	55.9
A100	NextItNet	CE	0.0098	0.0211	0.0065	0.984	69.1
A100	NextItNet	TOP1	0.0102	0.0207	0.0070	0.994	56.7
A100	NextItNet	TOP1Max	0.0126	0.0243	0.0090	0.989	56.2
A100	Pop	–	0.0216	0.1092	0.0102	0.036	3.5
A100	Random	–	0.0029	0.0156	0.0017	0.035	2.7

Table 10. Resultados Generales: ml-100k (20 épocas)

HW	Modelo	Loss	NDCG@10	HIT@10	MAP@10	CO ₂ (g)	Tiempo (s)
T4	SASRec	BPR	0.0315	0.0694	0.0203	0.947	137.7
T4	SASRec	BPRMax	0.0427	0.0925	0.0279	0.906	130.9
T4	SASRec	CE	0.0455	0.0973	0.0301	0.896	129.5
T4	SASRec	TOP1	0.0264	0.0575	0.0172	0.936	136.4
T4	SASRec	TOP1Max	0.0433	0.0928	0.0285	0.909	131.6
T4	GRU4Rec	BPR	0.0251	0.0559	0.0159	0.256	38.8
T4	GRU4Rec	BPRMax	0.0371	0.0790	0.0247	0.253	38.2
T4	GRU4Rec	CE	0.0384	0.0829	0.0252	0.247	37.4
T4	GRU4Rec	TOP1	0.0100	0.0219	0.0064	0.095	15.0
T4	GRU4Rec	TOP1Max	0.0398	0.0848	0.0265	0.253	37.9
T4	NextItNet	BPR	0.0271	0.0577	0.0181	5.156	732.2
T4	NextItNet	BPRMax	0.0376	0.0782	0.0254	5.367	751.0
T4	NextItNet	CE	0.0366	0.0762	0.0247	5.411	757.8
T4	NextItNet	TOP1	0.0245	0.0547	0.0155	5.381	754.0
T4	NextItNet	TOP1Max	0.0413	0.0829	0.0289	5.370	751.3
T4	Pop	–	0.0557	0.3139	0.0224	0.009	2.6
T4	Random	–	0.0074	0.0626	0.0024	0.005	2.2
L4	SASRec	BPR	0.0322	0.0716	0.0204	1.117	108.2
L4	SASRec	BPRMax	0.0419	0.0941	0.0263	1.126	108.3
L4	SASRec	CE	0.0468	0.1001	0.0309	1.096	103.9
L4	SASRec	TOP1	0.0245	0.0534	0.0160	0.745	72.0
L4	SASRec	TOP1Max	0.0438	0.0952	0.0285	1.126	108.2
L4	GRU4Rec	BPR	0.0242	0.0538	0.0154	0.266	26.8
L4	GRU4Rec	BPRMax	0.0371	0.0799	0.0244	0.262	26.2
L4	GRU4Rec	CE	0.0384	0.0828	0.0252	0.245	23.9
L4	GRU4Rec	TOP1	0.0098	0.0215	0.0064	0.100	10.6
L4	GRU4Rec	TOP1Max	0.0397	0.0851	0.0261	0.265	26.5
L4	NextItNet	BPR	0.0282	0.0611	0.0185	1.419	152.0
L4	NextItNet	BPRMax	0.0357	0.0732	0.0246	1.063	106.6
L4	NextItNet	CE	0.0390	0.0821	0.0262	1.387	146.5
L4	NextItNet	TOP1	0.0250	0.0543	0.0163	1.258	126.9
L4	NextItNet	TOP1Max	0.0408	0.0838	0.0280	0.010	124.9
L4	Pop	–	0.0557	0.3139	0.0224	0.013	2.5
L4	Random	–	0.0074	0.0626	0.0024	0.010	2.2
A100	SASRec	BPR	0.0307	0.0686	0.0195	1.304	75.1
A100	SASRec	BPRMax	0.0432	0.0977	0.0270	1.309	75.2
A100	SASRec	CE	0.0447	0.0952	0.0297	1.258	70.2
A100	SASRec	TOP1	0.0249	0.0527	0.0167	0.932	53.9
A100	SASRec	TOP1Max	0.0445	0.0972	0.0288	1.313	75.4
A100	GRU4Rec	BPR	0.0245	0.0550	0.0155	0.297	23.2
A100	GRU4Rec	BPRMax	0.0358	0.0766	0.0237	0.306	22.8
A100	GRU4Rec	CE	0.0392	0.0833	0.0261	0.308	18.2
A100	GRU4Rec	TOP1	0.0102	0.0229	0.0065	0.113	9.5
A100	GRU4Rec	TOP1Max	0.0380	0.0816	0.0251	0.309	22.8
A100	NextItNet	BPR	0.0279	0.0599	0.0183	1.719	131.1
A100	NextItNet	BPRMax	0.0358	0.0728	0.0247	1.438	86.7
A100	NextItNet	CE	0.0359	0.0782	0.0233	1.775	124.4
A100	NextItNet	TOP1	0.0234	0.0517	0.0150	1.688	102.5
A100	NextItNet	TOP1Max	0.0412	0.0834	0.0286	1.688	101.9
A100	Pop	–	0.0557	0.3139	0.0224	0.031	2.5
A100	Random	–	0.0074	0.0626	0.0024	0.017	2.2

A.3. Tablas de rendimiento por función de pérdida

Table 11. Rendimiento (NDCG@10, HIT@10, MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s) promedio por modelo y hardware. Función de pérdida: CE

Dataset	Métrica	SASRec			GRU4Rec			NextItNet		
		T4	L4	A100	T4	L4	A100	T4	L4	A100
lastfm	NDCG@10	0.0251	0.0249	0.0249	0.0140	0.0138	0.0143	0.0096	0.0105	0.0098
	HIT@10	0.0514	0.0508	0.0508	0.0271	0.0267	0.0279	0.0189	0.0211	0.0211
	MAP@10	0.0171	0.0171	0.0171	0.0101	0.0099	0.0103	0.0068	0.0074	0.0065
	CO ₂ (g)	0.184	0.577	0.736	0.051	0.130	0.192	1.104	0.735	0.984
	Tiempo (s)	67.3	54.6	38.8	19.6	13.1	10.7	393.9	77.4	69.1
ml-100k	NDCG@10	0.0455	0.0468	0.0447	0.0384	0.0384	0.0392	0.0366	0.0390	0.0359
	HIT@10	0.0973	0.1001	0.0952	0.0829	0.0828	0.0833	0.0762	0.0821	0.0782
	MAP@10	0.0301	0.0309	0.0297	0.0252	0.0252	0.0261	0.0247	0.0262	0.0233
	CO ₂ (g)	0.896	1.096	1.258	0.247	0.245	0.308	5.411	1.387	1.775
	Tiempo (s)	129.5	103.9	70.2	37.4	23.9	18.2	757.8	146.5	124.4
beauty	NDCG@10	0.0427	0.0422	0.0426	0.0267	0.0271	0.0277	0.0207	0.0215	0.0207
	HIT@10	0.0859	0.0865	0.0853	0.0519	0.0532	0.0547	0.0415	0.0428	0.0423
	MAP@10	0.0295	0.0287	0.0295	0.0191	0.0193	0.0196	0.0145	0.0151	0.0141
	CO ₂ (g)	2.036	1.814	2.043	0.625	0.469	0.553	11.646	2.284	3.101
	Tiempo (s)	215.7	172.5	111.1	68.2	45.7	30.2	1209.1	237.7	193.9
diginetica	NDCG@10	0.2383	0.2385	0.2381	0.2048	0.2066	0.2060	0.1474	0.1540	0.1524
	HIT@10	0.4039	0.4049	0.4043	0.3590	0.3624	0.3610	0.2674	0.2797	0.2783
	MAP@10	0.1875	0.1875	0.1872	0.1577	0.1590	0.1587	0.1109	0.1158	0.1141
	CO ₂ (g)	2.893	8.671	9.758	1.162	2.974	3.371	50.454	9.665	12.099
	Tiempo (s)	1058.6	815.9	491.6	432.5	281.1	147.2	5308.7	963.0	742.7

Table 12. Rendimiento (NDCG@10, HIT@10, MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s) promedio por modelo y hardware. Función de pérdida: BPR

Dataset	Métrica	SASRec			GRU4Rec			NextIttNet		
		T4	L4	A100	T4	L4	A100	T4	L4	A100
lastfm	NDCG@10	<u>0.0168</u>	0.0180	0.0159	0.0099	<u>0.0095</u>	0.0083	<u>0.0082</u>	0.0079	0.0087
	HIT@10	<u>0.0355</u>	0.0386	0.0343	<u>0.0201</u>	0.0207	0.0171	<u>0.0169</u>	0.0173	0.0173
	MAP@10	<u>0.0111</u>	0.0118	0.0103	0.0069	<u>0.0061</u>	0.0057	<u>0.0057</u>	0.0051	0.0061
	CO ₂ (g)	0.195	<u>0.564</u>	0.753	0.054	<u>0.137</u>	0.180	1.111	0.746	<u>0.955</u>
	Tiempo (s)	72.7	<u>56.0</u>	41.5	20.6	<u>14.1</u>	13.8	397.4	<u>79.7</u>	72.4
ml-100k	NDCG@10	<u>0.0315</u>	0.0322	0.0307	0.0251	0.0242	<u>0.0245</u>	0.0271	0.0282	<u>0.0279</u>
	HIT@10	<u>0.0694</u>	0.0716	0.0686	0.0559	0.0538	<u>0.0550</u>	0.0577	0.0611	<u>0.0599</u>
	MAP@10	<u>0.0203</u>	0.0204	0.0195	0.0159	0.0154	<u>0.0155</u>	0.0181	0.0185	<u>0.0183</u>
	CO ₂ (g)	0.947	<u>1.117</u>	1.304	0.256	<u>0.266</u>	0.297	5.156	1.419	<u>1.719</u>
	Tiempo (s)	137.7	<u>108.2</u>	75.1	38.8	<u>26.8</u>	23.2	732.2	<u>152.0</u>	131.1
beauty	NDCG@10	0.0195	<u>0.0190</u>	0.0187	0.0104	<u>0.0103</u>	0.0095	0.0091	0.0084	<u>0.0088</u>
	HIT@10	<u>0.0421</u>	0.0427	0.0414	<u>0.0205</u>	0.0210	0.0195	0.0179	0.0173	<u>0.0171</u>
	MAP@10	0.0126	0.0118	<u>0.0119</u>	0.0074	<u>0.0071</u>	0.0066	0.0065	0.0058	<u>0.0063</u>
	CO ₂ (g)	2.070	1.770	<u>2.049</u>	0.583	0.432	<u>0.566</u>	11.625	2.047	<u>2.982</u>
	Tiempo (s)	221.3	<u>173.4</u>	116.7	64.6	<u>44.0</u>	35.6	1208.9	<u>218.6</u>	201.7
diginetica	NDCG@10	0.1622	<u>0.1635</u>	0.1639	0.0288	0.0303	<u>0.0299</u>	0.0061	<u>0.0026</u>	<u>0.0026</u>
	HIT@10	0.2713	0.2761	<u>0.2720</u>	0.0571	0.0594	<u>0.0580</u>	0.0123	0.0053	<u>0.0054</u>
	MAP@10	0.1289	<u>0.1291</u>	0.1309	0.0204	0.0216	<u>0.0214</u>	0.0042	0.0018	<u>0.0018</u>
	CO ₂ (g)	2.569	<u>5.910</u>	8.999	0.782	<u>2.015</u>	2.566	14.540	8.369	<u>10.638</u>
	Tiempo (s)	937.9	<u>559.1</u>	497.4	292.4	<u>200.2</u>	153.2	5204.0	<u>877.1</u>	723.8

Table 13. Rendimiento (NDCG@10, HIT@10, MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s) promedio por modelo y hardware. Función de pérdida: TOPI

Dataset	Métrica	SASRec			GRU4Rec			NextIttNet		
		T4	L4	A100	T4	L4	A100	T4	L4	A100
lastfm	NDCG@10	0.0172	0.0161	<u>0.0169</u>	0.0074	0.0069	<u>0.0071</u>	<u>0.0091</u>	0.0089	0.0102
	HIT@10	0.0353	<u>0.0357</u>	0.0361	0.0165	<u>0.0157</u>	0.0149	<u>0.0185</u>	0.0177	0.0207
	MAP@10	0.0117	0.0102	<u>0.0111</u>	0.0048	0.0043	<u>0.0047</u>	<u>0.0063</u>	0.0063	0.0070
	CO ₂ (g)	0.194	<u>0.593</u>	<u>0.778</u>	0.053	<u>0.076</u>	<u>0.176</u>	1.108	0.664	<u>0.994</u>
	Tiempo (s)	71.4	<u>56.8</u>	42.6	20.5	8.0	<u>13.7</u>	395.1	<u>66.9</u>	56.7
ml-100k	NDCG@10	0.0264	0.0245	<u>0.0249</u>	<u>0.0100</u>	0.0098	0.0102	<u>0.0245</u>	0.0250	0.0234
	HIT@10	0.0575	<u>0.0534</u>	<u>0.0527</u>	<u>0.0219</u>	0.0215	0.0229	0.0547	<u>0.0543</u>	0.0517
	MAP@10	0.0172	0.0160	<u>0.0167</u>	<u>0.0064</u>	<u>0.0064</u>	0.0065	<u>0.0155</u>	0.0163	0.0150
	CO ₂ (g)	0.936	0.745	<u>0.932</u>	0.095	<u>0.100</u>	0.113	5.381	1.258	<u>1.688</u>
	Tiempo (s)	136.4	<u>72.0</u>	53.9	15.0	<u>10.6</u>	9.5	754.0	<u>126.9</u>	102.5
beauty	NDCG@10	<u>0.0126</u>	0.0125	0.0134	0.0097	0.0097	0.0097	<u>0.0099</u>	0.0105	<u>0.0099</u>
	HIT@10	<u>0.0265</u>	0.0263	0.0273	0.0187	<u>0.0196</u>	0.0199	0.0198	0.0209	<u>0.0204</u>
	MAP@10	<u>0.0084</u>	0.0083	0.0092	0.0070	<u>0.0068</u>	0.0067	<u>0.0070</u>	0.0074	0.0068
	CO ₂ (g)	2.072	1.821	<u>2.070</u>	0.573	0.436	<u>0.556</u>	11.523	2.020	<u>2.726</u>
	Tiempo (s)	220.6	<u>176.1</u>	118.6	63.5	<u>44.7</u>	36.7	1198.6	<u>203.3</u>	160.0
diginetica	NDCG@10	<u>0.1417</u>	0.1444	0.1410	0.0163	0.0148	<u>0.0161</u>	<u>0.0135</u>	0.0142	0.0114
	HIT@10	<u>0.2417</u>	0.2459	0.2404	0.0332	0.0309	<u>0.0329</u>	<u>0.0283</u>	0.0299	0.0238
	MAP@10	<u>0.1111</u>	0.1134	0.1106	0.0113	0.0100	<u>0.0111</u>	<u>0.0091</u>	0.0095	0.0077
	CO ₂ (g)	1.188	<u>3.601</u>	4.108	0.783	<u>2.058</u>	2.563	49.002	8.771	<u>11.203</u>
	Tiempo (s)	432.6	<u>342.8</u>	228.6	293.1	<u>204.7</u>	155.7	5161.6	<u>867.3</u>	674.0

Table 14. Rendimiento (NDCG@10, HIT@10, MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s) promedio por modelo y hardware. Función de pérdida: BPRMax

Dataset	Métrica	SASRec			GRU4Rec			NextIttNet		
		T4	L4	A100	T4	L4	A100	T4	L4	A100
lastfm	NDCG@10	0.0235	<u>0.0234</u>	0.0231	0.0127	0.0136	<u>0.0129</u>	0.0120	0.0085	0.0116
	HIT@10	0.0520	<u>0.0494</u>	0.0488	<u>0.0275</u>	0.0281	<u>0.0261</u>	0.0267	0.0191	<u>0.0237</u>
	MAP@10	0.0149	0.0155	<u>0.0152</u>	0.0083	0.0093	<u>0.0089</u>	<u>0.0077</u>	0.0053	0.0080
	CO ₂ (g)	0.190	<u>0.592</u>	0.763	0.050	<u>0.139</u>	0.172	1.097	0.655	<u>0.991</u>
	Tiempo (s)	69.6	<u>56.6</u>	41.5	19.2	<u>14.2</u>	13.1	390.8	<u>65.6</u>	55.9
ml-100k	NDCG@10	<u>0.0427</u>	0.0419	0.0432	0.0371	0.0371	<u>0.0358</u>	0.0376	0.0357	<u>0.0358</u>
	HIT@10	0.0925	0.0941	0.0977	<u>0.0790</u>	0.0799	0.0766	0.0782	<u>0.0732</u>	0.0728
	MAP@10	0.0279	0.0263	<u>0.0270</u>	0.0247	<u>0.0244</u>	0.0237	0.0254	<u>0.0246</u>	<u>0.0247</u>
	CO ₂ (g)	0.906	<u>1.126</u>	1.309	0.253	<u>0.262</u>	0.306	5.367	1.063	<u>1.438</u>
	Tiempo (s)	130.9	<u>108.3</u>	75.2	38.2	<u>26.2</u>	22.8	751.0	<u>106.6</u>	86.7
beauty	NDCG@10	0.0280	0.0271	<u>0.0278</u>	0.0179	<u>0.0181</u>	0.0183	<u>0.0158</u>	0.0156	0.0163
	HIT@10	<u>0.0617</u>	0.0589	0.0625	0.0359	<u>0.0368</u>	0.0374	<u>0.0327</u>	0.0325	0.0334
	MAP@10	0.0177	<u>0.0174</u>	0.0173	<u>0.0124</u>	<u>0.0124</u>	0.0125	<u>0.0107</u>	0.0105	0.0112
	CO ₂ (g)	<u>2.028</u>	1.808	2.063	<u>0.551</u>	0.430	0.564	11.486	2.008	<u>2.726</u>
	Tiempo (s)	214.0	<u>173.9</u>	117.1	60.3	<u>43.3</u>	35.1	1193.7	<u>201.6</u>	158.6
diginetica	NDCG@10	<u>0.1864</u>	0.1868	0.1861	<u>0.1067</u>	0.1066	0.1082	0.0769	0.0706	<u>0.0738</u>
	HIT@10	0.3120	0.3134	<u>0.3129</u>	0.1987	<u>0.2001</u>	0.2016	0.1523	0.1398	<u>0.1481</u>
	MAP@10	<u>0.1480</u>	0.1482	0.1474	<u>0.0789</u>	0.0783	0.0800	0.0543	0.0499	<u>0.0515</u>
	CO ₂ (g)	2.514	<u>7.874</u>	8.966	0.764	<u>1.996</u>	2.558	36.503	8.721	<u>11.175</u>
	Tiempo (s)	910.3	<u>742.9</u>	494.5	285.6	<u>195.2</u>	147.8	5141.3	<u>858.6</u>	665.9

Table 15. Rendimiento (NDCG@10, HIT@10, MAP@10), emisiones (CO₂ g) y tiempo de entrenamiento (s) promedio por modelo y hardware. Función de pérdida: TOP1Max

Dataset	Métrica	SASRec			GRU4Rec			NextIttNet		
		T4	L4	A100	T4	L4	A100	T4	L4	A100
lastfm	NDCG@10	0.0233	<u>0.0231</u>	0.0223	0.0139	<u>0.0146</u>	0.0152	<u>0.0137</u>	0.0149	0.0126
	HIT@10	0.0502	<u>0.0482</u>	0.0462	0.0283	<u>0.0293</u>	0.0295	<u>0.0259</u>	0.0291	0.0243
	MAP@10	<u>0.0152</u>	0.0157	0.0151	0.0096	<u>0.0101</u>	0.0109	<u>0.0101</u>	0.0107	0.0090
	CO ₂ (g)	0.189	<u>0.589</u>	0.766	0.050	<u>0.139</u>	0.175	1.097	0.656	<u>0.989</u>
	Tiempo (s)	69.0	<u>56.4</u>	41.6	19.4	<u>14.2</u>	13.0	390.9	<u>66.1</u>	56.2
ml-100k	NDCG@10	0.0433	<u>0.0438</u>	0.0445	0.0398	<u>0.0397</u>	0.0380	0.0413	0.0408	<u>0.0412</u>
	HIT@10	0.0928	<u>0.0952</u>	0.0972	<u>0.0848</u>	0.0851	0.0816	0.0829	0.0838	<u>0.0834</u>
	MAP@10	<u>0.0285</u>	<u>0.0285</u>	0.0288	0.0265	<u>0.0261</u>	0.0251	0.0289	0.0280	<u>0.0286</u>
	CO ₂ (g)	0.909	<u>1.126</u>	1.313	0.253	<u>0.265</u>	0.309	5.370	0.010	<u>1.688</u>
	Tiempo (s)	131.6	<u>108.2</u>	75.4	37.9	<u>26.5</u>	22.8	751.3	<u>124.9</u>	101.9
beauty	NDCG@10	<u>0.0244</u>	0.0242	0.0246	0.0176	<u>0.0172</u>	0.0168	0.0158	<u>0.0167</u>	0.0174
	HIT@10	<u>0.0520</u>	<u>0.0526</u>	0.0529	0.0357	<u>0.0354</u>	0.0346	0.0335	<u>0.0346</u>	0.0361
	MAP@10	0.0161	0.0157	<u>0.0160</u>	0.0121	<u>0.0117</u>	0.0115	0.0105	<u>0.0114</u>	0.0118
	CO ₂ (g)	<u>2.029</u>	1.810	2.057	<u>0.556</u>	0.426	0.568	11.489	2.006	<u>2.719</u>
	Tiempo (s)	214.3	<u>174.3</u>	117.1	60.8	<u>43.1</u>	35.3	1193.4	<u>201.6</u>	158.8
diginetica	NDCG@10	0.1475	<u>0.1483</u>	0.1486	0.0971	0.0974	<u>0.0971</u>	0.0670	<u>0.0674</u>	0.0680
	HIT@10	0.2599	<u>0.2613</u>	0.2616	0.1876	<u>0.1873</u>	0.1870	0.1324	<u>0.1338</u>	0.1339
	MAP@10	0.1132	<u>0.1139</u>	0.1142	0.0699	0.0703	<u>0.0700</u>	0.0474	<u>0.0475</u>	0.0482
	CO ₂ (g)	1.022	<u>3.174</u>	3.637	0.763	<u>2.008</u>	2.576	36.529	8.544	<u>11.194</u>
	Tiempo (s)	371.2	<u>300.4</u>	201.0	283.4	<u>196.5</u>	149.0	5145.4	<u>857.2</u>	668.5

A.4. Tablas de rendimiento por hardware

Table 16. Rendimiento y emisiones agrupados por dataset, modelo y función de pérdida. Hardware fijo: T4. BPR-M representa BPRMax y T1-M representa TOP1Max; NDCG, HIT y MAP se reportan @10, CO₂ en gramos y T en segundos.

Dataset	Modelo	Métr.	CE	BPR	TOP1	BPR-M	T1-M
lastfm	SASRec	NDCG	0.0251	0.0168	0.0172	0.0235	0.0233
		HIT	<u>0.0514</u>	0.0355	0.0353	0.0520	0.0502
		MAP	0.0171	0.0111	0.0117	0.0149	<u>0.0152</u>
		CO ₂	0.184	0.195	0.194	0.190	<u>0.189</u>
		T	67.3	72.7	71.4	69.6	<u>69.0</u>
	GRU4Rec	NDCG	0.0140	0.0099	0.0074	0.0127	<u>0.0139</u>
		HIT	0.0271	0.0201	0.0165	0.0275	0.0283
		MAP	0.0101	0.0069	0.0048	0.0083	<u>0.0096</u>
		CO ₂	0.051	0.054	0.053	0.050	<u>0.050</u>
		T	19.6	20.6	20.5	19.2	<u>19.4</u>
	NextItNet	NDCG	0.0096	0.0082	0.0091	0.0120	0.0137
		HIT	0.0189	0.0169	0.0185	0.0267	0.0259
		MAP	0.0068	0.0057	0.0063	0.0077	0.0101
		CO ₂	1.104	1.111	1.108	1.097	<u>1.097</u>
		T	393.9	397.4	395.1	390.8	<u>390.9</u>
ml-100k	SASRec	NDCG	0.0455	0.0315	0.0264	0.0427	<u>0.0433</u>
		HIT	0.0973	0.0694	0.0575	0.0925	<u>0.0928</u>
		MAP	0.0301	0.0203	0.0172	0.0279	<u>0.0285</u>
		CO ₂	0.896	0.947	0.936	0.906	0.909
		T	129.5	137.7	136.4	<u>130.9</u>	131.6
	GRU4Rec	NDCG	0.0384	0.0251	0.0100	0.0371	0.0398
		HIT	<u>0.0829</u>	0.0559	0.0219	0.0790	0.0848
		MAP	<u>0.0252</u>	0.0159	0.0064	0.0247	0.0265
		CO ₂	<u>0.247</u>	0.256	0.095	0.253	0.253
		T	<u>37.4</u>	38.8	15.0	38.2	37.9
	NextItNet	NDCG	0.0366	0.0271	0.0245	0.0376	0.0413
		HIT	0.0762	0.0577	0.0547	0.0782	0.0829
		MAP	0.0247	0.0181	0.0155	<u>0.0254</u>	0.0289
		CO ₂	5.411	5.156	5.381	<u>5.367</u>	5.370
		T	757.8	732.2	754.0	<u>751.0</u>	751.3
beauty	SASRec	NDCG	0.0427	0.0195	0.0126	0.0280	0.0244
		HIT	0.0859	0.0421	0.0265	<u>0.0617</u>	0.0520
		MAP	0.0295	0.0126	0.0084	<u>0.0177</u>	0.0161
		CO ₂	2.036	2.070	2.072	2.028	<u>2.029</u>
		T	215.7	221.3	220.6	214.0	<u>214.3</u>
	GRU4Rec	NDCG	0.0267	0.0104	0.0097	0.0179	0.0176
		HIT	0.0519	0.0205	0.0187	<u>0.0359</u>	0.0357
		MAP	0.0191	0.0074	0.0070	<u>0.0124</u>	0.0121
		CO ₂	0.625	0.583	0.573	0.551	<u>0.556</u>
		T	68.2	64.6	63.5	60.3	<u>60.8</u>
	NextItNet	NDCG	0.0207	0.0091	0.0099	0.0158	<u>0.0158</u>
		HIT	0.0415	0.0179	0.0198	0.0327	<u>0.0335</u>
		MAP	0.0145	0.0065	0.0070	0.0107	0.0105
		CO ₂	11.646	11.625	11.523	11.486	11.489
		T	1209.1	1208.9	1198.6	<u>1193.7</u>	1193.4
diginetica	SASRec	NDCG	0.2383	0.1622	0.1417	0.1864	0.1475
		HIT	0.4039	0.2713	0.2417	<u>0.3120</u>	0.2599
		MAP	0.1875	0.1289	0.1111	0.1480	0.1132
		CO ₂	2.893	2.569	<u>1.188</u>	2.514	1.022
		T	1058.6	937.9	<u>432.6</u>	910.3	371.2
	GRU4Rec	NDCG	0.2048	0.0288	0.0163	0.1067	0.0971
		HIT	0.3590	0.0571	0.0332	<u>0.1987</u>	0.1876
		MAP	0.1577	0.0204	0.0113	<u>0.0789</u>	0.0699
		CO ₂	1.162	0.782	0.783	<u>0.764</u>	0.763
		T	432.5	292.4	293.1	<u>285.6</u>	283.4
	NextItNet	NDCG	0.1474	0.0061	0.0135	0.0769	0.0670
		HIT	0.2674	0.0123	0.0283	<u>0.1523</u>	0.1324
		MAP	0.1109	0.0042	0.0091	0.0543	0.0474
		CO ₂	50.454	14.540	49.002	36.503	36.529
		T	5308.7	5204.0	5161.6	5141.3	<u>5145.4</u>

Table 17. Rendimiento y emisiones agrupados por dataset, modelo y función de pérdida. Hardware fijo: L4. BPR-M representa BPRMax y T1-M representa TOP1Max; NDCG, HIT y MAP se reportan @10, CO₂ en gramos y T en segundos.

Dataset	Modelo	Métr.	CE	BPR	TOP1	BPR-M	T1-M
lastfm	SASRec	NDCG	0.0249	0.0180	0.0161	0.0234	0.0231
		HIT	0.0508	0.0386	0.0357	0.0494	0.0482
		MAP	0.0171	0.0118	0.0102	0.0155	0.0157
		CO ₂	0.577	0.564	0.593	0.592	0.589
		T	54.6	56.0	56.8	56.6	56.4
	GRU4Rec	NDCG	0.0138	0.0095	0.0069	0.0136	0.0146
		HIT	0.0267	0.0207	0.0157	0.0281	0.0293
		MAP	0.0099	0.0061	0.0043	0.0093	0.0101
		CO ₂	0.130	0.137	0.076	0.139	0.139
		T	13.1	14.1	8.0	14.2	14.2
	NextItNet	NDCG	0.0105	0.0079	0.0089	0.0085	0.0149
		HIT	0.0211	0.0173	0.0177	0.0191	0.0291
		MAP	0.0074	0.0051	0.0063	0.0053	0.0107
		CO ₂	0.735	0.746	0.664	0.655	0.656
		T	77.4	79.7	66.9	65.6	66.1
ml-100k	SASRec	NDCG	0.0468	0.0322	0.0245	0.0419	0.0438
		HIT	0.1001	0.0716	0.0534	0.0941	0.0952
		MAP	0.0309	0.0204	0.0160	0.0263	0.0285
		CO ₂	1.096	1.117	0.745	1.126	1.126
		T	103.9	108.2	72.0	108.3	108.2
	GRU4Rec	NDCG	0.0384	0.0242	0.0098	0.0371	0.0397
		HIT	0.0828	0.0538	0.0215	0.0799	0.0851
		MAP	0.0252	0.0154	0.0064	0.0244	0.0261
		CO ₂	0.245	0.266	0.100	0.262	0.265
		T	23.9	26.8	10.6	26.2	26.5
	NextItNet	NDCG	0.0390	0.0282	0.0250	0.0357	0.0408
		HIT	0.0821	0.0611	0.0543	0.0732	0.0838
		MAP	0.0262	0.0185	0.0163	0.0246	0.0280
		CO ₂	1.387	1.419	1.258	1.063	0.010
		T	146.5	152.0	126.9	106.6	124.9
beauty	SASRec	NDCG	0.0422	0.0190	0.0125	0.0271	0.0242
		HIT	0.0865	0.0427	0.0263	0.0589	0.0526
		MAP	0.0287	0.0118	0.0083	0.0174	0.0157
		CO ₂	1.814	1.770	1.821	1.808	1.810
		T	172.5	173.4	176.1	173.9	174.3
	GRU4Rec	NDCG	0.0271	0.0103	0.0097	0.0181	0.0172
		HIT	0.0532	0.0210	0.0196	0.0368	0.0354
		MAP	0.0193	0.0071	0.0068	0.0124	0.0117
		CO ₂	0.469	0.432	0.436	0.430	0.426
		T	45.7	44.0	44.7	43.3	43.1
	NextItNet	NDCG	0.0215	0.0084	0.0105	0.0156	0.0167
		HIT	0.0428	0.0173	0.0209	0.0325	0.0346
		MAP	0.0151	0.0058	0.0074	0.0105	0.0114
		CO ₂	2.284	2.047	2.020	2.008	2.006
		T	237.7	218.6	203.3	201.6	201.6
diginetica	SASRec	NDCG	0.2385	0.1635	0.1444	0.1868	0.1483
		HIT	0.4049	0.2761	0.2459	0.3134	0.2613
		MAP	0.1875	0.1291	0.1134	0.1482	0.1139
		CO ₂	8.671	5.910	3.601	7.874	3.174
		T	815.9	559.1	342.8	742.9	300.4
	GRU4Rec	NDCG	0.2066	0.0303	0.0148	0.1066	0.0974
		HIT	0.3624	0.0594	0.0309	0.2001	0.1873
		MAP	0.1590	0.0216	0.0100	0.0783	0.0703
		CO ₂	2.974	2.015	2.058	1.996	2.008
		T	281.1	200.2	204.7	195.2	196.5
	NextItNet	NDCG	0.1540	0.0026	0.0142	0.0706	0.0674
		HIT	0.2797	0.0053	0.0299	0.1398	0.1338
		MAP	0.1158	0.0018	0.0095	0.0499	0.0475
		CO ₂	9.665	8.369	8.771	8.721	8.544
		T	963.0	877.1	867.3	858.6	857.2

Table 18. Rendimiento y emisiones agrupados por dataset, modelo y función de pérdida. Hardware fijo: A100. BPR-M representa BPRMax y T1-M representa TOP1Max; NDCG, HIT y MAP se reportan @ 10, CO₂ en gramos y T en segundos.

Dataset	Modelo	Métr.	CE	BPR	TOP1	BPR-M	T1-M
lastfm	SASRec	NDCG	0.0249	0.0159	0.0169	0.0231	0.0223
		HIT	0.0508	0.0343	0.0361	0.0488	0.0462
		MAP	0.0171	0.0103	0.0111	0.0152	0.0151
		CO ₂	0.736	0.753	0.778	0.763	0.766
		T	38.8	41.5	42.6	41.5	41.6
	GRU4Rec	NDCG	0.0143	0.0083	0.0071	0.0129	0.0152
		HIT	0.0279	0.0171	0.0149	0.0261	0.0295
		MAP	0.0103	0.0057	0.0047	0.0089	0.0109
		CO ₂	0.192	0.180	0.176	0.172	0.175
		T	10.7	13.8	13.7	13.1	13.0
	NextItNet	NDCG	0.0098	0.0087	0.0102	0.0116	0.0126
		HIT	0.0211	0.0173	0.0207	0.0237	0.0243
		MAP	0.0065	0.0061	0.0070	0.0080	0.0090
		CO ₂	0.984	0.955	0.994	0.991	0.989
		T	69.1	72.4	56.7	55.9	56.2
ml-100k	SASRec	NDCG	0.0447	0.0307	0.0249	0.0432	0.0445
		HIT	0.0952	0.0686	0.0527	0.0977	0.0972
		MAP	0.0297	0.0195	0.0167	0.0270	0.0288
		CO ₂	1.258	1.304	0.932	1.309	1.313
		T	70.2	75.1	53.9	75.2	75.4
	GRU4Rec	NDCG	0.0392	0.0245	0.0102	0.0358	0.0380
		HIT	0.0833	0.0550	0.0229	0.0766	0.0816
		MAP	0.0261	0.0155	0.0065	0.0237	0.0251
		CO ₂	0.308	0.297	0.113	0.306	0.309
		T	18.2	23.2	9.5	22.8	22.8
	NextItNet	NDCG	0.0359	0.0279	0.0234	0.0358	0.0412
		HIT	0.0782	0.0599	0.0517	0.0728	0.0834
		MAP	0.0233	0.0183	0.0150	0.0247	0.0286
		CO ₂	1.775	1.719	1.688	1.438	1.688
		T	124.4	131.1	102.5	86.7	101.9
beauty	SASRec	NDCG	0.0426	0.0187	0.0134	0.0278	0.0246
		HIT	0.0853	0.0414	0.0273	0.0625	0.0529
		MAP	0.0295	0.0119	0.0092	0.0173	0.0160
		CO ₂	2.043	2.049	2.070	2.063	2.057
		T	111.1	116.7	118.6	117.1	117.1
	GRU4Rec	NDCG	0.0277	0.0095	0.0097	0.0183	0.0168
		HIT	0.0547	0.0195	0.0199	0.0374	0.0346
		MAP	0.0196	0.0066	0.0067	0.0125	0.0115
		CO ₂	0.553	0.566	0.556	0.564	0.568
		T	30.2	35.6	36.7	35.1	35.3
	NextItNet	NDCG	0.0207	0.0088	0.0099	0.0163	0.0174
		HIT	0.0423	0.0171	0.0204	0.0334	0.0361
		MAP	0.0141	0.0063	0.0068	0.0112	0.0118
		CO ₂	3.101	2.982	2.726	2.726	2.719
		T	193.9	201.7	160.0	158.6	158.8
diginetica	SASRec	NDCG	0.2381	0.1639	0.1410	0.1861	0.1486
		HIT	0.4043	0.2720	0.2404	0.3129	0.2616
		MAP	0.1872	0.1309	0.1106	0.1474	0.1142
		CO ₂	9.758	8.999	4.108	8.966	3.637
		T	491.6	497.4	228.6	494.5	201.0
	GRU4Rec	NDCG	0.2060	0.0299	0.0161	0.1082	0.0971
		HIT	0.3610	0.0580	0.0329	0.2016	0.1870
		MAP	0.1587	0.0214	0.0111	0.0800	0.0700
		CO ₂	3.371	2.566	2.563	2.558	2.576
		T	147.2	153.2	155.7	147.8	149.0
	NextItNet	NDCG	0.1524	0.0026	0.0114	0.0738	0.0680
		HIT	0.2783	0.0054	0.0238	0.1481	0.1339
		MAP	0.1141	0.0018	0.0077	0.0515	0.0482
		CO ₂	12.099	10.638	11.203	11.175	11.194
		T	742.7	723.8	674.0	665.9	668.5