
Temporal Repeat-Aware Recommendation: T-BPR y comparación con baselines modernos en Last.fm 1K Users

Pedro Munita José Racioppi Tomás Couyoumdjian
Grupo 32 — IIC3633 Sistemas Recomendadores 2026-1
Pontificia Universidad Católica de Chile
{pmunita, jracioppi, tcouyoumdjian}@uc.cl
<https://github.com/Couyoumdjian13/Analisis-Last.fm-1K-Users>

Abstract

Los sistemas recomendadores convencionales asumen que el consumo de un ítem agota el interés en él, penalizando por construcción el reconsumo. En streaming musical esta hipótesis es incorrecta: el 60.43 % de las reproducciones en el dataset Last.fm 1K Users son re-escuchas. Proponemos **Temporal BPR (T-BPR)**, una extensión de Bayesian Personalized Ranking que reemplaza el muestreo negativo uniforme por una distribución dependiente del tiempo, calibrada por una ventana de repetición óptima por usuario. Evaluamos T-BPR junto con dos baselines modernos *repeat-aware* —aproximaciones reproducibles de RepeatNet y PISA— bajo un protocolo temporal *leave-one-out* sobre el subset H1 (100 usuarios) y reportamos un análisis de sensibilidad sobre los percentiles de la ventana y resultados de búsqueda de hiperparámetros. Los mejores modelos alcanzan $\text{Recall}@10 = 0.09$ y $\text{nDCG}@10 = 0.067$, superando a todos los baselines no temporales que obtienen 0 hits. Una búsqueda de hiperparámetros con validación temporal *rolling* confirma que T-BPR no supera al fuerte baseline de recencia en métricas de ranking (−19 % en $\text{nDCG}@10$), pero calibra el balance *repeat/explore* hacia la tasa empírica del dataset (Repeat Ratio 0.43 frente a ≈ 1.0 de los competidores puramente repetitivos), evitando la política degenerada de recomendar únicamente repeticiones.

1 Introducción

1.1 Problema y motivación

La mayoría de los algoritmos de filtrado colaborativo modelan las interacciones pasadas como señal de preferencias positivas y tratan el espacio de candidatos de recomendación como el complemento del historial. Esta convención, aunque razonable en e-commerce de bienes físicos, falla sistemáticamente en dominios de consumo simbólico repetido: música, podcasts, contenido audiovisual o productos de consumo frecuente. En estos contextos la repetición es la norma, no la excepción.

El dataset Last.fm 1K Users [2] registra las escuchas de 992 usuarios con una resolución temporal de segundos. Un análisis preliminar sobre un subset de 100 usuarios muestra que: (i) el 60.43 % de las reproducciones son reconsumos de ítems previamente escuchados; (ii) el 50 % de las repeticiones ocurre dentro de las primeras 27 horas (localidad temporal / ráfagas); y (iii) la tasa de repetición individual varía entre 3.2 % y 98.2 %, evidenciando heterogeneidad extrema entre usuarios.

Este fenómeno tiene consecuencias directas sobre la evaluación: si el sistema filtra los ítems del historial del catálogo de candidatos —práctica estándar en recomendación exploratoria— un modelo *repeat-aware* obtiene 0 hits por construcción, independientemente de su calidad. El presente trabajo adopta el paradigma *repeat-aware*: el catálogo de candidatos incluye el historial del usuario y el objetivo es predecir su próxima interacción, ya sea un *repeat* o una exploración.

1.2 Contribuciones

1. **T-BPR**: variante de BPR-MF con muestreo negativo dependiente del tiempo, calibrado por una ventana de repetición óptima $W_u = (p_{\text{low}}, p_{\text{high}})$ por usuario derivada del historial de intervalos.
2. Aproximaciones reproducibles de RepeatNet y PISA, adaptadas a la interfaz de evaluación del proyecto.
3. Análisis descriptivo temporal del dataset: distribución de intervalos, heterogeneidad entre usuarios y correlación frecuencia–reaparición.
4. Búsqueda de hiperparámetros para T-BPR mediante validación temporal *rolling*, y un protocolo reproducible de análisis de sensibilidad sobre los percentiles de la ventana W_u .
5. Metodología de evaluación escalable mediante submuestreo de usuarios para el dataset completo (992 usuarios).

2 Trabajos relacionados

2.1 Bayesian Personalized Ranking (BPR)

BPR [7] optimiza los parámetros de una factorización matricial mediante triplas (u, i, j) donde i es un ítem observado por el usuario u y j es un ítem no observado. La función objetivo maximiza la probabilidad de que el usuario prefiera i sobre j :

$$\mathcal{L}_{\text{BPR}} = - \sum_{(u,i,j)} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) + \lambda \|\Theta\|^2, \quad \hat{x}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i, \quad (1)$$

donde $\hat{x}_{ui}$ es el score del par usuario-ítem y j se muestrea uniformemente desde $\mathcal{I} \setminus \mathcal{H}_u$. Esta convención de muestreo uniforme ignora la dinámica temporal: trata como *negativo duro* a un ítem que el usuario escuchará dentro de su próxima ráfaga, lo cual degrada la señal de entrenamiento en dominios de alta repetición.

2.2 RepeatNet (AAAI 2019)

RepeatNet [6] introduce un mecanismo explícito de repetición en recomendación secuencial basada en sesiones. La arquitectura combina un codificador GRU sobre la secuencia de la sesión (estado $\mathbf{h}_t$), un decodificador con mecanismo de copia que puede generar un ítem nuevo del vocabulario global o copiar un ítem del historial de la sesión, y una compuerta de mezcla aprendida $g_t \in [0, 1]$ que pondera ambos modos:

$$P(\text{próximo ítem}) = g_t \cdot P_{\text{copiar}} + (1 - g_t) \cdot P_{\text{generar}}. \quad (2)$$

La compuerta se aprende de extremo a extremo: el modelo aprende cuándo repetir y cuándo explorar. Nuestra aproximación reproducible (`src/models/repeatnet.py`) captura los principios clave sin el componente GRU: una rama *repeat* que combina recencia y frecuencia del historial, una rama *explore* que usa probabilidades de transición entre ítems y popularidad global, y una compuerta por usuario estimada a partir de la tasa histórica de repetición.

2.3 PISA (RecSys 2024)

PISA [8] (*Transformers Meet ACT-R*) integra dos componentes. El **componente ACT-R**, basado en la teoría cognitiva *Adaptive Control of Thought–Rational* [1], modela la memoria episódica como

activaciones que decaen con el tiempo y se refuerzan con repeticiones. Para cada ítem i en el historial del usuario u , la activación en el instante T es:

$$A_i(T) = \ln \left(\sum_{k: t_k \leq T} (T - t_k)^{-d} \right), \quad (3)$$

donde t_k son los instantes de escucha pasados del ítem i y $d > 0$ es el parámetro de decaimiento. El **componente Transformer** procesa la secuencia con auto-atención, incorporando las activaciones ACT-R como sesgo temporal. PISA supera a modelos puramente secuenciales (SASRec, GRU4Rec) en streaming musical con alta tasa de repetición. Nuestra aproximación (`src/models/pisa.py`) implementa la activación ACT-R sobre el historial, más señal de contexto de sesión (co-ocurrencias) y un prior de popularidad global, combinados linealmente con pesos ($w_{\text{act}}, w_{\text{ctx}}, w_{\text{pop}}$) optimizados en validación; prescinde del Transformer para mantener la reproducibilidad sin entrenamiento neuronal profundo.

3 Metodología

3.1 Dataset

Last.fm 1K Users [2] contiene 19.098.853 eventos de escucha de 992 usuarios activos, registrados con marca de tiempo. El dataset no incluye calificaciones explícitas: cada fila es un evento $(u, \text{artista}, \text{pista}, t)$.

Preprocesamiento. El TSV original (2.5 GB) contiene columnas `artist_id` y `track_id` con 69.000 NaN (IDs MusicBrainz faltantes). Para evitar propagación de nulos se construye una clave determinista `item_id = "<artist_name> - <track_name>"`. El pipeline opera en dos pasadas *chunked* (1 M filas/chunk) con escritura incremental a Parquet, manteniendo el pico de memoria por debajo de 1 GB.

Subsets experimentales. El **subset H1 (desarrollo)** toma 100 usuarios $\times$ 2000 reproducciones (últimas) 200.000 interacciones, 88.234 ítems únicos, usado para desarrollo rápido y búsqueda de hiperparámetros. El **dataset completo (validación)** tiene 992 usuarios y 19.098.853 interacciones, evaluado mediante submuestreo (Sección 5.4).

3.2 Protocolo de evaluación

Split temporal leave-one-out (LOO): para cada usuario u la última interacción cronológica se reserva como *ground truth* de test; el resto del historial conforma el entrenamiento. Bajo el paradigma *repeat-aware*, el catálogo de candidatos no filtra el historial del usuario. Las métricas ($K = 10$) son:

$$\text{Recall@10}_u = \mathbb{1}[i_u^* \in L_u^{10}], \quad \text{nDCG@10}_u = \frac{\mathbb{1}[i_u^* \in L_u^{10}]}{\log_2(\text{rank}_u(i_u^*) + 1)}, \quad (4)$$

$$\text{MRR} = \frac{1}{|\mathcal{U}|} \sum_u \frac{1}{\text{rank}_u(i_u^*)}, \quad \text{RepeatRatio}(L_u^{10}) = \frac{|\{i \in L_u^{10} : i \in \mathcal{H}_u\}|}{10}, \quad (5)$$

donde i_u^* es el ítem de test y L_u^{10} la lista top-10 recomendada. nDCG@10 es sensible a la posición, lo que la hace más informativa que Recall@10 en el escenario *repeat-aware*. RepeatRatio es una métrica diagnóstica del sesgo *explore/repeat*, no de la calidad.

3.3 Modelos evaluados

Baselines no repeat-aware: *Random* (muestreo uniforme, semilla 42), *MostPopular* (frecuencia global), *SimpleRepeat-Freq* (historial por frecuencia acumulada, *fallback* a popularidad) y *SimpleRepeat-Recency* (historial en orden cronológico inverso; captura la localidad temporal).

Table 1: Distribución de intervalos entre repeticiones (subset H1). La masa a corto plazo y la cola larga motivan una ventana W_u por usuario.

Estadístico	Valor (horas)
p_{25}	1.74
Mediana (p_{50})	27.04
p_{75}	160.67
Media	175.05
Máximo	13 503.65

Temporal BPR (T-BPR) — contribución propia. T-BPR extiende BPR-MF reemplazando el muestreo negativo uniforme por una distribución dependiente del tiempo. Para cada interacción positiva (u, i, t) , el ítem negativo j se muestrea con peso:

$$p(j \mid u, t) \propto \begin{cases} \alpha & \text{si } j \in \mathcal{H}_u \text{ y } \Delta_{uj}(t) \in W_u, \\ 1 & \text{si } j \notin \mathcal{H}_u, \\ \beta & \text{en otro caso,} \end{cases} \quad 0 < \alpha < 1 < \beta, \quad (6)$$

donde $\Delta_{uj}(t) = t - t_{uj}^{\text{last}}$ es el intervalo desde la última escucha de j por u , y $W_u = (p_{\text{low}}^u, p_{\text{high}}^u)$ es la ventana de repetición óptima del usuario, calibrada por los percentiles de su distribución empírica de intervalos entre repeticiones. *Intuición:* si un ítem ya consumido cae dentro de la ventana en que el usuario suele repetir, no se penaliza como negativo duro (peso $\alpha < 1$); si cae fuera, se penaliza con peso $\beta > 1$. BPR estándar se recupera con $\alpha = \beta = 1$. El score final combina la factorización aprendida con un boost de recencia y una activación temporal tipo ACT-R, seguido de calibración del Repeat Ratio objetivo.

Aproximaciones de RepeatNet y PISA. Se implementan aproximaciones reproducibles de ambos modelos (§2.2–§2.3) que capturan sus principios algorítmicos clave sin el componente de red neuronal profunda.

4 Análisis descriptivo

Tasa global de repetición. Sobre el subset H1 la tasa global de repetición es 60.43 %. Sin embargo, cuando se aísla la última interacción de cada usuario (test bajo LOO), sólo el 33 % es un *repeat*: los eventos terminales tienden a ser más exploratorios que el promedio, lo que hace el problema más difícil que la tasa global sugiere.

Distribución de intervalos. Sobre las 87 985 instancias de repetición identificadas (Tabla 1), el 50 % de las repeticiones ocurre dentro de las primeras 27 horas. La cola larga (> 160 h, hasta 562 días) revela ítems “favoritos persistentes”. Esta dualidad justifica calibrar la ventana W_u por usuario en lugar de una constante global.

Heterogeneidad inter-usuario. La tasa de repetición individual varía entre 3.2 % y 98.2 % (media 0.604, std 0.207): coexisten usuarios “exploradores” y “loopers”, de modo que ninguna política única puede operar eficientemente sobre toda la población.

Correlación frecuencia $\leftrightarrow$ reaparición. Partiendo el historial en mitad pasada y futura, el coeficiente de Spearman entre la frecuencia histórica de un ítem y su reaparición es $\rho_{\text{Spearman}} = 0.284$ ($p < 10^{-300}$, $n = 64018$): positivo pero moderado-débil. Esto motiva combinar frecuencia con recencia en los modelos avanzados.

Table 2: Comparación de modelos sobre subset H1 ($K = 10$, run_id: 20260701T). La recencia pura es un baseline muy fuerte; T-BPR ofrece el mejor balance *repeat/explore* (Repeat Ratio cercano a la tasa empírica 0.33).

Modelo	Recall@10	nDCG@10	MRR	Repeat Ratio	Hits
Random	0.0000	0.0000	0.0000	0.009	0/100
MostPopular	0.0000	0.0000	0.0000	0.055	0/100
SimpleRepeat-Freq	0.0000	0.0000	0.0000	0.055	0/100
SimpleRepeat-Recency	0.0900	0.0667	0.0597	1.000	9/100
RepeatNet	0.0800	0.0374	0.0247	0.267	8/100
PISA	0.0900	0.0673	0.0604	0.992	9/100
TemporalBPR	0.0700	0.0596	0.0564	0.507	7/100

Table 3: Búsqueda de hiperparámetros de T-BPR —validación *rolling* (offsets {2, 3, 4}, $K = 10$). La mejor configuración (C6) no supera al baseline de recencia en ranking. *rec. b.* = recency_boost; *trr* = target_repeat_ratio.

Config	factors	lr	epochs	α	β	rec. b. / trr	rolling nDCG@10
Baseline: SR-Recency	—	—	—	—	—	— / —	0.0825
C1	32	0.010	10	0.70	1.20	0.9 / 0.35	0.0536
C2	48	0.012	12	0.80	1.15	1.1 / 0.35	0.0610
C3	64	0.012	16	0.90	1.10	1.5 / 0.35	0.0635
C4	64	0.008	14	0.85	1.10	1.2 / 0.33	0.0576
C5	96	0.010	14	0.90	1.10	1.4 / 0.35	0.0667
C6	48	0.015	12	0.80	1.20	1.0 / 0.30	0.0669

5 Experimentación y resultados

5.1 Comparación principal de modelos (subset H1, 100 usuarios)

Todos los modelos se evalúan bajo el mismo protocolo LOO temporal sobre el subset H1 (train = 199 900 interacciones, test = 100 usuarios); ver Tabla 2.

Observaciones. (1) *Recencia domina sobre frecuencia*: SimpleRepeat-Freq obtiene 0 hits pese a que el 33 % de los ítems de test provienen del historial (el ítem de test ocupa la posición mediana 221 en el ranking por frecuencia), mientras SimpleRepeat-Recency alcanza Recall@10 = 0.09 sólo reordenando por recencia. (2) PISA y SimpleRepeat-Recency empatan en Recall@10 (0.09), con PISA levemente mejor en nDCG/MRR pero casi tan *repeat-only* (Repeat Ratio 0.992 vs 1.000). (3) *T-BPR ofrece el mejor balance*: con Repeat Ratio 0.507 calibra la mezcla hacia la tasa empírica de la última interacción (33 %), con nDCG/MRR competitivos. (4) RepeatNet logra buen Recall (0.08) pero nDCG/MRR inferiores (hits en posiciones más bajas).

5.2 Búsqueda de hiperparámetros de T-BPR

Se realizó una búsqueda en grilla sobre 6 configuraciones mediante validación temporal *rolling* con offsets {2, 3, 4}: cada offset reserva la interacción $n - \text{offset}$ como validación y promedia los tres folds. La configuración ganadora por nDCG@10 se reentrena con train + validación y se evalúa sobre la última interacción (Tabla 3).

La configuración ganadora **C6** (factors=48, lr=0.015, epochs=12, alpha=0.8, beta=1.2, recency_boost=1.0, target_repeat_ratio=0.30), reentrenada y evaluada en test, alcanza Recall@10 = 0.060, nDCG@10 = 0.0563, MRR = 0.055 y Repeat Ratio = 0.431 (6/100 hits); queda persistida en data/tbpr_best_config.json. **Hallazgos:** (1) T-BPR no supera al baseline de recencia en ranking (C6: rolling nDCG@10 = 0.0669 vs 0.0825, −19 %; Recall@10 −24 %), y ninguna configuración cierra la brecha. (2) El valor de T-BPR está en la calibración *repeat/explore*: C6 mantiene Repeat Ratio 0.431 (vs 1.000 del baseline), cediendo ~1.6 puntos de nDCG por una política no degenerada que preserva la exploración. (3) Retornos

Table 4: Costo de cómputo (subset H1, CPU). Los tiempos de T-BPR son medidos; los de PISA/RepeatNet se caracterizan por su complejidad (una pasada, sin entrenamiento iterativo).

Modelo	Paradigma	Entrenamiento	Complejidad	Costo (H1)
SimpleRepeat-Recency	Conteo + orden cronológico	Ninguno	—	< 1 s
MostPopular	Frecuencia global	Ninguno	—	< 1 s
PISA (aprox.)	ACT-R + contexto (numpy)	Ninguno	$O(D)$	segundos (est.)
RepeatNet (aprox.)	Recencia/frec. + transición	Ninguno	$O(D)$	segundos (est.)
T-BPR	BPR-MF + muestreo neg. temporal	Iterativo (SGD)	$O(\text{ep} \cdot D \cdot f)$	$\approx 150\text{--}320$ s

decrecientes en capacidad: C6 (factors=48) y C5 (factors=96) empatan en nDCG, señalando que la señal aprovechable proviene del muestreo negativo temporal, no de la dimensión latente.

5.3 Análisis de sensibilidad del intervalo W_u (protocolo reproducible)

El parámetro de diseño central es la ventana $W_u = (p_{\text{low}}^u, p_{\text{high}}^u)$. Por defecto se usa (p_{25}, p_{75}) , no validada empíricamente. El protocolo (`src/sensitivity_analysis.py`) varía $p_{\text{low}} \in \{10, \dots, 40\}$ y $p_{\text{high}} \in \{60, \dots, 90\}$, evaluando las 49 combinaciones válidas bajo LOO temporal y produciendo un mapa de calor de nDCG@10. El barrido cuesta ~ 300 s por combinación en CPU (≈ 4 h total), por lo que no se ejecutó en esta corrida y se documenta como protocolo reproducible; su omisión no afecta las conclusiones de §5.1–§5.2.

5.4 Evaluación escalada: submuestreo de 992 usuarios

Para estimar el desempeño sobre el dataset completo se realiza el split LOO sobre los 992 usuarios y 5 rondas de submuestreo (100 usuarios cada una, semillas 42–46), promediando las métricas. El submuestreo con el T-BPR seleccionado implica 5 entrenamientos completos y no se ejecutó en esta corrida; se reporta como protocolo reproducible (`src/run_scaled_evaluation.py`, `data/lastfm_1k_complete_fixed.parquet`). La comparación sobre H1 (§5.1) sigue siendo la evidencia empírica principal. El subset H1 (top-100 por actividad) sobrerrepresenta usuarios muy activos; el submuestreo aleatorio genera una estimación más representativa del desempeño medio.

5.5 Tiempos de ejecución y complejidad

T-BPR es el único que entrena de forma iterativa (SGD sobre triplas BPR); las aproximaciones de PISA y RepeatNet son *scorers* heurísticos de una sola pasada (Tabla 4). El costo de T-BPR escala con $\text{epochs} \times |D| \times \text{factors}$: ~ 150 s (C1) a ~ 320 s (C3), con C6 en ≈ 230 s. Las heurísticas se ubican uno o dos órdenes de magnitud por debajo ($O(|D|)$) para poblar activaciones/transiciones). En inferencia los tres restringen el scoring a los candidatos del usuario, con latencia comparable; la diferencia decisiva está en el ajuste.

5.6 Dificultad de implementación e infraestructura

El PISA original acopla un Transformer a un módulo ACT-R (framework de DL, GPU); RepeatNet requiere un GRU con mecanismo de copia (GPU). Nuestras aproximaciones capturan los principios algorítmicos con numpy puro, en CPU y de forma determinista: la barrera baja de “cluster con GPU” a “portátil”. T-BPR se ubica en un punto intermedio (requiere un muestreador negativo dependiente del tiempo, la calibración de W_u y el boost de recencia) pero permanece en numpy/CPU; su costo principal es de tiempo de cómputo (§5.5), no de infraestructura.

6 Discusión

Los resultados obtenidos sobre el subconjunto de los 100 usuarios más activos (H1) demuestran que la capacidad predictiva supera con creces el nivel de azar. En un escenario con $\sim 88\,000$ ítems y $K = 10$, la probabilidad aleatoria de acierto es $\sim 1.1 \times 10^{-4}$; en este contexto, un Recall@10 de 0.09 representa un desempeño $\sim 800\times$ superior al azar. Al evaluar bajo el esquema *Leave-One-Out* (LOO), se observa que la última interacción corresponde a un consumo repetido en el 33 % de los casos, de los cuales el modelo más destacado logra identificar 9/33 ($\sim 27\%$ de precisión condicional). La principal limitación de estos experimentos radica en el uso exclusivo de este subconjunto H1 (Tabla 2), el cual sobrerrepresenta historiales densos donde la variable temporal tiene un peso desproporcionado. Por consiguiente, aplicar un submuestreo sobre la cohorte completa de 992 usuarios (§5.4) constituye el paso natural para cuantificar la capacidad de generalización del sistema. A partir de este marco, el análisis arroja las siguientes conclusiones:

- **Dominancia de la señal temporal (recencia):** La proximidad en el tiempo determina de forma crítica el siguiente consumo. Esta premisa se confirma tanto en la distribución de intervalos (el 50 % de las interacciones ocurre en < 27 h) como en el contraste de los modelos base, donde *SimpleRepeat-Recency* supera drásticamente a *SimpleRepeat-Freq* (9 frente a 0 aciertos). En consecuencia, los enfoques que omiten el orden temporal son incapaces de predecir el ítem objetivo.
- **Compromiso (*trade-off*) en el modelo T-BPR:** T-BPR demuestra ser la arquitectura que mejor equilibra la dicotomía *repeat/explore*. Frente a modelos como PISA y *SimpleRepeat-Recency*, que colapsan en políticas degeneradas (*Repeat Ratio* > 0.99), T-BPR alcanza ratios de 0.507/0.431, aproximándose a la tasa empírica del 33 %. Aunque la validación *rolling* evidencia que esto tiene un costo en la precisión del ranking ($\sim 19\%$ menos nDCG@10 y $\sim 24\%$ menos Recall@10 respecto al *baseline*), la lectura metodológica correcta es que T-BPR sacrifica aciertos puntuales para preservar la exploración, permitiendo además controlar explícitamente este balance mediante el hiperparámetro `target_repeat_ratio`.

7 Trabajo futuro

Modelo híbrido repeat/explore. Un clasificador de segundo nivel (regresión logística o árbol) decide, para cada par $(u, t + 1)$, si delegar en el sub-recomendador *repeat* (*SimpleRepeat-Recency*) o *explore* (iALS), usando como features $r_u, \tau_{u,t}, \log \hat{\Delta}_u$ y $|H_u^{30d}|$. El diagrama del modelo fue generado con asistencia de IA generativa y se indica explícitamente en la documentación del repositorio. **Validación en Amazon Reviews — Grocery & Gourmet Food** [3], con régimen temporal contrastante (recompra estacional), reutilizando el pipeline Parquet. **SASRec** [5] y **GRU4Rec** [4] como baselines secuenciales (disponibles en RecBole [9]) para separar la contribución del componente temporal del modelado secuencial.

8 Conclusiones

Presentamos T-BPR, una extensión de BPR con muestreo negativo dependiente del tiempo que modela la dinámica de reconsumo. Sobre Last.fm 1K Users: (1) la señal temporal de recencia es más informativa que la frecuencia (0.09 vs 0.00 Recall@10) y es un baseline que T-BPR no supera en ranking; (2) el aporte de T-BPR es la calibración *repeat/explore* (*Repeat Ratio* 0.43–0.51 vs > 0.99) a costa de una caída acotada ($\sim 19\%$ nDCG@10); (3) las aproximaciones de PISA/RepeatNet reproducen los principios originales con un stack numpy/CPU liviano; (4) la búsqueda con validación *rolling* cuantifica el efecto de las decisiones de diseño y el análisis de sensibilidad de W_u queda como protocolo reproducible. El código está disponible en <https://github.com/Couyoumdjian13/Analisis-Last.fm-1K-Users>.

Acknowledgments and Disclosure of Funding

Trabajo desarrollado en el curso IIC3633 (Sistemas Recomendadores, 2026-1), Pontificia Universidad Católica de Chile. Agradecemos al profesor Denis Parra por la conducción del curso y al ayudante Alejandro Plaza por su valioso feedback sobre el poster y sus aportes a lo largo del semestre.

References

- [1] J. R. Anderson and C. Lebiere. *The Atomic Components of Thought*. Lawrence Erlbaum Associates, 1998.
- [2] O. Celma. *Music Recommendation and Discovery in the Long Tail*. Springer, 2010. Dataset Last.fm 1K Users.
- [3] R. He and J. McAuley. Ups and downs: Modeling the visual evolution of fashion trends with one-class collaborative filtering. In *WWW*, 2016. Dataset Amazon Reviews.
- [4] B. Hidasi, A. Karatzoglou, L. Baltrunas, and D. Tikk. Session-based recommendations with recurrent neural networks. In *ICLR*, 2016.
- [5] W.-C. Kang and J. McAuley. Self-attentive sequential recommendation. In *ICDM*, 2018.
- [6] P. Ren, Z. Chen, J. Li, Z. Ren, J. Ma, and M. de Rijke. RepeatNet: A repeat aware neural recommendation machine for session-based recommendation. In *AAAI*, volume 33, pages 4806–4813, 2019.
- [7] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme. BPR: Bayesian personalized ranking from implicit feedback. In *UAI*, pages 452–461, 2009.
- [8] V.-A. Tran, G. Salha-Galvan, B. Sguerra, and R. Hennequin. Transformers meet ACT-R: Repeat-aware and sequential listening session recommendation. In *RecSys*, 2024.
- [9] W. X. Zhao et al. RecBole: Towards a unified, comprehensive and efficient framework for recommendation algorithms. In *CIKM*, 2021.

A Estructura del repositorio y reproducibilidad

```
Analisis-Last.fm-1K-Users/
|-- data/                                # Datasets procesados y resultados (ignorados por git)
|   |-- lastfm_100_users_h1_fixed.parquet
|   |-- lastfm_1k_complete_fixed.parquet
|   |-- baselines_results.csv / repeat_advanced_results.csv / tbpr_results.csv
|   |-- tbpr_tuning_results.csv / sensitivity_interval_results.csv
|   +-- scaled_eval_per_round.csv / scaled_eval_summary.csv
|-- notebooks/
|   |-- preprocessing.py                 # Pipeline chunked Parquet, < 1 GB RAM
|   +-- preprocessing.ipynb             # Notebook exploratorio H1
|-- src/
|   |-- models/
|   |   |-- baselines.py                 # Random, MostPopular, SimpleRepeat-Freq/Recency
|   |   |-- tbpr.py                     # T-BPR con ventana configurable
|   |   |-- pisa.py                     # Aproximacion reproducible de PISA
|   |   +-- repeatnet.py                 # Aproximacion reproducible de RepeatNet
|   |-- evaluation.py                   # split L00 + evaluate_recommender
|   |-- utils.py                       # recall@k, nDCG@k, MRR, repeat_ratio
|   |-- run_baselines.py / run_repeat_advanced.py / run_tbpr.py
|   |-- run_all_models.py               # Orquesta todas las corridas
|   |-- tune_tbpr.py                   # Búsqueda de hiperparametros rolling
|   |-- sensitivity_analysis.py         # Sensibilidad al intervalo W_u
|   +-- run_scaled_evaluation.py        # Evaluacion escalada 992 usuarios
|-- docs/ (Informe_Final.md, H2_Midterm.md, figures/)
+-- README.md
```

Pasos de reproducción:

<code>python notebooks/preprocessing.py</code>	# 1. Preprocesamiento (TSV original en data/)
<code>python src/run_baselines.py</code>	# 2. Baselines
<code>python src/run_repeat_advanced.py</code>	# 3. T-BPR, PISA, RepeatNet
<code>python src/tune_tbpr.py</code>	# 4. Búsqueda de hiperparametros de T-BPR
<code>python src/sensitivity_analysis.py</code>	# 5. Sensibilidad sobre el intervalo W_u
<code>python src/run_scaled_evaluation.py</code>	# 6. Evaluacion escalada sobre 992 usuarios
<code>python src/run_all_models.py</code>	# 7. Corrida consolidada con run_id compartido

NeurIPS Paper Checklist

1. Claims

Question: Do the main claims made in the abstract and introduction accurately reflect the paper’s contributions and scope?

Answer: [\[Yes\]](#)

Justification: El resumen y la §1.2 declaran con precisión las contribuciones (T-BPR, aproximaciones reproducibles, análisis descriptivo y protocolos), y los resultados (§5, §8) confirman explícitamente que T-BPR *no* supera al baseline de recencia en ranking, evitando sobre-afirmar.

Guidelines:

- The answer [\[N/A\]](#) means that the abstract and introduction do not include the claims made in the paper.
- The abstract and/or introduction should clearly state the claims made, including the contributions made in the paper and important assumptions and limitations. A [\[No\]](#) or [\[N/A\]](#) answer to this question will not be perceived well by the reviewers.
- The claims made should match theoretical and experimental results, and reflect how much the results can be expected to generalize to other settings.
- It is fine to include aspirational goals as motivation as long as it is clear that these goals are not attained by the paper.

2. Limitations

Question: Does the paper discuss the limitations of the work performed by the authors?

Answer: [\[Yes\]](#)

Justification: La Sección 6 (“Limitación principal”) señala que los experimentos usan el subset H1 (100 usuarios más activos), que sobrerrepresenta historiales densos; además §5.2 documenta que T-BPR queda $\sim 19\%$ por debajo del baseline de recencia y §5.3–§5.4 declaran los barridos no ejecutados como protocolos reproducibles.

Guidelines:

- The answer [\[N/A\]](#) means that the paper has no limitation while the answer [\[No\]](#) means that the paper has limitations, but those are not discussed in the paper.
- The authors are encouraged to create a separate “Limitations” section in their paper.
- The paper should point out any strong assumptions and how robust the results are to violations of these assumptions.
- The authors should reflect on the scope of the claims made, e.g., if the approach was only tested on a few datasets or with a few runs.
- The authors should reflect on the factors that influence the performance of the approach.
- The authors should discuss the computational efficiency of the proposed algorithms and how they scale with dataset size.
- If applicable, the authors should discuss possible limitations of their approach to address problems of privacy and fairness.

- While the authors might fear that complete honesty about limitations might be used by reviewers as grounds for rejection, a worse outcome might be that reviewers discover limitations that aren't acknowledged in the paper.

3. Theory assumptions and proofs

Question: For each theoretical result, does the paper provide the full set of assumptions and a complete (and correct) proof?

Answer: [N/A]

Justification: El trabajo es empírico. Las ecuaciones (pérdida BPR, activación ACT-R, distribución de muestreo de T-BPR, métricas) son definiciones y no teoremas; no se enuncian resultados teóricos que requieran demostración.

Guidelines:

- The answer [N/A] means that the paper does not include theoretical results.
- All the theorems, formulas, and proofs in the paper should be numbered and cross-referenced.
- All assumptions should be clearly stated or referenced in the statement of any theorems.
- The proofs can either appear in the main paper or the supplemental material, but if they appear in the supplemental material, the authors are encouraged to provide a short proof sketch to provide intuition.
- Inversely, any informal proof provided in the core of the paper should be complemented by formal proofs provided in appendix or supplemental material.
- Theorems and Lemmas that the proof relies upon should be properly referenced.

4. Experimental result reproducibility

Question: Does the paper fully disclose all the information needed to reproduce the main experimental results of the paper to the extent that it affects the main claims and/or conclusions of the paper (regardless of whether the code and data are provided or not)?

Answer: [Yes]

Justification: Se describe el protocolo LOO temporal (§3.2), el preprocesamiento determinista, la grilla de hiperparámetros y semillas (§5.2), y el Anexo A lista la estructura del repositorio y los comandos exactos de reproducción; la configuración ganadora queda persistida en `data/tbpr_best_config.json`.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- If the paper includes experiments, a [No] answer to this question will not be perceived well by the reviewers.
- If the contribution is a dataset and/or model, the authors should describe the steps taken to make their results reproducible or verifiable.
- Depending on the contribution, reproducibility can be accomplished in various ways.
- While NeurIPS does not require releasing code, the conference does require all submissions to provide some reasonable avenue for reproducibility.

5. Open access to data and code

Question: Does the paper provide open access to the data and code, with sufficient instructions to faithfully reproduce the main experimental results, as described in supplemental material?

Answer: [Yes]

Justification: El código es público (<https://github.com/Couyoumdjian13/Analisis-Last.fm-1K-Users>) con scripts de preprocesamiento y evaluación; el

dataset Last.fm 1K Users es público [2]. Los archivos de datos derivados se excluyen del control de versiones, pero el pipeline para regenerarlos desde el TSV original se documenta en el Anexo A.

Guidelines:

- The answer [N/A] means that paper does not include experiments requiring code.
- Please see the NeurIPS code and data submission guidelines (<https://neurips.cc/public/guides/CodeSubmissionPolicy>) for more details.
- While we encourage the release of code and data, we understand that this might not be possible, so [No] is an acceptable answer.
- The instructions should contain the exact command and environment needed to run to reproduce the results.
- The authors should provide instructions on data access and preparation.
- The authors should provide scripts to reproduce all experimental results for the new proposed method and baselines.
- Providing as much information as possible in supplemental material is recommended, but including URLs to data and code is permitted.

6. Experimental setting/details

Question: Does the paper specify all the training and test details (e.g., data splits, hyperparameters, how they were chosen, type of optimizer) necessary to understand the results?

Answer: [Yes]

Justification: El split temporal LOO (§3.2), la validación *rolling* con offsets {2, 3, 4}, el optimizador (SGD sobre triplas BPR), la grilla de hiperparámetros y la configuración ganadora se detallan en §5.1–§5.2 y Tabla 3.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The experimental setting should be presented in the core of the paper to a level of detail that is necessary to appreciate the results.
- The full details can be provided either with the code, in appendix, or as supplemental material.

7. Experiment statistical significance

Question: Does the paper report error bars suitably and correctly defined or other appropriate information about the statistical significance of the experiments?

Answer: [No]

Justification: Las métricas principales (Tabla 2) se reportan como valores puntuales sobre el subset H1 sin barras de error; la validación *rolling* promedia tres folds pero no reporta intervalos de confianza. El protocolo de submuestreo de 5 rondas (§5.4), diseñado precisamente para estimar variabilidad, se documenta como reproducible pero no se ejecutó por costo computacional.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The authors should answer [Yes] if the results are accompanied by error bars, confidence intervals, or statistical significance tests.
- The factors of variability that the error bars are capturing should be clearly stated.
- The method for calculating the error bars should be explained.
- The assumptions made should be given (e.g., Normally distributed errors).
- It should be clear whether the error bar is the standard deviation or the standard error of the mean.

- It is OK to report 1-sigma error bars, but one should state it.
- For asymmetric distributions, be careful not to show symmetric error bars out of range.
- If error bars are reported, the authors should explain in the text how they were calculated.

8. Experiments compute resources

Question: For each experiment, does the paper provide sufficient information on the computer resources (type of compute workers, memory, time of execution) needed to reproduce the experiments?

Answer: [Yes]

Justification: La Sección 5.5 (Tabla 4) reporta ejecución en CPU sin GPU, con tiempos medidos de T-BPR ($\approx 150\text{--}320$ s por entrenamiento) y el pico de memoria del preprocesamiento (< 1 GB, §3.1); las heurísticas se caracterizan como $O(|D|)$ de una sola pasada.

Guidelines:

- The answer [N/A] means that the paper does not include experiments.
- The paper should indicate the type of compute workers CPU or GPU, internal cluster, or cloud provider, including relevant memory and storage.
- The paper should provide the amount of compute required for each of the individual experimental runs as well as estimate the total compute.
- The paper should disclose whether the full research project required more compute than the experiments reported in the paper.

9. Code of ethics

Question: Does the research conducted in the paper conform, in every respect, with the NeurIPS Code of Ethics <https://neurips.cc/public/EthicsGuidelines>?

Answer: [Yes]

Justification: La investigación usa un dataset público y anonimizado de escuchas musicales, no involucra sujetos humanos ni datos sensibles, y respeta las licencias de los recursos utilizados.

Guidelines:

- The answer [N/A] means that the authors have not reviewed the NeurIPS Code of Ethics.
- If the authors answer [No], they should explain the special circumstances that require a deviation from the Code of Ethics.
- The authors should make sure to preserve anonymity (e.g., if there is a special consideration due to laws or regulations in their jurisdiction).

10. Broader impacts

Question: Does the paper discuss both potential positive societal impacts and negative societal impacts of the work performed?

Answer: [Yes]

Justification: La discusión (§6) aborda directamente el trade-off social relevante: los modelos puramente repetitivos (Repeat Ratio ≈ 1) maximizan el hit inmediato pero degradan el descubrimiento, mientras que T-BPR preserva explícitamente la exploración mediante `target_repeat_ratio`, mitigando efectos de burbuja de filtro.

Guidelines:

- The answer [N/A] means that there is no societal impact of the work performed.
- If the authors answer [N/A] or [No], they should explain why their work has no societal impact.

- Examples of negative societal impacts include potential malicious or unintended uses, fairness, privacy, and security considerations.
- The conference expects that many papers will be foundational research and not tied to particular applications.
- The authors should consider possible harms under intended use, incorrect results, and misuse.
- If there are negative societal impacts, the authors could also discuss possible mitigation strategies.

11. **Safeguards**

Question: Does the paper describe safeguards that have been put in place for responsible release of data or models that have a high risk for misuse (e.g., pre-trained language models, image generators, or scraped datasets)?

Answer: [N/A]

Justification: No se libera ningún modelo o dataset de alto riesgo de uso indebido; el artefacto liberado es un recomendador musical liviano entrenado sobre un dataset público ya anonimizado.

Guidelines:

- The answer [N/A] means that the paper poses no such risks.
- Released models that have a high risk for misuse or dual-use should be released with necessary safeguards.
- Datasets that have been scraped from the Internet could pose safety risks.
- We recognize that providing effective safeguards is challenging, and many papers do not require this.

12. **Licenses for existing assets**

Question: Are the creators or original owners of assets (e.g., code, data, models), used in the paper, properly credited and are the license and terms of use explicitly mentioned and properly respected?

Answer: [Yes]

Justification: Se citan las fuentes originales de todos los recursos: el dataset Last.fm 1K Users [2], y los métodos de referencia BPR [7], RepeatNet [6], PISA [8] y RecBole [9].

Guidelines:

- The answer [N/A] means that the paper does not use existing assets.
- The authors should cite the original paper that produced the code package or dataset.
- The authors should state which version of the asset is used and, if possible, include a URL.
- The name of the license (e.g., CC-BY 4.0) should be included for each asset.
- For scraped data from a particular source, the copyright and terms of service should be provided.
- If assets are released, the license, copyright information, and terms of use should be provided.
- For existing datasets that are re-packaged, both the original license and the derived license should be provided.
- If this information is not available online, the authors are encouraged to reach out to the asset's creators.

13. **New assets**

Question: Are new assets introduced in the paper well documented and is the documentation provided alongside the assets?

Answer: [\[Yes\]](#)

Justification: Los nuevos artefactos (T-BPR y las aproximaciones reproducibles de PISA/RepeatNet) se documentan en el repositorio con un README y el Anexo A, incluyendo la estructura de módulos y los comandos de ejecución.

Guidelines:

- The answer [\[N/A\]](#) means that the paper does not release new assets.
- Researchers should communicate the details of the dataset/code/model as part of their submissions via structured templates.
- The paper should discuss whether and how consent was obtained from people whose asset is used.
- At submission time, remember to anonymize your assets (if applicable).

14. Crowdsourcing and research with human subjects

Question: For crowdsourcing experiments and research with human subjects, does the paper include the full text of instructions given to participants and screenshots, if applicable, as well as details about compensation (if any)?

Answer: [\[N/A\]](#)

Justification: El trabajo no involucra crowdsourcing ni investigación con sujetos humanos; se emplea exclusivamente un dataset público preexistente de logs de escucha.

Guidelines:

- The answer [\[N/A\]](#) means that the paper does not involve crowdsourcing nor research with human subjects.
- Including this information in the supplemental material is fine, but if the main contribution involves human subjects, then as much detail as possible should be included in the main paper.
- According to the NeurIPS Code of Ethics, workers involved in data collection should be paid at least the minimum wage.

15. Institutional review board (IRB) approvals or equivalent for research with human subjects

Question: Does the paper describe potential risks incurred by study participants, whether such risks were disclosed to the subjects, and whether Institutional Review Board (IRB) approvals (or an equivalent approval/review based on the requirements of your country or institution) were obtained?

Answer: [\[N/A\]](#)

Justification: No se realizó investigación con sujetos humanos, por lo que no se requiere aprobación de un IRB o equivalente.

Guidelines:

- The answer [\[N/A\]](#) means that the paper does not involve crowdsourcing nor research with human subjects.
- Depending on the country in which research is conducted, IRB approval (or equivalent) may be required for any human subjects research.
- We recognize that the procedures for this may vary significantly between institutions and locations.
- For initial submissions, do not include any information that would break anonymity.

16. Declaration of LLM usage

Question: Does the paper describe the usage of LLMs if it is an important, original, or non-standard component of the core methods in this research? Note that if the LLM is used only for writing, editing, or formatting purposes and does *not* impact the core methodology, scientific rigor, or originality of the research, declaration is not required.

Answer: [N/A]

Justification: Ningún LLM forma parte de la metodología central (los modelos son BPR-MF y heurísticas ACT-R/transición en numpy). Se usó IA generativa únicamente como apoyo para un diagrama ilustrativo (§7), lo que se declara explícitamente en el repositorio; ese uso no impacta la metodología ni los resultados.

Guidelines:

- The answer [N/A] means that the core method development in this research does not involve LLMs as any important, original, or non-standard components.
- Please refer to our LLM policy in the NeurIPS handbook for what should or should not be described.