
Los Sistemas Recomendadores Conocen a los Sellos de Advertencia: Modelos Recomendadores de Recetas Consciente de la Nutrición

Catalina Anusch

`catalina.anusch@uc.cl`

Departamento de Ciencias de la
Computación

Pontificia Universidad Católica de
Chile

Santiago, Chile

José Villalobos

`jos.villalobos@uc.cl`

Departamento de Ciencias de la
Computación

Pontificia Universidad Católica de
Chile

Santiago, Chile

Aníbal Villegas

`anibal.villegas@uc.cl`

Departamento de Ciencias de la
Computación

Pontificia Universidad Católica de
Chile

Santiago, Chile

Abstract

Los sistemas de recomendación de comida priorizan tradicionalmente la relevancia basada en el historial del usuario, lo que induce un sesgo hacia alimentos ultraprocesados y de alta densidad calórica. Este trabajo propone un sistema recomendador de recetas *consciente de la nutrición* que integra la Ley de Etiquetado de Alimentos de Chile (Ley 20.606) mediante sellos de advertencia. Sobre el dataset *Food.com Recipes and Reviews* evaluamos cuatro familias de modelos—Content-Based, LightFM, HTFRS y Deep Q-Learning— que integran la señal de salud a través de tres mecanismos distintos: como *features* del *embedding*, como *re-ranking* post-hoc controlable, y como *reward shaping* del agente. Adicionalmente, introducimos: (i) una corrección del tamaño de porción que rectifica la asignación de sellos en recetas de tipo *batch*; (ii) dos estrategias de post-procesamiento híbrido mediante cuotas de salud, una composición balanceada y una cuota con ruido saludable que controlan la composición nutricional de la lista final; y (iii) las métricas propias S@K, SS@K, Diversidad@K y Novedad@K. Los resultados muestran que la integración de sellos como *features* del *embedding* logra el mejor balance entre relevancia y salud, mientras que el *re-ranking* controlable ofrece un ajuste granular sin necesidad de reentrenar el modelo.

Trabajo desarrollado para el curso IIC3633 – Sistemas Recomendadores. Código disponible en <https://github.com/jtvvtj/RecSys-FRR>. Correspondencia a: Catalina Anusch <catalina.anusch@uc.cl>, José Villalobos <jos.villalobos@uc.cl>, Aníbal Villegas <anibal.villegas@uc.cl>.

1. Introducción

Los sistemas recomendadores de comida se han vuelto herramientas relevantes para mitigar la sobrecarga de información en plataformas de recetas. Sin embargo, la mayoría de estos sistemas optimizan únicamente la relevancia respecto a las preferencias históricas del usuario, ignorando el factor nutricional (Rostami et al., 2023). En consecuencia, tienden a reforzar el consumo de alimentos poco saludables, dado que las recetas más populares suelen concentrar altos contenidos de azúcar, sodio, grasas saturadas y calorías.

Nuestra propuesta aborda este problema integrando la **Ley 20.606** de etiquetado nutricional chilena (Ministerio de Salud de Chile, 2019), que asigna *sellos de advertencia* (“ALTO EN”) a los alimentos que superan umbrales por cada 100 g de producto. El objetivo es entregar a cada usuario una lista Top-10 de recetas que *balancee relevancia y salud*.

Este trabajo se basa metodológicamente en el sistema HTFRS de Rostami et al. (2023), adaptando su factor de salud y su mecanismo de recomendación controlable al contexto de los sellos chilenos, y extendiéndolo con cuatro modelos adicionales y un conjunto de métricas orientadas a salud. Las contribuciones principales son:

- La adaptación del *Healthy Factor* de HTFRS a los sellos de la Ley 20.606.
- Una corrección del tamaño de porción que rectifica la asignación de sellos en ~32.500 recetas de tipo *batch*.
- Dos estrategias de post-procesamiento híbrido basadas en cuotas de salud, composición balanceada y cuota con ruido saludable, que controlan la fracción de recetas saludables/con sello en la lista final.
- Cuatro métricas orientadas a salud (S@K, SS@K, Di-

versidad@K, Novedad@K) y un protocolo de evaluación con negativos muestreados.

2. Trabajos Relacionados

2.1. Recomendación de alimentos consciente de la salud

Los sistemas recomendadores de alimentos han evolucionado desde enfoques puramente colaborativos hacia modelos que integran información nutricional. Rostami et al. (2023) proponen HTFRS (*Healthy and Time-aware Food Recommender System*), que combina filtrado colaborativo ponderado temporalmente con un modelo basado en ingredientes, e incorpora un *Healthy Factor* derivado de los rangos de macronutrientes de la OMS. Su formulación permite controlar el balance entre relevancia y salud mediante un parámetro γ sin reentrenar el modelo. Nuestro trabajo adapta esta arquitectura al contexto regulatorio chileno, reemplazando el factor de salud continuo por sellos discretos de la Ley 20.606.

2.2. Modelos híbridos de factorización

Los modelos de factorización híbrida abordan el problema de *cold-start* combinando señales colaborativas y de contenido. Kula (2015) propone LightFM, donde cada ítem se representa como la suma de los *embeddings* de sus *features*, permitiendo incorporar metadata arbitraria. En nuestro trabajo aprovechamos esta capacidad para integrar los sellos nutricionales como *features* binarias del ítem.

2.3. Diversidad y regulación nutricional

La tensión entre relevancia y diversidad en sistemas recomendadores ha sido estudiada recientemente por Chen et al. (2025) en el contexto de modelos basados en LLMs. En el dominio alimentario, esta tensión se manifiesta de forma particular: las recetas saludables se concentran en pocas categorías, de modo que optimizar la salud reduce la diversidad de la lista. Por otra parte, la Ley 20.606 de etiquetado nutricional chilena (Ministerio de Salud de Chile, 2019) establece umbrales por cada 100 g para cuatro nutrientes críticos, proporcionando un marco regulatorio concreto para cuantificar la calidad nutricional de las recomendaciones.

3. Dataset

Utilizamos el dataset público *Food.com Recipes and Reviews*¹. Cada receta incluye nombre, descripción, ingredientes, categoría, información nutricional (calorías, azúcar, grasas saturadas, sodio, etc.) y el tamaño de porción. Tras el preprocesamiento se conservan **257.707 recetas** y **72.099 usuarios**.

¹<https://www.kaggle.com/datasets/irkaal/foodcom-recipes-and-reviews>

Estadísticas	Todo	Filtrado
Cantidad de usuarios	271.907	72.099
Cantidad de recetas	522.359	257.707
Total de ratings	1.401.982	1.202.174
Número promedio de ratings por usuario	5,16	16,67
Número promedio de ratings por recetas	2,68	4,65
Rating promedio	4,41	4,52
Rating Moda	5	5
Desviación estándar de Rating	1,27	1,07
Cantidad más alta de ratings de un usuario	8.842	8.842
Cantidad más alta de ratings de una receta	2.892	2.359
Densidad (%)	0,00 %	0,01 %

Tabla 1. Estadísticas descriptivas del dataset Food.com

Filtrado. Se eliminaron: (i) usuarios con un solo *review* —al no permitir partición *train/test* por usuario—, y (ii) recetas con tamaño de porción nulo o no parseable. Los *ratings* se dividieron en 80 % entrenamiento (959.671) y 20 % prueba (239.918).

Desbalance de ratings. Un desafío propio de Food.com es que el **73,9 %** de las reseñas tienen *rating* 5. Por lo tanto, casi cualquier receta consumida puede considerarse “relevante”, lo que beneficia sistemáticamente a las recetas más populares —que, a su vez, concentran sellos de advertencia. Este sesgo motiva directamente la integración del factor de salud.




Figura 1. Distribución de Ratings

Clustering de recetas. Siguiendo a Rostami et al. (2023), se calcularon ponderaciones *tf-isf* (*Term Frequency-Inverse Recipe Frequency*) sobre los ingredientes para construir un grafo de similitud, sobre el cual se aplicó detección de comunidades *Louvain*. Esto produce clústeres semánticamente coherentes (repostería, panes, pollo, bebidas, etc.) que usamos como categoría $c(f)$ de cada receta f . El conjunto de clústeres se denota $\mathcal{C}$, con $|\mathcal{C}|$ categorías.

4. Preprocesamiento



Figura 2. Límites de Nutrientes en Etiquetado Nutricional

La Ley 20.606 asigna un sello de advertencia por cada nutriente crítico que supere un umbral definido *por cada 100 g* (Ministerio de Salud de Chile, 2019). Dado el valor nutricional X de una receta *por porción* y su tamaño de porción s (gramos), el valor por 100 g es $X/s \times 100$. Los cuatro sellos se definen como indicadores binarios:

$$\text{Cal}(f) = \mathbb{1}\left[\frac{\text{Calorías}}{s} \times 100 \geq 275\right] \quad (1)$$

$$\text{Azúc}(f) = \mathbb{1}\left[\frac{\text{Azúcar}}{s} \times 100 \geq 10\right] \quad (2)$$

$$\text{GSat}(f) = \mathbb{1}\left[\frac{\text{Grasa Sat.}}{s} \times 100 \geq 4\right] \quad (3)$$

$$\text{Sodio}(f) = \mathbb{1}\left[\frac{\text{Sodio}}{s} \times 100 \geq 400\right] \quad (4)$$

El número total de sellos de la receta f es

$$\begin{aligned} \text{sellos}(f) &= \text{Cal}(f) + \text{Azúc}(f) \\ &+ \text{GSat}(f) + \text{Sodio}(f) \in \{0, \dots, 4\}. \end{aligned} \quad (5)$$

La Intersección de Sellos muestra cómo se combinan estos cuatro sellos en las recetas del catálogo: la mayoría de las recetas con advertencias acumula más de un sello simultáneamente, lo que evidencia que los nutrientes críticos tienden a ocurrir.

Intersección de Sellos en las 10,000 Recetas Más Populares




Figura 3. Intersección de Sellos

4.1. Corrección del tamaño de porción

Detectamos que el campo `ExtractedServingSize` no siempre representa el peso de una porción individual: en recetas de tipo *batch* (p. ej. “24 bites”, “16 snacks”) captura el *peso total* del lote, mientras que la información nutricional se reporta *por unidad*. Esto subestima la densidad por 100 g y, por lo tanto, *omite sellos* incorrectamente.

Proponemos una corrección: para recetas con `ConsolidatedServings = 1` cuyo campo `RecipeYield` indica $n > 1$ unidades (excluyendo unidades de peso/volumen como “grams”, “cups”), el tamaño de porción se corrige a

$$s \leftarrow \frac{s}{n}, \quad \text{si } \frac{s}{n} \geq 5 \text{ g.} \quad (6)$$

La condición $s/n \geq 5$ g evita divisiones espúreas. La corrección rectificó **32.496 recetas**, reduciendo la proporción de recetas sin sello del 44,9 % al 39,4 %, un valor consistente con la fracción de alimentos sin sello reportada tras la implementación de la ley en Chile.

5. Metodología

Evaluamos cuatro familias de modelos que representan tres mecanismos de integración de la señal de salud: (a) como *features* en el *embedding* (LightFM), (b) como *re-ranking* post-hoc controlable (HTFRS), y (c) como *reward shaping* del agente (Deep Q-Learning). Content-Based actúa como *baseline* sin salud.

5.1. Content-Based (baseline)

Se construye una representación textual de cada receta concatenando nombre y descripción, vectorizada con *TF-IDF* y reducida con *TruncatedSVD* a 50 dimensiones. La afinidad entre recetas es la similitud coseno $\cos(\mathbf{e}_i, \mathbf{e}_j)$. El perfil del usuario corresponde al promedio de los *embeddings* de su historial, y se recomiendan las recetas más similares no vistas. Este modelo no incorpora la señal de salud.

5.2. LightFM

Modelo de factorización que combina señal colaborativa y de contenido (Kula, 2015). En LightFM cada ítem se representa como la suma de los *embeddings* de sus *features*. Integramos la salud añadiendo los cuatro sellos, agrupados en el conjunto $S = \{\text{Cal}, \text{Azúc}, \text{GSat}, \text{Sodio}\}$, como *features* binarias del ítem, de modo que su *embedding* es

$$\mathbf{q}_f = \mathbf{e}_f^{\text{id}} + \sum_{k \in S} \mathbb{1}[k(f) = 1] \mathbf{e}_k, \quad (7)$$

donde $\mathbf{e}_f^{\text{id}}$ es el *embedding* propio de la receta y $\mathbf{e}_k$ el *embedding* aprendido para el sello k . De este modo el modelo

aprende dimensiones latentes asociadas a las propiedades nutricionales, constituyendo una integración *implícita* de la salud. Por limitaciones de estabilidad de la implementación de BPR en nuestro entorno de ejecución, la factorización se realiza mediante *TruncatedSVD* sobre la matriz usuario-ítem, que preserva la misma semántica de factores latentes. Se comparan dos variantes: *sin sellos* (base) y *con sellos* (híbrido).

5.3. HTFRS-Sellos

Réplica adaptada de Rostami et al. (2023). La predicción de preferencia $p_i^{\text{pref}}(u)$ combina dos señales: un filtrado colaborativo *time-aware* y un modelo basado en ingredientes.

Filtrado colaborativo *time-aware*. Sea $s_{uv} = \text{SimU}(u, v)$ una similitud entre usuarios ponderada temporalmente (las reseñas más recientes reciben mayor peso). La predicción colaborativa para la receta f_i es

$$p_i^{\text{cf}}(u) = \bar{r}(u) + \frac{\sum_{v \in C_u} s_{uv} (r_i(v) - \bar{r}(v))}{\sum_{v \in C_u} |s_{uv}|}, \quad (8)$$

donde C_u es el conjunto de vecinos de u que calificaron f_i y $\bar{r}(u)$ el *rating* promedio de u .

Modelo basado en ingredientes. El peso *tf-isf* del ingrediente Ing_j en la receta f_i es $w_{ij} = \log(M/n_j)$, con M el número de recetas y n_j el de recetas que contienen Ing_j . El peso global del ingrediente se obtiene promediando sobre todas las recetas:

$$w_j = \frac{1}{M} \sum_{i=1}^M w_{ij}. \quad (9)$$

Con estos pesos, la similitud entre recetas se calcula sobre el conjunto de ingredientes I (de tamaño $L = |I|$):

$$\text{SimF}(f_i, f_j) = \sum_{l=1}^L w_l \cdot \text{Sim}_l(f_i, f_j), \quad (10)$$

donde $\text{Sim}_l(f_i, f_j) = \mathbb{1}[\text{Ing}_l \in f_i \cap f_j]$ indica la presencia compartida del ingrediente Ing_l . Esta similitud da lugar a una predicción basada en contenido $p_i^{\text{food}}(u)$ que mitiga el problema de *cold-start*. Ambas señales se combinan mediante un parámetro $\beta \in [0, 1]$:

$$p_i^{\text{pref}}(u) = (1 - \beta) p_i^{\text{cf}}(u) + \beta p_i^{\text{food}}(u). \quad (11)$$

Factor de salud adaptado. A diferencia de Rostami et al. (2023), que deriva el *Healthy Factor* de la distancia a los rangos de macronutrientes de la OMS, nosotros lo definimos directamente a partir de los sellos:

$$\text{HF}(f) = 1 - \frac{\text{sellos}(f)}{4} \in [0, 1], \quad (12)$$

de modo que una receta sin sellos obtiene $\text{HF} = 1$ y una con los cuatro sellos obtiene $\text{HF} = 0$. La recomendación final controlable integra preferencia (Ecuación (11)) y salud mediante el parámetro $\gamma \in [0, 1]$:

$$p_i(u) = (1 - \gamma) p_i^{\text{pref}}(u) + \gamma \cdot 5 \cdot \text{HF}(f_i), \quad (13)$$

donde el factor 5 reescala HF a la escala de *ratings* $[0, 5]$. Con $\gamma = 0$ se ignora la salud; con $\gamma = 1$ se ignora la preferencia.

5.4. Deep Q-Learning

Modelamos la recomendación como un problema de decisión secuencial en el que el agente puntúa recetas del catálogo completo.

Estado. El estado del usuario concatena su *embedding* SVD de la matriz de interacciones (20 dimensiones) y su nivel de salud reciente:

$$\mathbf{s}_u = [\mathbf{z}_u^{(20)} \parallel \overline{\text{sellos}_u}/4] \in \mathbb{R}^{21}. \quad (14)$$

Features de ítem. Cada receta se representa mediante un vector $\phi(f)$ que concatena tres bloques: (i) sus *factores colaborativos* $\mathbf{v}_f^{(20)}$ (los vectores singulares derechos de la misma SVD); (ii) un *embedding* de contenido TF-IDF+SVD (24 dimensiones) de nombre y descripción; y (iii) un conjunto de *features* tabulares (los cuatro sellos, sellos/4, popularidad y *rating*).

Recompensa. La recompensa balancea relevancia y salud mediante el parámetro α , con $\text{rel}(a) = +1$ si $\text{rating} \geq 4$, 0 si es igual a 3, y -1 en otro caso:

$$R(s, a) = \text{rel}(a) - \alpha \cdot \frac{\text{sellos}(a)}{4}. \quad (15)$$

Red Q con producto punto. La red estima $Q(\mathbf{s}_u, \phi(f))$. Dado que un perceptrón multicapa aproxima con dificultad las interacciones multiplicativas, se inyecta explícitamente el producto punto colaborativo usuario-ítem como *feature* adicional:

$$Q(\mathbf{s}_u, \phi(f)) = \text{MLP}([\mathbf{s}_u \parallel \phi(f) \parallel \langle \mathbf{z}_u, \mathbf{v}_f \rangle]). \quad (16)$$

El término $\langle \mathbf{z}_u, \mathbf{v}_f \rangle$ constituye la señal de filtrado colaborativo que habilita la personalización.

Objetivo. El objetivo TD minimiza el error de Bellman, con red objetivo $Q_{\bar{\theta}}$ actualizada periódicamente y un *replay buffer* de experiencias:

$$y = R + \gamma_R \max_{a'} Q_{\bar{\theta}}(\mathbf{s}', \phi(a')), \quad (17)$$

$$\mathcal{L} = \text{Huber}(Q_{\theta}(\mathbf{s}, \phi(a)), y). \quad (18)$$

6. Post-procesamiento por Cuotas de Salud

Sobre el ranking base producido por cualquier modelo aplicamos un re-ranking híbrido que impone una *cuota* explícita sobre la composición nutricional de la lista final R de tamaño $K = 10$. Sea L_u el ranking base del usuario u , H_u su historial, $\mathcal{P}_{\text{sano}} = \{f : \text{sellos}(f) = 0\}$ el conjunto de recetas saludables, $\mathcal{P}_{\text{sello}} = \{f : \text{sellos}(f) \geq 1\}$ su complemento, y c_u^* el clúster dominante de H_u .

El mecanismo reserva m posiciones para un bloque de relevancia B_{rel} (con $|B_{\text{rel}}| = m$) y las $K - m$ restantes para un bloque de salud B_{sano} , construyendo la lista final como

$$R = \pi(B_{\text{rel}} \parallel B_{\text{sano}}), \quad (19)$$

donde $\parallel$ denota concatenación y π una permutación aleatoria uniforme que elimina el sesgo posicional entre bloques. El parámetro de cuota m gobierna el compromiso entre relevancia y salud en la lista entregada. Estudiamos dos configuraciones.

6.1. Composición balanceada ($m = 5$)

El bloque de relevancia toma los cinco ítems mejor rankeados por el modelo, y el bloque de salud, cinco recetas saludables no vistas del clúster dominante:

$$B_{\text{rel}} = \text{primeros } 5 \text{ de } L_u, \quad (20)$$

$$B_{\text{sano}} \subseteq \{f \in \mathcal{P}_{\text{sano}} : c(f) = c_u^*, f \notin H_u\}. \quad (21)$$

Si el clúster dominante no aporta suficientes recetas saludables, el bloque se completa desde $\mathcal{P}_{\text{sano}}$ global.

6.2. Cuota con ruido saludable ($m = 7$)

La composición balanceada tiende a sobrerrepresentar recetas sin sello, inflando la percepción de salud de la lista. Para obtener una composición realista invertimos la cuota: el bloque de relevancia reserva $m = 7$ posiciones para recetas con al menos un sello, y las tres restantes se destinan a recetas saludables que actúan como ruido de contraste:

$$B_{\text{rel}} \subseteq \mathcal{P}_{\text{sello}}, \quad |B_{\text{rel}}| = 7, \quad (22)$$

$$B_{\text{sano}} \subseteq \mathcal{P}_{\text{sano}}, \quad |B_{\text{sano}}| = 3. \quad (23)$$

El llenado de cada bloque sigue un orden jerárquico de prioridad. Para el bloque con sello: (i) recomendaciones del modelo que ya poseen sello; (ii) recetas con sello del clúster dominante; y (iii) cualquier receta con sello. Para el bloque de ruido saludable: (i) recomendaciones saludables del modelo; (ii) recetas saludables del clúster dominante; y (iii) cualquier receta saludable. Esta configuración permite cuantificar la degradación de la relevancia al forzar una mayor presencia de sellos, manteniendo las recetas saludables como una minoría controlada.

6.3. Correspondencia entre listas y métricas

Es importante precisar sobre qué lista se evalúa cada métrica. Las métricas de relevancia y de carga de sellos ($P@K$, $R@K$, $nDCG@K$, $S@K$ y $SS@K$) se calculan sobre el ranking base L_u del modelo, mientras que Diversidad@K y Novedad@K se calculan sobre la lista híbrida R resultante de la Ecuación (19). Por ello, $SS@K$ refleja la salud intrínseca de cada modelo (y no queda fijada por la cuota impuesta), en tanto que Diversidad@K y Novedad@K describen la lista finalmente presentada al usuario.

7. Métricas de Evaluación

Junto con las métricas estándar de *ranking* (Precision@K, Recall@K, $nDCG@K$, $F1@K$ y $MAP@K$, cuyas definiciones son ampliamente conocidas), definimos cuatro métricas propias orientadas a salud, que constituyen el foco de este trabajo. Sea $R = \{r_1, \dots, r_K\}$ la lista recomendada, H_u el historial del usuario, $c(r_i)$ el clúster de la receta r_i , y c_u^* el clúster dominante de H_u . El promedio de sellos y el porcentaje de recetas sin sello son

$$S@K = \frac{1}{K} \sum_{i=1}^K \text{sellos}(r_i), \quad (24)$$

$$SS@K = \frac{1}{K} \sum_{i=1}^K \mathbb{1}[\text{sellos}(r_i) = 0]. \quad (25)$$

La diversidad y la novedad se definen como

$$\text{Div@K} = \frac{|\{c(r_i) : r_i \in R\}|}{K}, \quad (26)$$

$$\text{Nov@K} = \frac{1}{K} \sum_{i=1}^K \mathbb{1} \left[\begin{array}{l} r_i \notin H_u \wedge \text{sellos}(r_i) = 0 \\ \wedge c(r_i) = c_u^* \end{array} \right]. \quad (27)$$

S@K y SS@K miden la salud desde dos ángulos complementarios. $S@K$ ($\downarrow$) promedia la *severidad* nutricional de la lista (número medio de sellos), mientras que $SS@K$ ($\uparrow$) ofrece una lectura binaria y directamente interpretable: la fracción de la lista que un usuario atento a su salud puede consumir sin advertencias. Adoptamos $SS@K$ como indicador principal, pues no se ve atenuada por recetas de severidad intermedia.

Diversidad@K ($\uparrow$) es la fracción de clústeres distintos respecto al *número de recomendaciones* K (y no respecto al total de clústeres del catálogo), penalizando las listas que se concentran en pocas categorías.

Novedad@K ($\uparrow$) exige simultáneamente las tres condiciones (no vista, sin sello y del clúster dominante), pues su objetivo es capturar el *descubrimiento saludable pertinente*: sugerir opciones sanas que el usuario no ha probado pero

que aún se ajustan a su gusto (su clúster dominante), en lugar de recetas saludables arbitrarias o ajenas a sus preferencias.

Evaluación con negativos muestreados. Sobre un catálogo de 234.335 recetas, acertar el ítem exacto de *test* dentro del Top-10 resulta estadísticamente casi imposible, por lo que el nDCG absoluto tiende a cero para cualquier modelo. Con el fin de diagnosticar si el Deep Q-Learning efectivamente aprende a personalizar sobre el catálogo completo, adoptamos el protocolo estándar de *negativos muestreados*: por cada ítem positivo se lo rankea frente a 100 negativos aleatorios, donde una línea base aleatoria produce $HR@10 \approx 0,10$. Este protocolo se emplea únicamente como diagnóstico interno del Deep Q-Learning y no se reporta en la tabla principal de resultados.

8. Análisis de Parámetros

Se realizó un análisis de sensibilidad respecto a los parámetros que controlaban el balance interno entre relevancia y salud. En el caso de HTFRS, $\gamma \in [0, 1]$ controlaba el peso relativo del factor de salud en la predicción final. La Figura 4 muestra la evolución de las métricas al variar γ en $\{0, 0.1, 0.2, 0.3, 0.5, 0.8\}$.




Figura 4. Sensibilidad de γ en HTFRS: Relevancia v/s Salud

Al aumentar γ , la relevancia (nDCG@10) comienza a decaer monótonicamente, mientras que la métrica de salud (SS@10) aumenta de forma significativa. El mayor beneficio marginal ocurre en el primer incremento ($\gamma = 0$ a $\gamma = 0.1$), donde SS@10 sube 0.35 con una caída de solo 0.0016 en nDCG. A partir de $\gamma = 0.5$, las métricas se estabilizaron, siendo $\gamma = 0.5$ y $\gamma = 0.8$ idénticos, indicando que el factor de salud domina completamente el ranking. Revelando así que el rango operativo útil se encontraba en $\gamma \in [0.1, 0.5]$.

Luego, en el caso de Deep Q-Learning, el parámetro $\alpha \in [0, 1]$ controlaba el peso de la penalización por sellos en la función de recompensa. A diferencia de HTFRS, α actuaba durante el *entrenamiento*, lo que requería reentrenar al agente para cada nuevo valor.

La Figura 5 ilustra cómo la métrica S@10 cae abruptamente y SS@10 aumenta velozmente en el tramo de $\alpha = 0$ a $\alpha = 0.25$. No obstante, la relevancia en nDCG exhibe un comportamiento irregular y no monótono. Es fundamental




Figura 5. Sensibilidad de α en Deep Q-Learning: Relevancia v/s Salud

destacar que, a pesar de registrar un leve incremento local en $\alpha = 0.25$ (alcanzando un nDCG de 0.0029), este rendimiento absoluto es críticamente bajo en comparación con el resto de los modelos evaluados.

9. Resultados

Para evaluar la efectividad de la integración de salud, se compararon las mejores configuraciones halladas frente a las versiones puramente basadas en relevancia. Previo a la inyección del factor salud, los modelos base (Content-Based, LightFM base y HTFRS $\gamma = 0$) presentaban en promedio un $S@10 > 1,2$ y un $SS@10 < 36\%$. Es decir, las recetas recomendadas tenían al menos un sello y solo menos del 36 % no presentaba sellos en lo absoluto. Al introducir las penalizaciones nutricionales, cada modelo adoptó un compromiso distinto entre relevancia y salud.

LightFM es quien logró un mejor balance, dado que logró elevar SS@10 del 31,4 % al 95,7 % con una caída en relevancia tan solo de (-0,0024 en nDCG respecto a su versión base). Además, reducir S@10 de 1,226 a 0.047. El agregar los sellos como features binarias del ítem, permitió que el modelo fuera capaz de aprender ciertas dimensiones del vector que corresponden a propiedades nutricionales. Esta integración transparente demuestra que la arquitectura de LightFM es altamente capaz de asimilar propiedades nutricionales como dimensiones latentes de contenido.

Luego, HTFRS destacó por ofrecer el control más flexible post-entrenamiento. Mediante $\gamma: \gamma = 0.2$ alcanza SS@10 = 78 % manteniendo relevancia 0.0102 en nDCG, y $\gamma = 0.5$ maximizó salud (SS@10 = 86 %) sacrificando -0.003 en nDCG respecto a $\gamma = 0$. En este sentido, el ajuste del parámetro γ probó ser un buen enfoque hacia controlar el nivel de salud deseado en la recomendación al momento de re-ranear la lista. Teniendo como fortaleza su adaptabilidad para que un futuro usuario o plataforma lo ajuste de acuerdo a sus prioridades.

Por último, para el caso de Deep Q-Learning, el agente con $\alpha = 0.5$ alcanza SS@10 = 93 % y S@10 = 7 %, alcanzando niveles de salud competitivos para LightFM con sellos,

Tabla 2. Comparación de modelos (Top-10). ↑ mejor mayor, ↓ mejor menor

Modelo	P@10 $\uparrow$	R@10 $\uparrow$	nDCG@10 $\uparrow$	S@10 $\downarrow$	SS@10 $\uparrow$	Div $\uparrow$	Nov $\uparrow$
Content-Based	0.0002	0.0009	0.0011	1.309	0.359	0.481	0.113
LightFM (sin sellos)	0.0051	0.0148	0.0117	1.226	0.314	0.729	0.047
LightFM (con sellos)	0.0044	0.0103	0.0093	0.047	0.957	0.363	0.022
HTFRS ($\gamma = 0$)	0.0027	0.0103	0.0139	1.229	0.342	0.788	0.033
HTFRS ($\gamma = 0.2$)	0.0016	0.0078	0.0102	0.341	0.780	0.477	0.017
HTFRS ($\gamma = 0.5$)	0.0010	0.0047	0.0072	0.261	0.859	0.429	0.017
Deep Q-Learning ($\alpha = 0$)	0.0004	0.0011	0.0007	2.220	0.022	0.629	0.281
Deep Q-Learning ($\alpha = 0.5$)	0.0007	0.0018	0.0014	0.069	0.932	0.419	0.024

pero con nDCG muy bajo. Algo que como se vio en el análisis de sensibilidad no era debido a la penalización de salud, sino a desafíos estructurales frente al dataset. Por un lado, la baja densidad (promedio de 4,65 interacciones por receta) dificulta aprender trayectorias secuenciales robustas. Por otro lado, el 73,9 % de los *ratings* globales son de 5 estrellas, generando una señal de preferencia casi constante. Ante esta señal débil, la penalización por sellos domina la recompensa, forzando al agente a recomendar recetas saludables genéricas en vez de personalizadas. De hecho, su versión base (sin penalización, $\alpha = 0$) ya presentaba un nDCG= 0.0007, el más bajo de toda la evaluación.




Figura 6. Relevancia (nDCG@10) v/s Salud (SS@10)

De esta forma, la frontera de Pareto permite confirmar que el modelo dominante estará determinado por la prioridad del usuario o sistema. Si se exige la máxima relevancia pura, la opción recae en HTFRS base; si se busca maximizar la salud con un deterioro mínimo, LightFM con sellos es la opción superior; y si el objetivo es habilitar un entorno dinámico y controlable, las configuraciones intermedias de HTFRS lideran la frontera.

10. Discusión

Un hallazgo transversal es que mayor SS@10 y menor S@10 se asocia consistentemente a menor Diversidad@10. Esto sugiere que las recetas saludables disponibles se concentran en pocas categorías (ensaladas, sopas, carnes), de modo que empujar la salud reduce la variedad de clústeres ofrecidos. Es una observación importante que revelan los resultados. En el caso de LightFM, vemos que al agregar los sellos, la diversidad se reduce en un 50,2 % (de 0,729 a 0,363). La mayoría de los clústers ofrecidos por la recomendación corresponden a platos que incluyen pollo ('Chicken Breast', 'Chicken Thigh & Leg', 'Chicken'). Pudiéndose deducir que las recetas de pollo son las más sanas, en este caso entonces, las que presentan menos sellos.




Figura 7. Top 20 Clústers en Recetas Recomendadas por LightFM, LightFM [TruncatedSVD (k=20)] — Diversidad y Novedad (K=10)




Figura 8. Diversidad y novedad de LightFM.

En el caso de HTFRS, vemos que a medida que se ajusta γ a mayores valores, tanto diversidad y novedad caen. Progresivamente con γ : de 0,788 ($\gamma = 0$) a 0,429 ($\gamma = 0.5$), se reduce en un 45,5 % la diversidad. Es decir, ambos modelos prueban que ciertas categorías con alta densidad de sellos, como *Dessert*, tenderán a no ser recomendadas. Por lo que las recomendaciones tenderán a ser de categorías de platos más salados que dulces. Como ilustra la Figura 9, las categorías dominantes en las recomendaciones saludables de ambos modelos corresponden a platos proteicos (*Chicken Breast*, *Meat*, *Pork*), evidenciando que el espacio de recetas nutricionalmente válidas no está concentrado en todas las categorías del catálogo. Un usuario cuyo clúster dominante es repostería enfrentará sistemáticamente recomendaciones que tiendan más a otras categorías, porque la mayoría de las recetas disponibles en esa son nutricionalmente deficientes según la Ley 20.606.




Figura 9. Top 20 Clústers en Recetas Recomendadas por HTFRS




Figura 10. Diversidad y novedad de HTFRS

Por último, al evaluar la novedad en las estrategias de restricción híbridas, es crucial notar que el enfoque heurístico de cuotas con $m = 7$ acota por diseño la Novedad@10 a un techo teórico de $\sim 0,30$. Dado que únicamente 3 de los 10 *slots* disponibles en la lista final permiten la inclusión de recetas con sellos de advertencia. Esto debe considerarse al interpretar los valores de novedad para interpretarse como una restricción matemática forzada por las reglas del sistema de filtrado y no como una incapacidad predictiva de los modelos baselines subyacentes.

11. Conclusiones

Presentamos un sistema recomendador de recetas consciente de la nutrición que integra los sellos de la Ley 20.606 chilena mediante tres mecanismos distintos. La evaluación sobre Food.com muestra que LightFM con sellos ofrece el mejor balance relevancia-salud, mientras que HTFRS ofrece la opción de un control granular. Nuestras contribuciones metodológicas: la corrección de porción, el diseño de estrategias de restricción por cuotas, y las métricas orientadas a salud S@K, SS@K, Diversidad@K y Novedad@K son transversales a cualquier modelo base y pueden adoptarse directamente en trabajos futuros sobre recomendación alimentaria consciente de la nutrición.

Por otra parte, los resultados obtenidos estuvieron fundamentalmente acotados por la distribución del dataset. En ese escenario, el trade-off entre salud y diversidad no fue un problema del diseño del recomendador, sino una consecuencia directa de la composición del catálogo que ofrecía el dataset. En este sentido, se abre la posibilidad para futuros trabajos de buscar un factor de salud continuo más allá del conteo discreto de sellos o explorar modelos generativos como LLMs especializados en dominio culinario capaces de adaptar los ingredientes de una receta a las restricciones nutricionales del usuario. Desplazando el problema a no solo buscar las mejores opciones dentro de un catálogo preexistente, sino de reescribir y adaptar dinámicamente los ingredientes de una receta para ajustarse de forma personalizada a las restricciones metabólicas y de salud de un usuario específico.

Referencias

- Chen, J., Gao, C., Yuan, S., Liu, S., Cai, Q., and Jiang, P. Dlrec: A novel approach for managing diversity in llm-based recommender systems, 2025. URL <https://arxiv.org/abs/2408.12470>.
- Kula, M. Metadata embeddings for user and item cold-start recommendations. In *Proceedings of the 2nd Workshop on New Trends on Content-Based Recommender Systems (CBRecSys 2015)*, 2015.
- Ministerio de Salud de Chile. *Manual de Etiquetado Nutricional de Alimentos*. Ministerio de Salud de Chile, 2a edition, 2019. URL <https://minsal.cl>.
- Rostami, M., Farrahi, V., Ahmadian, S., Jalali, S. M. J., and Oussalah, M. A novel healthy and time-aware food recommender system using attributed community detection. *Expert Systems with Applications*, 221:119719, 2023. doi: 10.1016/j.eswa.2023.119719.

Anexos: Ejemplos de Recomendación

En esta sección se presentan ejemplos cualitativos de las recomendaciones generadas por los modelos evaluados.

Usuario ID: 2000967168 **Clúster:** Rice
Diversidad: 0.400 **Novedad:** 0.100

Historial de Consumo (ID - Receta)		Sellos
114337 - Spinach Arancini (Rice Balls)		1
219980 - Best Blueberry Grunt (Dessert)		1
#	Lista de Recomendación (Top-10)	Sellos
1	Spinach Rice – Spanakorizo (Rice)	0
2	Coconut Rice from Zanzibar (Rice)	1
3	Beefy Rice (Rice)	1
4	Spinach Rice Fantastic (Rice)	2
5	wild rice and spinach gratin (Rice)	1
6	Spinach and Rice (Rice)	0
7	Spinach and Rice Appetizers (Rice)	1
8	Spinach With Rice (Rice)	0
9	Spinach Rice Loaf (Rice)	2
10	Leek, Mushroom and Lemon Risotto (Rice)	2

Tabla 3. Ejemplo de recomendación Content-Based.

Usuario ID: 312081 **Clúster:** Chicken Breast
Diversidad: 0.70 **Novedad:** 0.10

Historial de Consumo (ID - Receta)		Sellos
15072 - Perfect Chocolate Brownies		3
93142 - Oven-Fried Almond Chicken		2
394114 - Chocolate Peppermint Bark - Christmas		3
#	Lista de Recomendación (Top-10)	Sellos
1	Oatmeal Raisin Cookies (Drop Cookies)	3
2	Kittencal's Italian Melt-In-Your-Mouth Meatballs (Meat)	0
3	Kittencal's Moist Cheddar-Garlic Oven Fried Chicken (Chicken Breast)	2
4	Pancakes (Breakfast)	2
5	Creamy Cajun Chicken Pasta (Chicken Breast)	1
6	To Die for Crock Pot Roast (One Dish Meal)	0
7	Yes, Virginia There is a Great Meatloaf (Meatloaf)	2
8	Crock Pot Broccoli Cheese Chicken (Chicken Breast)	0
9	Jo Mama's World Famous Spaghetti (Spaghetti)	1
10	Bourbon Chicken (Chicken Breast)	1

Tabla 4. Ejemplo de recomendación LightFM (con sellos).

Usuario ID: 298791 **Clúster:** Breakfast
Diversidad: 0.80 **Novedad:** 0.30

Historial de Consumo (ID - Receta)		Sellos
47780 - Easy Homemade Pancake Syrup (Breakfast)		2
355871 - Blackberry Crunch Bars (Breakfast)		0
357530 - Emergency Chocolate Cake (Dessert)		3
#	Lista de Recomendación (Top-10)	Sellos
1	Creamed spinach with mushrooms and onions (Breakfast)	0
2	Lemon Chicken (Chicken Breast)	1
3	Lemon Chicken-Just Like Take out ! (Chicken)	1
4	Oatmeal Berry Pancakes (Breakfast)	0
5	Scott Hibb's Amazing Whiskey Grilled Bab (Meat)	1
6	Lemon Granola Chicken Salad (Poultry)	1
7	Tangy Ramen Noodle Salad (Vegetable)	1
8	Better Than Olive Garden Pasta Pomodoro (European)	1
9	Corn and Salmon Eggs on Toast (Breakfast)	0
10	Challah I (Braided Egg Bread) (Yeast Breads)	1

Tabla 5. Ejemplo de recomendación Deep Q-Learning.